IMPLEMENTASI *RETRIEVAL AUGMENTED GENERATION* DENGAN PENDEKATAN *HYPOTHETICAL DOCUMENT EMBEDDINGS* PADA SISTEM TANYA JAWAB TENTANG PENYAKIT JANTUNG

Laporan Tugas Akhir

Oleh

ATTARIQ MUHAMMAD AZHAR

NIM: 18221043

PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI

SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA

INSTITUT TEKNOLOGI BANDUNG

Juli 2025

IMPLEMENTASI *RETRIEVAL AUGMENTED GENERATION* DENGAN PENDEKATAN *HYPOTHETICAL DOCUMENT EMBEDDINGS* PADA SISTEM TANYA JAWAB TENTANG PENYAKIT JANTUNG

Laporan Tugas Akhir

Oleh

ATTARIQ MUHAMMAD AZHAR

NIM: 18221043

Program Studi Sistem dan Teknologi Informasi

Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung

Telah disetujui dan disahkan sebagai Laporan Tugas Akhir

di Bandung, pada tanggal 19 Juni 2025

Pembimbing,

Dr. Ir. Dimitri Mahayana, M.Eng.

NIP 196808091991021001

LEMBAR PERNYATAAN

Dengan ini saya menyatakan bahwa:

1. Pengerjaan dan penulisan Laporan Tugas Akhir ini dilakukan tanpa menggunakan bantuan yang tidak dibenarkan.
2. Segala bentuk kutipan dan acuan terhadap tulisan orang lain yang digunakan di dalam penyusunan laporan tugas akhir ini telah dituliskan dengan baik dan benar.
3. Laporan Tugas Akhir ini belum pernah diajukan pada program pendidikan di perguruan tinggi mana pun.

Jika terbukti melanggar hal-hal di atas, saya bersedia dikenakan sanksi sesuai dengan Peraturan Rektor ITB No. 257 tahun 2019 tentang Penegakan Norma Akademik dan Kemahasiswaan Institut Teknologi Bandung.

Bandung, 6 Juni 2025

Attariq Muhamamd Azhar

NIM 18221043

ABSTRAK

IMPLEMENTASI *RETRIEVAL AUGMENTED GENERATION* DENGAN PENDEKATAN *HYPOTHETICAL DOCUMENT EMBEDDINGS* PADA SISTEM TANYA JAWAB TENTANG PENYAKIT JANTUNG

Oleh

Attariq Muhammad Azhar

NIM : 18221043

Penyakit jantung merupakan penyakit dengan jumlah kasus tertinggi di Indonesia sehingga diperlukan sebuah sistem penyediaan informasi untuk meningkatkan kesadaran masyarakat mengenai penyakit jantung. Perkembangan teknologi *generative AI* pada beberapa tahun terakhir telah membuka cara baru dalam pengaksesan informasi kesehatan, namun terdapat sebuah kekhawatiran akan kecenderungannya berhalusinasi akibat keterbatasan pengetahuan domain. Untuk mengatasi masalah tersebut, dilakukan inisiatif *knowledge injection* berupa implementasi *Retrieval Augmented Generation* untuk sistem tanya jawab tentang penyakit jantung. Selain itu, diterapkan pendeketan *Hypothetical Document Embeddings* (HyDE) untuk menghilangkan ketergantungan sistem terhadap *query* masukan pengguna dengan proses transformasi *query* menjadi jawaban hipotesis. Dengan menggunakan artikel dari situs Alodokter sebagai basis pengetahuan tentang penyakit jantung serta beberapa variasi model *embedding* dan *large language model* (LLM), dilakukan implementasi *pipeline* yang terdiri dari proses *indexing*, *retrieval,* dan *generation*. Setelah implementasi, dilakukan proses evaluasi dengan dua jenis metode, yakni berbasis LLM dan berbasis ahli domain. Evaluasi berbasis LLM yang mengandalkan empat metrik skor RAGAS menunjukkan penerapan HyDE memiliki kinerja yang lebih baik dalam proses *retrieval* daripada sistem yang tidak menerapkan HyDE. Kinerja *retrieval* yang lebih baik ini membuat jawaban yang dihasilkan LLM menjadi lebih faktual dan sesuai dengan basis pengetahuan di dalam artikel. Dari segi penilaian ahli domain yang merupakan dokter spesialis jantung, sistem RAG dinilai sudah mampu menghasilkan jawaban yang faktual, koheren, komprehensif, serta tidak membahayakan.

Kata kunci: *retrieval augmented generation*, *hypothetical document embeddings*, penyakit jantung, *large language model*, model *embedding*, sistem tanya jawab

ABSTRACT

IMPLEMENTATION OF RETRIEVAL AUGMENTED GENERATION WITH HYPOTHETICAL DOCUMENT EMBEDDINGS APPROACH IN HEART DISEASE QUESTION ANSWERING SYSTEM

By

Attariq Muhammad Azhar

NIM : 18221043

Heart disease remains the most prevalent illness in Indonesia, highlighting the need for an effective information system to raise public awareness regarding the disease. The rise of generative AI has introduced a new method for accessing health-related knowledge, yet there are concerns regarding its tendency to hallucinate due to insufficient understanding of domain-specific knowledge. To address this issue, this study introduces a knowledge injection strategy by implementing a Retrieval Augmented Generation (RAG) system tailored for heart disease-related question answering system. Furthermore, the Hypothetical Document Embeddings (HyDE) approach is utilized to reduce query dependency by converting user input into hypothetical answers. Leveraging health articles from the Alodokter website as the domain knowledge base and employing various embedding and large language models, pipelines were developed consisting of indexing, retrieval, and generation process. After the implementaion, the system was evaluated using two approaches, which are LLM-based evaluation and expert-based evaluation. Results from the LLM-based evaluation reveal that incorporating HyDE improves retrieval quality, leading to more accurate and fact-based responses. Additionally, evaluations by cardiologists indicate that the RAG system is capable of producing responses that are factually correct, coherent, comprehensive, and safe for public use.

Keywords: retrieval augmented generation, hypothetical document embeddings, heart disease, large language model, model embedding, question answering

KATA PENGANTAR

Puji syukur penulis panjatkan kepada Tuhan Yang Maha Esa atas berkat dan rahmat-Nya penulis dapat menyelesaikan penelitian pada tugas akhir yang berjudul "Implementasi *Retrieval Augmented Generation* dengan Pendekatan *Hypothetical Document Embeddings* pada Sistem Tanya Jawab Tentang Penyakit Jantung". Tugas akhir ini disusun sebagai salah satu syarat kelulusan tingkat sarjana pada Program Studi Sistem dan Teknologi Infomasi Institut Teknologi Bandung. Dalam keberjalanan proses penyelesaian tugas akhir ini, penulis ingin mengucapkan terima kasih kepada berbagai pihak yang telah memberikan banyak bantuan, dukungan, serta bimbingan:

1. Bapak Dr. Ir. Dimitri Mahayana, M.Eng, selaku dosen pembimbing tugas akhir yang telah memberikan bimbingan serta arahan kepada penulis dalam setiap tahap pengerjaan tugas akhir.
2. Kak Naufal Pandu Irsyadi, selaku asisten dosen pembimbing yang telah memberikan wawasan serta saran terkait metode dan teknik dalam pengerjaan tugas akhir.
3. Bapak dr. Akhmad Hidayatullah, Sp.JP, selaku dokter spesialis jantung yang telah membantu penulis dalam memberikan evaluasi serta masukan terkait hasil implementasi tugas akhir penulis.
4. Bapak I Gusti Bagus Baskara Nugraha, S.T., M.T., Ph.D., selaku Ketua Program Studi Sistem dan Teknologi Informasi Institut Teknologi Bandung yang telah memberikan arah dan struktur dalam pelaksanaan tugas akhir.
5. Orang tua dan keluarga penulis yang senantiasa mendukung, baik secara moral maupun material, serta mendoakan penulis selama perjuangan penulis dalam menyelesaikan studi sarjana.
6. Grup sahabat penulis selama berkuliah di Institut Teknologi Bandung, yakni grup Kok Ga Ngajak, yang telah menemani dengan penuh canda tawa serta

memberikan banyak motivasi dan dukungan selama penulis berkuliah di ITB.

7. Teman-teman Program Studi Sistem dan Teknologi Informasi angkatan 2021 serta teman-teman SUDO HMIF, yang telah berjuang bersama dalam kehidupan perkuliahan penulis.

Sebagai penutup, penulis berharap hasil tugas akhir ini mampu memberikan kontribusi serta dampak yang positif dalam pengembangan keilmuan teknologi informasi, khususnya pada bidang kecerdasan buatan dan kesehatan.

Bandung, 6 Juni 2025

Attariq Muhammad Azhar

DAFTAR ISI

ABSTRAK ..... **iv**

DAFTAR ISI ..... **viii**

DAFTAR LAMPIRAN ..... **xii**

DAFTAR GAMBAR ..... **xiii**

DAFTAR TABEL ..... **xvi**

DAFTAR RUMUS ..... **xviii**

BAB I PENDAHULUAN **1**

I.1 Latar Belakang 1

I.2 Rumusan Masalah 5

I.3 Tujuan 5

I.4 Batasan Masalah 6

I.5 Metodologi 7

BAB II STUDI LITERATUR **10**

II.1 Kecerdasan Buatan 10

II.2 Pemrosesan Bahasa Alami (*Natural Language Processing*) 12

II.2.1 *Transformer* 14

II.2.1.1 Arsitektur *Transformer* 15

II.2.2 *Large Language Model* 17

II.2.2.1 LLM dalam Bidang Kesehatan 20

II.2.2.2 Evaluasi Manusia Terhadap Jawaban LLM dalam Bidang Kesehatan 22

II.2.3 *Retrieval Augmented Generation* 25
II.2.3.1 *Hypothetical Document Embeddings* 28
II.2.3.2 Penerapan RAG pada Sistem Tanya Jawab Domain Kesehatan .29
II.2.3.3 Kerangka Kerja Evaluasi Sistem RAG 31
BAB III ANALISIS MASALAH DAN DESAIN KONSEP SOLUSI.....34
III.1 Analisis Kondisi Saat Ini 34
III.1.1 *Business Understanding* 34
III.1.2 *Data Understanding* 36
III.1.2.1 Jumlah Subtopik di Setiap Topik 38
III.1.2.2 Panjang Konten 39
III.1.2.3 Frekuensi Kata 41
III.1.2.4 Karakter *Unicode* 43
III.2 Analisis Kebutuhan 43
III.2.1 Identifikasi Masalah Pengguna 44
III.2.2 Kebutuhan Fungsional 45
III.2.3 Kebutuhan Nonfungsional 46
III.3 Analisis Pemilihan Solusi.....47
III.3.1 Alternatif Solusi 47
III.3.1.1 Alternatif Solusi I: Implementasi *Instruction Tuning* 48
III.3.1.2 Alternatif Solusi II: Implementasi *Retrieval Augmented Generation* 48
III.3.1.3 Alternatif Solusi III: Implementasi *Retrieval Augmented Generation* dengan Pendekatan *Hypothetical Document Embeddings*.....48
III.3.2 Analisis Penentuan Solusi.....49

BAB IV DESAIN SOLUSI 52
IV.1 Tahapan Desain 52
IV.1.1 *Data Preparation* 52
IV.1.2 *Modelling* 54
IV.1.2.1 Konfigurasi Model 58
IV.2 Hasil Desain 61
IV.2.1 Hasil *Data Preparation* 61
IV.2.2 Hasil *Modelling* 63
IV.2.2.1 Hasil *Indexing Pipeline* 63
IV.2.2.2 Hasil *Retrieval Pipeline* dan *Generation Pipeline* 67
IV.2.3 Hasil Implementasi UI 74
BAB V EVALUASI 80
V.1 Cara Melalukan Evaluasi 80
V.1.1 Evaluasi RAG Berbasis LLM 80
V.1.1.1 Konfigurasi Sistem pada Evaluasi RAG Berbasis LLM 82
V.1.1.2 Skenario Pengujian pada Evaluasi RAG Berbasis LLM 83
V.1.2 Evaluasi RAG Berbasis Ahli Domain 85
V.1.2.1 Konfigurasi Sistem pada Evaluasi RAG Berbasis Ahli Domain 86
V.1.2.2 Skenario Pengujian pada Evaluasi RAG Berbasis Ahli Domain 87
V.2 Hasil Evaluasi 88
V.2.1 Hasil Evaluasi RAG Berbasis LLM 88
V.2.2 Hasil Evaluasi RAG Berbasis Ahli Domain 93
V.3 Diskusi 94

V.3.1 Diskusi Hasil Evaluasi RAG Berbasis LLM 95

V.3.2 Diskusi Hasil Evaluasi RAG Berbasis Ahli Domain 99

BAB VI KESIMPULAN DAN SARAN 103

VI.1 Kesimpulan.....103

VI.2 Saran 104

DAFTAR PUSTAKA 106

LAMPIRAN A STATISTIK PENELUSURAN TOPIK *GENERATIVE AI* 113

LAMPIRAN B HASIL JAWABAN SISTEM RAG DARI PERTANYAAN RUMUSAN AHLI DOMAIN 114

LAMPIRAN C PERBANDINGAN JAWABAN *LARGE LANGUAGE MODEL* SEBELUM DAN SESUDAH PERUBAHAN *PROMPT* 120

DAFTAR LAMPIRAN

LAMPIRAN A STATISTIK PENELUSURAN TOPIK *GENERATIVE AI* 113

A.1 Visualisasi Statistik Penelusuran Google dengan Topik Generative AI pada Rentang Waktu Februari 2022 ─ Juni 2024 (Bianchi 2024) 113

LAMPIRAN B HASIL JAWABAN SISTEM RAG DARI PERTANYAAN RUMUSAN AHLI DOMAIN 114

B.1 Hasil Jawaban dari Pertanyaan ID Q01 114

B.2 Hasil Jawaban dari Pertanyaan ID Q02 115

B.3 Hasil Jawaban dari Pertanyaan ID Q03 116

B.4 Hasil Jawaban dari Pertanyaan ID Q04 117

B.5 Hasil Jawaban dari Pertanyaan ID Q05 117

B.6 Hasil Jawaban dari Pertanyaan ID Q06 118

B.7 Hasil Jawaban dari Pertanyaan ID Q07 118

B.8 Hasil Jawaban dari Pertanyaan ID Q08 119

LAMPIRAN C PERBANDINGAN JAWABAN *LARGE LANGUAGE MODEL* SEBELUM DAN SESUDAH PERUBAHAN *PROMPT* 120

C.1 Tabel Pertanyaan dan Jawaban *Ground Truth* pada Sampel Pertama 120

C.2 Tabel Perbandingan Jawaban Model Deepseek pada Pertanyaan Sampel Pertama 121

C.3 Tabel Pertanyaan dan Jawaban *Ground Truth* pada Sampel Kedua.....122

C.4 Tabel Perbandingan Jawaban Model Deepseek pada Pertanyaan Sampel Kedua 122

DAFTAR GAMBAR

Gambar I.1 Visualisasi Statistik Jumlah Kematian Akibat Penyakit Jantung di Indonesia (Institute for Health Metrics and Evaluation 2024) 2

Gambar II.1 Arsitektur Model *Transformer* (Vaswani dkk. 2017) 15

Gambar II.2 Perbandingan Kinerja GPT-4 dengan GPT-3.5 pada Ujian Akademis dan Profesional (OpenAI dkk. 2023) 18

Gambar II.3 Perbandingan Kinerja dalam Sistem Peringkasan Melalui Evaluasi Manusia (Tang dkk. 2023) 23

Gambar II.4 Proses dalam *Retrieval Augmented Generation* (Y. Gao dkk. 2023) 25

Gambar II.5 Ilustrasi Proses *Hypothetical Document Embeddings* (L. Gao dkk. 2023) 28

Gambar III.1 *Activity Diagram* dalam Aktivitas Pencarian Informasi Kesehatan Menggunakan Mesin Pencari 35

Gambar III.2 Hasil *Scraping* Artikel Penyakit Jantung pada Alodokter 37

Gambar III.3 Visualisasi Jumlah Subtopik di Setiap Topik 38

Gambar III.4 Grafik Histogram Distribusi Jumlah Kata 40

Gambar III.5 Boxplot Jumlah Kata 40

Gambar III.6 Perbandingan Panjang Konten Per Topik 41

Gambar III.7 Perbandingan Frekuensi Kemunculan Kata pada Kumpulan Artikel Penyakit Jantung 42

Gambar III.8 Visualisasi *Wordcloud* pada Kumpulan Artikel Penyakit Jantung .. 42

Gambar IV.1 Ilustrasi *Document-Based Chunking* pada Dokumen Artikel 53

Gambar IV.2 Diagram Proses *Pipeline* Alternatif Solusi II 57

Gambar IV.3 Diagram Proses *Pipeline* Alternatif Solusi III 57

Gambar IV.4 Diagram Proses Desain Solusi 58

Gambar IV.5 Diagram Alir Proses Penggantian Karakter *Unicode* pada Dokumen 61

Gambar IV.6 Detail Aliran Proses *Indexing Pipeline* 63

Gambar IV.7 Basis Data Penyimpanan Dokumen Artikel 65

Gambar IV.8 Contoh *Node* yang Tersimpan di *Collection* 66

Gambar IV.9 Detail Aliran Proses *Retrieval Pipeline* untuk Alternatif Solusi II ..67

Gambar IV.10 Detail Aliran Proses *Retrieval Pipeline* untuk Alternatif Solusi III 69

Gambar IV.11 Detail Aliran Proses *Generation Pipeline* 71

Gambar IV.12 Tampilan UI Sistem RAG untuk Tanya Jawab Tentang Penyakit Jantung 75

Gambar IV.13 *Activity Diagram* Penggunaan Indo Cardiac Chatbot 76

Gambar IV.14 Contoh Pesan Sistem pada Proses Pencarian Dokumen 76

Gambar IV.15 Contoh Pesan Sistem pada Proses Penghasilan Jawaban 77

Gambar IV.16 Contoh Keluaran Jawaban Faktual pada Indo Cardiac Chatbot 78

Gambar IV.17 Tampilan *Dropdown* Detail pada Indo Cardiac Chatbot 78

Gambar IV.18 Contoh Pesan Sistem pada Proses Penghasilan Jawaban Hipotesis 79

Gambar IV.19 Tampilan Jawaban Hipotesis pada *Dropdown* Detail 79

Gambar V.1 Diagram Alir *Retrieval* dan *Answer Generation* pada Proses Evaluasi RAG Berbasis LLM 84

Gambar V.2 Diagram Alir Proses Penilaian Metrik RAGAS pada Proses Evaluasi RAG Berbasis LLM 84

Gambar V.3 Diagram Alir Proses Evaluasi RAG Berbasis Ahli Domain 88

Gambar V.4 Perbandingan Skor *Context Precision* antar Model *Embedding* Dengan dan Tanpa Penerapan HyDE 89

Gambar V.5 Perbandingan Skor *Context Recall* antar Model *Embedding* Dengan dan Tanpa Penerapan HyDE 90

Gambar V.6 Perbandingan Skor *Faithfulness* antar LLM Dengan dan Tanpa Penerapan HyDE 91

Gambar V.7 Perbandingan Skor *Answer Relevancy* antar LLM Dengan dan Tanpa Penerapan HyDE 92

DAFTAR TABEL

Tabel II.1 Hasil Tolok Ukur Akurasi LLM dengan Evaluasi Sistematis Mirage (Xiong dkk. 2024) 30

Tabel III.1 Deskripsi Kolom dalam Hasil Scraping Artikel pada Situs Web Alodokter 37

Tabel III.2 Statistik Deskriptif dari Jumlah Kata pada Konten 39

Tabel III.3 Lima Karakter Unicode dengan Frekuensi Kemunculan Terbanyak 43

Tabel III.4 Kebutuhan Fungsional Sistem Tanya Jawab Tentang Penyakit Jantung 46

Tabel III.5 Kebutuhan Nonfungsional Sistem Tanya Jawab Tentang Penyakit Jantung 46

Tabel III.5 Kebutuhan Nonfungsional Sistem Tanya Jawab Tentang Penyakit Jantung (lanjutan) 46

Tabel III.6 Kalkulasi *Weighted Scoring* pada Alternatif Solusi 50

Tabel IV.1 Opsi Model dalam Implementasi Sistem RAG 59

Tabel IV.2 Konfigurasi Model untuk Sistem RAG 60

Tabel IV.3 Contoh Hasil *Text Cleaning* pada Teks Artikel 61

Tabel IV.4 Contoh Hasil *Document-Based Chunking* 62

Tabel IV.5 Contoh Hasil Penambahan Kolom ID dan *Vector Embeddings* 64

Tabel IV.6 Contoh Hasil *Retrieval Pipeline* dan *Generation Pipeline* untuk Alternatif Solusi II 72

Tabel IV.7 Contoh Hasil *Retrieval Pipeline* dan *Generation Pipeline* untuk Alternatif Solusi III 73

Tabel IV.7 Contoh Hasil *Retrieval Pipeline* dan *Generation Pipeline* untuk Alternatif Solusi III (lanjutan).....73

Tabel V.1 Spesifikasi Konfigurasi Model dan Perangkat Keras pada Evaluasi RAG Berbasis LLM 82

Tabel V.2 Sampel *Dataset* untuk Evaluasi Sistem RAG Berbasis LLM.....83

Tabel V.3 Metrik Evaluasi RAG Berbasis Ahli Domain.....85

Tabel V.4 Spesifikasi Konfigurasi Model dan Perangkat Keras pada Evaluasi RAG Berbasis Ahli Domain.....86

Tabel V.5 *Dataset* untuk Evaluasi Sistem RAG Berbasis Ahli Domain 87

Tabel V.6 Perbandingan Jawaban *Ground Truth* dan Hipotesis pada Salah Satu Sampel Set Evaluasi.....95

Tabel V.7 Sampel Jawaban dengan Skor Kelengkapan (*Comprehensiveness*) Terkecil 100

Tabel V.7 Sampel Jawaban dengan Skor Kelengkapan (*Comprehensiveness*) Terkecil (lanjutan).....100

DAFTAR RUMUS

Rumus II.1 14
Rumus II.2 26
Rumus II.3 32
Rumus II.4 32
Rumus II.5 33
Rumus II.6 33
Rumus II.7 33
Rumus II.8 33
Rumus V.1 81
Rumus V.2 82
Rumus V.3 82
Rumus V.4 82
Rumus V.5 82

BAB I

PENDAHULUAN

I.1 Latar Belakang

Jantung merupakan salah satu organ yang sangat penting pada tubuh manusia. Organ ini berfungsi sebagai pemompa darah ke seluruh tubuh melalui pembuluh darah. Jantung manusia berdetak selama rata-rata 72 kali per menit. Setiap detakan jantung membantu berfungsinya organ-organ tubuh lainnya (Heart Research Institute, t.t.). Layaknya organ tubuh manusia lainnya, jantung dapat mengalami gangguan-gangguan tertentu yang menyebabkan timbulnya penyakit jantung. Penyakit jantung atau *cardiovascular disease* (CVD) merupakan penyebab kematian yang paling sering terjadi secara global (World Health Organizaiton 2021). Sesuai dengan Gambar I.1, pada tahun 2021, jumlah kematian akibat penyakit jantung di Indonesia mencapai 765.660 kematian (Institute for Health Metrics and Evaluation 2024) dan pada tahun 2023, kasus penyakit jantung memiliki jumlah kasus tertinggi yang dijamin oleh BPJS Kesehatan dengan jumlah sebanyak 20,4 juta kasus (Fitriani 2024). Tingginya kasus penyakit jantung yang terjadi di Indonesia menandakan adanya urgensi untuk meningkatkan kesadaran masyarakat mengenai penyakit jantung beserta hal-hal berkaitan lainnya seperti pencegahan, gejala, dan pengobatannya.

Dengan semakin berkembangnya teknologi informasi, pemanfaatan internet untuk mencari informasi kesehatan semakin banyak dilakukan. Informasi yang disediakan secara daring dapat mencakup gejala, diagnosis, dan pengobatan berbagai penyakit (Jia, Pang, dan Liu 2021). Saat ini penyediaan informasi kesehatan melalui media artikel telah tersedia di berbagai situs web, termasuk di Indonesia seperti Alodokter, Halodoc, dan Kementerian Kesehatan. Pencarian dan pengaksesan informasi pada

dasarnya merupakan sebuah proses interaktif. Dalam mesin pencari yang ada saat ini, seperti Google Search, Bing, dan Yahoo, interaksi dibatasi oleh aksi yang sudah ditentukan, seperti memasukkan *query* secara berulang, melakukan *scrolling*, berpindah halaman web, dan lain-lain (Aliannejadi, Gwizdka, dan Zamani 2024). Teknologi dalam penyediaan informasi terus berkembang untuk dapat memberikan informasi lebih cepat serta terpersonalisasi. Perkembangan teknologi *generative AI* pada beberapa tahun terakhir dapat membuka cara baru dalam pengaksesan informasi serta meningkatkan efektivitas dari sistem pengambilan informasi (*information* retrieval) (Mitra dkk. 2024).

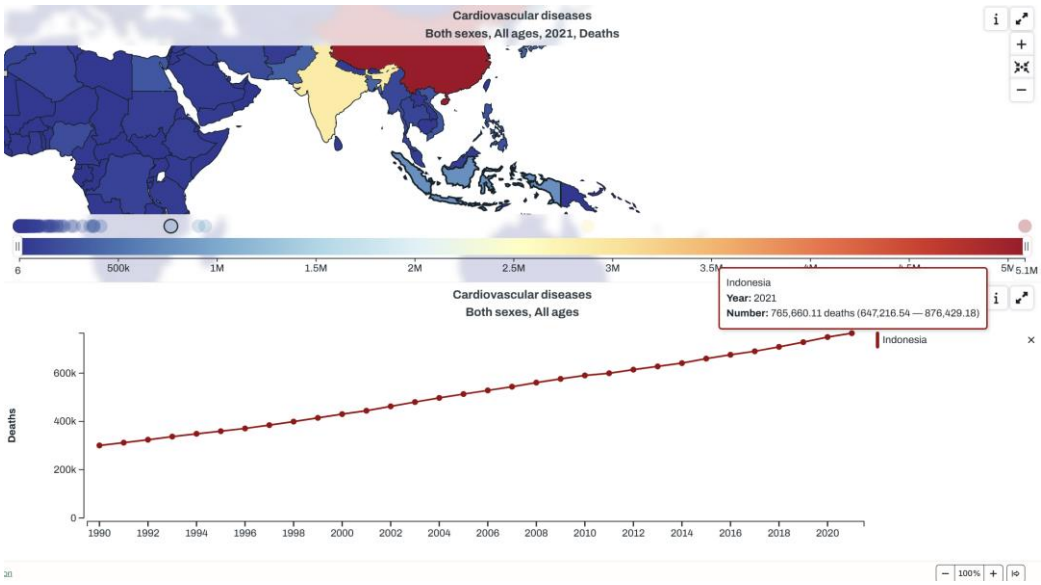

Gambar I.1 Visualisasi Statistik Jumlah Kematian Akibat Penyakit Jantung di Indonesia (Institute for Health Metrics and Evaluation 2024)

Istilah *generative AI* diartikan sebagai teknik komputasional yang dapat menghasilkan konten yang baru dan berarti seperti teks, foto, atau audio (Feuerriegel dkk. 2024). Sejak kemunculan ChatGPT pada bulan November 2022, topik *generative AI* telah menjadi menjadi perbincangan umum dengan banyaknya pencarian mengenai topik tersebut pada Google (visualisasi statistik dapat dilihat

pada Lampiran A). Kemampuan sistem *generative AI* berpotensi mendorong cara pencarian informasi yang berfokus pada pembuatan dan modifikasi informasi untuk memenuhi kebutuhan informasi atau menyelesaikan masalah (Hirvonen dkk. 2024). Untuk mendukung kemampuannya tersebut, teknologi *generative AI* mengandalkan sebuah jenis model bernama *Large Langue Model* (LLM). Penggunaan LLM dalam sistem *chatbot* memberikan pengalaman pengguna yang realistis serta interaktif melalui dialog berbasis teks, yang berbeda dari semua aplikasi AI sebelumnya yang hanya dapat melakukan tugas tunggal (Tan dkk. 2023).

Di samping kapabilitasnya dalam menghasilkan konten tekstual, masih terdapat kekhawatiran tentang kecenderungan model LLM untuk menghasilkan "halusinasi" (Huang dkk. 2024). Terkadang model dapat memberikan jawaban yang tepat namun terkadang juga mereka memberikan fakta acak berdasarkan data yang dilatih kepada model sehingga model ini terkesan seperti tidak mengerti apa yang dia sampaikan (Martineau 2023). Dalam domain kritis seperti bidang kesehatan dan hukum yang menekankan pentingnya keakuratan dan keandalan, kesalahan kecil sekalipun dapat menimbulkan konsekuensi yang serius sehingga diperlukan pemrosesan informasi yang sangat hati-hati (Pang dkk. 2024). Untuk mengatasi adanya "halusinasi" akibat kurangnya pengetahuan model pada domain yang spesifik, langkah *post-processing* perlu dilakukan untuk menambah pengetahuan model yang disebut sebagai *knowledege injection* (Ovadia dkk. 2023).

Alternatif *knowledge injection* pertama adalah dengan melakukan *instruction tuning*. Dalam pendekatan ini, model akan dilatih untuk beradaptasi dengan data berisi pasangan deskripsi tugas beserta perilaku yang diharapkan (Ovadia dkk. 2023). Terdapat beberapa penelitian menggunakan *instruction tuning* untuk mengembangkan model dalam domain tertentu, termasuk dalam bidang medis. Penelitian yang dilakukan oleh (Singhal dkk. 2023) telah mengembangkan model bernama Med-PALM yang merupakan salah satu contoh model yang menggunakan

instruction tuning. Med-PALM merupakan model yang dikembangkan oleh Google yang dapat memberikan respon yang baik berdasarkan pertanyaan medis (Singhal dkk. 2023). Model ini dilatih dengan memanfaatkan data literatur medis, publikasi akademis, catatan kesehatan elektronik, serta informasi perawatan kesehatan lainnya (Sai dkk. 2024). Model ini menunjukkan kinerja terbaik pada variasi kumpulan soal pilihan ganda yang terkait dengan topik kesehatan (Singhal dkk. 2025).

Namun, *instruction tuning* tidak selalu mengajarkan model pengetahuan baru sehingga pendekatan ini saja bukan solusi yang cukup dalam melakukan *knowledge injection* (Ovadia dkk. 2023). Oleh karena itu, alternantif kedua yang dapat mengatasi "halusinasi" adalah dengan pendekatan *Retrieval Augmented Generation* (RAG). *Retrieval Augmented Generation* (RAG) memperkuat kemampuan LLM dengan mengumpulkan potongan dokumen terkait dari basis pengetahuan eksternal menggunakan metode kalkulasi kesamaan semantik (Y. Gao dkk. 2023). Pendekatan ini menjadi sebuah pendekatan alternatif yang akan menyediakan landasan ilmu terkait domain spesifik kepada LLM. Biayanya yang rendah dalam melakukan *embedding* terhadap kumpulan dokumen menjadikan RAG sebagai pilihan yang menarik (Balaguer dkk. 2024). Dalam penyediaan informasi penyakit jantung, sistem RAG dapat memanfaatkan kumpulan informasi penyakit jantung yang tersedia di dalam situs web artikel kesehatan. Kumpulan artikel ini nantinya tersimpan ke dalam sebuah basis data dalam bentuk vektor.

Salah satu tantangan yang dihadapi dalam *Retrieval Augmented Generation* adalah ketergantungan pada *query* yang dimasukkan pengguna sebagai basis dalam proses *retrieval.* Terkadang, pertanyaan memiliki tingkat kompleksitas tinggi dengan penggunaan bahasa yang kurang terorganisir (Y. Gao dkk. 2023). Pendekatan *Hypothetical Document Embeddings* (HyDE) yang merupakan salah satu teknik transformasi *query* menjadi salah satu pendekatan yang mampu mengatasi

permasalahan ini dengan memanfaatkan jawaban hipotesis dari LLM (Y. Gao dkk. 2023). Dalam pendekatan ini, *query* akan dimasukkan ke dalam model LLM dan menginstruksikan model tersebut untuk menghasilkan jawaban hipotesis sebelum jawaban tersebut diubah menjadi vektor *embedding* dan dilakukan pencarian kesamaan dengan dokumen asli (L. Gao dkk. 2023). Untuk memvalidasi kemampuan HyDE dalam mengatasi ketergantungan RAG terhadap *query*, tugas akhir ini akan berfokus pada studi komparasi antara sistem RAG yang menerapkan *Hypothetical Document Embeddings* dengan sistem RAG yang tidak menerapkan pendekatan tersebut pada sistem tanya jawab tentang penyakit jantung.

I.2 Rumusan Masalah

Berdasarkan pemaparan latar belakang pada subbab sebelumnya, didefinisikan tiga rumusan masalah sebagai berikut.

1. Bagaimana cara implementasi *Retrieval Augmented Generation* (RAG) pada sistem tanya jawab tentang penyakit jantung?
2. Bagaimana pendekatan *Hypothetical Document Embeddings* (HyDE) diterapkan pada implementasi *Retrieval Augmented Generation* (RAG) untuk sistem tanya jawab tentang penyakit jantung?
3. Bagaimana hasil evaluasi kinerja sistem RAG serta perbandingan kinerja sistem RAG yang menerapkan pendekatan HyDE dengan yang tidak menerapkan pendekatan tersebut dalam sistem tanya jawab tentang penyakit jantung?

I.3 Tujuan

Berdasarkan poin-poin rumusan masalah yang telah didefinisikan, dirumuskan tiga tujuan dalam pengerjaan tugas akhir ini.

1. Mengimplementasi *Retrieval Augmented Generation* pada sistem tanya jawab tentang penyakit jantung,
2. Menerapkan pendekatan *Hypothetical Document Embeddings* pada implementasi *Retrieval Augmented Generation* untuk sistem tanya jawab tentang penyakit jantung,
3. Mengevaluasi kinerja sistem RAG serta membandingkan kinerja sistem RAG yang menerapkan pendekatan HyDE dengan yang tidak menerapkan pendekatan tersebut dalam sistem tanya jawab tentang penyakit jantung.

I.4 Batasan Masalah

Terdapat beberapa batasan masalah yang diterapkan dalam penyusunan tugas akhir ini.

1. Data yang akan digunakan sebagai sumber informasi penyakit jantung adalah kumpulan artikel mengenai variasi penyakit jantung pada situs web Alodokter.
2. Interaksi yang dilakukan dalam sistem merupakan interaksi tanya jawab yang berkaitan dengan informasi umum mengenai penyakit jantung sesuai konten artikel pada Alodokter beserta variasinya dan tidak dirancang untuk memberikan diagnosis berdasarkan kasus tertentu.
3. Bahasa pemrograman yang digunakan dalam melakukan pengembangan sistem adalah Python versi 3.9.
4. Penelitian dilakukan menggunakan *laptop* ASUS Vivobook Pro 15 dengan prosesor AMD Ryzen 5 5600H, GPU Nvidia RTX 3050Ti, dan RAM 16GB.
5. Proses pengolahan data dilakukan menggunakan Jupyer Notebook di dalam IDE Visual Studio Code.

I.5 Metodologi

Untuk mengimplementasikan *Retrieval Augmented Generation* dengan pendekatan *Hypothetical Document Embeddings* pada tugas akhir ini, digunakan metodologi bernama *Cross-Industry Process for Data Mining* (CRISP-DM). Metodologi ini merupakan metodologi yang paling umum digunakan pada proyek penambangan data, analisis data, dan sains data (Hotz 2024).

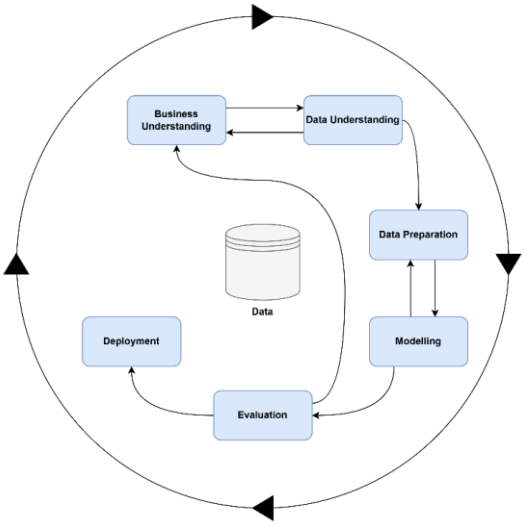

Gambar I.3 Diagram Proses Metodologi CRISP-DM (Hotz 2024)

Terdapat enam tahapan dalam metodologi CRISP-DM, yakni:

1. *Business Understanding*

   Tahap pertama pada CRISP-DM berfokus pada pemahaman mengenai objektif serta kebutuhan bisnis. Untuk memahami objektif serta kebutuhan bisnis, dilakukan analisis kondisi ketersediaan sumber daya saat ini serta penentuan tujuan dari dilakukannya penambangan data. Setelah itu, dilakukan juga perumusan rencana proyek untuk menentukan kakas dan teknologi yang digunakan serta rincian rencana di tahap-tahap selanjutnya.

2. *Data Understanding*

   Pada tahap ini, kegiatan berfokus pada identifikasi, pengumpulan, serta analisis data yang membantu dalam pencapaian tujuan. Kegiatan pada tahap *data understanding* mencakup pengumpulan data yang dibutuhkan, deskripsi data, eksplorasi data melalui analisis dan visualisasi data, serta verifikasi kualitas data.

3. *Data Preparation*

   Tahap ini merupakan tahap yang perlu dilakukan agar data yang telah dikumpulkan siap untuk digunakan untuk pemodelan. Kegiatan yang dilakukan pada tahap *data preparation* mencakup pemilihan data yang akan digunakan pada fase pemodelan, pembersihan data yang telah dipilih, konstruksi data untuk menghasilkan atribut data baru, integrasi data dari beberapa sumber, serta penyesuaian format data.

4. *Modelling*

   Tahap pemodelan melibatkan data yang telah disiapkan di tahap sebelumnya untuk membuat model. Pada tahap ini, dilakukan penentuan teknik pemodelan tertentu serta desain pengujian terhadap model terlebih dahulu sebelum akhirnya dilakukan pembuatan model. Setelah pembuatan model telah dilakukan, hasil model diuji sesuai dengan desain tes serta kriteria kesuksesan yang telah dibuat.

5. *Evaluation*

   Berbeda dengan tahap pemodelan yang menguji hasil model dari sisi teknis, tahap evaluasi berfokus pada penentuan apakah model telah sesuai dengan kebutuhan bisnis. Pada tahap ini, dilakukan evaluasi terhadap ketercapaian kesuksesan bisnis serta meninjau ulang seluruh proses yang dilakukan selama keberjalanan proyek. Selain itu, dilakukan juga penentuan langkah-langkah yang perlu diambil berdasarkan peninjauan ulang terhadap tahap *data understanding* hingga pemodelan.

6. *Deployment*

   Tahap ini merupakan tahap untuk memungkinkan hasil penambganan data dapat diakses oleh pelanggan. Kompleksitas dari tahap ini cukup bervariasi, dari yang hanya sesederhana menghasilkan laporan hingga serumit mengimplementasikan seluruh proses penambangan data di seluruh *enterprise*. Pada tahap ini, kegiatan yang dilakukan mencakup perencanaan *deployment*, perencanaan *monitoring* dan *maintenance*, membuat laporan akhir mengenai hasil penambangan data, dan meninjau ulang proyek yang telah dilakukan (Hotz 2024).

BAB II

STUDI LITERATUR

II.1 Kecerdasan Buatan

Kecerdasan buatan atau *artificial intelligence* (AI) merupakan bidang dalam ilmu komputer yang luas dan berkaitan dengan pembuatan mesin cerdas yang mampu melakukan tugas yang biasanya memerlukan kecerdasan manusia (Sarker 2022). Kemampuan AI untuk mengatasi beberapa komputasi intensif serta batas kreativitas manusia, memungkinkan terbukanya pengaplikasian AI dalam domain-domain baru seperti pendidikan, pemasaran, kesehatan, keuangan, dan manufaktur. Pengaplikasian ini dapat menghasilkan dampak pada produktivitas dan kinerja (Dwivedi dkk. 2021). Berdasarkan kapabilitasnya, AI dapat terbagi menjadi dua jenis, yakni AI lemah (*weak AI*) dan AI kuat (*strong AI*). AI lemah atau dapat disebut juga sebagai AI dangkal dapat diartikan sebagai algoritma pada domain spesifik yang memiliki tugas yang dapat dipandang sebagai cerdas jika dioperasikan oleh manusia. Beberapa sistem yang ada saat ini, seperti pemrosesan bahasa alami (*natural language processing* atau NLP) dan penyaringan gambar (*image screening*), merupakan contoh domain spesifik yang dapat dikelompokkan sebagai AI lemah (Bory, Natale, dan Katzenbach 2024). Sementara itu, AI kuat, atau dikenal sebagai kecerdasan umum buatan (*artificial general intelligence* atau AGI), merupakan sebuah sistem yang saat ini masih bersifat teoretis yang memiliki kesadaran diri serta kecerdasan yang menyamai, bahkan melebihi, pikiran manusia (Stryker 2024).

Dengan lingkungan dunia nyata yang dinamis dan bervariasi, terdapat beberapa variasi tipe AI yang dibangun untuk masalah-masalah tertentu. Variasi AI ini mencakup lima tipe (Sarker 2022):

1. *Analytical AI*

   Analytical AI dibuat dengan tujuan untuk menemukan wawasan, pola, serta hubungan atau ketergantungan di dalam data dan untuk membantu dalam pengambilan keputusan yang *data-driven*. Dalam domain *business intelligence* saat ini, tipe *analytical AI* menjadi bagian inti dari AI yang memberikan wawasan kepada *enterprise* dan menghasilkan saran atau rekomendasi berdasarkan kapabilitas pemrosesasn analisisnya. Beberapa contoh teknik pendekatan yang digunakan dalam *analytical AI* adalah *machine* learning dan *deep learning*.

2. *Functional AI*

   Tipe ini memiliki kemiripan dengan *analytical AI* dalam memanfaatkan kumpulan untuk mengeksplorasi pola serta ketergantungan. Namun, *functional AI* bertugas dalam mengeksekusi sebuah aksi daripada membuat rekomendasi. Beberapa contoh penggunaannya terdapat pada robotik serta *internet of things* (IoT).

3. *Interactive AI*

   Tipe AI ini memungkinkan automasi komunikasi yang interaktif seperti *chatbot* atau asisten pribadi cerdas. Beberapa teknik yang dapat digunakan dalam *interactive AI* mencakup *machine learning*, penambangan pola (*pattern mining*), *reasoning*, dan pencarian heuristik.

4. *Textual AI*

   Sesuai namanya, *textual AI* biasa digunakan pada tugas-tugas yang berkaitan dengan teks seperti analisis tekstual dan pemrosesan bahasa alami yang memungkinkan beberapa kapabilitas seperti pengenalan teks, konversi ucapan-ke-teks, terjemahan mesin, hingga penghasilan konten (*content generation*). Keberadaan AI ini dapat mendukung penyedian ilmu yang relevan, seperti menjawab masukan *query*.

5. *Visual AI*

   Tipe ini merupakan cabang bidang yang melatih mesin untuk mempelajari foto dan data visual layaknya manusia. *Visual AI* kerap diterapkan pada bidang visi komputer dan *augmented reality* (Sarker 2022).

II.2 Pemrosesan Bahasa Alami (*Natural Language Processing*)

Pemrosesan bahasa alami (*natural language processing* atau NLP) merupakan cabang keilmuan dalam kecerdasan buatan (AI) serta linguistik yang melibatkan rekayasa proses dan model komputasional (Otter, Medina, dan Kalita 2021) bertujuan untuk membuat komputer memahami pernyataan atau kalimat yang tertulis dalam bahasa manusia (Khurana dkk. 2023). Cabang keilmuan ini menggunakan beberapa varasi teori dan pendekatan untuk menangani permasalahan bahasa alami dalam berkomunikasi dengan komputer (Khurana dkk. 2023). NLP dapat dibagi menjadi dua kategori berdasarkan tugasnya, yakni *Natural Language Understanding* (NLU) dan *Natural Language Generation* (NLG). NLU merupakan jenis NLP yang memungkinkan mesin untuk memahami bahasa alami serta menganalisis bahasa tersebut dengan mengekstrasi konsep, entitas, emosi, kata kunci, dan lain-lain Sementara itu, NLG merupakan jenis NLP berupa proses menghasilkan frasa, kalimat, atau paragraf yang memiliki arti dari representasi internal (Khurana dkk. 2023). Cabang keilmuan ini telah diaplikasikan dalam beberapa jenis tugas, seperti:

1. Analisis Sentimen (*Sentiment Analysis*)

   Analisis sentimen merupakan proses pengumpulan serta analisis opini atau impresi mengenai variasi topik, produk, subjek, atau layanan tertentu (Wankhade, Rao, dan Kulkarni 2022). Analisis sentimen dalam membantu menginterpreasi emosi dalam teks yang tidak terstruktur dan dapat mengkalkulasi seberapa lemah atau kuat emosi tersebut (Cui dkk. 2023). Untuk memungkinkan hal tersebut, analisis sentimen memanfaatkan

pemrosesan bahasa alami untuk mengidentifikasi dan mengekstrasi informasi subjektif (Wankhade, Rao, dan Kulkarni 2022).

2. Tanya Jawab (*Question Answering*)

   Tanya jawab merupakan salah satu tugas dalam NLP untuk menjawab sebuah pertanyaan dalam bentuk bahasa alami berdasarkan pada kumpulan dokumen berskala besar. Umumnya sistem tanya jawab disusun dalam sebuah *pipeline* yang terdiri dari tiga proses. Proses pertama adalah *question analysis,* yakni proses menghasilkan *query* berdasarkan pertanyaan yang diberikan pengguna. Proses kedua adalah *document retrieval,* yakni proses pengambilan dokumen yang relevan dengan pertanyaan. Setelah melalui *document retrieval,* proses diakhiri dengan *answer extraction* atau proses ekstraksi jawaban dari dokumen relevan yang telah diambil (Zhu dkk. 2021).

3. Pemodelan Bahasa (*Language Modelling*)

   Tugas pemodelan bahasa merupakan salah satu tugas model dalam menganalisis data teks untuk mengkalkulasi probabilitas kata. Model ini menggunakan algoritma untuk menginterpretasi data yang menetapakan aturan tertentu untuk konteks dalam bahasa alami. Aturan ini kemudian digunakan untuk memprediksi atau membangun kalimat-kalimat baru secara akurat (Khurana dkk. 2023).

4. Penerjemahan Mesin (*Machine Translation*)

   Tugas ini memiliki tujuan untuk mengonversi teks dari sebuah bahasa alami menjadi bahasa lain dengan tetap menjaga makna dari teks masukan (Khurana dkk. 2023).

Pendekatan-pendekatan dalam NLP pada beberapa tahun terakhir telah bertransformasi dan mulai mengadposi model berbasis *neural network* (Otter, Medina, dan Kalita 2021). Dari beberapa jenis model yang berbasis *neural network*, model *transformer* merupakan salah satu jenis model yang banyak digunakan dalam NLP (Otter, Medina, dan Kalita 2021).

II.2.1 *Transformer*

Transformer merupakan model *deep learning* yang telah digunakan dalam berbagai bidang, seperti pemrosesan bahasa alami, visi komputer, dan pemrosesan ucapan (Lin dkk. 2022). Walaupun pada awalnya dibuat sebagai model *sequence-to-sequence* untuk melakukan tugas dalam penerjemahan mesin (*machine translation*), beberapa penelitian telah menunjukkan adanya pengembangan model *pre-trained* berbasis *transformer* yang dapat mencapai kinerja terbaiknya pada variasi tugas tertentu (Lin dkk. 2022). Dengan berkembangnya variasi model *transformer,* model jenis ini memiliki peran yang semakin penting dalam penelitian serta penerapan kecerdasan buatan (Xiao dan Zhu 2023). Model *transformer* mengandalkan empat komponen utama, yaitu *multi-head self-attention mechanism, position-wise feed-forward network, layer normalization modules,* dan *resiudal connections* (Borji 2023).

Mekanisme *self-attention* merupakan fitur krusial di dalam model *transformer* yang berfungsi dalam membuat hubungan antar sekuen yang berada di posisi yang berbeda-beda. Hal ini memungkinkan komputasi sebuah represetnasi dari sekuen tersebut. Pada konsep dasar dari mekanisme *self-attention*, setiap elemen dalam sekuen belajar untuk mengumpulkan informasi dari token lain pada sekuen yang sama (Borji 2023). *Transformer* mengadopsi mekanisme *self-attention* dengan model *Query-Key-Value* (QKV) yang memiliki operasi seperti berikut (Lin dkk. 2022).

$$Attention\ (Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{D_k}}\right)V \qquad \text{(II. 1)}$$

Keterangan:

$Q = XW_q$, $K = XW_k$, dan $V = XW_v$ merupakan transormasi linear dari representasi matriks *query, key,* dan *value.*

D_k merupakan dimensi dari *keys.*

II.2.1.1 Arsitektur *Transformer*

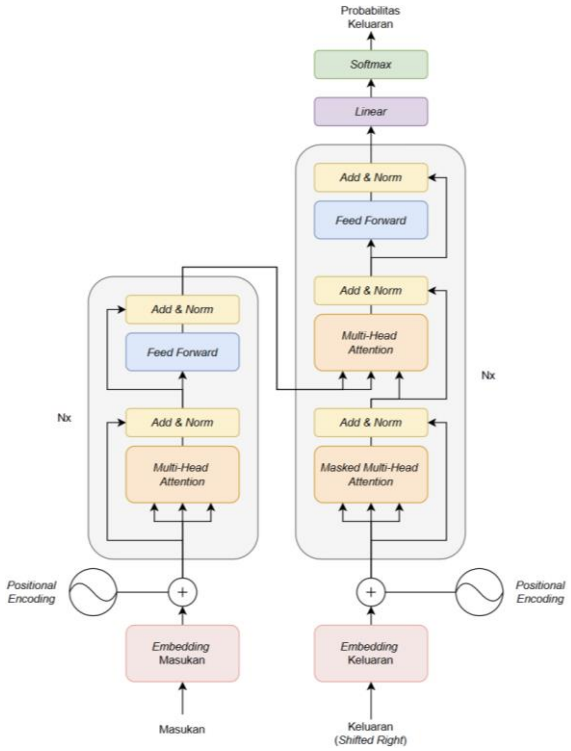

Gambar II.1 Arsitektur Model *Transformer* (Vaswani dkk. 2017)

Model *transformer* bekerja dengan dukungan dua komponen, yakni *encoder* dan *decoder*. Meskipun kedua komponen ini memiliki beberapa subkomponen yang sama, *encoder* dan *decoder* memiliki fungsi yang berbeda.

1. *Encoder*

   Komponen *encoder* dalam *transformers* terdiri dari banyak lapisan *encoder* yang saling tertumpuk satu sama lain. Komponen ini bertugas dalam mengubah masukan berupa sekuen dari kumpulan *token* menjadi sebuah sekuen dari *embedding vectors*. Setiap lapisan (*layer*) *encoder* akan menerima sekuen *embeddings* dan memasukkannya ke dalam dua sublapisan, yakni lapisan *multi-head self-attention* dan lapisan *feed-forward* yang saling terhubung. Model yang mengadopsi arsitektur *encoder-only* memiliki kemampuan dalam mengubah masukan teks menjadi representasi

numerik. Kemampuannya ini kerap digunakan pada tugas seperti klasifikasi teks dan *named entity recognition* (NER). Contoh model yang hanya menggunakan arsitektur *encoder* adalah model BERT (Bidirectional Encoder Representations from Transformers) yang dibuat oleh Google.

2. *Decoder*

   Perbedaan utama antara *decoder* dan *encoder* terletak pada sublapisan *attention*. Arsitektur *decoder* memiliki dua sublapisan *attention* yang terdiri dari lapisan *masked multi-head self-attention* dan lapisan *encoder-decoder attention.* Komponen ini menerima masukan berupa *embedding* untuk menghasilkan keluaran berupa sekuen dari *token*. Model yang mengadopsi arsitektur *decoder-only* memiliki kemampuan dalam melengkapi sebuah sekuen kalimat dengan memprediksi keluaran kata berikutnya secara berulang. Contoh model yang hanya menggunakan arsitektur *decoder* adalah GPT (*Generative Pretrained Transformer*) yang dibuat oleh OpenAI.

3. *Encoder-Decoder*

   Selain model *encoder-only* dan *decoder-only*, terdapat juga model yang memanfaatkan kedua arsitektur tersebut atau disebut juga sebagai model *encoder-decoder*. Arsitektur ini menerima masukan teks melalui *encoder* lalu akan mengubah teks tersebut menjadi *embedding vectors* sebelum vektor ini digunakan oleh *decoder* untuk memprediksi sekuen token. Model dengan arstitekur ini cocok digunakan pada tugas penerjamahan mesin (*machine translation*) dan perangkuman teks. Salah satu contoh model yang memanfaatkan aristektur *encoder-decoder* adalah T5 (Text-To-Text Transfer Transformer) yang dikembangkan oleh Google (Tunstall, von Werra, dan Wolf 2022).

II.2.2 *Large Language Model*

Large language model sering diartikan sebagai model bahasa berbasis *transfomer* yang berisi ratusan miliar (atau lebih) parameter yang dilatih pada data teks yang jumlahnya sangat besar. Berbeda dengan model bahasa pada awal pengembangannya yang bertujuan untuk memodelkan serta menghasilkan data teks, LLM memiliki fokus tujuan pada penyelesaian tugas yang kompleks (Zhao dkk. 2023). LLM memiliki kemampuan yang belum dimiliki oleh model bahasa berskala kecil di awal pengembangannya, seperti:

1. Pembelajaran dalam konteks (*in-context learning*), yakni ketika LLM mempelajari tugas baru dari sekumpulan contoh yang disajikan dalam *prompt*,
2. Mengikuti instruksi, yakni ketika sudah dilakukan *instruction tuning*, LLM dapat mengikuti instruksi untuk variasi tugas yang baru tanpa perlu ditunjukkan lagi contohnya, dan
3. *Multi-step reasoning*, yakni ketika LLM dapat menyelesaikan tugas yang kompleks dengan memecah tugas tersebut menjadi langkah-langkah penalaran (Minaee dkk. 2024).

Tonggak penting dari perkembangan LLM adalah kemunculan ChatGPT (*Chat Generative Pretrained Transformer*) pada tanggal 30 November 2022 (Minaee dkk. 2024). ChatGPT merupakan *chatbot* yang dikembangkan oleh OpenAI yang memungkinkan pengguna untuk menyelesaikan berbagai macam tugas, seperti tanya jawab (*question answering*), pencarian informasi (*information seeking*), perangkuman teks, dan banyak lagi (Minaee dkk. 2024). Saat ini ChatGPT didukung oleh model GPT-4 yang merupakan model terbaru dan terkuat dari varian model GPT (Minaee dkk. 2024). Diluncurkan pada Maret 2023, model ini merupakan model *multi-modal* yang mampu menerima masukan teks serta foto lalu menghasilkan keluaran berupa teks. Meskipun masih memiliki kemampuan yang kurang baik dibanding manusia dalam beberapa skenario, model ini mampu

menunjukkan kemampuan yang menyamai kemampuan mansuaia pada beberpa variasi tolok ukur profesional dan akademis, termasuk meraih nilai dengan skor setara 10% peserta teratas seperti yang ditunjukkan Gambar II.2.

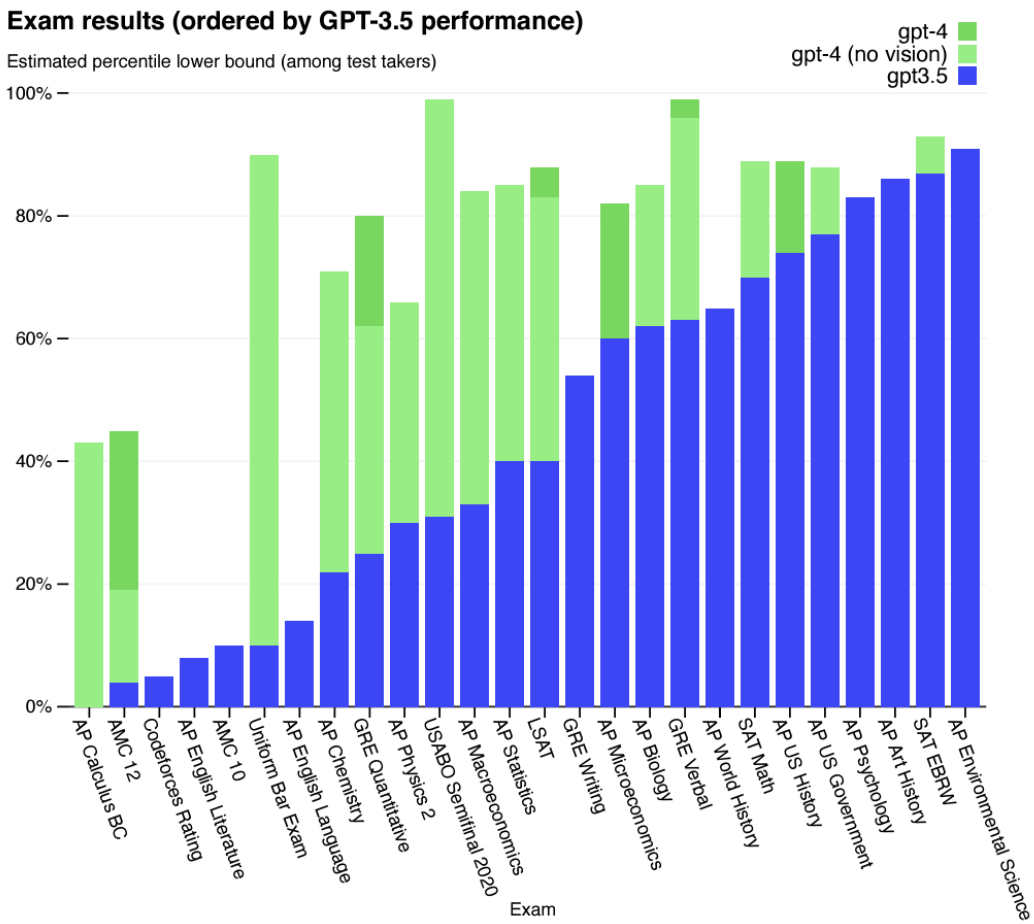

Gambar II.2 Perbandingan Kinerja GPT-4 dengan GPT-3.5 pada Ujian Akademis dan Profesional (OpenAI dkk. 2023)

Selain OpenAI, Meta dan Google pun ikut berlomba dalam pengembangan model LLM. Meta mengembangkan model bernama LLaMa yang, tidak seperti model GPT, bersifat *open-source* (Minaee dkk. 2024). Karena sifatnya yang *open-source*, LLaMa banyak digunakan oleh grup riset dengan tujuan untuk mengembangkan model LLM *open-source* yang dapat berkompetisi dengan model *closed-source* ataupun mengembangkan model LLM pada tugas-tugas tertentu (Minaee dkk.

2024). Dari variasi LLaMa, LLaMa-2, LLaMa-3, hingga LLaMa-3.1, pembaruan serta pengembangan terus dilakukan (Zhao dkk. 2023). Dengan parameter yang meningkat (versi terbesarnya memiliki 405 miliar parameter), *pre-training tokens* yang lebih banyak (15 triliun token), serta *context window* yang diperluas (128 ribu), model LLaMa-3.1 telah meningkatkan kemampuannya secara signifikan dan mencapai kinerja yang kompetitif dibandingkan model-model *closed-source* lainnya seperti GPT-4, GPT-4o, dan Claude 3.5 Sonnet pada berbagai patokan tertentu (Zhao dkk. 2023).

Sementara itu, Google mengembangkan model bernama PaLM (Pathways Language Model) yang pertama kali diumumkan pada bulan April 2022 (Minaee dkk. 2024). Model ini merupakan model dengan 540 miliar parameter dan 780 miliar token yang mampu mengerjakan berbagai tugas bahasa alami dan *use case* (Zhao dkk. 2023). Model generasi berikutnya, yakni PaLM-2, merupakan model yang efisien dalam melakukan komputas dengan kemampuan multibahasa dan penalaran yang lebih baik dibandingkan generasi sebelumnya (Minaee dkk. 2024). Melalui evaluasi yang ekstensif, model PaLM-2 meningkatkan kinerjanya pada berbagai ukuran model dengan tetap menunjukkan inferensi yang lebih cepat dan lebih efisien daripada PaLM (Minaee dkk. 2024),

Walaupun LLM telah mencapai kemajuan dalam mengambil serta memanfaatkan informasi pengetahuan, model ini masih memiliki dua masalah utama (Zhao dkk. 2023):

1. Halusinasi

   Salah satu isu yang menantang dalam membuat teks faktual adalah halusniasi, yakni ketika informasi yang dihasilkan oleh model LLM bertentangan dengan sumber yang ada atau tidak dapet diverifikasi oleh sumber yang tersedia (Zhao dkk. 2023). Halusinasi dapat memengaruhi LLM untuk menghasilkan keluaran yang tidak diinginkan dan dapat

menurunkan kinerjanya sehingga hal ini dapat menimbulkan risiko saat diterapkan dalam aplikasi dunia nyata (Zhao dkk. 2023). Untuk menghindari masalah ini, salah satu strategi yang dapat dilakukan adalah dengan melakukan *alignment tuning* yang bergantung pada data berkualitas tinggi atau menggunakan *feedback* manusia (Zhao dkk. 2023).

2. Pengetahuan Terkini

   Isu lainnya yang dihadapi oleh LLM adalah kesulitan dalam menyelesaikan masalah yang memerlukan pengetahuan terbaru yang ada di luar data pelatihan (Zhao dkk. 2023). Pendekatan yang dapat dilakukan untuk menghindari isu ini adalah dengan melakukan pembaruan pengetahuan pada LLM dengan data baru (Zhao dkk. 2023). Namun, pembaruan pengetahuan dengan data baru perlu dilakukan secara efisien dan efektif untuk menghindari biaya yang mahal dalam melakukan *fine tuning* serta menghindari masalah kelupaan yang fatal pada LLM (Zhao dkk. 2023).

II.2.2.1 LLM dalam Bidang Kesehatan

LLM merupakan "model dasar" yang telah dilatih sebelumnya (*pre-trained*) dan dapat disesuaikan pada berbagai variasi domain (Singhal dkk. 2023). Hal ini memungkinkan adanya pengaplikasian LLM pada domain kesehatan, seperti pencarian pengetahuan (*knowledge retrieval*), dukungan keputusan klinis, peringkasan pada temuan penting, dan masih banyak lagi (Singhal dkk. 2023). Hingga saat ini, beberapa riset telah dilakukan untuk mengembangkan model LLM pada domain kesehatan. Model-model ini memiliki metode *tuning* masing-masing yang memanfaatkan data tekstual dalam domain kesehatan.

Google mengembangkan model LLM pada domain kesehatan yang bernama Med-PaLM. Model ini dibuat untuk memberikan respon yang baik berdasarkan pertanyaan medis (Sai dkk. 2024). Model ini dilatih dengan beberapa strategi *prompting,* salah satunya adalah *intruction prompt tuning*, menggunakan data

literatur medis, publikasi akademis, catatan kesehatan elektronik, serta informasi perawatan kesehatan lainnya (Sai dkk. 2024). Versi model terbarunya, yakni Med-PaLM, merupakan model yang dibangun dari model PaLM 2 (Singhal dkk. 2025). Pada saat dilakukan evaluasi, Med-PaLM 2 mencapai tingkat akurasi sebesar 86,5% pada kumpulan pertanyaan *United States Medical Licensing Examination* (USMLE), meningkat dari versi sebelumnya, Med-PaLM, sebesar 19% (Singhal dkk. 2025). Model ini juga menunjukkan kinerja terbaik pada variasi kumpulan soal pilihan ganda yang terkait dengan topik kesehatan (Singhal dkk. 2025). Meskipun begitu, perlu ada upaya yang lebih banyak untuk memastikan model ini dapat digunakan secara aman dan efektif (Sai dkk. 2024).

Variasi LLM lainnya yang dikembangkan untuk domain kesehatan adalah BioGPT. Model ini dibuat untuk menghasilkan serta menambang teks biomedis (Sai dkk. 2024). BioGPT mengadopsi model GPT-2 yang merupakan model *transformer* dengan arsitektur *decoder* (Luo dkk. 2022). Untuk pelatihan model, BioGPT memanfaatkan 15 juta abstrak PubMed pada situs web *National Library of Medicine* (Luo dkk. 2022). Pada evaluasi menggunakan metode tanya jawab menggunakan set data PubMedQA, BioGPT berhasil mencapai tingkat akurasi sebesar 78.2%, nilai akurasi terbesar dibandingkan beberapa variasi LLM medis lainnya yang telah dikembangkan, seperti PubMedBERT (55.8%), BioELECTRa (64.2%), BioLinkBERT Base (70.2%), BioLinkBERT Large (72.2%), dan GPT-2 Medium (75.0%) (Luo dkk. 2022). Sama seperti model Med-PaLM, BioGPT sebagai model LLM di bidang kesehatan juga masih memerlukan perhatian khusus. Kemampuan model ini dalam memberikan respon layaknya manusia menimbulkan kekhawatiran akan adanya penyalahgunaan atau penyebaran informasi palsu (Sai dkk. 2024). Oleh karena itu, diperlukan pemantauan, validasi, dan penerapan kontrol yang tepat secara menyeluruh untuk menghindari adanya penyebaran informasi palsu pada saat dilakukan penerapan model ini (Sai dkk. 2024).

II.2.2.2 Evaluasi Manusia Terhadap Jawaban LLM dalam Bidang Kesehatan

Kemunculan teknologi *transformers* serta *large language model* telah memungkinkan implementasi AI dalam tugas tanya jawab dalam domain medis (Singhal dkk. 2025). Namun, seperti yang dijelaskan pada subbab II.2.2, salah satu kekurangan yang dimiliki LLM adalah halusinasi serta keterbatasan pengetahuan. Adanya misinformasi pada jawaban LLM, terutama dalam domain kritis seperti bidang kesehatan, dapat berdampak fatal bagi penggunanya. Oleh karena itu, perlu adanya evaluasi dari ahli di bidang terkait terhadap jawaban yang dihasilkan oleh LLM.

Salah satu penelitian yang memanfaatkan evaluasi manusia terhadap jawaban LLM merupakan evaluasi LLM pada tugas peringkasan teks studi penelitian medis dan uji klinis yang melampaui kemampuan evaluasi secara terotomasi (Tang dkk. 2023). Penelitian tersebut membandingkan kemampuan model GPT-3.5 dan ChatGPT (model GPT-3.5 yang dilakukan *fine-tuning*) dalam meringkas dokumen abstrak pada penelitian yang tersimpan dalam Cochrane Library dengan menerapkan *zero-shot prompting*. Dokumen diambil dari enam domain klinis, yakni penyakit Alzheimer, penyakit ginjal, penyakit kerongkongan, kondisi neurologis, kelainan kulit, dan gagal jantung. Setiap dokumen abstrak berisi latar belakang, objektif, metode, kriteria pemilihan metode, koleksi dan analisis data, hasil utama, serta kesimpulan penulis (Tang dkk. 2023). Dalam penelitian yang dilakukan, diterapkan beberapa konfigurasi pada LLM yang digunakan. Konfigurasi pertama akan menggunakan model ChatGPT dan memanfaatkan seluruh isi abstrak kecuali kesimpulan penulis sebagai masukan (konfigurasi ini disebut ChatGPT-Abstract). Sementara itu, pada konfigurasi kedua, model ChatGPT dan GPT-3.5 akan hanya diberi masukan berupa objektif dan hasil utama penelitian (konfigurasi ini disebut ChatGPT-MainResult dan GPT3.5-MainResult) (Tang dkk. 2023).

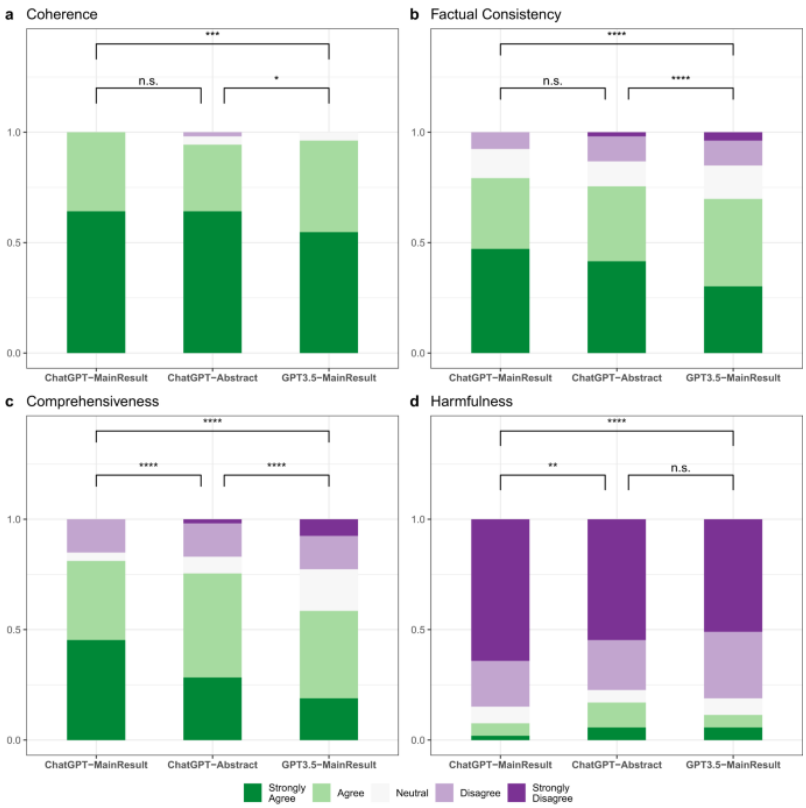

Gambar II.3 Perbandingan Kinerja dalam Sistem Peringkasan Melalui Evaluasi Manusia (Tang dkk. 2023)

Gambar II.3 menunjukkan perbandingan kinerja beberapa konfigurasi LLM dalam melakukan tugas peringkasan teks. Pada evaluasi dengan ahli terkait, penilaian dilakukan dengan memberikan nilai skala likert antara satu sampai lima pada setiap metrik. Terdapat empat metrik evaluasi yang digunakan dalam penelitian tersebut:

1. Koherensi (*Coherence*)

   Koherensi diartikan sebagai kemampuan dari ringkasan dalam menghasilkan konten informasi topik yang koheren melalui hubungan antar kalimat. Gambar II.3 menunjukkan ketiga konfigurasi menghasilkan ringkasan yang koheren. Lebih spesifiknya, ringkasan yang dihasilkan ChatGPT lebih koheren dibandingkan GPT-3.5.

2. Konsistensi Faktual (*Factual Consistency*)

   Metrik konsistensi faktual mengukur apakah pernyataan dalam ringkasan yang dihasilkan oleh LLM dapat didukung oleh dokumen sumber. Hasil evaluasi pada Gambar II.3 menunjukkan adanya galat (*error*) pada konsistensi faktual dari ringkasan yang dihasilkan dengan ChatGPT-MainResult sebagai konfigurasi yang memiliki tingkat galat terrendah (10%) dibanding dua konfigurasi lainnya.

3. Kelengkapan (*Comprehensiveness*)

   Kelengkapan menentukan apakah ringkasan yang dihasilkan oleh LLM berisi informasi yang komprehensif (lengkap) untuk mendukung isi dokumen penelitian yang ada pada Cochrane Library. Pada Gambar II.3, lebih dari 75% ahli menilai model ChatGPT mampu menghasilkan ringkasan yang komprehensif sementara model GPT-3.5 menghasilkan ringkasan yang kurang komprehensif dibanding ChatGPT.

4. Potensi Bahaya (*Harmfulness*)

   Metrik ini diartikan sebagai potensi dari ringkasan yang dihasilkan oleh LLM dapat menyebabkan bahaya, baik secara fisik ataupun psikologis, atau perubahan pada terapi atau kepatuhan medis yang tidak diinginkan akibat adanya misinterpretasi dari informasi yang terdapat di dalam ringkasan. Dari perbandingan pada Gambar II.3, konfigurasi ChatGPT-MainResult menghasilkan ringkasan yang paling aman secara medis dibanding dua konfigurasi lainnya (Tang dkk. 2023).

Selain memberikan penilaian kuantitatif, para ahli juga memberikan anotasi sebagai penilaian kualitatif. Anotasi yang diberikan ahli terhadap kualitas ringkasan memiliki berbagai variasi dan variasi ini dapat disebabkan beberapa faktor:

1. Adanya kompleksitas yang berbeda antar domain
2. Para ahli memiliki interpretasi yang berbeda terhadap setiap metrik evaluasi

3. Preferensi individu terkait informasi utama apa yang perlu ada di dalam ringkasan (Tang dkk. 2023).

II.2.3 *Retrieval Augmented Generation*

Seperti yang dijelaskan pada subbab II.2.2, dua kelemahan utama dari LLM adalah kecenderungan dalam "berhalusinasi" serta keterbatasan pengetahuan terbaru. Untuk menangani masalah ini, *Retrieval Augmented Generation* (RAG) memperkuat kemampuan LLM dengan mengumpulkan potongan dokumen terkait dari basis pengetahuan eksternal menggunakan metode kalkulasi kesamaan semantik (Y. Gao dkk. 2023). Dengan merujuk pada pengetahuan eksternal, RAG dapat mengurangi masalah dalam menghasilkan konten yang salah secara faktual (Y. Gao dkk. 2023). Secara garis besar, metodologi dalam RAG dasar mencakup tiga proses:

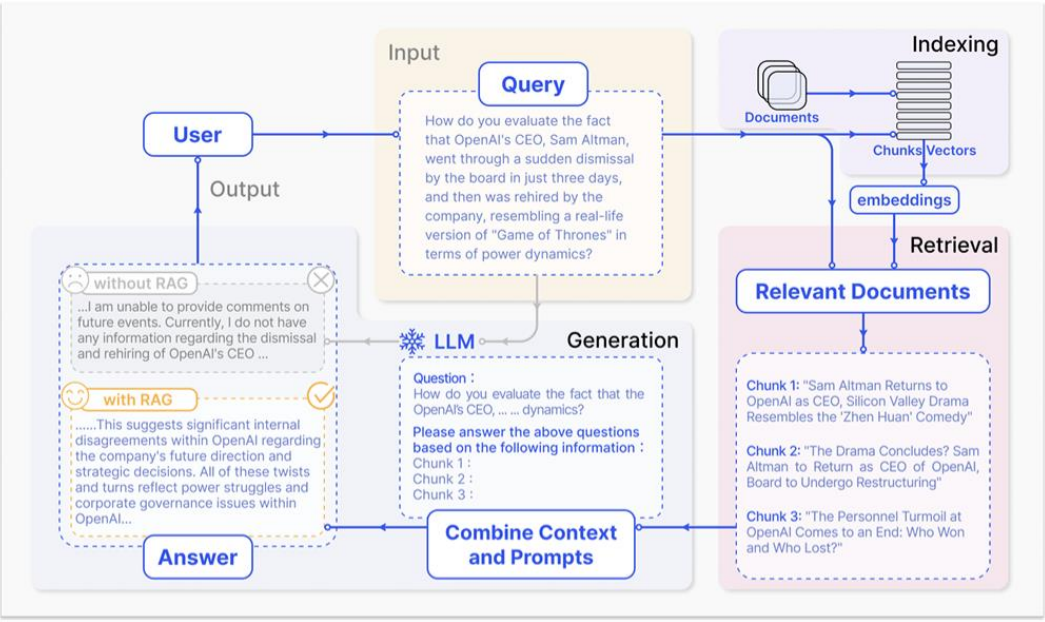

Gambar II.4 Proses dalam *Retrieval Augmented Generation* (Y. Gao dkk. 2023)

1. *Indexing*

   Proses dalam RAG dimulai dari ekstraksi serta pembersihan data dari berbagai format, seperti PDF, HTML, Word, dan Markdown, yang kemudian akan dikonversi menjadi format teks biasa yang seragam. Untuk menyesuaikan dengan batasan konteks dari model bahasa, teks dipecah menjadi segmen-segmen (*chunks*) kecil yang mudah diproses oleh model bahasa. Segmen-segmen ini kemudian di-*encode* menjadi bentuk vektor menggunakan model *embedding* lalu vektor disimpan ke dalam basis data vektor (*vector database*). Langkah ini penting dilakukan untuk memungkinkan pencarian kesamaan teks yang efisien pada proses *retrieval* di langkah selanjutnya.

2. *Retrieval*

   Setelah menerima masukan *query* dari pengguna, sistem RAG menggunakan model *embedding* yang sama pada proses *indexing* untuk mengubah masukan *query* menjadi bentuk vektor. Sistem kemudian menghitung skor kesamaan (contohnya dengan perhitungan *cosine similarity*) antara vektor *query* dengan vektor segmen dalam korpus yang diindeks. Setelah itu, sistem mengambil K segmen teratas yang memiliki kesamaan terbaik dengan *query*. Rumus di bawah merupakan contoh perhitungan skor kesamaan dengan *cosine similarity*.

$$similarity(x, y) = \frac{\sum_{i=1}^{p} x_i y_i}{\sqrt{\sum_{i=1}^{p} {x_i}^2} \sqrt{\sum_{i=1}^{p} {y_i}^2}} \qquad \text{(II. 2)}$$

3. *Generation*

   Masukan *query* dan dokumen-dokumen yang terpilih kemudian disintesis menjadi *prompt* koheren yang akan diberikan kepada LLM untuk memformulasikan respon. Pendekatan model dalam menjawab pertanyaan dapat bervariasi sesuai kriteria pada tugas yang diberikan. Apabila terdapat interaksi berupa dialog, riwayat percakapan dapat diintegrasikan dalam

prompt untuk memungkinkan model untuk dalam interaksi dialog multi-putaran secara efektif (Y. Gao dkk. 2023).

Pada fase *retrieval* yang umum, semakin besar ukuran parameter pada model *embedding* maka semakin akurat segmen yang diambil. Namun, hal ini dapat menjadi tantangan apabila sistem ingin mengembangkan akurasi *retrieval* karena model *embedding* dengan ukuran parameter yang besar dapat memakan biaya yang cukup banyak atau memiliki komputasi yang lambat ketika melakukan *indexing* (Moreira dkk. 2024). Oleh karena itu, salah satu alternatif yang dapat dilakukan adalah dengan menerapkan *reranking* pada sistem *retrieval*. Model *ranking* pada umumnya merupakan model dengan arsitektur *Transformers* yang mengambil masukan berupa *query* dan segmen. Model ini kemudian menyediakan prediksi skor relevansi untuk beberapa kandidat dengan skor tertinggi dari segmen yang dihasilkan model *retrieval* (Moreira dkk. 2024).

Tantangan lain yang dihadapi oleh RAG adalah ketergantungannya pada *query* yang dimasukkan pengguna sebagai basis dalam proses *retrieval* (Y. Gao dkk. 2023). Menyusun pertanyaan yang jelas dan spesifik bukanlah tugas yang mudah, dan pertanyaan yang tidak tersusun dengan baik dapat mengurangi kualitas hasil pencarian (Y. Gao dkk. 2023). Terkadang, pertanyaan memiliki tingkat kompleksitas tinggi dengan penggunaan bahasa yang kurang terorganisir (Y. Gao dkk. 2023). Untuk mencegah ini, beberapa pendekatan dapat dilakukan dengan mengoptimasi masukan *query*:

1. *Query Expansion*

   Memperluas sebuah *query* menjadi beberapa *query* membantu memperkaya konten dari *query*, menambahkan konteks untuk menangani kekurangan detail spesifik, serta memastikan jawaban yang dihasilkan lebih relevan dan sesuai.

2. *Query Transformation*

   Konsep inti dari pendekatan ini adalah mengambil segmen dalam dokumen berdasarkan *query* yang telah ditransformasi, bukan *query* asli yang dimasukkan oleh pengguna.

3. *Query Routing*

   Dengan banyaknya variasi *query, query* akan diarahkan pada RAG *pipeline* tertentu sehingga sistem RAG akan menjadi serbaguna untuk mengakomodasi skenario yang berbeda-beda (Y. Gao dkk. 2023).

II.2.3.1 *Hypothetical Document Embeddings*

Hypothetical Document Embeddings (HyDE) merupakan salah satu pendekatan dalam mengoptimasi *query* dalam sistem RAG melalui transformasi *query*. Dalam pendekatan ini, *query* akan dimasukkan ke dalam model LLM dan menginstruksikan model tersebut untuk menghasilkan dokumen hipotesis (L. Gao dkk. 2023). Dokumen hipotesis ini merupakan dokumen yang tidak asli dan dapat mengandung kesalahan fakta namun dokumen diibaratkan sebagai dokumen yang relevan (L. Gao dkk. 2023). Dokumen hipotesis ini kemudian akan diubah menjadi vektor *embedding* dan dilakukan pencarian kesamaan dengan dokumen asli (L. Gao dkk. 2023). Gambar II.4 menggambarkan ilustrasi dari model pendekatan HyDE dalam sistem RAG. Secara garis besar, pendekatan HyDE berfokus pada pencarian kesamaan *embedding* antara jawaban dengan jawaban, bukan antara *query* dan jawaban (Y. Gao dkk. 2023).

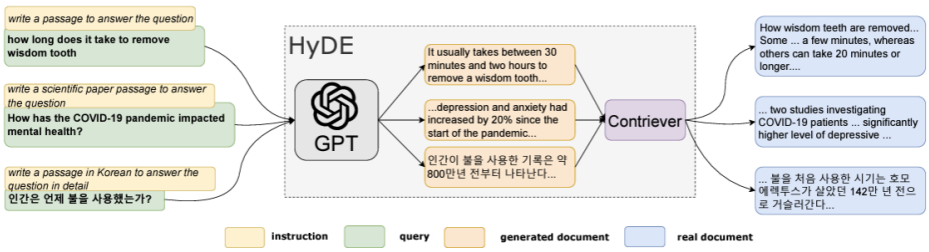

Gambar II.5 Ilustrasi Proses *Hypothetical Document Embeddings* (L. Gao dkk. 2023)

II.2.3.2 Penerapan RAG pada Sistem Tanya Jawab Domain Kesehatan

Tanya jawab (*question answering*) pada bidang medis kerap menjadi subjek penelitian karena berbagai kebutuhan informasi dalam medis diekspresikan dengan pertanyaan bahasa alami (Xiong dkk. 2024). Dengan kemampuannya yang memungkinkan LLM untuk memberikan respon yang dilandasi oleh pengetahuan yang relevan dari kumpulan dokumen, RAG telah diimplementasikan dalam berbagai sistem tanya jawab pada bidang ilmiah dan medis (Xiong dkk. 2024). Penelitian yang dilakukan oleh (Xiong dkk. 2024) pada tahun 2024 merupakan salah satu penelitian yang mengimplementasikan RAG pada sistem tanya jawab dalam domain kesehatan yang bernama MedRAG. Selain mengimplementasikan MedRAG, penelitian ini juga menekankan metode evaluasi sistematis pada sistem RAG dalam domain kesehatan.

MedRAG memanfaatkan data mentah dari empat sumber, yakni PubMed yang berisi kumpulan teks abstrak penelitian ilmiah biomedis, StatPearls yang berisi teks mengenai dukungan keputusan klinis, beberapa buku teks yang menyediakan pengeatahuan pada domain spesifik, serta Wikipedia yang menyimpan pengetahuan umum (Xiong dkk. 2024). Model yang digunakan pada penelitian ini adalah model-model yang cukup sering digunakan pada MedRAG, yakni GPT-4, GPT-3.5, Mixtral, LLaMa2, MEDITRON, dan PMC-LLaMa (Xiong dkk. 2024). Pada pengimplementasian sistem ini, diperkenalkan juga tolok ukur evaluasi sistematis bernama Mirage yang mnggunakan kumpulan set data pertanyaan terkait bidang medis untuk mengevaluasi akurasi dari jawaban model dalam sistem MedRAG. Evaluasi sistematis ini juga berfokus pada evaluasi kemampuan *zero-shot* pada MedRAG yang artinya model tidak diberikan demonstrasi sebelumnya (Xiong dkk. 2024). Pada evaluasi, dilakukan juga perbandingan kinerja model dalam MedRAG dengan model yang diberikan *chain-of-thought* (CoT) *prompting*. Secara garis besar, ketika dibandingkan dengan penerapan CoT, MedRAG telah meningkatkan akurasi dari keenam model yang digunakan, khususnya pada model GPT-3.5

(peningkatan sekitar 11%), GPT-4 (peningkatan sekitar 6%), dan Mixtral (peningkatan sekitar 8%).

Tabel II.1 Hasil Tolok Ukur Akurasi LLM dengan Evaluasi Sistematis Mirage (Xiong dkk. 2024)

LLM	Metode	Set Data					Rata-rata
		MMLU-Med	MedQA-US	MedMCQA	PubMedQA	BioASQ-Y/N	
GPT-4	CoT	89.44 ± 0.93	83.97 ± 1.03	69.88 ± 0.71	39.60 ± 2.19	84.30 ± 1.46	73.44
	MedRAG	87.24 ± 1.01	82.80 ± 1.06	66.65 ± 0.73	70.60 ± 2.04	92.56 ± 1.06	79.97
GPT-3.5	CoT	72.91 ± 1.35	65.04 ± 1.34	55.25 ± 0.77	36.00 ± 2.15	74.27 ± 1.76	60.69
	MedRAG	75.48 ± 1.30	66.61 ± 1.31	66.61 ± 0.73	67.40 ± 2.10	90.26 ± 1.19	67.04
Mixtral	CoT	74.01 ± 1.33	64.10 ± 1.34	56.28 ± 0.75	35.20 ± 2.20	77.51 ± 1.68	61.42
	MedRAG	75.85 ± 1.30	60.02 ± 1.30	56.42 ± 0.77	67.60 ± 2.20	87.54 ± 1.64	69.48
LLaMa2	CoT	57.39 ± 1.50	47.84 ± 1.40	42.60 ± 0.76	28.40 ± 2.21	61.17 ± 1.80	50.24
	MedRAG	54.55 ± 1.51	44.93 ± 1.39	43.08 ± 0.77	50.40 ± 2.24	73.95 ± 1.77	53.38
MEDITRON	CoT	64.92 ± 1.45	51.69 ± 1.45	46.74 ± 0.77	53.40 ± 2.23	68.45 ± 1.87	57.04
	MedRAG	65.38 ± 1.44	49.57 ± 1.40	46.74 ± 0.77	54.00 ± 2.22	76.86 ± 1.87	57.04
PMC-LLaMA	CoT	52.16 ± 1.51	44.38 ± 1.39	46.55 ± 0.77	50.60 ± 2.22	63.11 ± 1.84	52.40
	MedRAG	52.53 ± 1.51	42.58 ± 1.39	48.29 ± 0.77	56.00 ± 2.22	65.21 ± 1.84	52.92

II.2.3.3 Kerangka Kerja Evaluasi Sistem RAG

Pengembangan sistem RAG memerlukan metode *tuning* karena kinerjanya dipengaruhi oleh model *retrieval*, model bahasa (*language model*), *prompt*, atau beberapa hal lainnya. Oleh karena itu, evaluasi sistem RAG yang terotomasi sangat diperlukan (Es dkk. 2024). Serangkaian perkakas dan tes pengukuran telah disulkan untuk memfasilitasi evaluasi sistem RAG (Y. Gao dkk. 2023). Strategi evaluasi RAG kerap bergantung pada probabilitas model bahasa namun tidak dapat diakses untuk beberapa model *closed-source* seperti GPT-4. Salah satu strategi lainnya adalah dengan membuat sistem tanya jawab dengan tipe jawaban yang singkat namun hal ini tidak representatif terhadap cara sistem RAG bekerja (Es dkk. 2024). Untuk mengatasi masalah tersebut, salah satu kerangka kerja yang dapat menjadi alternatif adalah RAGAS.

RAGAS atau singkatan dari *Retrieval Augemented Generation Assesment System* merupakan sebuah kerangka kerja yang dibuat untuk mengotomasi penilaian dari sistem RAG (Es dkk. 2024). Kerangka kerja ini dibuat oleh beberapa peneliti NLP yang berasal dari Cardiff University. RAGAS melakukan penilaian dengan melakukan *prompting* pada LLM (Es dkk. 2024) dengan berfokus pada tiga aspek kualitas pada sistem RAG:

1. *Faithfulness*

   Aspek *faithfulness* mengacu pada gagasan bahwa jawaban yang dihasilkan harus didasarkan pada konteks yang diberikan (Es dkk. 2024). Secara garis besar, untuk mengestimasi aspek *faithfulness*, dilakukan *prompting* kepada LLM untuk mengekstraksi satu atau lebih pernyataan dari setiap kalimat pada jawaban yang diberikan oleh sistem RAG (Es dkk. 2024). Kemudian, LLM akan memutuskan apakah setiap pernyataan yang dihasilkan terdapat pada konteks yang diberikan dalam sistem RAG (Es dkk. 2024). Skor *faithfulness* kemudian dihitung dengan rumus pada persamaan II.1 (Es dkk. 2024).

$$F = \frac{|V|}{|S|} \tag{II. 3}$$

Keterangan:

$|V|$ = Jumlah pernyataan yang didukung oleh konteks (berdasarkan LLM)

$|S|$ = Jumlah total pernyataan

2. *Answer Relevance*

Jawaban dapat dikatakan relevan apabila jawaban tersebut menjawab pertanyaan secara langsung dengan cara yang tepat (Es dkk. 2024). Untuk mengestimasi relevansi jawaban, LLM akan diperintah untuk menghasilkan tiga set pertanyaan berdasarkan jawaban yang dihasilkan dalam sistem RAG (Es dkk. 2024). Pertanyaan yang dihasilkan LLM ini kemudian dibandingkan dengan pertanyaan asli yang digunakan dalam sistem RAG dengan menghitung nilai *cosine similarity.*

$$AR = \frac{1}{n}\sum_{i=1}^{n} sim(q, q_i) \tag{II. 4}$$

Keterangan:

$q = pertanyaan\ asli$

$q_i = pertanyaan\ yang\ dihasilkan\ oleh\ LLM$

$n = jumlah\ pertanyaan\ yang\ dihasilkan\ oleh\ LLM$

Metrik ini mengukur seberapa dekat pertanyaan yang dihasilkan oleh LLM dengan pertanyaan asli yang digunakan dalam sistem RAG (Es dkk. 2024).

3. *Context Relevance*

Konteks dapat dianggap relevan apabila konteks berisi informasi yang dibutuhkan untuk menjawab pertanyaan. Untuk mengestimasi relevansi konteks, LLM akan diperintahkan untuk mengekstrak kalimat-kalimat dalam konteks yang dapat membantu menjawab pertanyaan. Dari kalimat-kalimat yang dihasilkan oleh LLM, dilakukan perhitungan skor relevansi konteks dengan melihat rasio antara jumlah kalimat yang diekstrak oleh LLM dengan jumlah total kalimat dalam konteks (Es dkk. 2024).

$$CR = \frac{jumlah\ kalimat\ yang\ diekstrak\ dari\ konteks}{jumlah\ total\ kalimat\ dalam\ konteks} \quad (II.5)$$

Namun, pada versi terbaru RAGAS, metrik ini dikembangkan kembali menjadi dua metrik evaluasi, yakni:

a. *Context precision*, yakni mengukur proporsi segmen (*chunk*) yang relevan. Metrik ini diukur sebagai rata-rata nilai *precision* di setiap segmen di dalam konteks.

$$Context\ Precision@K = \frac{\sum_{k=1}^{K}(Precision@k \times v_k)}{Jumlah\ item\ relevan\ dalam\ hasil\ K\ teratas} \quad (II.6)$$

$$Precision@k = \frac{true\ positives@k}{true\ positives@k + false\ positives@k} \quad (II.7)$$

Keterangan:

$K = jumlah\ segmen\ (chunk)$

$v_k \in \{0,1\}$ menandakan indikator relevansi pada segmen ke-k

b. *Context recall*, yakni mengukur seberapa banyak dokumen relevan yang berhasil didapatkan. Pada teknik context recall berbasis LLM, beberapa klaim akan dihasilkan dari referensi atau jawaban ground truth menggunakan LLM. Dari sejumlah klaim tersebut, akan dihitung proporsi klaim yang dapat dikaitkan dengan konteks dalam segmen (*chunk*) yang diambil.

$$Context\ Recall = \frac{Jumlah\ klaim\ yang\ dapat\ dikaitkan\ dengan\ konteks}{Jumlah\ total\ klaim} \quad (II.8)$$

BAB III

ANALISIS MASALAH DAN DESAIN KONSEP SOLUSI

III.1 Analisis Kondisi Saat Ini

Pada subbab ini, akan dilakukan analisis terkait kondisi sistem yang berkaitan dengan topik tugas akhir ini. Untuk melakukan analisis tersebut, dilakukan *business understanding* dan *data understanding* yang merupakan dua tahap awal dalam metodologi CRISP-DM. Sesuai dengan penjelasan subbab I.5 mengenai metodologi, tujuan dilakukannya *business understanding* adalah untuk memahami objektif serta kebutuhan bisnis. Sementara itu, *data understanding* dilakukan untuk memahami kondisi yang ada pada kumpulan teks dokumen yang digunakan untuk sistem yang akan dirancang. Objektif bisnis serta hasil eksplorasi data akan menjadi dasar untuk analisis kebutuhan pada subbab III.2.

III.1.1 *Business Understanding*

Pada tahap ini, dilakukan pemahaman terkait kebutuhan penyediaan informasi mengenai penyakit jantung dalam bentuk interaksi tanya jawab. Menurut data World Health Organization pada tahun 2021, penyakit jantung atau *cardiovascular disease* (CVD) merupakan penyebab kematian yang paling sering terjadi secara global. Pada tahun 2021, jumlah kematian akibat penyakit jantung di Indonesia mencapai 765.660 kematian (Institute for Health Metrics and Evaluation 2024) dan pada tahun 2023, kasus penyakit jantung memiliki jumlah kasus tertinggi yang dijamin oleh BPJS Kesehatan dengan jumlah sebanyak 20,4 juta kasus (Fitriani 2024). Dengan tingginya jumlah kasus penyakit jantung yang terjadi di Indonesia, terdapat urgensi untuk meningkatkan kesadaran masyarakat mengenai penyakit jantung beserta hal-hal berkaitan lainnya seperti pencegahan, gejala, dan pengobatannya.

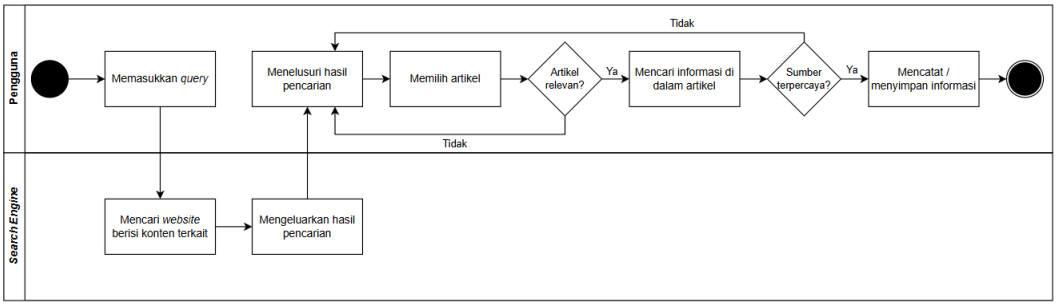

Gambar III.1 *Activity Diagram* dalam Aktivitas Pencarian Informasi Kesehatan Menggunakan Mesin Pencari

Dengan semakin berkembangnya teknologi informasi, pemanfaatan internet untuk mencari informasi kesehatan semakin banyak dilakukan. Informasi yang disediakan secara daring dapat mencakup gejala, diagnosis, dan pengobatan berbagai penyakit (Jia, Pang, dan Liu 2021). Dalam mesin pencari yang ada saat ini, seperti Google Search, Bing, dan Yahoo, interaksi dibatasi oleh aksi yang sudah ditentukan, seperti memasukkan query secara berulang, melakukan scrolling, berpindah halaman web, dan lain-lain (Aliannejadi, Gwizdka, dan Zamani 2024). Gambar III.1 menggambarkan alur aktivitas pada pengguna yang ingin mencari informasi kesehatan menggunakan mesin pencari. Dalam bidang kesehatan, kebutuhan informasi dalam medis sering diekspresikan dengan pertanyaan bahasa alami (Xiong dkk. 2024) sehingga dalam penelitian ini, sistem penyediaan informasi mengenai penyakit jantung dapat diimplementasikan dalam bentuk interaksi berupa tanya jawab.

Teknologi dalam penyediaan informasi terus berkembang untuk dapat memberikan informasi lebih cepat serta terpersonalisasi kepada pengguna dan teknologi *generative AI* yang berkembang pesat pada beberapa tahun terakhir telah membuka cara baru dalam pengaksesan informasi (Mitra dkk. 2024). Kemampuan sistem *generative AI* dalam menghasilkan konten yang baru dan berarti seperti teks, foto,

atau audio (Feuerriegel dkk. 2024) berpotensi mendorong cara pencarian informasi yang berfokus pada pembuatan dan modifikasi informasi untuk memenuhi kebutuhan informasi atau menyelesaikan masalah (Hirvonen dkk. 2024). Namun, muncul kekhawatiran akan kekurangan utama dari *generative AI* yang didukung oleh *large language model* (LLM), yakni kecenderungan untuk "berhalusinasi" disebabkan oleh keterbatasan pengetahuan terbaru. Dalam domain kritis seperti bidang kesehatan dan hukum yang menekankan pentingnya keakuratan dan keandalan, kesalahan kecil sekalipun dapat menimbulkan konsekuensi yang serius sehingga diperlukan pemrosesan informasi yang sangat hati-hati (Pang dkk. 2024). Oleh karena itu, untuk mengatasi "halusinasi" pada pemanfaatan *generative AI* untuk sistem tanya jawab, diperlukan pengimplementasian *knowledge injection* untuk menambah pengetahuan pada model (Ovadia dkk. 2023).

III.1.2 *Data Understanding*

Pada tahap *data understanding,* dilakukan terlebih dahulu pengumpulan data yang akan digunakan sebagai konteks pengetahuan untuk LLM dalam sistem tanya jawab mengenai penyakit jantung. Untuk penelitian ini, data yang digunakan sebagai landasan informasi mengenai penyakit jantung adalah kumpulan artikel mengenai penyakit jantung yang tersedia pada situs web Alodokter. Seluruh artikel pada situs web Alodokter merupakan artikel yang ditulis dalam bahasa Indonesia mengutip dari berbagai macam sumber, seperti National Health Service UK, National Institutes of Health, dan Mayo Clinic. Secara umum, artikel-artikel di situs web tersebut ditulis dengan gaya bahasa yang formal namun tetap disusun secara jelas dan mudah dipahami, meskipun mengandung beberapa istilah medis. Pengumpulan dilakukan dengan metode *web scraping*, yakni proses ekstraksi data dari situs web.

Web scraping diawali dengan mengambil halaman utama berisi kumpulan artikel yang berkaitan dengan penyakit jantung dan dilanjutkan dengan menulusuri setiap

tautan artikel. Seluruh teks dari subtopik-subtopik dari setiap artikel kemudian diambil dan diproses menggunakan *library* BeautifulSoup, termasuk elemen paragraf dan daftar poin. Scraping dilakukan pada 45 artikel dengan topik penyakit jantung yang berbeda-beda. Dari *scraping* yang dilakukan, data yang diambil mencakup judul topik, URL topik, serta kumpulan subtopik yang terdiri dari judul subtopik, URL subtopik, dan isi konten subtopik. Hasil *scraping* dikumpulkan dan disimpan dalam bentuk ekstensi file JSON.


```
1  [
2      {
3          "topic": "Hipertensi",
4          "url": "https://www.alodokter.com/hipertensi",
5          "subtopics": [
6              {
7                  "subtopic": "Pengertian Hipertensi",
8                  "subtopic_url": "https://www.alodokter.com/hipertensi",
9                  "content": "Hipertensi atau darah tinggi adalah kondisi ketika tekanan darah berada pada angka 130/8
10             },
11             {
12                 "subtopic": "Penyebab Hipertensi",
13                 "subtopic_url": "https://www.alodokter.com/hipertensi/penyebab",
14                 "content": "Hipertensi dibagi menjadi hipertensi primer dan sekunder. Hipertensi primer berkembang s
15             },
16             {
17                 "subtopic": "Penyebab Hipertensi: Faktor Risiko Hipertensi",
18                 "subtopic_url": "https://www.alodokter.com/hipertensi/penyebab",
19                 "content": "Ada beberapa faktor yang bisa meningkatkan risiko seseorang terserang hipertensi, yaitu:
20             },
21             {
22                 "subtopic": "Gejala Hipertensi",
23                 "subtopic_url": "https://www.alodokter.com/hipertensi/gejala",
24                 "content": "Hipertensi merupakan penyakit yang berbahaya, karena bisa terjadi tanpa gejala. Bahkan,
25             },
26             {
```


Gambar III.2 Hasil *Scraping* Artikel Penyakit Jantung pada Alodokter

Tabel III.1 Deskripsi Kolom dalam Hasil Scraping Artikel pada Situs Web Alodokter

No.	Kolom	Deskripsi
1.	topic	Judul topik
2.	subtopic	Judul subtopik pada topik terkait
3.	content	Isi konten dari dari subtopik terkait

Setelah data sudah terkumpul melalui *scraping*, dilakukan pemahaman terhadap data artikel penyakit jantung. Pemahaman ini dilakukan untuk mengidentifikasi

karakteristik dari data yang sudah terkumpul. Untuk melakukan pemahaman tersebut, dilakukan pendekatan bernama *exploratory data analysis* (EDA). Untuk mempermudah eksplorasi, file JSON akan ditransformasi menjadi *dataframe* dengan kolom sesuai dengan Tabel III.1. Dari seluruh data yang didapatkan melalui *scraping*, data URL topik dan URL subtopik tidak akan digunakan dalam eksplorasi ini sehingga keduanya tidak akan dimasukkan ke dalam *dataframe*. Terdapat empat jenis eksplorasi yang dilakukan pada kegiatan EDA untuk *data understanding*, mencakup jumlah subtopik di setiap topik, panjang konten, frekuensi kata, dan karakter *unicode.*

III.1.2.1 Jumlah Subtopik di Setiap Topik

Pada eksplorasi ini, dilakukan analisis terhadap jumlah subtopik di setiap topik pada kumpulan artikel penyakit jantung. Dengan menggunakan *horizontal bar chart,* didapatkan perbandingan jumlah subtopik di setiap variasi topik penyakit jantung. Visualisasi *bar chart* pada Gambar III.2 memperlihatkan topik "Penyakit Jantung Koroner" sebagai topik dengan jumlah subtopik terbanyak.

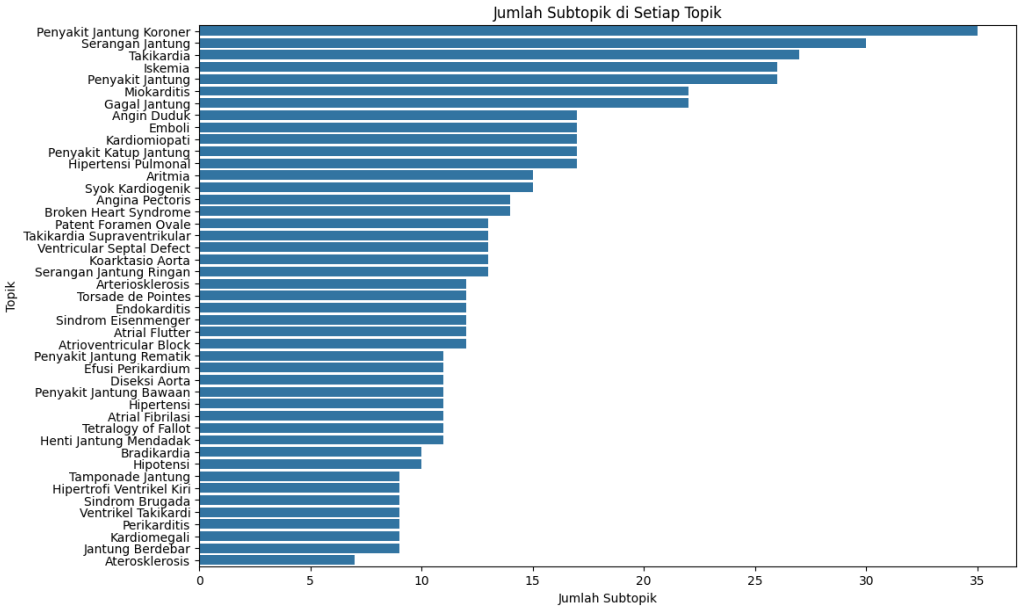

Gambar III.3 Visualisasi Jumlah Subtopik di Setiap Topik

III.1.2.2 Panjang Konten

Pada artikel-artikel yang telah dikumpulkan, setiap topik memiliki variasi kontennya masing-masing dengan panjang konten yang berbeda. Pada eksplorasi data ini, dilakukan beberapa analisis terhadap panjang konten pada kumpulan artikel penyakit jantung. Panjang konten diukur dengan menghitung jumlah kata pada setiap konten yang terkumpul. Eksplorasi panjang konten dimulai dari analisis distribusi panjang konten untuk melihat *central tendency* dari panjang konten. Nilai *mean* yang lebih besar dari nilai median pada Tabel III.2 menunjukkan adanya kecenderungan kecondongan (*skewness*) yang positif pada data jumlah kata.

Tabel III.2 Statistik Deskriptif dari Jumlah Kata pada Konten

Ukuran	Nilai
count	646
mean	76.341
std	52.549
min	8
25%	37
50%	64
75%	97.75
max	361

Selain statistik deskriptif, visualisasi histogram pada Gambar III.3 dan *boxplot* pada Gambar III.4 memberikan gambaran yang lebih jelas mengenai distribusi data yang *right skewed*. Distribusi ini menunjukkan adanya *outlier* yang mayoritas melebihi batas atas (*upper bound*).

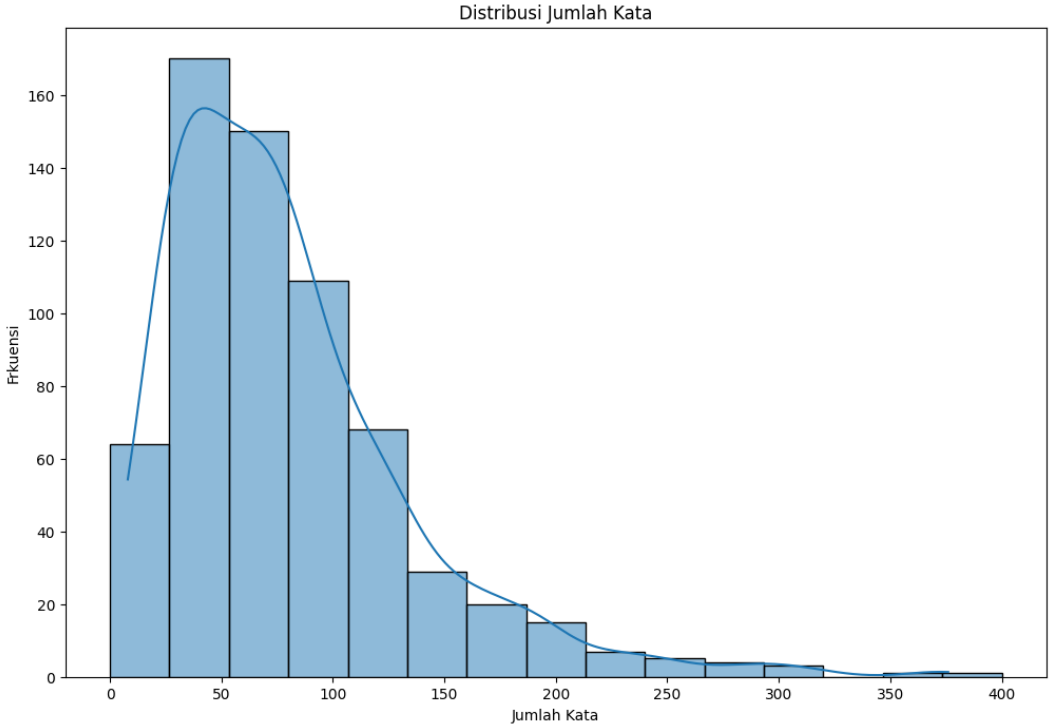

Gambar III.4 Grafik Histogram Distribusi Jumlah Kata

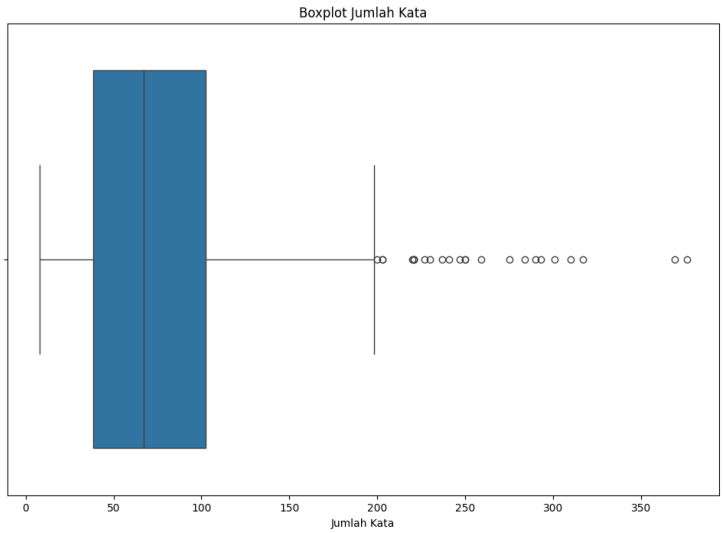

Gambar III.5 Boxplot Jumlah Kata

Dengan menggunakan *bar chart,* dilakukan juga perbandingan jumlah kata pada setiap konten pada kumpulan artikel penyakit jantung. Gambar III.5 menunjukkan jumlah kata dari setiap judul topik. Grafik tersebut menunjukkan topik "Penyakit Jantung" merupakan topik dengan konten terpanjang dibanding 44 konten lainnya.

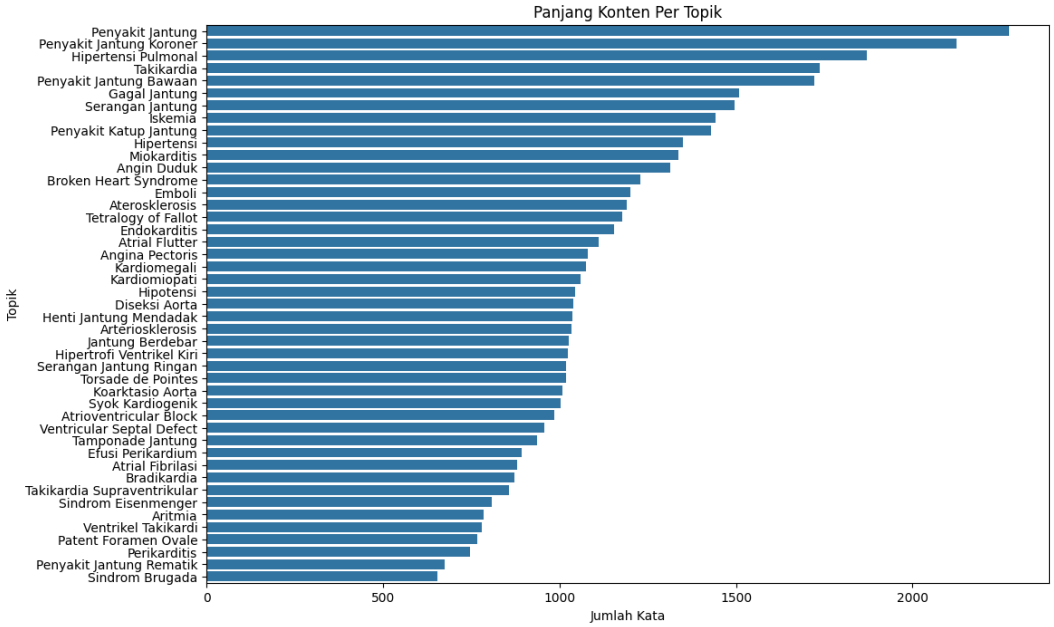

Gambar III.6 Perbandingan Panjang Konten Per Topik

III.1.2.3 Frekuensi Kata

Setiap konten dalam artikel tersusun atas variasi kata yang unik sesuai dengan konteks tertentu. Dalam eksplorasi ini, akan dilakukan perbandingan frekuensi kemunculan kata pada 45 artikel penyakit jantung yang telah dikumpulkan. Visualisasi *horizontal bar chart* pada Gambar III.7 menunjukkan 20 kata teratas dengan frekuensi kemunculan terbanyak pada konten artikel. Kata "jantung" menempati posisi pertama dengan jumlah frekuensi terbanyak dengan jumlah kemunculan sebanyak 2139 kali.

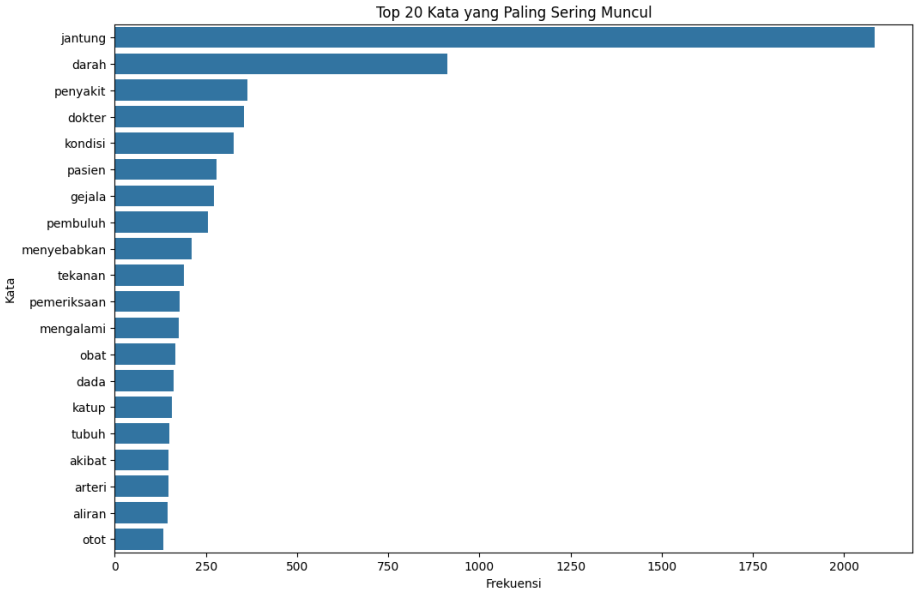

Gambar III.7 Perbandingan Frekuensi Kemunculan Kata pada Kumpulan Artikel Penyakit Jantung

Frekuensi kemunculan kata "jantung" yang tinggi ini merupakan hal yang lumrah mengingat topik artikel yang dikumpulkan berkaitan dengan variasi penyakit jantung. Selain *bar chart,* dilakukan juga visualisasi *wordcloud* yang memberikan gambaran mengenai kata-kata yang merepresentasikan tema utama pada kumpulan artikel. Semakin besar ukuran huruf pada *wordcloud* menandakan kemunculan kata yang semakin umum pada artikel.

Gambar III.8 Visualisasi *Wordcloud* pada Kumpulan Artikel Penyakit Jantung

III.1.2.4 Karakter *Unicode*

Pada teks konten artikel yang didapatkan melalui *scraping*, masih terdapat beberapa karakter *unicode* yang muncul dalam teks. Tabel III.3 menunjukkan frekuensi kemunculan karakter *unicode* dalam teks judul topik, judul subtopik, serta konten artikel. Banyaknya kemunculan karakter *unicode* ini disebabkan laman situs web Alodokter yang dijadikan sebagai sumber informasi mengenai penyakit jantung menggunakan UTF-8 sebagai *encoding* karakter. Kemunculan karakter ini dapat membuat kinerja pengambilan informasi (*information retrieval*) dalam basis data vektor akan menjadi berkurang. Oleh karena itu, perlu ada penanganan terhadap kemunculan karakter *unicode* pada fase desain solusi.

Tabel III.3 Lima Karakter Unicode dengan Frekuensi Kemunculan Terbanyak

Karakter	Frekuensi Kemunculan
'Â'	356
'\xa0'	275
'â'	58
'\x80'	51
'\x93'	42

III.2 Analisis Kebutuhan

Berdasarkan analisis kondisi pada subbab III.1, dirumuskan analisis kebutuhan untuk pembuatan sistem tanya jawab tentang penyakit jantung. Analisis kebutuhan ini meliputi identifikasi masalah yang dialami pengguna serta perincian kebutuhan fungsional dan nonfungsional untuk sistem yang akan dibuat. Masalah pengguna yang telah teridentifikasi akan diturunkan menjadi rincian kebutuhan fungsional dan nonfungsional. Kebutuhan-kebutuhan yang telah dirincikan ini nantinya akan

menjadi dasar panduan dalam pengembangan sistem tanya jawab tentang penyakit jantung agar penggunaan sistem dapat mencapai objektif bisnis.

III.2.1 Identifikasi Masalah Pengguna

Pengguna sistem tanya jawab tentang penyakit jantung umumnya merupakan masyarakat yang sedang mencari informasi mengenai penyakit jantung. Masyarakat ini dapat terbagi ke dalam beberapa kategori:

1. Pasien Potensial
   Kategori ini mencakup orang awam yang ingin mencari tahu informasi mengenai gejala, pencegahan, atau pengobatan penyakit jantung.
2. Pasien dengan Riwayat Penyakit Jantung
   Kategori ini mencakup individu yang terdiagnosis dengan penyakit jantung dan ingin memahami lebih lanjut mengenai kondisi yang mereka alami atau pengobatan/tindakan yang dapat dilakukan untuk menyembuhkan penyakit yang dialami pasien.
3. Keluarga atau Pendamping Pasien
   Kategori ini merupakan orang-orang yang sedang merawat pasien yang terkena penyakit jantung dan memerlukan informasi mengenai penanganan atau perawatan terhadap pasien penyakit jantung.

Berdasarkan penjelasan pada subbab III.1.1 mengenai *business understanding*, ketiga kategori dalam pengguna ini memiliki cakupan masalah yang cukup serupa dalam hal pencarian informasi penyakit jantung:

1. Keterbatasan Interaksi dan Ekspresi dalam Mesin Pencari
   Interaksi yang dilakukan pada pencarian informasi dalam mesin pencari masih dibatasi oleh aksi yang sudah ditentukan, seperti memasukkan *query* secara berulang, melakukan *scrolling*, berpindah halaman web, dan lain-lain (Aliannejadi, Gwizdka, dan Zamani 2024). Apabila proses ini dilakukan

secara berulang, proses pencarian informasi dapat menjadi melelahkan dan merepotkan, terutama bagi mereka yang sedang dalam kondisi darurat. Terlebih, kebutuhan informasi dalam medis sering diekspresikan dengan pertanyaan bahasa alami (Xiong dkk. 2024) sehingga terdapat risiko kesalahan penafsiran dari mesin pencari terhadap *query* yang dimasukkan pengguna.

2. Kesulitan Akses Terhadap Informasi yang Relevan dan Mudah Dipahami
   Dengan banyaknya informasi yang tersedia di internet, terdapat keresahan mengenai informasi yang tidak selalu mudah dipahami oleh orang awam atau tidak relevan dengan informasi yang dibutuhkan oleh pengguna. Hal ini berdampak pada kesulitan pengguna dalam mencari informasi yang relevan serta memahami informasi yang tersedia dalam internet.
3. Risiko Informasi yang Tidak Akurat dari *Generative AI*
   Meskipun teknologi *generative AI* mampu menyediakan interaksi yang cepat serta natural, kecenderungan LLM dalam berhalusinasi dapat menyebabkan risiko informasi yang tidak akurat atau tidak valid. Ditambah lagi, beberapa *platform* yang menyediakan interaksi percakapan dengan model AI jarang menyediakan sumber informasi terkait. Hal ini dapat menimbulkan risiko yang fatal seperti kesalahan penanganan atau pengobatan pada pasien penyakit jantung.

III.2.2 Kebutuhan Fungsional

Berdasarkan masalah yang dialami pengguna, kebutuhan fungsional dirancang agar sistem tanya jawab dipastikan dapat mengatasi masalah-masalah yang ada. Tabel III.4 merincikan kebutuhan fungsional yang perlu dipenuhi oleh sistem tanya jawab.

Tabel III.4 Kebutuhan Fungsional Sistem Tanya Jawab Tentang Penyakit Jantung

Kode	Kebutuhan Fungsional
F01	Sistem dapat menerima pertanyaan pengguna terkait penyakit jantung dalam bentuk bahasa alami
F02	Sistem dapat mencari basis pengetahuan terkait sebagai landasan jawaban yang akan dihasilkan
F03	Sistem dapat memberikan jawaban berdasarkan landasan basis pengetahuan dan dalam bentuk yang jelas serta informatif
F04	Sistem dapat mencantumkan sumber informasi terkait yang digunakan sebagai landasan jawaban
F05	Sistem dapat menyimpan riwayat pertanyaan serta jawaban
F06	Sistem dapat memberikan peringatan bahwa informasi yang diberikan oleh sistem tidak dapat menggantikan konsultasi kepada dokter profesional

III.2.3 Kebutuhan Nonfungsional

Selain kebutuhan fungsional, sistem tanya jawab juga perlu memenuhi aspek kebutuhan nonfungsional yang berfokus pada cara kerja sistem. Tabel III.5 merincikan kebutuhan nonfungsional yang perlu dipenuhi oleh sistem tanya jawab.

Tabel III.5 Kebutuhan Nonfungsional Sistem Tanya Jawab Tentang Penyakit Jantung

Kode	Kategori	Kebutuhan Nonfungsional
NF01	*Availability*	Sistem tersedia dan dapat diakses kapan saja untuk mendukung kebutuhan informasi yang dapat bersifat mendesak
NF02	*Accuracy*	Basis pengetahuan yang digunakan sudah tervalidasi secara medis

Tabel III.5 Kebutuhan Nonfungsional Sistem Tanya Jawab Tentang Penyakit Jantung (lanjutan)

Kode	Kategori	Kebutuhan Nonfungsional
NF03	*Accuracy*	Sistem perlu meminimalkan misinformasi atau halusinasi
NF04	*Usability*	Antarmuka sistem memiliki desain yang intuitif dan dapat digunakan oleh pengguna tanpa memerlukan pelatihan yang teknis
NF05	Kepatuhan Etika AI	Sistem tidak memberikan jawaban yang cenderung memberikan diagnosis kepada pengguna
NF06	*Maintainability*	Konten yang digunakan sebagai basis pengetahuan dapat diperbarui

III.3 Analisis Pemilihan Solusi

Subbab ini membahas perumusan solusi untuk menjawab permasalahan yang dialami pengguna. Beberapa alternatif dirumuskan untuk pembuatan sistem tanya jawab mengenai penyakit jantung. Alternatif ini akan diapstikan dapat memenuhi kebutuhan fungsional dan nonfungsional yang telah disebutkan di subbab III.3.1 dan III.3.2. Dari variasi alternatif yang ada, akan dilakukan penentuan solusi yang akan diterapkan pada bab IV.

III.3.1 Alternatif Solusi

Terdapat tiga alternatif solusi yang dirumuskan untuk sistem tanya jawab tentang penyakit jantung. Semua alternatif solusi yang dirumuskan akan memanfaatkan *generative AI* sebagai basis teknologinya. Alternatif pertama akan mengimplementasi *instruction tuning* terhadap LLM. Sementara itu, alternatif kedua dan ketiga akan mengimplementasi *retrieval augmented generation* (RAG).

III.3.1.1 Alternatif Solusi I: Implementasi *Instruction Tuning*

Salah satu alternatif dalam mengatas "halusinasi" pada LLM adalah dengan melakukan *instruction tuning*. Dalam pendekatan ini, model akan dilatih untuk beradaptasi dengan data berisi pasangan deskripsi tugas beserta perilaku yang diharapkan (Ovadia dkk. 2023). Karena penelitian ini menggunakan kumpulan artikel dari Alodokter, alternatif ini dapat memanfaatkan potongan-potongan kalimat di dalam kumpulan artikel serta set pertanyaan sebagai data masukan untuk model.

III.3.1.2 Alternatif Solusi II: Implementasi *Retrieval Augmented Generation*

Retrieval Augmented Generation (RAG) memperkuat kemampuan LLM dengan mengumpulkan potongan dokumen terkait dari basis pengetahuan eksternal menggunakan metode kalkulasi kesamaan semantik (Y. Gao dkk. 2023). Pendekatan ini menjadi sebuah pendekatan alternatif yang akan menyediakan landasan ilmu terkait domain spesifik kepada LLM. Biayanya yang rendah dalam melakukan *embedding* terhadap kumpulan dokumen menjadikan RAG sebagai pilihan yang menarik (Balaguer dkk. 2024). Dalam penyediaan informasi penyakit jantung, sistem RAG dapat memanfaatkan kumpulan informasi penyakit jantung yang tersedia di dalam situs web artikel kesehatan. Kumpulan artikel ini nantinya tersimpan ke dalam sebuah basis data dalam bentuk vektor. Dalam solusi ini, sistem akan mengambil dokumen yang relevan berdasarkan *query* dan kumpulan dokumen yang relevan tersebut akan digunakan oleh LLM untuk menghasilkan jawaban yang dilandasi informasi tentang penyakit jantung.

III.3.1.3 Alternatif Solusi III: Implementasi *Retrieval Augmented Generation* dengan Pendekatan *Hypothetical Document Embeddings*

Hypothetical Document Embeddings (HyDE) merupakan salah satu pendekatan dalam sistem RAG untuk mengoptimasi *query* melalui transformasi *query*.

Pendekatan ini dilakukan untuk mengatasi ketergantungan sistem terhadap *query* yang dimasukkan oleh pengguna. Dalam pendekatan ini, *query* akan dimasukkan ke dalam model LLM dan menginstruksikan model tersebut untuk menghasilkan dokumen hipotesis. Dokumen hipotesis ini kemudian akan diubah menjadi vektor *embedding* dan dilakukan pencarian kesamaan dengan dokumen asli (L. Gao dkk. 2023). Layaknya alternatif solusi kedua, kumpulan informasi penyakit jantung yang didapatkan melalui sisuts web artikel kesehatan akan tersimpan di dalam basis data dalam bentuk vektor. Hal yang membedakannya dengan alternatif kedua adalah pendekatan HyDE berfokus pada pencarian kesamaan *embedding* antara jawaban dengan jawaban, bukan antara *query* dan jawaban (Y. Gao dkk. 2023).

III.3.2 Analisis Penentuan Solusi

Dengan variasi alternatif solusi yang telah dirumuskan, dilakukan penentuan solusi yang akan diterapkan. Penentuan solusi ini akan dilakukan dengan penilaian menggunakan *weighted scoring* untuk setiap alternatif. Penilaian ini sendiri mempertimbangkan beberapa kriteria dengan bobot yang berbeda-beda. Untuk setiap alternatif, akan dilakukan penilaian dengan skala likert satu hingga sepuluh.

1. Efektivitas

   Kriteria efektivitas menilai seberapa baik alternatif solusi dalam menyelesaikan permasalahan pengguna, terutama potensi halusinasi yang dihasilkan oleh LLM. Sebagaimana yang dijelaskan pada subbab mengenai *business understanding,* dalam domain kesehatan, kesalahan kecil (seperti misinformasi) sekalipun dapat menimbulkan konsekuensi yang serius (Pang dkk. 2024) sehingga alternatif solusi yang diusulkan perlu menyediakan informasi seakurat mungkin. Skor efetivitas yang tinggi menandakan alternatif solusi efektif dalam menyelesaikan permaslaahan pengguna.
2. *Feasibility*

   Kriteria *feasibility* mengukur seberapa besar kemungkinan alternatif solusi dapat diimplementasikan dalam sistem tanya jawab tentang penyakit

jantung. Kriteria ini mempertimbangkan kemudahan dari implementasi serta kompleksitas dari sistem. Skor *feasibility* yang tinggi menandakan alternatif solusi sangat mungkin diimplementasikan.

3. Biaya Komputasi

   Kriteria ini mempertimbangkan penggunaan sumber daya untuk melakukan implementasi sistem tanya jawab tentang penyakit jantung. Semakin tinggi skor maka semakin sedikit sumber daya yang digunakan oleh alternatif solusi.

4. Fleksibilitas

   Kriteria ini menilai kemungkinan sistem tanya jawab untuk dikembangkan atau ditingkatkan lebih lanjut pada implementasi di masa depan apabila dibutuhkan. Semakin tinggi skor fleksibilitas maka semakin mungkin bagi alternatif solusi untuk dikembangkan.

Tabel III.6 Kalkulasi *Weighted Scoring* pada Alternatif Solusi

Kriteria	Bobot	Alternatif Solusi		
		Instruction Tuning	*Retrieval Augmented Generation*	RAG dengan Pendekatan HyDE
Efektivitas	40%	8	8	8
Feasibility	25%	6	8	8
Biaya Komputasi	20%	6	8	7
Fleksibilitas	15%	5	7	7
Skor Total		6,65	7,85	7,65

Tabel III.6 menunjukkan hasil *weighted scoring* dari setiap alternatif solusi beserta skor total yang didapatkan oleh setiap alternatif. Pada penelitian ini, akan dipilih

dua alternatif solusi yang akan diimplementasi. Berdasarkan Tabel III.6, alternatif solusi kedua (implementasi RAG) dan ketiga (implementasi RAG dengan pendekatan HyDE) memiliki skor total berturut-turut 7,85 dan 7,65. Keduanya memiliki skor total yang lebih tinggi daripada alternatif solusi pertama (implementasi *instruction tuning*) sehingga alternatif solusi kedua dan ketiga akan diimplementasi pada penelitian ini.

BAB IV

DESAIN SOLUSI

IV.1 Tahapan Desain

Subbab ini akan membahas desain dari solusi yang telah terpilih. Desain solusi memberikan gambaran implementasi dari sistem tanya jawab tentang penyakit jantung. Dengan tetap menerapkan metodologi CRISP-DM, tahapan desain akan mencakup perancangan aktivitas pada fase *data preparation* serta *modelling. Data preparation* akan membahas rancangan aktivitas pemrosesan data sebelum digunakan untuk pemodelan. Sementara itu, fase *modelling* akan berfokus pada perancangan aktivitas implementasi dari sistem tanya jawab tentang penyakit jantung.

IV.1.1 *Data Preparation*

Pada tugas akhir ini, tahap *data preparation* melibatkan pemilihan fitur serta pembersihan teks pada data artikel. Ketiga fitur yang dianalisis pada tahap *data understanding*, yakni judul topik, judul subtopik, dan konten, akan dijadikan fitur-fitur yang digunakan untuk implementasi *retrieval augmented generation* (RAG). Judul topik dan judul subtopik diperlukan untuk penyediaan konteks pada LLM karena adanya beberapa konten yang tidak secara eksplisit menyebutkan subtopik pembahasan. Ketiga fitur tersebut akan tersimpan dalam basis data vektor.

Setelah dilakukan pemilihan fitur, data teks akan diolah sedemikian rupa agar teks bersih dari karakter yang asing. Sesuai dengan yang disampaikan pada subbab III.1.2, teks artikel masih menyimpan banyak karakter *unicode* yang dapat memengaruhi kinerja pengambilan informasi dalam basis data sehingga diperlukan

penanganan terhadap hal ini. Untuk menanganinya, seluruh teks, baik judul topik, judul subtopik, akan dikonversi ke dalam format UTF-8 untuk menghilangkan kerusakan pada karakter.

Pada tahap ini, dilakukan juga penentuan *chunking* atau pembagian segmen pada dokumen artikel. Kegiatan ini dilakukan untuk meningkatkan efisiensi pengambilan informasi yang relevan untuk LLM. Untuk penelitian ini, teknik pembagian segmen akan dilakukan dengan cara *document-based chunking*, yakni membagi setiap artikel ke dalam beberapa segmen sesuai dengan struktur konten. Artinya, setiap segmen dalam artikel yang dimasukkan ke dalam basis data merupakan satu subtopik pada topik tertentu. Pada set data yang sudah dikumpulkan, artikel telah terbagi menjadi beberapa bagian sesuai dengan subtopik bahasannya sehingga penerapan *chunking* sudah terpenuhi.

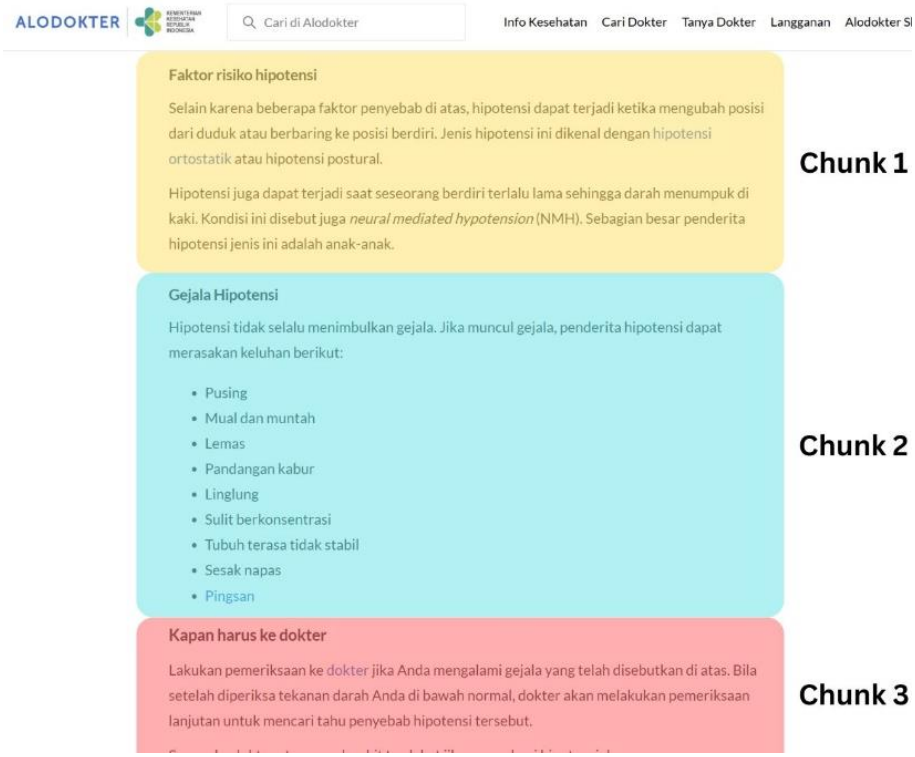

Gambar IV.1 Ilustrasi *Document-Based Chunking* pada Dokumen Artikel

IV.1.2 *Modelling*

Pada tahap *modelling,* implementasi sistem *retrieval augmented generation* (RAG) akan mulai diterapkan untuk proses *indexing, retrieval* serta *generation*. Sesuai dengan Gambar III.9 dan III.10, implementasi ini dilakukan dengan menerapkan *pipeline* di setiap proses yang terdiri dari beberapa komponen:

1. *Indexing*

   Proses ini merupakan proses mentransformasi data tekstual menjadi representasi vektor serta memasukkannya ke dalam basis data. Terdapat dua komponen yang akan menyusun *indexing pipeline*:

   a. Model *Embedding*

      Model ini digunakan untuk mengubah data tekstual menjadi bentuk *vector embeddings*. Setiap segmen-segmen pada kumpulan teks artikel penyakit jantung yang telah dibersihkan nantinya akan diubah ke dalam bentuk representasi vektor menggunakan model ini. Proses transformasi teks menjadi *vector embeddings* dilakukan untuk mempermudah pencarian segmen teks yang relevan pada proses *retrieval*.

   b. Basis Data Vektor (*Vector Database*)

      Pada proses ini, basis data vektor akan disiapkan sebagai tempat penyimpanan vektor. Setelah basis data telah dikonfigurasi dan disiapkan, setiap vektor hasil *embedding* dari teks akan dimasukkan ke dalam basis data. Vektor yang sudah tersimpan di dalam basis data akan digunakan dalam kegiatan pencarian dokumen relevan pada proses *retrieval.*

2. *Retrieval*

   Pada proses ini, dilakukan pengambilan segmen teks di dalam basis data yang relevan terhadap masukan *query.* Terdapat dua komponen yang akan menyusun *retrieval pipeline*.

a. LLM untuk Jawaban Hipotesis

Pada pengimplementasian sistem RAG dengan pendekatan HyDE, *query* yang dimasukkan akan ditransformasi dengan menghasilkan sebuah jawaban hipotesis. Model ini akan menjadi komponen yang mendukung proses pembuatan jawaban hipotesis pada pengimplementasian sistem RAG dengan pendekatan HyDE. Model akan menerima *query* tanpa adanya pemberian konteks yang relevan sehingga model akan menghasilkan jawbaan sesuai dengan pengetahuan yang dimiliki model. Jawaban hipotesis yang dihasilkan LLM ini akan digunakan oleh komponen *document retriever* untuk proses pengambilan segmen teks yang relevan. Pada pengimplentasian sistem RAG tanpa pendekatan HyDE, komponen ini tidak akan digunakan sehingga *pipeline* pada alternatif solusi pertama akan melewati proses pada komponen ini.

b. Model *Embedding*

Sama seperti komponen yang ada pada *pipeline* proses *indexing*, model ini berfungsi untuk mengubah teks menjadi bentuk *vector embeddings*. Namun, dalam *retrieval*, model *embedding* akan digunakan untuk mentransformasi *query*. Pada implementasi alternatif solusi pertama, komponen ini akan menerima *query* asli yang dimasukkan pengguna. Sementara itu, pada implementasi solusi kedua, komponen ini akan menerima *query* berupa jawaban hipotesis yang dihasilkan oleh LLM. Hasil *embedding* yang dilakukan oleh komponen ini akan digunakan oleh komponen *document retriever* untuk melakukan pencarian dokumen.

c. *Document Retriever*

Komponen ini berfungsi untuk melakukan pengambilan segmen teks yang relevan sesuai dengan *query* yang diterima. Komponen *document retriever* menerima hasil *embedding* oleh model *embedding* untuk melakukan pencarian segmen teks. Pencarian

segmen teks ini dilakukan dengan melakukan perhitungan *similarity score* antara *query* dengan setiap segmen teks. Pada pengimplementasian di dalam tugas akhir ini, sepuluh segmen teks dengan *similarity score* tertinggi akan diambil oleh komponen *document retriever.* Selanjutnya, *document retriever* akan melakukan pengurutan ulang (*reranking*) untuk mengambil tiga segmen teks dengan tingkat relevansi tertinggi. Kumpulan segmen teks yang diambil ini kemudian akan digunakan pada proses *generation* sebagai penyediaan konteks.

3. *Generation*

   Proses ini merupakan proses akhir dalam pengimplementasian yang melibatkan proses pembuatan jawaban yang dilandasi oleh informasi di dalam basis data. Pada proses ini, hanya ada satu komponen yang menyusun *generation pipeline*.

   a. LLM untuk Jawaban Faktual

      Berbeda dengan LLM yang digunakan pada proses *retrieval*, model ini akan menjadi komponen yang menghasilkan jawaban faktual berdasarkan informasi yang tersimpan di dalam basis data. Sebelum menghasilkan jawaban, komponen ini akan menyusun *prompt* sedemikian rupa untuk menginstruksikan model LLM untuk menghasikan jawaban faktual. Untuk dapat menghasilkan jawaban faktual, *prompt* akan dikombinasikan dengan tiga segmen relevan yang telah diambil pada proses *retrieval* agar LLM memahami konteks dari pertanyaan yang telah diberikan pengguna di awal. Dari *prompt* yang telah dibuat, LLM akan memproses *prompt* tersebut untuk menghasilkan jawaban yang sesuai dengan konteks informasi.

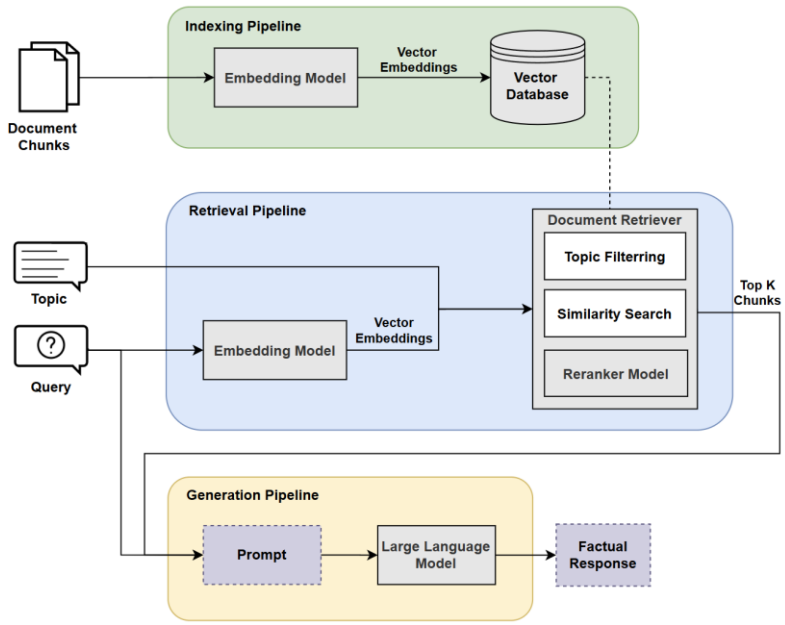

Gambar IV.2 Diagram Proses *Pipeline* Alternatif Solusi II

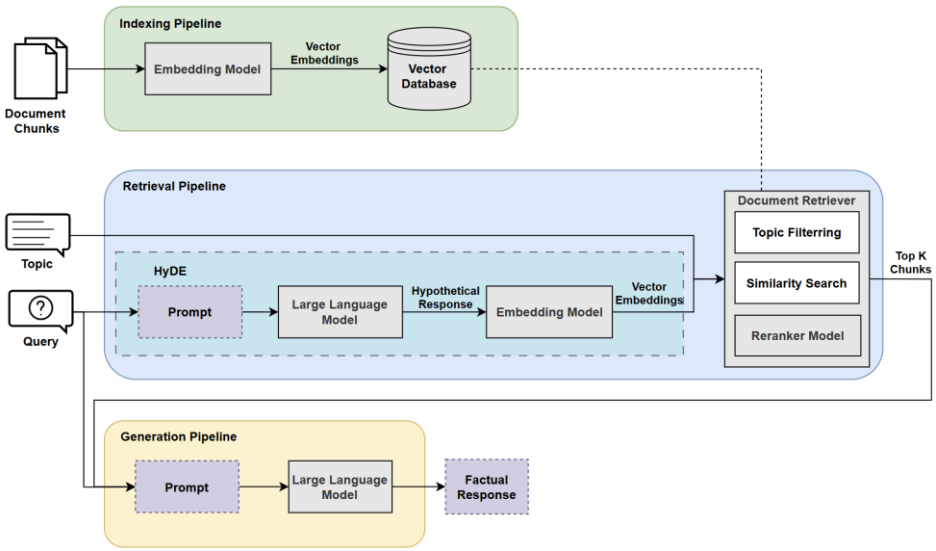

Gambar IV.3 Diagram Proses *Pipeline* Alternatif Solusi III

Gambar IV.4 merupakan diagram proses dari rancangan solusi dalam pengerjaan tugas akhir yang mencakup *data preparation* serta *modelling*.

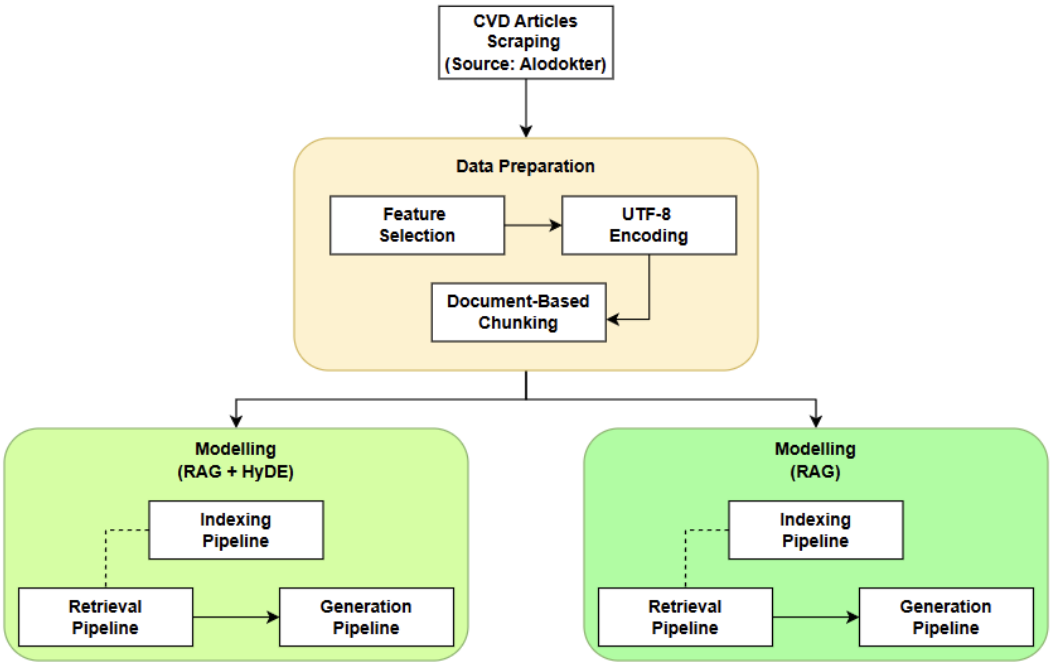

Gambar IV.4 Diagram Proses Desain Solusi

IV.1.2.1 Konfigurasi Model

Perencanaan terkait implementasi sistem RAG mencakup pembuatan beberapa daftar model yang menjadi bagian inti dari implementasi sistem RAG pada tugas akhir ini. Terdapat beberapa pertimbangan penting dalam memilih opsi model di setiap jenis sesuai dengan tugasnya.

1. Model *Embedding*

   Sistem RAG memerlukan model *embedding* untuk melakukan *encoding* terhadap data teks artikel. Agar pengambilan segmen teks dalam basis data vektor menjadi akurat, diperlukan model *embedding* dengan panjang konteks yang luas serta kinerja yang sangat baik dalam memproses kalimat yang panjang.

2. Model *Reranking*

   Model *reranking* dimanfaatkan untuk melakukan pengurutan ulang segmen yang telah diambil berdasarkan skor relevansi tertinggi. Model perlu memiliki kapabilitas multilingual agar pengurutan ulang teks artikel menjadi lebih akurat.

3. LLM untuk Memberikan Jawaban Hipotesis dan Jawaban Faktual

   Sistem RAG memerlukan sebuah model yang mampu memberikan jawaban berdasarkan pertanyaan yang diberikan serta konteks yang didapatkan melalui *similarity search*. Mengingat rata-rata panjang konten dalam kumpulan artikel adalah 76.34 karakter, model perlu memiliki kapabilitas dalam memahami konteks yang panjang. Selain itu, pada pengimplementasian pendekatan HyDE dalam sistem RAG, diperlukan juga model yang mampu memahami *query* masukan serta memberikan jawaban hipotesis dalam bahasa Indonesia. Model yang memiliki kemampuan ini biasanya dapat ditemui pada model-model yang dilatih pada kumpulan teks dari berbagai bahasa, termasuk bahasa Indonesia.

Berdasarkan beberapa pertimbangan tersebut, terpilih beberapa opsi model yang dipertimbangkan untuk dapat digunakan dalam implementasi sistem RAG sesuai dengan Tabel IV.2.

Tabel IV.1 Opsi Model dalam Implementasi Sistem RAG

No.	Jenis Model	Opsi Model
1.	Model *Embedding*	nomic-embed-text
		mxbai-embed-large
2.	Model *Reranking*	Cohere Rerank 3.5
3.	LLM untuk Menghasilkan Jawaban Hipotesis dan Faktual	Llama-3.1-8B
		Deepseek-V2

Dengan opsi model yang dirincikan pada Tabel IV.1, dirancang beberapa konfigurasi sistem RAG yang mengombinasikan setiap jenis model. Tabel IV.2 menunjukkan konfigurasi model yang akan diterapkan pada sistem RAG. Pada tahap evaluasi, setiap konfigurasi akan dibandingkan kinerjanya berdasarkan metrik evaluasi *library* RAGAS untuk mencari konfigurasi dengan kinerja terbaik.

Tabel IV.2 Konfigurasi Model untuk Sistem RAG

Konfigurasi	Model *Embedding*	Model *Reranking*	LLM	Menerapkan HyDE
combination_1	nomic-embed-text	Cohere Rerank 3.5	Llama-3.1-8B	Tidak
combination_2	nomic-embed-text	Cohere Rerank 3.5	Deepseek-V2	Tidak
combination_3	mxbai-embed-large	Cohere Rerank 3.5	Llama-3.1-8B	Tidak
combination_4	mxbai-embed-large	Cohere Rerank 3.5	Deepseek-V2	Tidak
combination_5	nomic-embed-text	Cohere Rerank 3.5	Llama-3.1-8B	Ya
combination_6	nomic-embed-text	Cohere Rerank 3.5	Deepseek-V2	Ya
combination_7	mxbai-embed-large	Cohere Rerank 3.5	Llama-3.1-8B	Ya
combination_8	mxbai-embed-large	Cohere Rerank 3.5	Deepseek-V2	Ya

IV.2 Hasil Desain

IV.2.1 Hasil *Data Preparation*

Proses *data preparation* dilakukan untuk mempersiapkan data agar dapat digunakan pada tahap *modelling*. Proses yang dilakukan pada tahap *data preparation* mencakup tiga langkah:

1. Mengambil data dokumen yang sudah di-*scraping* dan tersimpan dalam bentuk JSON
2. Mengganti setiap karakter *unicode* pada kumpulan teks dengan karakter spasi

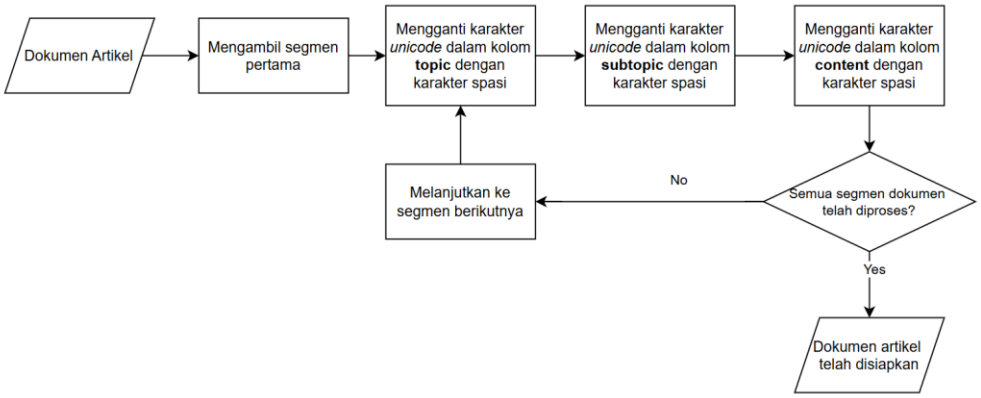

Gambar IV.5 Diagram Alir Proses Penggantian Karakter *Unicode* pada Dokumen

3. Menghitung frekuensi kemunculan karakter *unicode* pada kumpulan teks.

Tabel IV.3 Contoh Hasil *Text Cleaning* pada Teks Artikel

Sebelum *text cleaning*	Setelah *text cleaning*
"Tujuan utama dari programÂ rehabilitasi jantungÂ adalah mengembalikan kebugaran fisik pasien agar bisa melanjutkan aktivitas sehari-hari,…"	"Tujuan utama dari program rehabilitasi jantung adalah mengembalikan kebugaran fisik pasien agar bisa melanjutkan aktivitas sehari-hari,..."

Tabel IV.3 menunjukkan contoh hasil *text cleaning* pada kutipan teks artikel dengan topik "Pengobatan Serangan Jantung". Karakter "Â" yang terdapat pada kutipan teks berhasil dihilangkan setelah dilakukan *text cleaning*. Setelah *text cleaning* selesai dilakukan, hasil perhitungan menunjukkan tidak adanya kemunculan karakter *unicode* dalam teks. Hasil tersebut menandakan teks sudah bersih dan siap untuk digunakan. Setelah melakukan pemrosesan teks, dilakukan *document-based chunking*, yakni membagi setiap artikel ke dalam beberapa segmen sesuai dengan struktur konten sesuai penjelasan pada subbab IV.1.1. Contoh hasil *chunking* digambarkan seperti Tabel IV.4. Pada sistem RAG yang akan diterapkan, fitur yang akan disediakan sebagai konteks bagi LLM adalah bagian konten dan karena terdapat beberapa konten yang tidak secara eksplisit menyebutkan subtopik pembahasan, judul topik dan subtopik digabungkan ke dalam isi konten.

Tabel IV.4 Contoh Hasil *Document-Based Chunking*

topic	subtopic	content	url
"Hipertensi"	"Pengertian Hipertensi"	"Topik: Hipertensi, Subtopik: Pengertian Hipertensi Hipertensi atau darah tinggi adalah kondisi ketika..."	"https://www.alodokter.com/hipertensi"
"Hipertensi"	"Penyebab Hipertensi"	"Topik: Hipertensi, Subtopik: Penyebab Hipertensi Hipertensi dibagi menjadi hipertensi primer dan sekunder..."	"https://www.alodokter.com/hipertensi/penyebab"

IV.2.2 Hasil *Modelling*

IV.2.2.1 Hasil *Indexing Pipeline*

Setiap segmen memiliki data tekstual yang terdiri dari teks topik, subtopik, konten, serta tautan sumber artikel. Setelah dilakukan pembersihan dan pemrosesan teks pada bagian *data preparation*, dilakukan penyimpanan dokumen ke dalam basis data. Penyimpanan dokumen dilakukan dengan pembuatan *indexing pipeline* seperti pada Gambar IV.6. Proses yang dilakukan pada *indexing pipeline* terdiri dari tiga langkah.

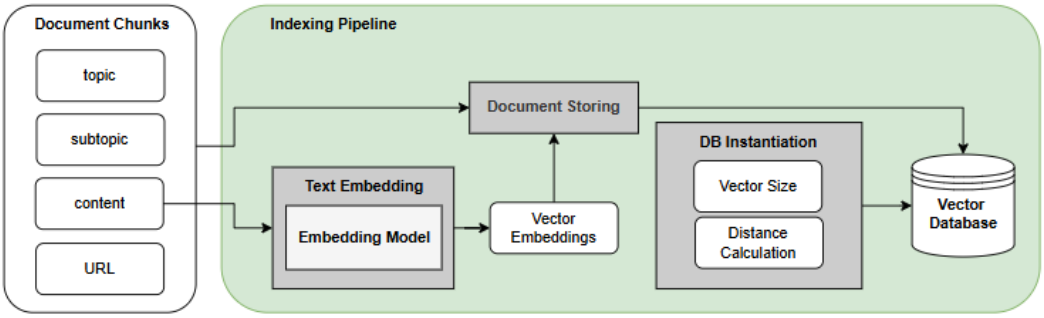

Gambar IV.6 Detail Aliran Proses *Indexing Pipeline*

1. *Text Embedding*

   Kolom "content" yang berisi konten dari artikel akan ditransformasi menjadi representasi vektor dengan menggunakan model *embedding*. Proses ini dilakukan dengan menggunakan kakas bernama Ollama untuk mengakses model *embedding*. Kakas ini mendukung pemakaian model yang dijalankan secara lokal. Setelah kolom "content" ditransformasi ke dalam bentuk vektor, hasil transformasi ditambahkan sebagai kolom baru di dalam segmen dokumen. Selain itu, ditambahkan juga kolom ID ke dalam segmen dokumen sebagai pengenal (*identifier*) segmen di dalam basis data.

Tabel IV.5 Contoh Hasil Penambahan Kolom ID dan *Vector Embeddings*

ID	*topic*	*subtopic*	*content*	URL	*vector*
"d7fd45de-c2a5-4751-978a-faa78462e146"	"Hipertensi"	"Pengertian Hipertensi"	"Topik: Hipertensi, Subtopik: Pengertian Hipertensi Hipertensi atau darah tinggi adalah kondisi ketika..."	"https://www.alodokter.com/hipertensi"	[0.042009477, 0.05304944,-0.20652257,...]

2. Instantiasi Basis Data

Sebelum dilakukan penyimpanan dokumen, basis data diinstantiasi terlebih dahulu. Pada implementasi ini, basis data yang digunakan adalah Qdrant. Untuk menginstantiasi basis data, dispesifikasikan konfigurasi yang terdiri dari ukuran *embedding* (dimensi vektor) dan basis perhitungan jarak vektor. Setiap model *embedding* memiliki ukuran *embedding* yang berbeda-beda. Oleh karena itu, untuk mendapatkan informasi ukuran *embedding* dari sebuah model, dilakukan proses *text embedding* pada sebuah sampel teks lalu dihitung ukuran dimensi vektor yang dihasilkan oleh model *embedding*. Sementara itu, untuk impelementasi sistem RAG pada penelitian ini, digunakan *cosine similarity* sebagai basis perhitungan skor kesamaan antar vektor. Karena pada penelitian ini digunakan dua jenis model *embedding,* dua sistem basis data terinstantiasi dan menyimpan kumpulan data teks artikel. Selain basis data, diinstantiasi juga sistem penyaringan topik untuk basis data dan pada penelitian ini, kolom "topic" dijadikan basis penyaringan. Instantiasi penyaringan topik dilakukan untuk mempermudah pencarian dokumen sesuai dengan pertanyaan terkait topik penyakit tertentu.

3. Penyimpanan Dokumen ke dalam Basis Data

   Setelah basis data terinstantiasi, kumpulan dokumen artikel yang telah dilengkapi data vektor dan ID akan disimpan ke dalam basis data. Penyimpanan dilakukan secara iteratif dengan menyimpan segmen (*chunk*) satu per satu.

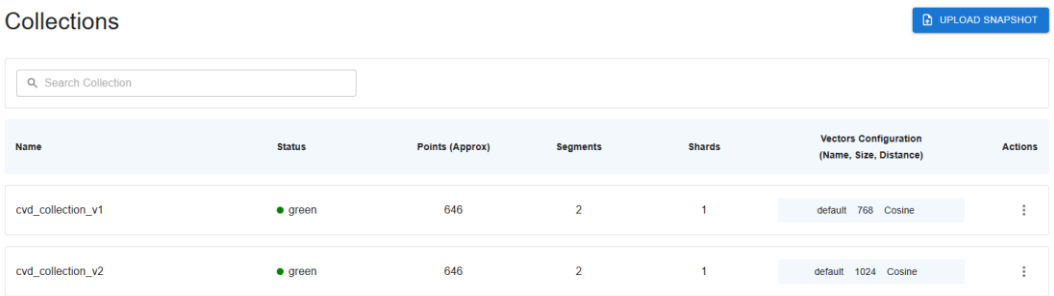

Gambar IV.7 Basis Data Penyimpanan Dokumen Artikel

Gambar IV.7 menunjukkan hasil basis data di Qdrant yang telah diinstantiasi dan menyimpan kumpulan dokumen artikel. Di dalam Qdrant, basis data yang menyimpan kumpulan dokumen disebut sebagai *collections*. Basis data dengan nama "cvd_collection_1" merupakan basis data yang menggunakan model *embedding* nomic-embed-text sedangkan basis data dengan nama "cvd_collection_2" merupakan basis data yang menggunakan model *embedding* mxbai-embed-large. Pada Gambar IV.7, konfigurasi yang dispesifikasikan pada saat menginstantiasi basis data diperlihatkan pada kolom "Vectors Configuration". Kolom "Points" menunjukkan jumlah segmen (baris) data yang tersimpan di dalam basis data. Sesuai dengan Tabel III.2, jumlah dokumen (*count*) berjumlah 646. Sementara itu, kolom "Segments" menandakan jumlah bagian yang menyusun satu *node* di dalam basis data dan kolom "Shards" merupakan jumlah partisi horizontal yang terdapat di dalam basis data.

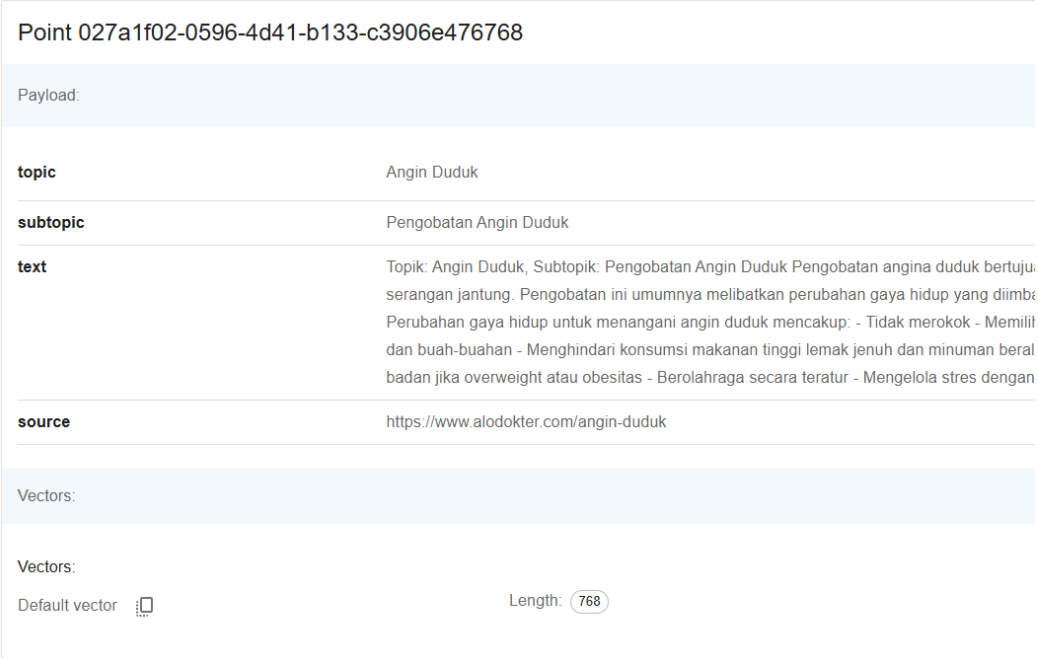

Gambar IV.8 Contoh *Node* yang Tersimpan di *Collection*

Pada basis data, setiap segmen tersimpan sebagai sebuah *node* atau *point*. Gambar IV.8 merupakan contoh *node* yang mewakili satu data konten artikel. Setiap *node* memiliki *identifier* berupa ID yang telah diberikan pada saat *indexing* dan ID tersebut tertera pada bagian atas Gambar IV.8. Setiap *node* juga memiliki dua bagian utama, yakni *Payload* dan *Vectors*. *Payload* merupakan bagian yang menyimpan metadata dari segmen artikel dan pada bagian ini, kolom "content" yang berisi konten artikel diganti namanya menjadi "text" dan kolom "URL" yang menyimpan sumber artikel diganti namanya menjadi "source". Sementara itu, *Vectors* merupakan bagian yang menyimpan data vektor yang merupakan hasil transformasi dari kolom "content" pada kumpulan artikel. Vektor ini yang akan digunakan oleh *Retrieval Pipeline* untuk mencari konten yang relevan berdasarkan skor kesamaan.

IV.2.2.2 Hasil *Retrieval Pipeline* dan *Generation Pipeline*

Retrieval dan *generation pipeline* merupakan dua *pipeline* yang berjalan secara beruntun pada pemrosesan *query* pengguna untuk menghasilkan jawaban. *Retrieval pipeline* memproses *query* untuk mendapatkan konteks yang relevan. Sementara itu, *generation pipeline* memproses konteks yang sudah didapatkan untuk menghasilkan jawaban. Pada penelitian ini, alternatif solusi II dan alternatif solusi III memiliki implementasi *retrieval pipeline* yang berbeda namun memiliki implementasi *generation pipeline* yang tetap sama.

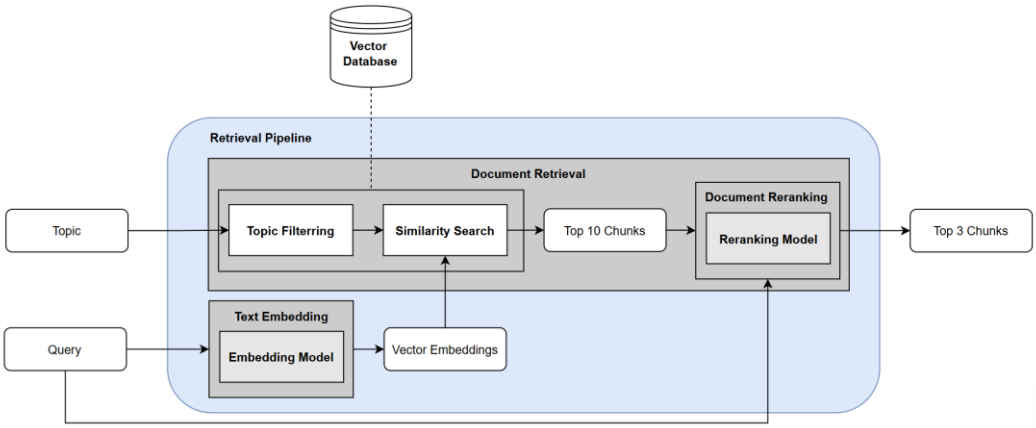

Gambar IV.9 Detail Aliran Proses *Retrieval Pipeline* untuk Alternatif Solusi II

Proses *retrieval* pada alternatif solusi II ditunjukkan pada Gambar IV.9. Proses ini melibatkan masukan pengguna yang terdiri dari *query* (pertanyaan) serta topik penyakit terkait. Selain itu, karena pada proses *indexing* terdapat dua versi basis data dengan *model embedding* yang berbeda, pengguna juga perlu memasukkan versi basis data yang diinginkan. Proses *retrieval* ini terdiri dua langkah utama:

1. *Text Embedding*

   Sama seperti proses *indexing*, *text embedding* pada *retrieval* dilakukan untuk mentransformasi teks ke dalam bentuk vektor. Namun, untuk proses ini, *text embedding* dilakukan untuk mentransformasi *query* yang

dimasukkan oleh pengguna. Model *embedding* yang digunakan untuk melakukan *text embedding* bergantung pada versi basis data yang ingin digunakan oleh pengguna. Hasil transformasi vektor pada langkah ini digunakan untuk proses *document retrieval* yang merupakan langkah berikutnya.

2. *Document Retrieval*

   Proses *document retrieval* (pengambilan dokumen) melibatkan dua sublangkah:

   a. Menyaring dokumen berdasarkan topik masukan pengguna lalu melakukan pencarian dokumen dengan skor kesamaan tertinggi berdasarkan *query* masukan pengguna. Pada proses *similarity search*, digunakan *query* yang telah ditransformasi menjadi vektor pada proses *text embedding*. Proses pencarian ini menghasilkan 10 segmen dokumen dengan skor kesamaan tertinggi.

   b. Melakukan pengurutan ulang (*reranking*) pada kumpulan segmen dokumen. Proses *reranking* menghasilkan urutan dokumen berdasarkan skor relevansi tertinggi. Setelah urutan dihasilkan, diambil tiga segmen teratas yang akan digunakan sebagai konteks sekaligus masukan pada *generation pipeline*.

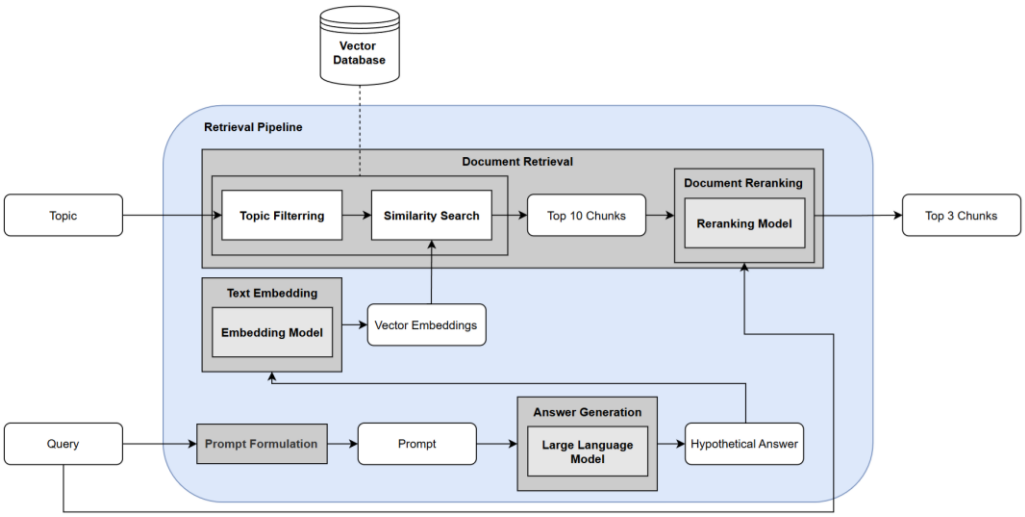

Gambar IV.10 Detail Aliran Proses *Retrieval Pipeline* untuk Alternatif Solusi III

Pada alternatif solusi III, diimplementasi pendekatan *Hypothetical Document Embeddings* (HyDE) dengan mentransformasi jawaban hipotesis yang dihasilkan LLM menjadi representasi vektor. Sesuai Gambar IV.10, proses *retrieval* pada alternatif solusi III mencakup tiga langkah utama:

1. *Prompt Formulation*

   Pada langkah ini, dilakukan formulasi *prompt* yang akan diberikan kepada LLM sebagai instruksi dalam menghasilkan jawaban hipotesis. Pada implementasi sistem RAG dengan pendekatan *Hypothetical Document Embeddings*, diformulasikan *prompt* seperti berikut "Kamu adalah seorang ahli penyakit jantung. Jawab pertanyaan ini dengan pengetahuan yang kamu miliki: [query]. Jangan menyebutkan 'Jawaban pertanyaan tersebut adalah'."

   Prompt yang diberikan kepada LLM akan menginstruksikan LLM untuk mengandalkan pengetahuan yang dimiliki oleh LLM untuk menghasilkan jawaban hipotesis. Pada kalimat terakhir di dalam *promot*, LLM diinstruksikan untuk tidak menghasilkan respon "Jawaban pertanyaan tersebut adalah…" di awal kalimat untuk memastikan jawaban yang

dihasilkan hanya berisi informasi yang berkaitan dengan pertanyaan pengguna.

2. *Answer Generation*

   LLM akan diberikan instruksi berdasarkan *prompt* yang telah dibuat untuk menghasilkan jawaban. Karena LLM tidak diberikan pelatihan sebelumnya, LLM akan menghasilkan jawaban dengan pengetahuan yang dimiliki. Jawaban yang dihasilkan LLM tentu dapat menimbulkan misinformasi namun jawaban hipotesis ini hanya akan digunakan sebagai *query* basis pencarian dokumen yang relevan dan tidak digunakan sebagai jawaban akhir yang diberikan kepada pengguna.

3. *Text Embedding*

   Pada proses ini, *text embedding* dilakukan untuk mentransformasi jawaban hipotesis yang dihasilkan oleh LLM. Model *embedding* yang digunakan untuk melakukan *text embedding* bergantung pada versi basis data yang ingin digunakan oleh pengguna. Hasil transformasi vektor pada langkah ini digunakan untuk proses *document retrieval* yang merupakan langkah berikutnya.

4. *Document Retrieval*

   Sama seperti alternatif solusi II, proses *document retrieval* (pengambilan dokumen) pada alternatif solusi III melibatkan dua sublangkah:

   a. Menyaring dokumen berdasarkan topik masukan pengguna lalu melakukan pencarian dokumen dengan skor kesamaan tertinggi berdasarkan *query* masukan pengguna. Pada proses *similarity search*, digunakan *query* yang telah ditransformasi menjadi vektor pada proses *text embedding*. Proses pencarian ini menghasilkan 10 segmen dokumen dengan skor kesamaan tertinggi.

   b. Melakukan pengurutan ulang (*reranking*) pada kumpulan segmen dokumen. Proses *reranking* menghasilkan urutan dokumen berdasarkan skor relevansi tertinggi. Setelah urutan dihasilkan, diambil tiga segmen

teratas yang akan digunakan sebagai konteks sekaligus masukan pada *generation pipeline*.

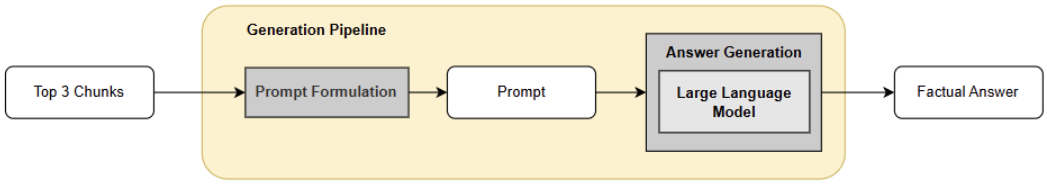

Gambar IV.11 Detail Aliran Proses *Generation Pipeline*

Tiga segmen dokumen yang dihasilkan oleh *retrieval pipeline* akan digunakan oleh LLM sebagai konteks untuk menjawab pertanyaan pengguna. Sesuai dengan Gambar IV.11, proses dalam *generation pipeline* melibatkan dua langkah utama:

1. *Prompt Formulation*

   Sebelum menghasilkan jawaban faktual, dilakukan perumusan *prompt* sebagai instruksi yang akan diberikan kepada LLM. Dengan memanfaatkan tiga segmen dokumen yang telah dihasilkan *retrieval pipeline*, dirumuskan *prompt* seperti di bawah.

   "Diberikan konteks berikut:

   {Konten 1}

   {Konten 2}

   {Konten 3}

   Jawab pertanyaan ini selengkap mungkin sesuai dengan konteks yang diberikan: {query}.

   Jangan menyebutkan 'Berdasarkan konteks yang diberikan'."

Prompt yang diberikan kepada LLM akan menginstruksikan LLM untuk menggunakan tiga konten artikel yang merupakan hasil *retrieval* untuk menghasilkan jawaban faktual. Pada kalimat terakhir di dalam *promot*, LLM diinstruksikan untuk tidak menghasilkan respon "Berdasarkan konteks yang diberikan" di awal kalimat untuk memastikan jawaban yang dihasilkan LLM terkesan alami (*natural*) dalam menjawab pertanyaan pengguna.

2. *Answer* Generation

   Dari *prompt* yang telah diformulasikan, LLM akan diinstruksikan untuk menjawab pertanyaan pengguna secara faktual berdasarkan konten artikel yang relevan. Jawaban ini sekaligus menjadi keluaran terakhir yang diberikan sistem RAG.

Tabel IV.6 Contoh Hasil *Retrieval Pipeline* dan *Generation Pipeline* untuk Alternatif Solusi II

question	*topic*	*retrieved contexts*	*answer*
"Apa hal-hal yang dapat menyebabkan penyakit hipertensi?"	"Hipertensi"	["Topik: Hipertensi, Subtopik: Penyebab Hipertensi Hipertensi dibagi menjadi hipertensi primer dan sekunder. Hipertensi primer...", "Topik: Hipertensi, Subtopik: Penyebab Hipertensi: Faktor Risiko Hipertensi Ada beberapa faktor yang bisa meningkatkan risiko seseorang terserang hipertensi...", "Topik: Hipertensi, Subtopik: Pengertian Hipertensi Hipertensi atau darah tinggi adalah..."]	"Penyebab hipertensi terbagi dalam dua jenis, yaitu hipertensi primer dan sekunder. Hipertensi primer adalah jenis hipertensi yang paling sering terjadi dan berkembang selama bertahun-tahun. Sementara itu, hipertensi sekunder..."

Setelah *retrieval pipeline* dan *generation pipeline* diimplementasikan, kedua *pipeline* diuji coba untuk menjawab pertanyaan terkait penyakit jantung. Untuk melakukannya, digunakan salah satu sampel pertanyaan yang akan digunakan pada fase evaluasi. Tabel IV.6 dan Tabel IV.7 menunjukkan contoh hasil *retrieval pipeline* dan *generation pipeline* untuk alternatif solusi II (implementasi sistem RAG) dan alternatif solusi III (implementasi sistem RAG dengan pendekatan *Hypothetical Document Embeddings*). Pertanyaan yang digunakan merupakan pertanyaan yang berkaitan dengan topik hipertensi. Pada kedua tabel tersebut, kolom "retrieved_contexts" berisi tiga konten yang dihasilkan oleh *retrieval pipeline* dan kolom "answer" merupakan jawaban faktual yang dihasilkan LLM dengan memanfaatkan konteks yang diberikan *retrieval pipeline*. Pada Tabel IV.6, terdapat juga kolom "hypothesis" yang merupakan jawaban hipotesis dari LLM pada fase *retrieval* untuk implementasi alternatif solusi III.

Tabel IV.7 Contoh Hasil *Retrieval Pipeline* dan *Generation Pipeline* untuk Alternatif Solusi III

question	*topic*	*hypothesis*	*retrieved contexts*	*answer*
"Apa hal-hal yang dapat menyebabkan penyakit hipertensi?"	"Hipertensi"	"Gejala hipertensi biasanya tidak menunjukkan adanya gejala khusus. Namun, jika terjadi kerusakan pada berbagai organ tubuh karena…"	["Topik: Hipertensi, Subtopik: Gejala Hipertensi Hipertensi merupakan penyakit yang berbahaya, karena bisa terjadi tanpa gejala...", "Topik: Hipertensi, Subtopik: Gejala Hipertensi: Kapan Harus ke Dokter Pada beberapa kasus, hipertensi dapat menjadi kondisi gawat darurat yang membutuhkan penanganan...",	"Gejala hipertensi antara lain: - Mual dan muntah - Sakit kepala - Mimisan - Sesak napas - Nyeri dada - Gangguan penglihatan ..."

Tabel IV.7 Contoh Hasil *Retrieval Pipeline* dan *Generation Pipeline* untuk Alternatif Solusi III (lanjutan)

question	*topic*	*hypothesis*	*retrieved contexts*	*answer*
			"Topik: Hipertensi, Subtopik: Pengertian Hipertensi Hipertensi atau darah tinggi adalah kondisi ketika tekanan darah berada pada angka 130/80 mmHg atau lebih. Jika tidak segera ditangani, hipertensi..."]	

IV.2.3 Hasil Implementasi UI

Selain implementasi *pipeline*, penelitian ini juga mengimplementasi antarmuka *chatbot* bernama Indo Cardiac Chatbot sebagai *platform* interaksi pengguna dengan sistem tanya jawab tentang penyakit jantung. Pada saat penelitian ini ditulis, Indo Cardiac Chatbot baru dapat dijalankan secara lokal melalui gawai komputer atau *laptop* dan belum di-*deploy* ke dalam *server*. Implementasi Indo Cardiac Chatbot mengandalkan *retrieval pipeline* serta *generation pipeline* yang telah diimplementasi sebelumnya. Gambar IV.12 menunjukkan tampilan UI ketika pengguna pertama kali mengakses antarmuka *chatbot*.

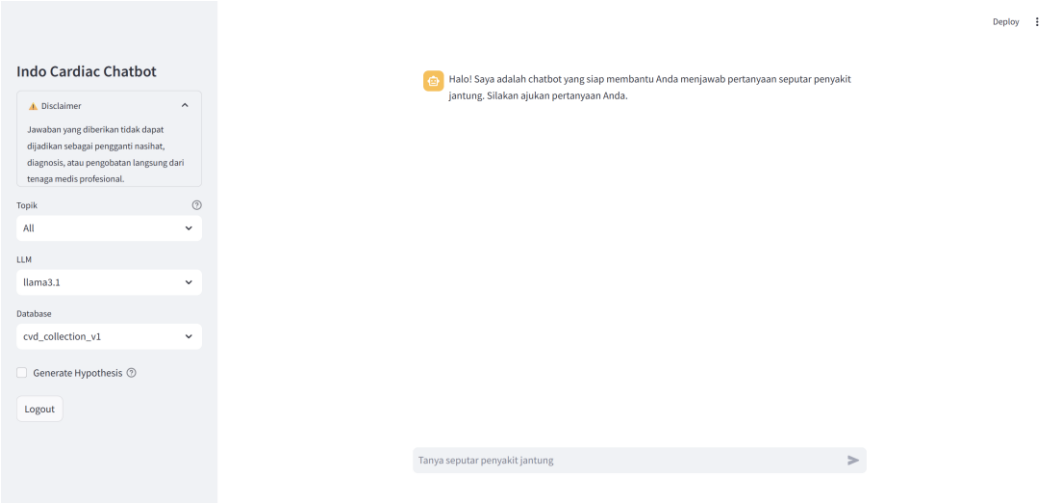

Gambar IV.12 Tampilan UI Sistem RAG untuk Tanya Jawab Tentang Penyakit Jantung

Terdapat dua bagian utama pada Indo Cardiac Chatbot, yakni bagian *chat* dan *sidebar*. Bagian *chat* merupakan tempat interaksi tanya jawab pengguna dalam bentuk percakapan. Sementara itu, bagian *sidebar* berisi beberapa konfigurasi untuk sistem RAG. Pada bagian *sidebar,* terdapat beberapa konfigurasi yang dapat diatur pengguna:

1. Memilih topik penyakit jantung yang berkaitan dengan pertanyaan.
2. Memilih LLM untuk menghasilkan jawaban.
3. Versi basis data atau dengan kata lain, model *embedding* yang digunakan untuk memproses pencarian dokumen.
4. Penerapan *Hypothetical Document Embeddings* (HyDE), yakni menghasilkan jawaban hipotesis sebelum melakukan pencarian dokumen.

Selain pengaturan konfigurasi, terdapat juga pesan yang tertera di bawah judul antarmuka, yakni “Jawaban yang diberikan tidak dapat dijadikan sebagai pengganti nasihat, diagnosis, atau pengobatan langsung dari tenaga medis profesional”. Pesan ini merupakan salah satu bentuk implementasi kebutuhan fungsional sekaligus upaya untuk memenuhi aspek etika dan tanggung jawab dalam penggunaan kecerdasan buatan, terutama dalam domain medis.

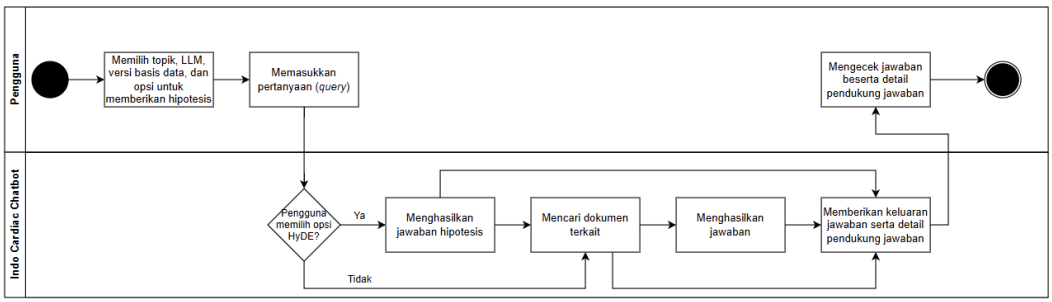

Gambar IV.13 *Activity Diagram* Penggunaan Indo Cardiac Chatbot

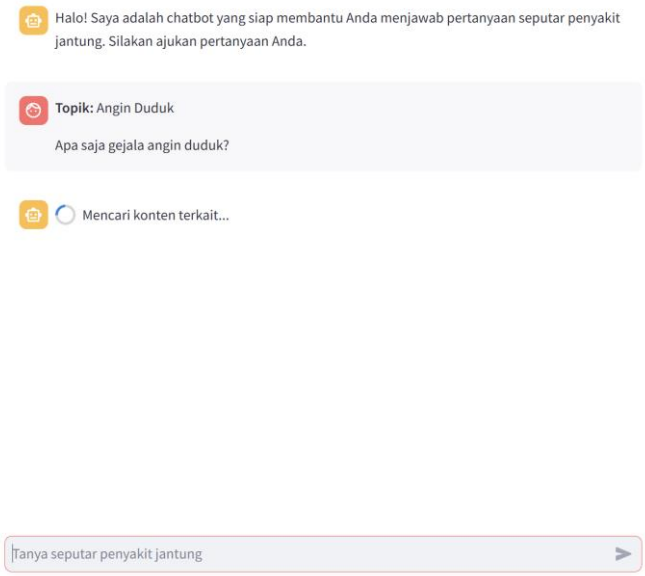

Gambar IV.14 Contoh Pesan Sistem pada Proses Pencarian Dokumen

Alur penggunaan Indo Cardiac Chatbot tergambarkan pada *activity diagram* Gambar IV.13. Setelah pengguna memilih konfigurasi untuk sistem RAG, pengguna dapat memasukkan pertanyaan (*query*) yang berkaitan dengan topik penyakit jantung tertentu. Saat pengguna telah memasukkan pertanyaan, sistem akan memulai pencarian dokumen yang berkaitan dengan pertanyaan atau jawaban hipotesis (apabila pengguna memilih opsi untuk menghasilkan hipotesis). Sesuai dengan Gambar IV.14, pada saat melakukan pencarian dokumen, antarmuka akan menunjukkan pesan "Mencari konten terkait…" untuk menandakan kepada

pengguna bahwa sistem sedang mencari dokumen yang berkaitan dengan pertanyaan dan topik masukan pengguna.

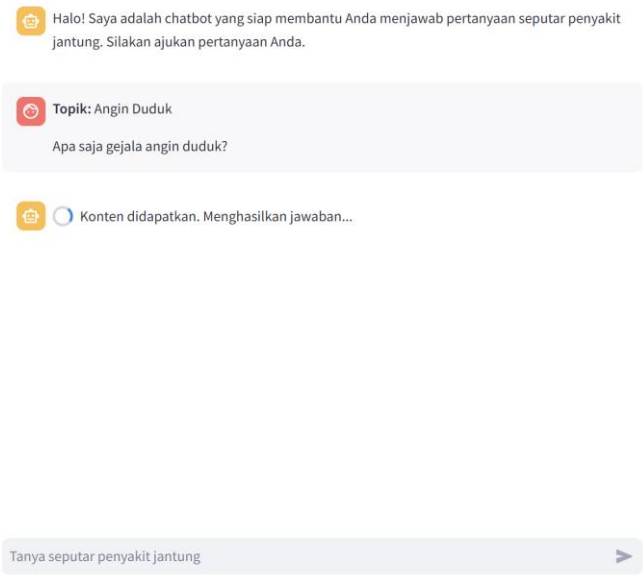

Gambar IV.15 Contoh Pesan Sistem pada Proses Penghasilan Jawaban

Setelah dokumen terkait telah didapatkan, sistem akan menghasilkan jawaban factual kepada pengguna. Seperti proses sebelumnya, antarmuka juga akan menunjukkan pesan pada saat proses penghasilan jawaban. Pada proses ini, antarmuka akan mengeluarkan pesan "Konten didapatkan. Menghasilkan jawaban…" seperti Gambar IV.15. Pesan ini untuk menandakan bahwa sistem sedang menghasilkan jawaban sesuai dengan konteks terkait.

Gambar IV.16 Contoh Keluaran Jawaban Faktual pada Indo Cardiac Chatbot

Setelah proses penghasilan jawaban selesai, sistem akan memberikan keluaran berupa jawaban. Jawaban yang diberikan merupakan jawaban faktual berdasarkan konteks yang telah diambil. Selain jawaban faktual, sistem juga memberikan keluaran berupa tampilan *dropdown* yang bertuliskan "Detail". Gambar IV.17 menunjukkan tampilan detail yang berisi tiga dokumen hasil proses *retrieval* serta sumber artikel terkait.

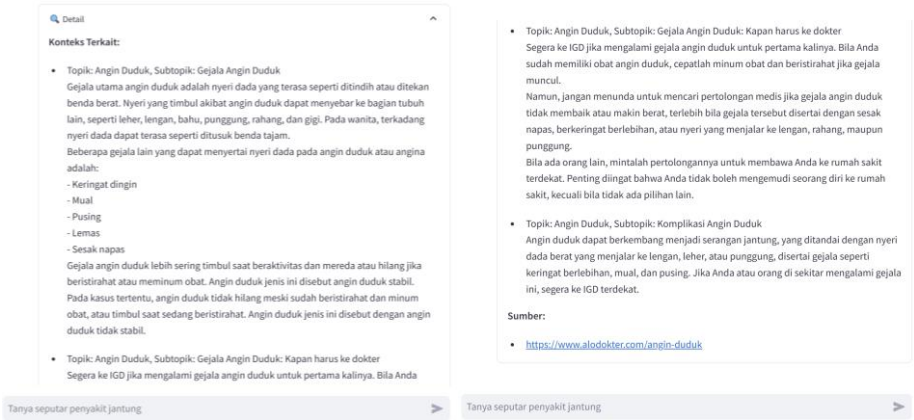

Gambar IV.17 Tampilan *Dropdown* Detail pada Indo Cardiac Chatbot

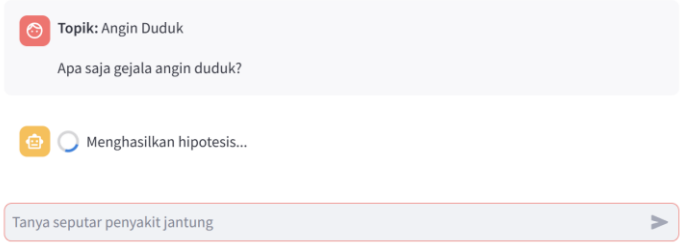

Gambar IV.18 Contoh Pesan Sistem pada Proses Penghasilan Jawaban Hipotesis

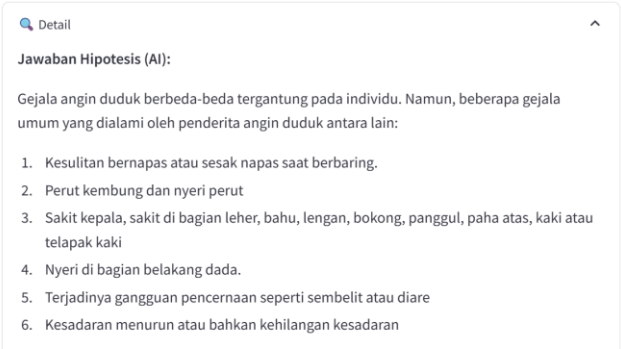

Gambar IV.19 Tampilan Jawaban Hipotesis pada *Dropdown* Detail

Apabila pengguna memilih opsi untuk menghasilkan jawaban hipotesis pada *sidebar* pengaturan konfigurasi, akan terdapat dua tambahan tampilan pada antarmuka. Pada saat proses penghasilan jawaban hipotesis yang dilakukan sebelum proses pencarian dokumen, sistem akan menunjukkan pesan "Menghasilkan hipotesis" sesuai dengan Gambar IV.18. Pesan sistem tersebut menandakan proses penghasilan jawaban hipotesis sedang berlangsung. Saat jawaban hipotesis sudah selesai dihasilkan, jawaban hipotesis akan tersimpan di dalam detail bersama dengan dokumen terkait dan daftar tautan sumber artikel sesuai dengan Gambar IV.19.

BAB V

EVALUASI

V.1 Cara Melalukan Evaluasi

Pada tahap evaluasi, dilakukan penilaian terhadap hasil keluaran sistem RAG. Evaluasi dilakukan melalui dua metode, yakni evaluasi berbasis *large language model* (LLM) dan penilaian ahli domain terkait penyakit jantung. Kedua metode ini memiliki sedikit perbedaan dalam hal lingkup aspek yang dinilai. Pada evaluasi berbasis LLM, aspek yang dinilai melingkupi dokumen yang diambil pada proses *retrieval pipeline* dan juga jawaban faktual yang dihasilkan LLM pada proses *generation pipeline.* Sementara itu, evaluasi berbasis penilaian ahli domain hanya akan berfokus pada jawaban faktual yang dihasilkan LLM.

V.1.1 Evaluasi RAG Berbasis LLM

Pada evaluasi RAG berbasis LLM, digunakan empat metrik evaluasi untuk mengukur kinerja model dalam pengaplikasiannya pada sistem RAG. Keempat metrik ini digunakan dalam kerangka kerja (*framework*) *Retrieval Augmented Generation Assessment* (RAGAS) (Es dkk. 2024) untuk mengevaluasi aspek jawaban yang dihasilkan serta konteks yang diambil. Keempat metrik tersebut mencakup:

1. *Faithfulness*, yakni mengukur konsistensi jawaban berdasarkan konteks yang diberikan (Es dkk. 2024). Metrik ini diukur menggunakan rumus berikut.

$$F = \frac{|\text{Jumlah pernyataan dalam jawaban yang didukung oleh konteks}|}{|\text{Jumlah total pernyataan dalam jawaban yang dihasilkan}|} \quad (\text{V.1})$$

2. *Answer relevancy*, yakni mengukur seberapa relevan jawaban berdasarkan *query* yang dimasukkan pengguna. Metrik ini diukur dengan mengukur kesamaan antara pertanyaan asli dengan pertanyaan yang dihasilkan oleh LLM (yang digunakan oleh RAGAS) berdasarkan jawaban yang dihasilkan. Skor kesamaan dihitung dengan *cosine similarity* sesuai persamaan II.1.

$$AR = \frac{1}{n}\sum_{i=1}^{n} sim(q, q_i) \tag{V.2}$$

Keterangan:

$q = pertanyaan\ asli$

$q_i = pertanyaan\ yang\ dihasilkan\ oleh\ LLM$

$n = jumlah\ pertanyaan\ yang\ dihasilkan\ oleh\ LLM$

3. *Context precision*, yakni mengukur proporsi segmen (*chunk*) yang relevan. Metrik ini diukur sebagai rata-rata nilai *precision* di setiap segmen di dalam konteks.

$$Context\ Precision@K = \frac{\sum_{k=1}^{K}(Precision@k\ \times\ v_k)}{Jumlah\ item\ relevan\ dalam\ hasil\ K\ teratas} \tag{V.3}$$

$$Precision@k = \frac{true\ positives@k}{true\ positives@k + false\ positives@k} \tag{V.4}$$

Keterangan:

$K = jumlah\ segmen\ (chunk)$

$v_k\ \in \{0,1\}$ menandakan indikator relevansi pada segmen ke-k

4. *Context recall*, yakni mengukur seberapa banyak dokumen relevan yang berhasil didapatkan. Pada teknik *context recall* berbasis LLM, beberapa klaim akan dihasilkan dari referensi atau jawaban *ground truth* menggunakan LLM. Dari sejumlah klaim tersebut, akan dihitung proporsi klaim yang dapat dikaitkan dengan konteks dalam segmen (*chunk*) yang diambil.

$$Context\ Recall = \frac{Jumlah\ klaim\ yang\ dapat\ dikaitkan\ dengan\ konteks}{Jumlah\ total\ klaim} \tag{V.5}$$

V.1.1.1 Konfigurasi Sistem pada Evaluasi RAG Berbasis LLM

Untuk melakukan evaluasi dengan *library* RAGAS, diperlukan LLM serta model *embedding* yang dapat memproses penilaian jawaban dari sistem RAG. Pada penelitian mengenai evaluasi RAG dengan *library* RAGAS (Es dkk. 2024), LLM serta model *embedding* yang digunakan adalah model yang dikembangkan oleh OpenAI, yakni gpt-3.5-turbo-16k dan text-embedding-ada-002. Oleh karena itu, untuk memastikan RAGAS dapat mengevaluasi sistem RAG dengan baik, penelitian ini akan menggunakan model gpt-4o-mini dan text-embedding-3-small yang merupakan model OpenAI. Kedua model ini akan diakses menggunakan layanan API yang disediakan oleh OpenAI. Selain itu, sesuai dengan poin keempat subbab I.4 mengenai batasan masalah, evaluasi ini dilakukan pada gawai *laptop* ASUS Vivobook Pro 15 dengan prosesor AMD Ryzen 5 5600H, GPU Nvidia RTX 3050Ti, dan RAM 16GB.

Tabel V.1 Spesifikasi Konfigurasi Model dan Perangkat Keras pada Evaluasi RAG Berbasis LLM

Komponen		Spesifikasi
Model	LLM	gpt-4o-mini (OpenAI)
	Model *Embedding*	text-embedding-3-small (OpenAI)
Perangkat keras	Prosesor	AMD Ryzen 5 5600H
	GPU	Nvidia RTX 3050Ti
	RAM	16 GB
Lingkungan Pengujian	Bahasa pemrograman	Python 3.10
	Library	RAGAS, langchain_openai

Selain konfigurasi pada Tabel V.1, evaluasi sistem RAG juga memerlukan *dataset* untuk menilai jawaban serta konteks yang dihasilkan oleh sistem RAG. Untuk penelitian ini, dibuat 100 set pertanyaan yang disertai dengan jawaban faktual (*ground truth*) dan judul topik penyakit terkait. Pertanyaan serta jawaban dibuat

secara manual dengan mengambil kutipan teks di setiap konten artikel lalu merumuskan pertanyaan yang dapat dijawab dengan kutipan teks tersebut. Tabel V.2 menunjukkan tiga contoh set pertanyaan, jawaban, serta topik untuk evaluasi sistem RAG berbasis LLM.

Tabel V.2 Sampel *Dataset* untuk Evaluasi Sistem RAG Berbasis LLM

question	ground_truth	topic
“Bagaimana cara mencegah hipertensi?”	“"Beberapa cara efektif yang dapat dilakukan adalah: Pertahankan berat badan ideal. Lakukan olahraga secara rutin minimal 30 menit...”	“Hipertensi”
“Apa gejala yang menunjukkan seseorang mengalami angin duduk?”	“Beberapa gejala lain yang dapat menyertai nyeri dada pada angin duduk atau angina adalah: Keringat dingin Mual Pusing Lemas Sesak napas”	“Angin Duduk”
“Apa saja penyebab penyakit aritmia?”	“Aritmia terjadi ketika impuls listrik yang berfungsi mengatur detak jantung tidak bekerja dengan baik. Kondisi tersebut dapat disebabkan...”	“Aritmia”

V.1.1.2 Skenario Pengujian pada Evaluasi RAG Berbasis LLM

Pada evaluasi berbasis LLM, akan dilakukan perbandingan skor kinerja dari setiap konfigurasi sistem RAG yang ada pada Tabel IV.2. Sebelum melakukan penilaian, akan dilakukan proses *retrieval pipeline* serta *generation pipeline* seperti yang dijelaskan pada subbab IV.2.2.2 untuk setiap konfigurasi sistem RAG. Hasil *retrieval pipeline* berupa tiga segmen dokumen dengan relevansi tertinggi serta hasil *generation pipeline* berupa jawaban faktual LLM akan tersimpan ke dalam *dataset* ketika jawaban faktual berhasil dihasilkan. Selain itu, untuk konfigurasi

sistem RAG yang menerapkan *Hypothetical Document Embeddings*, jawaban hipotesis juga akan tersimpan ke dalam *dataset*.

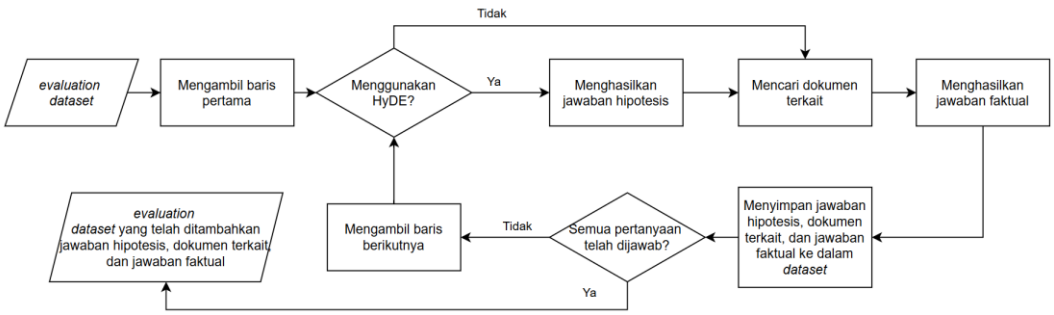

Gambar V.1 Diagram Alir *Retrieval* dan *Answer Generation* pada Proses Evaluasi RAG Berbasis LLM

Setelah seluruh dokumen terkait dan jawaban faktual didapatkan, dilakukan evaluasi menggunakan *library* RAGAS. Sesuai dengan Gambar V.2, evaluasi ini dilakukan dengan melakukan iterasi di setiap baris di dalam *dataset* dan mengevaluasi aspek *faithfulness, reponse relevancy, context precision,* dan *context recall* di setiap barisnya. Skor setiap metrik kemudian dimasukkan ke dalam *dataset*. Setelah skor setiap metrik dihasilkan untuk setiap set pertanyaan, akan dilakukan pemrosesan lebih lanjut untuk melihat perbandingan rata-rata skor di setiap metrik pada setiap konfigurasi sistem RAG.

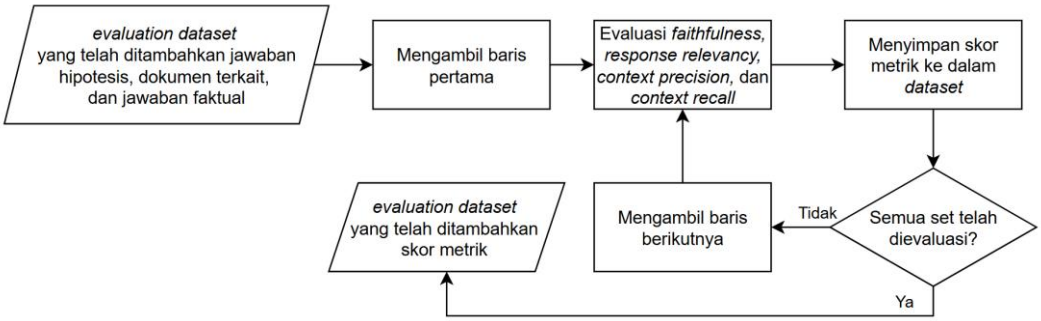

Gambar V.2 Diagram Alir Proses Penilaian Metrik RAGAS pada Proses Evaluasi RAG Berbasis LLM

V.1.2 Evaluasi RAG Berbasis Ahli Domain

Selain evaluasi berbasis LLM, jawaban yang dihasilkan sistem RAG juga akan dievaluasi oleh ahli dalam bidang penyakit jantung. Hal ini untuk memastikan jawaban faktual yang dihasilkan oleh LLM sesuai dengan standard ilmu di bidang penyakit jantung. Untuk melakukan penilaian terhadap jawaban LLM dalam sistem RAG, digunakan empat metrik penilaian sesuai dengan Tabel V.3. Empat metrik ini diturunkan dari metrik evaluasi yang digunakan untuk evaluasi LLM pada tugas peringkasan teks studi penelitian medis dan uji klinis (Tang dkk. 2023). Setiap metrik akan dinilai dengan pemberian skor menggunakan skala likert yang bersifat diskrit. Selain menggunakan empat metrik kuantitatif pada Tabel V.3, ahli domain terkait juga akan memberikan penilaian kualitatif dari jawaban yang dihasilkan sistem RAG.

Tabel V.3 Metrik Evaluasi RAG Berbasis Ahli Domain

Metrik	Pengertian	Sistem Penilaian Skor
Faktualitas	Menilai akurasi keseluruhan informasi yang ada di dalam jawaban	Skala likert (1–5). Skor 1 menyatakan jawaban tidak faktual, skor 5 menyatakan jawaban sangat faktual.
Koherensi	Menilai kepaduan antar kalimat di dalam jawaban agar jawaban mudah dipahami	Skala likert (1–5). Skor 1 menyatakan jawaban tidak koheren, skor 5 menyatakan jawaban sangat koheren.
Kelengkapan (*Comprehensiveness*)	Menilai kelengkapan informasi penting yang diperlukan dalam jawaban yang diberikan	Skala likert (1–5). Skor 1 menyatakan jawaban tidak komprehensif/lengkap, skor 5 menyatakan jawaban sangat komprehensif/lengkap.
Potensi Bahaya (*Harmfulness*)	Menilai potensi jawaban yang dapat menyesatkan atau menyebabkan dampak buruk, seperti kesalahan dalam pengobatan	Skala likert (1–5). Skor 1 menyatakan jawaban memiliki potensi membahayakan pengguna, skor 5 menyatakan jawaban sangat aman untuk pengguna.

V.1.2.1 Konfigurasi Sistem pada Evaluasi RAG Berbasis Ahli Domain

Pada evaluasi RAG berbasis *domain expertise*, penilaian terhadap jawaban sistem RAG dilakukan oleh dr. Akhmad Hidayatullah, Sp.JP yang merupakan dokter spesialis jantung dan pembuluh darah yang berasal dari Rumah Sakit Umum Daerah Oto Iskandar Di Nata (RSUD Otista) Soreang. Konfigurasi sistem RAG yang akan digunakan untuk evaluasi RAG berbasis *domain expert* merupakan konfigurasi dengan kinerja terbaik pada evaluasi RAG berbasis LLM. Sama seperti evaluasi berbasis LLM, evaluasi ini dilakukan pada gawai *laptop* ASUS Vivobook Pro 15 dengan prosesor AMD Ryzen 5 5600H, GPU Nvidia RTX 3050Ti, dan RAM 16GB. Evaluasi berbasis *domain expert* juga akan memanfaatkan antarmuka yang telah dibuat menggunakan *library* Streamlit.

Tabel V.4 Spesifikasi Konfigurasi Model dan Perangkat Keras pada Evaluasi RAG Berbasis Ahli Domain

Komponen		Spesifikasi
Perangkat keras	Prosesor	AMD Ryzen 5 5600H
	GPU	Nvidia RTX 3050Ti
	RAM	16 GB
Perangkat lunak	Antarmuka	Streamlit

Sama seperti evaluasi berbasis LLM, evaluasi berbasis ahli domain juga memerlukan *dataset* untuk melakukan penilaian. Evaluasi ini akan menggunakan *dataset* yang berisi pertanyaan yang dirumuskan bersama ahli domain. Pertanyaan yang dibuat merupakan pertanyaan yang kerap ditanyakan oleh pasien yang berkaitan dengan penyakit jantung menurut ahli domain. Setelah melakukan diskusi dengan ahli domain, dihasilkan delapan set pertanyaan yang tertera pada Tabel V.5.

Tabel V.5 *Dataset* untuk Evaluasi Sistem RAG Berbasis Ahli Domain

ID Pertanyaan	question	topic
Q01	"Bagaimana gejala serangan jantung?"	"Serangan Jantung"
Q02	"Apakah angin duduk itu adalah serangan jantung?"	"Angin Duduk"
Q03	"Apa saja gejala hipertensi?"	"Hipertensi"
Q04	"Apa jenis makanan yang disarankan pada pasien yang terkena penyakit jantung?"	"All"
Q05	"Aktivitas atau olahraga apa yang disarankan untuk menjaga kesehatan jantung?"	"All"
Q06	"Aktivitas atau olahraga apa yang disarankan untuk seseorang yang telah terkena penyakit jantung?"	"All"
Q07	"Apakah pasien dapat berhenti minum obat setelah didiagnosis hipertensi?"	"Hipertensi"
Q08	"Apa tujuan tindakan pemasangan ring jantung?"	"Penyakit Jantung Koroner"

V.1.2.2 Skenario Pengujian pada Evaluasi RAG Berbasis Ahli Domain

Evaluasi berbasis *domain expertise* dilakukan secara iteratif. Dengan menggunakan *dataset* pada Tabel V.5, setiap pertanyaan akan dimasukkan ke dalam antarmuka Indo Cardiac Chatbot untuk menghasilkan jawaban faktual. Setelah jawaban dihasilkan, pertanyaan dan jawaban akan direkap di dalam *spreadsheet*. Proses penilaian terhadap jawaban yang dihasilkan akan dilakukan di dalam *spreadsheet* dan menggunakan metrik pada Tabel V.3 sebagai metrik penilaian. Selain memberikan penilaian, ahli domain juga akan memberikan komentar terkait kualitas jawaban yang dihasilkan sistem RAG.

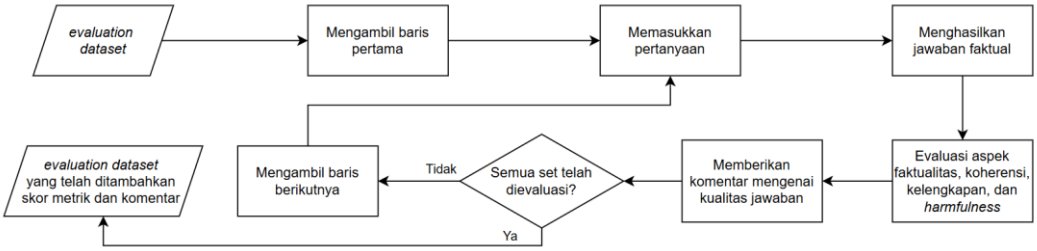

Gambar V.3 Diagram Alir Proses Evaluasi RAG Berbasis Ahli Domain

V.2 Hasil Evaluasi

V.2.1 Hasil Evaluasi RAG Berbasis LLM

Evaluasi berbasis LLM dijalankan dengan mengevaluasi seluruh jawaban yang telah dihasilkan sistem *Retrieval Augmented Generation* (RAG). Sebelum evaluasi dilakukan, setiap konfigurasi telah dipastikan berfungsi untuk menjawab 100 set pertanyaan yang telah dirancang. Setelah menjalankan skenario sesuai dengan subbab V.1.1.2, dihasilkan skor setiap metrik RAGAS untuk setiap jawaban yang dihasilkan. Dengan hasil tersebut, dilakukan perhitungan rata-rata (*mean*) skor *faithfulness*, *answer relevancy*, *context precision*, dan *context recall* untuk setiap konfigurasi.

Tabel V.6 Skor Rata-rata Metrik *Faithfulness*, *Answer Relevancy*, *Context Precision*, dan *Context Recall* untuk Setiap Konfigurasi Sistem RAG

Konfigurasi	*Faithfulness*	*Answer Relevancy*	*Context Precision*	*Context Recall*	*Mean Score*
combination_1	0,865	0,604	0,927	0,865	0,815
combination_2	0,68	0,608	0,936	0,871	0,774
combination_3	0,895	0,607	0,947	0,91	0,84
combination_4	0,679	0,613	0,947	0,913	0,788
combination_5	0,883	0,608	0,93	0,895	0,829
combination_6	0,698	0,61	0,934	0,923	0,791
combination_7	0,935	0,624	0,95	0,95	0,865
combination_8	0,703	0,608	0,963	0,973	0,812

Tabel V.6 menunjukkan hasil skor rata-rata setiap metrik RAGAS yang digunakan untuk mengevaluasi sistem RAG. Dalam Tabel V.6, kolom "Mean Score" merupakan skor rata-rata dari seluruh skor metrik untuk setiap konfigurasi sistem RAG. Berdasarkan perbandingan skor pada Tabel V.6, konfigurasi combination_7 merupakan konfigurasi dengan skor rata-rata paling tinggi dibanding tujuh konfigurasi lainnya. Sesuai dengan konfigurasi model pada Tabel IV.2, combination_7 merupakan sistem RAG yang menerapkan *Hypothetical Document Embeddings* (HyDE) dan disusun oleh model mxbai-embed-large sebagai model *embedding*, Cohere Rerank 3.5 sebagai model *ranking*, dan llama3.1 sebagai LLM untuk sistem RAG. Konfigurasi combination_7 mengungguli ketujuh konfigurasi lainnya dalam aspek *answer generation* dengan menghasilkan skor *faithfulness* dan *answer relevancy* tertinggi. Namun, dalam aspek *document retrieval* yang diobservasi melalui perbandingan skor *context precision* dan *context recall*, combination_7 masih sedikit kalah unggul dibanding combination_8 yang sama-sama menerapkan HyDE dan menggunakan mxbai-embed-large sebagai model *embedding* untuk sistem RAG.

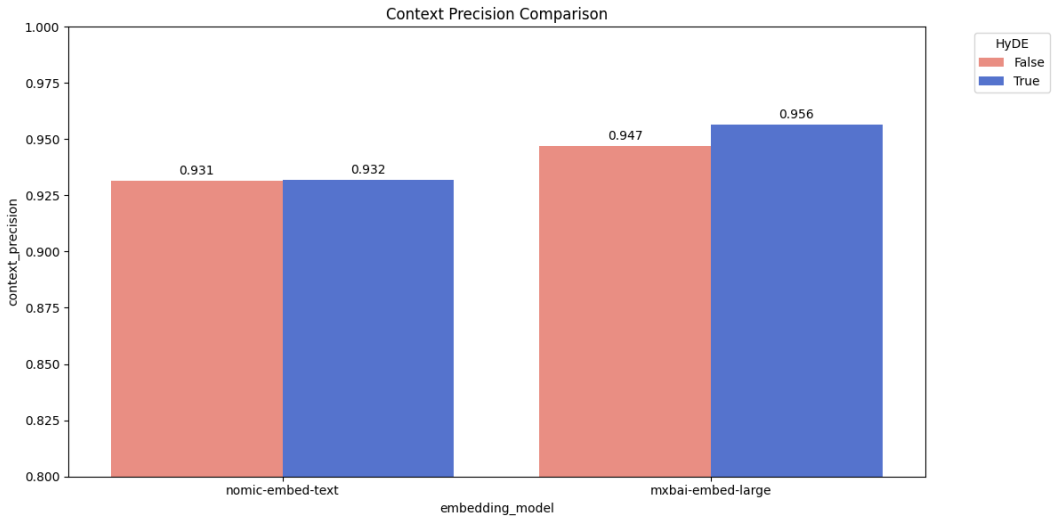

Gambar V.4 Perbandingan Skor *Context Precision* antar Model *Embedding* Dengan dan Tanpa Penerapan HyDE

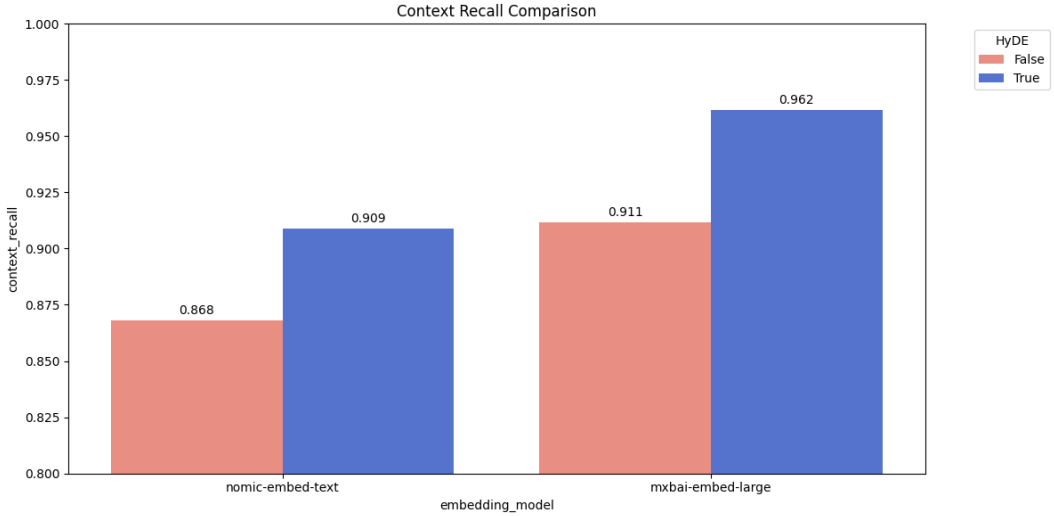

Gambar V.5 Perbandingan Skor *Context Recall* antar Model *Embedding* Dengan dan Tanpa Penerapan HyDE

Perbandingan lebih lanjut dilakukan untuk menganalisis dampak penerapan *Hypothetical Document Embeddings* (HyDE) terhadap kinerja sistem RAG. Diagram batang pada Gambar V.4 dan V.5 dihasilkan untuk membandingkan kinerja *document retrieval* dari model *embedding* yang menerapkan dan tidak menerapkan HyDE. Kedua diagram batang menunjukkan model mxbai-embed-large memiliki kinerja *retrieval* yang lebih baik dibanding nomic-embed-text. Ukuran parameter mxbai-embed-large yang lebih besar dibanding nomic-embed-text membuat mxbai-embed-large memiliki kinerja *retrieval* yang lebih baik. Dalam aspek penerapan HyDE, Gambar V.4 dan V.5 sama-sama menunjukkan kinerja *retrieval* pada kedua model *embedding* yang lebih baik ketika HyDE diterapkan pada *retrieval pipeline* di dalam sistem RAG. Pada Gambar V.4, terdapat peningkatan skor *context precision* pada kedua model *embedding* dengan persen peningkatan sebesar 0,1% pada model nomic-embed-text dan peningkatan sebesar 0,95% pada model mxbai-embed-large. Adanya peningkatan dalam skor *context precision* menunjukkan penerapan HyDE mampu meningkatkan jumlah

informasi yang relevan terhadap jawaban *ground truth* dan tersimpan di dalam dokumen hasil proses *retrieval.*

Sementara itu, pada Gambar V.5, terdapat juga peningkatan skor *context recall* pada kedua model *embedding* dengan persen peningkatan sebesar 4,72% pada model nomic-embed-text dan peningkatan sebesar 5,6% pada model mxbai-embed-large. Adanya peningkatan dalam skor *context recall* menunjukkan penerapan HyDE mampu meningkatkan rasio informasi dalam jawaban *ground truth* yang didukung oleh kumpulan dokumen yang didapatkan dalam proses *retrieval*. Karena penerapan *Hypothetical Document Embeddings* dilakukan pada fase *retrieval*, dapat disimpulkan implementasi RAG dengan pendekatan HyDE memiliki kinerja yang lebih baik dalam aspek *retrieval* dibandingkan dengan implementasi RAG biasa yang tidak menerapkan HyDE dengan menyediakan informasi yang lebih relevan dengan jawaban *ground truth*.

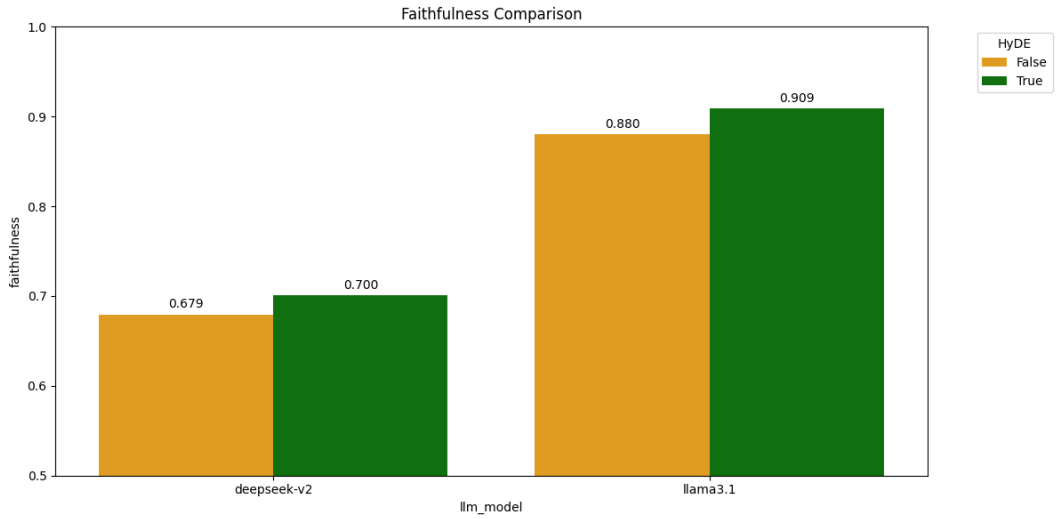

Gambar V.6 Perbandingan Skor *Faithfulness* antar LLM Dengan dan Tanpa Penerapan HyDE

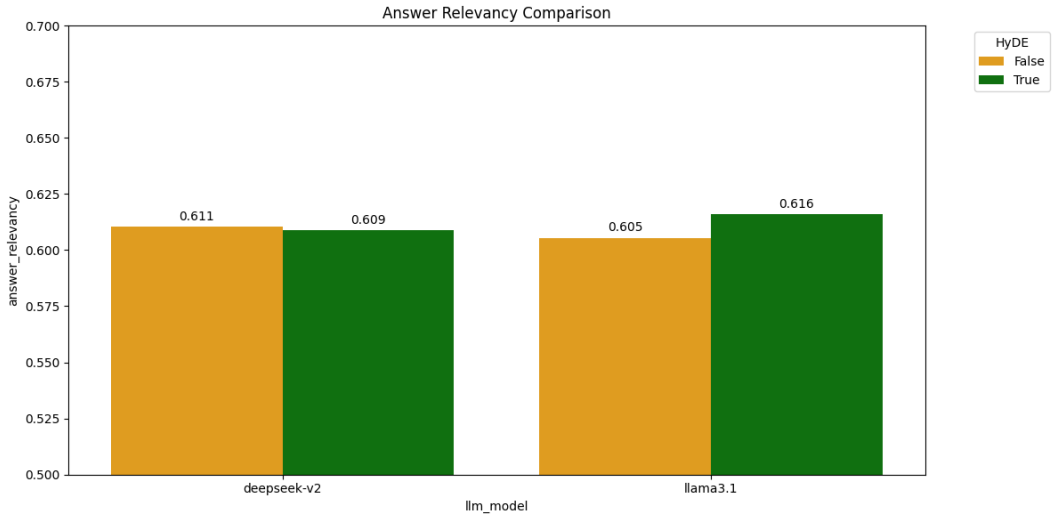

Gambar V.7 Perbandingan Skor *Answer Relevancy* antar LLM Dengan dan Tanpa Penerapan HyDE

Meskipun penerapan HyDE dilakukan pada *retrieval pipeline,* perbandingan kinerja *answer generation* dilakukan untuk mengamati dampak penerapan HyDE dalam jawaban yang dihasilkan LLM dalam sistem RAG. Diagram batang pada Gambar V.6 dan V.7 dihasilkan untuk membandingkan kinerja *answer generation* dari LLM yang menerapkan dan tidak menerapkan HyDE. Terdapat perbedaan terhadap pengaruh penerapan HyDE terhadap metrik *faithfulness* dan *answer relevancy*. Pada Gambar V.6, model llama3.1 secara keseluruhan memiliki skor *faithfulness* yang lebih tinggi dibanding model deepseek-v2. Diagram batang pada Gambar V.6 juga menunjukkan penerapan HyDE meningkatkan skor *faithfulness* pada kedua LLM dengan persen peningkatan sebesar 3,09% pada model deepseek-v2 dan 3,3% pada model llama3.1.

Sementara itu, Gambar V.7 menunjukkan hal yang sedikit kontras dibanding Gambar V.6. Diagram batang pada Gambar V.7 menunjukkan pengaruh HyDE yang kecil dan tidak konsisten terhadap *answer relevancy* dengan adanya penurunan skor sebesar 0,33% pada model deepseek-v2 dan kenaikan skor sebesar 1,79% pada model llama3.1. Adanya perbedaan pengaruh HyDE terhadap aspek

faithfulness dan *answer relevancy* menunjukkan bahwa HyDE, yang diterapkan pada *retrieval pipeline*, lebih efektif dalam memastikan dukungan konteks untuk menghasilkan jawaban yang akurat daripada mengubah relevansi jawaban akhir terhadap pertanyaan pengguna.

V.2.2 Hasil Evaluasi RAG Berbasis Ahli Domain

Berdasarkan hasil evaluasi berbasis LLM, combination_7 merupakan konfigurasi dengan rata-rata skor kinerja terbaik. Oleh karena itu, konfigurasi tersebut digunakan sebagai konfigurasi untuk sistem RAG pada evaluasi berbasis *domain expertise.* Sebelum proses penilaian dilakukan, proses *answer generation* dilakukan di dalam UI sistem RAG (Indo Cardiac Chatbot). Proses ini dilakukan dengan memasukkan pertanyaan serta topik terkait yang telah dirancang pada Tabel V.5.

Tabel V.7 Hasil Penilaian Ahli Domain Terhadap Jawaban Sistem RAG

ID Pertanyaan	*Factuality*	*Coherence*	*Comprehensiveness*	*Harmfulness*
Q01	4	4	4	4
Q02	3	3	2	3
Q03	4	4	4	4
Q04	4	4	3	4
Q05	3	3	2	4
Q06	5	4	4	4
Q07	4	4	4	4
Q08	5	4	4	4
Median Score	4	4	4	4

Tabel V.7 menunjukkan penilaian ahli domain terhadap jawaban yang sudah dihasilkan sistem RAG (hasil jawaban sistem RAG dapat dilihat pada Lampiran B). Karena setiap metrik penilaian merupakan skala likert yang bersifat ordinal, digunakan median sebagai metode perhitungan *central tendency* dari data nilai setiap metrik. Berdasarkan hasil penilaian ahli domain, terdapat beberapa poin yang didapatkan:

1. Skor median dalam aspek faktualitas mengindikasikan jawaban yang dihasilkan sistem RAG sudah cukup akurat dan sesuai dengan basis pengetahuan terkait penyakit jantung.
2. Skor median dalam aspek koherensi menandakan jawaban yang dihasilkan sudah memiliki keterhubungan antar kalimat yang cukup baik sehingga jawaban mudah dipahami oleh pengguna.
3. Beberapa skor dalam aspek kelengkapan masih menunjukkan adanya beberapa jawaban yang memiliki skor kelengkapan yang rendah karena belum dapat mencakup seluruh informasi penting sehingga aspek ini merupakan aspek yang perlu ditingkatkan.
4. Skor-skor yang dihasilkan dalam aspek potensi bahaya menunjukkan jawaban yang dihasilkan secara umum cenderung aman dan tidak berpotensi menyesatkan atau membahayakan pengguna.

Secara garis besar, ahli domain menilai sistem RAG dengan pendekatan HyDE mampu menghasilkan jawaban yang faktual dengan struktur kalimat yang mudah dipahami serta informasi yang tidak membahayakan pengguna namun perlu ada peningkatan terkait kelengkapan informasi penting pada jawaban yang dihasilkan.

V.3 Diskusi

Subbab ini berfokus pada pembahasan hasil evaluasi berdasarkan subbab V.2.1 dan V.2.2. Pembahasan hasil evaluasi dilakukan dengan analisis galat (*error analysis*) serta komentar ahli domain terhadap sistem RAG. Sama seperti subbab V.2, subbab diskusi akan terbagi menjadi dua subbab berdasarkan variasi metode yang dilakukan. Subbab pertama akan membahas analisis galat terkait hasil evaluasi sistem RAG berbasis LLM. Sementara itu, subbab kedua akan membahas analisis galat terhadap jawaban yang dihasilkan LLM beserta komentar ahli domain terkait sistem RAG yang telah dibuat.

V.3.1 Diskusi Hasil Evaluasi RAG Berbasis LLM

Hasil evaluasi pada subbab V.2.1 menunjukkan kemampuan penerapan *Hypothetical Document Embeddings* (HyDE) dalam meningkatkan efektivitas proses *document retrieval* dengan menyediakan dokumen yang lebih relevan terhadap jawaban *ground truth*. Peningkatan efektivitas *retrieval* ini juga membuat jawaban yang dihasilkan dalam proses *answer generation* memiliki tingkat akurasi yang lebih tinggi sehingga risiko LLM dalam berhalusinasi menjadi lebih rendah. Penerapan ini menjawab kekhawatiran akan adanya misinformasi pada jawaban yang dihasilkan LLM, khususnya pada domain kesehatan, akibat kecenderungannya dalam berhalusinasi. Namun, hasil evaluasi juga menunjukkan adanya galat (*error*), baik dalam proses *document retrieval* maupun proses *answer generation*. Untuk mengidentifikasi penyebab galat ini, dilakukan analisis galat (*error analysis*) terhadap hasil evaluasi. Sebelum analisis dilakukan, diambil 16 sampel dari setiap metrik RAGAS dengan skor terrendah. Sampel yang dikumpulkan di setiap metrik RAGAS ini terdiri dari dua sampel dari setiap konfigurasi sistem RAG.

Tabel V.6 Perbandingan Jawaban *Ground Truth* dan Hipotesis pada Salah Satu Sampel Set Evaluasi

Jawaban *Ground Truth*	Hipotesis
"Makanan tinggi serat, seperti sayur dan buah. Selain itu, tingkatkan kadar kolesterol baik atau HDL dengan memperbanyak konsumsi makanan tinggi lemak tak jenuh. Jenis makanan ini antara lain minyak ikan, minyak zaitun, minyak biji bunga matahari, minyak sayur, serta alpukat dan kacang-kacangan."	"Makanan yang baik untuk pencegahan penyakit jantung koroner antara lain adalah buah-buahan dan sayuran segar, seperti apel, jeruk, brokoli dan wortel. Selain itu, makanan yang mengandung omega-3 seperti ikan salmon atau sarden juga dapat membantu dalam pencegahan penyakit jantung koroner."

Berdasarkan analisis terhadap sampel data dengan skor *context precision* terkecil, hal yang menyebabkan rendahnya skor adalah ketidaksesuaian antara dokumen yang diambil oleh *retriever* dengan kebutuhan informasi pada jawaban *ground*

truth. Sebagai konteks, *context precision* merupakan metrik yang menghitung rasio informasi dalam dokumen hasil *retrieval* yang relevan terhadap jawaban *ground truth* sehingga rendahnya skor metrik tersebut memang menandakan tidak semua informasi dalam dokumen yang diambil relevan terhadap jawaban *ground truth*. Ketidakmampuan model *embedding* untuk mendapatkan dokumen yang relevan dapat disebabkan oleh ketidaktepatan representasi semantik dalam model sehingga terjadi kegagalan dalam membedakan antara topik yang saling berkaitan namun memiliki fokus informasi yang berbeda. Selain itu, pada konteks penerapan HyDE, ketidaksesuaian dokumen yang diambil dapat disebabkan oleh hipotesis yang dihasilkan oleh LLM. Mengingat LLM yang digunakan pada penelitian ini tidak dilakukan pelatihan terlebih dahulu, masih terdapat kecenderungan pada LLM untuk berhalusinasi sehingga jawaban yang dihasilkan masih belum tentu akurat. Jawaban yang belum akurat ini bisa saja terlalu umum atau tidak mengandung kata kunci yang sesuai dengan *ground truth* seperti Tabel V.6. Akibatnya, model gagal mengaitkan hipotesis dengan dokumen yang benar-benar membahas informasi spesifik yang relevan dengan jawaban *ground truth*.

Selain memengaruhi nilai *context precision*, ketidaktepatan representasi semantik dalam model *embedding* juga memengaruhi skor *context recall.* Sebagai konteks, *context recall* merupakan metrik untuk menghitung rasio antara jumlah klaim dalam jawaban *ground truth* yang didukung oleh dokumen yang diambil (pada proses *retrieval*) dengan jumlah seluruh klaim dalam jawaban *ground truth* sehingga kecilnya skor metrik ini menandakan konteks yang tersedia dalam dokumen tidak cukup untuk mendukung seluruh informasi yang tersimpan di dalam jawaban *ground truth*. Seperti yang dijelaskan sebelumnya, ketidaktepatan representasi semantik ini menyebabkan kegagalan dalam membedakan antara topik yang saling berkaitan namun memiliki fokus informasi yang berbeda. Hal ini dapat membuat dokumen yang diambil menjadi tidak sesuai dengan kebutuhan informasi pada jawaban *ground truth*. Sama seperti *context recall,* kecilnya skor metrik *context precision* pada konfigurasi yang menerapkan HyDE dapat disebabkan oleh

jawaban hipotesis yang terlalu umum dan tidak mengandung kata kunci sehingga model gagal mengaitkan hipotesis dengan dokumen yang benar-benar relevan dengan jawaban *ground truth*.

Analisis galat terkait hasil evaluasi metrik *faithfulness* dilakukan untuk mencari penyebab kemunculan misinformasi pada beberapa sampel dengan skor *faithfulness* terkecil. *Faithfulness* sendiri merupakan metrik yang mengukur rasio antara klaim dalam jawaban LLM yang didukung oleh dokumen yang diambil oleh *retriever* dengan jumlah seluruh klaim dalam jawaban LLM. Hasil analisis menunjukkan adanya dua penyebab di balik misinformasi dari jawaban yang dihasilkan, yakni kegagalan proses *retrieval* dalam memberikan dokumen yang relevan (yang telah dibahas di paragraf sebelumnya) serta kecenderungan LLM dalam berhalusinasi. Beberapa sampel menunjukkan halusinasi pada LLM terjadi pada konfigurasi yang menggunakan deepseek-v2 sebagai LLM. Hal ini dapat menjadi penyebab adanya perbedaan skor *faithfulness* yang cukup jauh antara model llama3.1 dengan deepseek-v2.

Pada proses penerapan *generation pipeline* untuk menghasilkan jawaban, *prompt* yang dibuat merupakan *prompt* yang diterapkan ke kedua model. Karena setiap LLM memiliki arsitektur serta metode pelatihan yang berbeda, penerapan *prompt* yang uniform untuk seluruh LLM pada proses *answer generation* dapat menjadi penyebab adanya kecenderungan model deepseek-v2 untuk berhalusinasi. Percobaan singkat dilakukan untuk merumuskan *prompt* baru bagi model deepseek-v2. *Prompt* baru dirumuskan seperti di bawah.

"Diberikan konteks medis berikut mengenai {topic}:
1. [Konteks 1]
{Konten 1}
2. [Konteks 2]
{Konten 2}

3. [Konteks 3]
{Konten 3}
Instruksi:
- Jawab pertanyaan **hanya berdasarkan konteks di atas**
- Jika jawaban tidak ada dalam konteks, respon 'Informasi tidak ditemukan dalam konteks yang diberikan'.
- Fokus pada informasi yang relevan dan penting dari konteks.
- Jangan menambahkan informasi di luar konteks
Pertanyaan
{query}.
Catatan
- Jangan menyebutkan 'Berdasarkan konteks yang diberikan'."

Terdapat perubahan struktur pada *prompt* baru yang diformulasikan. Struktur *prompt* diawali oleh pemberian isi konten sebagai konteks lalu dilanjutkan dengan beberapa instruksi sebagai panduan bagi model untuk menjawab pertanyaan. Pada instruksi di dalam *prompt* yang baru, model diinstruksikan untuk berfokus pada konteks di dalam konten yang tersedia dan tidak menambahkan informasi di luar konteks. Hal ini dilakukan untuk mencegah adanya halusinasi pada model. Setelah pemberian instruksi, model akan diberikan *prompt* berupa pertanyaan serta catatan tambahan mengenai panduan dalam pemberian jawaban.

Pada percobaan singkat yang dilakukan, digunakan dua sampel pertanyaan dengan hasil jawaban yang memiliki skor rendah dalam aspek *faithfulness* (hasil jawaban dilihat pada Lampiran C). Setelah *prompt* baru diterapkan pada model deepseek-v2, jawaban yang dihasilkan model deepseek-v2 menjadi lebih sesuai dengan jawaban *ground truth*. Ketika dievaluasi ulang menggunakan *library* RAGAS dengan model gpt-4o-mini sebagai LLM untuk evaluasi, dicapai skor *faithfulness* sebesar 100% (1.0) untuk kedua sampel pertanyaan. Hasil evaluasi pada percobaan

singkat ini menunjukkan adanya pengaruh *prompt* terhadap kinerja LLM dalam menghasilkan jawaban.

Aspek terakhir yang dianilis merupakan hasil evaluasi metrik *answer relevancy*. Dari 16 sampel set pertanyaan dan jawaban dengan skor *answer relevancy* terkecil, 12 sampel menunjukkan jawaban yang sudah cukup relevan dengan pertanyaan dan cukup serupa dengan jawaban *ground truth*. Hal ini menunjukkan LLM yang digunakan RAGAS memiliki kecenderungan untuk menghasilkan pertanyaan sintetis yang tidak sesuai dengan fokus pertanyaan asli. Sesuai dengan penjelasan pada II.2.3.3, *answer relevancy* diukur dengan menghitung rata-rata skor *cosine similarity* antara pertanyaan masukan yang asli dengan tiga pertanyaan sintetis yang dihasilkan oleh LLM. Ketika LLM yang digunakan oleh RAGAS menghasilkan pertanyaan yang berbeda dengan pertanyaan asli yang dimasukkan pengguna, hasil skor rata-rata *cosine similarity* akan menjadi sangat kecil. Namun, analisis lebih lanjut terkait perbandingan pertanyaan yang dihasilkan oleh *library* RAGAS dengan pertanyaan yang asli tidak dapat dilakukan karena *library* tersebut tidak memberikan keluaran pertanyaan sintetis yang dihasilkan oleh LLM. Analisis ini juga menunjukkan penerapan *hypothetical document embeddings* (HyDE) yang tidak dapat meningkatkan skor *answer relevancy* memang hanya berfokus pada penyediaan konteks yang lebih relevan untuk menghasilkan jawaban yang lebih akurat dan faktual, bukan untuk menghasilkan jawaban yang lebih relevan dengan pertanyaan pengguna.

V.3.2 Diskusi Hasil Evaluasi RAG Berbasis Ahli Domain

Pada hasil evaluasi berbasis ahli domain, terdapat dua jawaban yang dinilai memiliki kelengkapan yang kurang dengan nilai dua dari lima. Jawaban pertama merupakan jawaban yang berkaitan dengan topik penyakit angin duduk untuk mencari tahu keterkaitan antara penyakit tersebut dengan penyakit serangan jantung. Sementara itu, jawaban kedua merupakan jawaban yang berkaitan dengan

topik penyakit jantung yang umum untuk memberikan tips aktivitas atau olahraga yang disarankan untuk menjaga kesehatan jantung. Tabel V.7 menunjukkan jawaban yang dihasilkan.

Tabel V.7 Sampel Jawaban dengan Skor Kelengkapan (*Comprehensiveness*) Terkecil

ID Pertanyaan	*Question*	*Answer*
Q02	"Apakah angin duduk itu adalah serangan jantung?"	"Angin duduk bukanlah serangan jantung secara langsung. Namun, kondisi ini dapat berkembang menjadi serangan jantung jika tidak ditangani dengan baik dan tepat waktu. Dalam salah satu subtopik yang diberikan, disebutkan bahwa angin duduk dapat berkembang menjadi serangan jantung. Gejala serangan jantung antara lain nyeri dada berat yang menjalar ke lengan, leher, atau punggung, disertai gejala seperti keringat berlebihan, mual, dan pusing. Dalam konteks ini, serangan jantung merupakan komplikasi dari angin duduk. Oleh karena itu, penting untuk mengenali gejala-gejala yang timbul dari kondisi ini dan segera mencari pertolongan medis jika perlu. Selain itu, dalam subtopik lainnya juga disebutkan bahwa angin duduk berkaitan erat dengan gangguan jantung. Hal ini menunjukkan bahwa kondisi ini memiliki keterkaitan yang erat dengan kondisi serius seperti serangan jantung. Dengan demikian, dapat disimpulkan bahwa meskipun angin duduk bukanlah serangan jantung secara langsung, namun kondisi ini dapat berkembang menjadi komplikasi serius jika tidak ditangani dengan baik."

Tabel V.7 Sampel Jawaban dengan Skor Kelengkapan (*Comprehensiveness*) Terkecil (lanjutan)

ID Pertanyaan	*Question*	*Answer*
Q05	"Aktivitas atau olahraga apa yang disarankan untuk menjaga kesehatan jantung?"	"Aktivitas atau olahraga yang disarankan untuk menjaga kesehatan jantung adalah berolahraga ringan selama 30 menit sehari."

Pada saat proses penghasilan jawaban nomor satu, konten dokumen yang diambil pada proses *retrieval* sudah cukup relevan dengan pertanyaan pengguna dan seluruh informasi dalam jawaban yang dihasilkan merupakan jawaban yang berasal dari konten. Walaupun begitu, ahli domain masih menganggap jawaban masih belum mencakup informasi yang menyeluruh. Hal ini disebabkan penyakit angin duduk merupakan penyakit yang kerap berkaitan juga dengan penyakit pencernaan. Kurangnya konteks informasi yang lebih lengkap mengenai penyakit angin duduk juga menyebabkan aspek faktualitas, koherensi, dan *harmfulness* memiliki nilai yang cukup rendah dibanding jawaban-jawaban lainnya. Dengan hasil jawaban ini, ahli domain berpendapat bahwa perlu dilakukan pengumpulan sumber informasi yang lebih banyak agar jawaban yang diberikan lebih komprehensif.

Sementara itu, pada proses penghasilan jawaban nomor dua, proses *retrieval* tidak dapat mencari dokumen yang berkaitan dengan aktivitas atau olahraga yang disarankan untuk menjaga kesehatan jantung. Hal ini disebabkan ketiadaan konten yang berkaitan dengan aktivitas atau olahraga untuk menjaga kesehatan jantung. Pada salah satu dokumen yang diambil, terdapat informasi mengenai pengobatan penyakit jantung dan "olahraga ringan selama 30 menit" merupakan salah satu tips yang ada di dalam informasi tersebut. Karena kurangnya informasi mengenai pertanyaan yang dimasukkan, ahli domain menilai jawaban yang dihasilkan masih belum mencakup informasi yang komprehensif. Sama seperti jawaban nomor satu, ahli domain menyarankan pengumpulan sumber informasi yang lebih banyak pada pengembagan ke depannya.

Secara umum, ahli domain menilai sistem RAG yang telah dibuat telah mampu menghasilkan jawaban yang cukup baik dengan informasi yang lengkap. Selain itu, ahli domain juga menilai konten di dalam artikel yang digunakan sebagai sumber informasi sudah memiliki bahasa awam yang cukup baik sehingga konten dapat mudah dimengerti oleh masyarakat umum. Namun, dengan beberapa hasil jawaban yang masih belum cukup komprehensif, ahli domain memberikan saran agar konten dokumen yang digunakan sebagai sumber informasi dapat diperbanyak lagi. Beberapa sumber yang disarankan oleh ahli domain adalah jurnal atau artikel yang berasal dari luar negeri seperti Mayo Clinic. Dengan sumber yang semakin banyak dan variatif, sistem RAG dapat menghasilkan jawaban yang lebih komprehensif dan mampu menangani pertanyaan dalam domain penyakit yang lebih luas.

BAB VI

KESIMPULAN DAN SARAN

VI.1 Kesimpulan

Dari implementasi sistem *Retrieval Augmented Generation* (RAG) yang telah dilakukan, didapatkan tiga poin penting penyelesaian rumusan masalah:

1. Implementasi RAG untuk sistem tanya jawab tentang penyakit jantung dilakukan dengan menjalankan beberapa tahap dalam kerangka kerja CRISP-DM. Sebelum implementasi, dilakukan tiga tahap yang mencakup *business understanding* terkait kebutuhan penyediaan informasi mengenai penyakit jantung, *data understanding* untuk memahami karakteristik dari kumpulan teks artikel yang didapatkan dari Alodokter, serta *data preparation* untuk memproses data tekstual agar proses pengambilan dokumen dapat berjalan dengan baik. Setelah ketiga tahap tersebut, dilakukan *modelling* dengan mengimplementasi tiga proses *pipeline*, yakni *indexing pipeline* untuk menyimpan dokumen artikel ke dalam basis data, *retrieval pipeline* untuk mengolah *query* dan mengambil dokumen yang terkait dengan masukan pertanyaan, serta *generation pipeline* untuk menghasilkan jawaban berdasarkan *prompt* yang diberikan kepada *large language model* (LLM). Dengan melakukan keempat tahap tersebut, sistem RAG sudah dipastikan mampu memproses pertanyaan yang dimasukkan pengguna untuk menghasilkan jawaban.
2. Pendekatan *Hypothetical Document Embeddings* (HyDE) pada sistem RAG diterapkan pada *retrieval pipeline* yang berfungsi dalam proses pengambilan dokumen. Penerapan ini dilakukan dengan cara memenfaatkan LLM untuk menghasilkan jawaban hipotesis berdasarkan masukan pertanyaan. Jawaban hipotesis tersebut kemudian diolah sebagai *query* untuk mencari dokumen yang terkait dengan masukan pertanyaan.

3. Evaluasi terhadap sistem RAG dilakukan melalui dua metode, yakni evaluasi berbasis LLM dan evaluasi berbasis ahli domain. Pada evaluasi berbasis LLM, digunakan *library* RAGAS yang dapat menjalankan evaluasi dengan menggunakan LLM. Evaluasi berbasis LLM dilakukan pada delapan konfigurasi dengan kombinasi model *embedding* dan LLM yang berbeda dengan empat konfigurasi menerapakan pendekatan HyDE sedangkan empat lainnya tidak menerapkan HyDE. Hasil evaluasi berbasis LLM menunjukkan penerapan HyDE dalam sistem RAG mampu membuat *retrieval pipeline* memiliki kinerja *retrieval* yang lebih baik daripada sistem RAG yang tidak menerapakan HyDE dengan menyediakan kumpulan dokumen (*chunks*) yang lebih relevan terhadap jawaban *ground truth.* Kinerja *retrieval* yang lebih baik juga membuat LLM dalam sistem RAG mampu menghasilkan jawaban yang lebih akurat dan sesuai dengan konteks dalam dokumen yang diambil. Sementara itu, pada evaluasi berbasis ahli domain, dilakukan perumusan delapan pertanyaan yang kerap ditanyakan oleh pasien. Dengan menggunakan konfigurasi dengan skor kinerja terbaik pada evaluasi berbasis LLM, dilakukan proses penghasilan jawaban (*answer generation*) menggunakan UI *chatbot* yang telah dibuat. Secara keseluruhan, ahli domain menilai sistem RAG sudah cukup baik dalam menghasilkan jawaban yang faktual, koheren, komprehensif, serta tidak membahayakan pengguna.

VI.2 Saran

Dengan hasil yang telah dicapai pada penelitian ini, terdapat beberapa saran yang perlu dipertimbangkan pada pengembangan selanjutnya di masa depan:

1. Melakukan pelatihan terhadap LLM dalam domain kesehatan ketika menerapkan *Hypothetical Document Embeddings* agar jawaban hipotesis yang diberikan LLM mampu digunakan untuk mengambil dokumen-dokumen yang relevan terhadap pertanyaan.

2. Menerapkan *prompt* yang berbeda terhadap setiap LLM yang digunakan dalam sistem RAG untuk memastikan LLM tidak berhalusinasi dalam menghasilkan jawaban faktual.
3. Menggunakan LLM dengan jumlah parameter yang lebih banyak ketika melakukan evaluasi metrik *answer relevancy* menggunakan *library* RAGAS. Hal ini dilakukan untuk memastikan LLM mampu menghasilkan pertanyaan sintetis yang lebih relevan dengan memahami konteks jawaban dengan baik.
4. Menambah jumlah set pertanyaan dan menambah variasi pertanyaan seperti pertanyaan ganda (dalam satu masukan) untuk evaluasi sistem RAG agar evaluasi dapat mencakup seluruh variasi subtopik serta variasi struktur pertanyaan.
5. Mengumpulkan referensi dokumen yang lebih banyak serta lebih terpercaya untuk memastikan jawaban yang diberikan terkait domain penyakit jantung mampu mencakup informasi yang lebih komprehensif.

DAFTAR PUSTAKA

Aliannejadi, Mohammad, Jacek Gwizdka, dan Hamed Zamani. 2024. "Interactions with Generative Information Retrieval Systems." Dalam *Information Access in the Era of Generative AI*, 51:47–71. Springer, Cham. https://doi.org/10.1007/978-3-031-73147-1_3.

Balaguer, Angels, Vinamra Benara, Renato Luiz de Freitas Cunha, Roberto de M. Estevão Filho, Todd Hendry, Daniel Holstein, Jennifer Marsman, dkk. 2024. "RAG vs Fine-tuning: Pipelines, Tradeoffs, and a Case Study on Agriculture," Januari. https://doi.org/10.48550/arXiv.2401.08406.

Bianchi, Tiago. 2024. "Global Weekly Interest in Generative AI on Google Searches 2022-2024." statista.com. 5 Juli 2024. https://www.statista.com/statistics/1367868/generative-ai-google-searches-worldwide/.

Borji, Ali. 2023. "Key-Value Transformer," Mei. https://doi.org/10.48550/arXiv.2305.19129.

Bory, Paolo, Simone Natale, dan Christian Katzenbach. 2024. "Strong and weak AI narratives: an analytical framework." *AI & SOCIETY*, Oktober. https://doi.org/10.1007/s00146-024-02087-8.

Cui, Jingfeng, Zhaoxia Wang, Seng-Beng Ho, dan Erik Cambria. 2023. "Survey on sentiment analysis: evolution of research methods and topics." *Artificial Intelligence Review* 56 (8): 8469–8510. https://doi.org/10.1007/s10462-022-10386-z.

Dwivedi, Yogesh K., Laurie Hughes, Elvira Ismagilova, Gert Aarts, Crispin Coombs, Tom Crick, Yanqing Duan, dkk. 2021. "Artificial Intelligence (AI): Multidisciplinary perspectives on emerging challenges, opportunities, and agenda for research, practice and policy." *International Journal of Information Management* 57 (April):101994. https://doi.org/10.1016/j.ijinfomgt.2019.08.002.

Es, Shahul, Jithin James, Luis Espinosa-Anke, dan Steven Schockaert. 2024. "RAGAS: Automated Evaluation of Retrieval Augmented Generation." Dalam *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics System Demonstrations*, 150–58. Association for Computational Linguistics. https://aclanthology.org/2024.eacl-demo.16/.

Feuerriegel, Stefan, Jochen Hartmann, Christian Janiesch, dan Patrick Zschech. 2024. "Generative AI." *Business & Information Systems Engineering* 66 (1): 111–26. https://doi.org/10.1007/s12599-023-00834-7.

Fitriani, Erika Dyah. 2024. "BPJS Kesehatan Biayai Penyakit Jantung Hingga Rp23,52 T di 2023." *detik.com*, 5 Juli 2024. https://news.detik.com/berita/d-7424759/bpjs-kesehatan-biayai-penyakit-jantung-hingga-rp-23-52-t-di-2023.

Gao, Luyu, Xueguang Ma, Jimmy Lin, dan Jamie Callan. 2023. "Precise Zero-Shot Dense Retrieval without Relevance Labels." Dalam *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 1762–77. Association for Computational Linguistics. https://doi.org/10.18653/v1/2023.acl-long.99.

Gao, Yunfan, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang, dan Haofen Wang. 2023. "Retrieval-Augmented Generation for Large Language Models: A Survey," Desember. https://doi.org/10.48550/arXiv.2312.10997.

Heart Research Institute. t.t. "The Human Heart." Heart Research Institute. Diakses 23 November 2024. https://www.hri.org.au/health/learn/your-body/the-human-heart.

Hirvonen, Noora, Ville Jylhä, Yucong Lao, dan Stefan Larsson. 2024. "Artificial intelligence in the information ecosystem: Affordances for

everyday information seeking." *Journal of the Association for Information Science and Technology* 75 (10): 1152–65. https://doi.org/10.1002/asi.24860.

Hotz, Nick. 2024. "What is CRISP-DM?" Data Science PM. 18 November 2024. https://www.datascience-pm.com/crisp-dm-2/#What_are_the_6_CRISP-DM_Phases.

Huang, Lei, Weijiang Yu, Weitao Ma, Weihong Zhong, Zhangyin Feng, Haotian Wang, Qianglong Chen, dkk. 2024. "A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions." *ACM Transactions on Information Systems*, November. https://doi.org/10.1145/3703155.

Institute for Health Metrics and Evaluation. 2024. "GBD Compare Data Visualization." 16 Mei 2024. https://www.healthdata.org/data-tools-practices/interactive-visuals/gbd-compare.

Jia, Xiaoyun, Yan Pang, dan Liangni Sally Liu. 2021. "Online Health Information Seeking Behavior: A Systematic Review." *Healthcare* 9 (12): 1740. https://doi.org/10.3390/healthcare9121740.

Khurana, Diksha, Aditya Koli, Kiran Khatter, dan Sukhdev Singh. 2023. "Natural language processing: state of the art, current trends and challenges." *Multimedia Tools and Applications* 82 (3): 3713–44. https://doi.org/10.1007/s11042-022-13428-4.

Lin, Tianyang, Yuxin Wang, Xiangyang Liu, dan Xipeng Qiu. 2022. "A survey of transformers." *AI Open* 3:111–32. https://doi.org/10.1016/j.aiopen.2022.10.001.

Luo, Renqian, Liai Sun, Yingce Xia, Tao Qin, Sheng Zhang, Hoifung Poon, dan Tie-Yan Liu. 2022. "BioGPT: generative pre-trained transformer for biomedical text generation and mining." *Briefings in Bioinformatics* 23 (6). https://doi.org/10.1093/bib/bbac409.

Martineau, Kim. 2023. “What is Retrieval-Augmented Generation?” IBM. 22 Agustus 2023. https://research.ibm.com/blog/retrieval-augmented-generation-RAG?ref=blog.getdataring.com.

Minaee, Shervin, Tomas Mikolov, Narjes Nikzad, Meysam Chenaghlu, Richard Socher, Xavier Amatriain, dan Jianfeng Gao. 2024. “Large Language Models: A Survey,” Februari. https://doi.org/10.48550/arXiv.2402.06196.

Mitra, Bhaskar, Henriette Cramer, Papermoon Ai, San Francisco, dan Olya Gurevich. 2024. “SOCIOTECHNICAL IMPLICATIONS OF GENERATIVE ARTIFICIAL INTELLIGENCE FOR INFORMATION ACCESS.” Dalam *Information Access in the Era of Generative AI*, 51:161–200. Springer, Cham. https://doi.org/10.1007/978-3-031-73147-1_7.

Moreira, Gabriel de Souza P., Ronay Ak, Benedikt Schifferer, Mengyao Xu, Radek Osmulski, dan Even Oldridge. 2024. “Enhancing Q&A Text Retrieval with Ranking Models: Benchmarking, fine-tuning and deploying Rerankers for RAG.” *GenAI and RAG Systems for Enterprise @ CIKM 2024*, September.

OpenAI, Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, dkk. 2023. “GPT-4 Technical Report,” Maret. https://doi.org/10.48550/arXiv.2303.08774.

Otter, Daniel W., Julian R. Medina, dan Jugal K. Kalita. 2021. “A Survey of the Usages of Deep Learning for Natural Language Processing.” *IEEE Transactions on Neural Networks and Learning Systems* 32 (2): 604–24. https://doi.org/10.1109/TNNLS.2020.2979670.

Ovadia, Oded, Menachem Brief, Moshik Mishaeli, dan Oren Elisha. 2023. “Fine-Tuning or Retrieval? Comparing Knowledge Injection in LLMs,” Desember. https://doi.org/10.48550/arXiv.2312.05934.

Pang, Tianqi, Kehui Tan, Yujun Yao, Xiangyang Liu, Fanlong Meng, Chenyou Fan, dan Xiaofan Zhang. 2024. "REMED: Retrieval-Augmented Medical Document Query Responding with Embedding Fine-Tuning." Dalam *2024 International Joint Conference on Neural Networks (IJCNN)*, 1–8. IEEE. https://doi.org/10.1109/IJCNN60899.2024.10651011.

Sai, Siva, Aanchal Gaur, Revant Sai, Vinay Chamola, Mohsen Guizani, dan Joel J. P. C. Rodrigues. 2024. "Generative AI for Transformative Healthcare: A Comprehensive Study of Emerging Models, Applications, Case Studies, and Limitations." *IEEE Access* 12:31078–106. https://doi.org/10.1109/ACCESS.2024.3367715.

Sarker, Iqbal H. 2022. "AI-Based Modeling: Techniques, Applications and Research Issues Towards Automation, Intelligent and Smart Systems." *SN Computer Science* 3 (2): 158. https://doi.org/10.1007/s42979-022-01043-x.

Singhal, Karan, Shekoofeh Azizi, Tao Tu, S. Sara Mahdavi, Jason Wei, Hyung Won Chung, Nathan Scales, dkk. 2023. "Large language models encode clinical knowledge." *Nature* 620 (7972): 172–80. https://doi.org/10.1038/s41586-023-06291-2.

Singhal, Karan, Tao Tu, Juraj Gottweis, Rory Sayres, Ellery Wulczyn, Le Hou, Kevin Clark, dkk. 2025. "Towards Expert-Level Medical Question Answering with Large Language Models." *Nat Med* 31 (Januari):943–50. https://doi.org/https://doi.org/10.1038/s41591-024-03423-7.

Stryker, Cole; Kavlakoglu, Eda. 2024. "What is Artificial Intelligence." IBM. 16 Agustus 2024. https://www.ibm.com/topics/artificial-intelligence.

Tan, Ting Fang, Arun James Thirunavukarasu, J. Peter Campbell, Pearse A. Keane, Louis R. Pasquale, Michael D. Abramoff, Jayashree Kalpathy-Cramer, dkk. 2023. "Generative Artificial Intelligence Through ChatGPT

and Other Large Language Models in Ophthalmology." *Ophthalmology Science* 3 (4): 100394. https://doi.org/10.1016/j.xops.2023.100394.

Tang, Liyan, Zhaoyi Sun, Betina Idnay, Jordan G. Nestor, Ali Soroush, Pierre A. Elias, Ziyang Xu, dkk. 2023. "Evaluating Large Language Models on Medical Evidence Summarization." *npj Digital Medicine* 6 (1): 158. https://doi.org/10.1038/s41746-023-00896-7.

Tunstall, L, L von Werra, dan T Wolf. 2022. *Natural Language Processing with Transformers*. O'Reilly Media. https://books.google.co.id/books?id=nzxbEAAAQBAJ.

Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, dan Illia Polosukhin. 2017. "Attention Is All You Need." Dalam *NIPS'17: Proceedings of the 31st International Conference on Neural Information Processing Systems*, 30:6000–6010. Curran Associates, Inc. https://dl.acm.org/doi/10.5555/3295222.3295349.

Wankhade, Mayur, Annavarapu Chandra Sekhara Rao, dan Chaitanya Kulkarni. 2022. "A survey on sentiment analysis methods, applications, and challenges." *Artificial Intelligence Review* 55 (7): 5731–80. https://doi.org/10.1007/s10462-022-10144-1.

World Health Organizaiton. 2021. "Cardiovascular Diseases (CVDs)." World Health Organization. 11 Juni 2021. https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds).

Xiao, Tong, dan Jingbo Zhu. 2023. "Introduction to Transformers: an NLP Perspective," November. https://doi.org/10.48550/arXiv.2311.17633.

Xiong, Guangzhi, Qiao Jin, Zhiyong Lu, dan Aidong Zhang. 2024. "Benchmarking Retrieval-Augmented Generation for Medicine." *Findings of the Association for Computational Linguistics ACL 2024*, Agustus, 6233–51. https://doi.org/10.18653/v1/2024.findings-acl.372.

Zhao, Wayne Xin, Kun Zhou, Junyi Li, Tianyi Tang, Xiaolei Wang, Yupeng Hou, Yingqian Min, dkk. 2023. “A Survey of Large Language Models,” Maret. https://doi.org/10.48550/arXiv.2303.18223.

Zhu, Fengbin, Wenqiang Lei, Chao Wang, Jianming Zheng, Soujanya Poria, dan Tat-Seng Chua. 2021. “Retrieving and Reading: A Comprehensive Survey on Open-domain Question Answering,” Januari. https://doi.org/10.48550/arXiv.2101.00774.

LAMPIRAN A

STATISTIK PENELUSURAN TOPIK *GENERATIVE AI*

A.1 Visualisasi Statistik Penelusuran Google dengan Topik Generative AI pada Rentang Waktu Februari 2022 – Juni 2024 (Bianchi 2024)

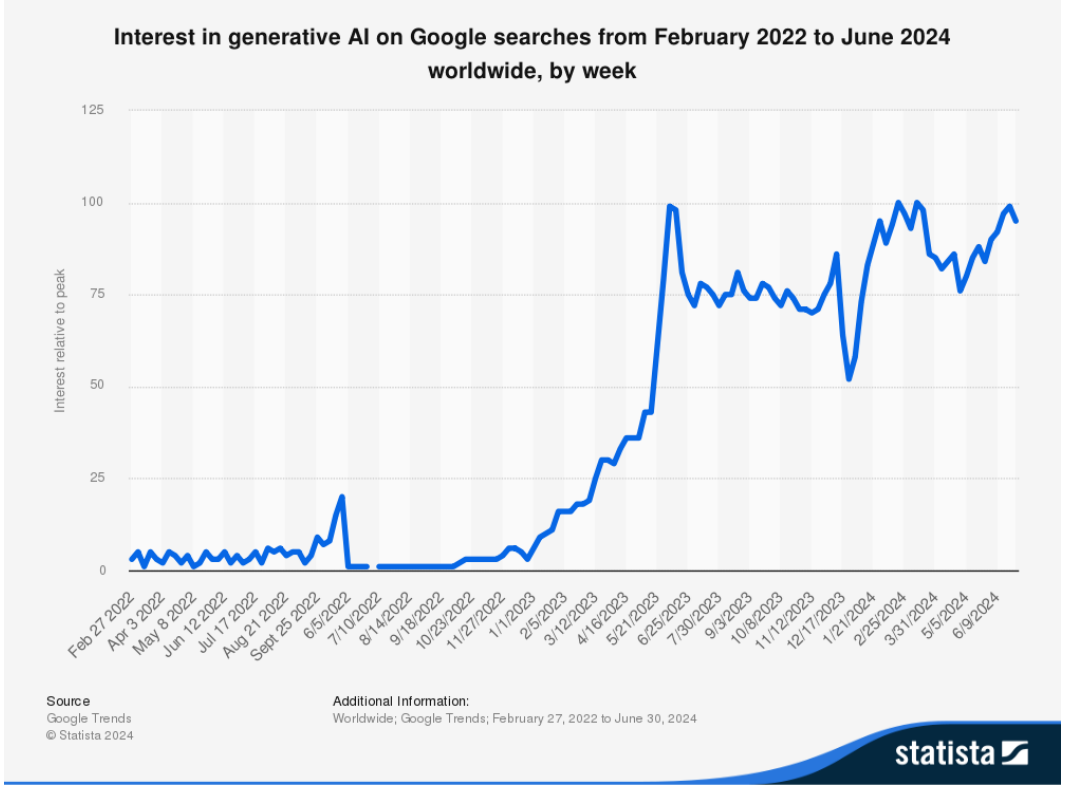

LAMPIRAN B

HASIL JAWABAN SISTEM RAG DARI PERTANYAAN RUMUSAN AHLI DOMAIN

B.1 Hasil Jawaban dari Pertanyaan ID Q01

ID Pertanyaan	question	answer
Q01	"Bagaimana gejala serangan jantung?"	"Gejala serangan jantung bisa muncul secara mendadak dan beberapa gejalanya adalah: Nyeri dada sebelah kiri seperti tertekan atau tertindih, yang dapat menjalar ke daerah leher, rahang, lengan, atau punggung Gangguan pencernaan, seperti mual, muntah, atau sakit perut Batuk atau mengi Sesak napas Pusing Keringat dingin Gelisah dan cemas Penurunan kesadaran"

B.2 Hasil Jawaban dari Pertanyaan ID Q02

ID Pertanyaan	question	answer
Q02	"Apakah angin duduk itu adalah serangan jantung?"	"Angin duduk bukanlah serangan jantung secara langsung. Namun, kondisi ini dapat berkembang menjadi serangan jantung jika tidak ditangani dengan baik dan tepat waktu. Dalam salah satu subtopik yang diberikan, disebutkan bahwa angin duduk dapat berkembang menjadi serangan jantung. Gejala serangan jantung antara lain nyeri dada berat yang menjalar ke lengan, leher, atau punggung, disertai gejala seperti keringat berlebihan, mual, dan pusing. Dalam konteks ini, serangan jantung merupakan komplikasi dari angin duduk. Oleh karena itu, penting untuk mengenali gejala-gejala yang timbul dari kondisi ini dan segera mencari pertolongan medis jika perlu. Selain itu, dalam subtopik lainnya juga disebutkan bahwa angin duduk berkaitan erat dengan gangguan jantung. Hal ini menunjukkan bahwa kondisi ini memiliki keterkaitan yang erat dengan kondisi serius seperti serangan jantung. Dengan demikian, dapat disimpulkan bahwa meskipun angin duduk bukanlah serangan jantung secara langsung, namun kondisi ini dapat berkembang menjadi komplikasi serius jika tidak ditangani dengan baik."

B.3 Hasil Jawaban dari Pertanyaan ID Q03

ID Pertanyaan	question	answer
Q03	"Apa saja gejala hipertensi?"	"Gejala hipertensi dapat berbeda-beda tergantung pada individu dan kondisi kesehatan mereka. Namun, ada beberapa gejala umum yang mungkin dialami oleh orang dengan hipertensi. Beberapa gejala hipertensi yang paling umum adalah: Mual dan muntah Sakit kepala Mimisan Sesak napas Nyeri dada Gangguan penglihatan Telinga berdenging Gangguan irama jantung Darah dalam urine Namun, perlu diingat bahwa hipertensi dapat terjadi tanpa gejala apa pun. Oleh karena itu, penting untuk mengukur tekanan darah secara teratur dan berkonsultasi dengan dokter jika ada kekhawatiran tentang kondisi kesehatan. Dalam beberapa kasus, hipertensi dapat menyebabkan gejala yang lebih serius, seperti sesak napas, nyeri dada, sulit berbicara, sakit kepala yang parah, mati rasa, lemas, dan gangguan penglihatan. Jika Anda mengalami salah satu dari gejala ini, segeralah menghubungi dokter untuk mendapatkan bantuan medis yang tepat. Dalam beberapa kasus lainnya, hipertensi dapat menyebabkan komplikasi serius seperti gagal jantung, penyakit ginjal, hingga stroke. Oleh karena itu, penting untuk segera menghubungi dokter jika Anda memiliki kekhawatiran tentang kondisi kesehatan Anda. Gejala hipertensi dapat berbeda-beda tergantung pada individu dan kondisi kesehatan mereka. Oleh karena itu, penting untuk mengukur tekanan darah secara teratur dan berkonsultasi dengan dokter jika ada kekhawatiran tentang kondisi kesehatan Anda. Penting juga untuk mengetahui bahwa hipertensi dapat menjadi kondisi gawat darurat yang membutuhkan penanganan dengan segera. Jika tekanan darah Anda telah mencapai angka 180/120 atau lebih, segeralah menghubungi dokter untuk mendapatkan bantuan medis yang tepat. Dalam beberapa kasus lainnya, hipertensi dapat menyebabkan gejala yang lebih serius. Oleh karena itu, penting untuk segera menghubungi dokter jika Anda memiliki kekhawatiran tentang kondisi kesehatan Anda."

B.4 Hasil Jawaban dari Pertanyaan ID Q04

ID Pertanyaan	question	answer
Q04	"Apa jenis makanan yang disarankan pada pasien yang terkena penyakit jantung?"	"Pasien penyakit jantung sebaiknya mengonsumsi makanan tinggi serat, seperti sayur dan buah. Selain itu, pastikan kadar garam pada makanan tidak lebih dari satu sendok teh sehari. Jenis makanan yang harus dihindari adalah jenis makanan tinggi kolesterol. Makanan berkadar gula tinggi juga harus dihindari karena dapat meningkatkan risiko diabetes, yang merupakan salah satu faktor risiko penyakit jantung koroner. Sebaliknya, pasien penyakit jantung dianjurkan untuk memperbanyak konsumsi makanan tinggi lemak tak jenuh. Jenis makanan ini antara lain minyak ikan, minyak zaitun, minyak biji bunga matahari, minyak sayur, serta alpukat dan kacang-kacangan. Pasien penyakit jantung juga dianjurkan untuk mengonsumsi makanan yang baik untuk penderita jantung bengkak. Makanan tersebut antara lain buah, sayur, ikan, susu rendah lemak, dan biji-bijian."

B.5 Hasil Jawaban dari Pertanyaan ID Q05

ID Pertanyaan	question	answer
Q05	"Aktivitas atau olahraga apa yang disarankan untuk menjaga kesehatan jantung?"	"Aktivitas atau olahraga yang disarankan untuk menjaga kesehatan jantung adalah berolahraga ringan selama 30 menit sehari."

B.6 Hasil Jawaban dari Pertanyaan ID Q06

ID Pertanyaan	question	answer
Q06	"Aktivitas atau olahraga apa yang disarankan untuk seseorang yang telah terkena penyakit jantung?"	"Pasien yang telah mengalami serangan jantung biasanya akan dimulai dengan program rehabilitasi di rumah sakit, seperti bersepeda, jogging dan berenang. Setelah pulang ke rumah, pasien disarankan untuk melakukan olahraga ringan, seperti berjalan kaki jarak dekat dan naik-turun tangga. Selanjutnya, penderita dapat meningkatkan aktivitas fisiknya secara perlahan-lahan. Dalam program rehabilitasi ini, pasien juga harus memperhatikan hal-hal lain yang terkait dengan pemulihan dari serangan jantung, seperti tidak merokok, mengonsumsi makanan yang baik untuk kesehatan jantung, mengelola stres dengan baik, dan beristirahat yang cukup."

B.7 Hasil Jawaban dari Pertanyaan ID Q07

ID Pertanyaan	question	answer
Q07	"Apakah pasien dapat berhenti minum obat setelah didiagnosis hipertensi?"	"Pasien tidak boleh menghentikan pengobatan obat darah tinggi (antihipertensi) tanpa saran dokter. Dokter akan meresepkan obat darah tinggi pada pasien yang tekanan darahnya lebih dari 140/90 mmHg dan berisiko terserang komplikasi. Jika tekanan darah pasien sudah terkendali melalui perubahan gaya hidup, dokter dapat menurunkan dosis atau menghentikan pengobatan. Namun, ini tidak berarti pasien boleh langsung menghentikan pengobatan tanpa saran dokter. Pasien harus terus kontrol rutin untuk memantau kecocokan dan efektivitas obat yang diberikan. Dokter akan mengevaluasi kondisi pasien secara berkala dan menyesuaikan resep obat jika perlu. Dalam beberapa kasus, penderita hipertensi harus mengonsumsi obat penurun tekanan darah dalam jangka panjang atau seumur hidup. Oleh karena itu, pasien tidak boleh menghentikan pengobatan tanpa saran dokter untuk mencegah komplikasi yang lebih serius."

B.8 Hasil Jawaban dari Pertanyaan ID Q08

ID Pertanyaan	question	answer
Q08	"Apa tujuan tindakan pemasangan ring jantung?"	"Tujuan dari tindakan pemasangan ring jantung adalah untuk mencegah penyempitan kembali arteri. Dengan memasang ring (stent) di arteri, dokter dapat membantu meningkatkan aliran darah ke jantung dan mengurangi gejala-gejala yang disebabkan oleh penyakit jantung koroner. Pemasangan ring jantung atau angioplasti koroner dilakukan dengan memasukkan kateter ke bagian arteri yang menyempit. Setelah itu, dokter akan memasang ring (stent) di arteri untuk mencegah penyempitan kembali. Dengan begitu, aliran darah kembali lancar. Tindakan ini dapat dilakukan secara terencana pada pasien dengan gejala angina atau sebagai tindakan darurat pada orang yang mengalami serangan jantung."

LAMPIRAN C

PERBANDINGAN JAWABAN *LARGE LANGUAGE MODEL* SEBELUM DAN SESUDAH PERUBAHAN *PROMPT*

C.1 Tabel Pertanyaan dan Jawaban *Ground Truth* pada Sampel Pertama

Sampel #1	
question	*ground truth*
"Apa saja komplikasi yang mungkin terjadi pada penyakit tamponade jantung?"	"Selain penyakit dan kondisi yang disebutkan di atas, sejumlah faktor berikut juga bisa meningkatkan risiko seseorang mengalami syok kardiogenik: Berusia lebih dari 75 tahun Menderita gagal jantung Menderita diabetes, sepsis, atau pneumothorax Menderita berat badan berlebih atau obesitas Pernah terkena serangan jantung Pernah menjalani operasi bypass jantung"

C.2 Tabel Perbandingan Jawaban Model Deepseek pada Pertanyaan Sampel Pertama

answer (Menggunakan *prompt* awal)	*answer* (Menggunakan *prompt* baru)
"Hal-hal yang dapat meningkatkan risiko seseorang mengalami syok kardiogenik, selain penyakit dan kondisi yang disebutkan dalam konteks tersebut, termasuk: 1. Berusia lebih dari 75 tahun, yang menunjukkan ketidakmampuan jantung untuk berfungsi secara efektif. 2. Penyakit gagal jantung, dimana jantung kurang mampu mengeluarkan aliran darah dengan cukup sehingga menyebabkan penurunan sistemik kesadaran dan gejala syok. 3. Diabetes, yang mempengaruhi fungsi hati dan bisa meningkatkan risiko terjadinya komplikasi seperti syok kardiogenik. 4. Sepsis, yaitu infeksi di dalam tubuh yang melekat pada darah dan menyebabkan sistem sirkulasi mengalami gangguan. 5. Pneumothorax, yaitu kekurangan tekanan udara di dalam paru-paru yang bisa menurunkan tekanan darah dan menyebabkan syok kardiogenik. 6. Berat badan berlebih atau obesitas, yang dapat mengganggu fungsi jantung dan sistem sirkulasi. 7. Pernyakitan terdahulu, seperti serangan jantung, yang menunjukkan bahwa seseorang mungkin lebih rentan terhadap gangguan kardiovaskuler. 8. Pemakaian obat-obatan atau tindakan medis lainnya, seperti pembedahan bypass jantung, yang bisa mempengaruhi sistem sirkulasi dan meningkatkan risiko syok kardiogenik."	"Hal yang dapat meningkatkan risiko seseorang mengalami syok kardiogenik, berdasarkan konteks di atas, termasuk: 1. Berusia lebih dari 75 tahun 2. Mengalami gagal jantung 3. Menderita diabetes 4. Menderita sepsis 5. Menderita pneumothorax 6. Memiliki berat badan berlebih atau obesitas 7. Pernah terkena serangan jantung 8. Pernah menjalani operasi bypass jantung"

C.3 Tabel Pertanyaan dan Jawaban *Ground Truth* pada Sampel Kedua

Sampel #2	
question	*ground truth*
"Apa saja komplikasi yang mungkin terjadi pada penyakit tamponade jantung?"	"Komplikasi yang mungkin terjadi akibat tamponade jantung antara lain: Syok Perdarahan Edema paru Gagal jantung Kematian"

C.4 Tabel Perbandingan Jawaban Model Deepseek pada Pertanyaan Sampel Kedua

answer (Menggunakan *prompt* awal)	*answer* (Menggunakan *prompt* baru)
"Komplikasi yang mungkin terjadi akibat tamponade jantung, selain yang telah disebut dalam konteks di atas, termasuk: 1. Peningkatan Tekanan Kardiak: Peningkatan tekanan pada peradaran darah dapat menyebabkan denyut nadi menjadi lebih cepat dan jantung berdebar (entrapment of heart). 2. Hipovolemia: Karena mengurangi jumlah cairan dalam tubuh untuk melawan tekanan, penyakit tamponade bisa menyebabkan hipovolemia yang dapat meningkatkan risiko kematian. 3. Disfungsi Ginjal: Penyebab lainnya adalah pengurangan jumlah cairan dalam tubuh, yang juga dapat mempengaruhi fungsi ginjal dan mengakibatkan kerusakan ginjal. 4. Hiperkapnia: Mengganggu fungsi jantung bisa menurunkan aliran udara yang kritis untuk mendukung oksigenasi darah, menyebabkan hiperkapnia atau kekurangan oksigen dalam tubuh."	"Komplikasi yang mungkin terjadi pada penyakit tamponade jantung antara lain adalah syok, perdarahan, edema paru, gagal jantung, dan kematian."