

***Smart Football* : Penerapan Re-Identification untuk
Konsistensi Pemberian ID pada Setiap Pemain
Sepak Bola**

Laporan Tugas Akhir

Oleh:

Riandra Diva Auzan

NIM: 18221077



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
JUNI 2025**

***Smart Football* : Penerapan Re-Identification untuk
Konsistensi Pemberian ID pada Setiap Pemain
Sepak Bola**

Laporan Tugas Akhir

Oleh
Riandra Diva Auzan
NIM: 18221077

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Telah disetujui dan disahkan sebagai Laporan Tugas Akhir
di Bandung, pada tanggal 11 Juli 2025

Pembimbing,



Prof. Dr. Ir. Suhono Harso Supangkat, M. Eng

NIP 1962120319881110011

LEMBAR PERNYATAAN ORISINALITAS

Dengan ini, saya menyatakan bahwa:

1. Pengerjaan dan penulisan Tugas Akhir ini sepenuhnya dilakukan oleh saya tanpa bantuan yang tidak dibenarkan.
2. Segala bentuk kutipan dan acuan terhadap tulisan orang lain yang digunakan di dalam penyusunan Tugas Akhir ini telah dituliskan dengan baik dan benar.
3. Tugas Akhir ini belum pernah diajukan untuk program pendidikan di perguruan tinggi mana pun.

Jika terbukti melanggar hal-hal di atas, saya bersedia dikenakan sanksi sesuai dengan Peraturan Rektor Institut Teknologi Bandung tentang Pelanggaran Peraturan Akademik dan Kemahasiswaan Institut Teknologi Bandung.

Bandung, 11 Juli 2025



Riandra Diva Auzan

NIM 18221077

ABSTRAK

***Smart Football* : Penerapan Re-Identification untuk Konsistensi Pemberian ID pada Setiap Pemain Sepak Bola**

Oleh

Riandra Diva Auzan

NIM: 18221077

Pencatatan kinerja pemain sepak bola di Indonesia masih banyak dilakukan secara manual dan subjektif, yang menyebabkan ketidakkonsistenan data serta evaluasi yang kurang akurat. Penelitian ini mengembangkan sistem analisis video yang mampu memberikan identitas (ID) unik secara konsisten kepada setiap pemain sepanjang pertandingan, bahkan dalam kondisi *occlusion* maupun perpindahan posisi pemain yang keluar-masuk frame. Sistem ini mengintegrasikan metode *object detection* menggunakan YOLOv8, *multi-object tracking* dengan StrongSORT, serta algoritma *Re-Identification* berbasis *Multi-Task Learning* yang mencakup *body part-based features*, *triplet loss*, dan *focal loss* untuk meningkatkan keandalan identifikasi pada tampilan citra dalam bounding box. Evaluasi menggunakan *dataset* Soccernet menunjukkan bahwa sistem ini efektif dalam mengurangi kasus ID-switch dan meningkatkan akurasi pelacakan, terutama untuk pemain yang tidak memiliki nomor punggung. Penerapan sistem ini tidak hanya meningkatkan akurasi pencatatan statistik individu secara otomatis, tetapi juga membuka peluang bagi penerapan evaluasi kinerja yang lebih objektif, terukur, dan berbasis data di lingkungan sekolah sepak bola (SSB)

Kata kunci : Re-Identification, Sepak Bola, Video Analisis, YOLOv8, StrongSORT, Pelacakan Pemain, Evaluasi kinerja

ABSTRACT

Smart Football: Implementation of Re-Identification for Consistent Player ID Assignment in Football Matches

By

Riandra Diva Auzan

NIM: 18221077

Recording football player performance in Indonesia is still frequently done manually and subjectively, resulting in inconsistent data and inaccurate evaluations. This research develops a video analysis system capable of consistently assigning unique identities (IDs) to each player throughout a match, even under occlusion or when players move in and out of the frame. The system integrates an object detection method using YOLOv8, multi-object tracking with StrongSORT, and a Re-Identification algorithm based on Multi-Task Learning, incorporating body part-based features, triplet loss, and focal loss to improve identification reliability within bounding box images. Evaluations conducted using the Soccernet dataset demonstrate that the system effectively reduces ID-switch cases and enhances tracking accuracy, especially for players without jersey numbers. Implementing this system not only enhances the accuracy of automated individual statistical recording but also opens opportunities for more objective, measurable, and data-driven performance evaluations in youth football academies.

Keywords: Re-Identification, Football, Video Analysis, YOLOv8, StrongSORT, Player Tracking, Performance Evaluation

KATA PENGANTAR

Puji dan syukur dipanjatkan kepada Allah Subhanahu wa Ta'ala karena hanya dengan rahmat, kasih sayang, rezeki, izin, serta hidayah-Nya penulis dapat menyelesaikan Tugas Akhir yang berjudul “Smart Football : Penerapan Re-Identification untuk Konsistensi Pemberian ID pada Setiap Pemain Sepak Bola” Dalam penyelesaian tugas akhir ini, penulis juga ingin mengucapkan terima kasih pada keluarga, teman, rekan, dan pihak-pihak lainnya yang terus selalu membantu penyelesaian topik tugas akhir yang serupa. Penulis dengan berbagai macam bentuk dukungan dan bantuan. Ucapan terima kasih yang lebih ingin penulis sampaikan kepada:

1. Bapak Prof. Dr. Ir. Suhono Harso Supangkat, M.Eng., selaku Dosen Pembimbing penulis yang memberikan bimbingan dan saran sehingga penulis dapat menyelesaikan tugas akhir.
2. Bapak Deden Permana, selaku ayah dari penulis yang terus memberikan ilmu dan pelajaran dalam berbagai aspek kehidupan semasa kecil, sehingga penulis memiliki semangat untuk menyelesaikan tugas akhir.
3. Ibu Enen Juhaeni Fatimah, selaku ibu dari penulis yang terus memberikan doa dan *support*. Serta tiada habisnya untuk terus mengingatkan ibadah dan berbuat kebaikan.
4. Rahman Satya dan Muhammad Fajri, sebagai sahabat dan pendamping penulis yang selalu ada dan terus mendukung penulis untuk menyelesaikan penulisan Tugas Akhir ini.
5. Steve Immanuel H., Zachrandika Alif, dan Thomas , sebagai pendahulu dari Smart Football yang membantu penulis dalam mengarahkan dan memberikan saran terkait keberlanjutan dalam penyelesaian tugas akhir penulis.

Dalam penulisan laporan ini, penulis menyadari bahwa terdapat berbagai kekurangan mulai dari penulisan hingga konten yang dibahas di laporan. Untuk itu, penulis mengucapkan permintaan maaf dan juga akan dengan terbuka menerima kritik dan saran yang diberikan. Pada akhirnya, semoga laporan ini

DAFTAR ISI

ABSTRAK.....	3
KATA PENGANTAR.....	4
DAFTAR ISI.....	5
DAFTAR GAMBAR.....	7
DAFTAR TABEL.....	8
DAFTAR ISTILAH.....	9
DAFTAR LAMPIRAN.....	10
BAB I	1
PENDAHULUAN.....	1
I.1 Latar Belakang.....	1
I.2 Rumusan Masalah.....	5
I.3 Tujuan.....	5
I.4 Batasan Masalah.....	6
I.5 Metodologi.....	7
I.6 Sistematika Pembahasan.....	8
BAB II.....	10
STUDI LITERATUR.....	10
II.1 Teknologi Video Analisis.....	10
II.1.1 Object Detection YOLO.....	12
II.2 Konsep Re-Identification.....	19
II.2.1 Body Part-Based Re-Identification.....	21
II.2.2 Ekstraktor Fitur.....	25
II.2.3 Triplet Network.....	27
II.2.4 Role Classification.....	29
BAB III.....	32
ANALISIS MASALAH.....	32
III.1 Analisis Kondisi.....	32
III.2 Analisis Kebutuhan.....	35
III.2.1 Identifikasi Masalah Pengguna.....	35
III.2.2 Kebutuhan Fungsional.....	36
III.2.3 Kebutuhan Non Fungsional.....	38
III.3 Analisis Pemilihan Solusi.....	40
III.3.1 Alternatif Solusi.....	40
III.3.2 Analisis Penentuan Solusi.....	42
BAB IV.....	46
DESAIN SOLUSI.....	46

IV.1 Rancangan Desain Solusi.....	46
IV.1.1 Pipeline Proses Re-Identifikasi Permainan Sepak Bola.....	48
IV.1.2 Pengumpulan dan Persiapan Dataset.....	49
IV.1.3 Pengembangan Model Re-Identification.....	50
IV.1.3.1 Model Re-Identification.....	51
IV.1.3.2 Integrate Learning.....	53
IV.2 Hasil Desain Solusi.....	54
IV.2.1 Akuisisi Data.....	54
IV.2.1.1 SoccerNet Gamestate Dataset.....	55
IV.2.2 Pelatihan Model Re-Identification.....	56
IV.2.2.1 Arsitektur Model.....	56
IV.2.2.2 Pengaturan Model.....	59
IV.2.2.3 Pemrosesan Re-Identifikasi Objek.....	61
IV.2.3 Penerapan Model pada Tracking.....	63
BAB V.....	68
EVALUASI.....	68
V.1 Uji Model Re-Identifikasi dan Uji Integrasi.....	68
V.1.1 Konfigurasi Sistem.....	68
V.1.2 Pengujian Re-Identification.....	70
V.2 Hasil Evaluasi.....	72
V.2.1 Model Re-Identification.....	72
V.2.2 kinerja Tracking.....	75
BAB VI.....	76
KESIMPULAN DAN SARAN.....	76
VII.1 Kesimpulan.....	76
VII.2 Saran.....	77
DAFTAR PUSTAKA.....	78

DAFTAR GAMBAR

Gambar I.1 Peringkat penggemar bola pada Negara Asia Tahun 2022 (Nielsen Company 2022).....	1
Gambar I.2 Ranking Indonesia berdasarkan FIFA (FIFA Men's Ranking 2024)....	2
Gambar II.1 The architecture of neural network design (Redmon dkk. 2016).....	13
Gambar II.2 Perbandingan linear motion dan non-linear motion (Luo dkk. 2022)...	15
Gambar II.3 Perbandingan antara DeepSORT dan StrongSORT (Du dkk. 2023).	17
Gambar II.4 Overview konsep dasar body part-based re-identification (Somers, Vleeschouwer, dan Alahi 2023).....	22
Gambar II.5 Arsitektur sistem dan training prosedur Body Part-Based (Somers, Vleeschouwer, dan Alahi 2023).....	23
Gambar II.6 Empat tahap jaringan resolusi tinggi HRnet (Wang dkk. 2020).....	26
Gambar II.7 High-to-Low dan Low-to-High framework HRNet (Sun dkk. 2020)...	27
Gambar II.8 Struktur triplet network (Hoffer dan Ailon 2015).....	28
Gambar III.1 Sistem Evaluasi Setiap Pemain di SSB Bandung Saat Ini.....	33
Gambar IV.1 Diagram alir proses pembuatan model re-identification.....	48
Gambar IV.2 Pipeline Proses Re-Identifikasi Pada Video Sepak Bola.....	48
Gambar IV.3 Skema Pembagian Dataset.....	49
Gambar IV.4 FlowChart Penerapan Masking dan pemisahan Data Query-Gallery...	50
Gambar IV.5 Diagram alir proses pelatihan model Re-Identification.....	52
Gambar IV.6 Diagram alir proses evaluasi model Re-Identification.....	52
Gambar IV.7 Diagram alir uji integrasi model Re-Identification dengan MOT....	53
Gambar IV.8 Dataset SoccerNet SN-Gamestate.....	55
Gambar IV.9 Arsitektur Model Re-Identification.....	57
Gambar IV.10 Ilustrasi Pencocokan Identitas Pemain.....	62
Gambar IV.11 Hasil Gambar Re-Identifikasi Body Part-Based.....	63
Gambar IV.12 Embedding Model Multi-Task Re-Identification dan StrongSORT...	64

DAFTAR TABEL

Tabel III.1 Kebutuhan Fungsional Sistem Berdasarkan Pengguna.....	37
Tabel III.2 Kebutuhan Non Fungsional Sistem.....	39
Tabel III.3 Kriteria dan Bobot Penilaian Alternatif Solusi.....	43
Tabel III.4 Perhitungan AHP untuk Pemilihan Alternatif Solusi.....	44
Tabel IV.1 Dataset SN-Gamestate Soccernet.....	56
Tabel IV.2 Loss Functions Dalam Pelatihan Model Re-Identification.....	58
Tabel IV.3 Pengaturan Pelatihan Model.....	59
Tabel IV.4 Pengaturan Model yang Divariasikan.....	60
Tabel IV.5 Label Dataset Training Model.....	61
Tabel IV.6 Pengaturan StrongSORT.....	65
Tabel IV.7 Hasil Integrasi Model dan Tracker.....	66
Tabel V.1 Perangkat Lunak Implementasi.....	69
Tabel V.2 Spesifikasi Server.....	69
Tabel V.3 Metrik Evaluasi Model Re-Identification.....	70
Tabel V.4 Metrik Evaluasi kinerja Tracking.....	71
Tabel V.5 Hasil Evaluasi Model Tuning Pooling dan Dim Reduce.....	73
Tabel V.6 Hasil Evaluasi Model Tuning Pembobotan.....	73
Tabel V.7 Hasil Evaluasi Model Re-Identification.....	74
Tabel V.8 Hasil Evaluasi kinerja Tracking.....	75

DAFTAR RUMUS

Rumus II.1 Pembaruan Representasi Fitur Objek pada Frame ke-t.....	18
Rumus II.2 Prediksi Kondisi Objek dengan Model Transisi.....	18
Rumus II.3 Koreksi Prediksi dengan Filter Kalman.....	18
Rumus II.4 Fungsi Biaya Gabungan Penampilan dan Gerak Objek.....	19
Rumus II.5 Ekstraksi Fitur Spasial Menggunakan Masker dan Bobot.....	24

DAFTAR ISTILAH

Singkatan	Uraian	Halaman pertama pemakaian kata
FIFA	Fédération Internationale de Football Association	1
YOLO	You Only Look Once – Metode deteksi objek berbasis deep learning	10
ID	Identitas objek	3
MOT	Multi-Object Tracking – Pelacakan beberapa objek secara simultan	10
SORT	Simple Online and Realtime Tracking	14
DeepSORT	Deep Simple Online and Realtime Tracking	16
StrongSORT	Versi pengembangan dari DeepSORT yang menambahkan fitur re-identifikasi	16
ReID	Re-Identification – Pengenalan ulang individu secara visual	3
CNN	Convolutional Neural Network	12
EMA	Exponential Moving Average – Digunakan dalam update fitur adaptif	17
IoU	Intersection over Union – Metode evaluasi tumpang tindih bounding box	14
GAP	Global Average Pooling	24
GWAP	Global Weighted Average Pooling	24
Bbox	Kotak persegi panjang yang membungkus objek pada gambar atau video untuk menunjukkan lokasi dan ukuran objek tersebut.	56

DAFTAR LAMPIRAN


Lampiran A. Repositori GitHub Re-Identification	85
Lampiran B. Artefak Model Hasil Pelatihan dan Video hasil Pemrosesan	85
Lampiran C. Dokumentasi Wawancara Terkait Kebutuhan Pengguna	85

BAB I

PENDAHULUAN

I.1 Latar Belakang

Sepak bola merupakan olahraga yang memiliki daya tarik kuat di seluruh dunia, Kompetisi piala dunia FIFA menempati peringkat kedua sebagai acara olahraga terpopuler setelah Summer Olympic Games (Deloitte 2022), termasuk di Indonesia. Dengan basis penggemar yang besar, secara persentase dengan jumlah penduduknya Indonesia menempati peringkat ketiga sebagai penggemar bola terbesar di Asia, hanya di bawah Vietnam dan UAE (Nielsen Company 2022).



Gambar I.1 Peringkat penggemar bola pada Negara Asia Tahun 2022 (Nielsen Company 2022)

Tingginya antusiasme masyarakat Indonesia terlihat dari banyaknya warga negara Indonesia yang datang untuk menyaksikan pertandingan, baik secara langsung maupun melalui siaran televisi dan media digital pada ajang Acara Piala Dunia yang diselenggarakan oleh FIFA pada tahun 2022 di Qatar (Ipsos 2022), Hal ini menjadikan sepak bola sebagai sektor olahraga dengan pasar yang besar di Indonesia, dengan potensi besar baik dari sisi industri maupun prestasi. Dalam beberapa tahun terakhir, industri sepak bola di Indonesia telah mengalami kemajuan signifikan. Dalam kurun waktu empat tahun, peringkat Indonesia di FIFA meningkat dari posisi 173 pada tahun 2020 menjadi posisi 125 pada Desember 2024 (Mardanih 2024). Kemajuan ini didorong oleh meningkatnya

investasi dari sektor swasta dan pemerintah dalam bidang olahraga juga penambahan pemain naturalisasi pada tim nasional sepakbola Indonesia (Rauf 2024).

122	↑ 9		Niger	1145.96	1114.73	+31.23	W W	▼
123	↑ 1		Estonia	1142.53	1145.52	-2.99	L D	▼
124	↑ 2		Rwanda	1136.06	1130.04	+6.02	W L W L	▼
125	↑ 5		Indonesia	1135.11	1118.87	+16.24	D D	▼
126	↑ 2		The Gambia	1134.69	1125.62	+9.07	W L	▼
127	↓ 2		India	1133.62	1133.78	-0.16	D	▼
128	↓ 8		Congo	1132.65	1159.42	-26.77	L L	▼

Gambar I.2 Ranking Indonesia berdasarkan FIFA (FIFA Men's Ranking 2024)

Selain itu, pemerintah Indonesia juga mencanangkan target besar untuk membawa peringkat Tim Nasional Indonesia ke posisi 100 besar peringkat FIFA sebagai bagian dari program pengembangan sepak bola nasional (Asad Arifin 2024).

Namun, meskipun potensi besar dan dukungan penuh dari masyarakat, kualitas sepak bola Indonesia masih menghadapi berbagai tantangan. Peringkat Tim Nasional Indonesia di FIFA masih berada di bawah negara-negara tetangga seperti Vietnam dan Thailand. Pada tahun 2024 di bulan Desember, Indonesia menempati peringkat 125 dari 211 negara (FIFA 2024). Berbagai kendala dihadapi oleh sepak bola Indonesia, antara lain kurangnya infrastruktur pendukung seperti stadion yang kurang memenuhi standar internasional, keterbatasan sistem pencatatan statistik pemain, dan minimnya penerapan teknologi modern dalam pertandingan sepak bola domestik. Infrastruktur yang terbatas membuat klub-klub Indonesia sulit bersaing dengan liga-liga besar dunia seperti UEFA (Liga Eropa). Salah satu penyebabnya adalah minimnya penerapan teknologi modern dalam sepak bola Indonesia, seperti penggunaan teknologi VAR dan Catapult yang sejauh ini hanya tersedia di Liga 1 (Wahyu Pratama, 2023). Selain itu, perbandingan teknologi yang diterapkan di Indonesia dengan standar FIFA sangatlah jauh. Banyak teknologi yang digunakan FIFA dan UEFA yang belum diterapkan di Indonesia, seperti Electronic kinerjance Tracking System (EPTS), Goal-Line Technology,

dan Semi-Automated Offside. Teknologi ini berperan penting dalam meningkatkan akurasi dan efisiensi pertandingan (Rifki Wuda Sudirman, 2022).

Di sisi lain, perkembangan teknologi dalam beberapa dekade terakhir membawa perubahan besar dalam industri olahraga, khususnya sepak bola. Teknologi digital, khususnya kecerdasan buatan (AI) dan *computer vision*, kini mulai banyak digunakan dalam analisis kinerja pemain, strategi tim, dan deteksi pola permainan dalam pertandingan (Gisma University 2024). Salah satu teknologi yang kini banyak digunakan dalam liga-liga besar di Eropa dan Amerika adalah sistem analisis video berbasis deep learning seperti Veo dan Fotmob. Sistem ini memungkinkan pelatih dan tim untuk mendapatkan data statistik yang akurat tentang setiap pemain, seperti *shot map*, 2D radar, *heatmap*, dan statistik permainan sehingga dapat membantu proses evaluasi dan perencanaan strategi dengan lebih baik. Namun, teknologi ini belum banyak diterapkan di Indonesia, terutama karena biaya yang mahal dan kebutuhan akan infrastruktur pendukung yang belum memadai.

Seiring dengan pentingnya statistik pemain dalam evaluasi kinerja, sistem analisis video berbasis deep learning menjadi solusi yang relevan untuk mengatasi keterbatasan dalam pencatatan statistik di lapangan. Sistem ini menggunakan metode deteksi dan pelacakan objek untuk mengenali pemain, bola, dan elemen lain dalam pertandingan. Namun, tidak cukup hanya dengan mendeteksi objek; setiap pemain juga perlu diberikan ID unik yang konsisten sepanjang pertandingan agar statistik per individu dapat diperoleh secara akurat. Dengan ID unik ini, pelatih dapat memantau statistik setiap pemain, seperti jarak tempuh, jumlah umpan yang sukses, dan kontribusi lainnya dalam pertandingan.

Menurut penelitian yang dilakukan oleh (Syahreza 2023) terkait penerapan deteksi objek dalam sepak bola, model seperti YOLOv8 dapat dimanfaatkan melalui pelatihan ulang (transfer learning) menggunakan *dataset* gambar yang sesuai. Hal ini memungkinkan pendeteksian objek dalam permainan sepak bola, seperti pemain, penjaga gawang, wasit, dan bola. Selain itu, alat pelacakan seperti ByteTrack dapat digunakan untuk melacak objek yang terdeteksi, sehingga objek tersebut dapat dikenali sebagai entitas yang sama saat bergerak, akan tetapi model

tersebut tidak dapat memberikan ID unik pada setiap objek. Permasalahan terletak pada objek yang keluar masuk frame dan masih banyaknya *occlusion* pada model ini. Untuk memberikan ID unik pada setiap pemain dan mengurangi *occlusion*, teknologi *re-identification* (ReID) diperkenalkan. ReID merupakan teknologi yang bertujuan untuk memberikan ID unik kepada setiap identitas yang sama (Bian dkk. 2023), dalam hal ini pemain, agar tetap dapat dikenali dan dilacak meskipun pemain tersebut berpindah posisi atau keluar-masuk frame kamera. Teknologi ini penting untuk mencegah kesalahan identifikasi yang sering terjadi dalam sistem analisis video ketika pemain bertukar posisi atau melakukan kontak fisik. Metode ini menggabungkan beberapa teknologi computer vision seperti deteksi objek menggunakan YOLO (You Only Look Once) dan pelacakan menggunakan StrongSORT yang telah terbukti efektif dalam mendeteksi objek dengan akurasi tinggi dan melacak pergerakan objek secara real-time.

Implementasi *Re-identification* diharapkan dapat mengatasi masalah *occlusion* dan memberikan ID (identitas) unik pada setiap pemain agar sistem dapat mencatat statistik setiap pemain dengan akurat. Dengan sistem analisis berbasis video yang memberikan ID unik pada setiap pemainnya, data statistik setiap pemain dapat diperoleh secara otomatis dan akurat, sehingga mengurangi ketergantungan pada pencatatan manual yang rentan terhadap kesalahan. Dengan adanya teknologi ini, klub-klub di Indonesia dapat lebih kompetitif di kancah internasional, dan prestasi Tim Nasional Indonesia pun dapat didorong menuju target 100 besar peringkat FIFA.

Selain memberikan manfaat dalam evaluasi dan perencanaan strategi, penerapan teknologi *re-identification* juga memiliki potensi jangka panjang untuk pengembangan sistem pencarian dan manajemen bakat. Data statistik yang konsisten dan akurat dapat digunakan untuk mengidentifikasi bakat-bakat muda potensial dan mengukur kinerja pemain secara objektif. Dengan demikian, diharapkan teknologi ini dapat membantu mempercepat proses pengembangan pemain muda di Indonesia dan menjadikan sepak bola Indonesia lebih kompetitif di tingkat global.

Lebih jauh lagi, pengembangan sistem analisis statistik pemain berbasis AI ini tidak hanya relevan untuk memenuhi kebutuhan tim sepak bola, tetapi juga menawarkan nilai tambah yang signifikan bagi industri sepak bola secara keseluruhan. Transformasi digital yang didorong oleh penggunaan AI diharapkan mampu meningkatkan kualitas evaluasi kinerja pemain, memfasilitasi pengambilan keputusan yang lebih akurat, serta membuka peluang baru dalam penyajian data sepak bola kepada berbagai pemangku kepentingan, termasuk penggemar, pelatih, dan klub. Dengan demikian, teknologi ini berpotensi menjadi pendorong kemajuan bagi sepak bola Indonesia, baik di tingkat lokal maupun internasional (shaputrabisnis 2024).

I.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, berikut adalah rumusan masalah dari tugas akhir ini.

1. Bagaimana cara memberikan ID (Identitas) pada setiap pemain dengan meminimalkan kemungkinan terjadinya ID (Identitas) switch selama analisis video berlangsung, khususnya bagi pemain yang tidak terdapat nomor punggung?
2. Bagaimana cara mengimplementasikan algoritma *Re-Identification* yang mampu melacak pemain sepak bola secara konsisten dan akurat dalam kondisi pertandingan yang dinamis dengan meningkatkan ketahanan (*robustness*) pelacakannya?
3. Bagaimana sistem *Re-Identification* dapat mengatasi kesalahan identifikasi yang terjadi akibat pemain keluar-masuk dalam jangkauan kamera atau bagian tubuh pemain yang terhalang oleh pemain lainnya?

I.3 Tujuan

Berdasarkan latar belakang yang telah dijelaskan, berikut adalah rumusan masalah dari tugas akhir ini.

1. Mengembangkan dan menerapkan algoritma *Re-Identification* yang dapat melakukan pelacakan pemain sepak bola secara konsisten dan akurat dalam berbagai situasi pertandingan yang dinamis khususnya bagi pemain yang tidak memiliki nomor punggung.
2. Mengidentifikasi solusi untuk mengurangi kesalahan identifikasi pemain akibat pertukaran posisi atau pergerakan pemain yang keluar-masuk dalam jangkauan kamera.
3. Menyediakan sistem *re-identification* pada analisis video dengan identifikasi yang lebih akurat berbasis bagian tubuh.

I.4 Batasan Masalah

Berikut adalah batasan-batasan yang berlaku untuk penelitian Tugas Akhir ini.

1. Penelitian ini akan mengembangkan algoritma *Re-Identification* berbasis bagian tubuh, afiliasi tim, dan klasifikasi peran untuk meningkatkan akurasi pelacakan pemain sepak bola dalam rekaman video pertandingan atau latihan, serta memberikan konsistensi ID kepada setiap pemain, khususnya bagi pemain yang tidak memiliki nomor punggung.
2. Video pertandingan sepak bola yang digunakan untuk analisis merupakan video pertandingan dengan sudut pandang 1 kamera pada kamera utama, tanpa menyertakan tayangan ulang atau angle close-up.
3. Pengembangan hanya berfokus pada peningkatan sistem pemberian ID yang lebih konsisten tanpa memfokuskan pada deteksi aksi atau kejadian spesifik (misalnya pelanggaran atau gol).
4. Objek yang diidentifikasi ulang dalam video hanya meliputi pemain, tetapi tidak mencakup referee, penonton, pelatih, atau objek lain di sekitar lapangan.
5. Sistem *Re-Identification* yang dikembangkan akan diuji menggunakan data dari hasil video dengan resolusi standar yang umum digunakan dalam pertandingan sepak bola, serta dari sudut pandang 1 kamera lapangan yang

statis. Penggunaan kamera dengan sudut pandang berbeda atau drone tidak termasuk dalam cakupan penelitian.

I.5 Metodologi

Metodologi yang digunakan dalam pengembangan fitur *Re-identification* pemain ini mengikuti metode *developmental research* (Ibrahim 2016), dengan pendekatan kuantitatif dan eksperimental. Metode ini bertujuan untuk merancang, mengembangkan, dan mengevaluasi fitur baru dalam sistem *Re-identification* pemain untuk analisis video pertandingan sepak bola. Pendekatan kuantitatif dan eksperimental dipilih karena penelitian ini melibatkan pengukuran dan analisis data numerik, seperti pengujian akurasi sistem, kinerja algoritma, serta evaluasi hasil secara eksperimental. Tahapan pengembangan dalam penelitian ini meliputi:

1. Analisis Masalah

Penelitian dimulai dengan tahap analisis masalah, bertujuan untuk mengidentifikasi permasalahan dalam *Re-identification* pemain serta merumuskan tujuan penelitian.

2. Persiapan Data

Tahap ini mencakup pengumpulan, pemahaman, dan pemrosesan data agar sesuai dengan format yang dibutuhkan untuk proses analisis dan pengujian lebih lanjut.

3. Perancangan Solusi

Pada tahap ini, solusi diterapkan untuk memecahkan masalah *Re-identification* yang dihadapi, dengan membuat desain dan rencana implementasi sistem.

4. Implementasi Solusi

Implementasi solusi ini mencakup penerapan rencana yang telah disusun dalam tahap perancangan, menghasilkan artefak sesuai dengan desain dan perancangan sistem *Re-identification* pemain.

5. Evaluasi

Tahap akhir adalah evaluasi, bertujuan untuk mengukur kinerja dari fitur *Re-identification* yang dikembangkan dan memastikan hasil sesuai dengan yang diharapkan.

I.6 Sistematika Pembahasan

Berikut merupakan sistematika penulisan tugas akhir yang terbagi ke dalam 5 bab.

1. Bab I Pendahuluan

Bab ini menguraikan latar belakang penelitian, yang mencakup alasan pemilihan topik serta pentingnya penelitian ini dalam konteks pengembangan teknologi *re-identification* dalam sepak bola. Selain itu, bab ini juga menyajikan rumusan masalah, tujuan penelitian, batasan masalah, dan metodologi. Rumusan masalah menjabarkan pertanyaan penelitian yang akan dijawab, tujuan menguraikan hasil yang ingin dicapai, batasan masalah memperjelas ruang lingkup penelitian, dan metodologi menjelaskan pendekatan yang digunakan dalam penyelesaian masalah.

2. Bab II Studi Literatur

Bab ini berisi kajian literatur terkait teori dan penelitian terdahulu yang mendukung penelitian ini. Studi literatur mencakup konsep-konsep utama seperti deteksi objek, pelacakan pemain dalam pertandingan sepak bola, algoritma *Re-Identification*, serta teknologi dan teknik yang relevan dalam analisis video olahraga. Literatur yang diacu meliputi buku, jurnal, dan penelitian sebelumnya yang relevan dengan penelitian ini.

3. Bab III Analisis Masalah

Pada bab ini dilakukan analisis terhadap kondisi dan tantangan nyata dalam mengimplementasikan sistem *re-identification* pada video pertandingan sepak bola. Dibahas pula kebutuhan sistem, baik fungsional maupun non-fungsional, serta dilakukan analisis terhadap alternatif solusi yang ada hingga dipilih rancangan solusi terbaik untuk mengatasi masalah ID switching dan menjaga konsistensi identitas pemain khususnya bagi pemain yang tidak memiliki nomor punggung.

4. Bab IV Desain Solusi

Bab ini menjelaskan tahapan-tahapan dalam merancang solusi berdasarkan hasil analisis pada bab sebelumnya. Termasuk di dalamnya perancangan

arsitektur sistem, strategi pencegahan ID switching, dan mekanisme pelacakan pemain dalam berbagai skenario pertandingan

5. Bab V Evaluasi

Bab ini berisi penjelasan tentang cara melakukan evaluasi terhadap sistem yang telah dikembangkan, mulai dari konfigurasi sistem, skenario pengujian, hingga metode evaluasi. Hasil evaluasi yang diperoleh dianalisis untuk mengukur efektivitas, keakuratan, dan keandalan solusi yang diimplementasikan, disertai dengan diskusi atas hasil tersebut.

6. Bab V Kesimpulan dan Saran

Bab terakhir ini merangkum hasil penelitian, menjawab rumusan masalah, serta menilai apakah tujuan penelitian tercapai. Selain itu, bab ini memberikan saran untuk pengembangan lebih lanjut dalam penelitian *re-identification*, mencakup rekomendasi untuk peningkatan akurasi pelacakan dan efektivitas sistem dalam kondisi pertandingan yang lebih kompleks.

BAB II

STUDI LITERATUR

II.1 Teknologi Video Analisis

Teknologi analisis video merupakan salah satu implementasi dari bidang Computer Vision (CV), yang bertujuan untuk memungkinkan komputer memahami dan menafsirkan informasi visual dari data gambar dan video secara otomatis. Dengan kemajuan dalam pembelajaran mendalam, analisis video kini mampu mengolah data visual secara efisien untuk berbagai aplikasi seperti pengawasan video, kendaraan otonom, dan pengenalan pola (Zhang dkk. 2024).

Tahap pertama dalam analisis video biasanya melibatkan deteksi objek untuk mengenali dan mengklasifikasi objek yang muncul dalam frame video. Teknik modern seperti YOLO (You Only Look Once) telah mengubah paradigma deteksi dengan menyatukan seluruh pipeline ke dalam satu jaringan neural yang melakukan regresi langsung dari gambar ke koordinat bounding box dan probabilitas kelas. YOLO bekerja dengan membagi gambar menjadi grid dan memprediksi beberapa bounding box sekaligus, memungkinkan deteksi waktu nyata dengan kecepatan hingga 45 frame per detik (Redmon dkk. 2016). Teknologi ini telah menjadi landasan dalam aplikasi analisis video karena efisiensinya yang tinggi dibandingkan metode sebelumnya seperti R-CNN atau Fast R-CNN yang memerlukan langkah-langkah terpisah untuk deteksi dan klasifikasi (Redmon dkk. 2016).

Setelah objek terdeteksi, tahap berikutnya dalam analisis video adalah pelacakan multi-objek (Multi-Object Tracking/MOT). MOT berfokus pada penghubungan identitas objek yang sama di berbagai frame video, memungkinkan pelacakan lintasan objek secara kontinu. Salah satu pendekatan populer adalah SORT (Simple Online and Real-Time Tracking), yang menggunakan kombinasi Kalman Filter untuk memprediksi pergerakan objek dan algoritma Hungarian untuk

mengasosiasikan deteksi pada frame saat ini dengan lintasan sebelumnya. SORT menonjol karena kesederhanaan dan kecepatannya, mampu memproses hingga 260 frame per detik, meskipun memiliki keterbatasan dalam menangani kasus *occlusion* yang kompleks (Bewley dkk. 2016).

Selain deteksi dan pelacakan, analisis video sering kali mencakup segmentasi gambar, yang membagi frame video menjadi wilayah-wilayah bermakna seperti objek dan latar belakang. Teknologi seperti Fully Convolutional Networks (FCN) memanfaatkan jaringan saraf untuk melakukan prediksi segmentasi secara end-to-end pada level piksel. Teknik ini sangat berguna dalam aplikasi seperti analisis medis dan pengawasan berbasis kamera, ketika detail tingkat tinggi diperlukan untuk interpretasi adegan (Wu dkk. 2024).

Teknologi deteksi objek dan pelacakan objek dalam analisis video seringkali menghadapi tantangan serius ketika hanya mengandalkan dua komponen tersebut tanpa memasukkan mekanisme *Re-Identification* (ReID). Dalam skenario seperti *occlusion* (ketika objek tertutup sebagian atau sepenuhnya) atau pergerakan objek keluar dari bidang pandang kamera, sistem tanpa ReID cenderung gagal mempertahankan ID yang konsisten. Akibatnya, ID baru sering kali dihasilkan untuk objek yang sama, yang mengakibatkan ketidakkonsistenan dalam pelacakan lintasan dan analisis lebih lanjut.

Re-Identification menjadi solusi penting untuk mengatasi tantangan ini, terutama karena kemampuannya untuk mengenali dan menghubungkan kembali objek yang sama di berbagai frame bahkan setelah gangguan seperti *occlusion*. Namun, seperti yang disebutkan dalam literatur, banyak pendekatan ReID hanya berfokus pada tugas tunggal tanpa mengintegrasikan fungsi lainnya seperti klasifikasi peran, atau afiliasi tim. Hal ini ditegaskan dalam penelitian terbaru yang menyatakan bahwa meskipun telah terjadi kemajuan substansial dalam metode analisis olahraga, sebagian besar metode pelacakan saat ini tidak menangani semua tugas ini secara bersamaan (Mansourian dkk. 2023). Sebaliknya, memecahkan setiap tugas secara individu seringkali mengabaikan tujuan bersama yang dimiliki ketiga tugas ini untuk merepresentasikan individu dengan akurasi tinggi, sehingga melewatkan potensi pendekatan terpadu.


Sebagai contoh, dalam sistem pelacakan olahraga, ReID tradisional dilatih dengan label identitas individu tetapi sering kali gagal mengenali afiliasi tim secara efektif. Hal ini disebabkan oleh atribut visual serupa antar pemain, seperti warna kulit, yang dapat menyebabkan model lebih mengelompokkan pemain berdasarkan kemiripan visual daripada afiliasi tim. Untuk mengatasi kekurangan ini, penelitian seperti *multitask learning* memperkenalkan pendekatan pembelajaran multi-tugas yang tidak hanya fokus pada ReID tetapi juga mengintegrasikan klasifikasi afiliasi tim dan peran menggunakan kerangka kerja bersama dengan melakukan *combine loss*. Dengan demikian, model ini menghasilkan representasi fitur yang lebih kaya dan lebih diskriminatif, serta lebih efisien dalam memori dan kecepatan karena menggunakan backbone tunggal.

Pendekatan multi-tugas ini menunjukkan bahwa integrasi beberapa tujuan selama pelatihan tidak hanya meningkatkan kinerja pada tugas individu tetapi juga memberikan manfaat sinergis, yang sangat relevan untuk aplikasi pelacakan dan analisis visual olahraga secara keseluruhan.

II.1.1 Object Detection YOLO

YOLO (You Only Look Once) adalah sebuah metode deteksi objek berbasis deep learning yang mendefinisikan tugas deteksi sebagai masalah regresi tunggal. Pendekatan ini memungkinkan YOLO memproses gambar secara menyeluruh dalam satu evaluasi jaringan, menghasilkan bounding box dan probabilitas kelas secara langsung, berbeda dengan metode tradisional seperti R-CNN yang menggunakan pipeline bertahap. YOLO membagi gambar input menjadi grid $S \times S$. Setiap sel bertanggung jawab untuk mendeteksi objek jika pusat objek berada di dalam sel tersebut. Setiap sel memprediksi beberapa bounding box yang mencakup koordinat x dan y (lokasi), w dan h (dimensi), serta skor kepercayaan yang menggambarkan kemungkinan keberadaan objek. Adapun rumus dasar dari *confidence score* adalah $\text{Pr}(\text{Object}) * \dots$, sehingga ketika tidak ada objek pada sebuah sel, *confidence score*-nya akan bernilai nol (Redmon dkk. 2016).

YOLO memanfaatkan arsitektur convolutional neural network (CNN) yang menggabungkan fitur spasial dan konteks global dalam gambar, menjadikannya cepat, sederhana, dan akurat.



Gambar II.1 The architecture of neural network design (Redmon dkk. 2016)

Seiring perkembangannya, YOLO telah mengalami beberapa iterasi, dimulai dari YOLOv1 hingga YOLOv8. Setiap iterasi membawa peningkatan yang signifikan, dan YOLOv8 muncul sebagai versi terbaik hingga saat ini. Salah satu peningkatan utama pada YOLOv8 adalah penggunaan arsitektur yang lebih ringan dan efisien, yang memungkinkan kecepatan inferensi lebih tinggi sambil tetap mempertahankan, bahkan meningkatkan, akurasi deteksi. YOLOv8 menggunakan backbone serupa dengan YOLOv5, tetapi dengan perubahan pada CSP Layer, yang kini digantikan oleh modul C2f (cross-stage partial bottleneck with two convolutions). Modul ini menggabungkan fitur-fitur tingkat tinggi dengan informasi kontekstual, sehingga meningkatkan akurasi deteksi (Terven dan Cordova-Esparza 2024).

Selain itu, YOLOv8 memperkenalkan arsitektur *anchor-free*, yang menyederhanakan proses deteksi. Pada YOLO versi sebelumnya (seperti YOLOv5), anchor box digunakan untuk memprediksi bounding box berdasarkan ukuran dan skala yang telah ditentukan, yang membutuhkan pengaturan manual untuk memastikan kesesuaian dengan data. Sebaliknya, YOLOv8 memprediksi koordinat bounding box langsung tanpa bergantung pada anchor box, melainkan

menggunakan koordinat absolut dan keypoints objek dalam grid sel. Pendekatan ini tidak hanya meningkatkan efisiensi pelatihan tetapi juga memperluas kemampuan model dalam menghadapi objek dengan ukuran dan bentuk yang beragam.

Evaluasi pada *dataset* MS COCO test-dev 2017 menunjukkan bahwa YOLOv8x mencapai Average Precision (AP) sebesar 53.9% pada ukuran gambar 640 piksel, meningkat dari 50.7% yang dicapai oleh YOLOv5 pada input yang sama. Keunggulan ini dicapai dengan kecepatan hingga 280 FPS pada NVIDIA A100 menggunakan TensorRT, menjadikannya sangat efisien untuk aplikasi real-time (Terven dan Cordova-Esparza 2024).


Keunggulan YOLOv8 dibandingkan YOLOv5 atau versi lainnya terletak pada fleksibilitas dan efisiensinya. Model ini tidak hanya lebih cepat dan lebih akurat, tetapi juga lebih mudah diadaptasi untuk berbagai kasus penggunaan. Peningkatan signifikan dalam mAP (mean Average Precision) membuktikan bahwa YOLOv8 memberikan kinerja terbaik dalam deteksi objek, baik di lingkungan laboratorium maupun dalam aplikasi dunia nyata. Hal ini menjadikan YOLOv8 sebagai pilihan utama untuk kebutuhan deteksi objek.

II.1.2 Multi Object Tracking

Multi-Object Tracking (MOT) adalah bidang penelitian dalam visi komputer yang berfokus pada pelacakan beberapa objek secara simultan dalam urutan gambar atau video. Tidak seperti Single Object Tracking (SOT) yang hanya berfokus pada pelacakan satu objek tunggal, MOT menghadapi tantangan unik seperti penanganan identitas banyak objek, *occlusion*, dan perubahan tampilan objek seiring waktu (Jyothi dkk. 2024).

Dalam pengembangannya, berbagai teknik dan algoritma telah dirancang untuk mengatasi tantangan MOT, termasuk metode berbasis filter, metode berbasis data asosiasi, dan metode berbasis pembelajaran mesin. Metode berbasis filter, seperti Kalman Filter, digunakan untuk memprediksi posisi objek pada frame berikutnya dengan menggunakan model gerakan linier yang sederhana. Prediksi ini

membantu mengatasi kasus hilangnya deteksi karena *occlusion* sementara atau ketidakakuratan detektor. Particle Filter, meskipun lebih kompleks, menawarkan fleksibilitas yang lebih besar dalam memodelkan pergerakan non-linier objek (Luo dkk. 2022).



Gambar II.2 Perbandingan *linear motion* dan *non-linear motion* (Luo dkk. 2022)

Metode berbasis data asosiasi berfokus pada pencocokan antara deteksi baru dengan objek yang telah dilacak. Algoritma seperti Hungarian dan Jonker-Volgenant sering digunakan untuk memecahkan masalah pencocokan ini dengan cara mengoptimalkan matriks biaya berbasis jarak atau kesamaan, seperti Intersection over Union (IoU). Pendekatan ini memainkan peran penting dalam mempertahankan konsistensi identitas objek di seluruh frame video (Bewley dkk. 2016).

Sementara itu, metode berbasis pembelajaran mesin telah merevolusi MOT dengan mengintegrasikan deteksi dan pelacakan menggunakan teknik pembelajaran mendalam. Model seperti ByteTrack, DeepSORT, BoTSORT, dan StrongSORT memanfaatkan representasi fitur mendalam untuk meningkatkan akurasi pelacakan, terutama dalam kondisi dengan *occlusion* yang kompleks atau perubahan signifikan dalam penampilan objek. Metode ini sering menggunakan arsitektur jaringan saraf untuk mempelajari fitur visual yang kaya, yang digunakan untuk asosiasi data dan re-identifikasi objek.

Pendekatan gabungan yang mengintegrasikan beberapa pembelajaran *deep learning* juga semakin populer. Contohnya, sistem berbasis *Re-Identification* (Re-ID) menggabungkan model deteksi dengan kemampuan untuk mengenali kembali objek yang hilang atau terhalang. Model semacam ini bekerja dengan menggunakan fitur visual seperti tekstur, warna, atau bentuk untuk menyambung kembali trajektori objek yang sempat terputus (Cho dan Kim 2023).

II.1.2.1 StrongSORT


Pendekatan yang dominan dalam sistem pelacakan multi-objek (MOT) adalah paradigma *track-by-detection*, ketika objek dideteksi pada setiap frame dan kemudian diasosiasikan antar-frame. Contoh awal pendekatan ini adalah SORT (Simple Online and Realtime Tracking), yang menggabungkan model gerakan Kalman filter dengan kriteria Intersection over Union (IoU) untuk asosiasi objek (Bewley dkk. 2016). Dalam pengembangan SORT, DeepSORT memperkenalkan integrasi fitur penampilan bersama dengan pelacakan berbasis gerakan yang secara signifikan meningkatkan keandalan pelacakan dalam skenario dengan oklusi dan tumpang tindih objek yang sering terjadi (Wojke, Bewley, dan Paulus 2017).

Kemajuan terbaru, seperti OC-SORT, lebih lanjut memperluas kemampuan SORT dengan menangani gerakan non-linear melalui model berbasis observasi (Cao dkk. 2023). Pendekatan lain, seperti CBIOU, memanfaatkan metode buffered IoU untuk meningkatkan penyelarasan kotak pembatas (bounding box) dan memperbaiki asosiasi objek (Yang dkk. 2023). Selain itu, munculnya pelacak berbasis re-identifikasi, seperti StrongSORT, menandai pergeseran menuju ekstraksi fitur penampilan yang lebih diskriminatif untuk meningkatkan re-identifikasi objek, memungkinkan akurasi yang lebih tinggi dalam tugas pelacakan jangka panjang (Du dkk. 2023).

Dalam pekerjaan ini, StrongSORT telah diadopsi dan ditingkatkan lebih lanjut. Untuk meningkatkan proses re-identifikasi, embedding penampilan telah diganti dengan fitur berbasis bagian tubuh (part-based features), sehingga sistem menjadi

lebih tangguh terhadap oklusi dan skenario kompleks. Selain itu, langkah pasca-pemrosesan baru telah diperkenalkan untuk menggabungkan *tracklet* pendek dengan fitur berbasis bagian yang serupa, secara signifikan meningkatkan kinerja pelacakan dalam kasus deteksi yang terfragmentasi (Du dkk. 2023). Kemajuan ini menunjukkan meningkatnya kecanggihan dalam sistem MOT, terutama untuk lingkungan yang menantang seperti analitik video olahraga.

StrongSORT adalah pengembangan dari DeepSORT yang meningkatkan kemampuan Multi-Object Tracking (MOT) melalui kombinasi algoritma yang berbeda pada ekstraksi fitur penampikan dan perubahan pada *feature bank* dengan algoritma Exponential Moving Average (EMA) untuk mengurangi *noise* dari deteksi (Du dkk. 2023).



Gambar II.3 Perbandingan antara DeepSORT dan StrongSORT (Du dkk. 2023)

Framework ini terdiri dari dua cabang utama, yaitu penampikan dan gerakan. Pada StrongSORT untuk cabang penampikan menggunakan ekstraktor fitur BoT (*Bag of Tricks*) berbasis ResNet50 untuk menghasilkan vektor penampikan yang diperbarui secara adaptif melalui *Exponential Moving Average (EMA)*, dirumuskan sebagai

$$e_t^i = \alpha e_{t-1}^i + (1 - \alpha) f_t^i \quad (\text{II.1})$$

- e_t^i : Vektor penampilan tracklet ke-i pada frame ke-t.
- f_t^i : Embedding deteksi baru.
- α : Koefisien momentum.

Selain itu, StrongSORT menggunakan Kalman Filter untuk memprediksi posisi objek dengan dua tahap, yaitu prediksi status dan *update* status.

$$\hat{x}'_k = F_k \hat{x}_{k-1} \quad (\text{II.2})$$

$$x_k = \hat{x}'_k + K(z_k - H_k \hat{x}'_k) \quad (\text{II.3})$$

- $\hat{x}'_k$: Prediksi Status
- $\hat{x}_k$: Vektor status yang diperbarui
- F_k : Matriks transisi keadaan.
- K : Gain kalman.
- H_k : Matriks pengamatan.
- z_k : Pengamatan baru.

Setelah dilakukan Vanilla Matching untuk mengatasi masalah asosiasi pendek (*missing association*), StrongSORT memperkenalkan *Appearance-Free Link (AFLink)* yang hanya menggunakan informasi spasial-temporal untuk menentukan hubungan antar-tracklet. Sementara itu, masalah kehilangan deteksi (*missing detection*) diatasi melalui algoritma interpolasi berbasis Gaussian Smoothed Interpolation (GSI), yang memanfaatkan regresi Gaussian untuk menghasilkan posisi interpolasi yang lebih akurat. Kompensasi gerakan kamera juga dilakukan menggunakan model Enhanced Correlation Coefficient (ECC) untuk mengoreksi rotasi dan translasi antar-frame. Selain itu, pembaruan Kalman Filter dilakukan

secara adaptif dengan kovarians kebisingan R'_k yang dihitung berdasarkan skor kepercayaan deteksi (Du dkk. 2023).

StrongSORT memanfaatkan pendekatan *matching cascade* berbasis algoritma Hungarian untuk proses asosiasi, biaya dihitung sebagai kombinasi jarak penampilan dan gerakan.

$$Cost = \lambda_1 A_{appearance} + (1 - \lambda) A_{motion} \quad (II.4)$$

Dengan kemampuan menangani gerakan non-linear, fitur penampilan adaptif, dan efisiensi komputasi, StrongSORT menjadi solusi unggul untuk pelacakan objek, khususnya dalam sistem *Re-Identification* yang membutuhkan pelacakan akurat pada video olahraga dengan tantangan seperti *occlusion* dan kemiripan antar objek (Du dkk. 2023).

II.2 Konsep *Re-Identification*

Person *Re-Identification* (ReID) adalah salah satu tugas dalam bidang computer vision yang bertujuan untuk mencocokkan gambar individu tertentu dari satu set data (*query*) dengan gambar dari basis data besar (*gallery*). Dalam konteks ini, ReID sering digunakan untuk melacak dan mengidentifikasi individu di berbagai sudut pandang kamera atau dalam kondisi lingkungan yang berbeda (Ye dkk. 2022). Dalam lingkungan olahraga, tantangan ReID menjadi semakin kompleks karena keberadaan gerakan dinamis, interaksi antar pemain, serta elemen visual yang sering kali mengaburkan tubuh pemain, seperti bola, peralatan olahraga, atau bahkan pemain lain (Zandycke dkk. 2022 ; Giancola dkk. 2022).

Secara teknis, salah satu tantangan terbesar dalam ReID adalah masalah obstruksi dan interferensi, ketika sebagian tubuh individu tertutup oleh objek lain. Hal ini menyebabkan hilangnya informasi kritis pada gambar, yang dapat mengurangi akurasi model ReID berbasis representasi global. Selain itu, kebutuhan untuk membandingkan bagian tubuh yang relevan dalam kondisi yang berbeda menjadi tantangan penting lainnya (Peng dkk. 2021). Untuk mengatasi masalah ini, pendekatan berbasis bagian tubuh (*part-based*) telah muncul sebagai solusi.

Metode ini memanfaatkan peta perhatian (attention maps) yang mampu mengidentifikasi bagian tubuh tertentu, seperti kepala, torso, atau kaki, meskipun sebagian tubuh terhalang (Zhu dkk. 2020). Model seperti Body Part-Based *Re-Identification* menggunakan modul perhatian berbasis bagian tubuh yang dilatih dengan pengawasan ganda, yaitu label identitas dan informasi semantik manusia yang diperoleh dari parsing kasar tubuh (Zhu dkk. 2020).

Selain itu, metode pelatihan seperti GiLt (Global-identity Local-triplet) telah diperkenalkan untuk melatih fitur lokal yang lebih diskriminatif. GiLt dirancang untuk menangani kemunculan atribut lokal yang tidak diskriminatif, seperti warna jersey yang serupa antar pemain dari tim yang berbeda, sambil tetap menjaga keunikan dalam representasi fitur gabungan. Strategi ini memungkinkan model untuk belajar fitur lokal yang robust terhadap penghalang dan variasi tampilan (Zhu dkk. 2020).

Pendekatan tradisional pada ReID menggunakan representasi global untuk setiap individu, tetapi metode ini memiliki keterbatasan dalam mengatasi masalah seperti obstruksi atau perbandingan antar bagian tubuh yang relevan. Oleh karena itu, pendekatan berbasis bagian tubuh (part-based) semakin banyak digunakan karena mampu menangkap fitur lokal yang lebih spesifik (Zhu dkk. 2020). Dalam konteks olahraga, beberapa atribut unik dapat dimanfaatkan untuk meningkatkan akurasi ReID, seperti afiliasi tim (Istasse, Moreau, dan Vleeschouwer 2019), peran pemain (Koshkina, Pidaparthi, dan Elder 2021), dan nomor jersey (Liu dan Bhanu 2019). Misalnya, dengan menggunakan nomor jersey sebagai fitur identifikasi, jaringan pembelajaran dapat dilatih untuk menghasilkan embedding yang memisahkan pemain dari tim yang berbeda. Selain itu, pemanfaatan peran pemain dan interaksi antar anggota tim dapat membantu dalam pengenalan pola unik yang relevan untuk identifikasi.

Untuk menghadapi variasi pose dan domain, beberapa model mengintegrasikan estimasi pose dalam arsitektur end-to-end, seperti yang dilakukan pada metode pose-guided ReID. Pendekatan ini memungkinkan identifikasi bagian tubuh yang relevan meskipun posisi pemain tidak simetris atau sebagian besar tubuh tertutup (Gao dkk. 2020). Namun, pendekatan ini memerlukan perhatian terhadap


overhead komputasi yang signifikan karena memerlukan cabang jaringan tambahan.

Dengan berkembangnya pendekatan berbasis bagian tubuh dan teknologi pelatihan yang lebih adaptif, ReID tidak hanya menjadi alat yang andal untuk pengawasan video tetapi juga untuk memahami dinamika permainan olahraga secara real-time. Dalam olahraga seperti sepak bola atau hoki es, ReID membantu mengenali pemain untuk analisis statistik, pelacakan kinerja, hingga integrasi ke dalam sistem manajemen tim untuk mendukung strategi permainan.

II.2.1 Body Part-Based *Re-Identification*

Body Part-Based *Re-Identification* (ReID) adalah cabang dari tugas person retrieval yang bertujuan untuk mencocokkan citra individu yang menjadi query dengan citra individu lain dalam galeri besar. Fokus utamanya adalah pada situasi saat sebagian tubuh subjek mengalami oklusi, sehingga membuat metode ReID global jadi kurang efektif. Dalam konteks ini, ReID berbasis bagian tubuh bertujuan untuk membangun representasi fitur lokal untuk setiap bagian tubuh, seperti kepala, torso, tangan, kaki, dan lainnya, sehingga memungkinkan pencocokan bagian tubuh yang terlihat antara dua citra meskipun salah satu bagian tubuh terhalang oleh objek lainnya (Zhu dkk. 2020).

ReID secara umum dirumuskan sebagai masalah pembelajaran representasi untuk menjawab tantangan *occlusion* karena gambar individu sering kali mengalami berbagai gangguan, termasuk interferensi dari objek atau pejalan kaki, kotak pembatas yang tidak akurat, variasi pose, perubahan pencahayaan, kualitas gambar yang buruk, dan oklusi dari objek jalan atau individu lain (Somers, Vleeschouwer, dan Alahi 2023).




Gambar II.4 Overview konsep dasar body part-based *re-identification* (Somers, Vleeschouwer, dan Alahi 2023)

Model *Body Part-Based Re-Identification* mengintegrasikan dua modul utama yang dirancang untuk menangani tantangan spesifik dalam tugas ReID berbasis bagian tubuh, yaitu *body part attention module* dan *global-local representation module*. Modul *body part attention* sendiri bertugas memprediksi *attention maps* untuk berbagai bagian tubuh seperti kepala, tangan, torso, dan kaki. Dengan memanfaatkan pendekatan *dual supervision*, modul ini dilatih menggunakan label identitas untuk mencocokkan individu serta label parsing tubuh manusia untuk mengidentifikasi bagian-bagian tubuh dengan lebih akurat. Pendekatan ini mengatasi kendala pada *dataset* ReID yang umumnya tidak menyediakan anotasi bagian tubuh yang rinci (Somers, Vleeschouwer, dan Alahi 2023). Sebagai hasilnya, modul ini dapat menghasilkan *attention maps* yang tidak hanya relevan untuk tugas ReID, tetapi juga lebih tahan terhadap *noise* dari latar belakang atau gangguan lainnya. *Attention maps* ini memastikan bahwa fitur lokal yang relevan dari setiap bagian tubuh dapat diekstraksi dan digunakan untuk representasi individu.

Selain itu, *Global-Local Representation Module*, Modul ini bertujuan untuk menggabungkan informasi global dan lokal secara optimal. Fitur holistik mewakili gambaran keseluruhan dari individu, sedangkan fitur berbasis bagian tubuh menangkap detail granular dari bagian tubuh tertentu. Modul ini

menggunakan teknik pooling yang dirancang khusus, seperti Global Weighted Average Pooling (GWAP), Global Average Pooling (GAP), dan Global Max Pooling (GMP) untuk mengekstrak fitur lokal dari *attention maps* yang dihasilkan. Selain itu, modul ini juga dilengkapi dengan mekanisme estimasi visibilitas untuk menentukan bagian tubuh mana yang terlihat dan layak dibandingkan selama proses inferensi. Hal ini penting untuk menangani kasus oklusi, ketika hanya bagian tubuh yang terlihat di kedua gambar yang relevan untuk dibandingkan (Somers, Vleeschouwer, dan Alahi 2023).



Gambar II.5 Arsitektur sistem dan training prosedur Body Part-Based (Somers, Vleeschouwer, dan Alahi 2023)

Pada *body part attention module*, proses untuk menghasilkan *attention maps* melibatkan *pixel-wise part classifier*. Modul ini bertugas mengklasifikasikan setiap piksel pada peta fitur menjadi salah satu bagian tubuh atau latar belakang. Tujuan utama dari proses ini adalah membagi gambar menjadi segmen-segmen yang secara lokal mewakili bagian tubuh, sehingga perhatian model dapat difokuskan hanya pada bagian tubuh yang relevan untuk tugas *ReID*. Dengan pendekatan ini, model dapat menghindari gangguan dari latar belakang atau bagian tubuh yang tidak terlihat. Dalam konteks ini, setiap piksel pada peta fitur dianalisis untuk menentukan bagian tubuh mana yang diwakilinya. Dalam konteks ini, setiap piksel pada peta fitur $G \in \mathbb{R}^{H \times W \times C}$ diproses oleh konvolusi 1×1 untuk

menghasilkan peta probabilitas bagian tubuh M yang memiliki rumus $M = \text{softmax}(GP^T)$, P merupakan parameter konvolusi yang dipelajari. Probabilitas $M_k(h, w)$ mengindikasikan seberapa besar piksel (h, w) termasuk ke bagian tubuh k (Somers, Vleeschouwer, dan Alahi 2023).

Selain itu, dilakukan *human parsing label* agar modul ini dapat dilatih, diperlukan label yang menjelaskan mana piksel yang termasuk ke bagian tubuh tertentu untuk mendeskripsikan lokasi bagian tubuh, seperti kepala, torso, tangan, dan kaki. Label ini dihasilkan menggunakan model parsing manusia (misalnya PifPaf) (Kreiss, Bertoni, dan Alahi 2019). Informasi ini digunakan sebagai dasar untuk melatih model agar dapat mengenali bagian tubuh dengan lebih baik dalam gambar baru, bahkan jika bagian tersebut mengalami oklusi sebagian.

Setelah modul menghasilkan prediksi peta perhatian, diperlukan fungsi loss untuk melatih modul ini agar dapat memprediksi bagian tubuh dengan akurasi tinggi. Fungsi loss menggunakan *cross-entropy* dengan smoothing label. Fungsi loss ini memastikan model dapat belajar dari ketidaksempurnaan data pelatihan, seperti kesalahan anotasi atau noise. Dengan smoothing label, model dapat lebih fleksibel dalam menentukan keputusan yang penting untuk oklusi dan kualitas gambar yang buruk.


Setelah *attention maps* dihasilkan, langkah berikutnya adalah menggabungkan informasi lokal (berbasis bagian tubuh) dan global (berbasis keseluruhan tubuh) yang menjadi bagian dari *global-local representation learning module* untuk membangun representasi yang robust. Modul ini juga memperhitungkan visibilitas bagian tubuh untuk mengatasi oklusi. Fitur holistik menangkap informasi menyeluruh tentang individu, sedangkan fitur berbasis bagian tubuh fokus pada detail lokal. Fitur lokal ini membantu dalam mencocokkan bagian tubuh yang terlihat antara dua gambar, sedangkan fitur holistik memberikan konteks global. Fitur bagian tubuh dengan rumus seperti berikut.

$$f_i = \frac{\sum_{h,w} G(h,w) M_i(h,w)}{\sum_{h,w} M_i(h,w)} \quad (\text{II.5})$$

M_i adalah peta perhatian untuk bagian tubuh ke- i . Fitur holistik f_g diperoleh melalui Global Average Pooling (GAP) (Somers, Vleeschouwer, dan Alahi 2023). Dalam BPBreID, terdapat aspek penting yang perlu diperhatikan, terutama untuk menangani oklusi yaitu *body part visibility estimation*. Mengingat bahwa tidak semua bagian tubuh terlihat pada setiap gambar, sangat penting untuk menentukan visibilitas masing-masing bagian tubuh sebelum fitur tersebut digunakan untuk proses pencocokan. Visibilitas dihitung berdasarkan intensitas pada peta perhatian. Jika nilai maksimum pada M_i melebihi ambang batas ($\lambda_v = 0.4$), bagian tubuh tersebut dianggap terlihat. Skor visibilitas v_i kemudian digunakan untuk memastikan bahwa hanya bagian tubuh yang terlihat yang akan dibandingkan selama proses inferensi (Somers, Vleeschouwer, dan Alahi 2023).

II.2.2 Ekstraktor Fitur


HRNet (High-Resolution Network) adalah arsitektur jaringan konvolusi yang dirancang untuk menangani berbagai tugas pengenalan visual, seperti estimasi pose manusia, segmentasi semantik, deteksi objek, dan re-identifikasi. Salah satu keunggulan utama HRNet adalah kemampuannya untuk mempertahankan representasi resolusi tinggi sepanjang proses, tanpa memerlukan pemulihan dari representasi resolusi rendah. HRNet menghubungkan jaringan resolusi tinggi-ke-rendah secara paralel dan melakukan fusi multi-resolusi berulang untuk menghasilkan representasi spasial yang lebih kaya dan semantik yang lebih kuat. Berbeda dengan jaringan tradisional seperti ResNet atau VGGNet, yang menurunkan resolusi secara bertahap, HRNet mempertahankan detail penting sepanjang proses. Pendekatan ini telah menunjukkan keunggulan pada tugas-tugas yang sensitif terhadap posisi, seperti estimasi pose manusia, segmentasi semantik, dan deteksi objek (Wang dkk. 2020).



Gambar II.6 Empat tahap jaringan resolusi tinggi HRnet (Wang dkk. 2020)

Arsitektur empat stage HRNet juga merupakan fitur unik yang membedakannya dari pendekatan tradisional. Pada stage pertama, HRNet memulai dengan sub-jaringan resolusi tinggi sederhana. Kemudian, pada setiap stage berikutnya, sub-jaringan baru ditambahkan dengan resolusi yang lebih rendah, dihubungkan secara paralel dengan sub-jaringan sebelumnya. Sebagai hasilnya, HRNet secara bertahap membangun representasi multi-resolusi yang saling terhubung. Setiap stage terdiri dari blok-blok residual yang menggabungkan konvolusi pada berbagai resolusi, memungkinkan pertukaran informasi antar-sub-jaringan di dalam dan antar-stage. Pada akhir proses, HRNet menggabungkan semua resolusi menjadi satu representasi akhir untuk menghasilkan output yang akurat (Wang dkk. 2020).

Pendekatan HRNet ini memungkinkan jaringan untuk menghasilkan representasi yang kaya secara semantik dan presisi secara spasial menghasilkan *heatmap* yang lebih akurat dan spasial yang lebih presisi dalam estimasi pose manusia. Arsitektur HRNet mengintegrasikan subnetwork resolusi High-to-Low yang terhubung secara paralel, memungkinkan pertukaran informasi berulang di antara subnetwork multi-resolusi (*multi-scale fusion*). Arah horizontal dan vertikal pada arsitektur ini masing-masing mewakili kedalaman jaringan dan skala *feature maps*. Fusi secara paralel dan berulang pada HRNet terbukti lebih efektif untuk menghasilkan peta panas yang akurat (Sun dkk., 2019 ; Newell, Yang, dan Deng, 2016).



Gambar II.7 High-to-Low dan Low-to-High framework HRNet (Sun dkk. 2020)


HRNet memperbaiki pendekatan konvensional seperti Stacked Hourglass Networks dan Cascaded Pyramid Networks yang masing-masing memiliki keterbatasan dalam mempertahankan informasi spasial dan integrasi multi-skala. Dalam Stacked Hourglass, fusi multi-skala dilakukan secara progresif, tetapi resolusi tinggi harus dipulihkan melalui lapisan tambahan, yang sering kali menyebabkan kehilangan detail. HRNet mengatasi masalah ini dengan mempertahankan resolusi tinggi sepanjang proses, memungkinkan prediksi yang lebih presisi, terutama dalam skenario yang kompleks seperti *occlusion* atau pose *non-standar* (Wang dkk. 2020).

Selain itu, HRNet melampaui Multi-Scale Structure-Aware Network dalam menangkap struktur spasial multi-skala. Dengan fusi multi-skala berulang, HRNet mampu lebih baik memanfaatkan hubungan spasial antara keypoint, menghasilkan peningkatan akurasi signifikan dalam tugas estimasi pose manusia multi-orang (Ke dkk., 2018). Dalam eksperimen menggunakan *dataset* MPII Human Pose, HRNet-W32 mencatat tingkat akurasi PCKh@0.5 sebesar 92.3%, yang melampaui pendekatan lain seperti metode berbasis fitur hierarkis (Sun dkk., 2019).

II.2.3 Triplet Network

Triplet Network adalah arsitektur deep learning yang dirancang untuk mempelajari representasi metrik berbasis jarak melalui pembelajaran triplet. Model ini terdiri dari tiga jaringan feedforward yang identik dengan parameter

yang dibagikan. Setiap jaringan menerima input berupa sampel anchor x , sampel positif x^+ (dari kelas yang sama), dan sampel negatif x^- (dari kelas berbeda). Output jaringan berupa jarak berbasis L2 antara representasi x dan masing-masing sampel lainnya. Tujuan dari pelatihan ini adalah meminimalkan jarak antara x dan x^+ sambil memaksimalkan jarak antara x dan x^- (Hoffer dan Ailon 2015).



Gambar II.8 Struktur triplet network (Hoffer dan Ailon 2015)

Pendekatan *Team Affiliation* dalam konteks *Re-Identification* telah dieksplorasi melalui beberapa pendekatan yang menarik. Hoffer dan Ailon (2015) memperkenalkan metode Triplet Network, yang bertujuan untuk mempelajari representasi jarak melalui pembelajaran triplet. Dengan membandingkan tiga sampel (satu anchor, satu positif, dan satu negatif), metode ini berhasil menghasilkan representasi berbasis jarak yang lebih kuat dibandingkan dengan pendekatan seperti Siamese Networks. Representasi ini cocok untuk memisahkan tim berdasarkan afiliasi mereka, memungkinkan margin yang lebih jelas dalam membedakan kelas-kelas yang relevan. Selain itu, metode ini menunjukkan potensi untuk digunakan dalam sistem *unsupervised learning*, menjadikannya

relevan untuk aplikasi dengan data berlabel terbatas tersedia (Hoffer dan Ailon, 2015).

Pendekatan ini memungkinkan model untuk belajar membedakan kelas-kelas berdasarkan hubungan jarak dalam ruang embedding, tanpa memerlukan label eksplisit untuk setiap sampel. Dengan memanfaatkan fungsi loss triplet, yaitu perbedaan jarak yang dikontrol oleh margin tertentu, model dapat memastikan bahwa representasi dari sampel-sampel dalam kelas yang sama tetap dekat satu sama lain, sementara sampel dari kelas yang berbeda dipisahkan dengan jarak yang lebih besar (Hoffer dan Ailon, 2015).

Dalam implementasinya, jaringan ini sering menggunakan arsitektur berbasis CNN (Convolutional Neural Network) untuk mengekstrak fitur visual dari data input, seperti warna, tekstur, atau pola. Misalnya, dalam konteks Team Affiliation, warna dan pola seragam dapat digunakan sebagai fitur utama untuk membedakan tim yang berbeda. Representasi visual ini kemudian dipetakan ke ruang embedding. Tim yang berbeda akan membentuk kluster-kluster terpisah yang memungkinkan pengelompokan tim berdasarkan afiliasi (Vat dkk. 2015).

Pendekatan berbasis pembelajaran temporal juga telah diterapkan oleh Vats dkk. (2021) dalam penelitian mereka tentang pelacakan dan identifikasi pemain hoki. Mereka mengembangkan sistem holistik yang mencakup pelacakan pemain, identifikasi tim berdasarkan warna seragam, dan identifikasi pemain melalui nomor jersey menggunakan CNN berbasis 1D temporal convolutional network. Dengan mengintegrasikan data roster dari pertandingan, sistem ini mencapai akurasi identifikasi pemain hingga 83%, dan metode pelacakan serta identifikasi tim memungkinkan pengelompokan yang akurat berdasarkan afiliasi. Sistem ini tidak hanya berguna untuk pelacakan pemain tetapi juga dapat digunakan untuk analisis strategi permainan berbasis tim (Vats dkk., 2021).

II.2.4 Role Classification

Focal Loss, yang diperkenalkan oleh (Lin dkk.2017), adalah fungsi kerugian yang dirancang untuk mengatasi ketidakseimbangan kelas dalam tugas deteksi objek.

Focal Loss menambahkan faktor modulasi pada cross-entropy loss standar dengan rumus. $(1 - p_t)^\gamma$, dengan keterangan p_t adalah probabilitas model terhadap kelas target, sedangkan γ adalah parameter yang mengontrol tingkat fokus pada contoh sulit. Fungsi Focal Loss dirumuskan $FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t)$, dengan $-\alpha_t$ adalah faktor penyeimbang untuk kelas minoritas dan mayoritas. Faktor $(1 - p_t)^\gamma$ memungkinkan model untuk secara dinamis mengurangi bobot pada contoh mudah dan lebih fokus pada contoh sulit. Hal ini sangat berguna dalam skenario yang terdapat dominasi kelas negatif atau latar belakang yang signifikan, seperti pada deteksi objek padat (Lin dkk. 2017).

Dalam konteks Person Re-Identification (Re-ID), tantangan utama adalah variasi penampilan individu dan ketidakseimbangan data, ketika beberapa identitas mungkin memiliki lebih banyak sampel daripada yang lain. Penerapan Focal Loss dalam ReID dapat membantu model untuk lebih memperhatikan sampel yang sulit dan identitas dengan representasi data yang lebih sedikit, sehingga meningkatkan akurasi identifikasi. Liu dkk. (2022) mengusulkan Adversarial Focal Loss yang memodifikasi Focal Loss dengan menambahkan jaringan adversarial untuk menghitung skor kesulitan s_i bagi setiap sampel. Rumus ini memungkinkan model untuk memprioritaskan pembelajaran pada contoh sulit bahkan tanpa adanya classifier eksplisit dengan s_i menunjukkan tingkat kesulitan dari contoh tertentu. Pendekatan ini terbukti efektif dalam meningkatkan metode deteksi keypoint dan kemampuan untuk menimbang ulang contoh berdasarkan tingkat kesulitan (Liu dkk. 2022).

Selain itu, (Huang dkk.2022) mengintegrasikan Focal Tversky Loss, varian dari Focal Loss, ke dalam baseline AGW untuk person re-identification. Focal Tversky Loss menggunakan pendekatan yang serupa dengan Focal Loss tetapi lebih disesuaikan untuk menangani ketidakseimbangan data pada tugas segmen dan identifikasi. Fungsi ini bertujuan untuk memfasilitasi model dalam mempelajari contoh-contoh sulit secara lebih efektif, yang pada akhirnya meningkatkan akurasi keseluruhan dalam tugas Re-ID. Dengan demikian, adaptasi

Focal Loss dan variannya dalam domain ReID menunjukkan potensi besar dalam meningkatkan kinerja model, terutama dalam menghadapi tantangan ketidakseimbangan data dan variasi penampilan individu (Huang dkk. 2022)

BAB III


ANALISIS MASALAH

III.1 Analisis Kondisi

Sistem pembinaan dan evaluasi pemain sepak bola di Sekolah Sepak Bola (SSB) di Indonesia, khususnya di wilayah Bandung, masih bersifat konvensional dan belum terstandarisasi. Berdasarkan hasil observasi dan wawancara dengan dua SSB, yaitu SSB UNI Bandung dan SSB Mandala Ganesha ITB (MG ITB), ditemukan bahwa proses identifikasi dan penilaian pemain dilakukan secara manual oleh pelatih melalui observasi langsung selama sesi latihan atau pertandingan. SSB UNI Bandung, sebagai salah satu SSB tertua dan terbesar di kota ini, serta SSB Mandala Ganesha ITB yang dikelola oleh sivitas akademika kampus ITB, memiliki sistem pencatatan dan evaluasi yang serupa, yaitu bersifat naratif, tidak terdokumentasi secara sistematis, dan sangat bergantung pada ingatan dan intuisi pelatih. Hal ini menyebabkan sulitnya melakukan evaluasi longitudinal atas perkembangan pemain dari waktu ke waktu. Minimnya penggunaan teknologi menjadikan proses evaluasi rentan terhadap bias subjektif dan tidak adanya rekam data historis yang dapat ditelusuri kembali.

Temuan dari wawancara dan observasi di lapangan menggambarkan pola umum sistem pembinaan dan evaluasi yang diterapkan di SSB UNI dan SSB Mandala Ganesha ITB. Meskipun keduanya memiliki karakteristik manajemen yang berbeda, SSB UNI dengan pengalaman panjang dalam membina pemain secara profesional dan SSB Mandala Ganesha ITB yang lebih bernuansa edukatif, keduanya masih mengandalkan pendekatan konvensional dalam mendokumentasikan perkembangan pemain. Proses evaluasi biasanya dilakukan secara lisan atau melalui catatan sederhana oleh pelatih, tanpa ada sistem digital atau database terpusat yang mampu merekam progres pemain secara berkelanjutan. Hal ini menunjukkan adanya kesenjangan antara praktik di lapangan dan potensi pemanfaatan teknologi dalam sistem pelatihan usia dini. Untuk memberikan gambaran lebih konkret mengenai alur dan komponen utama

yang saat ini berjalan di SSB. Adapun gambaran sistem terkini dari SSB UNI dan Mandala Ganesha ITB, serta komunitas lainnya terdapat pada gambar III.1.



Gambar III.1 Sistem Evaluasi Setiap Pemain di SSB Bandung Saat Ini

Sistem ini terdiri dari beberapa komponen utama:

1. Menjalankan Pertandingan Sepak Bola

Pertandingan dilaksanakan seperti biasa dengan atau tanpa wasit resmi untuk melihat kinerja setiap pemain saat bermain sepak bola secara langsung di luar latihan biasa.

2. Pelatih atau Pemain Melakukan Analisis Secara Manual

Saat pertandingan, pelatih atau staf pelatih akan menonton pertandingan untuk melakukan analisis secara manual untuk mengamati jalannya pertandingan.

3. Penandaan Identitas Pemain Dilakukan Secara Manual

Identitas pemain dikenali berdasarkan pengamatan visual, seperti nomor punggung, tampilan badan, gaya bermain, atau posisi di lapangan. Namun, jika pemain tidak mengenakan jersey bernomor atau sering berpindah posisi, penandaan menjadi tidak akurat. Terlebih lagi terlalu banyak hal yang terjadi di lapangan membuat pelatih seringkali tidak menangkap kejadian secara lengkap

4. Evaluasi kinerja Setiap Pemain Secara Manual

Pelatih mencatat penilaian atau masukan berdasarkan ingatan atau observasi pribadi. Tidak ada format baku atau data statistik objektif yang digunakan. Pencatatan dilakukan di buku catatan atau lembar evaluasi pribadi pelatih.

Berdasarkan hasil wawancara dengan Bapak Sabrun Hanapi, Direktur Teknis SSB UNI Bandung, mengungkapkan bahwa tidak adanya sistem evaluasi yang terstruktur

dan digital menjadi tantangan utama dalam pembinaan pemain. Penilaian masih bersifat subjektif, tanpa standar objektif berbasis data, meskipun SSB UNI memiliki reputasi melahirkan banyak pemain nasional. Hal serupa juga terjadi di SSB Mandala Ganesha ITB, yang meskipun berada dalam lingkungan akademik, masih mengandalkan observasi manual dalam mengevaluasi pemain. Dari hasil observasi dan wawancara tersebut, dapat disimpulkan bahwa sistem pembinaan dan evaluasi pemain di SSB saat ini masih memiliki beberapa masalah utama:

1. Belum tersedia sistem digital berbasis re-identifikasi yang mampu mengenali dan melacak pemain secara individual sepanjang pertandingan, sehingga pelatih kesulitan memperoleh data kinerja yang objektif dan terukur.
2. Tidak adanya integrasi video analisis dengan teknologi pelacakan identitas pemain menyebabkan momen-momen krusial dan aksi spesifik dari masing-masing pemain sulit diidentifikasi secara otomatis.
3. Proses evaluasi kinerja masih mengandalkan pengamatan langsung dan ingatan pelatih, tanpa sistem yang dapat merekam, menyimpan, dan menautkan data aksi ke identitas pemain secara konsisten.
4. Minimnya pemanfaatan statistik berbasis pelacakan individual membuat program latihan dan umpan balik untuk pemain tidak didasarkan pada data akurat hasil pertandingan atau latihan.

Pendekatan *re-identification* ini membuka peluang untuk menciptakan sistem evaluasi pemain yang lebih objektif di lingkungan SSB. Dengan kemampuan untuk mempertahankan identitas pemain secara konsisten sepanjang pertandingan, sistem ini memungkinkan setiap aksi, mulai dari sentuhan bola, pergerakan tanpa bola, dapat dikaitkan langsung dengan individu yang bersangkutan ketika sistem re-identifikasi ini diintegrasikan dengan model untuk mendeteksi aksi bola. Hal ini tidak hanya mendukung proses penilaian yang berbasis bukti (*evidence-based*), tetapi juga memberikan dasar statistik yang kuat dalam penyusunan program latihan dan pengembangan pemain secara personal.

III.2 Analisis Kebutuhan

Setelah dianalisis, sistem pembinaan dan evaluasi pemain di SSB seperti SSB UNI dan SSB MG ITB masih berjalan secara manual, tidak terdigitalisasi, dan sangat bergantung pada intuisi pelatih. Tidak adanya sistem identifikasi yang konsisten serta minimnya dokumentasi kinerja membuat proses evaluasi bersifat subjektif dan sulit ditelusuri kembali. Oleh karena itu, dibutuhkan sistem yang mampu memberikan identitas kepada setiap pemain secara otomatis melalui teknologi *Re-Identification (ReID)* dan juga menaikkan kinerja pelacakan pemain selama pertandingan. Identitas ini akan menjadi dasar untuk mengaitkan setiap aksi dalam pertandingan dengan pemain yang bersangkutan, sehingga memungkinkan evaluasi berbasis data yang objektif dan berkelanjutan. Agar sistem ini relevan dan tepat guna, diperlukan analisis kebutuhan yang mencakup identifikasi masalah pengguna, fitur-fitur yang dibutuhkan, serta spesifikasi kualitas sistem dari sisi kinerja, keamanan, dan kemudahan penggunaan.

III.2.1 Identifikasi Masalah Pengguna

Pengguna utama sistem adalah pelatih, manajemen SSB, dan pemain sepak bola di lingkungan sekolah sepak bola (SSB), khususnya SSB seperti SSB Uni dan SSB MG ITB yang belum menerapkan sistem pelacakan pemain secara otomatis ataupun komunitas lainnya. Berikut adalah permasalahan yang dihadapi oleh masing-masing pengguna:

1. Pelatih
 - a. Kesulitan dalam memberikan evaluasi yang objektif karena tidak ada sistem statistik yang terstruktur.
 - b. Aksi-aksi pemain dalam video tidak dapat dihubungkan dengan identitas pemain, terutama jika pemain tidak memiliki nomor punggung.
 - c. Pelatih kesulitan mengenali pemain yang berpindah posisi atau tertutup oleh pemain lain (*occlusion*), sehingga tidak dapat memantau kinerja secara konsisten.
 - d. Pelatih harus menonton ulang seluruh video secara manual untuk mencari momen penting, yang memakan waktu dan tidak efisien.

2. Manajemen SSB / Manajemen Komunitas

- a. Tidak memiliki dokumentasi statistik kinerja pemain secara terstruktur, sehingga sulit untuk memantau perkembangan pemain secara longitudinal.
- b. Sulit menyusun laporan kinerja atau portofolio pemain karena data identitas dan aksi tidak terdokumentasi otomatis.
- c. Tidak memiliki sistem terpusat yang mampu menyimpan dan melacak data individu pemain dari berbagai pertandingan.

3. Pemain

- a. Tidak mengetahui statistik personal mereka karena tidak ada sistem yang menghubungkan aksi dalam video dengan identitas individu.
- b. Tidak ada visualisasi yang bisa digunakan sebagai bahan evaluasi atau motivasi untuk perkembangan diri.
- c. Pemain dengan posisi fleksibel atau tanpa nomor punggung sering tidak dikenali, sehingga kinerja mereka tidak tercatat atau terabaikan dalam evaluasi.
- d. Sulit dalam menentukan bagian yang perlu dikembangkan secara statistik.

Masalah-masalah di atas menjadi dasar untuk merancang kebutuhan fungsional dan non-fungsional sistem yang mampu memberikan identitas berbasis ReID kepada setiap pemain dari video pertandingan, meskipun pemain tidak memakai nomor punggung atau mengalami *occlusion* dalam frame. Sistem ini juga diharapkan mampu membantu sistem deteksi aksi bola untuk menghubungkan setiap aksi dengan setiap pemain, dengan tujuan mempermudah pelatih dan manajemen dalam proses evaluasi kinerja secara akurat dan efisien.

III.2.2 Kebutuhan Fungsional

Hasil observasi lapangan dan wawancara dengan SSB UNI Bandung serta SSB Mandala Ganesha ITB menunjukkan bahwa proses evaluasi dan pembinaan pemain saat ini masih bersifat manual dan belum memanfaatkan sistem digital. Dari hasil wawancara tersebut, dapat diidentifikasi sejumlah kebutuhan fungsional dari tiga kelompok pengguna utama, yaitu pelatih, manajemen SSB, dan pemain.

Setiap kelompok menghadapi tantangan yang berbeda dalam mengakses, mencatat, dan mengevaluasi kinerja pemain secara konsisten. Oleh karena itu, sistem yang akan dikembangkan perlu dirancang untuk menjawab permasalahan tersebut secara menyeluruh. Tabel III.1 berikut merangkum kebutuhan fungsional dari hasil observasi lapangan dan wawancara SSB UNI Bandung dan SSB Mandala Ganesha.

Tabel III.1 Kebutuhan Fungsional Sistem Berdasarkan Pengguna

Kode	Pengguna	Kebutuhan Fungsional	Deskripsi
F01	Pelatih	Pemberian ID unik otomatis ke setiap pemain	Sistem menggunakan teknologi ReID untuk mengenali dan memberi identitas unik ke tiap pemain di video
F02	Pelatih	Pemantauan dan evaluasi aksi pemain secara individual	Setiap aksi bola dapat dikaitkan dengan pemain yang melakukannya berdasarkan ID dan pelacakannya.
F03	Pelatih	Pencatatan dan anotasi kinerja pemain	Sistem menyediakan fitur anotasi atau komentar untuk evaluasi terhadap kinerja pemain dalam video.
F04	Manajemen SSB	Penyimpanan data statistik pemain	Sistem menyimpan statistik individu pemain per pertandingan untuk keperluan dokumentasi dan seleksi.
F05	Manajemen SSB	Laporan kinerja pemain	Sistem menghasilkan laporan statistik yang dapat diunduh dalam format dokumen atau grafik interaktif.
F06	Pemain	Akses personal terhadap data kinerja	Pemain dapat melihat statistik pribadinya seperti jumlah operan, tembakan, dan waktu bermain.

Sistem ini diharapkan mampu memberikan pengalaman terintegrasi dan efisien untuk seluruh pemangku kepentingan di lingkungan SSB, dari sisi pelatihan hingga evaluasi kinerja, tanpa ketergantungan pada observasi manual yang bersifat subjektif.

III.2.3 Kebutuhan Non Fungsional

Kebutuhan non fungsional menggambarkan aspek teknis dan kualitas sistem yang menentukan bagaimana sistem akan beroperasi dalam praktik. Aspek ini mencakup keandalan, keamanan, efisiensi, skalabilitas, dan kemudahan akses yang secara langsung mempengaruhi pengalaman pengguna serta keberlangsungan sistem dalam jangka panjang. Dalam konteks Sekolah Sepak Bola (SSB), di mana pelatih, manajemen, dan pemain mungkin memiliki keterbatasan teknis, kebutuhan non fungsional menjadi krusial agar sistem dapat berjalan dengan stabil, aman, dan intuitif. Oleh karena itu, untuk memastikan sistem analisis kinerja pemain berbasis video dapat diimplementasikan secara efektif dan digunakan secara optimal oleh seluruh pemangku kepentingan, sejumlah kebutuhan non fungsional berikut harus dipenuhi. Tabel III.2 berikut merangkum kebutuhan non fungsional dari hasil observasi lapangan dan wawancara SSB UNI Bandung dan SSB Mandala Ganesha.

Tabel III.2 Kebutuhan Non Fungsional Sistem

Kode	Kebutuhan Non Fungsional	Deskripsi
NF01	Waktu Respon	Sistem harus mampu menampilkan data statistik dan cuplikan video dengan waktu respon maksimal 5 detik, meskipun digunakan secara bersamaan oleh pelatih, manajemen, dan beberapa pemain. Hal ini penting untuk menjaga efisiensi proses evaluasi dan pelatihan.
NF02	Availability	Sistem harus memiliki tingkat ketersediaan (uptime) minimal 99,5%, terutama pada waktu setelah sesi pertandingan atau latihan, saat pelatih dan manajemen paling sering mengakses sistem untuk evaluasi. Ketidakterjangkauan sistem akan mengganggu alur evaluasi pemain secara signifikan.
NF03	Keamanan	Semua data, termasuk video pertandingan dan statistik kinerja pemain harus dienkripsi menggunakan standar industri (misalnya AES-256). Sistem juga harus mendukung autentikasi dua faktor (2FA) untuk mencegah akses tidak sah. Aktivitas pengguna (akses data, perubahan identitas, atau evaluasi) harus dicatat dalam log audit secara rinci.
NF04	Skalabilitas	Sistem harus dapat menangani peningkatan jumlah pengguna dan pertandingan dari berbagai SSB, baik secara vertikal (scale-up) maupun horizontal (scale-out). Dukungan terhadap infrastruktur berbasis cloud juga diperlukan agar sistem dapat bertumbuh tanpa mengorbankan kinerja.
NF05	Usabilitas	Antarmuka sistem harus intuitif dan mudah digunakan oleh pelatih dan pemain yang mungkin tidak memiliki latar belakang teknis. Akses ke sistem harus tersedia melalui perangkat seluler, tablet, dan desktop. Selain itu, tampilan antarmuka harus memperhatikan prinsip aksesibilitas seperti kontras warna tinggi dan ukuran font yang dapat disesuaikan.

NF06	Fault Tolerance dan Reliability	Sistem harus melakukan pencadangan otomatis setiap 24 jam dan memiliki mekanisme failover. Jika server utama gagal, sistem harus dapat beralih ke server cadangan tanpa menyebabkan downtime yang signifikan agar data tetap aman dan layanan tetap tersedia.
------	---------------------------------	---

Dengan memenuhi kebutuhan nonfungsional ini, sistem akan mampu memberikan layanan yang stabil, aman, efisien, dan efektif untuk mendukung proses identifikasi dan pengembangan pemain sepak bola usia dini secara optimal.

III.3 Analisis Pemilihan Solusi

Dalam mengembangkan sistem analisis sepak bola berbasis video ini membahas sejumlah alternatif solusi khususnya dalam menyelesaikan permasalahan identifikasi otomatis pemain dari video pertandingan, khususnya pemberian ID unik yang konsisten pada pelacakkan sepanjang pertandingan. Setiap pendekatan dianalisis berdasarkan efektivitas solusi berdasarkan masalah, kemudahan implementasi, biaya implementasi, serta kemudahan evaluasi sesuai dengan kondisi SSB seperti SSB UNI dan SSB MG ITB yang sering menghadapi tantangan seperti latihan menggunakan jubah tanpa nomor punggung dan *occlusion*. Pemilihan solusi yang tepat menjadi kunci dalam pengembangan sistem analisis kinerja yang efisien dan relevan bagi kebutuhan pembinaan di SSB. Oleh karena itu, dilakukan analisis komparatif terhadap berbagai pendekatan guna menentukan opsi terbaik.

III.3.1 Alternatif Solusi

Berikut merupakan 4 alternatif solusi yang telah diidentifikasi dari analisis kondisi melalui wawancara bersama SSB UNI Bandung dan SSB Mandala Ganesha ITB dan analisis kebutuhan fungsional dan non fungsional:

1. Penggunaan Jasa Menghitung Statistik Manual

Solusi ini mengandalkan tenaga manusia untuk mengamati video pertandingan dan mencatat statistik secara manual. Keuntungannya adalah

fleksibilitas dan tidak memerlukan teknologi tambahan, namun metode ini tidak efisien dan sangat rentan terhadap kesalahan manusia, terutama jika diterapkan pada skala besar atau dalam waktu panjang.

2. Evaluasi Manual oleh Pelatih Secara Langsung ataupun Melalui Video

Solusi ini mengandalkan observasi langsung atau melalui rekaman video oleh pelatih untuk mengevaluasi kinerja pemain. Meskipun fleksibel dan memungkinkan penilaian mendalam, metode ini subjektif, tidak efisien untuk skala besar, serta sulit dijadikan dasar statistik yang terstruktur.

3. Pengenalan Nomor Punggung (*Jersey Number Recognition*)

Solusi ini menggunakan teknologi *Optical Character Recognition* (OCR) untuk membaca angka pada jersey pemain dari rekaman video. Metode ini relatif mudah diimplementasikan jika semua pemain menggunakan jersey bernomor dan dapat diintegrasikan langsung ke sistem statistik. Namun, akurasi sangat dipengaruhi oleh kualitas video, sudut kamera, dan keberadaan nomor yang jelas pada jersey.

4. *Baseline Tracking* tanpa ReID (Single Video Tracking)

Solusi ini menggunakan algoritma pelacakan seperti SORT atau ByteTrack untuk mendeteksi dan melacak pemain dalam satu video tanpa mempertahankan ID jika terjadi gangguan seperti *occlusion*. Metode ini ringan dan cepat untuk implementasi, namun tidak dapat menjamin konsistensi ID antar frame, apalagi antar video, sehingga kurang tepat untuk statistik jangka panjang.

5. *Tracking* + Lokal ReID

Pendekatan ini menggabungkan *tracking* dan *Re-Identification* (ReID) berbasis ciri visual lokal untuk memastikan ID pemain tetap konsisten di sepanjang video. Solusi ini sangat mendukung kebutuhan statistik jangka panjang dan lintas pertandingan, tetapi membutuhkan pelatihan model dengan *dataset* yang sesuai, serta beban komputasi yang tinggi.

III.3.2 Analisis Penentuan Solusi

Dalam menentukan alternatif solusi yang paling tepat untuk sistem identifikasi pemain berbasis video, digunakan pendekatan kuantitatif menggunakan metode

Analytical Hierarchy Process (AHP). AHP merupakan metode pengambilan keputusan yang dikembangkan oleh Thomas L. Saaty dan digunakan untuk membandingkan beberapa alternatif berdasarkan sejumlah kriteria tertentu secara sistematis. Pendekatan ini membantu dalam memperoleh solusi optimal dengan mempertimbangkan bobot kepentingan dari tiap kriteria yang relevan.

Dalam merancang sistem evaluasi kinerja pemain di SSB, empat kriteria utama ditetapkan melalui hasil diskusi bersama dosen pembimbing serta wawancara dengan pihak terkait dari SSB UNI Bandung dan SSB Mandala Ganesha ITB. Kriteria ini menjadi acuan dalam menilai berbagai alternatif solusi secara objektif dan dirangkum dalam Tabel III.3.

Tabel III.3 Kriteria dan Bobot Penilaian Alternatif Solusi

Kode	Kriteria	Deskripsi	Bobot
K1	Efektivita Solusi	Sejauh mana solusi mampu mengidentifikasi pemain secara akurat dan konsisten dalam berbagai kondisi	0.35

		pertandingan atau latihan.	
K2	Kemudahan Implementasi	Tingkat kemudahan dalam mengimplementasikan dan menjalankan analisis kinerja berdasarkan data yang dihasilkan oleh sistem.	0.15
K3	Biaya Pengembangan & Operasional	Estimasi sumber daya finansial yang dibutuhkan untuk mengembangkan dan mengoperasikan sistem secara optimal.	0.15
K4	Skalabilitas dan Robustness	Kemampuan sistem untuk beradaptasi pada skala penggunaan yang lebih besar dan bertahan terhadap kondisi lingkungan serta data yang bervariasi.	0.15
K5	Sustainability	Kemampuan sistem untuk tetap relevan, dapat dipelihara, dan dikembangkan dalam jangka panjang seiring perkembangan teknologi dan kebutuhan SSB.	0.2

Setelah kriteria dan bobot ditetapkan, setiap alternatif solusi dinilai menggunakan skala 1 hingga 5 untuk masing-masing kriteria, dengan acuan kondisi di lapangan dan masukan dari stakeholder. Nilai tersebut lalu dikalikan dengan bobot masing-masing kriteria untuk memperoleh nilai total dari tiap alternatif. Seluruh hasil evaluasi ini dirangkum dalam Tabel III.4.

Tabel III.4 Perhitungan AHP untuk Pemilihan Alternatif Solusi

Alternatif solusi	K1 (0.35)	K2 (0.15)	K3 (0.15)	K4 (0.15)	K5 (0.2)	Total
-------------------	--------------	--------------	--------------	--------------	-------------	-------

Penggunaan Jasa Penghitung Statistik Manual	3	4	2	1	1	2.4
Evaluasi Manual oleh Pelatih Secara Langsung ataupun Melalui Video	2	5	5	1	1	2.45
Pengenalan Nomor Punggung (Jersey Number Recognition)	3	3	3	2	2	2.65
Baseline Tracking tanpa ReID	3	3	4	3	2	2.95
Tracking + Lokal ReID	4	3	3	4	3	3.40

Berdasarkan hasil evaluasi multi-kriteria pada Tabel III.3, alternatif solusi Tracking + Lokal ReID memperoleh skor total tertinggi sebesar 3.40, mengungguli pendekatan lainnya dalam hal efektivitas identifikasi pemain, skalabilitas sistem, dan relevansi jangka panjang. Meskipun solusi ini memerlukan pengembangan awal yang lebih kompleks dibandingkan metode manual atau berbasis nomor punggung, kemampuannya dalam menjaga konsistensi identitas pemain selama pertandingan membuatnya lebih unggul dalam mendukung analisis kinerja yang akurat dan berkelanjutan.

Dengan demikian, Tracking + Lokal ReID dipilih sebagai pendekatan paling tepat untuk diimplementasikan dalam sistem analisis video pertandingan di SSB. Solusi ini dinilai mampu menjawab kebutuhan pelatih dan manajemen dalam melakukan evaluasi berbasis data yang lebih objektif, sekaligus membuka peluang

pemanfaatan teknologi lanjutan dalam proses pembinaan pemain muda secara lebih efisien dan terstruktur.

BAB IV

DESAIN SOLUSI

IV.1 Rancangan Desain Solusi


Dalam mengatasi tantangan dalam analisis video pertandingan sepak bola, solusi yang diusulkan melibatkan penggunaan pendekatan *multi-task learning* yang mengintegrasikan beberapa komponen kunci, termasuk *body part-based re-identification*, *role classification*, dan *team affiliation*. Pertama, *dataset* pertandingan sepak bola akan dikumpulkan dan dianotasi, termasuk anotasi untuk bounding box pemain, nomor punggung, peran (seperti pemain, penjaga gawang, wasit, staf), dan afiliasi tim.

Arsitektur model dimulai dengan *body part-based re-identification*, yang menghasilkan embedding lokal untuk setiap bagian tubuh pemain, menggunakan *attention maps* untuk memprioritaskan bagian tubuh yang terlihat, terutama saat terjadi *occlusion*. Untuk menangani masalah peran pemain di lapangan, *role classification* ditambahkan, menggunakan *focal loss* untuk mengatasi ketidakseimbangan kelas, sehingga model dapat mengklasifikasikan pemain sebagai pemain, penjaga gawang, wasit, atau staf. Untuk membedakan pemain dari tim yang sama, komponen *team affiliation* menggunakan *triplet loss* untuk mengelompokkan pemain berdasarkan tim mereka.

Model pelacakan dimulai dengan deteksi pemain menggunakan YOLOv8, diikuti oleh pelacakan berbasis *StrongSORT* yang telah dimodifikasi untuk memanfaatkan embedding yang dihasilkan oleh *body part-base*. Selama proses re-identifikasi, sistem mengenali pemain yang sama meskipun mereka keluar dan masuk frame, dengan memanfaatkan ekstraksi fitur lokal dan informasi nomor punggung untuk mengurangi kesalahan identifikasi. Setelah pelacakan dilakukan, *role classification*, *team affiliation*, dan pengenalan nomor punggung (MMOCR) dengan membantu memperkaya *embedding* pemain, meningkatkan akurasi pengenalan dan memudahkan pemisahan pemain dari tim yang berbeda.

Proses perancangan dimulai dengan akuisisi data, yaitu pengumpulan dataset video pertandingan sepak bola yang mencakup anotasi pemain, peran (seperti pemain, penjaga gawang, wasit, staf), afiliasi tim, dan nomor punggung. Selanjutnya, dilakukan pemrosesan label untuk mengekstrak fitur visual pemain yang dilakukan oleh backbone, seperti HRNet-W32 atau ResNet-50 digunakan untuk mengekstraksi fitur lokal dari setiap bagian tubuh pemain. Backbone ini berfungsi untuk memproses gambar dan menghasilkan embedding bagian tubuh yang diperlukan untuk *re-identification*, serta untuk mengekstraksi informasi nomor punggung secara langsung tanpa memerlukan teknik *Optical Character Recognition* (OCR). Proses ini memungkinkan model untuk mengenali nomor punggung sebagai bagian dari atribut visual pemain. Proses berikutnya adalah pemodelan body part-based *re-identification*, yang menggunakan model *Body Part-based Re-identification* untuk menghasilkan embedding bagian tubuh, diikuti oleh pelatihan model menggunakan multi-task learning, yang mencakup empat tugas utama, yaitu *re-identification*, *role classification*, dan *team affiliation*. Dalam proses pelatihan ini, digunakan triplet loss untuk *team affiliation*, focal loss untuk *role classification*, dan GiLt loss untuk *re-identification*.


Setelah model dilatih, proses optimasi model dilakukan untuk memastikan bahwa model dapat menangani *occlusion* dengan memanfaatkan fitur lokal bagian tubuh dan informasi lainnya secara citra dengan *focal loss* dan *triplet loss*. Langkah berikutnya adalah implementasi object tracking, menggunakan StrongSORT yang dimodifikasi untuk memanfaatkan embedding part-based, serta pengujian model pada video pertandingan sepak bola untuk mengevaluasi akurasi *re-identification*, pelacakan, dan klasifikasi peran. Metrik evaluasi yang digunakan mencakup mAP, Rank-1 Accuracy, HOTA, MOTA, IDF1, dan IDs untuk mengukur kinerja *re-identification* dan *tracking*, serta *accuracy* dan *precision*. Setelah pengujian, model terbaik yang menunjukkan kinerja terbaik dalam semua tugas akan dipilih untuk digunakan dalam analisis video pertandingan sepak bola. Alur mengenai rancangan solusi dijelaskan pada Gambar IV.1.



Gambar IV.1 Diagram alir proses pembuatan model *re-identification*

IV.1.1 Pipeline Proses Re-Identifikasi Permainan Sepak Bola

Sebelum memasuki tahapan pencocokan identitas dalam pipeline re-identifikasi, perlu dipahami bahwa model *Multi-Task Re-Identification* yang dikembangkan berfungsi sebagai *feature extractor*, yaitu mengubah citra pemain yang terdeteksi menjadi representasi vektor (embedding) yang mencerminkan karakteristik visual pemain tersebut. Namun, vektor tersebut belum memiliki arti yang dapat langsung digunakan untuk mengenali identitas secara menyeluruh. Oleh karena itu, diperlukan sistem tambahan berupa pipeline re-identifikasi yang menyimpan, mengelola, dan membandingkan vektor-vektor ini secara sistematis. Adapun *pipeline* proses re-identifikasi dapat dilihat pada Gambar IV.2.




Gambar IV.2 *Pipeline* Proses Re-Identifikasi Pada Video Sepak Bola

Dalam konteks ini, pipeline re-identifikasi bertindak sebagai sistem manajemen galeri (*gallery manager*) yang bertugas melakukan pencocokan antara vektor pemain yang baru (*query*) dengan kumpulan vektor pemain sebelumnya (*gallery*). Proses ini penting untuk memastikan bahwa setiap identitas pemain tetap konsisten meskipun pemain berpindah posisi atau keluar-masuk frame kamera.

Dalam implementasi sistem pipeline tersebut, digunakan algoritma *StrongSORT* sebagai *tracker*. StrongSORT tidak hanya melakukan pelacakan berbasis posisi dan gerakan, tetapi juga dilengkapi dengan kemampuan *tracklet management* melalui pemanfaatan fitur *appearance* dari vektor *embedding*. Dalam sistem ini, *tracklet manager* berperan sebagai *gallery manager* yang menyimpan dan membandingkan vektor pemain untuk menentukan tingkat kemiripan visual antar individu berdasarkan *embedding* yang dihasilkan oleh model re-identifikasi.

IV.1.2 Pengumpulan dan Persiapan *Dataset*


Pada penelitian ini, persiapan *dataset* merupakan langkah fundamental untuk mendukung pengembangan model *Re-Identification* berbasis *multi-task learning* yang mampu melakukan tugas *Re-identification*, *Team Affiliation*, dan *Role Classification*. *Dataset* yang digunakan berasal dari *dataset* publik SoccerNet-Gamestate yang menyediakan data pelacakan pemain dalam video pertandingan sepak bola. Adapun penjelasan mengenai skema pembagian *dataset* dapat dilihat pada Gambar IV.3.



Gambar IV.3 Skema Pembagian *Dataset*

Pada *preprocessing*, data diolah sedemikian rupa untuk mendukung tugas pelatihan model multitask yang mencakup *body part-based re-identification*, *team affiliation*, dan *role classification* dengan memanfaatkan bagian-bagian tubuh seperti kepala, torso, dan kaki sebagai local features yang relevan. Proses ini melibatkan data masking yang bertujuan untuk menandai bagian tubuh tertentu dalam setiap gambar pemain, sehingga model dilatih untuk fokus pada setiap bagian tubuh. Teknik ini tidak hanya memperkuat kemampuan model dalam mengenali identitas pemain meskipun terjadi *occlusion*, tetapi juga meningkatkan generalisasi terhadap berbagai kondisi pencahayaan, sudut kamera, dan pergerakan pemain.

Selain itu, data yang digunakan dalam *query* dan *gallery* juga diproses secara khusus untuk memastikan bahwa pasangan identitas pada proses pelatihan dan pengujian tidak saling tumpang tindih, sesuai dengan praktik standar dalam sistem re-identifikasi. Skema keseluruhan dari tahapan preprocessing ini, termasuk struktur input dan pemisahan antara query-gallery serta penerapan masking, dapat dilihat secara lebih rinci pada Gambar IV.4.



Gambar IV.4 *FlowChart* Penerapan Masking dan pemisahan Data Query-Gallery

IV.1.3 Pengembangan Model Re-Identification


Membangun sistem yang mampu menangani berbagai tantangan analisis video olahraga secara efektif membutuhkan pendekatan terintegrasi. Proses pengembangan model ini dirancang dengan memanfaatkan teknik multi-task learning, yang memungkinkan setiap komponen bekerja secara sinergis dalam menyelesaikan tugas-tugas utama seperti *re-identification*, pengenalan tim, klasifikasi peran, dan pengenalan jersey. Struktur arsitektur yang dikembangkan bertujuan menghasilkan representasi fitur yang kaya dan diskriminatif, sehingga

mampu memberikan solusi komprehensif terhadap berbagai skenario analisis video.

IV.1.3.1 Model Re-Identification

Pendekatan Re-identification dalam penelitian ini dilakukan melalui tiga tugas utama yang saling mendukung, yaitu *Body Part-based Embedding*, *Team Affiliation*, dan *Role Classification*. Dengan menerapkan arsitektur multi-task learning, model dapat memanfaatkan keterkaitan antar tugas untuk menghasilkan representasi fitur yang lebih kaya dan akurat. HRNet-W32 digunakan sebagai backbone karena kemampuannya dalam menjaga detail spasial resolusi tinggi selama ekstraksi fitur. Segmentasi tubuh membagi tubuh pemain menjadi lima bagian utama untuk menghasilkan embedding spesifik, yang kemudian diproses menggunakan *weighted average pooling* dan dioptimalkan dengan *Global identity Local triplet loss (GiLt loss)* guna meningkatkan kinerja Re-identification, terutama dalam kondisi *occlusion* dan variasi sudut pandang.


Embedding hasil segmentasi ini juga digunakan untuk tugas *Team Affiliation*, yang dilatih dengan *triplet loss* untuk mengelompokkan pemain dalam tim yang sama secara otomatis tanpa bergantung pada identitas tim yang telah dilatih sebelumnya. Sementara itu, tugas *Role Classification* dilakukan dengan modul klasifikasi berbasis *fully connected layer*, menggunakan *focal loss* untuk mengatasi ketidakseimbangan kelas. Ketiga tugas ini dilatih secara end-to-end menggunakan *Combine Loss*, yaitu gabungan dari *part prediction loss*, *GiLt loss*, *triplet loss*, dan *focal loss* yang masing-masing diberikan bobot proporsional berdasarkan hasil eksperimen untuk mencapai keseimbangan pelatihan yang optimal. Gambar IV.5 berikut menunjukkan alur keseluruhan proses pelatihan model.



Gambar IV.5 Diagram alir proses pelatihan model Re-Identification

Setelah proses pelatihan selesai, model dievaluasi untuk mengukur kinerjanya dalam menjalankan ketiga tugas utama yang telah ditentukan. Evaluasi dilakukan dengan memanfaatkan data uji yang telah dipisahkan sebelumnya dari proses pelatihan. Setiap modul dievaluasi menggunakan metrik yang relevan: *mean Average Precision* (mAP) dan *Cumulative Matching Characteristic* (CMC) untuk Re-identification, *Clustering Purity* untuk Team Affiliation, serta *Accuracy* dan *F1-Score* untuk Role Classification.

Embedding yang dihasilkan dari model dilalui serangkaian tahapan evaluasi untuk mengukur efektivitas segmentasi bagian tubuh, kualitas representasi fitur, serta kemampuan klasifikasi dan pengelompokan. Proses ini memungkinkan identifikasi kekuatan dan kelemahan model secara terpisah pada tiap tugas, serta memberikan wawasan untuk perbaikan lebih lanjut. Gambar IV.6 berikut ini memperlihatkan diagram alir proses evaluasi model secara keseluruhan.




Gambar IV.6 Diagram alir proses evaluasi model Re-Identification

IV.1.3.2 Integrate Learning

Setelah proses pelatihan selesai, hasil embedding yang dihasilkan oleh model Re-identification diintegrasikan ke dalam sistem pelacakan untuk menguji efektivitasnya dalam meningkatkan akurasi dan konsistensi pelacakan objek dalam video sepak bola. Embedding part-based yang diperoleh dari arsitektur multi-task digunakan sebagai pengganti fitur global dalam Strong-SORT, memungkinkan perhitungan jarak yang lebih presisi antara deteksi, tracklet, dan lintasan pada tiap frame. Integrasi ini bertujuan untuk mengurangi kesalahan asosiasi identitas (identity switches), terutama dalam kondisi kompleks seperti *occlusion*, interaksi antar pemain, atau perubahan sudut pandang kamera.

Sistem pelacakan ini dilengkapi dengan modul *part-based tracklet merging*, yang berfungsi menggabungkan lintasan pendek (tracklet) menjadi lintasan yang lebih panjang. Modul ini menggunakan metrik jarak berbasis embedding tubuh untuk menilai kesamaan antar tracklet. Proses penggabungan dilakukan menggunakan algoritma optimasi seperti Hungarian Algorithm, yang meminimalkan biaya asosiasi berdasarkan jarak embedding dan informasi temporal-spasial dari tracklet. Dengan cara ini, sistem dapat secara efisien mengelola identitas pemain bahkan dalam situasi yang kompleks, seperti perubahan posisi kamera atau pergerakan non-linear. Adapun alur mengenai rancangan solusi uji integrasi dengan MOT terdapat pada Gambar IV.7.



Gambar IV.7 Diagram alir uji integrasi model Re-Identification dengan MOT

Selain itu, metode ini tidak hanya mengandalkan fitur visual tetapi juga secara tidak langsung memanfaatkan informasi tentang afiliasi tim dan peran pemain, yang telah diintegrasikan ke dalam embedding multi-task. Hal ini memastikan bahwa lintasan pemain dari tim berbeda atau peran yang berbeda tetap terpisah dengan jarak embedding yang signifikan. Dengan integrasi ini, sistem pelacakan yang diusulkan mampu mengurangi identity switches, memperbaiki *tracking accuracy*, dan menghasilkan lintasan pemain yang konsisten sepanjang video. Pendekatan berbasis part ini terbukti memberikan hasil yang lebih baik dibandingkan metode pelacakan tradisional, sebagaimana dibuktikan melalui eksperimen pada *dataset* SoccerNet.

IV.2 Hasil Desain Solusi

Setelah melalui tahapan analisis masalah dan perancangan solusi yang telah diuraikan sebelumnya, langkah selanjutnya dalam penyusunan sistem Smart Football ini adalah merancang strategi pengujian serta evaluasi atas solusi yang dikembangkan. Hal ini penting untuk memastikan bahwa sistem Re-Identification yang dirancang mampu bekerja secara konsisten dan akurat dalam kondisi pertandingan yang dinamis. Oleh karena itu, pada subbab berikut akan dijelaskan secara rinci mengenai desain pengujian dan evaluasi yang dirancang untuk menilai kinerja dari solusi yang telah dibangun, mencakup metrik evaluasi, skenario pengujian, serta pendekatan teknis yang digunakan untuk mengukur keberhasilan implementasi sistem.

IV.2.1 Akuisisi Data

Langkah awal dalam pengembangan model *Re-Identification* pemain adalah melakukan akuisisi data yang akan digunakan untuk pelatihan. Pada penelitian ini, *dataset* yang digunakan terdiri dari kumpulan gambar pemain sepak bola yang diekstrak dari rekaman pertandingan. *Dataset* ini mencakup berbagai kondisi, seperti sudut pengambilan gambar, pencahayaan, variasi seragam, serta perbedaan postur dan gerakan pemain. Setelah melakukan riset terhadap *dataset open source* yang tersedia dan sesuai dengan karakteristik yang dibutuhkan, dipilih *dataset* yang akan dijelaskan lebih lanjut pada subbab berikut.

IV.2.1.1 SoccerNet Gamestate *Dataset*

Dalam penelitian ini, digunakan *dataset* SoccerNet Gamestate (SN-Gamestate) yang berisi data pelacakan pemain dari rekaman pertandingan sepak bola. *Dataset* ini mencakup 12 pertandingan lengkap yang direkam dari kamera utama, dengan tambahan 166 klip berdurasi 30 detik yang telah dianotasi dengan data pelacakan. Selain itu, terdapat satu babak penuh yang juga dilengkapi dengan anotasi pelacakan, serta video lengkap dari keseluruhan 12 pertandingan. Pada tahap awal penelitian, hanya sebagian dari *dataset* ini yang digunakan, yaitu 57 klip berdurasi 30 detik untuk pelatihan, 59 klip berdurasi 30 detik untuk Validasi, dan 50 klip berdurasi 30 detik untuk Pengujian serta sejumlah klip tambahan untuk tantangan publik mendatang. Beberapa contoh gambar dari *dataset* SN-Gamestate dapat dilihat pada Gambar IV.8.



Gambar IV.8 *Dataset* SoccerNet SN-Gamestate

Adapun untuk memastikan *dataset* dapat mendukung *multi-task learning*, setiap *instance* dalam *dataset* diperkaya dengan anotasi / label tambahan seperti identitas pemain, afiliasi tim, dan peran di lapangan (misalnya pemain, kiper, atau wasit). Anotasi ini digunakan untuk melatih model dalam tugas klasifikasi peran dan afiliasi tim. Seluruh *dataset* ini dibagi menjadi subset pelatihan, pengujian, dan validasi, dengan rasio yang disesuaikan untuk memastikan representasi data yang merata dan menghindari bias selama pelatihan. Adapun data yang digunakan mencakup informasi yang tercantum dalam Tabel IV.1.

Tabel IV.1 *Dataset* SN-Gamestate Soccernet


No.	Jenis Dataset	Deskripsi
1.	<i>Dataset</i> gambar	Data ini berupa potongan-potongan gambar dari video 25 frame per second.
2.	<i>Dataset</i> koordinat bbox <i>ground truth</i>	Data ini berupa koordinat deteksi objek berdasarkan <i>ground truth</i> berbentuk <i>bounding box</i> .
3.	<i>Dataset</i> Label <i>attribute</i>	<i>Dataset</i> ini berupa informasi klasifikasi objek pada permainan, seperti <i>role classification</i> , <i>team affiliation</i> , dan <i>jersey</i> .

IV.2.2 Pelatihan Model Re-Identification

Setelah proses akuisisi dan pemrosesan data selesai, tahap berikutnya adalah melatih model *Re-Identification* sesuai dengan metode dan arsitektur yang telah dibahas pada bab sebelumnya. Model ini dirancang untuk mengenali pemain berdasarkan bagian tubuh (*body-part based*), dengan memanfaatkan *dataset* SN-Gamestate serta label *human parsing* yang diproses dari *dataset* SN-Gamestate.

IV.2.2.1 Arsitektur Model

Arsitektur model yang digunakan dalam penelitian ini mengacu pada pendekatan multi-task part-based Re-Identification, yang mengintegrasikan tiga tugas utama: *body-part Re-ID*, *team affiliation classification*, dan *role classification*. Ketiga model ini mengadopsi arsitektur dasar yang serupa, namun masing-masing dirancang untuk mempelajari representasi fitur yang berbeda sesuai dengan fungsi spesifiknya. Meskipun dilatih secara independen, ketiganya tetap berbagi backbone representasi fitur awal, untuk meningkatkan efisiensi dan generalisasi model melalui skema *multi-task learning*.



Gambar IV.9 Arsitektur Model Re-Identification

Backbone utama yang digunakan dalam ketiga model ini adalah High-Resolution Network (HRNet-W32). Pemilihan arsitektur ini didasarkan pada kemampuannya dalam mempertahankan resolusi spasial tinggi selama proses ekstraksi fitur, yang sangat krusial dalam konteks video pertandingan sepak bola. Resolusi tinggi diperlukan untuk memastikan bahwa detail tubuh pemain tetap terjaga, terutama saat terjadi *occlusion*, perubahan skala, atau sudut pandang kamera yang dinamis. Gambar input yang digunakan memiliki resolusi [Batch, 3, 256, 128], sesuai dengan standar input *multi-task learning*, dan diproses melalui blok awal HRNet yang menggabungkan *convolutional layers*, *batch normalization*, dan *ReLU activation* untuk menghasilkan fitur awal yang informatif.

Setelah proses ekstraksi fitur awal, arsitektur dilanjutkan dengan cabang tugas yang berbeda. Untuk *body-part* Re-ID, digunakan modul *part-based feature extraction* yang memanfaatkan segmentasi tubuh hasil parsing untuk menghasilkan embedding lokal yang merepresentasikan bagian tubuh spesifik, seperti kepala, torso, dan kaki. Embedding ini digunakan sebagai dasar perhitungan jarak dalam proses asosiasi lintasan (*tracklet*) sebagai *cost appearance*.

Sementara itu, dua cabang lainnya bertanggung jawab untuk mengklasifikasikan afiliasi tim dan peran pemain. Keduanya mengandalkan *global feature representations* yang dihasilkan dari seluruh gambar pemain. Fitur-fitur ini

menggambarkan pola-pola umum seperti warna jersey, peralatan, atau posisi khas pemain, dan diproses melalui *fully connected layers* untuk menghasilkan prediksi kelas masing-masing.

Tabel IV.2 *Loss Functions* Dalam Pelatihan Model Re-Identification

<i>Loss Function</i>	Fungsi
<i>GiLt Loss</i>	Digunakan untuk tugas <i>re-identification</i> , membantu model dalam membedakan identitas pemain meskipun terdapat variasi pose atau <i>occlusion</i> .
<i>Triplet Loss</i>	Digunakan untuk klasifikasi afiliasi tim, mendorong embedding pemain dari tim yang sama untuk lebih dekat dalam ruang fitur, sementara pemain dari tim berbeda lebih jauh.
<i>Focal Loss</i>	Digunakan untuk klasifikasi peran pemain, efektif dalam menangani ketidakseimbangan kelas dengan memberikan fokus lebih pada kelas minoritas.

Dalam proses pengaturan model, setiap tugas dioptimalkan menggunakan fungsi *loss* yang sesuai. *Triplet loss* digunakan untuk *Re-Identification* dan *Team Affiliation*, dengan tujuan mengelompokkan pemain dalam tim yang sama dalam ruang embedding, serta memisahkan pemain dari tim yang berbeda. Untuk tugas *Role Classification*, digunakan *focal loss* guna menangani ketidakseimbangan distribusi kelas antara pemain, kiper, wasit, dan staf.

Pendekatan *multi-task learning* diterapkan untuk memastikan bahwa fitur yang diekstraksi dari backbone dapat digunakan secara bersamaan untuk berbagai tugas. Dengan metode ini, model dapat belajar representasi yang lebih kaya dan generalis, yang tidak hanya meningkatkan akurasi tugas individu tetapi juga memperkuat hubungan antar tugas dalam sistem pelacakan pemain sepak bola secara keseluruhan.

IV.2.2.2 Pengaturan Model

Dalam penelitian ini, model *Re-Identification* dikembangkan menggunakan pendekatan *multi-task learning* yang mencakup tiga tugas utama secara simultan: identifikasi pemain berbasis bagian tubuh (*body part-based embedding*), klasifikasi afiliasi tim (*team affiliation*), dan klasifikasi peran pemain (*role classification*). Arsitektur ini bertujuan untuk menghasilkan representasi fitur yang lebih kaya dan diskriminatif, dengan menggunakan jaringan *High-Resolution Network* (HRNet-W32) sebagai backbone utama karena kemampuannya dalam mempertahankan informasi spasial resolusi tinggi yang krusial untuk domain olahraga.

Beberapa parameter dasar yang digunakan dalam pelatihan model ini bersifat tetap selama eksperimen, karena sudah disesuaikan dengan karakteristik data video pertandingan sepak bola dan kebutuhan sumber daya pelatihan. Selain itu, dataset yang digunakan secara konsisten adalah SoccerNet Gamestate yang telah diproses menjadi format potongan gambar untuk kebutuhan pelatihan tugas identifikasi dan klasifikasi. Adapun variabel parameter pelatihan model yang tidak diganti dapat dilihat pada Tabel IV.3.

Tabel IV.3 Pengaturan Pelatihan Model

Parameter	Nilai	Deskripsi
batch_size	32	Ukuran batch untuk proses pelatihan.
max_epoch	20	Jumlah epoch maksimal untuk training.
dataset	SoccerNet Gamestate	Dataset sumber dan target untuk pelatihan.
height	256	Tinggi gambar input.
width	128	Lebar gambar input.
backbone	hrnet32	Arsitektur backbone untuk ekstraksi fitur.
dim_reduce_output	256	Dimensi output setelah reduksi.
dist_metric	euclidean, cosine	Metode pengukuran jarak antar embedding saat inference.
normalization	cosine	Jenis normalisasi fitur.

Sementara itu, untuk mengkaji pengaruh berbagai konfigurasi terhadap kinerja model, sejumlah parameter penting lainnya diuji dengan beberapa variasi nilai. Parameter-parameter yang divariasikan dalam eksperimen ini meliputi, metode pooling, jenis normalisasi, strategi reduksi dimensi, serta metrik jarak embedding (dist_metric) yang dibandingkan antara euclidean dan cosine. Selain itu, konfigurasi bobot fungsi loss untuk masing-masing komponen embedding juga dieksplorasi, seperti weight_globl, weight_foreg, weight_conct, dan weight_parts, baik untuk loss identitas (id) maupun triplet loss (tr).

Eksperimen dengan parameter-parameter tersebut dilakukan untuk menemukan konfigurasi yang paling optimal dalam meningkatkan kinerja model, terutama dalam mengatasi tantangan occlusion, perbedaan pose, dan tampilan visual antar pemain di lapangan. Seluruh hasil pengaturan model selama eksperimen dapat dilihat secara lengkap pada Tabel IV.4 berikut.

Tabel IV.4 Pengaturan Model yang Divariasikan

Parameter	Deskripsi
pooling	Metode pooling untuk ekstraksi fitur global.
dim_reduce	Strategi reduksi dimensi pada fitur.
weight_globl_id/tr	Bobot loss identitas global.
weight_foreg_id/tr	Bobot identitas foreground.
weight_conct_id/tr	Bobot identitas concatenated.
weight_parts_id/tr	Bobot identitas part-based.

Pengaturan hyperparameter ini berperan penting dalam memastikan proses pelatihan berjalan optimal dan stabil dalam kerangka multi-task learning yang kompleks. Seluruh konfigurasi telah diselaraskan dengan kebutuhan karakteristik data dari domain pertandingan sepak bola. Dengan pendekatan ini, model dapat beradaptasi terhadap dinamika data visual di lapangan, serta menjaga konsistensi kinerja di ketiga tugas utama yang dijalankan secara simultan. Strategi *tuning* ini juga memungkinkan integrasi yang lebih mulus dengan pipeline pelacakan berbasis StrongSORT pada tahap evaluasi akhir.


IV.2.2.3 Pemrosesan Re-Identifikasi Objek

Dalam proses pelatihan, digunakan sejumlah label penting yang merepresentasikan bagian tubuh pemain afiliasi tim seperti Team A dan Team B serta mengklasifikasikan peran pemain dalam pertandingan sesuai perannya. Rincian label yang digunakan dalam proses pelatihan model dapat dilihat pada Tabel IV.5.

Tabel IV.5 Label *Dataset Training Model*

No	Jenis Label	Kategori	Deskripsi
1.	Bagian Tubuh	<i>Head, up torso, low torso, legs, dan feet.</i>	Label bagian tubuh yang digunakan untuk meningkatkan akurasi identifikasi.
2.	Peran pemain	<i>Player, Goalkeeper, dan referee.</i>	Label yang menunjukkan afiliasi tim masing-masing pemain.
3.	Afiliasi Tim	Team A dan Team B	Label yang membedakan peran objek dalam pertandingan.


Dalam pendekatan multitask learning yang diterapkan, ketiga label ini dilatih secara simultan menggunakan gabungan beberapa fungsi loss, yaitu triplet loss untuk embedding Re-ID, focal loss untuk klasifikasi peran pemain, serta cross-entropy loss untuk prediksi bagian tubuh. Strategi ini memungkinkan model untuk belajar fitur representatif yang lebih robust dan saling melengkapi antar tugas. Adapun ilustrasi pencocokan identitas pemain antara galeri dan query dengan memanfaatkan embedding tubuh terdapat pada gambar IV.10.



Gambar IV.10 Ilustrasi Pencocokan Identitas Pemain

Penting untuk memahami bahwa proses pencocokan identitas pemain tidak dilakukan secara langsung pada keseluruhan gambar, melainkan dimulai dari pemrosesan bagian-bagian tubuh terlebih dahulu. Sesuai dengan pendekatan yang diadopsi dalam model multi task Re-Identification, proses identifikasi dimulai dengan deteksi dan ekstraksi fitur dari lima bagian tubuh utama, yaitu *head*, *upper torso*, *lower torso*, *legs*, dan *feet*. Pembagian ini bertujuan untuk meningkatkan ketahanan model terhadap *occlusion*, serta memfokuskan perhatian model pada bagian-bagian tubuh yang paling informatif dalam proses pencocokan.


Setelah representasi dari masing-masing bagian tubuh berhasil diperoleh, model kemudian melakukan agregasi informasi untuk menghasilkan representasi global pemain. Proses ini dilakukan bersamaan dengan pemisahan foreground dan background. Hanya informasi penting dari tubuh pemain yang difokuskan, sementara latar belakang yang tidak relevan diminimalisir. Dengan kombinasi strategi part-based feature learning dan masking berbasis *foreground*, model memperoleh embedding yang lebih tajam dan akurat dengan *combine loss foreground focal loss* dan *triplet loss*.



Gambar IV.11 Hasil Gambar Re-Identifikasi Body Part-Based

IV.2.3 Penerapan Model pada *Tracking*

Model multi-task yang telah dilatih ini kemudian diintegrasikan dalam sistem pelacakan multi-objek dengan modul StrongSORT yang menggunakan *embedding* lokal dari modul part-based untuk menggantikan fitur global dalam proses asosiasi antar tracklet. Proses ini memanfaatkan jarak embedding dan informasi spasial-temporal untuk menggabungkan tracklet menjadi lintasan pemain yang lebih panjang dan konsisten. Integrasi ini ditujukan untuk mengurangi *identity switches* serta meningkatkan *tracking accuracy*, sebagaimana dibuktikan melalui eksperimen pada *dataset* SoccerNet. Adapun gambaran dari *embedding Multi-task Re-Identification* dengan strongSORT dan cara melakukan *matching object* dan *merging tracklet* dapat dilihat pada gambar IV.12.



Gambar IV.12 *Embedding Model Multi-Task Re-Identification* dan StrongSORT

Dalam tujuan mengoptimalkan proses pelacakan antar *frame*, modul pelacakan StrongSORT digunakan sebagai pelacak utama yang terintegrasi dengan embedding hasil dari model Re-Identification. Proses asosiasi antar objek dilakukan dengan menggabungkan berbagai informasi, seperti jarak embedding, kesesuaian posisi, dan keypoint, dalam satu framework pelacakan yang adaptif.

Agar StrongSORT dapat berfungsi sebagai gallery manager, yakni modul yang secara aktif mengelola tracklet dan melakukan re-identifikasi ulang terhadap objek, diperlukan beberapa penyesuaian pada pengaturannya. Salah satu penyesuaian utama adalah menonaktifkan mekanisme Kalman Filter gating dengan mengatur `only_position_for_kf_gating` ke nilai False, sehingga semua objek yang terdeteksi dianggap layak untuk dilakukan proses pencocokan ulang (re-identification) tanpa perlu melalui seleksi berbasis prediksi posisi. Selain itu, nilai `max_age` disetel ke angka 750, sesuai dengan jumlah frame dalam 1 video, agar sistem tetap dapat mempertahankan dan memprediksi lintasan meskipun objek sempat menghilang dari beberapa frame. Adapun pengaturan *tracker* dirancang seperti yang bisa dilihat pada Tabel IV.6.


Tabel IV.6 Pengaturan StrongSORT

Parameter	Nilai yang Dicoba	Deskripsi
ema_alpha	0,9	Faktor <i>exponential moving average</i> untuk update fitur appearance.
max_iou_distance	0,8	Ambang maksimum IoU untuk asosiasi objek.
max_oks_distance	0,7	Ambang maksimum OKS untuk asosiasi keypoint.
max_age	750	Jumlah maksimum frame <i>missed</i> sebelum track dihapus.
nn_budget	10000	Jumlah maksimum galeri descriptor appearance.
min_bbox_confidence	0	Batas minimum confidence bounding box untuk dianggap valid.
only_position_for_kf_gating	False	Jika True, hanya posisi (x,y) digunakan oleh Kalman Filter.
max_kalman_prediction_without_update	100	Batas frame tanpa update sebelum Kalman Filter berhenti memprediksi.
gating_thres_factor	1	Faktor pengali ambang batas gating Kalman Filter.
mc_lambda (divariasikan)	0,8	Bobot kombinasi appearance dan Kalman Filter dalam pencocokan.
max_dist	0,6	Ambang maksimum jarak appearance untuk pencocokan identitas.
w_kfgd (divariasikan)	0	Bobot untuk Keypoint Filtered Gating Distance.
w_reid (divariasikan)	1,5	Bobot untuk fitur Re-Identification dalam asosiasi.
w_st (divariasikan)	1	Bobot komponen spasial-temporal dalam proses matching.

Setelah model multi-task diintegrasikan dengan sistem pelacakan multi-objek menggunakan StrongSORT, langkah selanjutnya adalah menguji kinerja *tracking* pada data pertandingan sepak bola. Proses ini dimulai dengan mendeteksi pemain di setiap *frame*, lalu mengasosiasikan identitas antar frame secara konsisten untuk membentuk lintasan setiap pemain. Dengan memanfaatkan embedding lokal hasil dari modul part-based, sistem ini mampu melakukan asosiasi yang lebih presisi,

bahkan ketika pemain berpindah tempat, saling menutupi, atau keluar-masuk frame, seperti yang bisa dilihat pada Tabel IV.7.

Tabel IV.7 Hasil Integrasi Model dan Tracker





Hasil pelacakan *frame-to-frame* berikut menunjukkan bahwa sistem berhasil mempertahankan identitas pemain secara konsisten, termasuk dalam situasi kompleks seperti saat pemain sempat terdeteksi dalam *frame* 489 dan keluar pada *frame* 540, sehingga tidak terdeteksi, kemudian kembali muncul dalam *frame* 616 seperti yang bisa dilihat pada gambar diatas pemain dengan id 50 yang sama dengan id sebelumnya.

BAB V

EVALUASI

Bab ini membahas proses pengujian dan evaluasi terhadap model deteksi lapangan dan kalibrasi kamera yang telah dikembangkan. Pengujian dan evaluasi dilakukan untuk memastikan bahwa model yang dihasilkan memiliki tingkat akurasi yang tinggi dalam mendeteksi elemen-elemen lapangan serta mampu mengkalibrasi parameter kamera secara efektif. Pada bab ini, berbagai metrik evaluasi akan dibahas dan diimplementasikan untuk menilai kinerja model secara keseluruhan.

V.1 Uji Model Re-Identifikasi dan Uji Integrasi

Pengujian dilakukan melalui dua tahap berurutan. Pertama, model Re-Identification diukur secara terpisah dengan menghitung *mean Average Precision* (mAP) dan *Cumulative Matching Characteristic* (CMC) Rank-1 pada split validasi SoccerNet-Gamestate, langkah ini memastikan kemampuan model mengenali identitas pemain tanpa campur tangan komponen lain. Kedua, embedding ReID dimasukkan ke dalam rantai pelacakan StrongSORT bersama data yang sudah siap dilakukan *tracking*, lalu dievaluasi pada rekaman pertandingan penuh menggunakan metrik HOTA, IDF1, MOTA, AssA, DetA, dan jumlah *IDs*. Perbandingan hasil tracker sebelum dan sesudah integrasi ReID menunjukkan sejauh mana ReID meningkatkan akurasi deteksi, konsistensi identitas, serta kualitas asosiasi lintasan pemain.

V.1.1 Konfigurasi Sistem

Dalam pelatihan model Re-Identification ini, terdapat perangkat keras dan perangkat lunak yang digunakan. Perangkat lunak yang digunakan mencakup *library* dan spesifikasi server. Implementasi sistem pengenalan aksi memanfaatkan beberapa *library* python yang dapat dilihat pada Tabel V.1.

Tabel V.1 Perangkat Lunak Implementasi

No	Perkakas	Deskripsi
1	SoccerNet	Pengunduhan <i>dataset</i> video dan anotasi aksi
2	HRNet-W32	Digunakan sebagai backbone CNN (Convolutional Neural Network) untuk menghasilkan representasi fitur spasial resolusi tinggi dari gambar input.
3	Pytorch	Pembangunan custom neural network
4	Sklearn	Perhitungan kinerja model atau evaluasi model, seperti mAP (Mean Average Precision) dan CMC Rank-1
5	NumPy	Digunakan untuk menangani manipulasi data numerik dan array.
6	scikit-learn	Digunakan untuk analisis clustering dan evaluasi.
7	NumPy	Digunakan untuk menangani manipulasi data numerik dan array.

Proses pelatihan dan pengujian model dilakukan menggunakan server cloud berbasis Google Cloud Platform (GCP), yang menyediakan sumber daya komputasi tinggi untuk menangani kebutuhan pemodelan deep learning pada data video sepak bola. Mengingat kompleksitas model dan besarnya ukuran data yang digunakan, diperlukan infrastruktur dengan GPU berkinerja tinggi agar pelatihan dapat berjalan secara efisien dan stabil. Spesifikasi lengkap dari server GCP yang digunakan dalam proses ini disajikan pada Tabel V.2.

Tabel V.2 Spesifikasi *Server*

No	Perangkat Keras	Spesifikasi
1	GPU	NVIDIA Tesla V100, 78 GB VRAM
2	CPU	12 vCPU (virtual CPU), 6-core Intel Haswell
3	<i>Operating System</i>	Ubuntu 20.04.02 LTS
4	Storage	SSD 400 GB

V.1.2 Pengujian Re-Identification

Evaluasi model Re-Identification difokuskan pada dua metrik utama. mean Average Precision (mAP) mengukur keseluruhan kualitas pencarian identitas dengan menghitung area di bawah kurva presisi-recall. Nilai mAP yang tinggi menunjukkan model mampu menemukan semua cuplikan pemain yang benar sambil meminimalisir kesalahan identifikasi. Cumulative Matching Characteristic (CMC) Rank-1 merepresentasikan probabilitas bahwa cuplikan pemain yang tepat muncul di peringkat teratas hasil pencarian, sehingga menggambarkan akurasi “sekali tebak” yang sangat penting bagi sistem real-time. Adapun deskripsi dari metrik evaluasi dapat dilihat pada Tabel V.3.

Tabel V.3 Metrik Evaluasi Model Re-Identification

No	Metrik Evaluasi	Deskripsi
1.	mAP (Mean Average Precision)	Rata-rata presisi dari seluruh query terhadap galeri; mengukur akurasi global.
2.	CMC Rank-1	Persentase pengenalan benar pada percobaan pertama; mengukur efektivitas awal pencocokan.

Evaluasi ini bertujuan untuk membandingkan kinerja model *Re-Identification* berbasis *Multi-Task Learning* pada benchmark *dataset* SN-Gamestate. Perbandingan ini difokuskan untuk melihat efektivitas masing-masing pendekatan dalam mengenali identitas pemain secara konsisten, serta kontribusinya terhadap peningkatan kualitas pelacakan ketika diintegrasikan ke dalam sistem tracker. Dengan membandingkan kedua arsitektur tersebut, dapat diperoleh insight mengenai keunggulan relatif dari masing-masing strategi, baik dari sisi akurasi identifikasi maupun stabilitas ID sepanjang pertandingan.

V.1.3 Pengujian Integrasi MOT

Setelah model Re-Identification diintegrasikan StrongSORT, kinerja pelacakan dinilai menggunakan rangkaian metrik untuk menilai kinerja *tracker*, yaitu *Higher-Order Tracking Accuracy* (HOTA) menilai keseimbangan antara deteksi

dan asosiasi identitas secara menyeluruh, IDF1 mengukur keselarasan temporal identitas, sedangkan MOTA meringkas kesalahan miss, false positive, dan mismatch. Dua komponen spesifik AssA (Association Accuracy) dan DetA (Detection Accuracy) memisahkan kontribusi ketepatan asosiasi dari akurasi deteksi murni, sementara jumlah IDs mencatat penggantian identitas yang tidak diinginkan; semakin sedikit nilainya, semakin konsisten pelacakan.

Tabel V.4 Metrik Evaluasi kinerja *Tracking*

No.	Matriks	Deskripsi
1	HOTA	Higher Order Tracking Accuracy, mengevaluasi keseimbangan antara detection accuracy dan association accuracy dalam pelacakan
2	IDF1	Identity F1 Score, memberikan fokus pada kemampuan model untuk menjaga identitas objek secara konsisten.
3	MOTA	Multiple Object Tracking Accuracy, mengukur seberapa akurat model dalam menjaga lintasan tanpa kehilangan objek atau membuat kesalahan identitas
4	AssA	Association Accuracy, mengukur akurasi asosiasi identitas lintasan antar frame. Metrik ini menilai kemampuan model dalam menghubungkan lintasan yang terpisah atau terputus
5	DetA	Detection Accuracy, mengevaluasi kemampuan model dalam mendeteksi objek dengan benar, tanpa memperhitungkan asosiasi lintasan
6	IDs	Identity Switches, jumlah Identity Switches

Evaluasi ini mencakup perbandingan kinerja pelacakan dengan tiga konfigurasi utama, yaitu:

1. Bytetrack sebuah *tracker* tanpa embedding model *appearance*.
2. StrongSORT dengan embedding model *Body Part-Based*.
3. StrongSORT dengan embedding model *Multi-Task Re-Identification*.

Perbandingan ini ditujukan untuk mengukur sejauh mana kontribusi embedding dalam meningkatkan metrik pelacakan seperti HOTA, IDF1, dan IDs, serta

mengevaluasi konsistensi dan keandalan sistem dalam kondisi pertandingan yang kompleks.

V.2 Hasil Evaluasi

Evaluasi Smart Football disusun dalam dua tingkat guna memperoleh gambaran kinerja model. Evaluasi pertama dilakukan untuk menguji kinerja model Re-Identification secara terpisah, mengukur seberapa akurat model mengenali identitas pemain melalui mAP dan CMC Rank-1 tanpa intervensi komponen lain. Hasil pada fase ini memberikan tolak ukur objektif tentang kemampuan model menangkap ciri unik setiap pemain.

Evaluasi kedua menguji dampak praktis model setelah di-embed ke *tracking* StrongSORT. Perbandingan metrik HOTA, IDF1, MOTA, AssA, DetA, serta jumlah pergantian IDs sebelum dan sesudah integrasi mengungkap kontribusi spesifik Re-Identification terhadap konsistensi ID, kestabilan lintasan, dan akurasi statistik pemain. Evaluasi ini mempermudah penilaian komponen yang memberikan pengaruh terbesar, sekaligus memvalidasi bahwa peningkatan kinerja sistem bukan berasal dari detektor atau tracker dasar, melainkan berasal dari modul re-identifikasi.

V.2.1 Model Re-Identification

Dalam mengevaluasi lebih lanjut pengaruh konfigurasi arsitektur terhadap kinerja model Re-Identification, dilakukan eksperimen dengan memvariasikan dua komponen penting yaitu jenis pooling dan strategi reduksi dimensi (*dim_reduce*). Semua eksperimen dilakukan dengan konfigurasi backbone tetap yaitu HRNet-W32, dan menggunakan skema pembobotan loss yang sama untuk seluruh bagian embedding, yaitu global id/tr: 1/0, foreground id/tr: 1/0, concat id/tr: 1/0, parts id/tr: 1/0, dan pixls ce: 0.35. Tujuannya adalah untuk mengidentifikasi kombinasi parameter *pooling* dan *dim reduce* yang paling efektif dalam meningkatkan nilai mean Average Precision (mAP) dan Rank-1 Accuracy. Adapun hasil evaluasi dapat dilihat pada Tabel V.5.

Tabel V.5 Hasil Evaluasi Model Tuning Pooling dan Dim Reduce

Backbone	Pooling	Dim Reduce	mAP	CMC Rank-1
HRNet-W32	gmp	before pooling	55,91%	73,57%
		after pooling	55,91	71,11%
	gap	before pooling	56,12%	73,57%
		after pooling	55,91%	73,32%
	gwap	before pooling	55,64%	73,04%
		after pooling	55,81%	72,37%

Setelah diperoleh konfigurasi arsitektur terbaik berdasarkan kombinasi pooling dan strategi reduksi dimensi, langkah selanjutnya adalah menguji pengaruh variasi pembobotan loss (weight) terhadap kinerja model. Eksperimen ini dilakukan dengan tetap mempertahankan backbone HRNet-W32 dan konfigurasi arsitektur terbaik sebelumnya, yaitu pooling gmp dan dim_reduce before_pooling. Tujuannya adalah untuk mengetahui komponen embedding mana yang paling berkontribusi terhadap akurasi identifikasi pemain, serta untuk mengevaluasi apakah kombinasi tertentu dari bobot loss dapat menghasilkan representasi fitur yang lebih efektif. Beberapa kombinasi bobot loss diuji dengan memberikan nilai berbeda pada komponen embedding global, foreground, concat, dan parts, sementara komponen pixls tetap pada nilai 0.35. Hasil evaluasi terhadap variasi bobot tersebut ditampilkan dalam Tabel V.6.

Tabel V.6 Hasil Evaluasi Model Tuning Pembobotan

Weight Global id/tr	Weight foreground	Weight parts id/tr	Weight concat id/tr	mAP	CMC Rank-1
1,0/0	1,0/0	1,0/0	0/1,0	56,12%	73,57%
0,6/0,5	0,5/0,3	0,5/0,4	1,0/1,0	56,02%	72,34%
0,8/0,8	0,3/0,3	0,6/0,6	0,8/0,8	56,89%	73,95%
0,6/0,7	0,6/0,6	0,4/0,6	1,0/0,8	56,4%	71,74%
0,5/0,5	0,6/0,3	0,4/0,4	1,0/1,0	56,14%	72,79%
0,5/0,5	0,3/0,4	0,5/0,4	0,8/1,0	55,76%	72,3%

Setelah dilakukan pengujian terhadap variasi pembobotan parameter, dipilih model dengan nilai mAP dan CMC Rank-1 tertinggi. Model terbaik tersebut kemudian dibandingkan dengan kinerja model Body Part-based baseline pada dataset Market-1501 yang diperoleh dari hasil pelatihan dalam penelitian body part-based re-identification (Somers, Vleeschouwer, dan Alahi, 2023), serta dibandingkan dengan model Re-Identification dan Multi-task Re-Identification yang dilatih menggunakan data training dan testing SoccerNet-Gamestate. Hasil perbandingan kinerja tersebut disajikan pada Tabel V.7.

Tabel V.7 Hasil Evaluasi Model Re-Identification

Model	mAP	CMC Rank-1
Body Part-based Re-Identification	52,3%	65,4%
Multi-task Re-Identification	56,89%	73,95%

Berdasarkan hasil evaluasi yang ditunjukkan pada Tabel V.5, model *Multi-task Re-Identification* menunjukkan kinerja yang lebih unggul dibandingkan *Body Part-based Re-Identification* yang sudah cukup tinggi sesuai dengan penelitian (Somers, Vleeschouwer, dan Alahi 2023), baik dari segi nilai *mAP* maupun *CMC Rank-1*. Hal ini mencerminkan kemampuan model *Multi-task* dalam mengekstraksi representasi fitur yang lebih kaya dan kontekstual karena selain melakukan identifikasi pemain, model ini juga dilatih untuk mengenali nomor punggung, afiliasi tim, dan peran pemain. Pendekatan multi-task ini terbukti efektif dalam meningkatkan akurasi identifikasi, terutama dalam skenario pertandingan sepak bola yang dinamis, penuh *occlusion*, dan variatif secara visual. Dengan demikian, model *Multi-task Re-Identification* dinilai lebih cocok untuk diaplikasikan dalam sistem pelacakan pemain sepak bola yang membutuhkan konsistensi ID di berbagai situasi pertandingan.

V.2.2 kinerja *Tracking*

Berikut merupakan perbandingan kinerja tracker StrongSORT dengan StrongSORT yang sudah diintegrasikan dengan modul Re-Identification dapat dilihat pada Tabel V.8.

Tabel V.8 Hasil Evaluasi kinerja *Tracking*

Model	HOTA	IDF1	MOT A	AssA	DetA	IDs
Bytetrack	51,535%	50,579%	64,562%	41,231%	64,475%	3828
StrongSORT + BPBReid	57,173%	60,556%	69,72%	47,771%	69,551%	1566
StrongSORT + Multitask Re-identification	58,672%	63,228%	70,649%	49,067%	69,91%	1334

Kenaikkan nilai HOTA, IDF1, dan AssA, disertai penurunan angka IDs, menjelaskan bahwa selain meningkatkan akurasi deteksi, penambahan modul Re-Identification juga mempertahankan identitas pemain secara berkesinambungan sepanjang pertandingan. Konsistensi ID yang lebih baik ini menghasilkan sistem yang lebih reliabel. Jika diintegrasikan dengan deteksi aksi, sistem ini dapat menghasilkan statistik seperti jarak tempuh, zona heat-map, dan kontribusi taktis setiap pemain yang dapat dipetakan dengan lebih akurat, sejalan dengan tujuan utama pengembangan sistem *Smart Football*.

BAB VI

KESIMPULAN DAN SARAN

VII.1 Kesimpulan

Berikut merupakan kesimpulan yang didapat dari pengerjaan tugas akhir yang sudah dilakukan:

1. Penerapan teknologi Re-Identification (ReID) dalam sistem analisis video sepak bola terbukti efektif untuk menjaga konsistensi ID pemain sepanjang pertandingan, terutama bagi pemain yang tidak memiliki nomor punggung. Penggunaan pendekatan body part-based ReID dan fitur embedding memungkinkan sistem mengenali pemain secara lebih akurat meskipun terjadi oklusi atau perpindahan posisi.
2. Integrasi metode pelacakan seperti StrongSORT dengan fitur ReID memberikan peningkatan kinerja dalam pelacakan multi-objek yang dinamis. Sistem ini mampu mengurangi terjadinya ID switching dan meningkatkan robustness pelacakan dalam kondisi pertandingan yang kompleks.

Secara umum, pengerjaan tugas akhir ini yang dilakukan melalui pendekatan kuantitatif dan eksperimental berhasil menghasilkan sistem Re-Identification untuk analisis video pertandingan sepak bola. Dengan mengintegrasikan metode *multi-task learning* dan pelacakan menggunakan StrongSORT, sistem ini mampu memberikan ID pemain yang lebih konsisten dari sistem *tracking* lainnya, meskipun terjadi oklusi atau perpindahan posisi. Teknologi ini, apabila diintegrasikan dengan model pengenalan aksi, memiliki potensi besar untuk menghasilkan statistik personal tiap pemain yang lebih lengkap, akurat, dan konsisten sepanjang pertandingan.

VII.2 Saran

Terdapat beberapa saran yang penulis dapat berikan pada penelitian yang serupa dengan penelitian yang sudah dilakukan:

1. Integrasi multi sumber fitur dan *multi-task learning*, kombinasikan sistem re-identifikasi dengan deteksi nomor punggung (jersey number) menggunakan pendekatan multitask learning, seperti combine loss untuk memperkuat representasi identitas pemain. Integrasi ini diharapkan dapat meningkatkan akurasi dan konsistensi pemberian ID terutama pada pemain dengan nomor punggung yang terlihat.
2. Integrasi dengan model aksi dan kalibrasi kamera dengan cara menggabungkan sistem ReID dengan model deteksi aksi dan kalibrasi kamera (*3D-to-2D projection*) guna menghasilkan statistik individu pemain secara otomatis, seperti akurasi tembakan, jumlah operan sukses, jumlah gol, shotmap, heatmap, serta lintasan dan jarak tempuh masing-masing pemain dalam satu pertandingan.
3. Lakukan penambahan dataset dan penanganan *edge case tracker*, Selain memperbanyak dan memperkaya data pelatihan untuk meningkatkan akurasi, perlu juga dibuat algoritma tambahan yang dirancang khusus untuk menangani edge case yang belum diimplementasi oleh sistem pelacakan (*tracker*) saat ini. Seperti pemain saling bertukar posisi atau hilang dari frame agar konsistensi pemberian ID tetap terjaga sepanjang pertandingan.

DAFTAR PUSTAKA

- Asad Arifin. 2024. "Target Ambisius Timnas Indonesia Tembus 100 Besar Ranking FIFA." Bola.net. January 23, 2024. https://www.bola.net/tim_nasional/target-ambisius-timnas-indonesia-tembus-100-besar-ranking-fifa-eebfed.html.
- Bewley, Alex , Zongyuan Ge, Lionel Ott, Fabio Ramos, and Ben Upcroft. 2016. "Simple Online and Realtime Tracking." *Published as Part of the Proceedings of the 2016 IEEE International Conference on Robotics and Automation (ICRA)*. <https://doi.org/10.1109/ICRA.2016.7487674>.
- Bian, Yuan , Min Liu, Xueping Wang, Yi Tang, and Yaonan Wang. 2023. "Occlusion-Aware Feature Recover Model for Occluded Person Re-Identification." *IEEE Transactions on Multimedia* 26 (November): pp. 5284-5295. <https://doi.org/10.1109/TMM.2023.3331192>.
- Cao, Jinkun , Jiangmiao Pang, Xinshuo Weng, Rawal Khirodkar, and Kris Kitani. 2023. "Observation-Centric SORT: Rethinking SORT for Robust Multi-Object Tracking." *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 9686–96.
- Cho, Yeong-Jun, and Dohyung Kim. 2023. "Rethinking Multi-Object Tracking Based on Re-Identification and Appearance Model Management." *IEEE Access* 11 (May): 54337–50. <https://doi.org/10.1109/ACCESS.2023.3274662>.
- Deloitte. 2022. "Most Popular Sports Events Worldwide 2022." Statista. 2022. <https://www.statista.com/statistics/1336094/most-popular-sports-leagues-events/>.
- Du, Yunhao , Zhicheng Zhao, Yang Song, Yanyun Zhao, Fei Su, Tao Gong, and Hongying Meng. 2023. "StrongSORT: Make DeepSORT Great Again." *IEEE Transactions on Multimedia*, February. <https://doi.org/10.1109/TMM.2023.3331192>.

- FIFA. 2024. "Men's Ranking." Inside.fifa.com. November 22, 2024.
<https://inside.fifa.com/fifa-world-ranking/men>.
- Gao, Shang , Jingya Wang, Huchuan Lu, and Zimo Liu. 2020. "Pose-Guided Visible Part Matching for Occluded Person Re-Identification." *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, 11741–49.
<https://doi.org/10.1109/CVPR42600.2020.01176>.
- Giancola, Silvio , Anthony Cioppa, Adrien Deliege, Floriane Magera, and Vladimir Somers. 2022. "SoccerNet 2022 Challenges Results." *Likely Part of the Proceedings of a Relevant Computer Vision Workshop or Journal Related to SoccerNet 2022*, October, 75–86.
- Gisma University. 2024. "How Will AI Be Used at the Football European Championships This Summer?" Gisma. June 14, 2024.
<https://www.gisma.com/blog/how-will-ai-be-used-at-the-football-european-championships-this-summer>.
- Hoffer, Elad , and Nir Ailon. 2015. "Deep Metric Learning Using Triplet Network." *Proceedings of the International Conference on Learning Representations (ICLR)*, 1–3.
- Huang, Shao-Kang , Chen-Chien Hsu, and Wei-Yen Wang. 2022. "Person Re-Identification with Improved performance by Incorporating Focal Tversky Loss in AGW Baseline." *Sensor* 22 (24).
<https://doi.org/10.3390/s22249852>.
- Ibrahim, Ahmad Abdullahi. 2016. "Definition, Purpose, and Procedure of Developmental Research: An Analytical Review." *Asian Research Journal of Arts & Social Sciences* 1 (6): 1–6.
<https://doi.org/10.9734/ARJASS/2016/30478>.
- Ipsos. 2022. "More than Half of Adults across 34 Countries Plan to Watch the 2022 FIFA World Cup." Ipsos. November 10, 2022.

<https://www.ipsos.com/en-nl/more-half-adults-across-34-countries-plan-watch-2022-fifa-world-cup>.

- Istasse, Maxime, Julien Moreau, and Christophe De Vleeschouwer. 2019. "Associative Embedding for Team Discrimination." *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*.
- Jyothi, D. Naga, N. Vivek Vardhan, G. Harish Reddy, and B. Prashanth. 2024. "Collaborative Training of Object Detection and Re-Identification in Multi-Object Tracking Using YOLOv8." *Proceedings of the 2024 International Conference on Computing and Data Science (ICCDs-2024)*. <https://doi.org/10.1109/ICCDs60734.2024.10560451>.
- Ke, Lipeng, Ming-Ching Chang, Honggang Qi, and Siwei Lyu. 2018. "Multi-Scale Structure-Aware Network for Human Pose Estimation," September.
- Koshkina, Maria, Hemanth Pidaparthi, and James H. Elder. 2021. "Contrastive Learning for Sports Video: Unsupervised Player Classification." *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, May, 4528–36. arxiv:2104.10068v2.
- Kreiss, Sven, Lorenzo Bertoni, and Alexandre Alahi. 2019. "PifPaf: Composite Fields for Human Pose Estimation." *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, March, 11969–78.
- Kuang, Zhanghui, Hongbin Sun, Zhizhong Li, and Xiaoyu Yue. 2021. "MMOCR: A Comprehensive Toolbox for Text Detection, Recognition and Understanding." *Proceedings of the 29th ACM International Conference on Multimedia (MM '21)*, October. <https://doi.org/10.1145/3474085.3478328>.
- Lin, Tsung-Yi, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. 2017. "Focal Loss for Dense Object Detection." *Proceedings of the IEEE*

- International Conference on Computer Vision (ICCV)*, 2999–3007.
<https://doi.org/10.1109/ICCV.2017.324>.
- Liu, Chen , Xiaomeng Dong, Michael Potter, Hsi-Ming Chang, and Ravi Soni. 2022. “Adversarial Focal Loss: Asking Your Discriminator for Hard Examples.”
- Liu, Hengyue , and Bir Bhanu. 2019. “Pose-Guided R-CNN for Jersey Number Recognition in Sports.” *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2457–66.
<https://doi.org/10.1109/CVPRW.2019.00301>.
- Luo, Wenhan , Junliang Xing, Anton Milan, Xiaoqin Zhang, Wei Liu, and Tae-Kyun Kim. 2022. “Multiple Object Tracking: A Literature Review.” *ArXiv.org*, February.
- Mansourian, Amir M. , Vladimir Somers, Christophe De Vleeschouwer, and Shohreh Kasaei. 2023. “Multi-Task Learning for Joint Re-Identification, Team Affiliation, and Role Classification for Sports Visual Tracking.” *Proceedings of the 6th International Workshop on Multimedia Content Analysis in Sports (MMSports '23)*, October, 103–12.
<https://doi.org/10.1145/3606038.3616172>.
- Mardanih, Dani. 2024. “Ranking FIFA Timnas Indonesia Naik, Jadi Yang Terbaik Sejak 14 Tahun Terakhir.” *Merdeka.com*. *Merdeka.com*. November 29, 2024.
<https://www.merdeka.com/trending/ranking-fifa-timnas-indonesia-naik-jadi-yang-terbaik-sejak-14-tahun-terakhir-246998-mvk.html?page=4>.
- Newell, Alejandro , Kaiyu Yang, and Jia Deng. 2016. “Stacked Hourglass Networks for Human Pose Estimation,” July.
- Nielsen Company. 2022. “Nielsen World Football Report 2022.” *Www.nielsen.com*. New York: Nielsen Company (US), LLC.
<https://www.nielsen.com/wp-content/uploads/sites/2/2022/07/Nielsen-World-Football-Report-2022.pdf>.

- Peng, Yunjie , Saihui Hou, Chunshui Cao, Xu Liu, Yongzhen Huang, and Zhiqiang He. 2021. "Deep Learning-Based Occluded Person Re-Identification: A Survey," August.
- Rauf, A. 2024. "Pemerintah Dan Swasta Kolaborasi Dorong Pertumbuhan Fasilitas Olahraga." Antara News. ANTARA. June 19, 2024. <https://www.antaranews.com/berita/4158987/pemerintah-dan-swasta-kolaborasi-dorong-pertumbuhan-fasilitas-olahraga>.
- Redmon, Joseph , Santosh Divvala, Ross Girshick, and Ali Farhadi. 2016. "You Only Look Once: Unified, Real-Time Object Detection," May.
- Rifki Wuda Sudirman. 2022. "5 Teknologi Dan Inovasi Dalam FIFA World Cup Qatar 2022TM." IDN Times. November 23, 2022. <https://www.idntimes.com/tech/trend/rifki-wuda-sudirman/teknologi-dan-inovasi-dalam-fifa-world-cup2022?page=all>.
- shaputrabisnis. 2024. "AI Dan Sepak Bola: Penggunaan AI Dalam Analisis - Aikreatif.net." Aikreatif.net. January 13, 2024. <https://aikreatif.net/2024/01/13/ai-sepakbola/>.
- Somers, Vladimir , Christophe De Vleeschouwer, and Alexandre Alahi. 2023. "Body Part-Based Representation Learning for Occluded Person Re-Identification." *2023 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 1613–23. <https://doi.org/10.1109/WACV56688.2023.00166>.
- Sun, Ke , Bin Xiao, Dong Liu, and Jingdong Wang. 2019. "Deep High-Resolution Representation Learning for Human Pose Estimation." *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://doi.org/10.1109/CVPR.2019.00584>.
- Syahreza, Zachrandika Alif . 2023. "Smart Football: Penerapan Object Detection Untuk Mengidentifikasi Objek Pada Video Pertandingan Sepak Bola," August.

- Terven, Juan R., and Diana M. Cordova-Esparza. 2024. "A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS." *Machine Learning and Knowledge Extraction*, February. <https://doi.org/10.3390/make5040083>.
- Vat, Kanav , Pascale Walters, Mehrnaz Fani, David A. Clausi, and John S. Zelek. 2015. "Player Tracking and Identification in Ice Hockey." *Journal of LaTeX Class Files* 14 (8).
- Vats, Kanav , Mehrnaz Fani, David A. Clausi, and John Zelek. 2021. "Multi-Task Learning for Jersey Number Recognition in Ice Hockey." *Proceedings of the 4th International Workshop on Multimedia Content Analysis in Sports (MMSports '21)*, October.
- Wahyu Pratama. 2023. "Pembangunan Infrastruktur Sepak Bola Nasional Kunci Kemajuan Prestasi Timnas Indonesia." *Bola.com*, January. <https://doi.org/1025152808.desktop.bola.indonesia.liga1>.
- Wang, Jingdong , Ke Sun, Tianheng Cheng, Borui Jiang, Chaorui Deng, Yang Zhao, Dong Liu, dkk. 2020. "Deep High-Resolution Representation Learning for Visual Recognition." *IEEE Transactions on Pattern Analysis and Machine Intelligence* 42 (10): 1–12. <https://doi.org/10.1109/TPAMI.2020.2978596>.
- Wojke, Nicolai , Alex Bewley, and Dietrich Paulus. 2017. "Simple Online and Realtime Tracking with a Deep Association Metric." *Proceedings of the 2017 IEEE International Conference on Image Processing (ICIP)*, 3645–49. <https://doi.org/10.1109/ICIP.2017.8296962>.
- Wu, Qing , Yungang Liu, Qiang Li, Shaoli Jin, and Fengzhong Li. 2024. "The Application of Deep Learning in Computer Vision." *Published as Part of IEEE Proceedings or Associated Publications*.
- Yang, Fan , Shigeyuki Odashima, Shoichi Masui, and Shan Jiang. 2023. "Hard to Track Objects with Irregular Motions and Similar Appearances? Make It Easier by Buffering the Matching Space." *Proceedings of the IEEE/CVF*

Winter Conference on Applications of Computer Vision (WACV), 4799–4808.

Ye, Mang , Jianbing Shen, Gaojie Lin, Tao Xiang, Ling Shao, and Steven C. H. Hoi. 2022. “Deep Learning for Person Re-Identification: A Survey and Outlook.” *IEEE Transactions on Pattern Analysis and Machine Intelligence* 44 (6): 2872–85. <https://doi.org/10.1109/TPAMI.2021.3054775>.

Zandycke, Gabriel , Vladimir Somers, Maxime Istasse, Carlo Del Don, and Davide Zambrano. 2022. “EepSportradar-V1: Computer Vision Dataset for Sports Understanding with High-Quality Annotations.” *Proceedings of the 5th International ACM Workshop on Multimedia Content Analysis in Sports (MMSports '22)*, October. <https://doi.org/10.1145/3552437.3555699>.

Zhang, Guoqing , Yu Ge, Zhicheng Dong, Hao Wang, Yuhui Zheng, and Shengyong Chen. 2021. “Deep High-Resolution Representation Learning for Cross-Resolution Person Re-Identification.” *IEEE Transactions on Image Processing* 30 (October): 8913–24. <https://doi.org/10.1109/TIP.2021.3120054>.

Zhang, Peng, Weimin Lei, Wei Zhang, Zhaonan Lin, Xinlei Zhao, Zhichao Li, and Lijia Dong. 2024. “A Computer Vision Based Warning and Behavior Analysis System for Large Passenger Flow in Stations.” *Proceedings of the 2024 8th International Conference on Management Engineering, Software Engineering and Service Sciences (ICMSS)*, pp. 126-132. <https://doi.org/10.1109/ICMSS61211.2024.00030>.

Zhu, Kuan , Haiyun Guo, Zhiwei Liu, Ming Tang, and Jinqiao Wang. 2020. “Identity-Guided Human Semantic Parsing for Person Re-Identification.” *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)* 12348 LNCS (July): 346–63. https://doi.org/10.1007/978-3-030-58580-8_21.

LAMPIRAN

Lampiran A. Repositori GitHub Re-Identification

Repositori GitHub	github.com/Riandra4trend/FootballMatchAnalysis.git
-------------------	---

Lampiran B. Artefak Model Hasil Pelatihan dan Video hasil Pemrosesan

Artefak Hasil Video dan Model	https://bit.ly/ArtefakHasilVideodanModel
-------------------------------	---

Lampiran C. Dokumentasi Wawancara Terkait Kebutuhan Pengguna

Wawancara Kebutuhan Pengguna	https://bit.ly/MeetingKebutuhanUser
------------------------------	---