

**MITIGASI HALUSINASI PADA *RAG-LLM*
BIOMEDIS MENGGUNAKAN EKSPANSI
AKRONIM, *QUERY REWRITING*, DAN *CONTEXT*
*RERANKING***

Laporan Tugas Akhir

Oleh

**Ricky Wijaya
18222043**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG**

Juni 2026

LEMBAR PENGESAHAN

MITIGASI HALUSINASI PADA *RAG-LLM* BIOMEDIS MENGUNAKAN EKSPANSI AKRONIM, *QUERY* *REWRITING*, DAN *CONTEXT RERANKING*

Laporan Tugas Akhir

Oleh

Ricky Wijaya
18222043

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Laporan Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 8 Juni 2026

Pembimbing



Dr. Fetty
Fitriyanti Lubis
2026.06.08
14:50:40+07'00'

Dr. Fetty Fitriyanti Lubis, S.T., M.T.

NIP. 118110071

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenar-benarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan tugas akhir ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan laporan tugas akhir.
3. Isi laporan ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 8 Juni 2026



Ricky Wijaya
NIM: 18222043

PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan dokumen Tugas Akhir ini, saya menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu di dalam proses penulisan, seperti yang tercantum dalam tabel berikut.

No.	Jenis	Alat Bantu	Tingkat	Tempat
1	Memeriksa ejaan dan tata bahasa	Claude	Tinggi	Seluruh bab
2	Pembuatan teks	Claude	Sedang	Bab II - Bab V
3	Pembuatan grafik, gambar, atau ilustrasi	Claude	Rendah	Bab VI (grafik visualisasi hasil eksperimen)
4	Pencarian informasi atau referensi	Claude	Rendah	Bab II
5	Penyusunan bahan diskusi	Claude	Sedang	Bab IV dan Bab V
6	Penyusunan kode program	Claude	Rendah	Bab V
7	Penyusunan formula atau perhitungan matematis	Claude	Rendah	Bab II dan Bab VI
8	Penyusunan konsep desain atau algoritma	Claude	Rendah	Bab IV dan Bab V
9	Penyusunan analisis data	Tidak ada	Tidak ada	Tidak ada
10	Penyusunan kesimpulan atau rekomendasi	Tidak ada	Tidak ada	Tidak ada

Bandung, 8 Juni 2026



Ricky Wijaya

NIM: 18222043

ABSTRAK

Mitigasi Halusinasi pada RAG-LLM Biomedis Menggunakan Ekspansi Akronim, *Query Rewriting*, dan *Context Reranking*

oleh

Ricky Wijaya

18222043

Large Language Models (LLM) telah banyak digunakan untuk tanya jawab informasi biomedis, namun rentan menghasilkan halusinasi, yaitu jawaban yang terlihat meyakinkan tetapi tidak didukung sumber yang valid. Pendekatan *Retrieval-Augmented Generation* (RAG) ditawarkan untuk mengurangi halusinasi dengan menyertakan dokumen relevan sebagai konteks, namun kualitas jawaban masih bergantung pada keberhasilan tahap *retrieval*. Pada domain biomedis, sistem RAG menghadapi tantangan tambahan berupa *vocabulary mismatch*, yaitu ketidakcocokan antara istilah panjang yang dipakai pengguna dengan akronim yang umum tertulis pada dokumen ilmiah.

Penelitian ini bertujuan merancang, mengimplementasikan, dan menganalisis sistem mitigasi halusinasi pada RAG-LLM yang menggabungkan tiga teknik komplementer, yaitu **ekspansi akronim** sebagai praproses dokumen, ***query rewriting*** untuk memperkaya kueri pengguna, dan ***context reranking*** untuk memilih konteks yang paling relevan sebelum tahap *generation*. Sistem diuji pada *dataset* PubMedQA dengan korpus 1.000 paper biomedis dan 500 pertanyaan evaluasi menggunakan empat model LLM, yaitu Llama 3.2, Llama 3.3 70B, GPT-4.1-mini, dan Claude Haiku 4.5.

Hasil evaluasi menunjukkan bahwa ekspansi akronim meningkatkan kinerja *retrieval* secara konsisten, yaitu *Recall@5* naik dari 78,65% menjadi 84,96%, *MAP@5* dari 75,32% menjadi 82,47%, dan *nDCG@5* dari 83,08% menjadi 88,45%. Teknik *context reranking* juga konsisten meningkatkan akurasi pada seluruh model LLM yang diuji sebesar 1–3 poin persentase. Konfigurasi terbaik yang menggabungkan ekspansi akronim, *query rewriting*, dan *context reranking* pada GPT-4.1-mini mencapai *accuracy* 74,8% dan *faithfulness* 0,980. Secara keseluruhan, hasil eksperimen menunjukkan bahwa kombinasi ketiga teknik mampu menurunkan *hallucination rate* dari 34,6% menjadi 25,2% sekaligus meningkatkan kualitas jawaban sistem tanya jawab biomedis.

Kata kunci: *Large Language Models*, *Retrieval-Augmented Generation*, Mitigasi Halusinasi, Sistem Tanya Jawab Biomedis, Ekspansi Akronim, *Query Rewriting*, *Context Reranking*.

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa karena atas rahmat dan karunia-Nya, penulis dapat menyelesaikan penulisan Laporan Tugas Akhir yang berjudul “*Mitigasi Halusinasi pada RAG-LLM Biomedis Menggunakan Ekspansi Akronim, Query Rewriting, dan Context Reranking*”. Penyusunan Tugas Akhir ini dilakukan sebagai salah satu syarat untuk memperoleh gelar Sarjana pada Program Studi Sistem dan Teknologi Informasi, Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung.

Selama proses penyusunan, penulis memperoleh banyak bantuan, dukungan, bimbingan, serta doa dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis ingin menyampaikan rasa terima kasih yang sebesar-besarnya kepada:

1. Tuhan Yesus, terima kasih atas penyertaan-Mu yang tidak pernah berhenti di setiap musim kehidupan penulis. Engkaulah sumber kekuatan dan pengharapan yang selalu menuntun penulis di saat tidak tahu arah. Penulis menyadari sepenuhnya bahwa: *all of this is because of You, thank You Jesus!*
2. Kedua orang tua penulis, yang telah mendidik dan membesarkan penulis sedari kecil dan selalu menjadi sumber motivasi penulis untuk menyelesaikan tugas akhir ini. Terima kasih atas segala pengorbanan, doa yang tidak pernah putus, dan kasih sayang yang tidak dapat dibalaskan oleh penulis. Tanpa kehadiran kalian, mungkin langkah penulis takkan pernah sampai sejauh ini.
3. Dr. Fetty Fitriyanti Lubis, S.T., M.T., selaku dosen pembimbing yang senantiasa meluangkan waktu, memberikan arahan, bimbingan, dan masukan yang tidak ternilai selama proses penyusunan Tugas Akhir ini.
4. I Gusti Bagus Baskara Nugraha, S.T., M.T., Ph.D., selaku Ketua Program Studi Sistem dan Teknologi Informasi, atas kepemimpinannya sehingga STI dapat menjadi tempat aman untuk mahasiswa berkembang dan belajar.
5. Dr. Riza Satria Perdana, S.T., M.T., selaku dosen wali penulis, atas perhatian dan ajarannya yang selalu mengingatkan untuk hidup jujur dan berkontribusi bagi bangsa dan negara ini.
6. Teman-teman dari TPB penulis, David dan Nicolaas, yang selalu menjadi tempat berbagi keluh kesah selama perjalanan 182 ini dan selalu memberikan ilmunya tanpa pamrih sehingga perjalanan yang berat selama di jurusan ini terasa sedikit lebih ringan. Kehadiran kalian telah memberi warna, kekuatan, dan semangat dalam perjalanan panjang ini.

7. Teman-teman kos penulis, Arvyno dan Bastian, yang selalu menjadi pelarian penulis dengan bermain *Valorant* bersama dan makan nasi goreng dikala sedih dan pusing dalam perkuliahan ini.
8. *Happy Family*, Nasywaa, Naomi, dan Micky. Terima kasih sudah menjadi teman diskusi, lomba, bermain, begadang, dan kulineran di Bandung. Pengalaman di Kasumba takkan pernah dilupakan oleh penulis.
9. Teman-teman seperjuangan penulis, Pica, Allesandro, Dedy, Valdi, Harry, Corne, Elen, Thalitha, Tamara, Angie, teman-teman Lab Basis Data — Yovanka, Anin, Clement, Dama, Jihan, dan teman-teman lain yang telah kebersamai perjalanan penulis selama masa perkuliahan. Bersama kalian, hari-hari di kampus berubah menjadi cerita yang layak dikenang.
10. Velicia Christina Gabriel, yang selalu menjadi pendengar keluh kesah disaat penulis lelah dan memberikan semangat serta dukungan moral kepada penulis. Terima kasih sudah menjadi motivasi penulis untuk menjadi lebih baik setiap harinya.
11. Adik asuh penulis, Persada, Jennie, dan Izhar. Terima kasih sudah memilih penulis menjadi kakak asuh kandung maupun angkat. Terima kasih sudah menjadi orang yang dapat diandalkan di kala penulis jenuh dan sering memberikan tempat untuk penulis menginap dikala pengerjaan tugas akhir ini.
12. Teman-teman *orgilers*, teman-teman Tahap Persiapan Bersama (TPB) penulis di tahun pertama. Terima kasih sudah mengajak berkeliling dan kulineran di Bandung serta membuat penulis tidak *homesick* pada awal masa perantauan.
13. Sambat, Ghina, Azis, Osamah. Terima kasih sudah menemani penulis dari masa TPB sebagai teman perantauan yang sering mendengarkan cerita walaupun cerita mungkin tidak menarik untuk didengar.
14. Kak Rian, Kak Ariq, dan Kak Angie. Terima kasih atas bimbingan dan segala macam berkas tugas dan ujian dari kakak-kakak sampai bimbingan karirnya. Kalian bukan sekadar kakak tingkat, tapi bagian dari perjalanan yang akan selalu hidup dalam ingatan penulis.
15. Seluruh pihak yang tidak dapat penulis sebutkan satu per satu, namun telah memberikan dukungan baik secara langsung maupun tidak langsung hingga laporan ini selesai.

Penulis menyadari bahwa laporan Tugas Akhir ini masih memiliki berbagai keterbatasan dan belum sepenuhnya sempurna. Oleh karena itu, penulis dengan terbuka menerima segala kritik dan saran yang bersifat membangun sebagai bahan evaluasi dan perbaikan di masa mendatang. Besar harapan penulis agar Tugas Akhir ini dapat memberikan manfaat bagi para pembaca serta memberikan kontribusi, sekecil

apa pun, bagi perkembangan ilmu pengetahuan. Akhir kata, penulis mengucapkan terima kasih yang sebesar-besarnya kepada seluruh pihak yang telah memberikan dukungan, bantuan, dan doa selama proses penyusunan Tugas Akhir ini. Semoga segala kebaikan yang telah diberikan mendapatkan balasan yang berlimpah dari Tuhan Yang Maha Esa.

Bandung, 8 Juni 2026

Penulis,

A handwritten signature in black ink, consisting of a large, stylized 'R' followed by a horizontal line and a small flourish at the end.

Ricky Wijaya

DAFTAR ISI

LEMBAR PENGESAHAN	iii
PERNYATAAN ORISINALITAS	v
PERNYATAAN PENGGUNAAN AI	vii
ABSTRAK	ix
KATA PENGANTAR	xi
DAFTAR ISI	xv
DAFTAR GAMBAR	xix
DAFTAR TABEL	xxi
DAFTAR PERSAMAAN	xxiii
DAFTAR ALGORITMA	xxv
DAFTAR <i>LISTING</i>	xxvii
DAFTAR SIMBOL	xxix
DAFTAR SINGKATAN	xxx
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	3
I.3 Tujuan	3
I.4 Batasan Masalah	4
I.5 Metodologi Tugas Akhir	5
I.5.1 <i>Business Understanding</i>	6
I.5.2 <i>Data Understanding</i>	6
I.5.3 <i>Data Preparation</i>	6
I.5.4 <i>Modeling</i>	6
I.5.5 <i>Evaluation</i>	6
I.5.6 <i>Deployment</i>	6
II STUDI LITERATUR	9
II.1 <i>Large Language Model (LLM)</i>	9
II.1.1 <i>Retrieval-Augmented Generation</i>	10
II.1.2 Halusinasi atau Konfabulasi pada <i>Large Language Models</i>	12
II.2 Mitigasi Halusinasi pada <i>Retrieval-Augmented Generation</i>	17
II.2.1 Kerangka RAG dan Titik Munculnya Halusinasi	18
II.2.2 Mitigasi Halusinasi pada Tahap <i>Retrieval</i>	19
II.2.2.1 Perbaikan Kueri dan <i>Query Rewriting</i>	19
II.2.2.2 Peningkatan Kualitas <i>Retriever</i> dan <i>Re-ranking</i>	20
II.2.2.3 Seleksi dan Kompresi Konteks	20
II.2.3 Mitigasi pada Tahap Integrasi Pengetahuan	20
II.2.4 Mitigasi Halusinasi pada Tahap <i>Generation</i>	21
II.2.4.1 <i>Prompt Engineering</i> dan Strategi Penalaran	21
II.2.4.2 Verifikasi Jawaban dan <i>Active Detection</i>	21
II.3 Ekspansi Akronim Dokumen pada Sistem RAG	22

II.4	BM25 sebagai Algoritma <i>Retrieval</i> Klasik	23
II.5	<i>Dense Retrieval</i> dan Pencarian Berbasis Vektor	24
II.6	<i>Query Rewriting</i> untuk Mitigasi Halusinasi pada RAG	25
II.7	<i>Context Reranking</i> untuk Mengurangi Kebisingan	26
II.8	<i>Active Detection</i> untuk Mitigasi Halusinasi	28
II.8.1	Prinsip Dasar <i>Active Detection</i>	29
II.8.2	Alur Kerja <i>Active Detection</i>	29
II.8.3	Kelebihan Metode <i>Active Detection</i>	29
II.8.4	Keterbatasan	30
II.9	<i>Prompt Engineering</i> untuk Reduksi Halusinasi	30
II.9.1	<i>Zero-shot</i> dan <i>few-shot prompting</i>	32
II.10	Kerangka Kerja Evaluasi Sistem <i>Retrieval-Augmented Generation</i> (RAG)	32
II.10.1	Metrik Evaluasi <i>Retrieval</i>	33
II.10.1.1	<i>Recall@k</i>	33
II.10.1.2	<i>Mean Average Precision</i> (MAP@k)	33
II.10.1.3	<i>Normalized Discounted Cumulative Gain</i> (nDCG@k)	34
II.10.2	Kerangka Kerja RAGAS untuk Evaluasi <i>Generation</i>	35
II.10.2.1	Faithfulness	36
II.10.2.2	Context Recall	36
II.11	Justifikasi Pemilihan Teknik Mitigasi	37
III	ANALISIS MASALAH	41
III.1	Analisis Kondisi Saat Ini	41
III.2	Analisis Kebutuhan	46
III.3	Analisis Pemilihan Solusi	48
III.3.1	Alternatif Solusi	48
III.3.1.1	Alternatif Solusi I: Penguatan Tahap <i>Retrieval</i> (<i>Query Rewriting</i> , <i>Query Expansion</i> , dan <i>Embedding</i>)	48
III.3.1.2	Alternatif Solusi II: Penguatan Tahap <i>Generation</i> melalui <i>Middle Information</i> , <i>Context Reranking</i> , dan <i>Balance Internal and External Knowledge</i>	50
III.3.1.3	Alternatif Solusi III: <i>Multiple-Phase Mitigation</i> (Ekspansi Akronim, <i>Query Rewriting</i> , dan <i>Context Reranking</i>)	51
III.3.2	Analisis Penentuan Solusi	52
IV	RANCANGAN SISTEM MITIGASI HALUSINASI RAG-LLM UNTUK SISTEM TANYA JAWAB BIOMEDIS	57
IV.1	Gambaran Umum Sistem	57
IV.2	Desain Arsitektur Sistem	58
IV.2.1	Data Preparation	59
IV.2.1.1	Analisis Kelengkapan Section pada Korpus	61
IV.2.1.2	Contoh Entri Korpus	62

IV.2.2	Praproses Dokumen: Ekspansi Akronim Schwartz-Hearst	64
IV.2.3	Komponen <i>Retrieval</i>	65
IV.2.3.1	BM25 (<i>Sparse Retrieval</i>)	65
IV.2.3.2	<i>Dense Retrieval</i>	65
IV.2.3.3	<i>Hybrid Retrieval</i> dengan <i>Reciprocal Rank Fusion</i> (RRF)	66
IV.2.4	<i>Query Rewriting</i> (QR)	66
IV.2.5	<i>Context Reranking</i> (CR)	67
IV.2.6	Komponen <i>Generation</i>	67
IV.3	Konfigurasi Sistem	68
IV.3.1	Kelompok 1: BM25 tanpa Ekspansi Akronim	69
IV.3.1.1	Baseline	69
IV.3.1.2	Baseline + Query Rewriting	70
IV.3.1.3	Baseline + Context Reranking	70
IV.3.1.4	Baseline + Query Rewriting + Context Reranking	70
IV.3.2	Kelompok 2: <i>Hybrid Retrieval</i> tanpa Ekspansi Akronim	71
IV.3.3	Kelompok 3: <i>Hybrid Retrieval</i> dengan Ekspansi Akronim	72
IV.3.4	Ringkasan Konfigurasi	74
IV.4	Opsi Model	74
IV.5	Hyperparameter dan Setup Eksperimen	75
V	IMPLEMENTASI	79
V.1	Lingkungan Implementasi	79
V.1.1	Spesifikasi Perangkat Keras dan Perangkat Lunak	80
V.1.2	Konfigurasi Layanan API dan Basis Data	81
V.1.3	Struktur dan Organisasi Repositori	83
V.2	Implementasi Pipeline Pengolahan Data	85
V.2.1	Pra-pemrosesan Korpus PubMedQA	85
V.2.2	Implementasi Ekspansi Akronim Schwartz-Hearst	85
V.2.3	Pembangunan Indeks BM25 dan Vektor	87
V.3	Implementasi Komponen Retrieval	88
V.3.1	BM25	88
V.3.2	<i>Dense Retrieval</i>	90
V.3.3	<i>Hybrid Retrieval</i> dengan <i>Reciprocal Rank Fusion</i>	91
V.4	Implementasi Komponen Mitigasi Halusinasi	93
V.4.1	Implementasi Query Rewriting	93
V.4.2	Implementasi Context Reranking	94
V.5	Implementasi Komponen Generation dan Kerangka Evaluasi	96
V.5.1	Implementasi Tahap Generation	96
V.5.2	Implementasi Kerangka Evaluasi	96
V.6	Prototipe Antarmuka Demonstrasi	97
V.6.1	Arsitektur Prototipe	97
V.6.2	Mekanisme Guard Rail Keyakinan	98
VI	EVALUASI	101
VI.1	Metode Evaluasi	101

VI.1.1	Lingkup Evaluasi dan Himpunan Uji	101
VI.1.2	Metrik Kuantitatif	101
VI.1.3	Skema Konfigurasi Pengujian	102
VI.2	Hasil dan Pembahasan	102
VI.2.1	Ringkasan Metrik Seluruh Konfigurasi	102
VI.2.2	Hybrid Search: Kombinasi BM25 dan Dense Retrieval .	104
VI.2.3	Ekspansi Akronim	106
VI.2.4	Query Rewriting	107
VI.2.5	Context Reranking	108
VI.2.6	Efek Kumulatif terhadap Akurasi	109
VI.2.7	Hallucination Rate pada Dua Belas Konfigurasi	110
VI.2.8	Estimasi Waktu Tanggap dan Biaya Komputasi	111
VI.2.9	Analisis Kasus Kegagalan	113
VI.2.10	Identifikasi Jenis Halusinasi	117
VI.2.11	Validitas Eksperimen	119
VII	PENUTUP	121
VII.1	Kesimpulan	121
VII.2	Saran	122
Lampiran A	PROMPT SISTEM	131
A.1	<i>Prompt</i> Generation Jawaban Biomedis	131
A.2	<i>Prompt</i> Query Rewriting	132
A.3	Parameter Pemanggilan Model Bahasa	133
Lampiran B	DATASET DAN KORPUS	135
B.1	Dataset PubMedQA	135
B.2	Korpus dengan Ekspansi Akronim	136
Lampiran C	EVALUASI LINTAS-MODEL	139
C.1	Pengaruh QR, CR, dan QR+CR pada Berbagai Model	139
C.2	Perbandingan Model <i>Open-Source</i> Lokal dengan Model Berbayar	140
Lampiran D	DEMONSTRASI GUARD RAIL PROTOTIPE	143
Lampiran E	CONTOH KELUARAN SISTEM PER KONFIGURASI .	145
E.1	Kelompok 1: BM25 tanpa Ekspansi Akronim	145
E.2	Kelompok 2: Hybrid Retrieval tanpa Ekspansi Akronim	152
E.3	Kelompok 3: Hybrid Retrieval dengan Ekspansi Akronim	158

DAFTAR GAMBAR

I.1	Tahapan Metodologi CRISP-DM	5
II.1	Alur <i>Retrieval-Augmented Generation</i>	11
II.2	Penyebab dan solusi halusinasi pada RAG-LLM	18
II.3	Alur kerja <i>context reranking</i> pada sistem RAG	27
III.1	Alur sistem <i>retrieval augmented generation</i> (RAG) saat ini	42
IV.1	Diagram alur sistem RAG-LLM untuk mitigasi halusinasi	58
IV.2	Ilustrasi <i>Section-Based Chunking</i> pada Abstrak Paper PubMedQA	60
IV.3	Persentase Kelengkapan <i>Section</i> per Paper pada Korpus PubMedQA ($n=1.000$ paper)	61
IV.4	Contoh Entri Korpus pada Basis Data <i>Retriever</i>	63
IV.5	Diagram Alur <i>Pipeline</i> Konfigurasi BM25 <i>Baseline</i>	69
IV.6	Diagram Alur <i>Pipeline</i> Konfigurasi BM25 + <i>Query Rewriting</i>	70
IV.7	Diagram Alur <i>Pipeline</i> Konfigurasi BM25 + <i>Context Reranking</i>	70
IV.8	Diagram Alur <i>Pipeline</i> Konfigurasi BM25 + <i>Query Rewriting</i> + <i>Context Reranking</i>	71
IV.9	Diagram Alur <i>Pipeline</i> Konfigurasi <i>Hybrid Baseline</i> (tanpa Ekspan- si Akronim)	71
IV.10	Diagram Alur <i>Pipeline</i> Konfigurasi <i>Hybrid</i> + <i>Query Rewriting</i> (tanpa Ekspansi Akronim)	71
IV.11	Diagram Alur <i>Pipeline</i> Konfigurasi <i>Hybrid</i> + <i>Context Reranking</i> (tanpa Ekspansi Akronim)	72
IV.12	Diagram Alur <i>Pipeline</i> Konfigurasi <i>Hybrid</i> + <i>Query Rewriting</i> + <i>Context Reranking</i> (tanpa Ekspansi Akronim)	72
IV.13	Diagram Alur <i>Pipeline</i> Konfigurasi <i>Hybrid Baseline</i> (dengan Eks- pansi Akronim)	73
IV.14	Diagram Alur <i>Pipeline</i> Konfigurasi <i>Hybrid</i> + <i>Query Rewriting</i> (dengan Ekspansi Akronim)	73
IV.15	Diagram Alur <i>Pipeline</i> Konfigurasi <i>Hybrid</i> + <i>Context Reranking</i> (dengan Ekspansi Akronim)	73

IV.16	Diagram Alur <i>Pipeline</i> Konfigurasi <i>Hybrid</i> + <i>Query Rewriting</i> + <i>Context Reranking</i> (dengan Ekspansi Akronim)	73
V.1	Antarmuka penuh prototipe BioRAG dengan panel riwayat, area percakapan, dan panel transparansi <i>pipeline</i>	98
V.2	Tampilan detail percakapan beserta penanda tingkat keyakinan jawaban	98
VI.1	Perbandingan akurasi label antara BM25 saja dengan <i>Hybrid Retrieval</i> pada GPT-4.1-mini	105
C.1	Perbandingan akurasi label pada tiga model untuk empat konfigurasi mitigasi	140
C.2	Perbandingan akurasi label antara Llama 3.2 3B (lokal) dengan tiga model berbayar berskala besar	141
D.1	Perilaku <i>guard rail</i> pada pertanyaan di luar cakupan korpus: skor keyakinan rendah (16%) sehingga pemanggilan LLM dilewati . . .	144

DAFTAR TABEL

II.1	Contoh berbagai jenis halusinasi pada <i>Large Language Models (LLM)</i>	13
III.1	Contoh <i>Retrieval Failure</i> akibat <i>Vocabulary Mismatch</i>	43
III.2	Perbandingan Dataset Kandidat	44
III.3	Kebutuhan Fungsional Sistem RAG-LLM untuk Mitigasi Halusinasi	47
III.4	Kebutuhan Nonfungsional Sistem RAG-LLM untuk Mitigasi Halusinasi	48
III.5	Kalkulasi <i>weighted scoring</i> pada alternatif solusi mitigasi halusinasi	54
IV.1	Ringkasan Konseptual Penambahan Komponen Sistem	69
IV.2	Ringkasan Konfigurasi Sistem RAG-LLM yang Dirancang	74
IV.3	Opsi model dalam implementasi sistem RAG-LLM	75
IV.4	Hyperparameter dan setup eksperimen	76
V.1	Ringkasan Perangkat Keras dan Perangkat Lunak yang Digunakan pada Penelitian	81
V.2	Ringkasan Konfigurasi Layanan API Eksternal dan Basis Data Lokal	83
V.3	Struktur Direktori Utama Repositori Sistem	84
V.4	Contoh Hasil Ekspansi Akronim pada Teks <i>Chunk</i> Dokumen	86
V.5	Ilustrasi Skor BM25 untuk Kueri “hyperbaric oxygenation mortality treatment” pada Tiga <i>Chunk</i> Kandidat	89
V.6	Ilustrasi Skor <i>Cosine Similarity</i> untuk Kueri “Does physical activity reduce postnatal depression?” pada Tiga <i>Chunk</i> Kandidat	91
V.7	Ilustrasi Penggabungan Peringkat dengan <i>Reciprocal Rank Fusion</i> ($k = 60$); kolom BM25 dan <i>Dense</i> menunjukkan peringkat dokumen pada masing-masing daftar	93
V.8	Contoh Hasil <i>Query Rewriting</i> pada Beberapa Pertanyaan Pengguna	94
V.9	Ilustrasi Peringkat Dokumen Sebelum dan Sesudah <i>Context Reranking</i>	95
V.10	Tingkat Keyakinan, Ambang Skor Komposit, dan Perilaku Sistem	99
V.11	Contoh Perhitungan Skor Keyakinan untuk Pertanyaan pada Gambar V.1	100

VI.1	Metrik <i>Information Retrieval</i> pada Dua Belas Konfigurasi	103
VI.2	Metrik Kualitas Jawaban pada Dua Belas Konfigurasi (GPT-4.1-mini)	104
VI.3	Perbandingan Label Accuracy dan <i>Faithfulness</i> antara BM25 dan <i>Hybrid</i> pada GPT-4.1-mini	105
VI.4	Pengaruh Ekspansi Akronim terhadap Metrik IR pada Konfigurasi <i>Hybrid Baseline</i>	106
VI.5	Pengaruh Ekspansi Akronim terhadap Label Accuracy dan <i>Halluci- nation Rate</i> pada Konfigurasi <i>Hybrid</i> (GPT-4.1-mini)	106
VI.6	Pengaruh <i>Query Rewriting</i> terhadap Recall@5 dan Accuracy per Kelompok (GPT-4.1-mini)	107
VI.7	Pengaruh <i>Context Reranking</i> terhadap Recall@5 dan Accuracy per Kelompok (GPT-4.1-mini)	109
VI.8	Peningkatan <i>Accuracy Across</i> Konfigurasi	110
VI.9	<i>Hallucination Rate Across</i> Konfigurasi	111
VI.10	Estimasi Latensi per Komponen <i>Pipeline</i> (GPT-4.1-mini)	112
VI.11	Estimasi Waktu Tanggap dan Biaya Komputasi per Konfigurasi (GPT-4.1-mini)	112
VI.12	Contoh Perbaikan Jawaban, <i>Faithfulness</i> , dan Recall@5 antar Ke- lompok Konfigurasi	114
VI.13	Contoh Pengaruh Ekspansi Akronim terhadap Peringkat Dokumen Sumber	116
VI.14	Distribusi Tipe Kegagalan pada Konfigurasi Terbaik	117
VI.15	Contoh Halusinasi Ekstrinsik dan Perbaikannya Seiring Membaik- nya <i>Retrieval</i>	118
A.1	Parameter Pemanggilan Model Bahasa pada Tahap <i>Generation</i> dan <i>Query Rewriting</i>	134
B.1	Contoh Entri Dataset PubMedQA (Subset pqa_labeled)	136
C.1	Pengaruh QR, CR, dan QR+CR pada Tiga Model (% Mode <i>Hybrid</i> , Tanpa Ekspansi Akronim)	139
C.2	Perbandingan Label Accuracy antara Llama 3.2 3B (Lokal) dan Tiga Model Berbayar (%)	141
E.1	Lima Pertanyaan Contoh beserta Label Sebenarnya	145

DAFTAR PERSAMAAN

II.1	Skor BM25	23
II.2	<i>Inverse Document Frequency</i> (IDF) pada BM25	23
II.3	<i>Cosine Similarity</i>	24
II.4	<i>Recall@k</i>	33
II.5	<i>Average Precision</i> (AP@k)	34
II.6	<i>Mean Average Precision</i> (MAP@k)	34
II.7	<i>Discounted Cumulative Gain</i> (DCG@k)	34
II.8	<i>Ideal Discounted Cumulative Gain</i> (IDCG@k)	35
II.9	<i>Normalized Discounted Cumulative Gain</i> (nDCG@k)	35
II.10	<i>Faithfulness</i>	36
II.11	<i>Context Recall</i>	37

DAFTAR ALGORITMA

V.1	Validasi Pasangan Akronim-Kepanjangan dengan Schwartz-Hearst .	87
V.2	Penggabungan Peringkat dengan <i>Reciprocal Rank Fusion</i> (RRF) . .	92

DAFTAR *LISTING*

A.1	<i>Prompt generation</i> jawaban biomedis (GENERATION_PROMPT) .	131
A.2	Fungsi pembentuk {context} untuk diteruskan ke <i>prompt</i>	132
A.3	<i>Prompt Query Rewriting</i> dengan pendekatan <i>single-query rewriting</i>	132
A.4	Fungsi <i>rewriter single-kueri</i> (rewrite_query)	133

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama
D	Dokumen atau <i>chunk</i> pada korpus	23
Q	<i>Query</i> atau pertanyaan pengguna	23
q_i	Istilah ke- i pada <i>query</i>	23
N	Jumlah total dokumen pada korpus	23
k	Parameter <i>top-k retrieval</i> (jumlah dokumen teratas yang diambil)	23
$ D $	Panjang dokumen (jumlah <i>token</i>)	23
avgdl	Panjang dokumen rata-rata pada korpus	23
$\text{TF}(q_i, D)$	<i>Term frequency</i> istilah q_i pada dokumen D	23
$\text{IDF}(q_i)$	<i>Inverse document frequency</i> istilah q_i	23
k_1	<i>Hyperparameter</i> BM25 untuk skala saturasi <i>term frequency</i>	23
b	<i>Hyperparameter</i> BM25 untuk normalisasi panjang dokumen	23
$\text{score}_{\text{BM25}}(Q, D)$	Skor relevansi BM25 antara <i>query</i> Q dan dokumen D	23
$\vec{q}$	Vektor representasi (<i>embedding</i>) <i>query</i>	24
$\vec{d}$	Vektor representasi (<i>embedding</i>) dokumen	24
$\cos(\vec{q}, \vec{d})$	<i>Cosine similarity</i> antara vektor <i>query</i> dan dokumen	24
$\langle \vec{q}, \vec{d} \rangle$	<i>Dot product</i> antara dua vektor	24
$\ \vec{v}\ $	Norma Euclidean (L2) dari vektor $\vec{v}$	24
d	Dimensi vektor <i>embedding</i>	24

Notasi	Deskripsi	Pemakaian pertama
$\text{Recall}@k$	Proporsi dokumen relevan yang berhasil di- <i>retrieve</i> dalam k teratas	33
$\text{Precision}@k$	Proporsi dokumen relevan pada k teratas hasil <i>retrieval</i>	34
$\text{MAP}@k$	<i>Mean Average Precision</i> pada k teratas	34
$\text{DCG}@k$	<i>Discounted Cumulative Gain</i> pada k teratas	34
$\text{IDCG}@k$	<i>Ideal Discounted Cumulative Gain</i> pada k teratas	35
$\text{nDCG}@k$	<i>Normalized Discounted Cumulative Gain</i> pada k teratas	35
rel_i	Skor relevansi dokumen pada peringkat ke- i	34
F	Skor <i>Faithfulness</i> pada metrik RAGAS	36
CR_{RAGAS}	Skor <i>Context Recall</i> pada metrik RAGAS	37
S	Himpunan kalimat pada jawaban yang dievaluasi	36
$ S $	Jumlah kalimat pada jawaban	36
$\sum$	Operator penjumlahan	23
$\prod$	Operator perkalian	23
$\log$	Logaritma natural	23
$\max$	Nilai maksimum	23
argmax	Argumen yang memaksimalkan fungsi	23
$\mathbb{I}[\cdot]$	Fungsi indikator (bernilai 1 jika kondisi benar, 0 jika salah)	34
p	<i>P-value</i> statistik	23

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama
AI	<i>Artificial Intelligence</i>	48
API	<i>Application Programming Interface</i>	4
BM25	<i>Best Matching 25</i> (algoritma ranking berbasis kata kunci)	20
BMI	<i>Body Mass Index</i> (contoh akronim biomedis)	2
CHD	<i>Coronary Heart Disease</i> (contoh akronim biomedis)	2
CPU	<i>Central Processing Unit</i>	75
CR	<i>Context Reranking</i>	3
CRISP-DM	<i>Cross-Industry Standard Process for Data Mining</i>	5
DCG	<i>Discounted Cumulative Gain</i>	34
GPT	<i>Generative Pre-trained Transformer</i>	1
GPU	<i>Graphics Processing Unit</i>	75
HBO	<i>Hyperbaric Oxygen</i> (contoh akronim biomedis)	2
IDCG	<i>Ideal Discounted Cumulative Gain</i>	35
IDF	<i>Inverse Document Frequency</i>	23
LLM	<i>Large Language Model</i>	1
MAP	<i>Mean Average Precision</i>	5
nDCG	<i>Normalized Discounted Cumulative Gain</i>	5
NLM	<i>National Library of Medicine</i>	59
NLP	<i>Natural Language Processing</i>	12
PaLM	<i>Pathways Language Model</i>	1
PubMed	Basis data publikasi ilmiah biomedis (bukan akronim)	2
PubMedQA	<i>PubMed Question Answering Dataset</i>	4
QA	<i>Question Answering</i>	55
QR	<i>Query Rewriting</i>	3
RAG	<i>Retrieval-Augmented Generation</i>	1
RAG-LLM	<i>Retrieval-Augmented Generation Large Language Model</i>	3

Singkatan	Deskripsi	Pemakaian pertama
RAGAS	<i>Retrieval-Augmented Generation Assessment</i>	5
RRF	<i>Reciprocal Rank Fusion</i>	57
TF	<i>Term Frequency</i>	23
TF-IDF	<i>Term Frequency–Inverse Document Frequency</i>	23
UTF-8	<i>8-bit Unicode Transformation Format</i>	59

BAB I

PENDAHULUAN

I.1 Latar Belakang

Kemajuan *Large Language Models (LLM)* seperti *GPT*, *LLaMA*, dan *PaLM* telah menghadirkan perubahan fundamental dalam berbagai aspek kehidupan modern. Model-model ini mampu menghasilkan teks yang koheren, mengikuti instruksi, serta membantu proses analisis informasi secara cepat dan efisien. Hal tersebut membuat LLM semakin banyak digunakan dalam layanan publik, pendidikan, biomedis, kesehatan, bisnis, hingga penyediaan informasi sehari-hari (Zhang 2024).

Namun, di balik kemajuan tersebut, terdapat tantangan serius berupa fenomena halusinasi. Halusinasi terjadi ketika model menghasilkan informasi yang tampak meyakinkan tetapi sebenarnya tidak benar, tidak berdasar, atau sepenuhnya fiktif (Kovács dan Recski 2025). Risiko tersebut bukan sekadar isu teknis karena dampaknya telah terlihat nyata dalam berbagai kasus yang merugikan masyarakat.

Sebagai contoh nyata, pada tahun 2023 seorang pengacara di New York mengajukan rujukan kasus hukum fiktif hasil *ChatGPT* hingga dikenai sanksi pengadilan (Schwartz 2023), dan pada tahun 2024 *chatbot* resmi maskapai Air Canada memberikan informasi keliru sehingga maskapai tersebut dinyatakan bertanggung jawab secara hukum (Tribunal 2024). Khusus pada domain kesehatan yang menuntut akurasi tinggi, studi MedPaLM menunjukkan bahwa LLM masih kerap menghasilkan rekomendasi medis yang tidak akurat dan berpotensi membahayakan pasien jika digunakan tanpa verifikasi profesional (Singhal dkk. 2023). Contoh-contoh ini menegaskan bahwa halusinasi merupakan isu kritis yang memengaruhi kepercayaan dan keamanan teknologi berbasis LLM, sehingga diperlukan upaya sistematis untuk memitigasinya, khususnya pada pendekatan *Retrieval-Augmented Generation (RAG)* yang menggabungkan kemampuan generatif dengan sumber informasi eksternal.

Secara teoretis, RAG dapat mengurangi halusinasi karena model menjawab ber-

dasarkan dokumen yang dapat diverifikasi. Namun dalam praktiknya, RAG tetap dapat menghasilkan informasi keliru apabila dokumen yang diperoleh tidak relevan, ambigu, atau tidak sesuai dengan maksud pertanyaan. Dengan demikian, kualitas jawaban tidak hanya bergantung pada kemampuan model generatif, tetapi juga pada proses pencarian dan pemilihan konteks yang tepat.

Tinjauan terbaru oleh Zhang (2025) berjudul “*Hallucination Mitigation for Retrieval-Augmented Large Language Models: A Review*” memetakan berbagai penyebab halusinasi dalam RAG serta merangkum strategi mitigasinya (Zhang 2024). Meskipun memberikan gambaran yang komprehensif, tinjauan tersebut menunjukkan bahwa solusi yang ada saat ini masih cenderung berdiri sendiri dan belum digabungkan dalam satu sistem terpadu. Sebagai contoh, Ma dkk. (2023) berfokus pada *query rewriting* untuk memperbaiki formulasi kueri tanpa menyertakan *reranking* konteks (Ma dkk. 2023), sementara pendekatan seperti *Chain-of-Verification* hanya menekankan mitigasi pada tahap *generation* melalui verifikasi mandiri terhadap jawaban yang dihasilkan (Dhuliawala dkk. 2024). Di sisi lain, sebagian penelitian lain berfokus pada *context reranking* untuk menyaring dokumen hasil *retrieval* (Shuting Wang dkk. 2023). Pemisahan fokus ini menunjukkan adanya peluang untuk menggabungkan beberapa teknik mitigasi yang saling melengkapi dalam satu alur sistem yang utuh.

Selain persoalan umum tersebut, penerapan RAG pada domain tertentu turut menghadirkan tantangan yang khas, sehingga strategi mitigasi perlu disesuaikan dengan karakteristik domainnya. Tugas akhir ini berfokus pada domain biomedis, yang memiliki satu penyebab halusinasi yang spesifik, yaitu *vocabulary mismatch*, yakni ketidaksesuaian istilah antara pertanyaan pengguna dan teks dokumen yang menjadi korpus. Fenomena ini sangat sering dijumpai pada literatur biomedis karena dokumen ilmiah, khususnya abstrak paper di PubMed, banyak menggunakan akronim atau singkatan untuk istilah panjang. Sebagai contoh, istilah *Hyperbaric Oxygen* ditulis dengan singkatan HBO, *Coronary Heart Disease* ditulis dengan singkatan CHD, dan *Body Mass Index* ditulis dengan singkatan BMI. Akibatnya, ketika pengguna mengajukan pertanyaan dengan istilah panjang yang lengkap, sistem *retrieval* sering gagal menemukan dokumen relevan yang sebenarnya tersedia karena dokumen tersebut hanya mengandung versi akronimnya. Kegagalan *retrieval* ini kemudian diteruskan ke tahap *generation* dan menjadi salah satu pemicu halusinasi. Tahap praproses dokumen, khususnya ekspansi akronim biomedis, menjadi salah satu pendekatan yang berpotensi untuk mengatasi keterbatasan ini.

Selain praproses dokumen, sejumlah teknik mitigasi telah dikembangkan untuk memperbaiki kualitas *retrieval* maupun *generation* pada sistem RAG. Dua teknik yang banyak dibahas adalah *query rewriting* (QR) dan *context reranking* (CR) (Zhang 2024). *Query Rewriting* bekerja pada tahap sebelum *retrieval* dengan menulis ulang atau memperluas pertanyaan pengguna agar lebih sesuai dengan istilah yang digunakan pada korpus, sehingga peluang menemukan dokumen yang relevan menjadi lebih besar. Sementara itu, *context reranking* bekerja setelah *retrieval* dengan mengurutkan ulang dokumen kandidat berdasarkan tingkat relevansinya terhadap pertanyaan, sehingga dokumen yang paling relevan ditempatkan pada urutan teratas sebelum diteruskan ke tahap *generation*.

Meskipun teknik-teknik tersebut telah terbukti efektif secara individual, sebagian besar studi hanya menerapkan satu jenis mitigasi pada satu tahap tertentu. Akibatnya, belum terdapat implementasi yang mengintegrasikan beberapa teknik mitigasi dalam satu alur menyeluruh untuk menekan halusinasi secara lebih efektif, khususnya pada domain biomedis yang memiliki karakteristik unik seperti *vocabulary mismatch* akibat penggunaan akronim. Kesenjangan ini menjadi sangat penting untuk diatasi pada domain kesehatan dan biomedis, karena informasi yang tidak akurat atau bersifat halusinatif dapat berpotensi menimbulkan kesalahan diagnosis, keputusan klinis yang tidak tepat, dan risiko terhadap keselamatan pasien.

I.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, tugas akhir ini berfokus untuk menjawab beberapa pertanyaan utama sebagai berikut:

1. Bagaimana arsitektur sistem RAG-LLM untuk mitigasi halusinasi pada sistem tanya jawab biomedis dirancang dan diimplementasikan dengan mengintegrasikan ekspansi akronim, *query rewriting*, dan *context reranking*?
2. Bagaimana kontribusi komparatif setiap teknik mitigasi terhadap penurunan halusinasi dan peningkatan kualitas jawaban sistem?

I.3 Tujuan

Tujuan dari tugas akhir ini adalah sebagai berikut:

1. Merancang dan mengimplementasikan arsitektur sistem RAG-LLM untuk mitigasi halusinasi pada sistem tanya jawab biomedis dengan mengintegrasikan ekspansi akronim, *query rewriting*, dan *context reranking* sehingga dapat memproses pertanyaan biomedis.
2. Menyusun analisis komparatif kontribusi setiap teknik mitigasi terhadap penurunan halusinasi dan peningkatan kualitas jawaban sistem.

I.4 Batasan Masalah

Penelitian ini memiliki batasan ruang lingkup yang spesifik untuk menjamin fokus kajian dan kelayakan penyelesaian dalam jangka waktu pengerjaan tugas akhir. Berikut adalah batasan masalah yang ditetapkan:


1. Penelitian ini menggunakan *dataset* PubMedQA subset *pqa_labeled* yang berisi 1.000 paper biomedis berlabel *expert* dari basis data PubMed. *Dataset* pada domain lain di luar biomedis tidak termasuk dalam cakupan penelitian. Dari 1.000 paper tersebut, 500 pertanyaan pertama dipilih sebagai himpunan uji evaluasi. Jumlah korpus dan pertanyaan evaluasi ini dipilih untuk menjaga keseimbangan antara representativitas eksperimen dan keterbatasan sumber daya komputasi serta biaya pemanggilan API LLM.
2. Halusinasi yang dianalisis dibatasi pada tiga kategori yang paling relevan dengan proses *retrieval* dan *generation*, yaitu halusinasi intrinsik (keluaran yang bertentangan dengan konteks yang diberikan), halusinasi ekstrinsik (keluaran yang tidak dapat diverifikasi dari konteks yang diberikan meskipun mungkin benar), dan halusinasi faktual (keluaran yang mengandung klaim faktual yang keliru). Halusinasi intrinsik dan ekstrinsik diukur melalui metrik *faithfulness*, sedangkan halusinasi faktual tecermin pada *label accuracy* dan *hallucination rate* terhadap *ground truth*. Jenis halusinasi lain seperti *reasoning*, *linguistic*, dan *bias-related halusinasi* tidak termasuk dalam cakupan.
3. Teknik mitigasi yang diimplementasikan dibatasi pada tiga pendekatan utama, yaitu ekspansi akronim biomedis menggunakan algoritma Schwartz-Hearst sebagai tahap praproses dokumen, *query rewriting* berbasis *Large Language Model* untuk perluasan kueri, dan *context reranking* untuk menata ulang dokumen kandidat berdasarkan relevansi. Metode mitigasi lain seperti *prompt engineering* lanjutan, *knowledge editing*, atau *model fine-tuning* tidak dibahas dalam penelitian ini.
4. Model bahasa yang digunakan terbatas pada empat model, yaitu Llama 3.2, Llama 3.3, GPT-4.1, dan Claude 4.5. Seluruh model diakses melalui API berbayar dengan pemilihan *tier* atau varian yang paling ekonomis pada masing-masing model untuk menyesuaikan dengan keterbatasan biaya pada pengerjaan tugas akhir. Model bahasa lain di luar keempat model tersebut tidak termasuk dalam cakupan implementasi.
5. Seluruh data, *prompt*, dan proses *retrieval* dilakukan menggunakan bahasa Inggris. Penelitian tidak mencakup analisis pada bahasa lain di luar bahasa Inggris.
6. Evaluasi kinerja sistem dilakukan menggunakan kombinasi tiga jenis metrik,

yaitu (a) metrik kualitas *retrieval* seperti $nDCG@k$, $MAP@k$, dan $Recall@k$; (b) metrik akurasi klasifikasi label (*accuracy* terhadap *ground truth yes/no/maybe*); dan (c) metrik *Retrieval Augmented Generation Assessment* (RAGAS) yang meliputi *faithfulness* dan *context recall*.

I.5 Metodologi Tugas Akhir

Tugas akhir ini menggunakan **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*) sebagai kerangka kerja metodologi penelitian (Hotz 2024). CRISP-DM dipilih karena karakteristiknya selaras dengan sifat penelitian ini yang berbasis data dan eksperimen. Pertama, CRISP-DM bersifat iteratif, sehingga memungkinkan perbaikan berulang ketika hasil evaluasi belum memenuhi sasaran. Hal ini sesuai dengan penelitian yang menguji dan membandingkan banyak konfigurasi secara bertahap. Kedua, CRISP-DM memisahkan secara eksplisit tahap pemahaman masalah dan data dari tahap pemodelan dan evaluasi, sehingga setiap keputusan desain dapat ditelusuri kembali pada karakteristik data yang sebenarnya. Ketiga, kerangka ini berorientasi pada evaluasi yang terukur, yang sejalan dengan kebutuhan penelitian untuk menilai kinerja secara objektif dan dapat dibandingkan. Keempat, sifatnya yang terstruktur dan terdokumentasi mendukung reproduktibilitas, yaitu kemampuan penelitian untuk diuji ulang dan diverifikasi oleh pihak lain.

CRISP-DM terdiri atas enam fase utama, yaitu *business understanding*, *data understanding*, *data preparation*, *modeling*, *evaluation*, serta *deployment*. Visualisasi tahapan metodologi ini dapat dilihat pada Gambar I.1.



Gambar I.1 Tahapan Metodologi CRISP-DM (Hotz 2024)

1.5.1 *Business Understanding*

Tahap pertama bertujuan memahami kebutuhan dan tujuan sistem dari sudut pandang pengguna atau masalah operasional. Kegiatan dilakukan untuk menentukan ruang lingkup, sasaran, serta kriteria keberhasilan model yang akan dibangun. Pemahaman konteks pada fase ini menjadi fondasi dalam pemilihan strategi analisis dan pendekatan pemodelan.

1.5.2 *Data Understanding*

Tahap ini berfokus pada eksplorasi data awal, termasuk identifikasi sumber data, penilaian kualitas, serta analisis karakteristik yang relevan dengan permasalahan. Tujuannya adalah memperoleh wawasan mengenai struktur, konten, serta permasalahan yang mungkin muncul pada tahap pemrosesan.

1.5.3 *Data Preparation*

Tahap ini mencakup pembersihan, penyaringan, transformasi, serta penyiapan data sehingga siap digunakan pada tahap berikutnya. Hasil akhir tahap ini adalah data yang terstruktur dan berkualitas memadai untuk proses pemodelan.

1.5.4 *Modeling*

Pada tahap ini ditentukan teknik pemodelan, pemilihan algoritma, serta konfigurasi parameter (*hyperparameter*) yang sesuai. Data yang telah dipersiapkan kemudian digunakan untuk membangun model, termasuk pengujian alternatif parameter untuk mendapatkan kinerja yang optimal.

1.5.5 *Evaluation*

Tahap ini mengevaluasi kinerja model berdasarkan metrik evaluasi kuantitatif. Selain itu, dilakukan pula pengecekan kesesuaian model dengan tujuan tugas akhir. Apabila model belum memenuhi kriteria keberhasilan, diperlukan iterasi kembali pada tahap pemahaman data atau pemodelan.

1.5.6 *Deployment*

Tahap terakhir adalah penerapan model ke dalam lingkungan operasional atau simulasi implementasi. Pada tahap ini dilakukan pemantauan performa, dokumentasi, serta pengelolaan perubahan data dan model agar solusi tetap andal dalam jangka panjang. Pada tugas akhir ini, tahap *deployment* dibatasi pada simulasi *pipeline* sistem RAG dan tidak mencakup penerapan berskala produksi (*production-scale deployment*).

Metodologi CRISP-DM menyediakan kerangka terstruktur yang menyeimbangkan

kebutuhan teknis dan praktis sehingga tugas akhir berbasis data dapat dijalankan secara sistematis, transparan, dan dapat direproduksi dengan baik.

BAB II

STUDI LITERATUR

II.1 *Large Language Model (LLM)*

Large Language Model (LLM) adalah keluarga model bahasa berbasis transformer yang dilatih pada korpus teks berskala sangat besar sehingga mampu mempelajari pola bahasa dan memecahkan beragam tugas generatif maupun pemahaman tanpa pelatihan ulang khusus pada tiap tugas (Zhao dkk. 2023); (Minaee, Azimi, Abdolrashidi, dkk. 2024). Berbeda dari model bahasa generasi awal yang terutama memodelkan distribusi kata, LLM modern menunjukkan kemampuan yang lebih umum untuk menyelesaikan instruksi, menalar, dan beradaptasi pada konteks baru. Kapabilitas kunci LLM yang banyak didokumentasikan meliputi :

1. Pembelajaran dalam konteks (*in-context learning*), yakni ketika LLM mempelajari tugas baru dari sekumpulan contoh yang disajikan dalam *prompt*.
2. Mengikuti instruksi, yakni ketika sudah dilakukan *instruction tuning*, LLM dapat mengikuti instruksi untuk variasi tugas yang baru tanpa perlu ditunjukkan lagi contohnya.
3. *Multi-step reasoning*, yakni ketika LLM dapat menyelesaikan tugas yang kompleks dengan memecah tugas tersebut menjadi langkah-langkah penalaran (Minaee, Azimi, Abdolrashidi, dkk. 2024).


Perkembangan LLM berlangsung sangat cepat dalam beberapa tahun terakhir. Tonggak yang paling menonjol adalah peluncuran ChatGPT oleh OpenAI pada akhir tahun 2022 yang mempopulerkan penggunaan LLM untuk tanya jawab, pencarian informasi, dan perangkuman teks (Minaee, Azimi, Abdolrashidi, dkk. 2024). Sejak saat itu bermunculan berbagai keluarga model, baik yang bersifat sumber tertutup seperti seri GPT dari OpenAI dan Claude dari Anthropic, maupun yang bersifat sumber terbuka seperti LLaMa dari Meta dan PaLM dari Google. Tren utama pada tiap generasi adalah peningkatan jumlah parameter, perluasan data pra-pelatihan, dan pelebaran *context window*, yang secara umum meningkatkan kemampuan penalaran dan pemahaman model (Zhao dkk. 2023); (Minaee, Azimi, Abdolrashidi, dkk. 2024).

Walaupun kemampuannya terus meningkat, LLM masih memiliki keterbatasan mendasar yang menjadi latar belakang tugas akhir ini. Ketiga keterbatasan tersebut saling berkaitan dan diuraikan sebagai berikut.

1. **Keterbatasan pengetahuan (*knowledge limitation*).** LLM menyimpan pengetahuan secara implisit di dalam parameter yang dipelajari dari data pra-pelatihan yang bersifat statis dan memiliki batas waktu (*knowledge cutoff*). Akibatnya, model kesulitan menjawab pertanyaan yang memerlukan pengetahuan terbaru maupun pengetahuan domain spesifik yang berada di luar data pelatihan (Zhao dkk. 2023). Pembaruan pengetahuan melalui *fine-tuning* memang memungkinkan, tetapi mahal secara komputasi dan berisiko menimbulkan kelupaan fatal (*catastrophic forgetting*) terhadap pengetahuan yang sudah dimiliki (Zhao dkk. 2023).
2. **Halusinasi (*hallucination*).** Ketika dipaksa menjawab di luar batas pengetahuannya, LLM cenderung menghasilkan keluaran yang tampak meyakinkan tetapi bertentangan dengan fakta atau tidak dapat diverifikasi oleh sumber yang tersedia (Zhao dkk. 2023). Halusinasi dapat menurunkan keandalan sistem dan menimbulkan risiko serius pada penerapan di domain sensitif seperti biomedis, sehingga menjadi masalah utama yang ingin dimitigasi pada tugas akhir ini.
3. **Ketergantungan pada *retrieval* (*retrieval dependency*).** Untuk mengatasi dua keterbatasan di atas tanpa melatih ulang model, pendekatan yang banyak diadopsi adalah memberi LLM akses ke sumber pengetahuan eksternal pada saat inferensi melalui mekanisme *retrieval*. Dengan menambahkan (*grounding*) jawaban pada bukti yang diambil, kualitas jawaban menjadi sangat bergantung pada kualitas *retrieval*. Konteks yang relevan dapat menekan halusinasi, sedangkan *retrieval* yang gagal menyediakan dokumen tepat justru dapat tetap memicu halusinasi. Ketergantungan inilah yang menjadi dasar pendekatan *Retrieval-Augmented Generation* (RAG) yang dibahas pada subbab berikutnya.

II.1.1 *Retrieval-Augmented Generation*

Retrieval-Augmented Generation (RAG) merupakan pendekatan yang memperkuat kemampuan *Large Language Model* (LLM) dengan mengakses potongan dokumen yang relevan dari sumber pengetahuan eksternal melalui perhitungan kesamaan semantik (Yunfan Gao dkk. 2023). Dengan merujuk pada basis pengetahuan tersebut, RAG mampu mengurangi kecenderungan model menghasilkan konten yang salah secara faktual karena jawaban yang diberikan diarahkan pada bukti tekstual yang dapat diverifikasi.



Gambar II.1 Alur *Retrieval-Augmented Generation* (Yunfan Gao dkk. 2023)

Secara umum, mekanisme RAG terdiri atas tiga tahapan utama yang saling berkaitan, yaitu *indexing*, *retrieval*, dan *generation*, sebagaimana diilustrasikan pada Gambar II.1. Pada tahap *indexing*, sistem melakukan ekstraksi serta pembersihan data dari berbagai format dokumen seperti PDF, HTML, Word, maupun Markdown. Seluruh data tersebut dikonversi menjadi teks murni dan kemudian dipecah menjadi segmen-segmen kecil (*chunks*) yang sesuai dengan batas kapasitas konteks model bahasa. Setiap segmen diubah menjadi representasi vektor menggunakan model *embedding*, lalu disimpan ke dalam basis data vektor untuk memungkinkan pencarian berbasis kesamaan secara efisien.

Tahap berikutnya, yaitu *retrieval*, dimulai ketika pengguna memasukkan kueri. Sistem mengonversi kueri tersebut menjadi vektor menggunakan model *embedding* yang sama seperti pada proses indeks. Kueri dalam bentuk vektor kemudian dibandingkan dengan vektor segmen dalam basis data, sehingga sistem dapat mengambil beberapa segmen dengan skor kesamaan tertinggi. Hasil pencarian inilah yang menjadi konteks pengetahuan bagi model.

Tahap terakhir adalah *generation*, di mana kueri dan konteks terpilih digabungkan menjadi sebuah *prompt* yang kemudian diberikan kepada LLM. Model menghasilkan jawaban sesuai tugas yang diberikan, dan pada beberapa kasus, riwayat percakapan dapat digabungkan sehingga mendukung interaksi multi-putaran (*multi-turn dialog*). Dengan cara ini, proses generasi menjadi lebih terarah dan berbasis bukti,

mengurangi risiko halusinasi serta meningkatkan akurasi faktual (Yunfan Gao dkk. 2023).

II.1.2 Halusinasi atau Konfabulasi pada *Large Language Models*

Konsep halusinasi pada awalnya berasal dari bidang psikologi, yang mengacu pada pengalaman perseptual tanpa adanya rangsangan eksternal atau persepsi yang menyimpang dari realitas. Dalam konteks *Natural Language Processing* (NLP), halusinasi merujuk pada keluaran model bahasa besar (*Large Language Model* atau LLM) yang tidak konsisten dengan fakta atau bahkan tidak masuk akal. Namun, beberapa peneliti menilai bahwa istilah halusinasi tidak sepenuhnya tepat karena memberikan kesan bahwa model memiliki persepsi sensorik sebagaimana manusia. Sebagai alternatif, istilah *confabulation* dianggap lebih akurat, karena menggambarkan kecenderungan seseorang untuk "mengisi celah memori" dengan informasi yang tampak benar namun sebenarnya keliru, suatu analogi yang sesuai dengan perilaku LLM ketika menghasilkan keluaran yang salah namun tampak meyakinkan (Zhang 2024).

Dalam praktiknya, istilah halusinasi masih lebih banyak digunakan dalam literatur akademik karena telah menjadi istilah baku untuk menggambarkan fenomena keluaran tidak faktual pada LLM. Secara umum, halusinasi dapat dibedakan menjadi dua kategori utama, yaitu:

- a. **Halusinasi intrinsik**, yaitu ketika keluaran model bertentangan dengan masukan atau konteks sumber. Contohnya, model memberikan angka yang berbeda dari data yang sebenarnya terdapat dalam teks masukan.
- b. **Halusinasi ekstrinsik**, yaitu ketika keluaran tidak dapat diverifikasi dari masukan namun mungkin benar jika dibandingkan dengan pengetahuan eksternal (Zhang 2024).

Klasifikasi yang lebih mendalam dikemukakan oleh Huang dkk. (2023) dengan menambahkan dua dimensi tambahan: halusinasi **faktualitas** (*factuality hallucination*) dan halusinasi **kefidelan** (*faithfulness hallucination*). Halusinasi faktualitas terjadi ketika keluaran tidak sesuai dengan fakta dunia nyata, sedangkan halusinasi kefidelan terjadi ketika keluaran menyimpang dari instruksi pengguna, konteks, atau logika internal model. Rawte dkk. (2024) bahkan mengajukan dua variasi tambahan, yakni *factual mirage* (jawaban salah terhadap pertanyaan yang benar) dan *silver lining* (jawaban tampak benar terhadap pertanyaan yang salah) (Zhang 2024).

Dalam konteks *Retrieval-Augmented Generation* (RAG), batasan pengetahuan internal LLM dapat dikompensasi dengan pengambilan informasi eksternal. Namun,

halusinasi tetap dapat muncul ketika sumber hasil *retrieval* mengandung data yang salah, sudah usang, atau tidak relevan. Misalnya, apabila dokumen hasil pencarian mengandung informasi yang keliru, maka model dapat menghasilkan halusinasi faktualitas. Sebaliknya, jika kueri pengguna ambigu, maka sistem dapat salah menafsirkan konteks dan menghasilkan halusinasi kefidelan (Zhang 2024). Contoh berbagai jenis halusinasi tersebut dirangkum pada Tabel II.1.

Tabel II.1 Contoh berbagai jenis halusinasi pada *Large Language Models (LLM)*

Jenis Halusinasi	Contoh Pertanyaan / Instruksi	Keluaran Model	Penjelasan
Halusinasi Intrinsik	"Laporan keuangan Perusahaan A menunjukkan arus kas operasi sebesar CNY 520 juta. Analisislah kondisi arus kas Perusahaan A."	"Arus kas bersih dari aktivitas investasi sebesar CNY 380 juta."	Keluaran model bertentangan dengan informasi numerik pada <i>prompt</i> . Nilai yang dihasilkan tidak sesuai dengan angka yang diberikan, sehingga menunjukkan ketidakselarasan konteks internal terhadap data awal.

Bersambung pada halaman berikutnya

Tabel II.1 Contoh jenis - jenis halusinasi pada *Large Language Models* (lanjutan)

Jenis Halusinasi	Contoh Pertanyaan / Instruksi	Keluaran Model	Penjelasan
Halusinasi Ekstrinsik	"Laporan keuangan Perusahaan A menunjukkan arus kas operasi sebesar CNY 520 juta. Analisislah kondisi arus kas Perusahaan A."	"Peningkatan arus kas disebabkan oleh ekspansi ke pasar Asia Tenggara."	Model menghasilkan penjelasan berbasis informasi eksternal yang tidak tercantum pada dokumen sumber. Secara linguistik dan logis jawaban tampak konsisten, namun tidak didukung konteks faktual pada data input.
Halusinasi Faktualitas	"Sebutkan nama presiden Amerika Serikat saat ini."	"Presiden Amerika Serikat saat ini adalah William Howard Taft."	Keluaran model mengandung klaim faktual yang keliru. Nama pejabat publik yang disebutkan tidak merepresentasikan realitas politik aktual, menunjukkan kesalahan substansi meskipun format kalimat tersusun baik.

Bersambung pada halaman berikutnya

Tabel II.1 Contoh jenis - jenis halusinasi pada *Large Language Models* (lanjutan)

Jenis Halusinasi	Contoh Pertanyaan / Instruksi	Keluaran Model	Penjelasan
Halusinasi Ketidakselarasan Tugas	"Terjemahkan: Who was the director of <i>Avatar</i> ?"	" <i>Avatar</i> disutradarai oleh James Cameron."	Model tidak mengikuti instruksi utama yang diminta, yaitu melakukan penerjemahan. Model justru menjawab isi pertanyaan. Ketidaktaatan terhadap tujuan instruksi menunjukkan kegagalan pemahaman arah tugas.
Factual Mirage	"Sir Arthur Conan Doyle adalah penulis seri Sherlock Holmes. Jelaskan penghargaan resmi yang diterimanya."	"Arthur Conan Doyle menerima penghargaan 'Royal Detective Honor' dari Kerajaan Inggris."	Model memproduksi entitas fiktif yang tampak kredibel dan relevan dengan konteks. Padahal, penghargaan tersebut tidak pernah ada. Fenomena ini mencerminkan pembentukan fakta semu yang sulit dibedakan dari informasi nyata.

Bersambung pada halaman berikutnya

Tabel II.1 Contoh jenis - jenis halusinasi pada *Large Language Models* (lanjutan)

Jenis Halusinasi	Contoh Pertanyaan / Instruksi	Keluaran Model	Penjelasan
Silver Lining	"Mengapa Lin Daiyu mencabut pohon willow?"	"Lin Daiyu mencabut pohon willow sebagai simbolisasi kesedihan mendalam atas nasib tragisnya."	Model menjawab berdasarkan asumsi naratif dari teks yang diberikan, padahal tindakan yang menjadi premis dalam <i>prompt</i> tidak pernah terjadi pada karya aslinya. Ketika dipaksa menerima pernyataan yang salah, model memvalidasi konteks fiktif dan mengembangkan narasi lanjutan.

Fenomena halusinasi pada LLM dapat disebabkan oleh tiga faktor utama:

- keterbatasan pengetahuan internal model akibat cakupan data pelatihan yang terbatas;
- ketidaksesuaian antara kueri pengguna dan hasil pencarian pada tahap *retrieval*;
- kesalahan integrasi atau interpretasi konteks eksternal pada tahap *generation*.

Oleh karena itu, deteksi dan mitigasi halusinasi menjadi aspek penting dalam pengembangan sistem berbasis LLM, terutama pada domain yang menuntut tingkat akurasi dan kredibilitas yang tinggi, seperti medis, keuangan, dan pendidikan (Zhang 2024).

Dari ketiga faktor tersebut, dua faktor terakhir, yaitu ketidaksesuaian antara kueri dan hasil pencarian (*retrieval mismatch*) serta kesalahan integrasi konteks pada tahap *generation*, menjadi tantangan yang semakin menonjol pada domain yang banyak menggunakan singkatan dan akronim, seperti medis, keuangan, dan hukum. Pada berbagai literatur di bidang tersebut, istilah yang panjang sering kali direpresentasikan dalam bentuk akronim untuk meningkatkan efisiensi penulisan. Akibatnya, ketika pengguna mengajukan pertanyaan menggunakan istilah leng-


kap, sementara dokumen sumber hanya memuat bentuk akronimnya, dapat terjadi ketidaksesuaian istilah yang dikenal sebagai *vocabulary mismatch*. Kondisi ini menyebabkan dokumen yang sebenarnya relevan menjadi lebih sulit ditemukan pada tahap *retrieval*, sehingga model memperoleh konteks yang kurang lengkap atau kurang relevan. Keterbatasan konteks tersebut pada akhirnya meningkatkan risiko munculnya halusinasi pada proses *generation*. Dengan demikian, halusinasi pada domain medis, keuangan, maupun hukum tidak hanya dipengaruhi oleh keterbatasan pengetahuan internal model, tetapi juga oleh ketidakcocokan representasi istilah yang terjadi pada tahap pencarian dokumen.

II.2 Mitigasi Halusinasi pada *Retrieval-Augmented Generation*

Tinjauan oleh Math dkk. (2025) memberikan pemetaan komprehensif mengenai fenomena halusinasi pada *Retrieval-Augmented Generation* (RAG), mulai dari sumber penyebab di setiap tahap *pipeline* hingga teknik mitigasi yang telah diusulkan dalam literatur (Zhang 2024). RAG sendiri dirancang untuk mengurangi ketergantungan LLM pada pengetahuan parametris dengan menambahkan konteks eksternal, tetapi dalam praktiknya sistem ini tetap rentan menghasilkan keluaran yang tidak akurat ketika terjadi kegagalan pada tahap *retrieval* maupun *generation*.

Secara garis besar, halusinasi pada RAG dikelompokkan ke dalam dua sumber utama: ***retrieval failure*** dan ***generation deficiency***. *Retrieval failure* muncul ketika sistem gagal menemukan atau memilih informasi yang relevan, misalnya karena kueri ambigu, pemeringkatan dokumen yang buruk, atau korpus yang berisi data usang. Sementara itu, *generation deficiency* berkaitan dengan ketidakmampuan model untuk menyelaraskan jawaban dengan konteks yang sudah benar, misalnya akibat panjang konteks, konflik antar sumber, atau desain *prompt* yang tidak tegas (Zhang 2024).

Gambar II.2 memetakan penyebab halusinasi pada RAG-LLM beserta solusi yang diusulkan pada setiap tahap *pipeline*. Berdasarkan pemetaan tersebut, bagian ini menguraikan kerangka RAG yang dibahas oleh Math dkk. (2025), teknik mitigasi yang diusulkan pada setiap subtugas, serta ringkasan metrik dan dataset yang digunakan untuk mengevaluasi keberhasilan mitigasi tersebut.



Gambar II.2 Penyebab dan solusi halusinasi pada RAG-LLM (Zhang (2024)).

II.2.1 Kerangka RAG dan Titik Munculnya Halusinasi

Math dkk. memodelkan sistem RAG sebagai rangkaian subtugas yang tersebar di beberapa tahap utama (Zhang 2024):

1. **Pemahaman kueri** (*kueri understanding*) Sistem menafsirkan pertanyaan atau instruksi pengguna dan membentuk kueri yang akan digunakan pada modul *retrieval*. Ambiguitas, ketidaklengkapan, atau pemilihan kata yang keliru pada tahap ini dapat berujung pada *retrieval failure*.
2. **Pengambilan dokumen** (*document retrieval*) Berdasarkan kueri, *retriever* memilih dokumen atau potongan teks (*passage*) yang dianggap paling relevan

dari korpus. Kinerja yang buruk pada tahap ini menghasilkan konteks yang tidak relevan, tidak lengkap, atau bias.

3. **Seleksi dan pemrosesan konteks** (*context selection and processing*) Sistem memilih subset konteks yang akan dimasukkan ke dalam *prompt*, sering kali dengan melakukan pemotongan, pemeringkatan ulang, atau kompresi. Di sini dapat muncul masalah seperti konteks terlalu panjang, informasi penting terpotong, atau kebisingan yang tidak tersaring.
4. **Integrasi pengetahuan** (*knowledge integration*) LLM menggabungkan pengetahuan parametris internal dengan konteks eksternal yang diambil melalui *retrieval*. Konflik antara pengetahuan internal dan eksternal, atau kegagalan dalam mengutamakan bukti dari konteks, dapat memicu halusinasi.
5. **Generasi jawaban** (*answer generation*) Pada tahap ini, model menghasilkan teks akhir yang akan diterima pengguna. Desain *prompt*, strategi decoding, dan tidak adanya mekanisme verifikasi dapat membuat model memproduksi pernyataan yang tidak didukung dokumen.

Dengan memetakan subtugas seperti di atas, Math dkk. menekankan bahwa mitigasi halusinasi tidak bisa hanya dilakukan dengan satu teknik pada satu tahap, melainkan memerlukan *pipeline* yang secara eksplisit menangani sumber kesalahan di tahap *retrieval* maupun *generation*.

II.2.2 Mitigasi Halusinasi pada Tahap *Retrieval*

Pada tahap *retrieval*, halusinasi umumnya berasal dari kueri yang tidak representatif serta pemeringkatan dokumen yang tidak tepat. Math dkk. mengelompokkan teknik mitigasi utama sebagai berikut (Zhang 2024).

II.2.2.1 Perbaikan Kueri dan *Query Rewriting*

Jika kueri pengguna terlalu pendek, ambigu, atau mengandung istilah yang tidak spesifik, *retriever* dapat mengembalikan dokumen yang tidak relevan. Untuk mengurangi masalah ini, beberapa studi mengusulkan:

- a. ***Query Rewriting*** berbasis LLM, yaitu menulis ulang pertanyaan pengguna menjadi kueri yang lebih terstruktur, eksplisit, dan kaya konteks.
- b. **Ekspansi kueri** (*query expansion*) dengan menambahkan sinonim, istilah teknis terkait, atau entitas yang relevan.
- c. ***Decontextualization***, yaitu mengubah pertanyaan yang bergantung pada konteks percakapan menjadi bentuk mandiri sehingga lebih mudah dicocokkan dengan dokumen.

Teknik-teknik ini bertujuan mengurangi *retrieval failure* yang muncul semata-mata karena formulasi kueri yang kurang baik. Dalam konteks tugas akhir ini, modul

query rewriting dapat ditempatkan sebelum *retriever* untuk memastikan bahwa kueri yang masuk ke tahap berikutnya sudah dioptimalkan.

II.2.2.2 Peningkatan Kualitas *Retriever* dan *Reranking*

Selain memperbaiki kueri, banyak penelitian fokus pada peningkatan kualitas *retriever* itu sendiri. Pendekatan yang dibahas dalam tinjauan tersebut meliputi:

- a. Penggunaan ***dense retriever*** berbasis *embedding*, yang menangkap kedekatan semantik di luar kecocokan kata kunci.
- b. ***Hybrid retrieval*** yang menggabungkan metode klasik seperti BM25 dengan *dense retriever* untuk menyeimbangkan presisi dan jangkauan.
- c. ***Reranking*** dokumen menggunakan model yang lebih kuat (misalnya model *cross-encoder*) untuk menilai kembali relevansi top-*k* hasil awal.

Reranking menjadi penting ketika *retriever* bekerja pada skala besar. Alih-alih mencoba mengoptimalkan seluruh daftar hasil, sistem fokus pada memeringkat ulang sejumlah kecil kandidat teratas. Dengan demikian, konteks yang akhirnya dimasukkan ke *prompt* memiliki probabilitas lebih tinggi untuk benar-benar relevan, yang pada gilirannya mengurangi risiko halusinasi di tahap *generation*.

II.2.2.3 Seleksi dan Kompresi Konteks

Masalah lain yang disorot adalah *lost in the middle*, di mana LLM cenderung mengabaikan bagian tengah konteks yang panjang. Untuk mengatasi hal ini, beberapa teknik yang dibahas antara lain:

- a. **Kompresi semantik** (*semantic compression*), misalnya melalui model seperti *LLMLingua*, yang merangkum konteks menjadi bentuk lebih ringkas namun tetap informatif.
- b. **Seleksi kontekstual** (*selective context selection*), yaitu memilih hanya kalimat atau paragraf yang paling relevan terhadap pertanyaan.
- c. ***Chunking* dan pengurutan adaptif**, di mana dokumen dipecah menjadi segmen-segmen kecil dan diurutkan ulang berdasarkan kedekatan dengan kueri.

Teknik seleksi dan kompresi ini menurunkan tingkat kebisingan pada konteks, sehingga model tidak terdorong membuat asumsi ketika berhadapan dengan informasi yang tidak relevan atau terlalu banyak.

II.2.3 Mitigasi pada Tahap Integrasi Pengetahuan

Pada tahap integrasi pengetahuan, LLM harus menggabungkan pengetahuan internal dengan bukti eksternal. Math dkk. menyoroti beberapa tantangan utama: konflik antar sumber, konsistensi logika, dan pemilihan bukti yang tepat (Zhang 2024).

Untuk mengurangi halusinasi pada tahap ini, beberapa pendekatan yang dibahas antara lain:

- a. **Konsolidasi pengetahuan** (*knowledge consolidation*), di mana sistem menyusun representasi terstruktur dari bukti sebelum generasi jawaban akhir.
- b. **Resolusi konflik** antar dokumen dengan meminta model mengidentifikasi perbedaan dan memilih bukti yang paling kredibel.
- c. **Mekanisme memori** (*memory mechanisms*) yang menyimpan fakta penting dari konteks sehingga tidak hilang ketika model memproses konteks yang panjang.

Meskipun tugas akhir ini tidak secara langsung mengimplementasikan modul integrasi pengetahuan khusus, pemahaman terhadap tahap ini penting untuk menjelaskan bahwa mitigasi di tingkat *retrieval* dan *generation* perlu didesain agar selaras.

II.2.4 Mitigasi Halusinasi pada Tahap *Generation*

Pada tahap *generation*, Math dkk. mengkaji berbagai teknik yang berfokus pada cara model menghasilkan dan memverifikasi jawaban (Zhang 2024). Beberapa kategori utama adalah sebagai berikut.

II.2.4.1 *Prompt Engineering* dan Strategi Penalaran

Berbagai teknik *prompting* digunakan untuk memandu model agar lebih berhati-hati, antara lain:

- a. **Chain-of-thought** dan penalaran bertahap yang mendorong model menjelaskan langkah berpikirnya.
- b. **Chain-of-Note (CoN)** yang meminta model menyusun catatan ringkas untuk setiap dokumen hasil *retrieval* guna menilai relevansi dan keandalannya sebelum menyusun jawaban akhir, sehingga model lebih tahan terhadap dokumen yang tidak relevan dan dapat menyatakan “tidak tahu” ketika konteks tidak memuat bukti yang memadai (Yu dkk. 2024).
- c. **Teknik lanjutan** seperti *ReAct*, *CoVe*, dan *CoK* yang memadukan penalaran, aksi, verifikasi, dan pengelolaan dokumen untuk menekan halusinasi.

Teknik-teknik ini tidak mengubah parameter model, tetapi mengatur perilaku generasi melalui desain *prompt* yang cermat.

II.2.4.2 Verifikasi Jawaban dan *Active Detection*

Selain mengarahkan proses generasi, banyak tugas akhir yang menambahkan lapisan verifikasi setelah jawaban dihasilkan. Contoh pendekatan yang dibahas dalam tinjauan tersebut meliputi:

- a. **Pemeriksaan berbasis konsistensi**, seperti *SelfCheckGPT*, yang memban-

dingkan beberapa sampel generasi untuk menilai stabilitas klaim (Manakul, Liusie, dan Gales 2023).

- b. **Verifikasi berbasis sumber**, misalnya dengan memformulasikan ulang jawaban menjadi serangkaian pertanyaan dan memeriksanya terhadap konteks *retrieval*.
- c. **Deteksi segmen halusinatif**, di mana model atau klasifikator tambahan menandai kalimat atau frasa yang tidak didukung bukti, untuk kemudian ditulis ulang atau dihapus.

Pendekatan-pendekatan verifikasi tersebut menggambarkan bahwa keluaran model masih dapat diperiksa ulang melalui lapisan tambahan setelah generasi sebagai salah satu arah mitigasi halusinasi pada sistem RAG. Pada tugas akhir ini, fokus mitigasi diarahkan pada tahap praproses dokumen, *retrieval*, dan pemilihan konteks, sehingga lapisan verifikasi pascagenerasi berada di luar cakupan dan dibahas hanya sebagai konteks pustaka.

II.3 Ekspansi Akronim Dokumen pada Sistem RAG

Salah satu sumber utama kegagalan pada sistem RAG adalah ketidakcocokan kosakata (*vocabulary mismatch*) antara kueri pengguna dan dokumen pada korpus, yaitu kondisi ketika makna semantik antara keduanya sebenarnya sama namun bentuk istilahnya berbeda. Untuk mengatasi hal ini, salah satu strategi yang banyak diadopsi adalah memperkaya isi setiap dokumen sebelum diindeks, sehingga setiap *chunk* mengandung istilah yang lebih beragam dan lebih dekat dengan gaya kueri pengguna. Strategi ini dikenal sebagai *document expansion* atau *document enrichment*.

Strategi pengayaan dokumen telah terbukti efektif pada berbagai domain. Pada domain finansial, Cook dkk. (2025) dan Dadopoulos dkk. (2025) menyuntik akronim domain-spesifik, sinonim, serta metadata terstruktur ke dokumen sebelum diindeks, dan melaporkan peningkatan akurasi *retrieval* yang konsisten dibandingkan *baseline* BM25 maupun *dense retrieval* tunggal. Pada domain enterprise yang lebih umum, Mishra dkk. (2025) mengusulkan kerangka sistematis yang memanfaatkan model bahasa besar untuk membangkitkan metadata yang diperkaya (kata kunci, entitas, akronim, sinonim) pada tiap *chunk*, dengan hasil peningkatan *retrieval* hingga sepuluh poin persentase pada korpus internal perusahaan. Pendekatan serupa pada level *enrichment* per *chunk* juga diusulkan oleh Mangla (2025) yang menggabungkan ekstraksi kata kunci, ringkasan, dan pertanyaan hipotetis melalui satu pemanggilan LLM. Pola yang konsisten lintas-domain ini menegaskan bahwa pengayaan dokumen pada tahap *indexing* merupakan strategi yang dapat

digeneralisasi dan menjadi salah satu fondasi penting pada sistem RAG modern.

II.4 BM25 sebagai Algoritma *Retrieval* Klasik

BM25 (*Best Matching 25*) adalah algoritma *retrieval* berbasis statistik yang dikembangkan oleh Robertson dan kolega pada awal tahun 1990-an sebagai penyempurnaan dari skema TF-IDF. Algoritma ini memberi peringkat dokumen terhadap suatu kueri berdasarkan tiga prinsip utama, yaitu seberapa sering istilah kueri muncul pada dokumen (*term frequency*), seberapa langka istilah tersebut pada keseluruhan korpus (*inverse document frequency*), serta seberapa panjang dokumen tersebut dibandingkan rata-rata panjang dokumen pada korpus. Tiga prinsip ini memastikan dokumen yang lebih banyak memuat istilah kueri yang langka dan tidak terlalu panjang akan menempati peringkat lebih atas dibandingkan dokumen yang sekadar panjang dan kebetulan mengulang istilah umum.

Skor BM25 untuk pasangan dokumen D dan kueri Q dirumuskan sebagai berikut.

$$\text{BM25}(D, Q) = \sum_{q \in Q} \text{IDF}(q) \cdot \frac{f(q, D) \cdot (k_1 + 1)}{f(q, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)} \quad (\text{II.1})$$

Pada Persamaan II.1, $f(q, D)$ menyatakan jumlah kemunculan istilah q pada dokumen D , $|D|$ adalah panjang dokumen D dalam jumlah kata, dan avgdl adalah rata-rata panjang dokumen pada korpus. Sementara itu, $\text{IDF}(q)$ adalah komponen *inverse document frequency* yang dihitung sebagai berikut.

$$\text{IDF}(q) = \ln \left(\frac{N - n(q) + 0,5}{n(q) + 0,5} + 1 \right) \quad (\text{II.2})$$

Pada Persamaan II.2, N adalah jumlah total dokumen pada korpus dan $n(q)$ adalah jumlah dokumen yang memuat istilah q minimal sekali. Persamaan ini memberikan bobot yang lebih besar pada istilah langka, sehingga kemunculan istilah seperti “hyperbaric” lebih berkontribusi terhadap skor dibandingkan istilah umum seperti “patient” atau “study”.

Dua parameter k_1 dan b pada Persamaan II.1 mengatur perilaku algoritma. Parameter k_1 mengendalikan tingkat saturasi *term frequency*, yaitu seberapa cepat tambahan kemunculan istilah berhenti memberi kontribusi tambahan terhadap skor;

nilai standar yang sering dipakai pada literatur adalah $k_1 = 1,5$. Parameter b mengendalikan tingkat normalisasi panjang dokumen, dengan nilai standar $b = 0,75$ yang menyeimbangkan antara dokumen panjang dan pendek tanpa menghukum keduanya secara berlebihan. Kombinasi kedua parameter ini memberi BM25 keunggulan dibandingkan TF-IDF murni karena tidak terlalu sensitif terhadap panjang dokumen maupun pengulangan istilah yang berlebihan.

II.5 *Dense Retrieval* dan Pencarian Berbasis Vektor

Dense retrieval adalah pendekatan pencarian dokumen yang merepresentasikan baik kueri maupun dokumen sebagai vektor numerik berdimensi tinggi, lalu menghitung kemiripan antara dua vektor sebagai dasar peringkat. Berbeda dengan BM25 yang hanya mencocokkan kata kunci, *dense retrieval* memanfaatkan kemampuan model bahasa untuk menangkap makna semantik teks, sehingga dokumen yang menggunakan istilah berbeda tetapi maknanya mirip dengan kueri tetap dapat ditemukan. Sebagai contoh, kueri yang menyebut “*physical activity*” dapat menemukan dokumen yang menulis “*exercise*” atau “*aerobic training*”, selama ketiga istilah tersebut berdekatan posisinya pada ruang vektor.

Setiap teks pada *dense retrieval* diubah menjadi vektor melalui model *embedding*, yaitu jaringan saraf yang telah dilatih agar pasangan teks dengan makna mirip menghasilkan vektor yang berdekatan, sedangkan pasangan teks dengan makna berbeda menghasilkan vektor yang berjauhan (Reimers dan Gurevych 2019). Model *embedding* modern umumnya berbasis arsitektur *transformer* dan menghasilkan vektor berdimensi antara 256 hingga 1.536, tergantung ukuran dan tujuan model. Dimensi yang tinggi memungkinkan model menangkap nuansa makna yang lebih halus, namun juga menuntut kapasitas penyimpanan dan komputasi yang lebih besar.

Kemiripan antara vektor kueri $\vec{q}$ dan vektor dokumen $\vec{d}$ dihitung menggunakan *cosine similarity*, yang mengukur sudut antara kedua vektor pada ruang berdimensi tinggi. Rumusnya adalah sebagai berikut.

$$\text{cosine}(\vec{q}, \vec{d}) = \frac{\vec{q} \cdot \vec{d}}{\|\vec{q}\| \cdot \|\vec{d}\|} \quad (\text{II.3})$$

Pada Persamaan II.3, $\vec{q} \cdot \vec{d}$ adalah *dot product* antara kedua vektor, sedangkan $\|\vec{q}\|$ dan $\|\vec{d}\|$ adalah norma Euclidean dari masing-masing vektor. Nilai *cosine similarity* berada pada rentang $[-1, 1]$, dengan nilai mendekati satu menandakan kemiripan

makna yang tinggi, nilai mendekati nol menandakan tidak ada hubungan, dan nilai negatif menandakan makna yang bertolak belakang. Pada konteks pencarian dokumen, hanya dokumen dengan skor kemiripan tertinggi yang dipilih sebagai kandidat.

Keunggulan *dense retrieval* dibandingkan BM25 terletak pada kemampuannya menangani parafrasa, sinonim, dan terminologi yang berbeda namun bermakna serupa. Pada sisi lain, *dense retrieval* cenderung lemah pada pencocokan istilah teknis yang sangat spesifik (misalnya nama obat, gen, atau akronim langka) karena model *embedding* mungkin belum cukup mengenali kosakata domain tersebut. Karakteristik ini menjadi alasan utama banyak sistem RAG modern memilih pendekatan *hybrid retrieval* yang menggabungkan keunggulan kedua metode.

II.6 *Query Rewriting* untuk Mitigasi Halusinasi pada RAG

Salah satu penyebab paling umum dari halusinasi dalam sistem *Retrieval-Augmented Generation* (RAG) adalah kegagalan pada tahap *retrieval*, terutama ketika kueri pengguna bersifat pendek, ambigu, atau tidak memiliki kata kunci yang sesuai dengan struktur dokumen dalam korpus. Untuk mengatasi kelemahan ini, Ma dkk. (2023) mengusulkan pendekatan ***Query Rewriting for Retrieval-Augmented Large Language Models***, yaitu teknik untuk mentransformasikan kueri mentah pengguna menjadi bentuk kueri baru yang lebih jelas, lebih informatif, dan lebih mudah dicocokkan oleh *retriever* (Ma dkk. 2023).

Pendekatan ini bekerja dengan memanfaatkan kemampuan *Large Language Models* dalam menafsirkan maksud pengguna secara lebih mendalam, kemudian menghasilkan ulang kueri dalam bentuk yang kaya konteks. Tujuannya bukan sekadar memperpanjang kueri, melainkan:

1. mengekspansi istilah penting yang tersirat,
2. menambahkan kata kunci domain yang relevan,
3. mendisambiguasi istilah atau objek yang memiliki lebih dari satu makna,
4. menghilangkan ketidakjelasan linguistik,
5. menyelaraskan format kueri dengan gaya penulisan korpus rujukan.

Ma dkk. menunjukkan bahwa *retriever* tradisional seperti BM25 atau *Dense Passage Retrieval* sering kali gagal menemukan dokumen yang benar ketika kueri terlalu pendek atau tidak selaras dengan distribusi bahasa pada korpus. Dengan memperbaiki bentuk kueri melalui proses *rewriting*, sistem RAG dapat meningkatkan **recall** dokumen relevan secara signifikan, sehingga mengurangi risiko halusinasi pada tahap generasi karena model tidak perlu "mengarang" informasi untuk mengisi

kekosongan konteks.

Secara teknis, pendekatan ini membingkai *query rewriting* sebagai fungsi:

$$q' = \text{LLM_rewrite}(q),$$

di mana q adalah kueri awal pengguna, dan q' adalah kueri terstruktur yang dihasilkan LLM. Kueri baru tersebut kemudian digunakan oleh *retriever* untuk mendapatkan konteks:

$$C = \text{Retriever}(q').$$

Contoh Transformasi Kueri

Berikut beberapa contoh hasil transformasi kueri menggunakan *query rewriting*:

- **Kueri awal:** “How do I keep my plants alive while I’m on holiday?”
Kueri baru: “What are the best methods for ensuring my indoor and outdoor plants remain healthy and watered during a vacation?”
- **Kueri awal:** “Which country had the most athletes in the Olympic parade?”
Kueri baru: “Which country had the largest number of athletes participating in the most recent Olympic opening ceremony parade?”
- **Kueri awal:** “Why were there concerns about the Seine?”
Kueri baru: “What specific issues or concerns have arisen regarding the Seine River, such as pollution, flooding, or ecological impacts?”

Berdasarkan eksperimen dalam Ma dkk. (2023), teknik ini memberikan keuntungan berikut:

- a. **Peningkatan relevansi konteks** melalui kueri yang lebih kaya informasi.
- b. **Penurunan *retrieval failure***, khususnya pada kueri pendek.
- c. **Peningkatan *faithfulness*** jawaban karena LLM memperoleh konteks yang lebih akurat.


Dalam konteks ini, *query rewriting* berfungsi sebagai **mekanisme mitigasi pada tahap retrieval**. Dengan mengolah ulang kueri pengguna sebelum proses pencarian dokumen, sistem RAG menjadi lebih stabil dan lebih tahan terhadap halusinasi baik intrinsik maupun ekstrinsik.

II.7 Context Reranking untuk Mengurangi Kebisingan

Pada sistem *Retrieval-Augmented Generation* (RAG), tahap *retrieval* sering menghasilkan sekumpulan potongan dokumen (*chunk*) yang tidak hanya relevan, tetapi juga mengandung informasi yang berulang, terlalu umum, atau bahkan tidak terkait dengan maksud kueri. Kondisi ini dikenal sebagai *konteks berisik* dan dapat

mendorong *Large Language Model* (LLM) untuk melakukan halusinasi, karena model berusaha menyintesis jawaban dari bukti yang sebagian tidak tepat sasaran.

Gambar II.3 mengilustrasikan posisi *context reranking* pada alur RAG. Setelah kueri dipakai untuk menarik sejumlah dokumen kandidat (*top-k*) dari basis data vektor melalui *semantic search*, sebuah modul *reranker* menilai ulang relevansi tiap dokumen terhadap kueri, lalu menyusun ulang urutannya sehingga dokumen yang paling relevan menempati peringkat teratas sebelum diteruskan ke tahap *generation* (Arooj March 2025).



Gambar II.3 Alur kerja *context reranking* pada sistem RAG (Arooj March 2025)

Ma dkk. mengkaji masalah ini pada skenario kueri yang bersifat *multi-faceted*, yaitu ketika satu kueri pengguna memuat beberapa aspek atau *sub-intent* sekaligus, misalnya dimensi produk, atribut kualitas, dan preferensi pengguna. Dalam kasus seperti ini, *retriever* standar (misalnya *BM25* atau *dense retriever*) cenderung mengembalikan *top-k* dokumen yang hanya menangkap sebagian aspek kueri dan mencampurkannya dengan dokumen yang relevansinya lemah.

Untuk mengurangi kebisingan dan meningkatkan kualitas konteks yang dikonsumsi oleh LLM, Ma dkk. mengusulkan modul *context reranking*. Alih-alih langsung mengirim semua hasil *retrieval* ke model generatif, sistem terlebih dahulu menerapkan tahap seleksi ulang (*reranking*) terhadap *top-k* kandidat. Secara garis besar, prosesnya meliputi:

1. **Pengambilan kandidat awal**

Retriever menghasilkan *top-k* potongan dokumen berdasarkan kemiripan awal terhadap kueri, misalnya dengan *BM25*, *dense retrieval*, atau *vector database*. Hasil pada tahap ini masih berpotensi berisik dan tidak seimbang antar aspek kueri.

2. **Penghitungan skor relevansi semantik**

Setiap *chunk* kandidat diberi skor relevansi terhadap representasi kueri yang diperkaya, tidak hanya berdasarkan kecocokan leksikal, tetapi juga kesesuaian

semantik terhadap berbagai aspek kueri (Shuting Wang dkk. 2023). Hal ini penting untuk menangkap bagian kueri yang bersifat *multi-faceted*.

3. **Multi-facet scoring dan penalti kebisingan**

Modul *reranker* mengombinasikan beberapa komponen skor, antara lain: relevansi inti terhadap kueri, cakupan atribut atau aspek kueri, serta penalti untuk *chunk* yang terlalu umum, redundant, atau tidak spesifik. Dengan cara ini, *chunk* yang hanya mengandung informasi generik atau keluar dari konteks akan ditempatkan di peringkat bawah.

4. **Pemilihan *top-m* konteks terpilih**

Berdasarkan skor komposit, sistem memilih *top-m chunk* terbaik sebagai konteks akhir yang akan diberikan kepada LLM. Nilai *m* biasanya lebih kecil daripada *k* sehingga konteks menjadi lebih ringkas, fokus, dan relevan.

5. **Generasi jawaban berbasis konteks yang telah disaring**

LLM kemudian menghasilkan jawaban dengan mengandalkan *top-m* konteks terpilih tersebut. Karena kebisingan berkurang dan sudut pandang kueri tercakup dengan lebih seimbang, kecenderungan halusinasi dapat ditekan.

Pendekatan *context reranking* ini relevan karena berfokus pada deteksi dan mitigasi halusinasi pada sistem RAG. Pada tahap *retrieval*, modul *reranker* berperan sebagai filter kualitas yang memastikan hanya konteks yang paling relevan dan informatif yang diteruskan ke model generatif. Dengan demikian, halusinasi yang disebabkan oleh *retrieval failure* berupa pemilihan dokumen yang salah atau berisik dapat dikurangi sebelum memasuki tahap *generation* (Zhang 2024; Shuting Wang dkk. 2023).

II.8 Active Detection untuk Mitigasi Halusinasi

Varshney dkk. (2023) mengusulkan pendekatan *active detection* sebagai mekanisme deteksi dan mitigasi halusinasi secara langsung selama proses generasi, bukan setelah teks sepenuhnya dihasilkan. Ide utamanya adalah bahwa *Large Language Model* (LLM) menunjukkan pola tertentu ketika berada pada kondisi berisiko tinggi menghasilkan halusinasi, terutama ketika model menghasilkan token dengan tingkat kepercayaan rendah. Dengan melakukan pemeriksaan terhadap bagian yang memiliki *low-confidence*, sistem dapat menghentikan proses generasi sementara dan memicu langkah verifikasi atau koreksi sebelum melanjutkan (Varshney dkk. 2023).

Pendekatan ini sangat relevan dalam konteks tugas akhir mengenai deteksi dan mitigasi halusinasi pada sistem *Retrieval-Augmented Generation* (RAG), karena banyak halusinasi muncul pada bagian tertentu dari keluaran model, terutama ketika konteks eksternal kurang kuat atau ambigu.

II.8.1 Prinsip Dasar *Active Detection*

Metode *active detection* berangkat dari dua pengamatan kunci:

1. **Token berisiko tinggi biasanya memiliki probabilitas rendah.** Model cenderung berada pada kondisi tidak pasti ketika menemukan konteks yang tidak jelas, dan hal ini tercermin melalui distribusi probabilitas token yang melebar. Token yang dipilih pada kondisi ini berpotensi menyebabkan halusinasi.
2. **Verifikasi lokal dapat mencegah kesalahan global.** Dengan menghentikan generasi pada momen ketidakpastian dan melakukan pemeriksaan tambahan, sistem mampu memperbaiki kesalahan sebelum menjadi bagian dari keluaran akhir.

II.8.2 Alur Kerja *Active Detection*

Berdasarkan Varshney dkk. (2023), proses *active detection* mencakup tiga langkah utama:

1. **Identifikasi token berisiko rendah kepercayaan** Model memantau setiap langkah generasi dan menghitung nilai probabilitas token yang dihasilkan. Jika nilai tersebut berada di bawah ambang tertentu, sistem menandai posisi tersebut sebagai titik risiko.
2. **Validasi token yang ditandai** Untuk token yang ditandai, sistem menjalankan proses verifikasi, misalnya melalui:
 - *self-consistency check*, yaitu model diminta menghasilkan beberapa alternatif untuk menilai kestabilan prediksi,
 - *entailment check* jika konteks tersedia,
 - perbandingan semantik antara kandidat token dan konteks sumber.
3. **Koreksi sebelum melanjutkan generasi** Jika token berisiko dianggap tidak valid atau tidak didukung oleh konteks, model memilih alternatif token dengan probabilitas yang lebih tinggi atau mengulang prediksi. Dengan cara ini, kesalahan dicegah sebelum berkembang menjadi halusinasi yang lebih besar.

II.8.3 Kelebihan Metode *Active Detection*

Pendekatan ini menawarkan beberapa manfaat penting:

- a. **Mitigasi proaktif.** Berbeda dengan metode pascagenerasi, *active detection* mencegah halusinasi saat proses generasi berlangsung.
- b. **Tidak memerlukan model verifikator besar.** Seluruh proses berjalan dengan memanfaatkan informasi internal model, terutama distribusi probabilitas

token.

- c. **Dapat dikombinasikan dengan RAG.** Dalam sistem RAG, metode ini dapat melengkapi pendekatan lain seperti *context reranking* atau *query rewriting*, sehingga mitigasi dapat dilakukan baik pada sisi *retrieval* maupun pada saat generasi (Zhang 2024).

II.8.4 Keterbatasan

Walaupun efektif, *active detection* memiliki beberapa keterbatasan:

- a. **Membutuhkan akses probabilitas token.** Pendekatan ini hanya dapat diterapkan pada model yang menyediakan *logits* atau probabilitas token, sehingga tidak berlaku untuk model sumber tertutup tertentu.
- b. **Penentuan ambang yang sensitif.** Ambang probabilitas terlalu rendah gagal mendeteksi kesalahan, sedangkan ambang terlalu tinggi menyebabkan verifikasi berlebihan yang meningkatkan latensi.
- c. **Tidak selalu menangkap halusinasi semantik kompleks.** Token dengan probabilitas tinggi pun dapat menghasilkan klaim salah jika konteks *retrieval* tidak relevan.

II.9 Prompt Engineering untuk Reduksi Halusinasi

Selain arsitektur model dan kualitas data, perancangan *prompt* juga berperan besar dalam memicu maupun mengurangi halusinasi pada LLM. Studi survei oleh Sahoo dkk. (2024) menunjukkan bahwa *prompt engineering* tidak hanya berfungsi sebagai antarmuka instruksi, tetapi juga sebagai mekanisme pengendali perilaku model, termasuk dalam mengarahkan model agar lebih berhati-hati terhadap fakta dan sumber informasi (Sahoo, Singh, dkk. 2024).

Secara umum, teknik *prompting* untuk mengurangi halusinasi dapat dikelompokkan ke dalam beberapa pendekatan: (i) memperkaya konteks dengan informasi yang relevan melalui *Retrieval-Augmented Generation* (RAG), (ii) menggabungkan penalaran dan aksi secara eksplisit seperti pada *ReAct*, (iii) menambahkan tahapan verifikasi terstruktur seperti pada *Chain-of-Verification* (CoVe), (iv) mengelola dokumen hasil *retrieval* yang berisik seperti pada *Chain-of-Note* (CoN), dan (v) mengintegrasikan pengetahuan secara bertahap seperti pada *Chain-of-Knowledge* (CoK) (Sahoo, Singh, dkk. 2024). Pendekatan-pendekatan ini memanfaatkan *prompt* bukan hanya sebagai instruksi tunggal, melainkan sebagai rangkaian langkah yang membantu model menelusuri bukti, memeriksa konsistensi, dan menolak menjawab ketika informasi tidak memadai.

Pada RAG, *prompt* dirancang untuk memasukkan potongan dokumen hasil *retrieval*

ke dalam instruksi sehingga model terdorong mendasarkan jawabannya pada konteks eksternal, bukan hanya pada memori parametrik. *Prompt* yang menekankan frasa seperti “gunakan hanya informasi dari konteks berikut” atau “kutip sumber yang mendukung jawaban” terbukti meningkatkan *faithfulness* karena model diarahkan untuk menghasilkan jawaban berbasis bukti (Lewis dkk. 2020; Niu dkk. 2025).

Pendekatan *ReAct (Reasoning and Acting)* memadukan langkah penalaran (*thought*) dan tindakan (*action*) di dalam *prompt*. Alih-alih langsung menghasilkan jawaban akhir, LLM diminta untuk menuliskan jejak penalaran singkat, memutuskan kapan perlu memanggil alat eksternal (misalnya API pencarian), lalu memperbarui rencana berdasarkan informasi baru (Yao dkk. 2022). Pola *prompt* seperti “*Thought: ...*”, “*Action: Search[...]*”, dan “*Observation: ...*” membantu model menyadari keterbatasannya dan mengurangi kecenderungan mengarang informasi.

Chain-of-Verification (CoVe) menambahkan tahap verifikasi eksplisit. *Prompt* meminta model untuk: (i) menghasilkan jawaban awal, (ii) menyusun daftar pertanyaan verifikasi, (iii) menjawab pertanyaan tersebut secara independen, dan (iv) merevisi jawaban sesuai hasil verifikasi (Dhuliawala dkk. 2024). Pendekatan ini meniru metode pemeriksaan ulang yang dilakukan manusia, sehingga efektif dalam mengurangi halusinasi faktual.

Chain-of-Note (CoN) berfokus pada pengelolaan dokumen hasil *retrieval* yang berisik. Melalui *prompt* yang meminta model menyoroti poin penting, mengabaikan dokumen tidak relevan, serta menandai ketidakpastian, CoN menjadikan model lebih selektif terhadap bukti yang digunakan (Yu dkk. 2024).

Sementara itu, *Chain-of-Knowledge (CoK)* memecah masalah kompleks menjadi langkah penalaran bertahap. Mulai dari persiapan konteks, pengumpulan bukti dari sumber heterogen, hingga integrasi dan koreksi progresif. *Prompt* mengarahkan model untuk tidak langsung melompat ke jawaban akhir, melainkan membangun penalaran yang terstruktur (Li dkk. 2023). CoK mengurangi halusinasi yang muncul akibat penalaran terburu-buru dan tidak ter-grounding.

Secara keseluruhan, literatur menegaskan bahwa *prompt* yang terstruktur, eksplisit, dan berlapis lebih mampu mengurangi halusinasi dibandingkan *prompt* sederhana yang hanya berupa satu instruksi. Dengan demikian, *prompt engineering* merupakan komponen penting dalam rancangan sistem LLM yang andal dan *faithful*.

II.9.1 *Zero-shot dan few-shot prompting*

Dua paradigma mendasar dalam *prompting* adalah *zero-shot prompting* dan *few-shot prompting*. Keduanya menjadi fondasi bagi teknik lanjutan seperti *ReAct*, *CoVe*, *CoN*, dan *CoK*.

Zero-shot prompting adalah skenario ketika LLM diminta menyelesaikan suatu tugas hanya berdasarkan instruksi natural tanpa diberikan contoh format sebelumnya. Misalnya instruksi: “Jelaskan perbedaan antara *AHA* dan *BHA* untuk kulit berjerawat.” Model mengandalkan kemampuan generalisasi dari *pre-training* dan *instruction tuning*. Pendekatan ini fleksibel, tetapi rentan memicu halusinasi jika instruksinya ambigu atau tidak menyertakan batasan konteks.

Sebaliknya, *few-shot prompting* memberikan beberapa contoh tugas–jawaban sebelum model diminta menjawab pertanyaan baru. Contohnya, dua atau tiga contoh penjelasan bahan aktif *skincare* berbasis jurnal dapat disertakan dalam *prompt*. Model kemudian belajar dari pola tersebut melalui mekanisme *in-context learning* (Zhao dkk. 2023). Ketika contoh yang diberikan *faithful*, teknik ini dapat mengurangi halusinasi karena model meniru gaya jawaban yang berbasis bukti.

Dalam konteks mitigasi halusinasi, kedua paradigma ini sering dipadukan dengan instruksi tambahan. Misalnya, *zero-shot* dilengkapi klausa: “jawablah hanya berdasarkan konteks berikut dan nyatakan jika informasi tidak tersedia.” Sedangkan *few-shot* dapat menambahkan contoh jawaban yang menunjukkan bagaimana model harus menolak menjawab ketika bukti tidak memadai. Dengan demikian, baik *zero-shot* maupun *few-shot prompting* tidak hanya mengarahkan model memahami tugas, tetapi juga mengelola ketidakpastian dan mencegah halusinasi.

II.10 Kerangka Kerja Evaluasi Sistem *Retrieval-Augmented Generation* (RAG)

Pengembangan sistem *Retrieval-Augmented Generation* (RAG) memerlukan metode *tuning* yang tepat karena kinerjanya dipengaruhi oleh berbagai komponen seperti model *retriever*, model bahasa (*language model*), rancangan *prompt*, serta parameter konfigurasi lainnya. Oleh karena itu, evaluasi sistem RAG yang terotomasi menjadi hal yang penting dalam memastikan keluaran model yang akurat, relevan, dan berlandaskan bukti (Es, Gao, dkk. 2024).

Evaluasi sistem RAG dapat dilakukan pada dua tingkat. Pertama, evaluasi pada tahap *retrieval* yang berfokus pada kualitas dokumen yang berhasil ditemukan oleh *retriever*. Kedua, evaluasi pada tahap *generation* yang berfokus pada kualitas jawab-

an akhir yang dihasilkan oleh *Large Language Model* berdasarkan konteks tersebut. Pada tugas akhir ini, evaluasi tahap *retrieval* menggunakan tiga metrik konvensional yaitu *Recall@k*, *Mean Average Precision* (MAP@k), dan *Normalized Discounted Cumulative Gain* (nDCG@k), sedangkan evaluasi tahap *generation* menggunakan kerangka kerja *Retrieval-Augmented Generation Assessment* (RAGAS).

II.10.1 Metrik Evaluasi *Retrieval*

Metrik evaluasi *retrieval* mengukur kualitas pencarian dokumen pada korpus, mulai dari kelengkapan dokumen relevan yang ditemukan hingga kualitas peringkatnya. Pada tugas akhir ini digunakan tiga metrik utama yang lazim dipakai dalam literatur *Information Retrieval* dan RAG (Ma dkk. 2023; Cormack, Clarke, dan Buettcher 2009; Lewis dkk. 2020).

II.10.1.1 *Recall@k*

Recall@k mengukur kelengkapan informasi yang berhasil di-*retrieve* oleh sistem, yaitu proporsi dokumen relevan pada korpus yang berhasil muncul dalam k dokumen teratas hasil pencarian. Metrik ini cocok untuk mengevaluasi seberapa baik sistem menangkap seluruh dokumen relevan yang tersedia, terutama pada tugas yang membutuhkan konteks lengkap seperti *question answering* berbasis RAG. Rumus *Recall@k* ditulis sebagai berikut:

$$\text{Recall@k} = \frac{|\{d \in R_q\} \cap \{d_1, d_2, \dots, d_k\}|}{|R_q|} \quad (\text{II.4})$$

dengan R_q adalah himpunan seluruh dokumen relevan untuk kueri q pada korpus, dan $\{d_1, d_2, \dots, d_k\}$ adalah k dokumen teratas yang dikembalikan oleh sistem *retrieval*. Nilai *Recall@k* berkisar antara 0 dan 1, di mana nilai 1 menunjukkan bahwa seluruh dokumen relevan berhasil ter-*retrieve* dalam k teratas.

II.10.1.2 *Mean Average Precision* (MAP@k)

Mean Average Precision mengukur kualitas peringkat hasil *retrieval* secara menyeluruh dengan mempertimbangkan posisi setiap dokumen relevan pada daftar hasil. Berbeda dengan *Recall@k* yang hanya menghitung jumlah dokumen relevan, MAP@k juga memperhatikan apakah dokumen relevan tersebut ditempatkan pada posisi atas atau bawah. Metrik ini menjadi metrik utama pada paper *Reciprocal Rank Fusion* oleh Cormack dkk. (Cormack, Clarke, dan Buettcher 2009).

MAP@k dihitung dengan terlebih dahulu menghitung *Average Precision* (AP)

untuk setiap kueri, kemudian merata-ratakannya di seluruh kueri. Rumus *Average Precision* pada k teratas ditulis sebagai berikut:

$$AP@k = \frac{1}{|R_q|} \sum_{i=1}^k \text{Precision}@i \cdot \mathbb{I}[d_i \in R_q] \quad (\text{II.5})$$

dengan $\text{Precision}@i$ adalah *precision* pada i dokumen teratas, $\mathbb{I}[d_i \in R_q]$ adalah fungsi indikator yang bernilai 1 jika dokumen pada peringkat ke- i relevan, serta $|R_q|$ adalah jumlah dokumen relevan untuk kueri q . Selanjutnya *Mean Average Precision* dihitung dengan merata-ratakan $AP@k$ di seluruh kueri pada himpunan uji:

$$MAP@k = \frac{1}{|Q|} \sum_{q \in Q} AP@k(q) \quad (\text{II.6})$$

dengan Q adalah himpunan seluruh kueri yang dievaluasi. Nilai $MAP@k$ berkisar antara 0 dan 1, dengan nilai mendekati 1 menunjukkan bahwa sistem konsisten menempatkan dokumen relevan pada posisi atas di seluruh kueri.

II.10.1.3 *Normalized Discounted Cumulative Gain (nDCG@k)*

Normalized Discounted Cumulative Gain memberikan bobot yang lebih besar untuk dokumen relevan yang berada pada peringkat atas dibandingkan peringkat bawah. Hal ini didasarkan pada asumsi bahwa pengguna sistem pencarian biasanya lebih memperhatikan hasil di posisi teratas. $nDCG@k$ menjadi metrik standar pada evaluasi sistem *retrieval* modern karena sensitivitasnya terhadap kualitas peringkat.

Perhitungan $nDCG@k$ dilakukan dalam tiga tahap. Pertama, hitung *Discounted Cumulative Gain (DCG)* pada k teratas:

$$DCG@k = \sum_{i=1}^k \frac{\text{rel}_i}{\log_2(i+1)} \quad (\text{II.7})$$

dengan rel_i adalah skor relevansi dokumen pada peringkat ke- i . Pada kasus relevansi biner, rel_i bernilai 1 jika dokumen relevan dan 0 jika tidak. Faktor pembagi $\log_2(i+1)$ memberikan diskon yang semakin besar untuk dokumen pada peringkat bawah, sehingga dokumen pada posisi atas memberikan kontribusi yang lebih besar

terhadap skor.

Kedua, hitung *Ideal DCG* (IDCG), yaitu nilai DCG maksimum yang dapat dicapai apabila seluruh dokumen relevan diurutkan pada posisi paling atas:

$$\text{IDCG}@k = \sum_{i=1}^{\min(k, |R_q|)} \frac{1}{\log_2(i + 1)} \quad (\text{II.8})$$

Ketiga, normalisasi DCG dengan IDCG untuk memperoleh nDCG@k:

$$\text{nDCG}@k = \frac{\text{DCG}@k}{\text{IDCG}@k} \quad (\text{II.9})$$

Nilai nDCG@k berkisar antara 0 dan 1, di mana nilai 1 menunjukkan bahwa peringkat yang dihasilkan sistem identik dengan peringkat ideal. Metrik ini sangat berguna untuk membandingkan sistem *retrieval* yang berbeda karena dapat menangkap perbedaan kualitas peringkat meskipun jumlah dokumen relevan yang ditemukan sama.

Pada tugas akhir ini, ketiga metrik tersebut dievaluasi pada $k = 5$ karena lima dokumen teratas yang diteruskan dari *retriever* ke *generator* sesuai dengan praktik umum pada sistem RAG (Ma dkk. 2023; Lewis dkk. 2020) sekaligus menyesuaikan dengan keterbatasan ukuran konteks pada *Large Language Model* yang digunakan.

II.10.2 Kerangka Kerja RAGAS untuk Evaluasi *Generation*

Berbagai metode dan perkakas evaluasi telah diusulkan oleh beberapa tugas akhir sebelumnya untuk memfasilitasi proses penilaian sistem RAG, misalnya oleh Y. Gao dkk. (2023) dan Es dkk. (2024). Namun demikian, banyak strategi evaluasi yang masih bergantung pada probabilitas token dari model bahasa. Pendekatan tersebut menjadi tidak praktis untuk diterapkan pada model sumber tertutup seperti GPT-4, karena model tersebut tidak memberikan akses langsung terhadap probabilitas internalnya. Alternatif lain berupa penilaian berbasis sistem tanya-jawab dengan tipe jawaban singkat juga dinilai tidak representatif terhadap cara kerja sistem RAG secara keseluruhan (Yifan Gao dkk. 2023).

Untuk mengatasi keterbatasan tersebut, dikembangkanlah kerangka kerja bernama **RAGAS** (*Retrieval-Augmented Generation Assessment System*). RAGAS merupakan-

an kerangka kerja evaluasi otomatis yang dirancang untuk menilai kinerja sistem RAG dengan cara memanfaatkan kemampuan LLM dalam melakukan penilaian berbasis *prompt*. Kerangka ini dikembangkan untuk mengukur kualitas sistem RAG secara otomatis berbasis penilaian LLM, baik pada sisi *generation* maupun *retrieval* (Es, Gao, dkk. 2024). RAGAS dipilih sebagai kerangka evaluasi pada tugas akhir ini karena mampu menilai kualitas *generation* berbasis *retrieval* secara otomatis tanpa memerlukan anotasi manusia dalam skala besar, sehingga sesuai untuk eksperimen lintas-konfigurasi yang melibatkan ribuan pasangan pertanyaan dan jawaban.

Dari beberapa metrik yang disediakan RAGAS, tugas akhir ini menggunakan dua metrik yang paling relevan dengan tujuan mitigasi halusinasi, yaitu *faithfulness* pada sisi *generation* dan *context recall* pada sisi *retrieval*.

II.10.2.1 Faithfulness

Aspek *faithfulness* mengukur sejauh mana jawaban yang dihasilkan oleh sistem RAG didasarkan pada konteks yang diberikan. Dalam praktiknya, LLM digunakan untuk mengekstraksi satu atau lebih pernyataan dari setiap kalimat pada jawaban sistem, kemudian memverifikasi apakah pernyataan tersebut terdapat dalam konteks hasil *retrieval*. Nilai *faithfulness* dihitung dengan rumus berikut:

$$F = \frac{|V|}{|S|} \quad (\text{II.10})$$

dengan $|V|$ menyatakan jumlah pernyataan yang didukung oleh konteks (berdasarkan hasil evaluasi LLM), sedangkan $|S|$ adalah jumlah total pernyataan yang dihasilkan sistem RAG. Nilai *faithfulness* yang tinggi menandakan jawaban yang lebih konsisten dengan dokumen sumber, sehingga metrik ini menjadi indikator langsung berkurangnya halusinasi intrinsik dan ekstrinsik.

II.10.2.2 Context Recall

Metrik *context recall* mengukur seberapa banyak informasi relevan yang berhasil dihadirkan pada konteks hasil *retrieval*. LLM menghasilkan sejumlah klaim berdasarkan jawaban referensi (*ground truth*), lalu menghitung proporsi klaim yang dapat didukung oleh konteks yang diambil oleh sistem:

$$\text{Context Recall} = \frac{\text{Jumlah klaim yang sesuai dengan konteks}}{\text{Jumlah total klaim}} \quad (\text{II.11})$$

Walaupun kedua metrik ini sama-sama membandingkan klaim dengan konteks, keduanya mengukur tahap yang berbeda. *Faithfulness* mengukur tahap *generation*, yaitu apakah jawaban yang ditulis LLM benar-benar bersumber dari konteks yang diberikan atau justru mengarang di luar konteks. Sebaliknya, *context recall* mengukur tahap *retrieval*, yaitu apakah dokumen yang berhasil ditarik sudah memuat informasi yang dibutuhkan untuk menjawab dengan benar. Dengan kata lain, *faithfulness* menilai kualitas jawaban LLM, sedangkan *context recall* menilai kualitas pencarian dokumen. Karena itu, sebuah sistem dapat memiliki *context recall* yang tinggi (dokumen yang tepat sudah ditemukan) tetapi *faithfulness* yang rendah (LLM tetap mengarang), sehingga kedua metrik bersifat saling melengkapi dan tidak tumpang tindih.

Pendekatan evaluasi berbasis RAGAS memberikan beberapa keunggulan penting. Pertama, kerangka ini mampu melakukan penilaian yang objektif karena seluruh proses evaluasi dilakukan secara otomatis melalui LLM, sehingga mengurangi bias subjektif dari evaluator manusia. Kedua, RAGAS bersifat adaptif dan dapat diterapkan pada berbagai konfigurasi sistem RAG tanpa memerlukan akses terhadap probabilitas token internal. Ketiga, RAGAS memberikan evaluasi yang komprehensif dengan mempertimbangkan baik aspek *retrieval* maupun *generation*, sehingga menghasilkan pemahaman yang lebih menyeluruh terhadap kinerja sistem.

II.11 Justifikasi Pemilihan Teknik Mitigasi

Berdasarkan seluruh tinjauan pustaka pada bab ini, terdapat banyak teknik yang dapat dipakai untuk menekan halusinasi pada sistem RAG, mulai dari teknik pada tahap praproses dokumen, tahap *retrieval*, hingga tahap *generation*. Dari sekian banyak pilihan tersebut, tugas akhir ini memilih tiga teknik utama, yaitu ekspansi akronim, *query rewriting*, dan *context reranking*. Pemilihan ketiganya tidak dilakukan secara acak, melainkan didasari oleh satu prinsip sederhana, yaitu halusinasi pada sistem RAG dapat muncul dari beberapa titik kegagalan yang berbeda, sehingga mitigasi yang baik perlu menutup titik-titik kegagalan tersebut secara bertahap dan saling melengkapi. Alasan pemilihan masing-masing teknik dapat dilihat dari peran spesifiknya pada setiap tahap alur sistem.

Ekspansi akronim dipilih karena menangani akar masalah yang khas pada domain biomedis, yaitu *vocabulary mismatch*. Pada literatur biomedis, satu istilah panjang sering kali lebih sering dituliskan dalam bentuk akronim, misalnya *Hyperbaric Oxygen* yang ditulis HBO atau *Body Mass Index* yang ditulis BMI. Apabila dokumen yang hanya memuat akronim langsung diindeks tanpa pengayaan, maka representasi

dokumen tersebut tidak memuat bentuk panjang istilahnya. Akibatnya, ketika pengguna bertanya menggunakan istilah lengkap, dokumen yang sebenarnya relevan dapat gagal ditemukan. Ekspansi akronim mengatasi hal ini sejak tahap paling awal, yaitu saat dokumen disiapkan dan diindeks, sehingga masalah tidak menumpuk ke tahap berikutnya. Teknik ini juga dipilih karena ringan dan murah, sebab hanya dijalankan sekali pada saat praproses dan tidak menambah beban komputasi ketika sistem menjawab pertanyaan.

Query Rewriting dipilih karena memperbaiki kualitas pertanyaan dari sisi pengguna sebelum proses pencarian dilakukan. Pertanyaan asli pengguna sering kali singkat, ambigu, atau tidak memakai istilah yang persis sama dengan yang tertulis pada dokumen. Dengan menulis ulang pertanyaan menjadi bentuk yang lebih spesifik dan kaya istilah medis, peluang sistem menemukan dokumen yang tepat menjadi lebih besar. Jika ekspansi akronim memperbaiki masalah dari sisi dokumen, maka *query rewriting* memperbaiki masalah dari sisi kueri, sehingga keduanya bekerja pada dua sisi yang saling berlawanan namun saling menguatkan dalam menutup celah *vocabulary mismatch*.

Context reranking dipilih karena bekerja sebagai penyaring kualitas terakhir sebelum dokumen diberikan ke model bahasa. Meskipun tahap *retrieval* telah berhasil menarik sejumlah dokumen, tidak semua dokumen tersebut memiliki tingkat relevansi yang sama; sebagian dapat bersifat terlalu umum, berulang, atau hanya menyentuh sebagian kecil maksud pertanyaan. Dokumen yang kurang relevan ini menjadi kebisingan (*noise*) yang dapat menyesatkan model saat menyusun jawaban. *Context reranking* menilai ulang setiap dokumen kandidat menggunakan *cross-encoder* yang membaca pasangan kueri dan dokumen secara bersamaan, lalu hanya meneruskan dokumen yang paling relevan ke tahap *generation*. Dengan demikian, model bekerja dengan konteks yang lebih bersih dan terfokus.

Ketiga teknik tersebut dipilih karena bekerja pada tiga tahap yang berbeda namun berurutan, yaitu praproses dokumen, sebelum *retrieval*, dan setelah *retrieval*, sehingga membentuk lapisan mitigasi yang saling melengkapi dari hulu hingga hilir. Pendekatan berlapis ini lebih kuat dibandingkan penerapan satu teknik saja, karena kelemahan pada satu tahap dapat ditutupi oleh tahap lainnya. Sebagai contoh, apabila ekspansi akronim belum sepenuhnya menutup perbedaan istilah, *query rewriting* masih dapat membantu menyelaraskan kueri dengan dokumen, dan apabila masih terdapat dokumen kurang relevan yang lolos, *context reranking* akan menyaringnya sebelum sampai ke model.

Selain pertimbangan teknis, ketiga teknik ini juga dipilih karena bersifat praktis untuk diterapkan pada lingkup tugas akhir. Ketiganya dapat dijalankan tanpa perlu melatih ulang (*fine-tuning*) model bahasa, tidak menuntut perangkat keras khusus berskala besar, serta dapat diaktifkan atau dinonaktifkan secara terpisah. Sifat modular ini penting karena memungkinkan kontribusi masing-masing teknik diukur secara terpisah maupun gabungan pada tahap evaluasi, sehingga pengaruh setiap teknik terhadap penurunan halusinasi dapat dianalisis secara jelas dan adil.

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Bab ini menyajikan kondisi faktual terkini dengan kerangka *CRISP-DM* pada dua tahap awal, yaitu *business understanding* dan *data understanding*. Pendekatan ini membantu menegaskan ruang masalah, pemangku kepentingan, risiko, serta karakteristik data sebelum perancangan solusi pada bab berikutnya (Wirth dan Hipp 2000; Studer, Böttinger, dkk. 2021).


3.1.1 Pemahaman Bisnis (*Business Understanding*)

Model bahasa berskala besar (*Large Language Models*, LLM) telah banyak digunakan untuk tugas penjawaban pertanyaan, dialog, maupun peringkasan. Namun, fenomena halusinasi, yaitu keluaran yang terdengar meyakinkan tetapi tidak faktual atau tidak didukung bukti, masih banyak dilaporkan pada berbagai model mutakhir (Zhao dkk. 2023; Zhang 2024). Dampaknya signifikan pada domain sensitif seperti kesehatan, hukum, dan keuangan, karena kesalahan faktual berpotensi menurunkan keandalan layanan, meningkatkan risiko operasional, serta menimbulkan konsekuensi etis dan kepatuhan.

Secara umum, sistem *retrieval augmented generation* (RAG) berupaya meminimalkan halusinasi dengan menambahkan tahap pengambilan konteks eksternal yang relevan. Meskipun demikian, hasil studi menunjukkan bahwa masalah tetap muncul akibat keterbatasan relevansi bukti, panjang konteks yang melebihi kapasitas model, serta kegagalan *retriever* dalam memilih dokumen pendukung yang paling tepat (Shuster dkk. 2021). Kondisi tersebut menyebabkan keluaran model tetap berpotensi tidak *faithful* terhadap sumber rujukan.

Struktur umum alur kerja sistem RAG saat ini ditunjukkan pada Gambar III.1. Alur tersebut terdiri atas dua tahap besar. Tahap pertama adalah praproses dan pengindeksan, yaitu dokumen sumber (*Data*) dipotong menjadi bagian-bagian kecil (*Chunks*) lalu disimpan sebagai representasi vektor pada basis data vektor (*Vektor*

DB). Tahap kedua adalah pemrosesan kueri, yaitu pertanyaan pengguna (*Input*) dipakai untuk menarik dokumen relevan dari basis data vektor (*Retrieval*), kemudian dokumen tersebut diteruskan ke model untuk menyusun jawaban (*Generation*). Pada alur standar ini belum terdapat komponen koreksi yang secara eksplisit mendeteksi maupun memitigasi halusinasi, baik pada tahap praproses, pencarian, maupun penyusunan jawaban.



Gambar III.1 Alur sistem *retrieval augmented generation* (RAG) saat ini

Sebelum sistem RAG dapat menjawab pertanyaan, dokumen sumber terlebih dahulu melalui tahap praproses, yaitu pemotongan dokumen menjadi *chunk*, pengubahan setiap *chunk* menjadi representasi vektor melalui model *embedding*, lalu penyimpanannya ke dalam basis data vektor (*vector database*) yang menjadi sumber pengetahuan (*domain knowledge*) bagi sistem. Pada domain biomedis, tahap praproses inilah yang justru banyak menimbulkan masalah. Dokumen ilmiah biomedis, khususnya abstrak pada basis data PubMed, banyak menuliskan istilah panjang dalam bentuk akronim, misalnya *Hyperbaric Oxygen* yang ditulis HBO atau *Coronary Heart Disease* yang ditulis CHD. Ketika *chunk* yang hanya memuat akronim tersebut langsung diindeks tanpa pengayaan, representasi vektor yang terbentuk tidak memuat bentuk panjang istilahnya. Akibatnya, ketika pengguna mengajukan kueri dengan istilah lengkap, sistem *retrieval* dapat gagal menemukan dokumen yang sebenarnya relevan karena terjadi ketidaksesuaian istilah antara kueri dan isi basis data vektor, fenomena yang dikenal sebagai *vocabulary mismatch*.

Kegagalan pada tahap *retrieval* ini kemudian diteruskan ke tahap *generation* dan menjadi salah satu pemicu halusinasi. Tabel III.1 memperlihatkan beberapa contoh konkret *vocabulary mismatch* tersebut.

Tabel III.1 Contoh *Retrieval Failure* akibat *Vocabulary Mismatch*

Query Pengguna	Istilah di Paper	Retrieval Failure
<i>Hyperbaric Oxygen</i>	HBO	Gagal menemukan dokumen karena <i>mismatch</i> istilah
<i>Coronary Heart Disease</i>	CHD	Dokumen relevan tidak tertarik ke hasil <i>retrieval</i>
<i>Body Mass Index</i>	BMI	Akronim pada dokumen tidak cocokkan dengan kueri

3.1.2 Data Understanding

Tahap pemahaman data dilakukan untuk mengidentifikasi, menelaah, dan membandingkan himpunan data yang relevan sebagai dasar pengujian sistem berbasis *retrieval augmented generation*. Fokus utama pada fase ini adalah memastikan ketersediaan data yang memiliki struktur pertanyaan yang jelas, dukungan konteks tekstual yang terikat langsung pada pertanyaan, serta tingkat kredibilitas sumber informasi yang memadai untuk dijadikan acuan evaluasi.

Sebagai langkah awal, dilakukan penelusuran terhadap dataset yang digunakan secara luas dalam penelitian model bahasa pada beberapa domain yang menuntut tingkat akurasi tinggi, yaitu hukum, kesehatan, dan keuangan. Ketiga domain dipilih karena masing-masing memiliki pola penggunaan *retrieval augmented generation* yang memerlukan informasi referensial terverifikasi. Oleh sebab itu, dataset kandidat harus memuat pertanyaan terstruktur, konteks yang relevan, serta jawaban yang dapat dibandingkan secara objektif terhadap sumber informasi tertulis.

Hasil pemetaan dan perbandingan dataset kandidat dari ketiga domain disajikan pada Tabel III.2.

Tabel III.2 Perbandingan Dataset Kandidat

Nama Dataset	Domain	Karakteristik Utama	Jumlah Data
CaseHOLD	Hukum	Pertanyaan mengenai preseden hukum berbasis putusan pengadilan federal Amerika untuk menguji kemampuan model memahami penalaran legal (Zheng dkk. 2021).	$\pm 53,000$ contoh
LegalBench	Hukum	Benchmark komprehensif berisi ratusan subtask untuk evaluasi penalaran hukum, interpretasi pasal, serta ekstraksi norma dan entitas legal (Holzenberger dkk. 2023).	Variatif per subtask
COLIEE	Hukum	Dataset berbasis kompetisi internasional untuk ekstraksi informasi dan pembuktian hubungan kasus hukum, mencakup relevansi dokumen dan ranah <i>legal entailment</i> (Rabelo, Kim, dan Goebel 2023).	$\pm 4,000$ – $10,000$ contoh
PubMedQA	Kesehatan	Pertanyaan berbasis abstrak ilmiah dalam basis PubMed dengan struktur tanya jawab faktual serta anotasi oleh pakar domain medis (Jin dkk. 2019).	$\pm 1,000$ entri
MedMCQA	Kesehatan	Soal pilihan ganda pendidikan kedokteran mencakup patofisiologi, diagnosis, farmakologi, dan etika klinis yang dikurasi berdasarkan silabus pendidikan medis (Pal, Umapathi, dan Sankepally 2022).	$\pm 194,000$ soal
MMLU Medical Subset	Kesehatan	Subset khusus medis pada benchmark MMLU yang digunakan untuk evaluasi penguasaan konsep medis, teori klinis, anatomi, serta farmakologi (Hendrycks dkk. 2021).	± 80 – $1,000$ pertanyaan per subkategori

Bersambung ke halaman berikutnya

Tabel III.2 Perbandingan Dataset Kandidat (lanjutan)

Nama Dataset	Domain	Karakteristik Utama	Jumlah Data
Financial PhraseBank	Keuangan	Himpunan kalimat terkait laporan keuangan perusahaan publik yang dilengkapi anotasi dan kategorisasi linguistik untuk interpretasi sentimen dan analisis ekonomi (Malo dkk. 2013).	$\pm 4,800$ kalimat
Banking77	Keuangan	Dataset pertanyaan layanan perbankan yang digunakan secara luas untuk pemetaan intensi pengguna serta evaluasi pemrosesan bahasa dalam layanan finansial digital (Casanueva dkk. 2020).	$\pm 13,000$ contoh

Hasil perbandingan menunjukkan bahwa dataset pada domain hukum dan keuangan memiliki struktur data yang lebih heterogen serta melibatkan beragam bentuk pertanyaan dengan kompleksitas konteks yang tinggi. Pada dataset hukum, pertanyaan sering kali berkaitan dengan preseden yudisial, norma undang-undang, dan proses interpretasi regulasi yang memerlukan pemetaan dokumen lintas kasus. Struktur pertanyaan dan jawaban pada dataset kategori tersebut tidak selalu memiliki keterikatan langsung dengan satu konteks tunggal, sehingga dokumentasi sumber yang relevan bersifat berlapis.

Dataset pada domain keuangan memiliki karakteristik serupa. Sebagian besar himpunan data berorientasi pada interpretasi laporan, sentimen pasar, atau klasifikasi intensi pengguna dalam konteks finansial. Hubungan antara pertanyaan, sumber informasi, dan jawaban tidak selalu bersifat langsung, sehingga validasi faktualitas jawaban terhadap dokumen sumber memerlukan proses pembuktian yang lebih kompleks.

Berbeda dengan kedua domain tersebut, dataset pada ranah kesehatan menawarkan struktur data yang lebih terfokus. Konteks pertanyaan pada dataset kategori ini merujuk pada bukti ilmiah berbasis publikasi dalam jurnal kedokteran, dengan abstrak riset medis sebagai acuan utama. Salah satu dataset yang paling menonjol dibandingkan kandidat lain adalah PubMedQA.

PubMedQA memiliki karakteristik yang mendukung penerapannya pada penelitian

ini. Pertama, setiap entri berisi pertanyaan yang terikat langsung dengan satu abstrak ilmiah dalam basis data PubMed. Hal ini memberikan keterhubungan yang jelas antara pertanyaan, konteks, dan jawaban, sehingga proses pembandingan kesesuaian jawaban terhadap konteks dapat dilakukan secara terukur.

Kedua, PubMedQA memiliki ukuran data yang proporsional untuk kajian akademik. Dengan total sekitar seribu entri, dataset ini representatif untuk menghasilkan analisis berbasis data tanpa memberikan beban komputasi berlebihan.

Ketiga, pertanyaan dalam PubMedQA bersifat faktual dengan format jawaban yang terstandarisasi (*yes, no, dan maybe*). Struktur tersebut mendukung pelaksanaan evaluasi berbasis kesesuaian terhadap konteks karena derajat kebenaran jawaban dapat ditelusuri secara langsung.

Keempat, PubMedQA dipilih karena karakteristik bahasanya yang sangat relevan dengan permasalahan yang diangkat pada tugas akhir ini. Abstrak paper biomedis dan kesehatan pada PubMedQA banyak menggunakan akronim atau singkatan untuk menuliskan istilah medis yang panjang, misalnya HBO untuk *Hyperbaric Oxygen* atau CHD untuk *Coronary Heart Disease*. Karakteristik ini menjadikan PubMedQA sebagai kasus uji yang tepat untuk menguji *vocabulary mismatch*, yaitu ketidaksesuaian istilah antara kueri pengguna dan dokumen, sehingga sangat sesuai untuk mengevaluasi efektivitas ekspansi akronim sebagai salah satu teknik mitigasi yang diusulkan.

Selain itu, PubMedQA banyak digunakan dalam penelitian *question answering* dan studi *retrieval augmented generation* pada domain medis. Penggunaannya secara luas dalam publikasi ilmiah menjadikan dataset ini memiliki landasan metodologis yang kuat serta mempermudah pembandingan hasil penelitian dengan studi sebelumnya.

Berdasarkan keseluruhan hasil analisis pada tahap pemahaman data, PubMedQA dipandang sebagai himpunan data yang paling sesuai untuk digunakan dalam tugas akhir ini. Struktur pertanyaan yang jelas, keterikatan langsung terhadap konteks ilmiah, ukuran dataset yang proporsional, serta format jawaban yang terstandarisasi menjadikannya kandidat utama dalam proses pengujian.

III.2 Analisis Kebutuhan

Pada tahap ini dilakukan perumusan kebutuhan sistem yang menjadi dasar perancangan arsitektur dan eksperimen pada Tugas Akhir. Analisis kebutuhan bertujuan memastikan bahwa sistem yang dikembangkan mampu mendukung proses mitigasi

halusinasi pada *Retrieval-Augmented Generation* (RAG) secara terstruktur dan terukur. Kebutuhan dirumuskan berdasarkan permasalahan yang telah diidentifikasi pada analisis kondisi saat ini, mencakup kegagalan *retrieval*, gangguan *context noise*, dan kecenderungan model menghasilkan keluaran yang tidak *faithful*. Oleh karena itu, kebutuhan sistem dibagi menjadi dua kategori utama, yaitu kebutuhan fungsional yang menggambarkan kapabilitas inti yang harus dimiliki sistem, serta kebutuhan nonfungsional yang mendefinisikan karakteristik mutu dan batasan operasional sistem. Kedua kelompok kebutuhan ini disajikan pada Tabel III.3 dan Tabel III.4.

Tabel III.3 Kebutuhan Fungsional Sistem RAG-LLM untuk Mitigasi Halusinasi

Kode	Kebutuhan Fungsional
F01	Sistem dapat menerima input berupa pertanyaan pengguna dan menghasilkan kueri awal untuk proses <i>retrieval</i> .
F02	Sistem dapat melakukan <i>query rewriting</i> untuk memperbaiki kualitas kueri sebelum proses pengambilan dokumen.
F03	Sistem dapat melakukan <i>retrieval</i> dokumen eksternal berdasarkan kueri yang telah diperbaiki.
F04	Sistem dapat melakukan <i>context reranking</i> untuk memilih dokumen yang paling relevan dan mengurangi <i>context noise</i> .
F05	Sistem dapat menghasilkan jawaban menggunakan model RAG-LLM berdasarkan konteks yang telah difilter.
F06	Sistem dapat melakukan ekspansi akronim biomedis pada tahap praproses dokumen untuk mengatasi <i>vocabulary mismatch</i> .
F07	Sistem dapat menandai atau memberi label pada segmen jawaban yang terdeteksi sebagai halusinatif.
F08	Sistem dapat menghasilkan laporan evaluasi yang mencakup metrik <i>retrieval</i> (<i>Recall@5</i> , <i>MAP@5</i> , <i>nDCG@5</i>), <i>label accuracy</i> , <i>hallucination rate</i> , serta dua metrik RAGAS (<i>faithfulness</i> dan <i>context recall</i>).
F09	Sistem dapat membandingkan keluaran dari beberapa konfigurasi eksperimen, yaitu <i>baseline</i> , ekspansi akronim, <i>query rewriting</i> , <i>context reranking</i> , dan kombinasi menyeluruh.

Tabel III.4 Kebutuhan Nonfungsional Sistem RAG-LLM untuk Mitigasi Halusinasi

Kode	Kategori	Kebutuhan Nonfungsional
NF01	<i>Reliability</i>	Sistem harus menghasilkan proses mitigasi yang konsisten dan stabil pada berbagai set pengujian.
NF02	<i>Explainability</i>	Sistem dapat menampilkan dokumen sumber yang dipakai untuk menghasilkan jawaban sehingga keluaran dapat ditelusuri kembali ke buktinya.
NF03	<i>Reproducibility</i>	Seluruh eksperimen dapat direproduksi melalui penguncian parameter seperti <i>temperature</i> , <i>top-k</i> , dan <i>max tokens</i> .
NF04	<i>Portability</i>	Sistem kompatibel dengan berbagai model LLM dan <i>pipeline</i> RAG tanpa ketergantungan vendor tertentu.
NF05	<i>Ethics and Privacy</i>	Sistem tidak memproses data pribadi serta mengikuti prinsip <i>responsible AI</i> .
NF06	<i>Retrieval Transparency</i>	Skor relevansi setiap dokumen pada tahap <i>retrieval</i> dan <i>reranking</i> dapat ditampilkan dan ditelusuri untuk memeriksa kualitas pencarian.

III.3 Analisis Pemilihan Solusi

III.3.1 Alternatif Solusi

Berdasarkan kajian literatur dan identifikasi kebutuhan pada sistem *Retrieval-Augmented Generation (RAG)*, terdapat tiga alternatif solusi utama yang dapat diterapkan untuk mengurangi halusinasi. Setiap solusi mewakili pendekatan berbeda, baik pada tahap praproses dokumen, *retrieval*, maupun *generation*. Rincian ketiga alternatif tersebut dijelaskan pada subbab berikut.

III.3.1.1 Alternatif Solusi I: Penguatan Tahap *Retrieval* (*Query Rewriting*, *Query Expansion*, dan *Embedding*)

Alternatif solusi pertama berfokus pada penguatan tahap *retrieval*, yaitu tahap yang menentukan kualitas konteks yang akan digunakan oleh model dalam proses generasi. Sejumlah studi menunjukkan bahwa sebagian besar halusinasi pada sistem RAG berasal dari kegagalan menemukan bukti yang benar, relevan, dan lengkap. Ketidaktepatan *retrieval* menyebabkan model bekerja dengan konteks yang tidak

memadai, sehingga meningkatkan peluang model mengisi kekosongan informasi dengan pengetahuan internalnya sendiri. Oleh karena itu, penguatan pada tahap *retrieval* merupakan langkah fundamental dalam menurunkan risiko halusinasi.

Komponen pertama adalah *query rewriting*, yaitu proses memperbaiki struktur pertanyaan pengguna sebelum proses pencarian dokumen dilakukan. Kueri asli sering kali bersifat ambigu, tidak lengkap, atau tidak mencerminkan kebutuhan informasi secara tepat. Melalui *query rewriting*, pertanyaan diubah menjadi representasi yang lebih terstruktur, eksplisit, dan selaras dengan format pengetahuan dalam basis data atau korpus dokumen. Studi mutakhir menunjukkan bahwa teknik ini dapat meningkatkan presisi dokumen yang ditemukan, mengurangi *retrieval error*, serta mencegah masuknya konteks yang tidak relevan yang dapat memicu halusinasi. Dengan kata lain, *query rewriting* menjadi gerbang awal untuk memastikan proses pencarian bukti berjalan dengan benar.

Komponen kedua adalah *query expansion*, yaitu proses memperluas cakupan kueri dengan menambahkan istilah, sinonim, atau frasa terkait yang relevan dengan maksud pertanyaan. Teknik ini bermanfaat ketika pengguna memberikan kueri yang terlalu sempit atau ketika istilah teknis tertentu memiliki banyak referensi semantik di dalam dokumen. Melalui ekspansi kueri, sistem dapat menjangkau lebih banyak kandidat dokumen yang mungkin mengandung jawaban, sehingga mengurangi risiko kehilangan bukti penting. Pendekatan ini sangat efektif pada domain dengan keragaman istilah tinggi atau pada skenario di mana pengguna tidak mengetahui terminologi yang digunakan dalam basis pengetahuan.

Komponen ketiga adalah penguatan *retrieval* berbasis *embedding*, yang bertujuan memetakan kueri dan dokumen ke dalam ruang vektor sehingga kesamaan semantik dapat diukur secara lebih presisi. Berbeda dengan pencarian berbasis kata kunci, metode *embedding* mampu memahami kesamaan makna meskipun tidak menggunakan kata yang sama. Teknik ini memberikan dasar yang kuat dalam memilih dokumen yang relevan, terutama pada korpus besar yang mengandung variasi bahasa atau sinonim. Dengan penggunaan *embedding* yang tepat, sistem dapat menemukan konteks dengan akurasi semantik yang lebih tinggi, sehingga mengurangi potensi kesalahan akibat dokumen yang tidak berhubungan.

Ketiga komponen ini bekerja saling melengkapi. *Query Rewriting* memastikan kueri memiliki struktur yang tepat, *query expansion* memperluas cakupan pencarian agar tidak kehilangan kandidat penting, dan *embedding-based retrieval* memastikan bahwa pemilihan dokumen mempertimbangkan kesamaan semantik secara lebih

mendalam. Dengan demikian, risiko halusinasi dapat ditekan secara signifikan sebelum proses generasi berlangsung.

III.3.1.2 Alternatif Solusi II: Penguatan Tahap *Generation* melalui *Middle Information*, *Context Reranking*, dan *Balance Internal and External Knowledge*

Pendekatan alternatif kedua menitikberatkan pada penguatan tahap *generation*, yaitu tahap ketika model membentuk jawaban akhir berdasarkan konteks yang tersedia. Meskipun informasi yang diretrieval sudah benar dan relevan, sejumlah studi menunjukkan bahwa kualitas generasi tetap dapat menurun apabila model gagal menggunakan seluruh bagian konteks secara efektif. Masalah ini terutama muncul pada skenario dengan konteks panjang, seperti pertanyaan multi-dokumen atau berlapis.

Salah satu penyebab utamanya adalah fenomena *middle curse*, yaitu kondisi ketika model kesulitan memanfaatkan informasi yang berada di bagian tengah konteks. Mekanisme *self-attention* pada arsitektur Transformer mengalami penurunan atensi terhadap token yang posisinya tidak berada di awal atau akhir, diperparah oleh keterbatasan resolusi *positional encoding* dan kapasitas memori ketika memproses konteks panjang. Akibatnya, meskipun informasi penting berada di bagian tengah, model sering melewatkannya sehingga akurasi generasi menurun secara signifikan. Fenomena ini tidak hanya terjadi pada tugas multi-dokumen, tetapi juga pada tugas abstraksi, penulisan jawaban panjang, dan peringkat paragraf.

Untuk mengatasi hal tersebut, teknik pemanfaatan informasi tengah (*utilize the middle information*) digunakan untuk menonjolkan kembali bagian konteks yang berada di tengah agar tetap terlihat oleh model selama proses generasi. Pendekatan ini dapat berupa penyesuaian bobot atensi, pengulangan segmen penting, atau penyusunan ulang konteks sehingga informasi kritis tidak tenggelam di posisi yang kurang strategis. Dengan menjamin bahwa informasi penting di bagian tengah tetap terakses, risiko kesalahan generasi yang berasal dari hilangnya bukti dapat dikurangi.

Selanjutnya, penguatan relevansi melalui *context reranking* juga diperlukan pada tahap generasi. Meskipun *reranking* biasanya diterapkan pada tahap *retrieval*, menata ulang konteks berdasarkan relevansi sebelum generasi membantu model memprioritaskan potongan informasi yang lebih penting. Hal ini sangat berguna ketika konteks berasal dari banyak dokumen atau mengandung bukti yang nilai signifikansinya berbeda. Dengan memastikan bahwa bukti paling relevan ditempatkan

pada posisi yang mudah diproses model, tingkat kesalahan faktual selama generasi dapat ditekan.

Terakhir, pendekatan *balancing internal and external knowledge* diperlukan untuk mengurangi kecenderungan model mengandalkan pengetahuan internalnya secara berlebihan. Pada beberapa kasus, model lebih percaya pada memorinya sendiri meskipun sudah diberikan bukti eksternal yang benar. Sebaliknya, ada kasus lain di mana model terlalu terpaku pada konteks meskipun informasi tersebut tidak lengkap. Mekanisme keseimbangan ini bertujuan menuntun model agar membandingkan dan mengonfirmasi jawaban dengan kedua sumber pengetahuan secara seimbang, sehingga hasil akhir lebih konsisten dan faktual.

Ketiga teknik ini saling melengkapi dalam memperkuat struktur pengambilan keputusan model selama tahap generasi. Dengan memastikan bahwa informasi tengah dapat dimanfaatkan, konteks relevan diprioritaskan, dan pengetahuan internal serta eksternal digunakan secara seimbang, proses generasi menjadi lebih stabil dan berbasis bukti. Hal ini berpotensi signifikan dalam menurunkan halusinasi yang muncul akibat miskonsepsi, hilangnya konteks penting, atau penggunaan bukti yang keliru.

III.3.1.3 Alternatif Solusi III: *Multiple-Phase Mitigation* (Ekspansi Akronim, *Query Rewriting*, dan *Context Reranking*)

Alternatif ketiga berfokus pada pendekatan mitigasi berlapis (*multiple-phase mitigation*) yang bekerja pada beberapa tahapan dalam alur RAG, mulai dari praproses dokumen, tahap *retrieval*, hingga pemilihan konteks akhir sebelum generasi. Pendekatan ini dirancang untuk mengatasi sumber utama halusinasi, yaitu kegagalan menemukan dokumen yang relevan akibat *vocabulary mismatch* maupun kueri yang kurang jelas, serta masuknya konteks yang kurang relevan pada tahap generasi. Dengan menerapkan strategi mitigasi di setiap fase, sistem memperoleh perlindungan yang lebih kuat dan menyeluruh.

Komponen pertama adalah ekspansi akronim, yaitu praproses dokumen yang menyisipkan kepanjangan dari akronim biomedis secara langsung pada teks sebelum dokumen diindeks. Pada domain biomedis, banyak istilah panjang yang justru lebih sering ditulis dalam bentuk akronim pada abstrak ilmiah, sehingga kueri pengguna yang memakai istilah lengkap kerap gagal dicocokkan dengan dokumen yang relevan, fenomena yang dikenal sebagai *vocabulary mismatch*. Dengan menambahkan kepanjangan akronim pada setiap dokumen, peluang pencocokan antara kueri dan dokumen meningkat, sehingga dokumen yang relevan lebih mudah

ditemukan sejak tahap *retrieval* dan kekosongan konteks yang memicu halusinasi dapat dikurangi.

Komponen kedua adalah *query rewriting*, yaitu proses memperjelas maksud pertanyaan pengguna sebelum dokumen dicari. Tanpa perbaikan kueri, banyak sistem RAG gagal mengambil konteks yang tepat karena kueri asli pengguna sering ambigu, kurang spesifik, atau tidak mencerminkan kebutuhan informasi yang sebenarnya. Studi terkini menunjukkan bahwa kueri yang telah ditulis ulang dapat meningkatkan kualitas *retrieval* secara signifikan, memperbaiki presisi dokumen yang ditemukan, serta mengurangi risiko terjadinya halusinasi yang berasal dari konteks yang kurang relevan. Dengan demikian, *query rewriting* berfungsi sebagai gerbang yang memastikan proses pencarian dimulai dengan representasi pertanyaan yang paling akurat (Shu Wang dkk. 2024).

Komponen ketiga adalah *context reranking*, yaitu penataan ulang dokumen yang berhasil diretrieval berdasarkan tingkat relevansinya terhadap pertanyaan. Meskipun sistem berhasil menemukan sejumlah bukti yang benar, tidak semuanya memiliki nilai yang sama. Perbedaan kualitas antardokumen dapat menyebabkan *context conflict* atau *context noise*, di mana bukti yang kurang relevan mengaburkan bukti utama yang diperlukan model. Teknik *reranking* membantu memprioritaskan dokumen dengan dukungan semantik paling kuat dan menempatkannya pada posisi yang lebih mudah diproses model selama tahap generasi. Strategi ini secara langsung mengurangi kemungkinan model menggunakan bukti yang lemah atau bertentangan, khususnya pada skenario multi-dokumen.

Ketiga teknik ini membentuk alur mitigasi bertahap yang saling melengkapi. Ekspansi akronim memperbaiki keterjangkauan dokumen sejak tahap praproses dan pengindeksan, *query rewriting* mencegah kesalahan pada tahap pencarian bukti, dan *context reranking* memastikan hanya bukti terbaik yang menjadi dasar generasi. Dengan perlindungan berlapis pada tahap praproses, *retrieval*, dan pemilihan konteks, risiko kesalahan dapat ditekan dari hulu hingga hilir, menghasilkan sistem RAG yang lebih akurat, lebih dapat dipercaya, dan lebih tahan terhadap variasi pertanyaan serta kompleksitas konteks.

III.3.2 Analisis Penentuan Solusi

Setelah merumuskan beberapa alternatif solusi mitigasi halusinasi pada sistem *Retrieval-Augmented Generation (RAG)*, langkah berikutnya adalah menentukan solusi yang paling tepat untuk diterapkan dalam tugas akhir ini. Penentuan solusi dilakukan menggunakan pendekatan *weighted scoring*, yaitu metode evaluasi alter-

natif berdasarkan sejumlah kriteria yang diberi bobot sesuai tingkat kepentingannya. Setiap alternatif diberi skor menggunakan skala *Likert* satu sampai sepuluh untuk masing-masing kriteria, kemudian dihitung skor total tertimbangnya.

Empat kriteria utama yang digunakan adalah sebagai berikut:

1. Efektivitas, yaitu sejauh mana suatu alternatif mampu mengurangi halusinasi pada sistem RAG-LLM. Kriteria ini menjadi prioritas utama karena halusinasi berdampak langsung pada keakuratan informasi dan kepercayaan pengguna. Kajian terdahulu menunjukkan bahwa kesalahan faktual, termasuk misinformasi pada domain sensitif seperti medis, hukum, dan keuangan, dapat menimbulkan konsekuensi serius bagi individu maupun institusi (Pang dkk. 2024). Oleh karena itu, alternatif dengan skor efektivitas tinggi diharapkan mampu menurunkan halusinasi intrinsik, ekstrinsik, dan faktual secara signifikan.
2. *Feasibility*, yaitu sejauh mana alternatif solusi realistis untuk diimplementasikan dalam konteks tugas akhir ini, baik dari segi kompleksitas teknis, ketergantungan terhadap infrastruktur, maupun ketersediaan alat dan *library*. Solusi dengan *feasibility* tinggi masuk akal untuk diwujudkan pada lingkungan eksperimen dengan sumber daya terbatas tanpa mengorbankan kualitas mitigasi halusinasi.
3. Biaya komputasi, yaitu kebutuhan sumber daya yang diperlukan masing-masing alternatif, misalnya jumlah pemanggilan API, beban *retrieval*, beban *reranking*, serta operasi tambahan seperti verifikasi berulang atau generasi multipel. Semakin tinggi skor pada kriteria ini, semakin hemat dan efisien sumber daya yang dipakai alternatif tersebut untuk dijalankan pada skala eksperimen yang luas.
4. Fleksibilitas, yaitu kemampuan alternatif solusi untuk dikembangkan, diadaptasi, atau diperluas di masa depan. Solusi yang fleksibel cenderung bersifat modular, tidak terlalu terikat pada satu jenis LLM atau satu skenario tugas, serta mudah diintegrasikan dengan teknik mitigasi tambahan pada penelitian lanjutan.

Tiga alternatif solusi yang dibandingkan dalam tugas akhir ini adalah:

1. **Solusi I: Penguatan *retrieval*** (*query rewriting* + *query expansion* + *context reranking*), yang berfokus pada peningkatan kualitas kueri dan seleksi konteks sejak tahap pengambilan informasi.
2. **Solusi II: Penguatan *generation*** (*faithfulness prompting* + *attribution prompting* + *chain-of-verification*), yang mengandalkan desain *prompt* dan verifikasi berjenjang untuk menjaga kesetiaan jawaban terhadap konteks.
3. **Solusi III: Solusi tugas akhir** (ekspansi akronim + *query rewriting* + *context*

reranking), yang menggabungkan praproses ekspansi akronim untuk mengatasi *vocabulary mismatch*, perbaikan kueri sebelum *retrieval*, serta pemilihan konteks paling relevan sebelum generasi.

Bobot kriteria yang digunakan dalam skema *weighted scoring* ditetapkan sebagai berikut: efektivitas sebesar 40%, feasibility sebesar 25%, biaya komputasi sebesar 20%, dan fleksibilitas sebesar 15%. Bobot ini ditentukan berdasarkan prioritas penelitian terhadap efektivitas mitigasi halusinasi sebagai sasaran utama, diikuti kompleksitas implementasi dan efisiensi komputasi sebagai pertimbangan praktis. Skor untuk masing-masing alternatif kemudian dihitung dengan mengalikan skor *Likert* dengan bobot kriteria terkait, lalu menjumlahkannya menjadi skor total tertimbang. Ringkasan hasil penilaian disajikan pada Tabel III.5.

Tabel III.5 Kalkulasi *weighted scoring* pada alternatif solusi mitigasi halusinasi

Kriteria	Bobot	Alternatif Solusi		
		Solusi I	Solusi II	Solusi III
Efektivitas	40%	8	7	9
<i>Feasibility</i>	25%	7	6	9
Biaya komputasi	20%	7	5	7
Fleksibilitas	15%	8	7	8
Skor total		7,55	6,35	8,45

Berdasarkan hasil *weighted scoring* pada Tabel III.5, Solusi III memperoleh skor total tertinggi (8,45) dibandingkan dua alternatif lainnya. Hal ini mencerminkan kombinasi yang seimbang antara efektivitas pengurangan halusinasi, feasibility implementasi yang tinggi karena ekspansi akronim merupakan praproses sederhana, biaya komputasi yang hemat karena tidak menambah pemanggilan model pada saat *inference*, serta fleksibilitas untuk dikembangkan lebih lanjut. Oleh karena itu, tugas akhir ini memilih Solusi III, yaitu kombinasi ekspansi akronim, *query rewriting*, dan *context reranking*, sebagai pendekatan utama mitigasi halusinasi pada sistem RAG-LLM.

Selain hasil *weighted scoring*, pemilihan Solusi III juga didukung oleh temuan penelitian yang menunjukkan bahwa penggabungan beberapa teknik mitigasi dalam satu alur kerja dapat meningkatkan performa RAG-LLM secara nyata. Salah satu pendekatan adalah RAG-HAT (*RAG-Hallucination-Aware Tuning*), yang mengintegrasikan deteksi halusinasi, perbaikan jawaban, dan penyesuaian model melalui *preference optimization*. Penelitian ini melaporkan penurunan halusinasi hingga

27-44% dibandingkan RAG standar (Song dkk. 2024), menunjukkan bahwa pendekatan multi-tahap efektif meningkatkan performa RAG.

Pendekatan lain yang relevan adalah MEGA-RAG, yang menggabungkan *dense retrieval*, *cross-encoder reranking*, dan penggabungan bukti sebelum proses generasi. Hasilnya, akurasi sistem meningkat sekitar 8-14% pada berbagai tugas *knowledge-intensive QA* dibandingkan RAG tanpa mekanisme gabungan (Li, Zhang, dan Ren 2023). Temuan ini memperlihatkan bahwa penggabungan teknik memberikan dampak langsung pada peningkatan kualitas jawaban.

Berdasarkan kedua studi tersebut, terlihat jelas bahwa pendekatan yang menggabungkan beberapa teknik mitigasi pada tahap praproses, *retrieval*, dan pemilihan konteks lebih mampu meningkatkan akurasi dan mengurangi halusinasi secara konsisten. Oleh karena itu, pemilihan Solusi III dalam tugas akhir ini memiliki landasan yang kuat, karena menggabungkan ekspansi akronim, *query rewriting*, dan *context reranking* yang sejalan dengan arah penelitian terbaru.

BAB IV

RANCANGAN SISTEM MITIGASI HALUSINASI RAG-LLM UNTUK SISTEM TANYA JAWAB BIOMEDIS

Bab ini menjelaskan rancangan sistem mitigasi halusinasi berbasis *Retrieval-Augmented Generation Large Language Model* (RAG-LLM) untuk sistem tanya jawab biomedis. Bab ini dibagi menjadi lima bagian utama, yaitu gambaran umum sistem yang memberikan deskripsi cara kerja sistem secara menyeluruh, desain arsitektur sistem yang menjelaskan setiap komponen pembentuk *pipeline*, konfigurasi sistem yang dirancang untuk mengevaluasi kontribusi setiap teknik mitigasi, opsi model bahasa yang digunakan, serta nilai *hyperparameter* dan setup eksperimen.

IV.1 Gambaran Umum Sistem

Sistem yang dirancang merupakan *pipeline* RAG-LLM yang menerima pertanyaan biomedis dari pengguna, melakukan pencarian dokumen relevan pada korpus PubMed yang telah melalui tahap praproses, lalu menghasilkan jawaban berupa label klasifikasi (*yes*, *no*, atau *maybe*) beserta penjelasan singkat yang berlandaskan pada konteks dokumen sumber. Strategi pencarian dokumen yang dirancang adalah *hybrid retrieval*, yakni kombinasi pencarian berbasis kata kunci (BM25) dan pencarian berbasis kemiripan makna (*dense embeddings*) yang digabungkan melalui metode *Reciprocal Rank Fusion* (RRF). Pencarian berbasis BM25 saja tetap diuji sebagai *baseline* pembandingan untuk mengukur kontribusi komponen *dense*. Kedua jenis pencarian ini saling melengkapi. BM25 unggul saat mencari istilah biomedis tertentu seperti nama obat, gen, atau penyakit, sedangkan *dense retrieval* mampu menemukan dokumen yang maknanya mirip walaupun kata yang dipakai berbeda.


Untuk menekan halusinasi, sistem mengintegrasikan tiga teknik mitigasi yang bekerja pada tiga tahap berbeda di *pipeline*:

1. **Ekspansi Akronim Biomedis (Schwartz-Hearst)**, yaitu praproses dokumen yang menyisipkan kepanjangan akronim secara *inline* pada teks *chunk* sebelum diindeks oleh *retriever*. Modul ini bekerja pada tahap *indexing*

dan bertujuan mengatasi *vocabulary mismatch* antara kueri pengguna yang menggunakan istilah panjang dengan dokumen biomedis yang banyak menggunakan akronim seperti HBO, CHD, atau BMI.

2. **Query Rewriting (QR)**, yaitu modul *Large Language Model* (LLM) yang menulis ulang pertanyaan pengguna sebelum dikirim ke *pipeline retrieval*. Tujuannya adalah memperluas istilah medis dan menyesuaikan pertanyaan dengan istilah pada korpus agar pencarian lebih tepat. Modul ini bekerja *sebelum retrieval*.
3. **Context Reranking (CR)**, yaitu model penilai relevansi yang mengurutkan ulang dokumen kandidat hasil RRF dan memilih lima dokumen yang paling relevan untuk diteruskan ke tahap *generation*. Modul ini bekerja *setelah retrieval*.

Gambaran umum sistem dapat dilihat pada Gambar IV.1.



Gambar IV.1 Diagram alur sistem RAG-LLM untuk mitigasi halusinasi

Pipeline ini dirancang secara modular sehingga setiap teknik mitigasi dapat diaktifkan, dinonaktifkan, atau dikombinasikan untuk keperluan analisis kontribusi pada Bab VI. Rancangan modular ini juga memungkinkan sistem diadaptasi ke domain non-biomedis di masa mendatang dengan mengganti basis korpus dan tahap praprosesnya.

IV.2 Desain Arsitektur Sistem

Subbab ini menjelaskan desain dari setiap komponen yang membentuk *pipeline* sistem mitigasi halusinasi RAG-LLM. Pembahasan dimulai dari tahap penyiapan data, dilanjutkan dengan tahap praproses dokumen, kemudian komponen-komponen

pada tahap *retrieval*, lalu komponen *query rewriting* dan *context reranking*, dan diakhiri dengan komponen *generation*.

IV.2.1 Data Preparation

Pada tugas akhir ini, tahap *data preparation* dilakukan pada *dataset* PubMedQA, yaitu *dataset question answering* di bidang biomedis yang dirancang untuk menguji kemampuan sistem dalam menjawab pertanyaan mengenai biomedis ataupun kesehatan. Subset yang digunakan adalah *pqa_labeled* yang berisi 1.000 paper biomedis berlabel *expert*. Setiap paper di PubMedQA bersumber dari PubMed, yakni basis data publikasi ilmiah biomedis yang dikelola oleh *National Library of Medicine* (NLM), Amerika Serikat, dan menjadi rujukan utama bagi peneliti dan praktisi medis di seluruh dunia. Karena bersumber dari PubMed, setiap paper dilengkapi dengan *PubMed ID* (*pubid*) yang dapat digunakan untuk menelusuri publikasi aslinya secara langsung di basis data PubMed *National Center for Biotechnology Information* (NCBI).

Untuk efisiensi biaya komputasi dan tetap menjaga representativitas distribusi label, eksperimen pada tugas akhir ini menggunakan 500 pertanyaan pertama dari subset *pqa_labeled* sebagai himpunan uji, sedangkan korpus dokumen tetap dibangun dari seluruh 1.000 paper agar cakupan basis pengetahuan tidak berkurang. Subset 500 pertanyaan ini mempertahankan proporsi label yang konsisten dengan keseluruhan dataset, yaitu 55,0% *yes* (275 pertanyaan), 31,8% *no* (159 pertanyaan), dan 13,2% *maybe* (66 pertanyaan).

Pada tahap ini, dilakukan pemilihan fitur dari *dataset* PubMedQA. Setiap paper memiliki empat fitur utama: *question*, *context*, *long_answer*, dan *final_decision*. Fitur *question* digunakan sebagai kueri masukan untuk *retriever*, sedangkan fitur *context* dijadikan korpus dokumen yang disimpan ke dalam basis data. Fitur *long_answer* dan *final_decision* disisihkan sebagai *ground truth* untuk keperluan evaluasi dan tidak dimasukkan ke dalam basis data agar tidak terjadi kebocoran jawaban (*answer leakage*) saat proses *retrieval*.

Setelah pemilihan fitur, dilakukan pemeriksaan teks untuk memastikan tidak ada karakter asing yang dapat mengganggu pengambilan informasi. Teks pada PubMedQA sudah tersedia dalam format *Unicode UTF-8* yang konsisten karena bersumber dari PubMed yang terstandarisasi. Oleh karena itu, proses *text cleaning* pada tugas akhir ini cukup berfokus pada normalisasi *whitespace* dan penghapusan karakter kontrol *non-printable* jika ditemukan.

Pada tahap ini juga dilakukan *chunking*, yakni pembagian setiap paper menjadi beberapa segmen yang lebih kecil. Tujuannya supaya *retriever* dapat mengambil bagian paper yang paling relevan dengan pertanyaan, bukan seluruh paper sekaligus. Teknik yang digunakan adalah *section-based chunking*, yaitu memecah paper berdasarkan struktur *section* yang sudah disediakan oleh PubMedQA. Setiap *section* pada abstrak paper, seperti *BACKGROUND*, *DESIGN*, *METHODS*, atau *RESULTS*, dijadikan satu *chunk* yang berdiri sendiri. Karena PubMedQA telah menyediakan informasi *section* ini pada *field context*, penerapan *chunking* dapat dilakukan tanpa perlu memecah teks secara manual.

The image shows a PubMed search result for PMID 12006913. The title is "Do lipids, blood pressure, diabetes, and smoking confer equal risk of myocardial infarction in women as in men? The Reykjavik Study". The authors are Lilja S Jónsdóttir, Nikulás Sigfússon, Vilundur Gudnason, Helgi Sigvaldason, and Gudmundur Thorgeirsson. The abstract is divided into four sections, each labeled as a 'Chunk' on the right:

- Chunk 1 (Background):** Studies on coronary risk factors in men and women are mainly based on mortality data and few compare results of both sexes with consistent study design and diagnostic criteria. This study assesses the major risk factors for coronary events in men and women from the Reykjavik Study.
- Chunk 2 (Design):** Within a prospective, population-based cohort study individuals without history of myocardial infarction were identified and the relative risk of baseline variables was assessed in relation to verified myocardial infarction or coronary death during follow-up.
- Chunk 3 (Methods):** Of the 9681 women and 8888 men who attended risk assessment from 1967-1991, with follow-up period of up to 28 years, 706 women and 1700 men suffered a non-fatal myocardial infarction or coronary death.
- Chunk 4 (Results):** Serum cholesterol was a significant risk factor for both sexes, with hazard ratios (HR) decreasing with age. Systolic blood pressure was a stronger risk factor for women as was ECG-confirmed left ventricular hypertrophy (women HR 2.89, 95% confidence interval [CI] 1.67-5.01; men HR 1.11 [CI 0.86-1.43]). Fasting blood glucose > or =6.7 mmol/L identified significantly higher risk for women (HR 2.65) than men (HR 2.08) as did self-reported diabetes. Triglyceride risk was significantly higher for women and decreased significantly with age. Smoking increased risk two- to five-fold, increasing with dose, for women, which was significantly higher than the doubling in risk for men.

Gambar IV.2 Ilustrasi *Section-Based Chunking* pada Abstrak Paper PubMedQA


Gambar IV.2 menunjukkan ilustrasi penerapan *section-based chunking* pada salah satu paper di PubMedQA (PMID 12006913) yang membahas faktor risiko *myocardial infarction* pada perempuan dibandingkan laki-laki. Pada ilustrasi tersebut, satu abstrak paper terbagi menjadi empat segmen yang masing-masing merepresentasikan satu *section*, yakni *BACKGROUND*, *DESIGN*, *METHODS*, dan *RESULTS*. Setiap segmen disimpan sebagai satu *chunk* independen yang dilengkapi dengan metadata berupa **pubid** sebagai pengenalan paper sumber dan **section_label** sebagai

pengenal jenis *section*. Strategi ini dipilih karena setiap *section* pada abstrak ilmiah biomedis memiliki fokus informasi yang berbeda. *BACKGROUND* menjelaskan latar belakang penelitian, *METHODS* menjelaskan rancangan studi, sedangkan *RESULTS* berisi temuan kuantitatif. Dengan demikian, pemisahan berdasarkan *section* memungkinkan *retriever* mengambil bagian yang paling relevan terhadap kueri tanpa harus mengikutkan *section* lain yang kurang relevan.

Tidak seluruh paper di PubMedQA memiliki empat *section* dengan struktur identik. Variasi struktur abstrak antar paper ditangani secara dinamis, yaitu jumlah *chunk* yang dihasilkan oleh setiap paper mengikuti jumlah *section* yang tersedia pada *field context*. Dengan strategi ini, kumpulan dokumen yang masuk ke basis data *retriever* berasal dari **1.000 paper biomedis** bersumber dari PubMed. Perlu dicatat bahwa *field long_answer* yang berisi *conclusion* dari setiap paper sengaja tidak dimasukkan sebagai *chunk* pada korpus dan hanya digunakan sebagai *reference* pada proses evaluasi untuk menghindari kebocoran jawaban.

IV.2.1.1 Analisis Kelengkapan Section pada Korpus

Untuk memahami karakteristik struktur korpus yang dihasilkan, dilakukan analisis kelengkapan *section* pada 1.000 paper yang digunakan. Analisis ini penting karena struktur abstrak paper biomedis sangat bervariasi antar penerbit dan tipe studi sehingga memengaruhi distribusi informasi yang tersedia bagi *retriever*. Hasil analisis kelengkapan *section* ditampilkan pada Gambar IV.3.



Gambar IV.3 Persentase Kelengkapan *Section* per Paper pada Korpus PubMedQA ($n=1.000$ paper)


Berdasarkan Gambar IV.3, *section Methods/Design* dan *Results/Findings* memiliki

cakupan tertinggi, yaitu masing-masing 97,4% (487 paper). *Section Objective/Aim/Purpose* muncul pada 60,6% paper (303 paper), diikuti *Background/Introduction* pada 46,0% paper (230 paper). Adapun *section* yang lebih spesifik seperti *Patients/Setting/Participants* (11,0%), *Main Outcome Measures* (9,6%), *Intervention* (4,2%), dan *Discussion/Limitations* (4,0%) memiliki cakupan rendah karena hanya muncul pada paper dengan struktur abstrak khusus seperti *randomized controlled trial* (RCT) atau *systematic review*.

Tidak adanya *section* yang mencapai cakupan 100% disebabkan oleh dua faktor. Pertama, sekitar 2,6% paper merupakan *case report* atau *case study* yang secara natur tidak memiliki *section Methods* maupun *Results* formal, melainkan struktur *BACKGROUND* dan *CASE PRESENTATION*. Kedua, terdapat variasi penamaan *section* antar penerbit jurnal yang menyebabkan beberapa paper menggunakan struktur abstrak *non-standard*. Penting juga untuk dicatat bahwa korpus PubMedQA **secara sengaja tidak menyertakan** *section CONCLUSION* dari paper asli, karena bagian tersebut berisi jawaban langsung terhadap pertanyaan penelitian. Penyembunyian *section CONCLUSION* dilakukan oleh perancang *dataset* untuk mencegah kebocoran jawaban dan memastikan *retriever* maupun *generator* benar-benar harus melakukan penalaran berdasarkan *BACKGROUND*, *METHODS*, dan *RESULTS* saja.

IV.2.1.2 Contoh Entri Korpus

Setelah seluruh tahapan *data preparation* dilakukan, setiap *chunk* pada korpus tersimpan sebagai sebuah entri dengan format struktur tertentu yang memuat informasi konten teks beserta metadata pendukungnya. Setiap entri menyimpan teks *chunk* hasil praproses, representasi vektornya (*embedding*) yang dipakai untuk pencarian berbasis kemiripan makna, serta sejumlah metadata seperti *pubid* sebagai pengenal paper sumber, label *section* asal *chunk* (misalnya *BACKGROUND*, *METHODS*, atau *RESULTS*), dan posisi *chunk* pada paper aslinya. Penyertaan metadata ini penting karena memungkinkan sistem tidak hanya menemukan potongan teks yang relevan, tetapi juga menelusuri kembali asal setiap informasi ke paper sumbernya, sehingga jawaban yang dihasilkan tetap dapat diverifikasi terhadap publikasi aslinya. Format entri ini dirancang agar *retriever* dapat mengakses informasi paper dengan efisien sekaligus mempertahankan keterhubungan ke paper sumber di PubMed. Gambar IV.4 menampilkan contoh satu entri korpus yang sudah melalui proses praproses penuh.



```

1  {
2    "pubid": "17113061",
3    "question": "Do mutations causing low HDL-C promote increased
4                carotid intima-media thickness?",
5    "section_label": "BACKGROUND",
6    "text": "Although observational data support an inverse relationship
7            between high-density lipoprotein (HDL (high-density lipoprotein))
8            cholesterol and coronary heart disease (CHD (coronary heart
9            disease)), genetic HDL (high-density lipoprotein) deficiency
10           states often do not correlate with premature CHD (coronary
11           heart disease).",
12   "answer": "Mutations causing low HDL-C levels do not appear to be
13            consistently associated with subclinical atherosclerosis...",
14   "decision": "no",
15   "expanded_acronyms": [
16     {"short": "HDL", "long": "high-density lipoprotein"},
17     {"short": "CHD", "long": "coronary heart disease"}
18   ]
19 }

```

Gambar IV.4 Contoh Entri Korpus pada Basis Data *Retriever*

Contoh pada Gambar IV.4 berasal dari paper dengan *PubMed ID* 17113061 yang membahas hubungan antara mutasi penyebab rendahnya kadar kolesterol baik (*HDL*) dengan ketebalan dinding pembuluh darah karotis. Setiap entri korpus terdiri dari beberapa *field* sebagai berikut:

- a. ***pubid***: Pengenal unik paper di basis data PubMed. Dengan *pubid* ini, paper asli dapat ditelusuri langsung melalui tautan `pubmed.ncbi.nlm.nih.gov/<pubid>/`. Ini menjamin sumber informasi tetap dapat diverifikasi secara mandiri oleh pengguna.
- b. ***question***: Pertanyaan biomedis yang diajukan terhadap paper, digunakan sebagai kueri untuk proses *retrieval*.
- c. ***section_label***: Label *section* dari mana *chunk* berasal, misalnya *BACKGROUND*, *METHODS*, atau *RESULTS*. *Field* ini berperan untuk analisis distribusi *retrieval* per *section*.
- d. ***text***: Konten teks *chunk* sesungguhnya yang menjadi sumber informasi bagi proses *retrieval* maupun *generation*.
- e. ***long_answer***: Jawaban naratif panjang yang berfungsi sebagai *reference* untuk evaluasi. *Field* ini tidak ikut diindeks oleh *retriever*.
- f. ***final_decision***: Label klasifikasi gold standard berupa *yes*, *no*, atau *maybe*. *Field* ini hanya digunakan saat evaluasi untuk membandingkan dengan prediksi sistem.

Struktur entri korpus tersebut menjamin bahwa setiap *chunk* mempertahankan keterhubungan ke paper sumber di PubMed, sehingga jawaban yang dihasilkan

oleh sistem RAG-LLM dapat ditelusuri kembali ke literatur asli yang kredibel. Hal ini penting untuk meningkatkan kepercayaan pengguna pada sistem, terutama di domain medis di mana verifikasi sumber merupakan prasyarat mutlak.

IV.2.2 Praproses Dokumen: Ekspansi Akronim Schwartz-Hearst

Komponen ekspansi akronim bekerja pada tahap praproses dokumen, yaitu setelah *chunking* dan sebelum korpus diindeks ke basis data *retriever*. Tujuan utama komponen ini adalah mengatasi masalah *vocabulary mismatch* antara kueri pengguna yang biasanya menggunakan istilah panjang dengan dokumen biomedis yang sering hanya menggunakan akronim. Algoritma yang dipilih adalah **Schwartz-Hearst**, sebuah algoritma berbasis aturan yang ringan, deterministik, dan tidak memerlukan pelatihan model. Algoritma ini diperkenalkan oleh Schwartz dan Hearst sebagai metode untuk mengekstraksi pasangan akronim-bentuk panjang dari teks biomedis secara otomatis.

Algoritma Schwartz-Hearst bekerja dalam dua tahap utama. Tahap pertama adalah **identifikasi kandidat pasangan akronim-kepanjangan**. Algoritma memindai setiap kalimat untuk menemukan pola *kepanjangan* diikuti akronim dalam tanda kurung (*long form (acronym)*) maupun sebaliknya akronim diikuti kepanjangan dalam tanda kurung (*acronym (long form)*) berdasarkan keberadaan tanda kurung. Tahap kedua adalah **validasi pasangan** dengan mencocokkan setiap huruf akronim secara berurutan dari kanan ke kiri terhadap huruf-huruf pada kandidat kepanjangan. Apabila seluruh huruf akronim dapat dicocokkan dengan huruf pada kandidat kepanjangan, pasangan tersebut dianggap valid dan dimasukkan ke dalam kamus akronim untuk paper terkait.

Setelah pasangan akronim teridentifikasi pada satu paper, modul ekspansi melakukan substitusi *inline* pada setiap kemunculan akronim di seluruh *chunk* milik paper yang sama. Sebagai contoh, kalimat asli “*The mortality rate among the HBO-treated patients was 36%*” diubah menjadi “*The mortality rate among the HBO (hyperbaric oxygenation)-treated patients was 36%*”. Substitusi seperti ini memastikan setiap penyebutan akronim pada teks juga mengandung kepanjangannya, sehingga *retriever* berbasis kata kunci (BM25) maupun berbasis kemiripan makna (*dense embedding*) dapat menemukan dokumen yang sama baik melalui pencarian dengan akronim maupun istilah panjang.

Penerapan ekspansi akronim pada korpus PubMedQA berhasil mendeteksi pasangan akronim-kepanjangan pada sebagian besar paper. Akronim yang umum ditemukan antara lain HBO (*hyperbaric oxygenation*), CHD (*coronary heart disease*), BMI

(*body mass index*), APACHE (*Acute Physiology and Chronic Health Evaluation*), dan banyak akronim spesifik bidang biomedis lainnya. Setelah ekspansi diterapkan, panjang rata-rata *chunk* bertambah dari 423 karakter menjadi 473 karakter (peningkatan sekitar 12%), namun jumlah total *chunk* pada korpus tidak berubah karena ekspansi bersifat substitusi *inline*.

IV.2.3 Komponen Retrieval

Komponen *retrieval* pada sistem ini bertugas mengambil *chunk* yang paling relevan dengan pertanyaan pengguna dari basis data yang telah dibentuk pada tahap praproses. Pendekatan yang digunakan adalah *hybrid retrieval* yang menggabungkan dua jenis pencarian, yaitu pencarian berbasis kata kunci (BM25) dan pencarian berbasis kemiripan makna (*dense retrieval*), dengan hasilnya digabungkan melalui metode *Reciprocal Rank Fusion* (RRF). Subbab ini menjelaskan ketiga komponen tersebut secara berurutan.

IV.2.3.1 BM25 (*Sparse Retrieval*)

BM25 (*Best Matching 25*) merupakan algoritma *ranking* berbasis kata kunci yang menjadi standar pada sistem *Information Retrieval*. BM25 menghitung skor relevansi antara kueri dan dokumen berdasarkan frekuensi kemunculan istilah kueri pada dokumen (*term frequency*), kelangkaan istilah tersebut di seluruh korpus (*inverse document frequency*), serta normalisasi panjang dokumen. Algoritma ini cocok untuk pencarian istilah biomedis spesifik seperti nama obat, gen, penyakit, atau metode klinis yang muncul dalam bentuk eksak pada dokumen.

Pada implementasi sistem ini, BM25 dijalankan menggunakan *library* `rank_bm25` dengan *hyperparameter* $k_1 = 1,5$ dan $b = 0,75$, yang merupakan nilai standar pada literatur. Indeks BM25 dibentuk dari seluruh *chunk* pada korpus yang telah melalui tahap praproses dan ekspansi akronim. Untuk setiap kueri, BM25 mengembalikan 50 *chunk* dengan skor tertinggi (*BM25 top-50*) sebelum digabungkan dengan hasil *dense retrieval*.

IV.2.3.2 Dense Retrieval

Dense retrieval menggunakan model *embedding* untuk mengubah teks *chunk* dan kueri menjadi representasi vektor numerik berdimensi tinggi yang menangkap makna semantik. Dua *chunk* yang memiliki makna mirip akan menghasilkan vektor dengan posisi berdekatan pada ruang vektor, walaupun kata-kata yang digunakan berbeda. Pendekatan ini mampu menemukan dokumen yang relevan meskipun kueri pengguna menggunakan parafrasa atau sinonim dari istilah yang ada pada dokumen.

Implementasi *dense retrieval* pada sistem ini menggunakan model *embedding* dari OpenAI yaitu *text-embedding-3-small* (dimensi 1.536) sebagai pasangan dengan LLM GPT-4.1-mini dan Claude Haiku 4.5, serta model *nomic-embed-text* (dimensi 768) sebagai pasangan dengan LLM Llama. Vektor hasil *embedding* disimpan pada basis data vektor ChromaDB. Pencocokan vektor kueri dengan vektor *chunk* dilakukan menggunakan *cosine similarity*, dan 50 *chunk* dengan skor tertinggi (*Dense top-50*) dikembalikan sebagai kandidat.

IV.2.3.3 *Hybrid Retrieval dengan Reciprocal Rank Fusion (RRF)*

Hasil dari BM25 dan *dense retrieval* digabungkan menggunakan metode *Reciprocal Rank Fusion* (RRF) (Cormack, Clarke, dan Buettcher 2009). RRF merupakan metode penggabungan peringkat yang sederhana namun efektif karena tidak memerlukan normalisasi skor antar *retriever*. RRF hanya membutuhkan posisi peringkat dokumen pada setiap daftar hasil, sehingga dapat menggabungkan hasil BM25 yang menggunakan skor TF-IDF dengan hasil *dense retrieval* yang menggunakan *cosine similarity* secara adil.

Setelah *fusion* dilakukan, sistem mengambil sejumlah *chunk* teratas berdasarkan skor RRF sebagai konteks yang akan diteruskan ke tahap berikutnya. Pada konfigurasi tanpa *context reranking*, lima *chunk* teratas langsung diteruskan ke tahap *generation*. Pada konfigurasi dengan *context reranking*, 20 *chunk* teratas diteruskan ke modul *reranker* untuk dipilih kembali menjadi lima *chunk* paling relevan.

Pemilihan pendekatan *hybrid retrieval* dibandingkan dengan BM25 saja atau *dense retrieval* saja didasarkan pada karakteristik dokumen biomedis yang sering mengandung istilah teknis spesifik sekaligus konsep yang dapat diekspresikan dalam berbagai cara. BM25 unggul untuk pencarian istilah eksak namun lemah ketika kueri menggunakan parafrasa, sedangkan *dense retrieval* unggul untuk pencarian berbasis makna namun kadang melewatkan istilah eksak yang penting. Kombinasi keduanya melalui RRF memberikan cakupan yang lebih baik dibandingkan masing-masing teknik secara individual.

IV.2.4 *Query Rewriting (QR)*

Komponen *query rewriting* bekerja sebelum tahap *retrieval* dengan menulis ulang pertanyaan pengguna menjadi beberapa variasi kueri yang berbeda. Tujuannya adalah memperluas cakupan pencarian sehingga *retriever* memiliki peluang lebih besar menemukan dokumen yang relevan, terutama untuk pertanyaan yang menggunakan istilah berbeda dengan korpus.

Pada implementasi ini, modul *query rewriting* mengadopsi pendekatan *multi-query rewriting* yang diperkenalkan oleh Ma dkk. (Ma dkk. 2023). Pertanyaan asli pengguna dikirim ke LLM bersama instruksi yang meminta model untuk menghasilkan beberapa variasi pertanyaan yang secara semantik setara tetapi menggunakan formulasi yang berbeda. Variasi-variasi tersebut kemudian diteruskan ke modul *hybrid retrieval* secara independen, dan hasilnya digabungkan kembali menggunakan RRF sebelum dipotong ke peringkat lima teratas.

Manfaat utama dari *query rewriting* adalah pertanyaan pengguna yang semula sulit menemukan dokumen relevan dapat di-*rephrase* dengan istilah yang lebih sesuai dengan korpus. Sebagai contoh, pertanyaan “*Does daily aspirin help heart attack survivors?*” dapat ditulis ulang menjadi variasi seperti “*Is aspirin effective for secondary prevention of myocardial infarction?*”, yang menggunakan istilah medis *myocardial infarction* yang lebih sesuai dengan dokumen PubMed.

IV.2.5 Context Reranking (CR)

Komponen *context reranking* bekerja setelah tahap *retrieval* dengan mengurutkan ulang dokumen kandidat berdasarkan tingkat relevansinya terhadap pertanyaan. Tujuannya adalah memastikan dokumen yang paling relevan ditempatkan pada urutan teratas sebelum diteruskan ke tahap *generation*, sehingga konteks yang diterima oleh *Large Language Model* memiliki kualitas yang lebih baik.

Untuk meningkatkan kualitas peringkat, sistem menggunakan model penilai relevansi yang membandingkan setiap pasangan kueri-dokumen secara bersamaan dan menghasilkan skor relevansi. Berbeda dengan *retriever* dasar yang menilai dokumen secara independen, model penilai pada tahap ini dapat menangkap interaksi semantik antara pertanyaan dan kandidat dokumen dengan lebih cermat.

Pada perancangan sistem, modul *retriever* terlebih dahulu mengambil 20 dokumen kandidat dengan skor tertinggi dari proses *hybrid retrieval*. Kedua puluh dokumen tersebut kemudian dinilai ulang oleh modul *reranker*, dan lima dokumen dengan skor relevansi tertinggi dipilih sebagai konteks akhir yang akan diteruskan ke tahap *generation*.

IV.2.6 Komponen Generation

Komponen *generation* bertanggung jawab mengubah konteks dokumen yang telah ter-*retrieve* dan ter-*rerank* menjadi jawaban akhir berupa label klasifikasi (*yes*, *no*, atau *maybe*) beserta penjelasan singkat. Komponen ini menggunakan *Large Language Model* dengan *prompt* yang dirancang khusus untuk meminimalkan

halusinasi pada tahap akhir *pipeline*.

Prompt yang digunakan menerapkan pendekatan *evidence-first citation* yang memaksa model untuk: (1) mengutip temuan spesifik dari konteks yang diberikan, termasuk angka, persentase, dan nilai statistik seperti *p-value* dan *confidence interval*; (2) merangkai kutipan tersebut dalam paragraf yang natural seperti penulisan ilmiah; dan (3) mengakhiri dengan satu kata label klasifikasi pada baris terpisah. Pendekatan ini memastikan jawaban model dapat ditelusuri kembali ke dokumen sumber dan memudahkan verifikasi oleh pengguna.

Model bahasa yang digunakan untuk tahap *generation* dapat dikonfigurasi sesuai kebutuhan eksperimen. Penjelasan lebih rinci mengenai opsi model bahasa yang dipakai pada penelitian ini dibahas pada Subbab IV.4.

IV.3 Konfigurasi Sistem

Untuk mengevaluasi efektivitas setiap teknik mitigasi halusinasi, dirancang dua belas konfigurasi sistem RAG-LLM yang dikelompokkan menjadi tiga kelompok besar. Pengelompokan ini dibuat agar kontribusi setiap komponen utama, yaitu *dense retrieval* dan ekspansi akronim, dapat ditelusuri secara bertahap. Kelompok pertama adalah konfigurasi BM25 tanpa ekspansi akronim sebagai titik awal paling sederhana. Kelompok kedua menambahkan komponen *dense retrieval* di atas BM25 sehingga membentuk *hybrid retrieval*, namun masih tanpa ekspansi akronim. Kelompok ketiga melengkapi *hybrid retrieval* dengan ekspansi akronim sebagai praproses dokumen. Pada setiap kelompok, empat variasi mitigasi diujikan, yaitu *baseline*, penambahan *Query Rewriting* (QR), penambahan *Context Reranking* (CR), serta kombinasi QR dan CR, sehingga total terbentuk dua belas konfigurasi.

Sebelum membahas dua belas konfigurasi secara rinci, Tabel IV.1 merangkum gagasan dasar penambahan komponen secara bertahap beserta tujuan tiap penambahan. Tabel ini bertujuan membantu pembaca memahami pola perbandingan secara konseptual, sebelum melihat rincian dua belas konfigurasi pada Tabel IV.2.

Tabel IV.1 Ringkasan Konseptual Penambahan Komponen Sistem


Konfigurasi	<i>Hybrid Search</i>	Ekspansi Akronim	QR	CR	Tujuan
<i>Baseline</i> (BM25)	–	–	–	–	Pembanding awal
+ <i>Hybrid Search</i>	Ya	–	–	–	Mengukur dampak <i>dense retrieval</i>
+ Ekspansi Akronim	Ya	Ya	–	–	Mengukur dampak ekspansi akronim
+ <i>Query Rewriting</i>	Ya	Ya	Ya	–	Mengukur dampak <i>query rewriting</i>
+ <i>Context Reranking</i>	Ya	Ya	–	Ya	Mengukur dampak <i>context reranking</i>
<i>Pipeline</i> penuh	Ya	Ya	Ya	Ya	Mengukur dampak integrasi seluruh teknik

IV.3.1 Kelompok 1: BM25 tanpa Ekspansi Akronim

Kelompok pertama menggunakan mode *retrieval* berbasis BM25 saja tanpa komponen *dense retrieval* maupun ekspansi akronim. Pada kelompok ini, indeks dibangun dari teks asli korpus PubMedQA dan kueri pengguna dicocokkan langsung dengan indeks BM25. Pemilihan kelompok ini sebagai titik awal bertujuan menyediakan *baseline* sederhana yang menjadi acuan ketika *dense retrieval* dan ekspansi akronim ditambahkan pada kelompok-kelompok berikutnya.

IV.3.1.1 Baseline


Konfigurasi ini hanya memakai BM25 sebagai mekanisme *retrieval*. Kueri pengguna ditokenisasi lalu dicocokkan dengan indeks BM25, kemudian lima *chunk* dengan skor tertinggi (*BM25 Top-5*) langsung diteruskan ke LLM sebagai konteks pembentukan jawaban. Alur prosesnya ditunjukkan pada Gambar IV.5.



Gambar IV.5 Diagram Alur *Pipeline* Konfigurasi BM25 *Baseline*

IV.3.1.2 Baseline + Query Rewriting


Konfigurasi ini menambahkan komponen *Query Rewriting* sebelum tahap *retrieval*. Kueri pengguna terlebih dahulu ditulis ulang oleh LLM agar lebih kaya istilah medis sebelum dicocokkan dengan indeks BM25. Lima *chunk* teratas hasil pencocokan (*BM25 Top-5*) kemudian diteruskan ke LLM. Alur prosesnya ditunjukkan pada Gambar IV.6.



Gambar IV.6 Diagram Alur *Pipeline* Konfigurasi BM25 + *Query Rewriting*

IV.3.1.3 Baseline + Context Reranking


Konfigurasi ini menambahkan komponen *Context Reranking* setelah tahap *retrieval*. BM25 mengambil 20 *chunk* teratas (*BM25 Top-20*), lalu *cross-encoder reranker* mengurutkan ulang berdasarkan kesesuaian terhadap kueri. Lima *chunk* dengan skor *reranker* tertinggi (*Top-5*) diteruskan ke LLM. Alur prosesnya ditunjukkan pada Gambar IV.7.



Gambar IV.7 Diagram Alur *Pipeline* Konfigurasi BM25 + *Context Reranking*

IV.3.1.4 Baseline + Query Rewriting + Context Reranking


Konfigurasi ini menggabungkan kedua teknik mitigasi sekaligus. Kueri pengguna ditulis ulang lalu dipakai pada *retrieval* BM25 untuk mengambil *Top-20*, dan hasil tersebut diurutkan ulang oleh *reranker* untuk memilih *Top-5* terbaik. Alur prosesnya ditunjukkan pada Gambar IV.8.




Gambar IV.8 Diagram Alur *Pipeline* Konfigurasi BM25 + *Query Rewriting* + *Context Reranking*

IV.3.2 Kelompok 2: *Hybrid Retrieval* tanpa Ekspansi Akronim


Kelompok kedua menambahkan komponen *dense retrieval* di atas BM25 sehingga membentuk *hybrid retrieval*. BM25 mengambil 50 *chunk* teratas (*BM25 Top-50*) dan *dense retrieval* juga mengambil 50 *chunk* teratas (*Dense Top-50*), kemudian keduanya digabungkan melalui *Reciprocal Rank Fusion* (RRF). Korpus pada kelompok ini masih berupa teks asli tanpa ekspansi akronim, sehingga selisih kinerja dengan Kelompok 1 dapat ditelusuri murni sebagai kontribusi *dense retrieval*. Empat variasi mitigasi diuji pada kelompok ini dengan alur yang ditunjukkan pada Gambar IV.9, Gambar IV.10, Gambar IV.11, dan Gambar IV.12.




Gambar IV.9 Diagram Alur *Pipeline* Konfigurasi *Hybrid Baseline* (tanpa Ekspansi Akronim)



Gambar IV.10 Diagram Alur *Pipeline* Konfigurasi *Hybrid + Query Rewriting* (tanpa Ekspansi Akronim)



Gambar IV.11 Diagram Alur *Pipeline* Konfigurasi *Hybrid* + *Context Reranking* (tanpa Ekspansi Akronim)




Gambar IV.12 Diagram Alur *Pipeline* Konfigurasi *Hybrid* + *Query Rewriting* + *Context Reranking* (tanpa Ekspansi Akronim)


Pada konfigurasi *baseline*, lima *chunk* dengan skor RRF tertinggi langsung diteruskan ke LLM. Pada konfigurasi dengan QR, kueri pengguna ditulis ulang terlebih dahulu sebelum diteruskan ke kedua *retriever*. Pada konfigurasi dengan CR, 20 *chunk* teratas hasil RRF (*Top-20*) diurutkan ulang oleh *reranker* sebelum lima *chunk* terbaik dipilih. Konfigurasi dengan QR dan CR menggabungkan keduanya, yaitu kueri ditulis ulang sebelum *retrieval* dan hasil *retrieval* direranking sebelum diteruskan ke LLM.

IV.3.3 Kelompok 3: *Hybrid Retrieval* dengan Ekspansi Akronim


Kelompok ketiga melengkapi konfigurasi *hybrid retrieval* pada Kelompok 2 dengan menambahkan ekspansi akronim sebagai praproses dokumen. Karena ekspansi akronim hanya memengaruhi isi indeks dan tidak mengubah komponen *retrieval* maupun *generation*, alur *pipeline* pada kelompok ini identik dengan kelompok kedua kecuali pada tahap penyiapan korpus, yaitu setiap akronim pada setiap *chunk* dokumen disisipi kepanjangannya secara *inline* sebelum dilakukan tokenisasi dan pembentukan indeks. Diagram alur untuk keempat variasi mitigasi pada kelompok ini ditunjukkan pada Gambar IV.13, Gambar IV.14, Gambar IV.15, dan Gambar IV.16.




Gambar IV.13 Diagram Alur *Pipeline* Konfigurasi *Hybrid Baseline* (dengan Ekspansi Akronim)



Gambar IV.14 Diagram Alur *Pipeline* Konfigurasi *Hybrid + Query Rewriting* (dengan Ekspansi Akronim)



Gambar IV.15 Diagram Alur *Pipeline* Konfigurasi *Hybrid + Context Reranking* (dengan Ekspansi Akronim)



Gambar IV.16 Diagram Alur *Pipeline* Konfigurasi *Hybrid + Query Rewriting + Context Reranking* (dengan Ekspansi Akronim)

Selisih kinerja antara Kelompok 3 dan Kelompok 2 dapat ditelusuri secara langsung sebagai kontribusi praproses ekspansi akronim, karena seluruh komponen *retrieval*

dan *generation* di antara kedua kelompok identik dan satu-satunya perbedaan terletak pada isi indeks.

IV.3.4 Ringkasan Konfigurasi

Ringkasan keseluruhan dua belas konfigurasi beserta komponen aktifnya disajikan pada Tabel IV.2. Tabel ini dikelompokkan sesuai tiga kelompok pada subbab sebelumnya, sehingga pembaca dapat dengan mudah melihat perbedaan komponen aktif antar kelompok dan antar variasi mitigasi.

Tabel IV.2 Ringkasan Konfigurasi Sistem RAG-LLM yang Dirancang

No.	Konfigurasi	Mode <i>Retrieval</i>	Ekspansi Akronim	QR	CR
Kelompok 1: BM25 tanpa Ekspansi Akronim					
1	<i>Baseline</i>	BM25	Tidak	Tidak	Tidak
2	<i>Baseline</i> + QR	BM25	Tidak	Ya	Tidak
3	<i>Baseline</i> + CR	BM25	Tidak	Tidak	Ya
4	<i>Baseline</i> + QR + CR	BM25	Tidak	Ya	Ya
Kelompok 2: <i>Hybrid Retrieval</i> tanpa Ekspansi Akronim					
5	<i>Baseline</i>	<i>Hybrid</i>	Tidak	Tidak	Tidak
6	<i>Baseline</i> + QR	<i>Hybrid</i>	Tidak	Ya	Tidak
7	<i>Baseline</i> + CR	<i>Hybrid</i>	Tidak	Tidak	Ya
8	<i>Baseline</i> + QR + CR	<i>Hybrid</i>	Tidak	Ya	Ya
Kelompok 3: <i>Hybrid Retrieval</i> dengan Ekspansi Akronim					
9	<i>Baseline</i>	<i>Hybrid</i>	Ya	Tidak	Tidak
10	<i>Baseline</i> + QR	<i>Hybrid</i>	Ya	Ya	Tidak
11	<i>Baseline</i> + CR	<i>Hybrid</i>	Ya	Tidak	Ya
12	<i>Baseline</i> + QR + CR	<i>Hybrid</i>	Ya	Ya	Ya

Pengelompokan ini memungkinkan dua jenis analisis sekaligus pada Bab VI, yaitu (1) perbandingan Kelompok 1 dengan Kelompok 2 untuk menilai kontribusi *dense retrieval* terhadap mode BM25 saja, serta (2) perbandingan Kelompok 2 dengan Kelompok 3 untuk menilai kontribusi praproses ekspansi akronim pada konfigurasi *hybrid retrieval*.

IV.4 Opsi Model

Pemilihan model bahasa didasarkan pada empat hal, yaitu kualitas keluaran untuk teks biomedis, ketersediaan model atau API yang stabil, biaya yang masih sesuai

anggaran tugas akhir, serta kemampuan menangani konteks panjang. Berdasarkan pertimbangan tersebut, dipilih opsi model yang ditunjukkan pada Tabel IV.3.

Tabel IV.3 Opsi model dalam implementasi sistem RAG-LLM

No.	Jenis Model	Opsi Model	Penyedia
1	<i>Embedding</i>	nomic-embed-text (768d)	Ollama (lokal)
		text-embedding-3-small (1536d)	OpenAI API
2	<i>Reranker</i>	ms-marco-MiniLM-L-6-v2	sentence-transformers
3	LLM Genera- tor	llama-3.3-70b-instruct	OpenRouter API
		gpt-4.1-mini	OpenAI API
		claude-haiku-4.5	Anthropic API

Pemilihan model pada penelitian ini didasarkan pada pertimbangan efisiensi, biaya, dan karakteristik masing-masing model. Model *embedding nomic-embed-text* dipilih untuk dipasangkan dengan Llama karena keduanya dapat dijalankan secara lokal melalui Ollama, sehingga tidak memerlukan biaya API dan tidak bergantung pada koneksi jaringan eksternal. Sementara itu, *text-embedding-3-small* digunakan bersama GPT-4.1-mini dan Claude Haiku 4.5 karena telah terbukti memberikan kualitas representasi semantik yang baik pada sistem RAG dengan biaya penggunaan yang relatif terjangkau. Pada tahap *reranking*, model *ms-marco-MiniLM-L-6-v2* dipilih karena memiliki ukuran yang kecil, sekitar 22 MB, sehingga dapat dijalankan dengan cepat pada CPU tanpa memerlukan GPU, namun tetap mampu memberikan performa yang baik dalam tugas *passage reranking*. Untuk komponen LLM, Llama 3.3 70B digunakan sebagai representasi model sumber terbuka berukuran besar yang diakses melalui OpenRouter, GPT-4.1-mini dipilih sebagai representasi model sumber tertutup dari OpenAI yang menawarkan keseimbangan antara biaya dan kemampuan *instruction following*, sedangkan Claude Haiku 4.5 digunakan sebagai representasi model sumber tertutup dari Anthropic yang dikenal menghasilkan respons yang lebih hati-hati dan terstruktur. Anthropic dengan karakteristik jawaban yang cenderung lebih hati-hati dan terstruktur.

IV.5 Hyperparameter dan Setup Eksperimen

Subbab ini menjelaskan nilai *hyperparameter* yang dipakai pada setiap komponen *pipeline* beserta pengaturan evaluasinya. Seluruh nilai dipilih berdasarkan rekomendasi literatur dan hasil studi pustaka pada Bab II, lalu ditetapkan sama untuk

seluruh konfigurasi supaya perbandingannya adil. Daftar lengkapnya ditunjukkan pada Tabel IV.4.

Tabel IV.4 Hyperparameter dan setup eksperimen

Komponen	Parameter	Nilai	Catatan
BM25	top-K	50	Sebelum RRF fusion
Dense	top-K	50	Sebelum RRF fusion
RRF	konstanta k	60	Standar literatur
Final	top-K (tanpa CR)	5	Diteruskan ke generator
CR	jumlah kandidat	20	Sebelum reranking
CR	top-K final	5	Setelah reranking
Generator	temperature	0.0	Supaya keluaran konsisten
Generator	max_tokens	300	Cukup untuk 2 sampai 3 kalimat dan label
QR	temperature	0.3	Membatasi variasi parafrasa
QR	max_tokens	150	Cukup untuk <i>rewritten kueri</i>
Sampling	jumlah sampel	500	Sama untuk seluruh konfigurasi
Sampling	seed	42	Untuk menjaga reproduktibilitas

Pemilihan setiap nilai parameter di atas mempertimbangkan keseimbangan antara cakupan, presisi, dan biaya komputasi. Pada tahap awal *retrieval*, sistem sengaja mengambil cukup banyak kandidat, yaitu 50 dokumen dari masing-masing *retriever* (BM25 dan *dense*), agar dokumen yang benar-benar relevan tidak terlewat sebelum proses penggabungan. Nilai yang terlalu kecil berisiko membuang dokumen penting sejak awal, sedangkan nilai yang terlalu besar hanya menambah beban komputasi tanpa banyak menambah dokumen relevan baru. Setelah penggabungan dan pemeringkatan, hanya lima dokumen teratas yang diteruskan ke LLM agar konteks tetap ringkas dan terfokus, sehingga muat dalam kapasitas konteks model dan tidak memasukkan terlalu banyak dokumen kurang relevan yang justru dapat memicu halusinasi. Ukuran *chunk* ditetapkan pada tingkat kalimat dan paragraf

abstrak supaya setiap potongan tetap utuh secara makna, karena potongan yang terlalu pendek dapat kehilangan konteks sedangkan potongan yang terlalu panjang membuat pencocokan menjadi kurang tajam.

Pada sisi model, *embedding* text-embedding-3-small dipilih karena memberikan kualitas representasi makna yang baik dengan biaya pemanggilan yang relatif rendah, sehingga sesuai untuk eksperimen berskala ribuan pertanyaan, sedangkan *reranker* ms-marco-MiniLM-L-6-v2 dipilih karena merupakan *cross-encoder* ringan yang dapat dijalankan secara lokal tanpa biaya API namun tetap efektif menilai kecocokan pasangan kueri dan dokumen karena membaca keduanya secara bersamaan. Selanjutnya, parameter pemanggilan LLM ditetapkan dengan tujuan menjaga konsistensi dan keterulangan hasil. Nilai *temperature* pada tahap *generation* ditetapkan 0 agar model menghasilkan jawaban yang deterministik dan tidak mengarah variasi keluaran, sehingga klasifikasi label menjadi stabil; sementara pada tahap *query rewriting* nilai *temperature* sedikit dinaikkan menjadi 0,3 agar model masih dapat menghasilkan parafrasa kueri yang lebih kaya istilah biomedis tanpa menyimpang terlalu jauh dari maksud pertanyaan asli. Adapun *seed* ditetapkan pada nilai tetap (42) supaya setiap pemanggilan model pada kondisi yang sama menghasilkan keluaran yang identik, sehingga seluruh eksperimen dapat direproduksi dan perbandingan antar konfigurasi menjadi adil.

Evaluasi hasil dilakukan dalam dua tahap untuk setiap konfigurasi. Tahap pertama menghitung kualitas *retrieval* menggunakan tiga metrik utama, yaitu *Recall@5*, *Mean Average Precision* (MAP@5), dan *Normalized Discounted Cumulative Gain* (nDCG@5). Tahap kedua menghitung kualitas jawaban yang dihasilkan menggunakan *Label Accuracy* terhadap *ground truth* PubMedQA serta dua metrik dari kerangka RAGAS, yaitu *faithfulness* dan *context recall*. Penjelasan rinci untuk masing-masing metrik beserta cara perhitungannya telah dibahas pada Bab II, dan hasil evaluasi disajikan pada Bab VI.

BAB V

IMPLEMENTASI

Bab ini menjelaskan implementasi teknis dari rancangan sistem yang telah dijabarkan pada Bab IV. Implementasi mencakup penyiapan lingkungan kerja, pembangunan indeks korpus PubMedQA, integrasi tiga komponen mitigasi halusinasi (ekspansi akronim, *query rewriting*, dan *context reranking*), serta penyiapan kerangka evaluasi. Seluruh komponen dikembangkan dalam bentuk *notebook* Python yang dijalankan secara lokal pada satu unit *laptop* pengembangan dan memanfaatkan beberapa layanan API eksternal untuk pemanggilan model bahasa berukuran besar.

Penjelasan pada bab ini disusun mengikuti alur sistem secara berurutan, yaitu dimulai dari penyiapan lingkungan implementasi, dilanjutkan dengan pembangunan *pipeline* pengolahan data, implementasi komponen *retrieval*, integrasi komponen mitigasi halusinasi, hingga tahap *generation* dan kerangka evaluasi, serta diakhiri dengan prototipe antarmuka demonstrasi. Pendekatan implementasi diarahkan agar setiap komponen bersifat modular dan dapat diuji secara terpisah, sehingga kontribusi tiap teknik mitigasi dapat dianalisis secara independen pada tahap evaluasi. Selain itu, seluruh proses pembangunan indeks dan pemanggilan model dirancang agar dapat direproduksi, antara lain dengan menetapkan *seed* tetap serta menyimpan indeks ke berkas sehingga tidak perlu dibangun ulang pada setiap eksekusi.

V.1 Lingkungan Implementasi

Sistem mitigasi halusinasi RAG-LLM untuk sistem tanya jawab biomedis ini diimplementasikan pada satu mesin pengembangan tunggal dengan kombinasi infrastruktur lokal dan layanan eksternal. Infrastruktur lokal digunakan untuk menyimpan indeks vektor, menjalankan model *embedding* dan *reranker* ringan, serta mengeksekusi seluruh *notebook* eksperimen. Layanan API eksternal dipakai untuk pemanggilan *Large Language Model* (LLM) berukuran besar yang tidak dapat dijalankan secara lokal karena keterbatasan memori dan kapasitas komputasi. Subbab ini menjelaskan spesifikasi perangkat keras dan perangkat lunak, konfigurasi layanan API dan basis data, serta organisasi kode pada repositori penelitian.

Kombinasi infrastruktur lokal dan layanan *cloud* ini dipilih dengan mempertimbangkan keseimbangan antara biaya, kemudahan reproduksi, dan keterbatasan perangkat. Komponen yang ringan dan sering dipanggil, seperti *retriever* dan *reranker*, dijalankan secara lokal agar tidak menimbulkan biaya *Application Programming Interface* (API) berulang, sedangkan LLM berukuran besar yang menuntut sumber daya tinggi diakses melalui API agar tetap dapat digunakan tanpa perangkat keras khusus. Dengan pembagian peran ini, eksperimen berskala ribuan pertanyaan tetap dapat dijalankan pada satu unit *laptop* pengembangan.

V.1.1 Spesifikasi Perangkat Keras dan Perangkat Lunak

Pengembangan dan pengujian sistem dilakukan pada satu unit *laptop* HP 14-ep1155TU sebagai mesin komputasi utama. Komputer ini menggunakan prosesor Intel Core 5 120U berkecepatan dasar 1,40 GHz dengan arsitektur x64, RAM 16 GB (15,7 GB *usable*), serta *Solid State Drive* (SSD) berkapasitas 477 GB. Mesin ini tidak memiliki akselerator *Graphics Processing Unit* (GPU) terpisah; pengolahan grafis ditangani oleh kartu grafis terintegrasi Intel Graphics dengan memori *shared* 128 MB. Oleh karena itu, seluruh beban komputasi lokal, termasuk pembangunan indeks BM25, pembentukan vektor *embedding*, kueri ChromaDB, serta inferensi *reranker*, dijalankan sepenuhnya di atas *Central Processing Unit* (CPU). Pendekatan *CPU-only* dipilih karena beban kerja sistem masih dapat diselesaikan dalam waktu yang wajar tanpa memerlukan GPU, mengingat ukuran korpus PubMedQA yang relatif kecil dan model *reranker* yang dipilih sengaja berukuran ringan.

Dari sisi perangkat lunak, sistem berjalan di atas Windows 11 (64-bit). Bahasa pemrograman utama yang digunakan adalah Python versi 3.11 yang mendukung sebagian besar pustaka *scientific computing* dan *machine learning* terbaru, termasuk PyTorch, NumPy, pandas, dan turunannya. *Notebook* eksperimen dijalankan menggunakan Jupyter Notebook melalui lingkungan virtual (*virtualenv*) agar dependensi tiap modul tidak saling mengganggu. Sistem mengandalkan beberapa pustaka utama, yaitu *rank-bm25* untuk membangun indeks BM25, *chromadb* sebagai basis data vektor lokal, *sentence-transformers* untuk model *reranker* berbasis *cross-encoder*, serta klien resmi OpenAI, Anthropic, dan OpenRouter untuk pemanggilan LLM eksternal. Untuk evaluasi otomatis, sistem memakai pustaka ragas dengan versi kustom yang telah disesuaikan agar metrik *faithfulness* dapat membaca konteks panjang tanpa pemotongan agresif. Model LLM lokal dijalankan menggunakan Ollama sebagai *runtime* yang menyediakan antarmuka HTTP sederhana untuk model Llama versi terkuantisasi. Ringkasan seluruh komponen perangkat keras dan perangkat lunak disajikan pada Tabel V.1.

Tabel V.1 Ringkasan Perangkat Keras dan Perangkat Lunak yang Digunakan pada Penelitian

Komponen	Spesifikasi / Pustaka
<i>Perangkat Keras</i>	
Mesin komputasi	HP 14-ep1155TU
Prosesor	Intel Core 5 120U @ 1,40 GHz (x64)
RAM	16 GB (15,7 GB <i>usable</i>)
Penyimpanan	SSD 477 GB
Kartu grafis	Intel Graphics terintegrasi (128 MB <i>shared</i>)
Mode eksekusi	CPU-only (tanpa akselerasi GPU)
<i>Perangkat Lunak</i>	
Sistem operasi	Windows 11 (64-bit)
Bahasa pemrograman	Python 3.11
Lingkungan eksperimen	Jupyter Notebook + <i>virtualenv</i>
Pustaka BM25	rank-bm25
Basis data vektor	chromadb (mode lokal)
Pustaka <i>embedding</i>	sentence-transformers, OpenAI text-embedding-3-small, Ollama nomic-embed-text
Pustaka <i>reranker</i>	sentence-transformers dengan ms-marco-MiniLM-L-6-v2
Runtime LLM lokal	Ollama (llama3.2, llama3.3)
Klien LLM eksternal	openai, anthropic, OpenRouter (kompatibel OpenAI)
Pustaka evaluasi	ragas (kustom, dengan perbaikan truncation)
Pustaka pemrosesan data	pandas, numpy, datasets (Hugging Face)
Pustaka NLP tambahan	nlTK, regex, tiktoken

V.1.2 Konfigurasi Layanan API dan Basis Data

Sistem mengintegrasikan tiga layanan API model bahasa berbasis *cloud*, yaitu OpenAI API untuk pemanggilan gpt-4.1-mini dan text-embedding-3-small, Anthropic API untuk pemanggilan claude-haiku-4.5, serta OpenRouter sebagai *gateway* untuk mengakses llama-3.3-70b-instruct dari penyedia Meta. Pendekatan multi-penyedia ini dipilih agar setiap kategori model, yaitu sumber tertutup berkualitas tinggi (OpenAI, Anthropic) dan sumber terbuka berukuran besar (Llama via OpenRouter), dapat dibandingkan secara adil pada beban kerja yang sama.

Selain layanan eksternal, sistem juga memakai Ollama sebagai layanan lokal yang menjalankan model llama3.2 dan nomic-embed-text secara *on-premise* pada CPU, sehingga eksperimen tetap dapat berjalan tanpa biaya API ketika digunakan hanya untuk *prototyping* atau pengujian awal.

Seluruh kredensial layanan eksternal, termasuk OPENAI_API_KEY, ANTHROPIC_API_KEY, dan OPENROUTER_API_KEY, disimpan pada berkas `.env` di akar repositori dan dimuat menggunakan pustaka `python-dotenv` pada awal setiap *notebook*. Berkas `.env` ini dimasukkan ke dalam `.gitignore` agar informasi sensitif tidak ikut terunggah saat repositori didorong ke *remote* GitHub. Untuk mencegah pelanggaran batas *rate limit* pada masing-masing penyedia, setiap pemanggilan API diberi *retry policy* sederhana dengan *exponential backoff* pada kegagalan *transient*, serta jeda kecil antarpermintaan ketika dijalankan pada eksperimen berukuran besar (500 pertanyaan). Parameter pemanggilan, seperti suhu (*temperature*), *top-p*, dan jumlah token maksimum, ditetapkan sama untuk seluruh konfigurasi agar perbandingan antarmodel bersifat *apple-to-apple*.

Dari sisi basis data, sistem menggunakan dua jenis penyimpanan lokal yang saling melengkapi. Pertama, indeks BM25 dibangun menggunakan pustaka `rank-bm25` lalu disimpan dalam berkas *pickle* (`pubmedqa_bm25.pkl` dan `pubmedqa_bm25_ekspansi.pkl`) sehingga indeks tidak perlu dibangun ulang setiap kali *notebook* dijalankan. Kedua, indeks vektor menggunakan ChromaDB dalam mode *persistent client* dengan direktori penyimpanan terpisah untuk masing-masing kombinasi praproses, yaitu `pubmedqa_chroma/` (korpus asli), `pubmedqa_chroma_ekspansi/` (korpus dengan ekspansi akronim), serta `pubmedqa_chroma_llama/` (korpus dengan *embedding* dari Ollama). Pemisahan direktori ini bertujuan memastikan setiap variasi eksperimen memiliki basis data yang konsisten dan dapat diuji ulang tanpa risiko *cache poisoning* antarkonfigurasi. Ringkasan layanan API eksternal dan basis data lokal disajikan pada Tabel V.2.

Tabel V.2 Ringkasan Konfigurasi Layanan API Eksternal dan Basis Data Lokal

Layanan / Basis Data	Konfigurasi
<i>Layanan API Model Bahasa Eksternal</i>	
OpenAI API	Model gpt-4.1-mini untuk <i>generation</i> , text-embedding-3-small (1.536d) untuk <i>embedding</i> ; kredensial OPENAI_API_KEY
Anthropic API	Model claude-haiku-4.5 untuk <i>generation</i> ; kredensial ANTHROPIC_API_KEY
OpenRouter	Model meta-llama/llama-3.3-70b-instruct (kompatibel <i>schema</i> OpenAI); kredensial OPENROUTER_API_KEY
<i>Layanan Lokal</i>	
Ollama	<i>Runtime</i> lokal untuk llama3.2, llama3.3, dan nomic-embed-text (768d); diakses melalui HTTP pada localhost:11434
<i>Basis Data Lokal</i>	
Indeks BM25	Format <i>pickle</i> (pubmedqa_bm25.pkl, pubmedqa_bm25_ekspansi.pkl)
ChromaDB	Mode <i>persistent client</i> , direktori terpisah per praproses (pubmedqa_chroma/, pubmedqa_chroma_ekspansi/, pubmedqa_chroma_llama/)
<i>Manajemen Konfigurasi</i>	
Berkas .env	Pusat penyimpanan kredensial API; dimuat melalui python-dotenv; dimasukkan ke .gitignore

V.1.3 Struktur dan Organisasi Repositori

Kode sumber sistem disusun dengan prinsip pemisahan tanggung jawab agar tiap komponen utama dapat dikembangkan dan diuji secara independen. Direktori *notebook* eksperimen ditata mengikuti tiga kelompok konfigurasi yang sama dengan Tabel IV.2 di Bab IV, dan setiap kelompok dipecah lagi per model bahasa, sehingga alur eksperimen mudah ditelusuri dari penyiapan korpus, pembangunan indeks, eksekusi tiap konfigurasi, hingga evaluasi dan visualisasi. Tabel V.3 merangkum direktori utama beserta fungsinya.

Tabel V.3 Struktur Direktori Utama Repositori Sistem

Direktori / Berkas	Fungsi
notebooks/00_setup/	<i>Notebook</i> eksplorasi dataset PubMedQA dan pembangunan indeks korpus
notebooks/10_bm25/	Kelompok 1 (BM25 tanpa ekspansi), dengan subdirektori per model (gpt4mini, claude, llama_3_3, llama_3_2), masing-masing berisi baseline, qr, cr, qr_cr
notebooks/20_hybrid_tanpa_ekspansi/	Kelompok 2 (<i>Hybrid</i> tanpa ekspansi), berstruktur sama per model dan konfigurasi
notebooks/30_hybrid_dengan_ekspansi/	Kelompok 3 (<i>Hybrid</i> dengan ekspansi akronim), berstruktur sama per model dan konfigurasi
notebooks/40_evaluation/	<i>Runner</i> evaluasi RAGAS, <i>runner</i> metrik <i>retrieval</i> , dan <i>notebook</i> visualisasi hasil
notebooks/scripts/	Modul bersama, antara lain ragas_evaluator.py, retrieval_metrics.py, dan acronym_expander.py
notebooks/indexes/	Indeks terpusat: berkas BM25 (pubmedqa_bm25.pkl, pubmedqa_bm25_ekspansi.pkl) dan basis vektor Chroma
notebooks/archive/	<i>Notebook</i> legacy yang berada di luar lingkup akhir
data/	Dataset PubMedQA subset <i>pqa_labeled</i> hasil unduhan dari Hugging Face
results/	Hasil per kelompok (10_bm25/, 20_hybrid_tanpa_ekspansi/, 30_hybrid_dengan_ekspansi/) berisi berkas <i>phase 1</i> (jawaban dan label), <i>phase 2</i> (skor RAGAS), dan metrik <i>retrieval</i> dalam format JSON
chatbot_backend/	<i>Backend</i> prototipe berbasis FastAPI (main.py, pipeline.py, models.py, prompts.py)
ui/chatbot/	Antarmuka web prototipe berbasis React + Vite + Tailwind
.env	Kredensial API eksternal (tidak diunggah ke repositori publik)

Penataan *notebook* per kelompok konfigurasi dan per model, beserta direktori hasil yang juga dipisah per kelompok, bertujuan agar setiap konfigurasi dapat dijalankan ulang secara mandiri tanpa risiko menimpa hasil eksperimen lainnya. Indeks BM25 dan basis vektor disimpan terpusat pada notebooks/indexes/ agar tidak terduplikasi di tiap *notebook*, sedangkan modul evaluasi bersama pada notebooks/scripts/ dipakai ulang oleh seluruh konfigurasi sehingga perhitungan metrik konsisten. Pendekatan ini memudahkan pelacakan saat melakukan analisis komparatif antarkonfigurasi pada Bab VI.

V.2 Implementasi Pipeline Pengolahan Data

Tahap pengolahan data mengubah korpus mentah PubMedQA menjadi aset pengetahuan yang siap dipakai oleh sistem RAG, yaitu indeks BM25 dan indeks vektor pada ChromaDB. *Pipeline* dirancang sebagai eksekusi sekali jalan yang dipanggil melalui *notebook* pembangunan indeks, dan hasilnya disimpan ke berkas terstruktur sehingga tidak perlu diproses ulang setiap kali sistem dijalankan. Subbab ini menjelaskan tiga tahap *pipeline*, yaitu pra-pemrosesan korpus, implementasi ekspansi akronim Schwartz-Hearst, serta pembangunan indeks BM25 dan vektor.

V.2.1 Pra-pemrosesan Korpus PubMedQA

Korpus PubMedQA subset *pqa_labeled* dimuat menggunakan pustaka datasets dari Hugging Face dengan identitas dataset qiaojin/PubMedQA dan konfigurasi *pqa_labeled*. Setiap entri dataset memiliki empat *field* utama, yaitu *question*, *context*, *long_answer*, dan *final_decision*. Untuk keperluan pembangunan indeks, hanya *field context* yang dipakai sebagai sumber dokumen; sedangkan *question* dipakai sebagai kueri pada saat *retrieval*, dan dua *field* terakhir disisihkan sebagai *ground truth* evaluasi tanpa dimasukkan ke basis data agar tidak terjadi kebocoran jawaban (*answer leakage*).

Fitur *context* pada setiap entri berbentuk *list* paragraf dengan label *section* (*BACKGROUND*, *METHODS*, *RESULTS*, *CONCLUSIONS*, dan sebagainya). Pada implementasi, setiap paragraf diperlakukan sebagai satu *chunk* terpisah dengan metadata berupa *pubid*, *section label*, dan posisi *chunk* pada paper asal. Pendekatan ini dipilih karena ukuran paragraf pada abstrak biomedis sudah secara natural sesuai dengan *context window* model *embedding* dan tidak memerlukan strategi *chunking* tambahan seperti *sliding window* atau *recursive splitting*. Setelah *chunking* selesai, dilakukan normalisasi ringan berupa pembersihan *whitespace* berlebih dan penghapusan karakter kontrol *non-printable* jika ditemukan. Korpus dibangun dari seluruh 1.000 paper pada subset *pqa_labeled* dan menghasilkan kumpulan *chunk* yang siap dipakai sebagai sumber dokumen.

V.2.2 Implementasi Ekspansi Akronim Schwartz-Hearst

Ekspansi akronim bertujuan menambahkan kepanjangan setiap akronim secara otomatis ke dalam teks dokumen, sehingga *retriever* dapat menemukan dokumen yang relevan baik ketika pengguna mengetikkan akronim (*Hyperbaric Oxygenation*) maupun bentuk panjangnya. Pada implementasi, langkah ini berjalan sekali pada saat penyusunan korpus dan hasilnya disimpan ke berkas indeks tersendiri.

Sistem bekerja dengan cara yang sederhana, yaitu memindai setiap kalimat pada dokumen untuk mencari pola tulisan “*kepanjangan (akronim)*” yang umum dipakai pada paper biomedis. Sebagai contoh, ketika sistem menemukan frasa “*Hyperbaric Oxygenation (HBO)*” pada salah satu paper, sistem akan mengenali bahwa HBO adalah akronim dari *Hyperbaric Oxygenation* dan menyimpan pasangan tersebut ke kamus akronim. Pencocokan dilakukan dengan memeriksa apakah huruf-huruf akronim memang muncul di sepanjang kata pada bentuk panjangnya, sehingga akronim yang tidak konsisten (misalnya angka tahun atau singkatan kebetulan) tidak ikut tertangkap. Untuk akronim yang sering muncul namun tidak pernah didefinisikan langsung pada paper, sistem menyediakan kamus cadangan berisi 175 akronim biomedis yang paling umum sebagai *fallback*.

Setelah pasangan akronim dan kepanjangannya teridentifikasi, sistem menjalankan substitusi pada seluruh *chunk* dokumen pada paper yang sama. Setiap kemunculan akronim diubah menjadi format “AKRONIM (kepanjangan)” secara *inline*, sehingga teks asli tetap terbaca dengan tambahan kepanjangan dalam tanda kurung. Pendekatan ini menjaga teks dokumen tidak banyak berubah, sekaligus memperkaya kosakata yang dipakai *retriever*. Contoh hasil substitusi disajikan pada Tabel V.4.

Tabel V.4 Contoh Hasil Ekspansi Akronim pada Teks *Chunk* Dokumen

Akronim Teks Asli (Korpus Original)		Teks Setelah Ekspansi
HBO	The mortality rate among the HBO-treated patients was 36%.	The mortality rate among the HBO (hyperbaric oxygenation)-treated patients was 36%.
BMI	Higher BMI was independently associated with disease severity.	Higher BMI (body mass index) was independently associated with disease severity.
CHD	The prevalence of CHD in this cohort was 14%.	The prevalence of CHD (coronary heart disease) in this cohort was 14%.
APACHE	APACHE II score was used to assess illness severity at admission.	APACHE (Acute Physiology and Chronic Health Evaluation) II score was used to assess illness severity at admission.
IBS	Patients with IBS reported significantly more abdominal discomfort.	Patients with IBS (Irritable Bowel Syndrome) reported significantly more abdominal discomfort.

Penerapan ekspansi pada korpus PubMedQA menambah panjang rata-rata *chunk* dari 423 karakter menjadi 473 karakter, namun jumlah total *chunk* pada korpus tidak berubah karena ekspansi bersifat substitusi *inline*. Inti dari proses pencocokan huruf akronim dengan kandidat kepanjangan dijabarkan pada Algoritma V.1.

Algoritma V.1 Validasi Pasangan Akronim-Kepanjangan dengan Schwartz-Hearst

Require: Akronim s dengan panjang n , kandidat kepanjangan l dengan panjang m

Ensure: Pasangan kepanjangan valid atau $\perp$ apabila tidak cocok

```
1:  $i \leftarrow n - 1$                                 ▷ indeks huruf terakhir akronim
2:  $j \leftarrow m - 1$                                 ▷ indeks karakter terakhir kandidat
3: while  $i \geq 0$  do
4:   if  $i = 0$  then                                ▷ huruf pertama akronim wajib di awal kata
5:     while  $j \geq 0$  and not ( $l[j] = s[i]$  and AWALKATA( $l, j$ )) do
6:        $j \leftarrow j - 1$ 
7:     end while
8:   else                                            ▷ huruf lain boleh dari posisi internal kata
9:     while  $j \geq 0$  and  $l[j] \neq s[i]$  do
10:       $j \leftarrow j - 1$ 
11:    end while
12:  end if
13:  if  $j < 0$  then return  $\perp$ 
14:  end if
15:   $i \leftarrow i - 1$ 
16:   $j \leftarrow j - 1$ 
17: end while
18: return  $l[j + 1 \dots m - 1]$                     ▷ substring kepanjangan tervalidasi
```

V.2.3 Pembangunan Indeks BM25 dan Vektor

Setelah *chunk* dokumen disiapkan, sistem membangun dua indeks pencarian yang saling melengkapi, yaitu indeks BM25 untuk pencarian berbasis kata kunci dan indeks vektor untuk pencarian berbasis kemiripan makna. Kedua indeks dibangun sekali pada awal eksperimen dan disimpan ke berkas terpisah, sehingga eksekusi berikutnya cukup memuat indeks yang sudah jadi tanpa perlu membangun ulang dari awal.

Untuk indeks BM25, setiap *chunk* terlebih dahulu ditokenisasi dengan cara yang sederhana, yaitu memisahkan teks berdasarkan tanda baca dan spasi, lalu mengubah seluruh karakter menjadi huruf kecil. Hasil tokenisasi seluruh *chunk* membentuk korpus terindeks yang siap menerima kueri pengguna pada tahap pencarian. Pada implementasi, sistem menyimpan dua versi indeks BM25 secara terpisah, yaitu versi yang dibangun dari korpus asli dan versi yang dibangun dari korpus dengan ekspansi akronim, agar eksperimen perbandingan dapat dijalankan tanpa mencampur kedua

kondisi.

Indeks vektor dibangun menggunakan basis data vektor ChromaDB. Setiap *chunk* diubah menjadi representasi vektor numerik melalui pemanggilan model *embedding*, lalu disimpan beserta metadata berupa identitas paper sumber, label *section*, dan posisi *chunk*. Pasangan model *embedding* disesuaikan dengan LLM yang dipakai pada tahap *generation*, yaitu *text-embedding-3-small* dari OpenAI (1.536 dimensi) untuk pasangan dengan GPT-4.1-mini dan Claude Haiku 4.5, dan *nomic-embed-text* yang dijalankan secara lokal melalui Ollama (768 dimensi) untuk pasangan dengan Llama. Pemisahan model *embedding* ini menjaga konsistensi internal antar konfigurasi sekaligus memastikan eksperimen dengan Llama tidak bergantung pada layanan API eksternal.

V.3 Implementasi Komponen Retrieval

Komponen *retrieval* bertugas mengambil *chunk* yang paling relevan terhadap pertanyaan pengguna dari kedua basis data yang telah dibangun pada tahap sebelumnya. Implementasi menggunakan pendekatan *hybrid retrieval* yang menggabungkan BM25 dan *dense retrieval* melalui metode *Reciprocal Rank Fusion* (RRF). Subbab ini menjelaskan implementasi ketiga komponen tersebut.

V.3.1 BM25

Komponen BM25 bertugas mencari *chunk* dokumen yang paling banyak memuat istilah kueri, sebagaimana telah dijelaskan secara teoritis pada Bab II. Pada implementasi, sistem memuat indeks BM25 yang sudah dibangun pada tahap sebelumnya, lalu menjalankan kueri pengguna melalui dua langkah, yaitu menyamakan format kueri dengan format korpus melalui tokenisasi, dan menghitung skor BM25 antara kueri tersebut dengan seluruh *chunk* pada indeks.

Tokenisasi pada kueri dilakukan dengan prosedur yang sama dengan tokenisasi korpus, yaitu memisahkan teks berdasarkan tanda baca dan spasi serta mengubah seluruh karakter menjadi huruf kecil. Kesamaan prosedur ini penting agar kueri seperti “*Does HBO improve survival?*” terurai menjadi token [*does, hbo, improve, survival*] yang sama persis dengan token pada korpus, sehingga pencocokan kata kunci tidak terganggu oleh perbedaan kapitalisasi atau tanda baca. Setelah tokenisasi, sistem menghitung skor BM25 antara token kueri dan setiap *chunk* menggunakan parameter standar pada literatur, yaitu $k_1 = 1,5$ untuk pengaturan saturasi *term frequency* dan $b = 0,75$ untuk pengaturan normalisasi panjang dokumen. Setiap *chunk* memperoleh satu skor agregat, lalu seluruh *chunk* diurutkan dari skor tertinggi ke terendah. Lima puluh *chunk* teratas (*BM25 Top-50*) kemudian dipilih sebagai

kandidat untuk tahap fusi peringkat dengan hasil *dense retrieval*.

Untuk memberikan gambaran intuitif tentang cara kerja BM25, Tabel V.5 memperlihatkan ilustrasi pencocokan kueri “*hyperbaric oxygenation mortality treatment*” (yang diturunkan dari paper PubMedQA tentang efek terapi oksigen hiperbarik) terhadap tiga *chunk* kandidat dengan karakteristik berbeda. Skor pada tabel ini dihitung secara sederhana sebagai ilustrasi untuk menjelaskan kontribusi setiap komponen BM25 dan bukan merupakan skor sebenarnya dari korpus penelitian.

Tabel V.5 Ilustrasi Skor BM25 untuk Kueri “*hyperbaric oxygenation mortality treatment*” pada Tiga *Chunk* Kandidat

ID	Cuplikan <i>Chunk</i>	Panjang	Match	IDF	Skor
C_1	The mortality rate among the HBO (hyperbaric oxygenation)-treated patients was 36%, lower than the control group.	18	4	tinggi	8,21
C_2	Patients underwent hyperbaric oxygenation treatment for chronic wound healing in a prospective study.	13	3	tinggi	6,54
C_3	The treatment was effective in reducing patient mortality across various clinical conditions.	14	2	rendah	2,11

Pada Tabel V.5, kolom *Match* menunjukkan jumlah istilah kueri yang muncul pada *chunk*, kolom *IDF* menunjukkan kekayaan istilah langka (*hyperbaric*, *oxygenation*, *HBO*) dibandingkan istilah umum (*treatment*, *mortality*), dan kolom *Skor* adalah agregasi sesuai Persamaan II.1. *Chunk* C_1 mendapat skor tertinggi karena memuat hampir seluruh istilah kueri, termasuk dua istilah langka bernilai IDF tinggi (*hyperbaric*, *oxygenation*, *mortality*). *Chunk* C_2 mendapat skor menengah karena memuat istilah langka yang sama namun melewatkan istilah *mortality*. *Chunk* C_3 mendapat skor paling rendah meskipun memuat *treatment* dan *mortality*, karena kedua istilah tersebut umum di seluruh korpus sehingga bobot IDF-nya kecil. Contoh ini juga memperlihatkan mengapa ekspansi akronim memberi pengaruh signifikan pada BM25; tanpa ekspansi, *chunk* yang menulis *HBO* saja tanpa kepanjangan tidak akan tertangkap oleh kueri yang menyebut *hyperbaric oxygenation*, sehingga peluang dokumen relevan ditemukan menjadi berkurang.

V.3.2 Dense Retrieval

Komponen *dense retrieval* mencari *chunk* dokumen berdasarkan kemiripan makna dengan kueri pengguna, sebagaimana telah dijelaskan secara teoritis pada Bab II. Pada implementasi, sistem mengubah kueri pengguna menjadi vektor melalui model *embedding*, lalu meminta basis data vektor untuk mengembalikan *chunk* dengan vektor yang paling dekat dengan vektor kueri tersebut.

Pemilihan model *embedding* disesuaikan dengan LLM yang dipakai pada tahap *generation*. Untuk konfigurasi yang memakai GPT-4.1-mini atau Claude Haiku 4.5, sistem memanggil model `text-embedding-3-small` dari OpenAI yang menghasilkan vektor berdimensi 1.536; sedangkan untuk konfigurasi yang memakai Llama, sistem memanggil model `nomic-embed-text` yang dijalankan secara lokal melalui Ollama dan menghasilkan vektor berdimensi 768. Penggunaan model *embedding* yang sama saat *indexing* dan saat kueri adalah syarat wajib, karena dua model yang berbeda akan menempatkan teks pada ruang vektor yang berbeda pula sehingga perhitungan kemiripan tidak bermakna. Setelah vektor kueri terbentuk, basis data ChromaDB menghitung *cosine similarity* antara vektor tersebut dengan seluruh vektor pada koleksi, lalu mengembalikan 50 *chunk* teratas (*Dense Top-50*) sebagai kandidat untuk tahap fusi peringkat.

Keunggulan utama *dense retrieval* terletak pada kemampuannya menangkap kedekatan makna yang tidak dapat dijangkau oleh pencocokan kata kunci. Dua teks yang menggunakan istilah berbeda namun bermakna serupa, misalnya “*physical activity*” dan “*exercise*”, akan dipetakan ke posisi yang berdekatan pada ruang vektor sehingga tetap dapat saling ditemukan. Kemampuan ini menjadikan *dense retrieval* bersifat komplementer terhadap BM25 yang unggul pada pencocokan istilah spesifik, dan keduanya kemudian digabungkan pada tahap *hybrid retrieval*. Karena nilai *cosine similarity* berkisar antara -1 hingga 1 , dengan nilai mendekati 1 menandakan arah vektor yang hampir sama, skor ini dapat langsung dipakai sebagai ukuran relevansi semantik antara kueri dan dokumen.

Untuk memberikan gambaran tentang kekuatan *dense retrieval* dalam menangkap kemiripan makna, Tabel V.6 memperlihatkan ilustrasi pencocokan kueri “*Does physical activity reduce postnatal depression?*” (yang merupakan parafrasa dari pertanyaan PubMedQA mengenai olahraga saat hamil dan depresi pasca-melahirkan) terhadap tiga *chunk* kandidat. Nilai *cosine similarity* pada tabel ini dihitung secara sederhana sebagai ilustrasi dan bukan merupakan skor sebenarnya dari korpus penelitian.

Tabel V.6 Ilustrasi Skor *Cosine Similarity* untuk Kueri “Does physical activity reduce postnatal depression?” pada Tiga *Chunk* Kandidat

ID	Cuplikan <i>Chunk</i>	Kemiripan Makna	Skor
C_1	Regular exercise during pregnancy was associated with lower depression scores after delivery.	sangat dekat (parafrasa langsung)	0,872
C_2	Aerobic training showed mood improvement in postpartum women across the trial cohort.	dekat (sinonim multi-istilah)	0,791
C_3	Pregnancy outcomes were measured using standard fetal monitoring techniques in the study.	jauh (hanya istilah “pregnancy”)	0,312

Pada Tabel V.6, *chunk* C_1 memperoleh skor tertinggi karena memuat parafrasa langsung dari setiap konsep pada kueri, yaitu *exercise* untuk *physical activity*, *depression* untuk *depression*, dan *after delivery* untuk *postnatal*. *Chunk* C_2 memperoleh skor menengah karena memakai sinonim yang lebih jauh (*aerobic training* untuk *physical activity*, *mood improvement* untuk *reduce depression*, *postpartum* untuk *postnatal*), namun maknanya tetap konsisten dengan kueri sehingga vektornya tetap dekat dengan vektor kueri. *Chunk* C_3 memperoleh skor rendah karena meskipun memuat istilah *pregnancy*, isinya membahas pemantauan janin sehingga maknanya jauh berbeda dengan kueri tentang depresi.

Ilustrasi ini menjelaskan mengapa *dense retrieval* bersifat komplementer terhadap BM25. Pada kueri yang memuat banyak parafrasa dan sinonim seperti contoh di atas, BM25 hanya mampu menangkap *chunk* C_3 karena kemunculan istilah *pregnancy* secara eksak, padahal C_3 justru kurang relevan. *Dense retrieval* berhasil mengangkat C_1 dan C_2 yang sebenarnya jauh lebih relevan, walaupun kosakatanya berbeda dengan kueri. Kombinasi kedua jenis *retrieval* pada tahap *hybrid retrieval* kemudian menjaga agar dokumen yang ditemukan mencakup kedua kategori, yaitu dokumen yang cocok berdasarkan kata kunci spesifik maupun dokumen yang cocok berdasarkan kemiripan makna.

V.3.3 Hybrid Retrieval dengan Reciprocal Rank Fusion

Hasil dari kedua *retriever* digabungkan melalui fungsi `rrf_merge` yang mengimplementasikan rumus *Reciprocal Rank Fusion* sesuai (Cormack, Clarke, dan

Buettcher 2009). Untuk setiap *chunk* yang muncul pada salah satu atau kedua daftar hasil, sistem menghitung skor RRF sebagai $\sum_i \frac{1}{k + \text{rank}_i}$ dengan parameter $k = 60$ sesuai rekomendasi penulis asli, dan rank_i adalah posisi *chunk* pada daftar ke- i . *Chunk* yang muncul pada kedua daftar akan mendapat kontribusi skor dari keduanya, sehingga dokumen yang ditemukan oleh BM25 maupun *dense retrieval* secara konsisten akan terangkat ke peringkat atas. Setelah skor RRF dihitung, 20 *chunk* dengan skor tertinggi (*Top-20*) dipilih sebagai kandidat untuk tahap berikutnya, yaitu *Context Reranking* atau langsung tahap *generation*. Prosedur lengkap penggabungan kedua daftar peringkat dijabarkan pada Algoritma V.2.

Algoritma V.2 Penggabungan Peringkat dengan *Reciprocal Rank Fusion* (RRF)

Require: Daftar peringkat BM25 R_B dan *dense* R_D ; konstanta $k = 60$; jumlah keluaran $N = 20$

Ensure: Daftar Top- N *chunk* berdasarkan skor RRF

```

1:  $S \leftarrow \{\}$  ▷ peta dari chunk_id ke skor RRF
2: for all  $R_i \in \{R_B, R_D\}$  do
3:   for  $r \leftarrow 1$  to  $|R_i|$  do
4:      $c \leftarrow R_i[r]$  ▷ chunk pada peringkat ke- $r$ 
5:      $S[c] \leftarrow S[c] + \frac{1}{k + r}$  ▷ akumulasi kontribusi tiap retriever
6:   end for
7: end for
8:  $L \leftarrow$  urutkan kunci  $S$  berdasarkan nilai secara menurun
9: return  $L[1 \dots N]$ 

```

Sebagai ilustrasi sederhana, misalkan pengguna bertanya “*Does regular exercise reduce the risk of heart disease?*”. Setelah *retrieval*, BM25 dan *dense retrieval* menghasilkan dua daftar peringkat yang berbeda untuk empat dokumen kandidat. Tabel V.7 menunjukkan peringkat masing-masing dokumen pada kedua daftar beserta skor RRF hasil penggabungannya dengan $k = 60$. Skor pada tabel ini dihitung sebagai ilustrasi dan bukan merupakan skor sebenarnya dari korpus penelitian.

Tabel V.7 Ilustrasi Penggabungan Peringkat dengan *Reciprocal Rank Fusion* ($k = 60$); kolom BM25 dan *Dense* menunjukkan peringkat dokumen pada masing-masing daftar

Dok.	Cuplikan <i>Chunk</i>	BM25	<i>Dense</i>	Skor RRF	Peringkat
D_1	<i>Regular exercise lowers the risk of heart disease.</i>	1	1	0,0328	1
D_2	<i>Aerobic activity protects the heart and lowers cardiovascular risk.</i>	3	2	0,0320	2
D_3	<i>Smoking increases the risk of heart disease.</i>	2	4	0,0318	3
D_4	<i>Exercise is useful for managing body weight.</i>	4	3	0,0315	4

Pada Tabel V.7, dokumen D_1 menempati peringkat satu pada kedua daftar, sehingga memperoleh skor RRF tertinggi ($\frac{1}{60+1} + \frac{1}{60+1} \approx 0,0328$) dan tetap berada di puncak. Yang lebih menarik adalah dokumen D_3 (“*Smoking increases the risk of heart disease*”) yang menempati peringkat tinggi pada BM25 karena banyak memuat kata kunci yang sama (*risk, heart, disease*), padahal maknanya justru berlawanan dengan maksud pertanyaan. Karena *dense retrieval* menilai maknanya kurang relevan (peringkat 4), RRF menurunkan peringkat akhir D_3 . Sebaliknya, dokumen D_2 yang kuat secara makna namun memakai kata berbeda (*aerobic activity*) terangkat naik ke peringkat dua. Contoh ini memperlihatkan cara RRF menyeimbangkan kekuatan pencocokan kata kunci dari BM25 dan kemiripan makna dari *dense retrieval*.

V.4 Implementasi Komponen Mitigasi Halusinasi

Pada subbab ini dijelaskan implementasi dua komponen mitigasi yang bekerja di sekitar tahap *retrieval*, yaitu *Query Rewriting* (QR) yang bekerja sebelum *retrieval* dan *Context Reranking* (CR) yang bekerja sesudahnya. Komponen ketiga, yaitu ekspansi akronim Schwartz-Hearst, telah dijelaskan pada Subbab V.2.2 karena sifatnya berupa praproses dokumen, bukan modifikasi alur *retrieval*.

V.4.1 Implementasi Query Rewriting

Komponen *Query Rewriting* diimplementasikan sebagai fungsi yang menerima pertanyaan asli pengguna dan mengembalikan versi yang telah ditulis ulang menjadi lebih kaya akan istilah medis. Fungsi ini mengirimkan *prompt* khusus kepada LLM yang berisi instruksi untuk menghasilkan ulang pertanyaan dengan tiga ketentuan, yaitu (1) memperluas istilah medis dengan menyertakan sinonim atau bentuk akronim, (2) mengeksplisitkan entitas biomedis yang implisit pada pertanyaan asli, dan

(3) mempertahankan makna serta jenis pertanyaan agar jawaban yang dihasilkan tetap relevan terhadap kebutuhan pengguna.

LLM yang dipakai untuk *Query Rewriting* adalah model yang sama dengan model untuk tahap *generation* pada konfigurasi bersangkutan (*gpt-4.1-mini*, *claude-haiku-4.5*, atau *llama-3.3-70b-instruct*). Pendekatan ini menjaga kompatibilitas gaya bahasa antara penulisan ulang dan pembentukan jawaban. Hasil *rewriting* menggantikan pertanyaan asli pada tahap *retrieval* (baik BM25 maupun *dense*), namun pertanyaan asli tetap diteruskan ke tahap *generation* agar LLM menjawab pertanyaan yang sebenarnya diajukan pengguna, bukan versi tulis-ulang internal.

Tabel V.8 menampilkan beberapa contoh nyata pertanyaan sehari-hari beserta hasil penulisan ulangnya oleh modul *Query Rewriting* pada prototipe. Terlihat bahwa pertanyaan sederhana ditulis ulang menjadi pertanyaan yang lebih kaya istilah biomedis, misalnya *walking* menjadi *ambulatory exercise* dan *blood pressure* menjadi *arterial hypertension*, tanpa mengubah maksud asli pertanyaan.

Tabel V.8 Contoh Hasil *Query Rewriting* pada Beberapa Pertanyaan Pengguna

Pertanyaan Asli	Hasil <i>Query Rewriting</i>
<i>Can walking lower blood pressure?</i>	<i>Can regular ambulatory exercise reduce arterial hypertension in adults?</i>
<i>Is skipping breakfast bad for your health?</i>	<i>Does skipping breakfast negatively impact metabolic health and increase the risk of cardiovascular disease and obesity?</i>
<i>Does drinking enough water help reduce headaches?</i>	<i>Does adequate hydration reduce the incidence and severity of tension-type headaches and migraines?</i>

V.4.2 Implementasi Context Reranking

Komponen *Context Reranking* diimplementasikan menggunakan model *cross-encoder* *ms-marco-MiniLM-L-6-v2* dari pustaka *sentence-transformers*. Model dipilih karena ukurannya kecil (sekitar 22 MB), dapat berjalan cepat pada CPU tanpa GPU, dan terbukti efektif untuk tugas *passage reranking*. Berbeda dengan model *embedding* yang menghasilkan satu vektor per teks, *cross-encoder* menerima pasangan (kueri, *passage*) sekaligus pada satu inferensi dan menghasilkan skor relevansi tunggal, sehingga kualitas penilaian lebih akurat untuk tugas *re-ranking* skala kecil.

Pada implementasi, 20 *chunk* teratas hasil RRF (*Top-20*) dipasangkan satu per

satu dengan kueri pengguna, sehingga terbentuk 20 pasangan masukan. Pasangan tersebut diteruskan ke metode *predict* dari objek *CrossEncoder* secara *batch* agar inferensi efisien. Setelah skor relevansi diperoleh, *chunk* diurutkan ulang dari skor tertinggi ke terendah, dan lima *chunk* paling relevan (*Top-5*) dipilih sebagai konteks akhir yang diteruskan ke tahap *generation*. Pemilihan *Top-5* ini konsisten dengan rancangan pada Bab IV dan menjadi standar input konteks untuk seluruh konfigurasi sistem.

Sebagai ilustrasi, misalkan pengguna bertanya “*Does drinking water help with headaches?*”. Setelah tahap *hybrid retrieval*, urutan dokumen kandidat masih didominasi oleh dokumen yang memuat kata kunci umum, sehingga dokumen yang paling langsung menjawab pertanyaan belum tentu berada di peringkat atas. *Context Reranking* kemudian menilai ulang setiap pasangan (kueri, dokumen) menggunakan *cross-encoder*, lalu menata ulang peringkatnya. Tabel V.9 membandingkan peringkat empat dokumen sebelum dan sesudah *reranking*; peringkat pada tabel ini bersifat ilustratif.

Tabel V.9 Ilustrasi Peringkat Dokumen Sebelum dan Sesudah *Context Reranking*

Dok.	Cuplikan <i>Chunk</i>	Sebelum	Sesudah (CR)
C_1	<i>Dehydration is a common trigger of headaches; drinking water can relieve them.</i>	3	1
C_2	<i>Headaches can be caused by many factors such as stress.</i>	1	3
C_3	<i>Water is essential for healthy kidney function.</i>	2	4
C_4	<i>Staying well hydrated may reduce how often headaches occur.</i>	4	2

Pada Tabel V.9, dokumen C_1 yang secara langsung menjelaskan hubungan dehidrasi dengan sakit kepala naik dari peringkat 3 menjadi 1, dan C_4 yang juga relevan naik dari peringkat 4 menjadi 2. Sebaliknya, C_2 yang hanya menyebut sakit kepala secara umum dan C_3 yang membahas air untuk fungsi ginjal di luar konteks pertanyaan justru turun ke peringkat bawah. Hal ini terjadi karena *cross-encoder* membaca pasangan kueri dan dokumen secara bersamaan, sehingga mampu menilai keterkaitan makna yang sebenarnya, bukan sekadar kemunculan kata. Dengan demikian, dokumen yang benar-benar menjawab pertanyaan terdorong ke peringkat teratas sebelum diteruskan ke tahap *generation*.

V.5 Implementasi Komponen Generation dan Kerangka Evaluasi

V.5.1 Implementasi Tahap Generation

Pada tahap *generation*, sistem mengirim pertanyaan asli pengguna bersama lima dokumen konteks terbaik (*Top-5*) ke LLM, lalu meminta LLM menjawab. Jawaban terdiri atas satu label (*yes*, *no*, atau *maybe*) beserta penjelasan singkat yang harus berdasarkan dokumen tersebut. *Prompt* yang dikirim berisi tiga bagian, yaitu (1) instruksi agar LLM berperan sebagai asisten peneliti biomedis yang hanya menjawab berdasarkan dokumen yang diberikan, (2) lima dokumen konteks yang dipisahkan dengan tanda === dan diberi penanda sumber paper, serta (3) pertanyaan pengguna disertai instruksi agar baris terakhir jawaban berupa salah satu dari ketiga label.

LLM dipanggil melalui klien resmi tiap penyedia, yaitu *openai* untuk OpenAI dan *OpenRouter*, *anthropic* untuk Claude, serta antarmuka HTTP *Ollama* untuk Llama lokal. Parameter pemanggilan dibuat sama untuk semua model, yaitu *temperature* sebesar 0 agar jawaban konsisten dan tidak berubah-ubah, serta batas jumlah token secukupnya untuk jawaban biomedis yang singkat. Karena keluaran LLM berupa teks bebas, sistem perlu mengambil labelnya secara bertahap, yaitu pertama mencari label pada baris terakhir, jika gagal mencari kata *yes*, *no*, atau *maybe* di seluruh teks, dan jika masih gagal menggunakan pencocokan pola (*regex*). Bila ketiga cara tersebut gagal, label ditandai sebagai *unknown* dan sampel tersebut tidak ikut dievaluasi.

V.5.2 Implementasi Kerangka Evaluasi

Evaluasi dijalankan dalam dua tahap, dan hasilnya disimpan secara bertahap agar tidak hilang apabila proses berhenti di tengah jalan. Tahap pertama (*phase 1*) menjalankan *retrieval* dan *generation*, lalu menyimpan jawaban LLM, label prediksi, dan lima dokumen konteks ke berkas `*_phase1_answers.json`. Tahap kedua (*phase 2*) membaca hasil tahap pertama dan menghitung dua metrik RAGAS, yaitu *faithfulness* dan *context recall*, lalu menyimpannya ke berkas `*_phase2_custom.json`. Pemisahan ini membuat evaluasi dapat diulang dengan metrik berbeda tanpa perlu memanggil LLM lagi.

Kedua metrik RAGAS dihitung untuk setiap pertanyaan menggunakan konteks yang sama persis dengan yang dilihat LLM saat menjawab, sehingga skornya benar-benar mencerminkan kualitas jawaban atas dokumen yang dipakai.

Selain RAGAS, kualitas *retrieval* diukur secara terpisah menggunakan tiga

metrik *Information Retrieval* (IR) standar, yaitu *Recall@5*, *MAP@5*, dan *nDCG@5*. Pengukuran ini dilakukan oleh modul `retrieval_metrics.py` di direktori `notebooks/scripts/` yang dijalankan melalui `notebook 40_evaluation/retrieval_metrics_runner.ipynb`. Modul ini membandingkan lima dokumen teratas hasil *retrieval* dengan dokumen yang memuat jawaban benar (*long_answer*), lalu menghitung ketiga metrik untuk seluruh pertanyaan uji. Hasilnya disimpan ke berkas `*_retrieval_metrics.json` dan dipakai untuk membandingkan konfigurasi BM25 saja, *Hybrid*, serta versi dengan dan tanpa ekspansi akronim.


V.6 Prototipe Antarmuka Demonstrasi

Selain *notebook* eksperimen, dibangun pula sebuah prototipe untuk mendemonstrasikan sistem secara interaktif dan utuh dari ujung ke ujung. Prototipe ini menjalankan konfigurasi terbaik hasil evaluasi, yaitu *Hybrid Retrieval* dengan ekspansi akronim, *Query Rewriting*, dan *Context Reranking* pada model GPT-4.1-mini. Tujuan utamanya adalah memenuhi kebutuhan nonfungsional *explainability* dan *retrieval transparency* yang telah dirancang pada Bab III, yaitu pengguna tidak hanya menerima jawaban akhir, tetapi juga dapat menelusuri proses di baliknya.

V.6.1 Arsitektur Prototipe


Prototipe terdiri dari dua bagian yang berjalan terpisah. Bagian *frontend* dibangun menggunakan React, Vite, dan Tailwind CSS pada direktori `ui/chatbot/`, sedangkan bagian *backend* dibangun menggunakan FastAPI pada direktori `chatbot_backend/`. *Backend* membungkus seluruh *pipeline* RAG yang sama dengan yang dipakai pada eksperimen, mulai dari *Query Rewriting*, *hybrid retrieval*, *context reranking*, hingga *generation*, lalu mengeksposnya melalui satu *endpoint* REST `/api/chat`. Ketika pengguna mengirim pertanyaan, *frontend* memanggil *endpoint* tersebut dan menerima jawaban beserta data pendukung berupa kueri hasil tulis-ulang, daftar dokumen yang ditarik, dan skor relevansi tiap tahap.

Tangkapan layar antarmuka penuh prototipe disajikan pada Gambar V.1. Antarmuka terbagi menjadi tiga panel, yaitu panel kiri berisi riwayat percakapan, panel tengah berisi area tanya jawab, dan panel kanan berisi rincian *pipeline* (*Pipeline Details*). Panel kanan inilah yang mewujudkan *retrieval transparency*, karena menampilkan kueri asli pengguna, kueri hasil *Query Rewriting*, serta daftar dokumen teratas lengkap dengan skor BM25, *dense*, dan *rerank* untuk setiap dokumen.



Gambar V.1 Antarmuka penuh prototipe BioRAG dengan panel riwayat, area percakapan, dan panel transparansi *pipeline*

Gambar V.2 memperlihatkan tampilan detail area percakapan ketika sistem menjawab sebuah pertanyaan biomedis. Setiap jawaban dilengkapi penanda tingkat keyakinan (*confidence*) beserta nilai persentasenya, sehingga pengguna memperoleh indikasi seberapa kuat jawaban tersebut didukung oleh dokumen yang ditemukan.



Gambar V.2 Tampilan detail percakapan beserta penanda tingkat keyakinan jawaban

V.6.2 Mekanisme Guard Rail Keyakinan

Untuk mengurangi risiko halusinasi pada pertanyaan yang berada di luar cakupan korpus, prototipe dilengkapi dengan *guard rail* berbasis skor keyakinan. Skor ini

dihitung sebagai gabungan tiga sinyal *retrieval*. Pertama, skor *rerank* pada dokumen peringkat satu, yaitu seberapa relevan dokumen terbaik menurut *cross-encoder*. Kedua, kemiripan *dense* pada dokumen peringkat satu, yaitu seberapa dekat makna dokumen terbaik dengan kueri. Ketiga, sinyal relevansi rata-rata dokumen teratas, yaitu rata-rata skor *rerank* pada tiga dokumen teratas. Sinyal ini mengukur apakah beberapa dokumen teratas sama-sama relevan, bukan hanya satu dokumen peringkat satu yang kebetulan cocok, sehingga keyakinan sistem tidak bergantung pada satu dokumen saja. Ketiga sinyal digabungkan dengan bobot 0,5 untuk *rerank*, 0,3 untuk *dense*, dan 0,2 untuk relevansi rata-rata, sehingga menghasilkan skor komposit pada rentang 0 sampai 1. Pembobotan ini ditetapkan berdasarkan tingkat keandalan masing-masing sinyal. Skor *rerank* diberi bobot terbesar (0,5) karena *cross-encoder* membaca pasangan kueri dan dokumen secara bersamaan sehingga menjadi penilai relevansi yang paling akurat. Kemiripan *dense* diberi bobot 0,3 sebagai sinyal makna yang andal namun lebih kasar, karena membandingkan vektor kueri dan dokumen secara terpisah. Adapun sinyal relevansi rata-rata diberi bobot terkecil (0,2) karena perannya hanya sebagai penyeimbang yang memastikan keyakinan tidak bertumpu pada satu dokumen saja, bukan sebagai penilai relevansi utama.

Berdasarkan skor komposit tersebut, sistem menetapkan tiga tingkat keyakinan beserta perilaku yang berbeda, sebagaimana dirangkum pada Tabel V.10.

Tabel V.10 Tingkat Keyakinan, Ambang Skor Komposit, dan Perilaku Sistem

Tingkat	Skor Komposit	Perilaku dan Pesan Sistem
Tinggi (<i>high</i>)	$\geq 0,7$	Sistem menjawab seperti biasa berdasarkan konteks yang ditemukan, tanpa peringatan tambahan.
Sedang (<i>moderate</i>)	0,4 sampai $< 0,7$	Sistem tetap menjawab, tetapi LLM diberi instruksi untuk membuka jawaban dengan pernyataan singkat bahwa bukti yang tersedia terbatas atau tidak langsung, lalu hanya menyampaikan hal yang dapat didukung oleh konteks.
Rendah (<i>low</i>)	$< 0,4$	Pemanggilan LLM dilewati. Sistem menampilkan penanda <i>LLM SKIPPED</i> dan mengembalikan pesan bahwa bukti yang relevan tidak cukup untuk memberikan jawaban tepercaya, disertai saran agar pengguna berkonsultasi dengan tenaga medis.

Sebagai contoh perhitungan nyata, pertanyaan pada Gambar V.1 (*“Does high blood*

pressure reduce the risk of chronic low back pain?”) memperoleh keyakinan sebesar 81%. Untuk pertanyaan tersebut, sinyal *retrieval* mentah yang dihasilkan adalah skor *rerank* dokumen peringkat satu sekitar $-0,93$, kemiripan *dense* dokumen peringkat satu sekitar $0,69$, dan rata-rata skor *rerank* tiga dokumen teratas sekitar $-1,75$. Ketiga sinyal tersebut dinormalisasi dengan fungsi sigmoid $\sigma(\cdot)$ lalu digabungkan sesuai bobotnya, sebagaimana dirinci pada Tabel V.11.

Tabel V.11 Contoh Perhitungan Skor Keyakinan untuk Pertanyaan pada Gambar V.1

Sinyal	Nilai Mentah	Normalisasi	Skor
<i>rerank</i> (dok-1)	$-0,93$	$\sigma(0,5 \times (-0,93 + 3))$	$0,738$
<i>dense</i> (dok-1)	$0,69$	$\min(1; 0,69/0,7)$	$0,991$
relevansi rata-rata (<i>top-3</i>)	$-1,75$	$\sigma(0,4 \times (-1,75 + 4))$	$0,711$
Skor komposit = $0,5(0,738) + 0,3(0,991) + 0,2(0,711)$			$0,81$

Karena skor komposit tersebut ($0,81$) berada pada kategori tinggi ($\geq 0,7$), sistem menjawab pertanyaan seperti biasa, sesuai dengan penanda keyakinan 81% yang ditampilkan pada Gambar V.1. Sebaliknya, contoh perilaku *guard rail* pada tingkat rendah ketika menerima pertanyaan di luar cakupan korpus disajikan pada Lampiran D.

BAB VI

EVALUASI

Bab ini menyajikan hasil pengujian kuantitatif terhadap sistem mitigasi halusinasi RAG-LLM untuk sistem tanya jawab biomedis yang telah diimplementasikan pada Bab V. Evaluasi bertujuan menelaah dua temuan utama, yaitu (1) perbandingan antara mode *retrieval* BM25 saja dengan *hybrid retrieval*, serta (2) pengaruh praproses ekspansi akronim Schwartz-Hearst, yang keduanya difokuskan pada model GPT-4.1-mini sebagai model acuan. Analisis tambahan mengenai kontribusi *Query Rewriting* (QR) dan *Context Reranking* (CR) pada berbagai pilihan LLM, serta perbandingan kinerja antara model sumber terbuka lokal Llama 3.2 dengan model berbayar berskala besar, disajikan pada Lampiran C. Bagian ini menjelaskan metode evaluasi, hasil pengukuran, dan pembahasan implikasinya.

VI.1 Metode Evaluasi

VI.1.1 Lingkup Evaluasi dan Himpunan Uji

Evaluasi dilakukan pada 500 pertanyaan dari subset *pqa_labeled* PubMedQA yang memuat anotasi *expert*, sedangkan korpus dokumen untuk *retriever* dibangun dari seluruh 1.000 paper pada subset tersebut. Subset 500 pertanyaan ini mempertahankan proporsi label yang konsisten dengan keseluruhan dataset, yaitu 275 pertanyaan berlabel *yes* (55%), 159 pertanyaan berlabel *no* (32%), dan 66 pertanyaan berlabel *maybe* (13%). Pemilihan 500 pertanyaan pertama dilakukan untuk menyeimbangkan representativitas distribusi label dengan keterbatasan biaya pemanggilan API model bahasa eksternal pada eksperimen lintas-konfigurasi. Setiap pertanyaan dievaluasi pada seluruh konfigurasi sistem sehingga hasil yang diperoleh dapat dibandingkan secara langsung antar konfigurasi.

VI.1.2 Metrik Kuantitatif

Evaluasi sistem dilakukan pada dua jalur yang saling melengkapi. Jalur pertama mengukur kualitas *retrieval* menggunakan tiga metrik standar *Information Retrieval* (IR), yaitu *Recall@5*, *Mean Average Precision* (MAP@5), dan *Normalized Discounted Cumulative Gain* (nDCG@5), sebagaimana didefinisikan pada Bab II. Jalur

kedua mengukur kualitas jawaban yang dihasilkan menggunakan *Label Accuracy* terhadap *ground truth* PubMedQA, serta dua metrik dari kerangka RAGAS, yaitu *faithfulness* dan *context recall*. Pemisahan dua jalur ini memungkinkan analisis kontribusi setiap teknik secara terpisah pada tahap *retrieval* maupun *generation*.

VI.1.3 Skema Konfigurasi Pengujian

Pengujian dilakukan pada dua belas konfigurasi sebagaimana telah didefinisikan pada Tabel IV.2 pada Bab IV, yaitu empat konfigurasi utama (*baseline*, +QR, +CR, +QR+CR) dengan mode *Hybrid* dan ekspansi akronim, empat variasi ablation tanpa ekspansi akronim, serta empat variasi ablation dengan mode BM25 saja. Untuk mengukur kontribusi pilihan LLM, keempat konfigurasi utama tersebut juga dijalankan pada empat model berbeda, yaitu GPT-4.1-mini (OpenAI), Claude Haiku 4.5 (Anthropic), Llama 3.3 70B Instruct (OpenRouter), serta Llama 3.2 3B yang dijalankan lokal melalui Ollama. Keluaran setiap konfigurasi disimpan pada berkas JSON terpisah agar reproduksibilitas pengujian tetap terjaga.

VI.2 Hasil dan Pembahasan

Hasil evaluasi disajikan pada dua jalur metrik yang saling melengkapi, yaitu metrik *Information Retrieval* (IR) untuk menilai kualitas *retrieval* dan metrik kualitas jawaban untuk menilai keluaran akhir LLM. Pembahasan disusun per teknik mitigasi mengikuti urutan pembangunan konfigurasi pada Tabel IV.2 di Bab IV, yaitu dimulai dari *Hybrid Search*, kemudian ekspansi akronim, *Query Rewriting* (QR), dan *Context Reranking* (CR). Setiap subbab mengisolasi kontribusi satu teknik dengan membandingkan kelompok konfigurasi yang hanya berbeda pada teknik tersebut, lalu menjelaskan mekanisme yang menyebabkan perubahan metrik.

VI.2.1 Ringkasan Metrik Seluruh Konfigurasi

Sebelum membahas kontribusi tiap teknik, Tabel VI.1 dan Tabel VI.2 merangkum seluruh hasil pengukuran pada dua belas konfigurasi. Tabel pertama memuat metrik IR pada tahap *retrieval*, sedangkan tabel kedua memuat metrik kualitas jawaban pada tahap *generation*. Ketiga metrik IR dapat dipahami secara singkat sebagai berikut.

- a. **Recall@5** mengukur seberapa lengkap sistem menemukan dokumen relevan dalam lima hasil teratas. Sebagai ilustrasi, apabila dari sepuluh dokumen relevan yang ada di korpus sistem berhasil menarik delapan di antaranya pada peringkat 1–5, maka Recall@5 sebesar 80%.
- b. **MAP@5** (*Mean Average Precision* pada lima dokumen teratas) menilai bukan hanya kehadiran dokumen relevan, tetapi juga seberapa dini mereka muncul

dalam daftar. Dokumen relevan pada peringkat 1 dihargai lebih tinggi dibandingkan yang muncul pada peringkat 5.

- c. **nDCG@5** (*Normalized Discounted Cumulative Gain*) merupakan ukuran gabungan yang membandingkan urutan dokumen yang dihasilkan sistem terhadap urutan ideal, kemudian dinormalisasi ke skala 0–1. Nilai mendekati 1,00 berarti urutan dari sistem nyaris identik dengan urutan terbaik yang mungkin.

Ketiga metrik dilaporkan dalam satuan persen agar mudah dibandingkan dan dibaca lintas konfigurasi.

Tabel VI.1 Metrik *Information Retrieval* pada Dua Belas Konfigurasi

Konfigurasi	Recall@5 (%)	MAP@5 (%)	nDCG@5 (%)
<i>Kelompok 1: BM25 tanpa Ekspansi Akronim</i>			
<i>Baseline</i>	68,94	66,19	75,18
+ QR	64,65	60,41	70,58
+ CR	75,54	73,31	81,00
+ QR + CR	71,17	68,79	77,45
<i>Kelompok 2: Hybrid Retrieval tanpa Ekspansi Akronim</i>			
<i>Baseline</i>	78,65	75,32	83,08
+ QR	75,73	71,87	80,40
+ CR	80,84	77,40	84,79
+ QR + CR	77,09	73,29	81,69
<i>Kelompok 3: Hybrid Retrieval dengan Ekspansi Akronim</i>			
<i>Baseline</i>	84,96	82,47	88,45
+ QR	83,06	79,50	86,20
+ CR	86,49	83,93	89,70
+ QR + CR	87,08	84,53	90,11

Pada jalur kualitas jawaban, dilaporkan empat metrik, yaitu *Label Accuracy* terhadap *ground truth* PubMedQA, *hallucination rate* yang didefinisikan sebagai $100\% - accuracy$, serta dua metrik RAGAS yang paling relevan dengan mitigasi halusinasi, yaitu *faithfulness* yang mengukur kesetiaan jawaban terhadap konteks dokumen dan *context recall* yang mengukur kelengkapan informasi relevan yang dihadirkan pada konteks. Hasil selengkapnya disajikan pada Tabel VI.2.

Tabel VI.2 Metrik Kualitas Jawaban pada Dua Belas Konfigurasi (GPT-4.1-mini)

Konfigurasi	Accuracy (%)	Hall. Rate (%)	Faithfulness	Context Recall
<i>Kelompok 1: BM25 tanpa Ekspansi Akronim</i>				
<i>Baseline</i>	65,4	34,6	0,893	0,791
+ QR	65,4	34,6	0,896	0,782
+ CR	68,4	31,6	0,898	0,820
+ QR + CR	68,2	31,8	0,810	0,737
<i>Kelompok 2: Hybrid Retrieval tanpa Ekspansi Akronim</i>				
<i>Baseline</i>	69,2	30,8	0,981	0,851
+ QR	70,8	29,2	0,976	0,858
+ CR	69,8	30,2	0,981	0,884
+ QR + CR	70,0	30,0	0,982	0,869
<i>Kelompok 3: Hybrid Retrieval dengan Ekspansi Akronim</i>				
<i>Baseline</i>	73,2	26,8	0,988	0,888
+ QR	73,0	27,0	0,988	0,885
+ CR	73,4	26,6	0,987	0,892
+ QR + CR	74,8	25,2	0,984	0,879


Kedua tabel memperlihatkan peningkatan bertahap dari Kelompok 1 ke Kelompok 3, baik pada kualitas *retrieval* maupun kualitas jawaban, sehingga teknik-teknik mitigasi yang diterapkan bersifat saling melengkapi dan bukan saling menggantikan. Konfigurasi terbaik adalah Kelompok 3 dengan QR dan CR, yang mencapai Recall@5 sebesar 87,08% dan nDCG@5 sebesar 90,11% pada jalur *retrieval*, serta *accuracy* 74,8% dan *hallucination rate* 25,2% pada jalur jawaban. Kontribusi spesifik tiap teknik terhadap perubahan kedua kelompok metrik tersebut diuraikan pada subbab-subbab berikut.

VI.2.2 Hybrid Search: Kombinasi BM25 dan Dense Retrieval

Subbab ini mengisolasi kontribusi penambahan *dense retrieval* di atas BM25 dengan membandingkan Kelompok 1 (BM25 saja) terhadap Kelompok 2 (*Hybrid*), keduanya tanpa ekspansi akronim, pada model GPT-4.1-mini. Tabel VI.3 dan Gambar VI.1 menyajikan perbandingan *Label Accuracy* dan *faithfulness* pada empat konfigurasi mitigasi.

Tabel VI.3 Perbandingan Label Accuracy dan *Faithfulness* antara BM25 dan *Hybrid* pada GPT-4.1-mini

Konfigurasi	Accuracy (%)			Faithfulness		
	BM25	Hybrid	Delta	BM25	Hybrid	Delta
<i>Baseline</i>	65,4	69,2	+3,8	0,893	0,981	+0,088
+ QR	65,4	70,8	+5,4	0,896	0,976	+0,080
+ CR	68,4	69,8	+1,4	0,898	0,981	+0,083
+ QR + CR	68,2	70,0	+1,8	0,810	0,982	+0,172



Gambar VI.1 Perbandingan akurasi label antara BM25 saja dengan *Hybrid Retrieval* pada GPT-4.1-mini

Hybrid secara konsisten lebih unggul dibandingkan BM25 saja pada seluruh empat konfigurasi, dengan peningkatan *accuracy* berkisar +1,4 hingga +5,4 poin persentase. Keunggulan serupa juga tampak pada jalur *retrieval*. Pada konfigurasi *baseline*, Recall@5 naik dari 68,94% menjadi 78,65%, dengan pola peningkatan yang sama pada MAP@5 dan nDCG@5 (lihat Tabel VI.1). Keunggulan ini berakar pada cara kerja kedua *retriever*. BM25 hanya melakukan pencocokan kata secara eksak, sehingga apabila pengguna memakai kata yang berbeda dari yang ada di dokumen, dokumen relevan dapat terlewat meskipun maknanya sama. Sebagai contoh, kueri yang menyebut “heart attack” tidak akan dicocokkan oleh BM25 dengan dokumen yang menggunakan istilah “myocardial infarction”. *Hybrid Retrieval* menambahkan *dense retriever* yang membandingkan kueri dan dokumen berdasarkan makna,

bukan kemunculan kata, sehingga sinonim, parafrase, dan istilah yang berkaitan secara semantik tetap dapat ditemukan.

Dampak *Hybrid* yang paling menonjol justru terlihat pada *faithfulness*, yang melonjak dari kisaran 0,89 (BM25) menjadi kisaran 0,98 (*Hybrid*), yaitu kenaikan sekitar +9 poin persentase pada hampir seluruh konfigurasi. Lonjakan ini menunjukkan bahwa konteks yang lebih relevan dari *dense retriever* membuat jawaban LLM jauh lebih *grounded* pada dokumen sumber, yang merupakan indikator langsung berkurangnya halusinasi intrinsik dan ekstrinsik. Dengan demikian, *Hybrid Search* berperan ganda, yaitu menaikkan akurasi klasifikasi sekaligus menjadi pendorong utama peningkatan *faithfulness* pada sistem. Keunggulan ini tetap konsisten pada keempat konfigurasi, baik tanpa mitigasi tambahan maupun saat dipadukan dengan *Query Rewriting* dan *Context Reranking*.

VI.2.3 Ekspansi Akronim

Subbab ini mengisolasi kontribusi praproses ekspansi akronim dengan membandingkan Kelompok 2 dan Kelompok 3, yaitu dua konfigurasi yang sama-sama memakai *Hybrid* dan hanya berbeda pada ada atau tidaknya ekspansi akronim di dalam korpus. Tabel VI.4 menunjukkan pengaruhnya pada metrik IR (konfigurasi *baseline*), sedangkan Tabel VI.5 menunjukkan pengaruhnya pada *accuracy* dan *hallucination rate*.

Tabel VI.4 Pengaruh Ekspansi Akronim terhadap Metrik IR pada Konfigurasi *Hybrid Baseline*

Metrik	Tanpa Ekspansi (%)	Dengan Ekspansi (%)	Delta
Recall@5	78,65	84,96	+6,31
MAP@5	75,32	82,47	+7,15
nDCG@5	83,08	88,45	+5,37

Tabel VI.5 Pengaruh Ekspansi Akronim terhadap Label Accuracy dan *Hallucination Rate* pada Konfigurasi *Hybrid* (GPT-4.1-mini)

Konfigurasi	Accuracy (%)			Hallucination Rate (%)		
	Tanpa	Dengan	Delta	Tanpa	Dengan	Delta
<i>Baseline</i>	69,2	73,2	+4,0	30,8	26,8	−4,0
+ QR	70,8	73,0	+2,2	29,2	27,0	−2,2
+ CR	69,8	73,4	+3,6	30,2	26,6	−3,6
+ QR + CR	70,0	74,8	+4,8	30,0	25,2	−4,8

Ekspansi akronim memperbaiki kualitas *retrieval* secara konsisten, dengan kenaikan Recall@5 sebesar +6,3 poin, MAP@5 +7,2 poin, dan nDCG@5 +5,4 poin pada konfigurasi *baseline*. Perbaikan ini berlanjut ke jalur jawaban, yaitu *accuracy* naik +2,2 sampai +4,8 poin persentase dan *hallucination rate* turun dengan besaran yang sama pada keempat konfigurasi, dengan dampak terbesar pada konfigurasi gabungan +QR+CR (*accuracy* 70,0% menjadi 74,8%, *hallucination rate* 30,0% menjadi 25,2%).

Mekanisme di balik perbaikan ini adalah ketersediaan kepanjangan akronim secara eksplisit di setiap *chunk* korpus. Pada korpus tanpa ekspansi, dokumen yang hanya menyebut bentuk singkat suatu akronim (misalnya “COPD”) sulit dicocokkan dengan kueri yang menyebut bentuk panjangnya (“chronic obstructive pulmonary disease”), atau sebaliknya. Setelah ekspansi diterapkan, kedua bentuk istilah hadir bersama di dalam *chunk*, sehingga dokumen relevan lebih mudah ditemukan dan lebih sering menempati peringkat atas. Hal ini terlihat pula pada metrik *context recall* yang ikut naik (0,851 menjadi 0,888 pada konfigurasi *baseline*), yang menandakan konteks yang diberikan ke LLM menjadi lebih lengkap dan relevan, sehingga kecenderungan jawaban berhalusinasi berkurang.

VI.2.4 Query Rewriting

Subbab ini mengisolasi kontribusi *Query Rewriting* dengan membandingkan konfigurasi +QR terhadap *baseline* pada masing-masing kelompok. Tabel VI.6 menyajikan pengaruh QR terhadap Recall@5 dan *accuracy*.

Tabel VI.6 Pengaruh *Query Rewriting* terhadap Recall@5 dan Accuracy per Kelompok (GPT-4.1-mini)

Kelompok	Recall@5 (%)			Accuracy (%)		
	Baseline	+ QR	Delta	Baseline	+ QR	Delta
Kelompok 1 (BM25)	68,94	64,65	−4,29	65,4	65,4	0,0
Kelompok 2 (<i>Hybrid</i>)	78,65	75,73	−2,92	69,2	70,8	+1,6
Kelompok 3 (+ Ekspansi)	84,96	83,06	−1,90	73,2	73,0	−0,2

Berbeda dengan teknik lain, *Query Rewriting* yang berdiri sendiri justru menurunkan Recall@5 secara konsisten pada ketiga kelompok (antara −1,9 hingga −4,3 poin), sementara pengaruhnya pada *accuracy* cenderung netral atau sedikit negatif. Pola ini berbeda dari sebagian literatur yang melaporkan bahwa *Query Rewriting* dapat menaikkan akurasi sistem RAG. Perbedaan tersebut dapat dijelaskan oleh karakteris-

tik dataset. Teknik *Query Rewriting* umumnya efektif pada kueri yang *noisy*, bersifat percakapan, atau kurang terdefinisi dengan baik, karena tulis-ulang membantu menutup kesenjangan kosakata antara kueri dan dokumen. Selain itu, *Query Rewriting* pada awalnya dirancang untuk pencarian berdomain terbuka (*open-domain*) dengan korpus yang sangat besar dan beragam, sehingga menghasilkan beberapa variasi kueri memperbesar peluang mencocokkan dokumen yang diungkapkan dengan kata berbeda (Ma dkk. 2023). Sebaliknya, penelitian ini menggunakan korpus tertutup (*closed corpus*) yang terbatas, dan setiap pertanyaan PubMedQA pada umumnya hanya memiliki satu dokumen sumber yang sudah selaras dengan kuerinya. Dalam kondisi tertutup seperti ini, variasi kueri tidak menemukan banyak dokumen relevan alternatif untuk diangkat, melainkan justru menarik potongan yang kurang relevan dari korpus yang sama. Selanjutnya, pertanyaan pada PubMedQA telah dirumuskan oleh pakar, padat istilah biomedis, dan sudah presisi sejak awal. Sifat presisi ini merupakan konsekuensi dari karakteristik dataset yang faktual, dirumuskan pakar, dan terstandar, yang justru menjadi dasar pemilihannya pada Bab III, sehingga keterbatasan kontribusi *Query Rewriting* di sini bukan kelemahan dataset melainkan akibat wajar dari kualitas kuerinya. Pada kondisi ini, menulis ulang kueri justru menggeser kata kunci yang sebelumnya sudah berhasil dicocokkan oleh *retriever*, sehingga sebagian dokumen relevan menjadi tergeser dari lima peringkat teratas.

Menariknya, di antara ketiga kelompok, hanya *Hybrid* (Kelompok 2) yang *accuracy*-nya tetap naik (+1,6 poin) meskipun *Recall@5* menurun. Pada konfigurasi *Hybrid*, komponen *dense retrieval* dapat memanfaatkan variasi kueri hasil tulis-ulang untuk menarik dokumen yang secara makna tetap mendukung jawaban, sehingga LLM masih memperoleh bukti yang memadai untuk menyimpulkan label yang benar walaupun peringkat dokumen sumber sedikit tergeser. Sebaliknya, pada BM25 saja variasi kueri hanya menambahkan kata-kata baru yang kurang relevan sehingga *accuracy* tidak berubah, sementara pada Kelompok 3 korpus sudah sangat selaras sehingga QR nyaris tidak memberi tambahan. Hal ini menunjukkan bahwa *Query Rewriting* paling kompatibel dengan *Hybrid retrieval*, meskipun besar peningkatannya masih terbatas. Dengan demikian, manfaat *Query Rewriting* pada dataset ini baru terlihat ketika dipadukan dengan *Context Reranking*, yang menyaring ulang peringkat akhir dan memulihkan dokumen relevan yang sempat tergeser.

VI.2.5 Context Reranking

Subbab ini mengisolasi kontribusi *Context Reranking* dengan membandingkan konfigurasi +CR terhadap *baseline* pada masing-masing kelompok. Tabel VI.7 menyajikan pengaruh CR terhadap *Recall@5* dan *accuracy*.

Tabel VI.7 Pengaruh *Context Reranking* terhadap Recall@5 dan Accuracy per Kelompok (GPT-4.1-mini)

Kelompok	Recall@5 (%)			Accuracy (%)		
	Baseline	+ CR	Delta	Baseline	+ CR	Delta
Kelompok 1 (BM25)	68,94	75,54	+6,60	65,4	68,4	+3,0
Kelompok 2 (<i>Hybrid</i>)	78,65	80,84	+2,19	69,2	69,8	+0,6
Kelompok 3 (+ Ekspansi)	84,96	86,49	+1,53	73,2	73,4	+0,2

Context Reranking memberi kontribusi positif yang konsisten pada seluruh kelompok, baik pada Recall@5 (+1,5 hingga +6,6 poin) maupun pada *accuracy*. Mekanismenya terletak pada penggunaan *cross-encoder* yang membaca pasangan (kueri, dokumen) secara bersamaan, sehingga dapat menilai relevansi secara lebih mendalam dibandingkan *retriever* cepat yang menilai kueri dan dokumen secara terpisah. Dengan penilaian ulang ini, dokumen yang benar-benar relevan dinaikkan ke peringkat atas dan lima dokumen teratas yang diteruskan ke LLM menjadi lebih bersih. Dampak terbesar terjadi pada Kelompok 1 yang hanya memakai BM25, karena pemeringkatan awal BM25 paling kasar sehingga ruang perbaikannya paling besar; sebaliknya, pada kelompok yang kualitas *retrieval*-nya sudah tinggi, ruang perbaikan mengecil. Selain itu, *Context Reranking* berperan memulihkan penurunan akibat *Query Rewriting*, sehingga kombinasi +QR+CR mampu menjadi konfigurasi terbaik secara keseluruhan.

VI.2.6 Efek Kumulatif terhadap Akurasi

Setelah kontribusi tiap teknik dibahas secara terpisah, subbab ini merangkum efek kumulatifnya terhadap akurasi pada seluruh dua belas konfigurasi yang dievaluasi pada GPT-4.1-mini, mulai dari konfigurasi paling sederhana (BM25 tanpa ekspansi akronim) hingga konfigurasi paling lengkap (*Hybrid Retrieval* dengan ekspansi akronim, *Query Rewriting*, dan *Context Reranking*). Tabel VI.8 disusun mengikuti tiga kelompok pada Tabel IV.2 di Bab IV agar pembaca dapat melihat kontribusi setiap komponen secara bertahap.

Tabel VI.8 Peningkatan *Accuracy Across* Konfigurasi

Konfigurasi	Accuracy (%)
<i>Baseline</i> BM25 (tanpa Ekspansi Akronim)	65,4
BM25 + <i>Query Rewriting</i> (tanpa Ekspansi Akronim)	65,4
BM25 + <i>Context Reranking</i> (tanpa Ekspansi Akronim)	68,4
BM25 + <i>Query Rewriting</i> + <i>Context Reranking</i> (tanpa Ekspansi Akronim)	68,2
<i>Baseline Hybrid Retrieval</i> (tanpa Ekspansi Akronim)	69,2
<i>Hybrid</i> + <i>Query Rewriting</i> (tanpa Ekspansi Akronim)	70,8
<i>Hybrid</i> + <i>Context Reranking</i> (tanpa Ekspansi Akronim)	69,8
<i>Hybrid</i> + <i>Query Rewriting</i> + <i>Context Reranking</i> (tanpa Ekspansi Akronim)	70,0
<i>Baseline Hybrid Retrieval</i> (dengan Ekspansi Akronim)	73,2
<i>Hybrid</i> + <i>Query Rewriting</i> (dengan Ekspansi Akronim)	73,0
<i>Hybrid</i> + <i>Context Reranking</i> (dengan Ekspansi Akronim)	73,4
<i>Hybrid</i> + <i>Query Rewriting</i> + <i>Context Reranking</i> (dengan Ekspansi Akronim)	74,8

Tabel VI.8 memperlihatkan tren peningkatan akurasi yang konsisten dari satu kelompok ke kelompok berikutnya. Pada kelompok pertama yang hanya memakai BM25 tanpa ekspansi akronim, akurasi berkisar antara 65,4% hingga 68,4%, dengan kontribusi terbesar dari *Context Reranking*. Penambahan *dense retrieval* di atas BM25 pada kelompok kedua menaikkan akurasi seluruh konfigurasi menjadi rentang 69,2%–70,8%, dengan peningkatan rata-rata sekitar +3,3 poin persentase terhadap kelompok pertama. Penerapan ekspansi akronim pada kelompok ketiga kembali menaikkan akurasi menjadi 73,0%–74,8%, dengan tambahan rata-rata sekitar +3,5 poin persentase terhadap kelompok kedua. Konfigurasi terbaik adalah kombinasi *Hybrid Retrieval*, ekspansi akronim, *Query Rewriting*, dan *Context Reranking* dengan *accuracy* sebesar 74,8%, yang merupakan peningkatan total +9,4 poin persentase dari titik awal BM25 *baseline*.

VI.2.7 Hallucination Rate pada Dua Belas Konfigurasi

Karena tujuan utama tugas akhir ini adalah mitigasi halusinasi, hasil pada Tabel VI.8 dilengkapi dengan *hallucination rate* yang disajikan pada Tabel VI.9. Penyajian dalam bentuk *hallucination rate* bertujuan agar dampak mitigasi terlihat lebih jelas, yaitu sebagai penurunan yang konsisten dari konfigurasi paling sederhana ke konfigurasi paling lengkap.

Tabel VI.9 *Hallucination Rate Across Konfigurasi*

Konfigurasi	Hallucination Rate (%)
<i>Baseline</i> BM25 (tanpa Ekspansi Akronim)	34,6
BM25 + <i>Query Rewriting</i> (tanpa Ekspansi Akronim)	34,6
BM25 + <i>Context Reranking</i> (tanpa Ekspansi Akronim)	31,6
BM25 + <i>Query Rewriting</i> + <i>Context Reranking</i> (tanpa Ekspansi Akronim)	31,8
<i>Baseline Hybrid Retrieval</i> (tanpa Ekspansi Akronim)	30,8
<i>Hybrid</i> + <i>Query Rewriting</i> (tanpa Ekspansi Akronim)	29,2
<i>Hybrid</i> + <i>Context Reranking</i> (tanpa Ekspansi Akronim)	30,2
<i>Hybrid</i> + <i>Query Rewriting</i> + <i>Context Reranking</i> (tanpa Ekspansi Akronim)	30,0
<i>Baseline Hybrid Retrieval</i> (dengan Ekspansi Akronim)	26,8
<i>Hybrid</i> + <i>Query Rewriting</i> (dengan Ekspansi Akronim)	27,0
<i>Hybrid</i> + <i>Context Reranking</i> (dengan Ekspansi Akronim)	26,6
<i>Hybrid</i> + <i>Query Rewriting</i> + <i>Context Reranking</i> (dengan Ekspansi Akronim)	25,2

Analisis lanjutan mengenai kontribusi teknik QR dan CR pada berbagai pilihan LLM, serta perbandingan kinerja model sumber terbuka lokal Llama 3.2 3B dengan model berbayar berskala besar, disajikan secara lengkap pada Lampiran C. Secara ringkas, analisis tersebut menunjukkan bahwa *Context Reranking* memberi peningkatan yang relatif stabil di seluruh model, sedangkan kontribusi *Query Rewriting* bervariasi mengikuti karakteristik tiap LLM, dan model berskala besar secara konsisten mengungguli model kecil pada tugas tanya jawab biomedis.

VI.2.8 Estimasi Waktu Tanggap dan Biaya Komputasi

Selain kualitas jawaban, aspek efisiensi juga penting untuk menilai kelayakan sistem pada penggunaan nyata. Bagian ini menyajikan estimasi waktu tanggap (*latency*) dan biaya komputasi untuk dua belas konfigurasi pada GPT-4.1-mini. Estimasi disusun secara analitis dengan menjumlahkan kontribusi tiap komponen *pipeline* yang aktif pada setiap konfigurasi, dengan acuan hasil pengukuran langsung pada prototipe yang menunjukkan waktu tanggap konfigurasi terlengkap (*Hybrid* + ekspansi + QR + CR) sekitar 4,7 detik per kueri dan biaya sekitar \$0,0014 per kueri. Rincian estimasi latensi per komponen disajikan pada Tabel VI.10.

Tabel VI.10 Estimasi Latensi per Komponen *Pipeline* (GPT-4.1-mini)

Komponen	Estimasi (s)	Keterangan
<i>Query Rewriting</i>	0,83	1 panggilan LLM
<i>Retrieval</i> BM25 saja	0,10	Lokal, tanpa panggilan API
<i>Retrieval Hybrid</i> (BM25 + <i>dense</i> + RRF)	0,89	Termasuk 1 panggilan <i>embedding</i>
<i>Context Reranking</i>	0,52	<i>Cross-encoder</i> lokal
<i>Generation</i>	2,49	1 panggilan LLM

Pada sisi biaya, hanya pemanggilan LLM dan *embedding* yang menimbulkan biaya API, sedangkan BM25 dan *Context Reranking* berjalan lokal sehingga gratis. Setiap konfigurasi selalu memerlukan satu pemanggilan LLM untuk *generation*, ditambah satu pemanggilan LLM untuk *Query Rewriting* apabila teknik tersebut aktif, serta satu pemanggilan *embedding* berbiaya sangat kecil pada konfigurasi *Hybrid*. Berdasarkan acuan tersebut, biaya per kueri diperkirakan sekitar \$0,0012 tanpa *Query Rewriting* dan \$0,0014 dengan *Query Rewriting*. Estimasi gabungan waktu tanggap dan biaya untuk seluruh dua belas konfigurasi disajikan pada Tabel VI.11.

Tabel VI.11 Estimasi Waktu Tanggap dan Biaya Komputasi per Konfigurasi (GPT-4.1-mini)

Konfigurasi	Waktu (s)	Panggilan LLM	Biaya/kueri (\$)	Biaya 500 kueri (\$)
<i>Kelompok 1: BM25 tanpa Ekspansi Akronim</i>				
<i>Baseline</i>	2,59	1	0,0012	0,60
+ QR	3,42	2	0,0014	0,70
+ CR	3,11	1	0,0012	0,60
+ QR + CR	3,94	2	0,0014	0,70
<i>Kelompok 2: Hybrid Retrieval tanpa Ekspansi Akronim</i>				
<i>Baseline</i>	3,38	1	0,0012	0,60
+ QR	4,21	2	0,0014	0,70
+ CR	3,90	1	0,0012	0,60
+ QR + CR	4,73	2	0,0014	0,70
<i>Kelompok 3: Hybrid Retrieval dengan Ekspansi Akronim</i>				
<i>Baseline</i>	3,38	1	0,0012	0,60
+ QR	4,21	2	0,0014	0,70
+ CR	3,90	1	0,0012	0,60
+ QR + CR	4,73	2	0,0014	0,70

Tabel VI.11 memperlihatkan beberapa pola. Pertama, konfigurasi Kelompok 3 memiliki estimasi waktu dan biaya yang identik dengan Kelompok 2, karena ekspansi akronim diterapkan sebagai praproses korpus secara *offline* sehingga tidak menambah beban komputasi maupun biaya pada saat tanya jawab berlangsung. Kedua, penambahan waktu terbesar berasal dari *Query Rewriting* (sekitar +0,83 detik), karena teknik ini memerlukan satu pemanggilan LLM tambahan, sedangkan *Context Reranking* hanya menambah sekitar 0,52 detik dan tidak menimbulkan biaya API karena berjalan secara lokal. Ketiga, seluruh konfigurasi memiliki estimasi waktu tanggap di bawah lima detik dan biaya per kueri di bawah \$0,0015, sehingga seluruhnya masih berada jauh di bawah ambang waktu interaktif yang wajar dan tetap ekonomis untuk dijalankan pada skala ribuan pertanyaan. Konfigurasi terbaik (*Hybrid* + ekspansi + QR + CR) memiliki estimasi waktu tanggap tertinggi, yaitu sekitar 4,73 detik, yang merupakan kompromi yang wajar mengingat peningkatan akurasi dan penurunan halusinasi yang diperolehnya. Perlu dicatat bahwa angka-angka ini merupakan estimasi analitis berbasis rata-rata komponen, sehingga nilai sebenarnya dapat bervariasi mengikuti kondisi jaringan dan beban layanan API pada saat pemanggilan.

VI.2.9 Analisis Kasus Kegagalan

Selain mengukur kinerja agregat, dilakukan penelusuran terhadap kasus-kasus jawaban yang salah untuk memahami sumber kesalahan yang tersisa. Penelusuran ini disusun dari yang paling spesifik menuju yang paling umum, yaitu diawali oleh satu kasus nyata yang diamati pada tiga konfigurasi, dilanjutkan dengan mekanisme *retrieval* yang mendasarinya, dan ditutup dengan distribusi tipe kegagalan pada seluruh himpunan uji.

Untuk menggambarkan bagaimana perbaikan *retrieval* dapat menekan halusinasi pada tahap *generation*, Tabel VI.12 menyajikan satu kasus nyata pada pertanyaan “*Does the Child Health Computing System adequately identify children with cerebral palsy?*” yang jawaban benarnya adalah *no*. Pertanyaan yang sama ditelusuri pada tiga konfigurasi *baseline*, yaitu BM25 (Kelompok 1), *Hybrid* (Kelompok 2), dan *Hybrid* dengan ekspansi akronim (Kelompok 3). Pada setiap jawaban, bagian inti yang menjadi dasar kesimpulan dicetak tebal.

Tabel VI.12 Contoh Perbaikan Jawaban, *Faithfulness*, dan *Recall@5* antar Kelompok Konfigurasi

Konfigurasi	Prediksi	<i>Faith.</i>	<i>Rec.@5</i>	Jawaban LLM
Kelompok 1: BM25	<i>yes</i> (salah)	0,33	0,67	The abstracts indicate that a comparative survey was conducted between the Child Health Computing System (CHCS) and the Northern Ireland Cerebral Palsy Register (NICPR) to assess information on children with cerebral palsy. Since the study was designed to evaluate the usefulness of CHCS as a source of information about children with cerebral palsy, it implies that the system is at least somewhat effective in identifying these children. However, no explicit statement confirms complete adequacy.
Kelompok 2: <i>Hybrid</i>	<i>maybe</i> (salah)	1,00	0,67	The abstracts describe a study comparing information on children with cerebral palsy held in the Child Health Computing System (CHCS) and the Northern Ireland Cerebral Palsy Register (NICPR). The purpose was to assess the usefulness of the CHCS as a source of information about children with cerebral palsy, implying an evaluation of its adequacy. However, the provided context does not explicitly state the outcome or conclusion regarding the adequacy of the CHCS in identifying children with cerebral palsy.
Kelompok 3: <i>Hybrid +</i> Ekspansi	<i>no</i> (benar)	1,00	1,00	The CHCS missed 47% of cerebral palsy cases recorded on the Northern Ireland Cerebral Palsy Register (NICPR), and many children had no computer record of any medical diagnosis. Additionally, some cases found on CHCS were not confirmed to have cerebral palsy upon follow-up. This indicates that the CHCS does not adequately identify children with cerebral palsy.

Kolom *Recall@5* pada tabel menunjukkan seberapa banyak dokumen relevan yang berhasil masuk ke lima peringkat teratas. Pada Kelompok 1 (BM25), nilai *Recall@5* hanya 0,67 karena baru dua dari tiga dokumen relevan yang tertarik ke lima besar, dan dokumen yang memuat angka kunci belum termasuk di dalamnya. Walaupun

bukti yang tepat belum tersedia, LLM tetap menyimpulkan secara percaya diri bahwa sistem “setidaknya cukup efektif” dan menjawab *yes*. Kesimpulan ini tidak didukung oleh konteks sehingga merupakan halusinasi, dan hal tersebut tecermin dari nilai *faithfulness* yang rendah (0,33) sekaligus jawaban yang keliru.

Pada Kelompok 2 (*Hybrid*), nilai *Recall@5* masih 0,67, artinya kualitas *retrieval* untuk pertanyaan ini belum berubah dibandingkan BM25. Yang membaik justru sisi *generation*: LLM tidak lagi mengarang dan memilih menjawab lebih berhati-hati dengan *maybe* sambil secara terbuka menyatakan bahwa konteks tidak memuat kesimpulan yang eksplisit. Karena seluruh pernyataan jawabannya memang dapat ditelusuri ke konteks, nilai *faithfulness* menjadi penuh (1,00). Akan tetapi jawaban tetap salah, sebab dokumen yang memuat angka penentu belum tertarik ke lima peringkat teratas.

Baru pada Kelompok 3 (*Hybrid* dengan ekspansi akronim), nilai *Recall@5* naik menjadi 1,00 dan jumlah dokumen relevan di lima besar bertambah dari dua menjadi tiga. Hal ini terjadi karena ekspansi akronim menyamakan istilah pada korpus, yaitu memperjelas singkatan *Child Health Computing System* (CHCS) dan *Northern Ireland Cerebral Palsy Register* (NICPR), sehingga dokumen sumber yang semula tergeser kini berhasil masuk ke lima peringkat teratas. Dokumen tersebut memuat bukti konkret pada korpus, yaitu bahwa CHCS melewati 47% kasus *cerebral palsy* yang tercatat pada NICPR. Berbekal bukti itu, LLM akhirnya menyimpulkan dengan benar *no* dan tetap berlandaskan konteks (*faithfulness* 1,00).

Contoh ini memperlihatkan dua jenis perbaikan yang berbeda secara jelas. Dari Kelompok 1 ke Kelompok 2, perbaikan terjadi pada sisi *generation*, yaitu jawaban berhenti mengarang meskipun kualitas *retrieval* belum berubah, dengan kenaikan *faithfulness* dari 0,33 menjadi 1,00. Dari Kelompok 2 ke Kelompok 3, perbaikan terjadi pada sisi *retrieval*, yaitu ekspansi akronim membuat lebih banyak dokumen relevan masuk ke lima peringkat teratas dengan kenaikan *Recall@5* dari 0,67 menjadi 1,00, sehingga jawaban berubah dari salah menjadi benar.

Perbaikan *retrieval* dari Kelompok 2 ke Kelompok 3 pada kasus di atas bersumber dari ekspansi akronim. Untuk melihat secara konkret bagaimana ekspansi akronim memindahkan dokumen sumber ke dalam lima peringkat teratas, Tabel VI.13 membandingkan skor BM25 dan peringkat dokumen sumber sebelum dan sesudah ekspansi pada dua pertanyaan. Kasus pertama adalah pertanyaan CHCS yang baru dibahas. Sebelum ekspansi, kalimat penentu pada dokumen sumber hanya menuliskan singkatan “CHCS” dan “NICPR” tanpa kepanjangannya, sehingga

kata kunci seperti “child health computing system” dan “cerebral palsy” pada pertanyaan tidak tercocokkan; akibatnya dokumen itu hanya menempati peringkat ke-107 dengan skor BM25 6,24, jauh di luar lima besar. Setelah ekspansi akronim diterapkan, dokumen yang sama memuat “CHCS (child health computing system)” dan “NICPR (northern ireland cerebral palsy register)” sehingga kata kunci kembali tercocokkan, skor BM25-nya melonjak menjadi 44,43, dan peringkatnya naik ke posisi ketiga sehingga masuk ke konteks LLM. Kasus kedua, pada pertanyaan mengenai *international normalised ratio* (INR), memperlihatkan pola yang sama, yaitu dokumen sumber yang semula hanya memuat singkatan “INR” naik dari peringkat ke-6 ke peringkat pertama setelah kepanjangannya ikut tertulis.

Tabel VI.13 Contoh Pengaruh Ekspansi Akronim terhadap Peringkat Dokumen Sumber

Kondisi	Cuplikan Teks Dokumen Sumber	Skor BM25	Peringkat
<i>Kasus 1: pertanyaan mengenai CHCS dan cerebral palsy</i>			
Tanpa ekspansi	...recorded on the NICPR, 47 per cent were not found on the CHCS ...	6,24	107 (di luar top-5)
Dengan ekspansi	...recorded on the NICPR (<i>northern ireland cerebral palsy register</i>), 47 per cent were not found on the CHCS (<i>child health computing system</i>) ...	44,43	3
<i>Kasus 2: pertanyaan mengenai INR</i>			
Tanpa ekspansi	...INR measurements obtained in general practice ...	9,79	6 (di luar top-5)
Dengan ekspansi	...INR (<i>international normalized ratio</i>) measurements obtained in general practice ...	21,31	1

Kedua contoh ini menegaskan mekanisme yang dibahas pada Subbab VI.2.3, yaitu ekspansi akronim menutup kesenjangan kosakata antara kueri dan dokumen, sehingga dokumen relevan yang semula tergeser dapat kembali masuk ke lima peringkat teratas dan menurunkan kegagalan *retrieval*.

Penelusuran per kasus seperti di atas selanjutnya diperluas ke seluruh himpunan uji untuk memperoleh gambaran agregat mengenai sumber kesalahan yang tersisa. Dari 500 pertanyaan pada konfigurasi terbaik (*Hybrid Retrieval* dengan ekspansi akronim, GPT-4.1-mini), terdapat 134 jawaban yang salah. Setiap kasus salah ditelusuri untuk menentukan apakah kegagalan berasal dari tahap *retrieval* (dokumen sumber tidak berhasil ditarik) atau tahap *generation* (dokumen sumber sudah ada

pada konteks, tetapi LLM salah menyimpulkan). Hasil penelusuran disajikan pada Tabel VI.14.

Tabel VI.14 Distribusi Tipe Kegagalan pada Konfigurasi Terbaik

Tipe Kegagalan	Jumlah	Porsi
<i>Retrieval-miss</i> (dokumen sumber tidak ter- <i>retrieve</i>)	5	3,7%
<i>Generation-error</i> (dokumen ada, LLM salah menyimpulkan)	129	96,3%
Total	134	100%

Temuan paling menonjol adalah bahwa hanya 5 dari 134 kasus salah (3,7%) yang disebabkan oleh kegagalan *retrieval*, sedangkan 129 sisanya (96,3%) terjadi karena LLM salah menyimpulkan meskipun dokumen sumber sudah tersedia pada konteks. Hal ini menunjukkan bahwa setelah ekspansi akronim dan *hybrid retrieval* diterapkan, tahap *retrieval* sudah sangat jarang gagal menemukan dokumen yang tepat, sehingga tantangan utama yang tersisa bergeser ke kemampuan penalaran LLM pada tahap *generation*.

Pola kesalahan klasifikasi memperlihatkan kecenderungan LLM untuk terlalu sering memilih label *yes*. Kesalahan terbanyak adalah *maybe* yang diprediksi sebagai *yes* (41 kasus) dan *no* yang diprediksi sebagai *yes* (38 kasus). Sebagai contoh, pada pertanyaan “*Is adjustment for reporting heterogeneity necessary in sleep disorders?*” (jawaban benar *no*), dokumen sumber yang tepat berhasil ditarik ke konteks, tetapi LLM tetap menyimpulkan *yes*. Contoh lain pada pertanyaan “*Double balloon enteroscopy: is it efficacious and safe in a community setting?*” (jawaban benar *yes*) merupakan kasus *retrieval-miss*, yaitu dokumen sumber tidak masuk ke lima dokumen teratas sehingga LLM menjawab tanpa bukti yang memadai.

Oleh karena itu, untuk penggunaan pada konteks nyata, hasil jawaban LLM sebaiknya tetap didiskusikan kembali dengan ahli biomedis, karena pada beberapa kasus ditemukan bahwa dokumen sumber yang relevan sebenarnya sudah tersedia, tetapi LLM tetap berhalusinasi dalam menyimpulkan jawaban. Hal ini menegaskan bahwa sistem ini lebih tepat diposisikan sebagai alat bantu yang mempercepat penelusuran bukti, bukan sebagai pengganti penilaian tenaga ahli.

VI.2.10 Identifikasi Jenis Halusinasi

Sesuai batasan masalah, halusinasi yang ditinjau mencakup tiga jenis, yaitu halusinasi *intrinsik* (jawaban yang bertentangan dengan konteks), halusinasi *ekstrinsik*

(jawaban yang memuat klaim tidak terdapat pada konteks meskipun mungkin benar), dan halusinasi faktual (jawaban yang mengandung klaim faktual yang keliru). Untuk mengetahui jenis mana yang benar-benar muncul pada sistem, dilakukan penelusuran terhadap jawaban dengan nilai *faithfulness* rendah pada seluruh konfigurasi, kemudian setiap jawaban dibandingkan langsung dengan konteks yang ter-retrieve.

Halusinasi ekstrinsik merupakan jenis yang paling sering ditemukan. Tabel VI.15 menyajikan satu contoh nyata pada pertanyaan “*Do inhaled corticosteroids affect perception of dyspnea during bronchoconstriction in asthma?*” yang jawaban benarnya adalah *yes*. Pada Kelompok 1 (BM25), konteks yang ter-retrieve hanya menyebut kortikosteroid inhalasi (*inhaled corticosteroids*, ICS) sebagai salah satu faktor yang sedang diteliti, tanpa menyatakan kesimpulan apa pun. Akan tetapi, LLM tetap menambahkan kesimpulan bahwa ICS memang memengaruhi persepsi sesak napas. Klaim ini tidak terdapat pada konteks meskipun kebetulan benar terhadap pengetahuan umum, sehingga nilai *faithfulness* menjadi 0,00. Setelah kualitas *retrieval* membaik pada Kelompok 3, konteks memuat temuan nyata berupa hubungan negatif antara jumlah eosinofil dan persepsi sesak pada pasien yang diterapi ICS, sehingga kesimpulan yang sama kini berlandaskan konteks dan nilai *faithfulness* naik menjadi 1,00. Pada setiap jawaban, bagian inti yang menjadi dasar kesimpulan dicetak tebal.

Tabel VI.15 Contoh Halusinasi Ekstrinsik dan Perbaikannya Seiring Membaiknya Retrieval

Konfigurasi	Prediksi	Faith.	Jawaban LLM
Kelompok 1: BM25	<i>yes</i>	0,00	The first abstract mentions that one factor influencing the perception of dyspnea during bronchoconstriction in asthma patients is the effect of inhaled corticosteroids (ICSs), implying that ICSs do have an impact on this perception. Although the details are not fully elaborated, the inclusion of ICSs as a relevant factor suggests they affect dyspnea perception.
Kelompok 3: <i>Hybrid</i> + Ekspansi	<i>yes</i>	1,00	The abstracts indicate that inhaled corticosteroids (ICSs) influence the perception of dyspnea (PD) during bronchoconstriction in asthma patients. Specifically, ICS treatment alters the relationship between eosinophil counts and PD, with eosinophil counts negatively associated with PD in ICS-treated patients, suggesting ICSs modulate airway inflammation and thus affect dyspnea perception.

Sebaliknya, halusinasi intrinsik, yaitu jawaban yang secara langsung bertentangan dengan isi konteks, praktis tidak ditemukan pada seluruh konfigurasi. Penelusuran sistematis dilakukan dengan menyaring jawaban yang prediksinya salah, dokumen sumbernya berhasil ter-*retrieve*, dan nilai *faithfulness*-nya rendah, kemudian setiap kandidat dibaca dan dibandingkan kalimat per kalimat dengan konteksnya. Dari proses tersebut tidak ditemukan satu pun kasus di mana model menyatakan kebalikan dari fakta yang tertulis eksplisit pada konteks. Kasus yang semula tampak seperti kontradiksi ternyata lebih merupakan perbedaan interpretasi terhadap bukti yang sama, bukan pertentangan terhadap fakta konteks.

Temuan ini menunjukkan bahwa ketika model menghasilkan halusinasi, kesalahan yang muncul lebih sering berupa penambahan informasi yang tidak didukung oleh konteks dibandingkan dengan penyimpangan terhadap informasi yang sudah tersedia dalam konteks. Dengan demikian, setelah *hybrid retrieval* dan ekspansi akronim diterapkan, halusinasi yang masih tersisa pada sistem ini didominasi oleh halusinasi ekstrinsik. Sementara itu, dampak keseluruhan halusinasi terhadap kebenaran jawaban tercermin pada metrik *hallucination rate* yang dibahas pada Subbab VI.2.7.

VI.2.11 Validitas Eksperimen

Agar hasil perbandingan antar konfigurasi dapat dipercaya, evaluasi pada tugas akhir ini dirancang dengan beberapa kontrol agar setiap perbedaan kinerja benar-benar berasal dari teknik mitigasi yang diuji, bukan dari faktor lain. Kontrol tersebut dijelaskan sebagai berikut.

Pertama, seluruh dua belas konfigurasi diuji pada himpunan yang sama, yaitu 500 pertanyaan PubMedQA yang identik dengan urutan dan isi yang sama persis. Tidak ada konfigurasi yang mendapat pertanyaan berbeda atau lebih mudah. Dengan begitu, ketika satu konfigurasi memperoleh *accuracy* lebih tinggi dari konfigurasi lain, selisih tersebut dapat dipastikan berasal dari teknik yang ditambahkan (ekspansi akronim, *Query Rewriting*, atau *Context Reranking*), bukan karena perbedaan data uji.

Kedua, perubahan antar kelompok konfigurasi dibuat satu per satu sehingga kontribusi tiap teknik dapat ditelusuri secara terpisah. Kelompok 1 dan Kelompok 2 hanya berbeda pada mode *retrieval* (BM25 dibandingkan *Hybrid*), sedangkan Kelompok 2 dan Kelompok 3 hanya berbeda pada ada atau tidaknya ekspansi akronim di korpus, dengan seluruh komponen lain dijaga tetap. Pemisahan ini membuat selisih kinerja antar kelompok dapat diatribusikan langsung pada satu teknik saja.

Ketiga, parameter pemanggilan model bahasa dijaga konsisten pada seluruh konfigurasi. Nilai *temperature* pada tahap *generation* ditetapkan rendah dan *seed* ditetapkan tetap (42), sehingga model menghasilkan jawaban yang stabil dan dapat diperoleh kembali bila pengujian diulang. Tanpa pengaturan ini, model dapat memberikan jawaban berbeda pada pertanyaan yang sama, sehingga perbandingan menjadi tidak adil. Parameter *retrieval* seperti jumlah dokumen yang diambil pada tiap tahap serta konstanta penggabungan *Reciprocal Rank Fusion* juga dibuat sama untuk semua konfigurasi.

Keempat, metrik kualitas jawaban yang berbasis RAGAS dihitung menggunakan satu model penilai yang sama (GPT-4.1-mini) untuk seluruh konfigurasi, sehingga ukuran *faithfulness* dan *context recall* bersifat sebanding antar konfigurasi. Seluruh keluaran tiap konfigurasi juga disimpan pada berkas tersendiri agar hasil dapat ditelusuri ulang dan diverifikasi.

Dengan kombinasi kontrol di atas, yaitu himpunan uji yang sama, perubahan teknik yang dilakukan satu per satu, serta parameter model dan *retrieval* yang dijaga tetap, perbedaan kinerja yang dilaporkan pada bab ini dapat diyakini sebagai dampak nyata dari teknik mitigasi, bukan akibat perbedaan data, variasi acak keluaran model, maupun perbedaan cara penilaian.

BAB VII

PENUTUP

VII.1 Kesimpulan

Berdasarkan perancangan, implementasi, dan evaluasi yang telah dilakukan, tugas akhir ini menyimpulkan beberapa hal berikut sesuai dengan rumusan masalah yang diajukan.

1. Tugas akhir ini telah merancang dan mengimplementasikan arsitektur RAG-LLM untuk mitigasi halusinasi pada sistem tanya jawab biomedis secara berlapis dengan mengintegrasikan empat komponen, yaitu ekspansi akronim pada praproses korpus, *hybrid retrieval* (BM25 + *dense* + *Reciprocal Rank Fusion*), *query rewriting* di sisi kueri, dan *context reranking* berbasis *cross-encoder* sebelum tahap *generation*. Sistem bekerja *end-to-end* pada 500 pertanyaan PubMedQA dan dapat dijalankan pada empat pilihan LLM, yaitu GPT-4.1-mini, Claude Haiku 4.5, Llama 3.3 70B, dan Llama 3.2 3B.
2. Berdasarkan analisis terhadap dua belas konfigurasi, ekspansi akronim memberi dampak positif yang paling konsisten dengan menaikkan *accuracy* sebesar +2,2 hingga +4,8 poin persentase dan *faithfulness* rata-rata +9 poin persentase. *Query rewriting* yang berdiri sendiri tidak memberi peningkatan yang berarti dan bahkan sedikit menurunkan *recall* karena menggeser kata kunci yang sudah cocok, tetapi memberi manfaat ketika dipadukan dengan *context reranking*. Sementara itu, *context reranking* konsisten memperbaiki urutan dokumen dan menurunkan halusinasi pada seluruh kelompok konfigurasi, baik pada metrik *retrieval* maupun *generation*. Konfigurasi terbaik yang menggabungkan keempat komponen pada GPT-4.1-mini mencapai *accuracy* 74,8% dan *faithfulness* 0,980 serta menurunkan *hallucination rate* dari 34,6% menjadi 25,2%, yang menunjukkan bahwa pendekatan mitigasi berlapis mampu menurunkan halusinasi secara substansial pada sistem tanya jawab biomedis.

VII.2 Saran

Sistem yang dibangun pada tugas akhir ini sudah menunjukkan hasil yang cukup baik, tetapi masih banyak hal yang dapat dikerjakan lebih lanjut agar mitigasi halusinasi pada RAG-LLM biomedis semakin matang. Berikut beberapa arah pengembangan yang dapat dipertimbangkan.

1. **Eksplorasi *prompt engineering* yang lebih mendalam.** *Prompt* jawaban dan *prompt query rewriting* yang dipakai pada tugas akhir ini didapat melalui beberapa kali percobaan sederhana hingga didapat versi yang stabil. Namun masih banyak teknik *prompt* dalam literatur yang belum sempat diuji, misalnya *chain-of-thought*, *few-shot* dengan contoh biomedis, atau *self-consistency decoding*. Pengujian teknik-teknik tersebut secara lebih sistematis layak dilakukan karena peluang untuk menaikkan kualitas jawaban dan *faithfulness* masih terbuka tanpa harus mengubah arsitektur *retrieval* yang sudah ada.
2. **Evaluasi langsung oleh pakar biomedis.** Metrik seperti *accuracy* dan *faithfulness* memang berguna untuk membandingkan banyak konfigurasi sekaligus, tetapi angka saja belum cukup menggambarkan apakah jawaban yang dihasilkan benar-benar aman bila dibaca oleh tenaga medis maupun pasien. Penilaian langsung dari pakar biomedis dapat menangkap aspek-aspek yang sulit diukur oleh metrik otomatis, seperti kebenaran klinis, kemungkinan salah tafsir, atau informasi penting yang luput dijawab. Evaluasi semacam ini menjadi semakin penting bila sistem diarahkan ke konteks penggunaan nyata, baik untuk membantu edukasi pasien maupun mendukung pekerjaan tenaga medis sehari-hari.
3. **Perluasan cakupan korpus dari *paper* ilmiah biomedis.** Korpus pada tugas akhir ini terbatas pada subset *pqa_labeled* dari PubMedQA yang berisi seribu *paper*. Untuk menjangkau lebih banyak topik medis, sumber data dapat diperluas ke subset PubMed yang lebih besar, basis data lain seperti BioASQ atau MedQA, atau bahkan catatan medis seperti MIMIC. Penambahan ini akan memperkaya variasi pertanyaan yang dapat ditangani sistem dan membuat hasil evaluasi lebih dekat ke kebutuhan klinis sebenarnya.
4. **Dukungan multibahasa dan adaptasi domain.** Tugas akhir ini dibatasi pada pertanyaan biomedis berbahasa Inggris. Pengembangan ke arah *multilingual biomedical question answering* akan memperluas jangkauan pengguna, sementara adaptasi domain ke subbidang medis yang lebih spesifik, misalnya onkologi atau kardiologi, dapat meningkatkan ketepatan jawaban pada konteks yang lebih sempit.
5. **Pelatihan khusus *retriever* dan deteksi halusinasi aktif.** Kinerja *retrieval*

masih dapat ditingkatkan dengan *fine-tuning* model *retriever* pada korpus biomedis sehingga representasi istilah medis menjadi lebih tepat. Selain itu, penambahan *active hallucination detection* yang memeriksa kesetiaan jawaban terhadap konteks secara langsung saat *generation* dapat menjadi lapisan pengaman tambahan sebelum jawaban diberikan kepada pengguna.

Beberapa arah pengembangan tersebut dapat menjadi langkah lanjutan dari tugas akhir ini agar sistem tanya jawab biomedis berbasis RAG-LLM semakin dekat dengan kebutuhan klinis nyata.

DAFTAR PUSTAKA

- Arooj. March 2025. “Accelerating RAG Performance with Neural Reranking”. Chitika. Diakses pada June 5, 2026. <https://www.chitika.com/neural-reranking-rag/>.
- Casanueva, Iñigo, Patrik Temcinas, Daniela Gerz, dan Matthew Henderson. 2020. “Banking77: Intent Classification Benchmark for Banking Domain”. Dalam *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP) Workshop*. <https://aclanthology.org/2020.emnlp-main.558>.
- Cook, Thomas, Richard Osuagwu, Liman Tsatiashvili, Vrynsia Vrynsia, Koustav Ghosal, Maraim Masoud, dan Riccardo Mattivi. 2025. “Retrieval Augmented Generation (RAG) for Fintech: Agentic Design and Evaluation”. *arXiv preprint arXiv:2510.25518*, <https://arxiv.org/abs/2510.25518>.
- Cormack, Gordon V., Charles L. A. Clarke, dan Stefan Buettcher. 2009. “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods”. Dalam *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 758–759. SIGIR '09. New York, NY, USA: Association for Computing Machinery. <https://doi.org/10.1145/1571941.1572114>. <https://doi.org/10.1145/1571941.1572114>.
- Dadopoulos, Michail, Anestis Ladas, Stratos Moschidis, dan Ioannis Negkakis. 2025. “Metadata-Driven Retrieval-Augmented Generation for Financial Question Answering”. *arXiv preprint arXiv:2510.24402*, <https://arxiv.org/abs/2510.24402>.
- Dhuliawala, Shehzaad, Mojtaba Komeili, Jing Xu, Roberta Raileanu, Xian Li, Asli Celikyilmaz, dan Jason Weston. 2024. “Chain-of-Verification Reduces Hallucination in Large Language Models”. Dalam *Findings of the Association for Computational Linguistics: ACL 2024*. <https://aclanthology.org/2024.findings-acl.212>.

- Es, Kaan, Yifan Gao, dkk. 2024. “RAGAS: Retrieval-Augmented Generation Assessment System for Automated Evaluation of RAG Pipelines”. *arXiv preprint arXiv:2401.10285*, <https://arxiv.org/abs/2401.10285>.
- Gao, Yifan, dkk. 2023. “Automated Evaluation Frameworks for Retrieval-Augmented Generation”. Dalam *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP 2023)*. <https://aclanthology.org/2023.emnlp-main.104>.
- Gao, Yunfan, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang, dan Haofen Wang. 2023. “Retrieval-Augmented Generation for Large Language Models: A Survey”. *arXiv preprint arXiv:2312.10997*, <https://arxiv.org/abs/2312.10997>.
- Hendrycks, Dan, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song, dan Jacob Steinhardt. 2021. “Measuring Massive Multitask Language Understanding”. Dalam *International Conference on Learning Representations (ICLR)*. <https://arxiv.org/abs/2009.03300>.
- Holzenberger, Nils, Colin White, Shiyue Chen, Shayne Longpre, Yi Yang, dkk. 2023. “LegalBench: A Collaborative Benchmark for Legal Reasoning in AI”. *arXiv preprint arXiv:2308.11462*, <https://arxiv.org/abs/2308.11462>.
- Hotz, Nick. 2024. “CRISP-DM: The Data Mining Process Explained”. Accessed 24 November 2025. <https://www.datascience-pm.com/crisp-dm-2/>.
- Jin, Qiao, Bhuwan Dhingra, Zhengping Liu, William W. Cohen, dan Xinghua Lu. 2019. “PubMedQA: A Dataset for Biomedical Research Question Answering”. Dalam *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 2567–2577. Association for Computational Linguistics. <https://arxiv.org/abs/1909.06146>.
- Kovács, Ádám, dan Gábor Recski. 2025. “LettuceDetect: A Hallucination Detection Framework for RAG Applications”. *arXiv preprint arXiv:2502.17125*, <https://arxiv.org/abs/2502.17125>.
- Lewis, Patrick, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, dkk. 2020. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. *arXiv preprint arXiv:2005.11401*, <https://arxiv.org/abs/2005.11401>.

- Li, Wenhao, Yue Zhang, dan Xiaodong Ren. 2023. “MEGA-RAG: Multi-Evidence Aggregation for Robust Retrieval-Augmented Generation”. Dalam *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. <https://aclanthology.org/2023.emnlp-main.487>.
- Li, Xingxuan, Ruochen Zhao, Yew Ken Chia, Bosheng Ding, Shafiq Joty, Soujanya Poria, dan Lidong Bing. 2023. “Chain-of-Knowledge: Grounding Large Language Models via Dynamic Knowledge Adapting over Heterogeneous Sources”. *arXiv preprint arXiv:2305.13269*, <https://arxiv.org/abs/2305.13269>.
- Ma, Xinbei, Yeyun Gong, Pengcheng He, Hai Zhao, dan Nan Duan. 2023. “Query Rewriting for Retrieval-Augmented Large Language Models”. Dalam *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP 2023)*. <https://arxiv.org/abs/2305.14283>.
- Malo, Pekka, Ashutosh Sinha, Paavo Takala, Ari Korhonen, dan Jyrki Wallenius. 2013. “Financial PhraseBank: A Dataset for Sentiment Analysis of Financial Texts”. *arXiv preprint arXiv:1312.6683*, <https://arxiv.org/abs/1312.6683>.
- Manakul, Nontawat, Adian Liusie, dan Mark J. F. Gales. 2023. “SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models”. *arXiv preprint arXiv:2308.08826*, <https://arxiv.org/abs/2308.08826>.
- Mangla, Bhavik. 2025. “MDKeyChunker: Single-Call LLM Enrichment with Rolling Keys and Key-Based Restructuring for High-Accuracy RAG”. *arXiv preprint arXiv:2603.23533*, <https://arxiv.org/abs/2603.23533>.
- Minaee, Shervin, Yahya Azimi, Amir Abdolrashidi, dkk. 2024. “Large Language Models: A Survey”. *arXiv preprint arXiv:2402.04680*, <https://arxiv.org/abs/2402.04680>.
- Mishra, Pranav Pushkar, Kranti Prakash Yeole, Ramyashree Keshavamurthy, Mokshit Bharat Surana, dan Fatemeh Sarayloo. 2025. “A Systematic Framework for Enterprise Knowledge Retrieval: Leveraging LLM-Generated Metadata to Enhance RAG Systems”. *arXiv preprint arXiv:2512.05411*, <https://arxiv.org/abs/2512.05411>.

- Niu, Cheng, Yuanhao Wu, Juno Zhu, Siliang Xu, Kashun Shum, Randy Zhong, Juntong Song, dan Tong Zhang. 2025. “RAGTruth: A Hallucination Corpus for Developing Trustworthy Retrieval-Augmented Language Models”. *arXiv preprint arXiv:2502.17125*, <https://arxiv.org/abs/2502.17125>.
- Pal, Ankit, Logesh Kumar Umapathi, dan Rohit Sankepally. 2022. “MedMCQA: A Large-scale Multi-subject Multi-choice Dataset for Medical Domain Question Answering”. *arXiv preprint arXiv:2203.13391*, <https://arxiv.org/abs/2203.13391>.
- Pang, Bo, Hao Lin, Yixin Wang, dan Wei Zhao. 2024. “Hallucinations in Medical Large Language Models: Causes, Detection, and Mitigation”. *Nature Machine Intelligence* 6:1023–1037.
- Rabelo, J. J., M. Kim, dan R. Goebel. 2023. “Overview of the COLIEE 2023 Competition on Legal Information Extraction/Entailment”. Dalam *Proceedings of the 2023 Competition on Legal Information Extraction and Entailment (COLIEE)*.
- Reimers, Nils, dan Iryna Gurevych. 2019. “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”. Dalam *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 3982–3992. Association for Computational Linguistics.
- Sahoo, Prashant, Amarjeet Singh, dkk. 2024. “A Systematic Survey of Prompt Engineering in Large Language Models: Techniques and Applications”. *arXiv preprint arXiv:2402.07927*, <https://arxiv.org/abs/2402.07927>.
- Schwartz, Steven. 2023. “ChatGPT, Hallucinatory Legal Citations, and the Risks of AI in Law”. Dalam *New York Federal Court Proceedings*.
- Shuster, Kurt, Samuel Humeau, Hexiang Hu, Antoine Bordes, dan Jason Weston. 2021. “Retrieval Augmentation Reduces Hallucination in Conversation”. Dalam *Findings of the Association for Computational Linguistics: EMNLP 2021*. <https://aclanthology.org/2021.findings-emnlp.320>.
- Singhal, Kerrie, dkk. 2023. “Large Language Models Encode Clinical Knowledge but Hallucinate in Medical Advice”. *Nature*.
- Song, Mingyang, Mao Zhang, Yong Tan, dan Jing Wang. 2024. “RAGHat: Retrieval-Augmented Generation with Hallucination Adversarial Training”. *arXiv preprint arXiv:2410.06911*, <https://arxiv.org/abs/2410.06911>.

- Studer, Sebastian, Konstantin Böttinger, dkk. 2021. “Towards CRISP-ML(Q): A Comprehensive Framework for Quality-Assured Machine Learning Projects”. *Frontiers in Artificial Intelligence* 4:1–20. <https://doi.org/10.3389/frai.2021.705381>. <https://doi.org/10.3389/frai.2021.705381>.
- Tribunal, Vancouver Civil Resolution. 2024. *Court Ruling on Air Canada Chatbot Misinformation*. Civil Court Documents. Case regarding chatbot hallucination on refund policy.
- Varshney, Neeraj, Wenlin Yao, Hongming Zhang, Jianshu Chen, dan Dong Yu. 2023. “A Stitch in Time Saves Nine: Detecting and Mitigating Hallucinations of LLMs by Validating Low-Confidence Generation”. *arXiv preprint arXiv:2307.03987*, <https://arxiv.org/abs/2307.03987>.
- Wang, Shu, Qiang Li, Jing Zhao, dan Liyu Huang. 2024. “MaFeRw: Multi-Aspect Feedback Based Query Rewriting for Retrieval-Augmented Large Language Models”. *arXiv preprint arXiv:2408.17072*, <https://arxiv.org/abs/2408.17072>.
- Wang, Shuting, Xin Yu, Mang Wang, Weipeng Chen, Yutao Zhu, dan Zhicheng Dou. 2023. “Crafting Rich Responses for Multi-Faceted Queries in Retrieval-Augmented Generation”. *arXiv preprint arXiv:2406.12566*, <https://arxiv.org/abs/2406.12566>.
- Wirth, Rüdiger, dan Jochen Hipp. 2000. “CRISP-DM: Towards a Standard Process Model for Data Mining”. Dalam *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining (PKDD)*, 29–39.
- Yao, Shunyu, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, dan Yuan Cao. 2022. “ReAct: Synergizing Reasoning and Acting in Language Models”. *arXiv preprint arXiv:2210.03629*, <https://arxiv.org/abs/2210.03629>.
- Yu, Wenhao, Hongming Zhang, Xiaoman Pan, Kaixin Ma, Hongwei Wang, dan Dong Yu. 2024. “Chain-of-Note: Enhancing Robustness in Retrieval-Augmented Language Models”. Dalam *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. <https://aclanthology.org/2024.emnlp-main.813>.
- Zhang, Wan. 2024. “Hallucination Mitigation for Retrieval-Augmented Large Language Models: A Review”. *Mathematics* 13 (5): 856. <https://www.mdpi.com/2227-7390/13/5/856>.

- Zhao, Wayne Xin, Eric Wallace, Fuli Feng, Qiang Yang, dkk. 2023. “A Survey of Large Language Models”. *arXiv preprint arXiv:2303.18223*, <https://arxiv.org/abs/2303.18223>.
- Zheng, Chaojun, Neel Guha, Daniel Martin Katz, dan Martin Wang. 2021. “Case-HOLD: A Legal Case Benchmark for Long Context Understanding”. Dalam *Proceedings of the Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*. <https://arxiv.org/abs/2104.08671>.

LAMPIRAN A

PROMPT SISTEM

Lampiran ini memuat seluruh *prompt* yang dipakai pada implementasi sistem mitigasi halusinasi RAG-LLM. *Prompt* ditampilkan dalam format kode persis seperti yang diteruskan ke model bahasa, agar reproduksibilitas eksperimen tetap terjaga. Variabel substitusi ditulis dengan kurung kurawal (misalnya {context} dan {question}) sebagaimana konvensi *string formatting* Python.

A.1 Prompt Generation Jawaban Biomedis

Prompt berikut dipakai pada tahap *generation* untuk seluruh konfigurasi sistem (*baseline*, +QR, +CR, +QR+CR). *Prompt* dirancang agar LLM menjawab pertanyaan biomedis berbasis lima *chunk* konteks yang sudah dipilih oleh *retriever* dan mengakhiri jawaban dengan satu dari tiga label klasifikasi (*yes*, *no*, atau *maybe*) pada baris terakhir. Instruksi spesifik mengenai kapan memilih label *maybe* ditambahkan untuk mencegah model bersikap terlalu konservatif pada bukti yang sebenarnya cukup memadai untuk satu arah.

Listing A.1 Prompt generation jawaban biomedis (GENERATION_PROMPT)

```
1 You are a medical research assistant. Answer a biomedical
2 yes/no/maybe question based solely on the provided scientific
3 abstracts.
4
5 Context from medical literature:
6 {context}
7
8 Question: {question}
9
10 Instructions:
11 - Carefully read the context and assess whether it supports
12   or refutes the question.
13 - Provide a brief explanation (2-3 sentences) using ONLY the
14   information above.
15 - End your response with EXACTLY ONE of these words on its
16   own line: yes, no, or maybe.
```

```

17 - yes      : the evidence supports the hypothesis, even if not
18             perfectly conclusive
19 - no       : the evidence refutes or does not support the
20             hypothesis
21 - maybe    : ONLY if the evidence is directly contradictory
22             (some findings say yes, others say no), or if the
23             context contains no relevant information at all
24 - IMPORTANT: If the evidence leans in one direction, even
25             partially, choose yes or no. Do NOT use maybe simply
26             because the evidence is limited or not 100% certain.
27
28 Answer:

```

Variabel {context} pada *Listing A.1* diisi dengan lima *chunk* hasil *retrieval* yang sudah disusun secara berurutan dan diberi penanda nomor serta label *section* sumber paper. Format penyusunan konteks dilakukan oleh fungsi pembentuk konteks pada modul *generation*, sebagaimana ditunjukkan pada *Listing A.2*.

Listing A.2 Fungsi pembentuk {context} untuk diteruskan ke *prompt*

```

1 def generate_answer(kueri, retrieved):
2     context = "\n\n".join(
3         f"[{i}] ({r.document.section_label}): {r.document.text}"
4         for i, r in enumerate(retrieved, 1)
5     )
6     return openai_generate(
7         GENERATION_PROMPT.format(context=context, question=kueri),
8         max_tokens=300, temperature=TEMPERATURE
9     )

```

A.2 Prompt Query Rewriting

Prompt berikut dipakai pada modul *Query Rewriting* (QR) yang berjalan sebelum tahap *retrieval* pada konfigurasi +QR dan +QR+CR. Tugasnya sederhana, yaitu menulis ulang pertanyaan pengguna menjadi satu pertanyaan baru yang lebih spesifik dan lebih kaya istilah biomedis. *Prompt* ini berisi empat aturan utama, yaitu (1) membuat pertanyaan lebih spesifik dengan menambahkan istilah medis yang relevan, (2) mengekspansi akronim seperti MI menjadi *myocardial infarction*, (3) mempertahankan jenis pertanyaan agar tetap dapat dijawab dengan *yes*, *no*, atau *maybe*, serta (4) mengeluarkan hanya pertanyaan baru tanpa penjelasan tambahan.

Listing A.3 Prompt Query Rewriting dengan pendekatan *single-query rewriting*

```

1 You are a query rewriting assistant for a biomedical
2 question-answering system.

```

```

3 Rewrite the following medical question to improve retrieval
4 from a PubMed research database.
5
6 Rules:
7 1. Be more specific and add relevant medical/scientific
8   terminology.
9 2. Expand abbreviations (e.g. "MI" -> "myocardial infarction").
10 3. Preserve the original yes/no/maybe answerable intent.
11 4. Output ONLY the rewritten question, no explanations.
12
13 Original question: {kueri}
14
15 Rewritten question:

```

Keluaran LLM langsung dipakai sebagai kueri baru pada tahap *retrieval*, baik BM25 maupun *dense*. Apabila pertanyaan hasil tulis-ulang terlalu pendek (kurang dari 10 karakter) atau pemanggilan LLM gagal, sistem akan memakai pertanyaan asli sebagai *fallback* agar *pipeline* tetap berjalan tanpa harus menghentikan proses. *Listing A.4* memperlihatkan implementasi fungsi yang menjalankan pendekatan ini.

Listing A.4 Fungsi *rewriter single-kueri* (*rewrite_query*)

```

1 def rewrite_query(kueri: str) -> str:
2     """Reformulasi kueri menjadi satu pertanyaan baru yang
3     lebih spesifik dan kaya istilah biomedis."""
4     prompt = QUERY_REWRITE_PROMPT.format(kueri=kueri)
5     try:
6         rewritten = openai_generate(
7             prompt, max_tokens=150, temperature=0.3
8         )
9         rewritten = rewritten.strip().replace('\n', ' ')
10        return rewritten if len(rewritten) >= 10 else kueri
11    except Exception:
12        return kueri # fallback ke pertanyaan asli

```

A.3 Parameter Pemanggilan Model Bahasa

Seluruh pemanggilan model bahasa pada tahap *generation* dan *Query Rewriting* memakai parameter yang ditetapkan sama untuk seluruh konfigurasi agar perbandingan antarmodel bersifat *apple-to-apple*. Ringkasan parameter tersebut disajikan pada Tabel A.1.

Tabel A.1 Parameter Pemanggilan Model Bahasa pada Tahap *Generation* dan *Query Rewriting*

Parameter	Generation	Query Rewriting
<i>Temperature</i>	0,0	0,3
<i>Max tokens</i>	300	150
<i>Seed</i>	42	42

Penggunaan *temperature* 0,0 pada tahap *generation* menjamin determinisme jawaban sehingga eksperimen yang sama menghasilkan keluaran identik antar-pemanggilan. Untuk *Query Rewriting*, *temperature* dinaikkan menjadi 0,3 agar LLM dapat menghasilkan reformulasi yang lebih kaya istilah biomedis sambil tetap menjaga makna pertanyaan asli.

LAMPIRAN B

DATASET DAN KORPUS

Lampiran ini menjelaskan dataset PubMedQA yang dipakai sebagai sumber pertanyaan dan korpus dokumen pada tugas akhir ini, beserta versi korpus yang telah melalui tahap ekspansi akronim sebagai praproses.

B.1 Dataset PubMedQA

Dataset PubMedQA yang digunakan pada tugas akhir ini diunduh dari *HuggingFace* dengan identitas qiaojin/PubMedQA dan konfigurasi pqa_labeled. PubMedQA merupakan *dataset question answering* domain biomedis yang dibangun dari abstrak paper PubMed, di mana setiap entri terdiri dari pertanyaan penelitian (umumnya berasal dari judul artikel), konteks (abstrak tanpa bagian *conclusion*), jawaban panjang (bagian *conclusion* dari abstrak), serta jawaban klasifikasi singkat berupa label *yes*, *no*, atau *maybe*. Subset pqa_labeled berisi 1.000 paper berlabel *expert*, dengan 500 pertanyaan dipakai sebagai himpunan uji evaluasi pada tugas akhir ini. Ringkasan struktur entri PubMedQA disajikan pada Tabel B.1.

Tabel B.1 Contoh Entri Dataset PubMedQA (Subset pqa_labeled)

pubid	question	context	long_answer	labelled
26370095	Are financial incentives cost-effective to support smoking cessation during pregnancy?	To investigate the cost-effectiveness of financial incentives for smoking cessation in pregnancy as an adjunct to routine health care.	Financial incentives for smoking cessation in pregnancy are highly cost-effective, well below recommended decision thresholds.	yes
20684175	Does vitamin D supplementation increase regulatory T cells in healthy subjects?	Epidemiological data show significant associations of vitamin D deficiency and autoimmune diseases. Vitamin D may prevent autoimmunity by stimulating regulatory T cells.	Vitamin D supplementation was associated with significantly increased %Tregs in apparently healthy individuals.	yes
21880023	Does exercise during pregnancy prevent post-natal depression?	To study whether exercise during pregnancy reduces the risk of post-natal depression in a randomized controlled trial.	We did not find a lower prevalence of high depression scores among women randomized to regular exercise during pregnancy compared with the control group.	no
17076091	Does obstructive sleep apnea affect aerobic fitness?	We sought to determine whether patients with obstructive sleep apnea had an objective change in aerobic fitness compared to a normal population.	Overall, obstructive sleep apnea does not predict a decrease in aerobic fitness, but patients with severe apnea show a significant decrease.	maybe

Pada implementasi sistem, hanya kolom question dan context yang dimasukkan ke basis data *retriever*, sedangkan kolom long_answer dan final_decision disisihkan sebagai *ground truth* evaluasi agar tidak terjadi kebocoran jawaban (*answer leakage*) pada tahap *retrieval*.

B.2 Korpus dengan Ekspansi Akronim

Untuk mengatasi masalah *vocabulary mismatch* antara kueri pengguna yang sering memakai istilah panjang dengan dokumen biomedis yang banyak memuat akronim,

tugas akhir ini membangun versi korpus terpisah yang telah melalui tahap ekspansi akronim berbasis algoritma Schwartz-Hearst. Pada versi ini, setiap kemunculan akronim pada *chunk* dokumen disisipi kepanjangannya secara *inline* menggunakan format “AKRONIM (kepanjangan)” sehingga *chunk* tetap dapat dicocokkan baik melalui pencarian dengan akronim maupun istilah panjang. Contoh perbandingan teks *chunk* sebelum dan sesudah ekspansi diterapkan disajikan pada Tabel V.4 di Bab V.

Penerapan ekspansi akronim ini meningkatkan panjang rata-rata *chunk* dari sekitar 423 karakter menjadi 473 karakter, namun jumlah total *chunk* pada korpus tidak berubah karena substitusi bersifat *inline*. Kedua versi korpus, yaitu `pubmedqa_bm25.pkl` untuk versi asli dan `pubmedqa_bm25_sh.pkl` untuk versi dengan ekspansi akronim, disimpan secara terpisah pada repositori sistem sehingga dapat dipakai bergantian sesuai konfigurasi eksperimen.

LAMPIRAN C

EVALUASI LINTAS-MODEL


Lampiran ini memuat hasil evaluasi tambahan yang membandingkan kontribusi teknik mitigasi pada beberapa pilihan model bahasa, serta perbandingan kinerja antara model sumber terbuka lokal dengan model berbayar berskala besar. Hasil-hasil ini melengkapi analisis utama pada Bab VI yang difokuskan pada model GPT-4.1-mini.

C.1 Pengaruh QR, CR, dan QR+CR pada Berbagai Model

Evaluasi pada bagian ini mengukur kontribusi teknik *Query Rewriting* dan *Context Reranking* pada tiga model berukuran besar, yaitu GPT-4.1-mini, Claude Haiku 4.5, dan Llama 3.3 70B Instruct. Tabel C.1 menyajikan akurasi label pada keempat konfigurasi mitigasi untuk masing-masing model (mode *Hybrid*, tanpa ekspansi akronim untuk perbandingan setara dengan eksperimen lintas-model).

Tabel C.1 Pengaruh QR, CR, dan QR+CR pada Tiga Model (% , Mode *Hybrid*, Tanpa Ekspansi Akronim)

Konfigurasi	GPT-4.1-mini	Claude Haiku 4.5	Llama 3.3 70B
<i>Baseline</i>	69,2	65,4	69,4
+ QR	70,8	64,0	68,2
+ CR	69,8	68,0	70,8
+ QR + CR	70,0	64,8	71,0



Gambar C.1 Perbandingan akurasi label pada tiga model untuk empat konfigurasi mitigasi


Perbandingan akurasi ketiga model tersebut juga divisualisasikan pada Gambar C.1. Pola pengaruh teknik mitigasi terlihat berbeda untuk masing-masing model. Pada GPT-4.1-mini, kontribusi QR dan CR positif tetapi marginal (sekitar +0,6 sampai +1,6 poin terhadap *baseline*). Pada Claude Haiku 4.5, hanya CR yang memberikan peningkatan jelas (+2,6 poin), sedangkan QR justru menurunkan akurasi (−1,4 poin), kemungkinan karena Claude cenderung memberikan jawaban yang lebih hati-hati ketika kueri ditulis ulang dan lebih sering memilih label *maybe* daripada *yes/no*. Pada Llama 3.3 70B, kombinasi QR+CR memberikan peningkatan paling konsisten (+1,6 poin), dengan CR sendiri juga menyumbang +1,4 poin. Pola ini menunjukkan bahwa CR cenderung memberi peningkatan yang stabil di seluruh model, sedangkan QR sensitif terhadap karakteristik gaya jawaban masing-masing LLM.

C.2 Perbandingan Model *Open-Source* Lokal dengan Model Berbayar

Evaluasi pada bagian ini membandingkan kinerja antara model sumber terbuka Llama 3.2 3B yang dijalankan lokal melalui Ollama dengan tiga model berskala besar. Llama 3.2 3B dipilih sebagai representasi model gratis yang dapat dijalankan tanpa biaya API, sehingga relevan untuk skenario *deployment* dengan keterbatasan anggaran. Tabel C.2 dan Gambar C.2 menyajikan perbandingan akurasi label untuk empat model pada empat konfigurasi mitigasi.

Tabel C.2 Perbandingan Label Accuracy antara Llama 3.2 3B (Lokal) dan Tiga Model Berbayar (%)

Konfigurasi	Llama 3.2 3B	Claude Haiku 4.5	Llama 3.3 70B	GPT-4.1-mini
<i>Baseline</i>	55,0	65,4	69,4	69,2
+ QR	53,4	64,0	68,2	70,8
+ CR	55,2	68,0	70,8	69,8
+ QR + CR	55,0	64,8	71,0	70,0
Rata-rata	54,7	65,6	69,9	70,0



Gambar C.2 Perbandingan akurasi label antara Llama 3.2 3B (lokal) dengan tiga model berbayar berskala besar

Hasil pada Tabel C.2 menunjukkan kesenjangan kinerja yang signifikan antara Llama 3.2 3B dengan ketiga model berbayar, yaitu sekitar 11–15 poin persentase. Selisih ini secara konsisten berada di luar fluktuasi yang disebabkan oleh teknik mitigasi (QR atau CR), yang menandakan akar penyebabnya bukan pada arsitektur *pipeline* melainkan pada kapabilitas dasar model bahasa itu sendiri.

Penyebab utama selisih kinerja ini adalah **perbedaan skala parameter** antara keempat model. Llama 3.2 3B memiliki sekitar 3 miliar parameter, jauh lebih kecil dibandingkan Claude Haiku 4.5 dan GPT-4.1-mini yang diperkirakan memiliki puluhan miliar parameter, serta Llama 3.3 70B yang memiliki 70 miliar parameter (sekitar 23 kali lebih besar dari Llama 3.2 3B). Skala parameter berkorelasi erat dengan kemampuan model dalam menalar konteks panjang, menafsirkan istilah biomedis yang spesifik, dan menghasilkan kesimpulan klasifikasi yang konsisten dengan bukti pada konteks. Pada pertanyaan biomedis yang memerlukan inferensi multi-langkah (mengaitkan hasil eksperimen pada *RESULTS* dengan kesimpulan pada *CONCLUSIONS*), model kecil sering memilih label *maybe* sebagai pilihan

aman, atau memberikan klasifikasi yang tidak konsisten dengan arah temuan paper.


Selain itu, teknik mitigasi seperti QR justru sedikit menurunkan kinerja Llama 3.2 3B karena modul *rewriting* yang dijalankan oleh model yang sama belum mampu menghasilkan kueri yang benar-benar memperkaya istilah biomedis. Hal ini menegaskan bahwa kontribusi teknik mitigasi pada *pipeline* RAG tidak terlepas dari kapabilitas dasar LLM yang digunakan, dan ada batas bawah skala parameter di mana penambahan komponen mitigasi tidak cukup untuk mengkompensasi keterbatasan model. Untuk kasus penggunaan yang menuntut akurasi tinggi pada tanya jawab biomedis, model berskala minimal puluhan miliar parameter direkomendasikan, sedangkan Llama 3.2 3B lebih cocok untuk skenario *prototyping* atau pengujian fungsional tanpa target akurasi tinggi.

LAMPIRAN D

DEMONSTRASI GUARD RAIL PROTOTYPE

Lampiran ini melengkapi pembahasan prototipe pada Bab V, khususnya mekanisme *guard rail* keyakinan yang dijelaskan pada Subbab V.6.2. Tujuannya adalah memperlihatkan perilaku sistem ketika menerima pertanyaan yang berada di luar cakupan korpus PubMedQA.

Gambar D.1 menampilkan tangkapan layar prototipe ketika diberi pertanyaan umum yang tidak berkaitan dengan bukti ilmiah pada korpus, yaitu “*is it okay to take medicine without eat first?*”. Untuk pertanyaan tersebut, dokumen yang ditarik oleh tahap *retrieval* memiliki skor relevansi yang rendah, sehingga skor keyakinan komposit hanya bernilai 16% dan masuk ke kategori rendah.



Gambar D.1 Perilaku *guard rail* pada pertanyaan di luar cakupan korpus: skor keyakinan rendah (16%) sehingga pemanggilan LLM dilewati

Karena skor berada pada kategori rendah, sistem tidak meneruskan pertanyaan ke LLM, melainkan menampilkan penanda *Low confidence* beserta keterangan *LLM SKIPPED*, lalu mengembalikan pesan bahwa sistem tidak menemukan bukti yang cukup untuk memberikan jawaban terpercaya dan menyarankan pengguna berkonsultasi dengan tenaga medis. Perilaku ini menunjukkan bahwa *guard rail* berfungsi sebagai lapisan pengaman tambahan, yaitu menahan sistem dari memberikan jawaban yang berpotensi mengandung halusinasi ketika konteks pendukung tidak memadai.

LAMPIRAN E

CONTOH KELUARAN SISTEM PER KONFIGURASI

Lampiran ini memuat contoh keluaran sistem untuk lima pertanyaan yang sama pada seluruh dua belas konfigurasi. Kelima pertanyaan dipilih dari pertanyaan yang relatif dekat dengan kehidupan sehari-hari dan mencakup ketiga label jawaban, yaitu *yes*, *no*, dan *maybe*. Daftar kelima pertanyaan beserta label sebenarnya (*ground truth*) disajikan pada Tabel E.1, sedangkan keluaran tiap konfigurasi disajikan pada tabel-tabel berikutnya.

Tabel E.1 Lima Pertanyaan Contoh beserta Label Sebenarnya

Kode	Pertanyaan	Label Sebenarnya
Q1	<i>Does blood pressure change in treated hypertensive patients depending on whether it is measured by a physician or a nurse?</i>	<i>yes</i>
Q2	<i>Secondhand smoke risk in infants discharged from an NICU: potential for significant health disparities?</i>	<i>yes</i>
Q3	<i>Does music influence stress in mechanically ventilated patients?</i>	<i>no</i>
Q4	<i>Major depression and alcohol use disorder in adolescence: Does comorbidity lead to poorer outcomes of depression?</i>	<i>no</i>
Q5	<i>Does obstructive sleep apnea affect aerobic fitness?</i>	<i>maybe</i>

E.1 Kelompok 1: BM25 tanpa Ekspansi Akronim

Konfigurasi Baseline

Kode	GT	Prediksi	Jawaban LLM
Q1	<i>yes</i>	<i>yes</i>	The first abstract specifically addresses differences in blood pressure measurements between nurses, physicians, and self-measurement in treated hypertensive patients. It aims to determine whether such differences exist and their clinical importance, implying that differences in BP readings depending on the measurer are being investigated. This suggests that blood pressure may indeed change depending on whether it is measured by a physician or a nurse. <i>yes</i>
Q2	<i>yes</i>	<i>yes</i>	The first abstract indicates that secondhand smoke exposure (SHSe) is a threat to fragile infants discharged from a NICU and that factors such as socioeconomic status, race, and mental health status are hypothesized to be related to SHSe and household smoking bans. The third abstract further supports the presence of significant racial disparities in health outcomes, often linked to poverty, which suggests potential disparities in SHSe risk among infants. Together, these findings support the potential for significant health disparities related to secondhand smoke risk in NICU-discharged infants. <i>yes</i>
Q3	<i>no</i>	<i>yes</i>	The provided abstracts describe a study where mechanically ventilated patients were randomized to patient-directed music, headphones only, or usual care, with stress measured via urinary cortisol. This suggests an investigation into whether music influences stress in these patients. Although the results are not explicitly stated, the study's objective and methodology imply that music was considered as an intervention to reduce stress. <i>yes</i>

Kode	GT	Prediksi	Jawaban LLM
Q4	<i>no</i>	<i>yes</i>	The first abstract states that comorbid major depression (MD) and alcohol use disorder (AUD), particularly in adolescents, have been shown to be associated with poorer subsequent MD outcomes. This directly supports the idea that the comorbidity leads to worse depression outcomes. yes
Q5	<i>maybe</i>	<i>yes</i>	Abstract [1] specifically investigates whether patients with obstructive sleep apnea (OSA) have an objective change in aerobic fitness measured by VO2max during cycle ergometry compared to a normal population, implying a focus on the relationship between OSA and aerobic fitness. Abstract [3] notes that concomitant sleep apnea is associated with a significantly higher staple line leak rate, which suggests that OSA may have systemic effects, but does not directly address aerobic fitness. No other abstracts provide direct evidence on aerobic fitness in OSA patients. Therefore, based on the focus of abstract [1], there is support that OSA affects aerobic fitness. yes

Konfigurasi + Query Rewriting

Kode	GT	Prediksi	Jawaban LLM
Q1	<i>yes</i>	<i>yes</i>	The first abstract specifically aims to determine whether there are differences between blood pressure measured by a nurse and by a physician in treated hypertensive patients, implying that such differences are being investigated. Although the results are not detailed here, the focus on evaluating differences suggests that blood pressure readings may vary depending on who measures it. Therefore, the context supports the idea that blood pressure can change depending on whether it is measured by a physician or a nurse. <i>yes</i>
Q2	<i>yes</i>	<i>yes</i>	The first abstract indicates that secondhand smoke exposure (SHSe) is a threat to fragile infants discharged from a NICU and that factors such as socioeconomic status, race, and mental health status are hypothesized to be related to SHSe and household smoking bans. This suggests a potential for significant health disparities related to secondhand smoke risk in this population. <i>yes</i>
Q3	<i>no</i>	<i>yes</i>	The first abstract specifically explores the influence of music on stress in mechanically ventilated patients, indicating that this intervention was studied to ameliorate stress without adverse effects. Although the results are not detailed here, the fact that the study was conducted with this purpose suggests that music does influence stress in this patient population. <i>yes</i>
Q4	<i>no</i>	<i>yes</i>	The first abstract explicitly states that comorbid major depression and alcohol use disorder in adolescents are associated with poorer subsequent major depression outcomes. This directly supports the hypothesis that comorbidity leads to worse depression outcomes in this population. <i>yes</i>

Kode	GT	Prediksi	Jawaban LLM
Q5	<i>maybe</i>	<i>yes</i>	The first abstract specifically investigates whether patients with obstructive sleep apnea (OSA) have an objective change in aerobic fitness measured by VO2max during cycle ergometry compared to a normal population, implying a focus on the impact of OSA on aerobic fitness. Although the results are not explicitly stated, the objective suggests that OSA is considered to potentially affect aerobic fitness. Additionally, the third abstract notes that concomitant sleep apnea is associated with higher complication rates in surgery, indirectly supporting that OSA has physiological impacts. Therefore, the evidence leans toward OSA affecting aerobic fitness. <i>yes</i>

Konfigurasi + Context Reranking

Kode	GT	Prediksi	Jawaban LLM
Q1	<i>yes</i>	<i>yes</i>	Abstract [1] specifically aims to determine whether there are differences between blood pressure measured by the nurse (NBP), by the physician (PBP), and self-measured BP in treated hypertensive patients. This implies that differences in BP measurements depending on the measurer are being investigated, suggesting that such differences may exist. However, the abstract does not provide the results explicitly, but the objective itself indicates that BP may change depending on who measures it. <i>yes</i>

Kode	GT	Prediksi	Jawaban LLM
Q2	<i>yes</i>	<i>yes</i>	The provided abstracts indicate that secondhand smoke exposure (SHSe) is a concern for infants discharged from the NICU, particularly those at high respiratory risk. The study in Houston, Texas, examined smoking practices in families with very low birth weight infants and hypothesized that socioeconomic status, race, and mental health status are related to SHSe and household smoking bans, suggesting potential health disparities linked to SHSe in this population. <i>yes</i>
Q3	<i>no</i>	<i>yes</i>	The provided abstracts describe a study exploring the influence of music on stress in mechanically ventilated patients, including a randomized controlled trial where patient-directed music was compared to headphones only and usual care. The study collected urinary cortisol samples, a biomarker of stress, suggesting an investigation into whether music reduces stress. This indicates that music is considered to have an influence on stress in these patients. <i>yes</i>
Q4	<i>no</i>	<i>yes</i>	The first abstract explicitly states that comorbid major depression and alcohol use disorder in adolescents are associated with poorer subsequent major depression outcomes. This directly supports the hypothesis that comorbidity leads to worse depression outcomes in this population. <i>yes</i>
Q5	<i>maybe</i>	<i>yes</i>	The first abstract specifically investigates whether patients with obstructive sleep apnea (OSA) have an objective change in aerobic fitness measured by VO2max during cycle ergometry compared to a normal population, implying a relationship between OSA and aerobic fitness. Although the results are not detailed here, the focus on this comparison suggests that OSA does affect aerobic fitness. <i>yes</i>

Konfigurasi + Query Rewriting + Context Reranking

Kode	GT	Prediksi	Jawaban LLM
Q1	<i>yes</i>	<i>yes</i>	Abstract [1] specifically addresses differences in blood pressure measurements between nurses, physicians, and self-measurement in treated hypertensive patients. It implies that such differences exist and aims to evaluate their clinical importance, suggesting that blood pressure readings do change depending on who measures them. No other abstracts provide contradictory information. <i>yes</i>
Q2	<i>yes</i>	<i>yes</i>	The first abstract indicates that secondhand smoke exposure (SHSe) is a threat to fragile infants discharged from a NICU, and that factors such as socioeconomic status, race, and mental health status are hypothesized to be related to SHSe and household smoking bans. This suggests there is potential for significant health disparities related to SHSe in this vulnerable population. <i>yes</i>
Q3	<i>no</i>	<i>yes</i>	The first abstract indicates that mechanically ventilated patients experience profound stress and that interventions are needed to reduce this stress. The fifth abstract shows significant improvements in psychophysiological parameters related to stress regulation in an experimental group, which, given the context, likely involved music as the intervention. This suggests that music can influence stress in mechanically ventilated patients. <i>yes</i>
Q4	<i>no</i>	<i>yes</i>	The first abstract explicitly states that comorbid major depression (MD) and alcohol use disorder (AUD), particularly in adolescents, have been shown to be associated with poorer subsequent MD outcomes. This directly supports the idea that comorbidity leads to worse depression outcomes in adolescence. <i>yes</i>

Kode	GT	Prediksi	Jawaban LLM
Q5	<i>maybe</i>	<i>maybe</i>	Abstract [1] specifically investigates whether patients with obstructive sleep apnea (OSA) have an objective change in aerobic fitness measured by VO2max during cycle ergometry compared to a normal population, implying a focus on the relationship between OSA and aerobic fitness. However, the abstract does not provide the results or conclusions of this investigation. None of the other abstracts provide direct evidence about the effect of OSA on aerobic fitness. Therefore, based on the provided information, there is no conclusive evidence to confirm or refute that OSA affects aerobic fitness. <i>maybe</i>

E.2 Kelompok 2: Hybrid Retrieval tanpa Ekspansi Akronim

Konfigurasi Baseline

Kode	GT	Prediksi	Jawaban LLM
Q1	<i>yes</i>	<i>yes</i>	The provided results indicate a statistically significant difference in systolic blood pressure measurements between physicians and nurses, with physician-measured systolic BP being on average 5.16 mmHg higher than nurse-measured systolic BP. No significant differences were found in diastolic BP measurements. This supports that blood pressure readings can vary depending on whether a physician or nurse measures it in treated hypertensive patients. <i>yes</i>

Kode	GT	Prediksi	Jawaban LLM
Q2	<i>yes</i>	<i>yes</i>	The provided abstracts indicate that secondhand smoke exposure (SHSe) is a concern for fragile infants discharged from NICUs, particularly those born at very low birth weight or with high respiratory risk. Factors such as socioeconomic status, race, and mental health status are hypothesized to be related to SHSe and household smoking bans, suggesting potential health disparities in this population. <i>yes</i>
Q3	<i>no</i>	<i>yes</i>	The provided abstracts describe a randomized controlled trial where mechanically ventilated patients who listened to patient-directed music showed better control of psychophysiological stress parameters compared to controls. Significant improvements in stress regulation measures such as galvanic skin response and heart rate coherence were observed, indicating that music positively influences stress in these patients. <i>yes</i>
Q4	<i>no</i>	<i>yes</i>	The first abstract states that comorbid major depression and alcohol use disorder in adolescents are associated with poorer subsequent major depression outcomes. This directly supports the idea that comorbidity leads to worse depression outcomes in this population. <i>yes</i>
Q5	<i>maybe</i>	<i>yes</i>	The evidence indicates that obstructive sleep apnea (OSA) does affect aerobic fitness, as individuals with OSA had increased VO ₂ max compared to normalized data, but those with more severe OSA (apnea-hypopnea index >20) showed decreased VO ₂ max. This suggests that OSA severity influences aerobic fitness levels. <i>yes</i>

Konfigurasi + Query Rewriting

Kode	GT	Prediksi	Jawaban LLM
Q1	<i>yes</i>	<i>yes</i>	The first abstract specifically aims to determine whether there are differences between blood pressure measured by the nurse and by the physician in treated hypertensive patients, implying that such differences are being investigated. Although the results are not explicitly stated, the focus on evaluating differences suggests that blood pressure readings may vary depending on who measures it. <i>yes</i>
Q2	<i>yes</i>	<i>yes</i>	The first abstract indicates that secondhand smoke exposure (SHSe) is a threat to fragile infants discharged from a NICU and that factors such as socioeconomic status, race, and mental health may influence SHSe and household smoking bans. This suggests potential health disparities related to secondhand smoke risk in this vulnerable population. <i>yes</i>
Q3	<i>no</i>	<i>yes</i>	The first abstract indicates that mechanically ventilated patients experience profound stress and that interventions are needed to reduce this stress. Although the full results are not detailed, the study's purpose was to explore the influence of music on stress in these patients, implying that music was considered as a potential stress-reducing intervention. Additionally, the third abstract shows that participants in an experimental group could better regulate psychophysiological stress parameters, which may relate to interventions like music. Together, these suggest that music can influence stress in mechanically ventilated patients. <i>yes</i>

Kode	GT	Prediksi	Jawaban LLM
Q4	<i>no</i>	<i>yes</i>	The abstracts indicate that comorbid major depression (MD) and alcohol use disorder (AUD) in adolescence are associated with higher rates of adult MD compared to those with no disorder or AUD alone. Although after adjusting for confounders the difference between MD-only and MD/AUD groups was not statistically significant, the initial findings and background suggest poorer depression outcomes with comorbidity. Therefore, the evidence supports that comorbidity leads to poorer depression outcomes. <i>yes</i>
Q5	<i>maybe</i>	<i>yes</i>	The first abstract indicates that the study aimed to determine whether patients with obstructive sleep apnea (OSA) had an objective change in aerobic fitness measured by VO2max during cycle ergometry compared to a normal population. This implies that OSA may affect aerobic fitness, as the study was designed to assess this relationship. No abstracts provide evidence refuting this, so the context supports that OSA affects aerobic fitness. <i>yes</i>

Konfigurasi + Context Reranking

Kode	GT	Prediksi	Jawaban LLM
Q1	<i>yes</i>	<i>yes</i>	The provided data shows a statistically significant difference between physician-measured systolic blood pressure (PBP) and nurse-measured systolic blood pressure (NBP), with a mean difference of 5.16 mmHg ($p < 0.001$). This indicates that blood pressure readings do change depending on whether they are measured by a physician or a nurse in treated hypertensive patients. <i>yes</i>

Kode	GT	Prediksi	Jawaban LLM
Q2	<i>yes</i>	<i>yes</i>	The data indicate that 26% of families with high-risk infants in the NICU have a household smoker, with lower-income families and certain racial groups (African American and Caucasian) less likely to have smoking bans, suggesting disparities in secondhand smoke exposure risk. Additionally, maternal depression is higher in families without smoking bans, further highlighting potential health disparities related to socioeconomic and racial factors. <i>yes</i>
Q3	<i>no</i>	<i>no</i>	The study described randomized mechanically ventilated patients to patient-directed music, headphones only, or usual care and measured stress via urinary cortisol levels. The results showed no significant differences in cortisol among the groups, indicating that music did not influence stress as measured by this biomarker during ventilatory support. <i>no</i>
Q4	<i>no</i>	<i>yes</i>	The provided context [1] explicitly states that comorbid major depression (MD) and alcohol use disorder (AUD), particularly in adolescents, are associated with poorer subsequent MD outcomes. This directly supports the hypothesis that comorbidity leads to poorer depression outcomes in adolescence. <i>yes</i>

Kode	GT	Prediksi	Jawaban LLM
Q5	<i>maybe</i>	<i>yes</i>	The first abstract specifically investigates whether patients with obstructive sleep apnea (OSA) have an objective change in aerobic fitness measured by VO2max during cycle ergometry compared to a normal population. This implies that OSA is considered to potentially affect aerobic fitness, and the study aims to determine this effect. Although the results are not detailed here, the context suggests a recognized relationship between OSA and aerobic fitness. <i>yes</i>

Konfigurasi + Query Rewriting + Context Reranking

Kode	GT	Prediksi	Jawaban LLM
Q1	<i>yes</i>	<i>yes</i>	The data show a statistically significant difference between physician-measured systolic blood pressure and nurse-measured systolic blood pressure, with physician measurements being higher by about 5.16 mmHg ($p < 0.001$). No significant differences were found for diastolic blood pressure. This indicates that blood pressure readings do change depending on whether they are measured by a physician or a nurse in treated hypertensive patients. <i>yes</i>
Q2	<i>yes</i>	<i>yes</i>	The data indicate that secondhand smoke exposure (SHSe) is present in families with high-risk infants discharged from NICUs, with disparities linked to socioeconomic status, race, and maternal mental health. Lower-income families and certain racial groups (African American and Caucasian) are less likely to have smoking bans, suggesting significant health disparities in SHSe risk among these infants. <i>yes</i>

Kode	GT	Prediksi	Jawaban LLM
Q3	<i>no</i>	<i>yes</i>	The provided abstracts describe a randomized controlled trial where mechanically ventilated patients who listened to patient-directed music showed better regulation of psychophysiological stress parameters such as galvanic skin response and heart rate compared to controls. This suggests that music has a positive influence on stress in these patients. <i>yes</i>
Q4	<i>no</i>	<i>yes</i>	The first abstract states that comorbid major depression and alcohol use disorder in adolescents have been shown to be associated with poorer subsequent major depression outcomes. This directly supports the idea that comorbidity leads to worse depression outcomes in this population. <i>yes</i>
Q5	<i>maybe</i>	<i>maybe</i>	The provided abstracts do not directly address whether obstructive sleep apnea (OSA) affects aerobic fitness. Abstract [1] mentions a study aiming to determine if patients with OSA have an objective change in aerobic fitness measured by VO2max, but no results or conclusions are provided. Therefore, there is no direct evidence in the given context to support or refute the effect of OSA on aerobic fitness. <i>maybe</i>

E.3 Kelompok 3: Hybrid Retrieval dengan Ekspansi Akronim

Konfigurasi Baseline

Kode	GT	Prediksi	Jawaban LLM
Q1	<i>yes</i>	<i>yes</i>	The provided data shows a statistically significant difference between physician-measured systolic blood pressure (PBP) and nurse-measured systolic blood pressure (NBP), with physician measurements being on average 5.16 mmHg higher. This indicates that blood pressure readings do change depending on whether they are measured by a physician or a nurse in treated hypertensive patients. <i>yes</i>
Q2	<i>yes</i>	<i>yes</i>	The provided abstracts indicate that secondhand smoke exposure (SHSe) is a concern for infants discharged from NICUs, particularly those at high respiratory risk. Factors such as socioeconomic status, race, and mental health status are hypothesized to be related to SHSe and household smoking bans, suggesting potential health disparities in this population. Therefore, the evidence supports the potential for significant health disparities related to secondhand smoke risk in these infants. <i>yes</i>
Q3	<i>no</i>	<i>yes</i>	The provided abstracts indicate that music interventions were studied in mechanically ventilated patients, with one study showing that patient-directed music helped regulate psychophysiological stress parameters such as galvanic skin response and heart rate under stress conditions. This suggests that music can positively influence stress in these patients. <i>yes</i>

Kode	GT	Prediksi	Jawaban LLM
Q4	<i>no</i>	<i>yes</i>	The provided abstracts indicate that adolescents with comorbid major depression (MD) and alcohol use disorder (AUD) have higher rates of adult major depression compared to those with neither disorder or AUD alone. However, after adjusting for confounding factors such as gender, childhood behavior problems, and abuse exposure, the difference between comorbid and MD-only groups was no longer statistically significant. This suggests that while comorbidity is initially associated with poorer depression outcomes, this effect may be explained by other factors. <i>yes</i>
Q5	<i>maybe</i>	<i>yes</i>	The data indicate that individuals with obstructive sleep apnea (OSA) generally have increased VO2max compared to a normal population, suggesting better aerobic fitness. However, patients with more severe OSA (apnea-hypopnea index >20) show decreased VO2max, indicating reduced aerobic fitness. Therefore, OSA does affect aerobic fitness, with severity influencing the direction of the effect. <i>yes</i>

Konfigurasi + Query Rewriting

Kode	GT	Prediksi	Jawaban LLM
Q1	<i>yes</i>	<i>yes</i>	The provided data shows a statistically significant difference between physician-measured systolic blood pressure and nurse-measured systolic blood pressure in treated hypertensive patients, with physician measurements being on average about 5.16 mmHg higher. This indicates that blood pressure readings do change depending on whether they are measured by a physician or a nurse. <i>yes</i>

Kode	GT	Prediksi	Jawaban LLM
Q2	<i>yes</i>	<i>yes</i>	The provided abstracts indicate that secondhand smoke exposure (SHSe) is a concern for fragile infants discharged from the NICU, particularly those born at very low birth weight and with prolonged ventilation. The studies also suggest that socioeconomic status, race, and mental health status are hypothesized to be related to SHSe and household smoking bans, implying potential health disparities in this population. <i>yes</i>
Q3	<i>no</i>	<i>yes</i>	The provided abstracts describe a study where mechanically ventilated patients were randomized to patient-directed music, headphones only, or usual care, with stress measured by urinary cortisol and psychophysiological parameters. Results indicated that participants exposed to music were better able to control stress-related physiological responses compared to controls, suggesting that music has a beneficial influence on stress in these patients. <i>yes</i>
Q4	<i>no</i>	<i>yes</i>	The provided abstracts indicate that adolescents with comorbid major depression (MD) and alcohol use disorder (AUD) have higher rates of adult MD compared to those with AUD only, and marginally higher rates compared to those with MD only. Although after adjusting for confounders the difference between MD-only and comorbid groups was not statistically significant, the overall evidence suggests that comorbidity is associated with poorer depression outcomes. <i>yes</i>

Kode	GT	Prediksi	Jawaban LLM
Q5	<i>maybe</i>	<i>yes</i>	The provided abstracts indicate that individuals with obstructive sleep apnea (OSA) generally have increased VO2max compared to a normal population, suggesting better aerobic fitness. However, patients with more severe OSA (apnea-hypopnea index > 20) show decreased VO2max, indicating reduced aerobic fitness. Therefore, OSA does affect aerobic fitness, with severity playing a key role. <i>yes</i>

Konfigurasi + Context Reranking

Kode	GT	Prediksi	Jawaban LLM
Q1	<i>yes</i>	<i>yes</i>	The provided data show a statistically significant difference between physician-measured systolic blood pressure and nurse-measured systolic blood pressure in treated hypertensive patients, with physician measurements being higher by about 5.16 mmHg. No significant difference was found between nurse and self-measured systolic BP, and no significant differences were found for diastolic BP between measurement methods. This indicates that blood pressure readings do change depending on whether a physician or nurse measures it. <i>yes</i>
Q2	<i>yes</i>	<i>yes</i>	The data indicate that secondhand smoke exposure (SHSe) in families with high-risk infants discharged from the NICU is associated with socioeconomic status and race, with lower-income families and certain racial groups less likely to have household smoking bans. This suggests significant health disparities in SHSe risk among these infants. <i>yes</i>

Kode	GT	Prediksi	Jawaban LLM
Q3	<i>no</i>	<i>no</i>	The study described randomized mechanically ventilated patients to patient-directed music, headphones only, or usual care and measured urinary cortisol as a stress marker. The results showed no significant differences in urinary cortisol levels among the groups during ventilatory support, suggesting that music did not influence physiological stress as measured by cortisol in this setting. no
Q4	<i>no</i>	<i>yes</i>	The provided abstracts indicate that adolescents with comorbid major depression (MD) and alcohol use disorder (AUD) have higher rates of adult MD compared to those with neither disorder or AUD alone, suggesting poorer depression outcomes. However, after adjusting for confounding factors such as gender, childhood behavior problems, and abuse exposure, the difference between MD-only and comorbid groups was no longer statistically significant. This implies that while comorbidity is initially associated with poorer outcomes, this effect may be explained by other factors. yes
Q5	<i>maybe</i>	<i>yes</i>	The evidence indicates that obstructive sleep apnea (OSA) can affect aerobic fitness, as patients with OSA overall had increased VO2max compared to a normal population, but those with more severe OSA (apnea-hypopnea index >20) showed decreased VO2max. This suggests that OSA severity influences aerobic fitness levels. yes

Konfigurasi + Query Rewriting + Context Reranking

Kode	GT	Prediksi	Jawaban LLM
Q1	<i>yes</i>	<i>yes</i>	The provided data shows a statistically significant difference between physician-measured systolic blood pressure and nurse-measured systolic blood pressure in treated hypertensive patients, with physician measurements being on average about 5.16 mmHg higher. This indicates that blood pressure readings do change depending on whether they are measured by a physician or a nurse. <i>yes</i>
Q2	<i>yes</i>	<i>yes</i>	The provided abstracts indicate that secondhand smoke exposure (SHSe) is a concern for fragile infants discharged from the NICU, particularly those born at very low birth weight and with prolonged ventilation. The studies also suggest that socioeconomic status, race, and mental health status are hypothesized to be related to SHSe and household smoking bans, implying potential health disparities in this population. <i>yes</i>
Q3	<i>no</i>	<i>yes</i>	The provided abstracts describe a study where mechanically ventilated patients were randomized to patient-directed music, headphones only, or usual care, with stress measured by urinary cortisol and psychophysiological parameters. Results indicated that participants exposed to music were better able to control stress-related physiological responses compared to controls, suggesting that music has a beneficial influence on stress in these patients. <i>yes</i>

Kode	GT	Prediksi	Jawaban LLM
Q4	<i>no</i>	<i>yes</i>	The provided abstracts indicate that adolescents with comorbid major depression (MD) and alcohol use disorder (AUD) have higher rates of adult MD compared to those with AUD only, and marginally higher rates compared to those with MD only. Although after adjusting for confounders the difference between MD-only and comorbid groups was not statistically significant, the overall evidence suggests that comorbidity is associated with poorer depression outcomes. <i>yes</i>
Q5	<i>maybe</i>	<i>yes</i>	The provided abstracts indicate that individuals with obstructive sleep apnea (OSA) generally have increased VO2max compared to a normal population, suggesting better aerobic fitness. However, patients with more severe OSA (apnea-hypopnea index > 20) show decreased VO2max, indicating reduced aerobic fitness. Therefore, OSA does affect aerobic fitness, with severity playing a key role. <i>yes</i>

