

**PERANCANGAN SISTEM PENDUKUNG
KEPUTUSAN KLINIS BERBASIS AI UNTUK
PREDIKSI INTERAKSI OBAT DARI KELUHAN
PASIENT BERBAHASA INDONESIA**

Laporan Tugas Akhir

Oleh

**Yovanka Sandrina Maharaja
18222094**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
Mei 2026**

LEMBAR PENGESAHAN

PERANCANGAN SISTEM PENDUKUNG KEPUTUSAN KLINIS BERBASIS AI UNTUK PREDIKSI INTERAKSI OBAT DARI KELUHAN PASIEN BERBAHASA INDONESIA

Laporan Tugas Akhir

Oleh

Yovanka Sandrina Maharaja
18222094

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Laporan Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 21 Mei 2026

Pembimbing



Dr. Nur Ulfa Maulidevi, S.T., M.Sc.

NIP. 19760309200802010


PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenar-benarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan tugas akhir ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan laporan tugas akhir.
3. Isi laporan ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 21 Mei 2026



Yovanka Sandrina Maharaja

NIM: 18222094

PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan dokumen Tugas Akhir ini, saya menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu di dalam proses penulisan, seperti yang tercantum dalam tabel berikut.

No.	Jenis	Alat Bantu	Tingkat	Tempat
1	Memeriksa ejaan dan tata bahasa	Claude	Sedang	Seluruh bab (pengecekan kesalahan ejaan)
2	Pembuatan teks	Tidak ada	Tidak ada	Tidak ada
3	Pembuatan grafik, gambar, atau ilustrasi	Tidak ada	Tidak ada	Tidak ada
4	Pencarian informasi atau referensi	Google Gemini 3.0	Rendah	Bab II (pencarian sitasi terkait)
5	Penyusunan bahan diskusi	Claude	Sedang	Bab IV dan Bab V (diskusi pemilihan pendekatan implementasi)
6	Penyusunan kode program	Claude	Rendah	Bab V (perbaikan kesalahan pada kode (<i>debugging</i>))
7	Penyusunan formula atau perhitungan matematis	Tidak ada	Tidak ada	Tidak ada
8	Penyusunan konsep desain atau algoritma	Tidak ada	Tidak ada	Tidak ada
9	Penyusunan analisis data	Gemini 2.5 Flash	Tinggi	Bab V (Modul RAG memanfaatkan Gemini)
10	Penyusunan kesimpulan atau rekomendasi	Tidak ada	Tidak ada	Tidak ada

Bandung, 21 Mei 2026

A handwritten signature in black ink, appearing to read 'Yovanka' followed by a stylized surname.

Yovanka Sandrina Maharaja

NIM: 18222094

ABSTRAK

Perancangan Sistem Pendukung Keputusan Klinis Berbasis AI untuk Prediksi Interaksi Obat dari Keluhan Pasien Berbahasa Indonesia

oleh

Yovanka Sandrina Maharaja

18222094

Interaksi obat merupakan salah satu penyebab utama efek samping yang tidak diinginkan dalam praktik klinis. Di Indonesia, tenaga kesehatan masih menghadapi keterbatasan sistem pendukung keputusan klinis (*Clinical Decision Support System/CDSS*) yang mampu memproses keluhan pasien berbahasa Indonesia secara otomatis. Penelitian ini merancang dan mengimplementasikan sistem CDSS hibrida yang mengintegrasikan tiga modul utama, yaitu: (1) modul *Named Entity Recognition* (NER) berbasis IndoBERT dengan *Conditional Random Field* (CRF) untuk mengekstraksi entitas medis dari teks keluhan pasien berbahasa Indonesia, (2) modul prediksi *Drug-Drug Interaction* (DDI) berbasis arsitektur *Multi-type Feature Fusion Graph Neural Network* (MFFGNN) yang menggabungkan representasi SMILES melalui Bi-GRU, graf molekul melalui GIN, dan graf interaksi melalui *Fusion* GCN, serta (3) modul *Retrieval-Augmented Generation* (RAG) menggunakan FAISS dan Gemini 2.5 Flash/Flash-Lite untuk menghasilkan laporan klinis yang informatif dan transparan. Hasil evaluasi menunjukkan bahwa modul NER mencapai rata-rata *F1-score* sebesar 0,9961 pada validasi silang *5-fold*. Modul DDI memperoleh ROC-AUC sebesar 0,9539 pada dataset ChCh-Miner. Pada modul RAG, penggunaan basis pengetahuan berisi 592.122 dokumen berhasil menurunkan tingkat halusinasi konten dari 16,9% pada mode tanpa RAG menjadi 9,6% pada mode dengan RAG, atau mengalami reduksi sebesar 42,9%. Selain itu, sistem menghasilkan 365 sitasi sumber pada 78 dari 83 kasus *end-to-end* (94,0%) sedangkan mode tanpa RAG tidak menghasilkan sitasi sama sekali. Seluruh kebutuhan fungsional (F01–F04) berhasil dipenuhi. Dukungan terhadap 130 alias obat menghasilkan keandalan prediksi DDI sebesar 81,2% pada 96 pasangan obat dari 83 kasus uji. Pasangan obat yang tidak tersedia pada basis data ChCh-Miner ditangani secara konservatif melalui mekanisme *abstain*. Dari sisi non-fungsional, sistem mencapai rata-rata waktu respons sebesar 6,2 detik dan memenuhi target operasional di bawah 10 detik. Hasil penelitian menunjukkan bahwa pendekatan hibrida NER-DDI-RAG memiliki potensi sebagai CDSS yang mampu memproses keluhan pasien berbahasa Indonesia untuk menghasilkan prediksi interaksi obat beserta laporan klinis pendukung secara otomatis.

Kata kunci: CDSS, NER, DDI, MFFGNN, RAG, IndoBERT, Bahasa Indonesia.

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa karena atas rahmat dan karunia-Nya, penulis dapat menyelesaikan penulisan Laporan Tugas Akhir yang berjudul “Perancangan Sistem Pendukung Keputusan Klinis Berbasis AI untuk Prediksi Interaksi Obat dari Keluhan Pasien Berbahasa Indonesia”. Penyusunan Tugas Akhir ini dilakukan sebagai salah satu syarat untuk memperoleh gelar sarjana pada program Sarjana di Program Studi Sistem dan Teknologi Informasi, Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung.

Selama proses penyusunan, penulis memperoleh banyak bantuan, dukungan, bimbingan, serta doa dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis ingin menyampaikan rasa terima kasih yang sebesar-besarnya kepada:

1. Dr. Nur Ulfa Maulidevi, S.T., M.Sc., selaku dosen pembimbing yang senantiasa meluangkan waktu, memberikan arahan, bimbingan, dan masukan yang tidak ternilai selama proses penyusunan Tugas Akhir ini.
2. I Gusti Bagus Baskara Nugraha, S.T., M.T., Ph.D., selaku Ketua Program Studi Sistem dan Teknologi Informasi, Dr. Fetty Fitriyanti Lubis, S.T., M.T., selaku dosen wali penulis, beserta seluruh dosen pengajar Program Studi Sistem dan Teknologi Informasi yang senantiasa memberikan bimbingan, ilmu pengetahuan, dan dukungan kepada penulis selama menjalani masa perkuliahan.
3. Dra. Tioman Rismauli Tampubolon, Apt., selaku narasumber ahli yang telah meluangkan waktu, memberikan pandangan, serta membagikan pengetahuan dan pengalaman yang sangat membantu dalam proses penyusunan skripsi ini.
4. Kedua orang tua penulis, *Papa* Samsudin Maharaja dan *Mama* Rosa Linda Mardiyanty, serta saudara penulis, Yolanda, Gregory, dan George yang selalu menyertakan penulis dan selalu penulis sertakan dalam doa, senantiasa memberi arti kasih sayang melalui dukungan dalam setiap fase kehidupan penulis, dan menjadi tempat pulang paling nyaman bagi penulis.
5. Teman-teman seperjuangan penulis, Tamara, Shazya, Kayla, Hira, Vania, Monica, Aben, Adnan, Dabbir, Gonza, Bryan, Anella, Denise, Naomi, Wiga, teman-teman Lab Basis Data – Anin, Ricky, Clement, Dama, Jihan, dan teman-teman lain yang telah mewarnai perjalanan penulis selama masa perkuliahan dan membantu penulis bertumbuh melalui setiap cerita, pengalaman, dan kebersamaan yang dirasakan.

6. Teman-teman penulis sejak bersekolah, Devi, Theresia R., Angela, Theresia S., Lianata, dan teman-teman XATU ITB yang senantiasa memberikan dukungan serta menjadi tempat berbagi cerita dan pengalaman selama perjalanan penulis.
7. Ikatan Alumni Informatika ITB (IAIF ITB), yang melalui Beasiswa ALIF telah memberikan kepercayaan, dukungan, dan keringanan beban secara finansial kepada penulis selama masa perkuliahan sehingga penulis dapat menempuh pendidikan dan menyelesaikan Tugas Akhir ini dengan lancar.
8. Staf Tata Usaha STEI, terutama Pak Lili dan Pak Rian, yang telah membantu penulis dalam berbagai keperluan administrasi selama masa perkuliahan hingga proses penyelesaian Tugas Akhir ini.

Penulis menyadari bahwa Tugas Akhir ini masih memiliki kekurangan. Oleh karena itu, penulis terbuka terhadap kritik dan saran yang membangun demi perbaikan di masa mendatang. Besar harapan penulis Tugas Akhir ini dapat memberikan manfaat bagi pembaca dan berkontribusi bagi perkembangan ilmu pengetahuan.

Bandung, 21 Mei 2026

Penulis

Yovanka Sandrina Maharaja

DAFTAR ISI

LEMBAR PENGESAHAN	iii
PERNYATAAN ORISINALITAS	v
PERNYATAAN PENGGUNAAN AI	vii
ABSTRAK	ix
KATA PENGANTAR	xi
DAFTAR ISI	xiii
DAFTAR GAMBAR	xvii
DAFTAR TABEL	xix
DAFTAR ALGORITMA	xxi
DAFTAR <i>LISTING</i>	xxiii
DAFTAR SINGKATAN	xxv
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	4
I.3 Tujuan	5
I.4 Batasan Masalah	5
I.5 Metodologi	6
I.6 Sistematika Penulisan	7
II STUDI LITERATUR	9
II.1 Polifarmasi dan Interaksi Obat-Obat (<i>Drug-Drug Interaction/DDI</i>)	9
II.1.1 Polifarmasi dalam Praktek Medis	9
II.1.2 Interaksi Obat-Obat (<i>Drug-Drug Interaction/DDI</i>)	10
II.2 Sistem Pendukung Keputusan Klinis (<i>Clinical Decision Support System/CDSS</i>)	11
II.2.1 Definisi dan Fungsi Sistem Pendukung Keputusan Klinis (CDSS)	11
II.2.2 Tantangan dalam Sistem Pendukung Keputusan Klinis (CDSS)	12
II.3 Pemrosesan Bahasa Alami (NLP) dalam Kesehatan	13
II.3.1 Pemrosesan Bahasa Alami (<i>Natural Language Processing/NLP</i>)	13
II.3.2 <i>Biomedical Named Entity Recognition</i> (BioNER)	14
II.3.3 Korpus DDI Extraction 2013 dan Adaptasi Lintas-Bahasa	14
II.4 Model <i>Transformer</i>	15
II.4.1 Konsep Model <i>Transformer</i>	15
II.4.2 BERT (<i>Bidirectional Encoder Representations from Transformers</i>)	16
II.4.3 IndoBERT (<i>Indonesian Bidirectional Encoder Representations from Transformers</i>)	17
II.4.4 <i>Conditional Random Fields</i> (CRF)	17
II.5 <i>Graph-Based Deep Learning Model</i>	18
II.5.1 <i>Graph Neural Network</i> (GNN)	18

II.5.2	<i>Graph Convolutional Network (GCN)</i>	18
II.5.3	<i>Multi-type Feature Fusion based on Graph Neural Network (MFFGNN)</i>	19
II.6	Prediksi Interaksi Obat-Obat (DDI)	19
II.6.1	Pendekatan Konvensional dalam Prediksi Interaksi Obat-Obat (DDI)	19
II.6.2	Pendekatan <i>Machine Learning</i> dalam Prediksi Interaksi Obat-Obat (DDI)	20
II.7	<i>Retrieval-Augmented Generation (RAG)</i>	20
II.7.1	Konsep <i>Retrieval-Augmented Generation (RAG)</i>	20
II.7.2	<i>Retrieval-Augmented Generation</i> dalam Bidang Medis	21
II.8	Metrik Pengukuran	21
II.9	Penelitian Terdahulu	26
II.9.1	Perancangan <i>Clinical Decision Support System (CDSS)</i> untuk <i>Drug Drug Interaction (DDI)</i> pada <i>e-Prescription</i> (Perwirani dan Sari 2022)	26
II.9.2	Pengenalan Entitas Biomedis dalam Teks Konsultasi Kesehatan <i>Online</i> Berbahasa Indonesia Berbasis <i>Arsitektur Transformers</i> (Abdillah dkk. 2023)	27
II.9.3	<i>Multi-type Feature Fusion based on Graph Neural Network for Drug-Drug Interaction Prediction</i> (He, Liu, Li, dkk. 2022)	27
III	ANALISIS MASALAH	29
III.1	Analisis Kondisi Saat Ini	29
III.1.1	Pemrosesan Keluhan Pasien Berbahasa Indonesia	29
III.1.2	Prediksi Interaksi Obat-Obat Menggunakan AI	31
III.1.3	Ringkasan Permasalahan Saat Ini	33
III.2	Analisis Kebutuhan	34
III.2.1	Identifikasi Masalah Pengguna	34
III.2.2	Kebutuhan Fungsional	36
III.2.3	Kebutuhan Nonfungsional	36
III.3	Analisis Pemilihan Solusi	38
III.3.1	Alternatif Solusi	38
III.3.2	Analisis Penentuan Solusi	39
III.3.3	Komponen Sistem	41
IV	PERANCANGAN	45
IV.1	Komponen Perancangan Solusi	45
IV.1.1	Persiapan Data: Pembentukan Korpus Keluhan Pasien Bahasa Indonesia	45
IV.1.2	Modul 1: Ekstraksi Entitas Medis (NLP/NER)	47
IV.1.3	Modul 2: Prediksi Interaksi Obat dengan MFFGNN	49
IV.1.4	Modul 3: Laporan & Penjelasan (RAG)	51
IV.2	Perbandingan Sistem yang Ada dan Sistem yang Diusulkan	52
IV.2.1	Sistem Pendukung Keputusan Klinis Konvensional (<i>Rule-Based</i>)	53
IV.2.2	Sistem <i>CDSS Hybrid</i> Usulan Berbasis Kecerdasan Buatan	54

IV.2.3	Perbandingan Alur Kerja Sistem Konvensional dengan Sistem Usulan	55
IV.3	Diagram Sistem dan Alur Kerja	55
IV.3.1	Diagram Konteks	55
IV.3.2	Diagram Alur Proses Sistem	55
IV.3.3	Diagram Konseptual Arsitektur Sistem	56
V	IMPLEMENTASI	61
V.1	Lingkungan Pengembangan	62
V.2	Implementasi Modul NER	63
V.2.1	Persiapan Data NER	63
V.2.2	Arsitektur Model IndoBERT-CRF	64
V.2.3	Pelatihan Model NER	64
V.2.4	Inferensi NER dan Pasca-Pemrosesan	65
V.3	Resolusi Alias Nama Obat	67
V.3.1	Implementasi Kamus Alias	67
V.3.2	Mekanisme Resolusi dan Keterbatasan	68
V.4	Implementasi Modul DDI	69
V.4.1	Persiapan Data DDI	69
V.4.2	Arsitektur MFFGNN	69
V.4.3	Pelatihan Model DDI	71
V.5	Implementasi Modul RAG	72
V.5.1	Basis Pengetahuan dan Indeks FAISS	72
V.5.2	Mekanisme Retrieval	73
V.5.3	Generasi Laporan Klinis	73
V.6	Antarmuka API dan Web	76
VI	EVALUASI	79
VI.1	Evaluasi Modul NER	79
VI.1.1	Metrik Evaluasi	79
VI.1.2	Hasil Validasi Silang <i>K-Fold</i>	80
VI.1.3	Hasil Evaluasi pada Data Uji	80
VI.1.4	Analisis Kasus Tepi NER	81
VI.1.5	Evaluasi Penanganan Masukan Non-Medis	82
VI.2	Evaluasi Modul DDI	83
VI.2.1	Metrik Evaluasi	84
VI.2.2	Statistik <i>Dataset</i>	84
VI.2.3	Hasil Pelatihan dan Pengujian	85
VI.2.4	Analisis Keandalan Prediksi	86
VI.2.5	Evaluasi Resolusi Alias Nama Obat	86
VI.3	Evaluasi Modul RAG	88
VI.3.1	Metrik Evaluasi	88
VI.3.2	Evaluasi Laporan LLM	89
VI.3.3	Analisis Kualitatif Laporan LLM	90
VI.4	Evaluasi Perbandingan RAG dan Tanpa RAG	91
VI.4.1	Metodologi Pengecekan Halusinasi	91
VI.4.2	Hasil Perbandingan	92

VI.5	Evaluasi <i>End-to-End</i>	94
VI.5.1	Skenario Pengujian	95
VI.5.2	Hasil <i>End-to-End</i> untuk Kasus Representatif	96
VI.6	Evaluasi Kebutuhan Fungsional dan Non-Fungsional	98
VI.6.1	Evaluasi Kebutuhan Fungsional	98
VI.6.2	Evaluasi Kebutuhan Non-Fungsional	100
VI.7	Analisis Kesalahan per Modul	105
VII	PENUTUP	111
VII.1	Kesimpulan	111
VII.2	Saran	112
Lampiran A	Contoh Perbandingan Laporan RAG dan Tanpa RAG . .	123
A.1	Kasus 1: Interaksi Tinggi (Warfarin + Simvastatin)	123
A.1.1	Laporan dengan RAG	123
A.1.2	Laporan tanpa RAG	125
A.2	Kasus 5: Obat Tidak Dikenal di Basis Data (Omeprazole + Clopi- dogrel)	126
A.2.1	Laporan dengan RAG	126
A.2.2	Laporan tanpa RAG	126
A.3	Kasus 8: Input Non-Medis	127
A.3.1	Laporan dengan RAG	127
A.3.2	Laporan tanpa RAG	127
A.4	Contoh Keluaran Mode <i>Template Fallback</i>	127
Lampiran B	Daftar Kasus Uji <i>End-to-End</i>	131
Lampiran C	Konfigurasi <i>Hyperparameter</i> Pelatihan Model	145
C.1	Modul NER (IndoBERT-CRF)	145
C.2	Modul DDI (MFFGNN)	146
C.3	Modul RAG	148
Lampiran D	Daftar Alias Nama Obat dan Kata Henti Pasca- Pemrosesan NER	149
D.1	Kamus Alias Nama Obat	149
D.2	Kata Henti Pasca-Pemrosesan NER	154

DAFTAR GAMBAR

III.1	Model Konseptual Sistem MFFGNN (He, Liu, Li, dkk. 2022)	32
III.2	Model Konseptual Sistem CDSS RSUD Budi Rahayu Magelang (Perwirani dan Sari 2022)	33
IV.1	Contoh Entri Korpus Keluhan Pasien Bahasa Indonesia Hasil Persi- apan Data	48
IV.2	Contoh Keluaran Terstruktur dari Modul Ekstraksi Entitas Medis (NLP/NER)	49
IV.3	Contoh Keluaran Terstruktur dari Modul Prediksi Interaksi Obat dengan MFFGNN	51
IV.4	Contoh Keluaran Narasi Laporan dan Penjelasan Berbasis RAG	53
IV.5	Diagram Konteks Sistem CDSS <i>Hybrid</i>	57
IV.6	Diagram Alur Proses Sistem CDSS <i>Hybrid</i>	58
IV.7	Diagram Konseptual Arsitektur Sistem CDSS <i>Hybrid</i>	59
V.1	Alur Eksekusi <i>Pipeline</i> Implementasi Sistem CDSS <i>Hybrid</i>	61
V.2	Tampilan awal antarmuka web sistem CDSS	77
V.3	Hasil ekstraksi entitas (NER) dan prediksi interaksi obat (DDI)	78
V.4	Laporan klinis modul RAG beserta dokumen referensi	78

DAFTAR TABEL

III.1 Ringkasan Permasalahan Saat Ini	33
III.2 Identifikasi Masalah Pengguna	35
III.3 Kebutuhan Fungsional Sistem	36
III.4 Kebutuhan Nonfungsional Sistem	37
III.5 Analisis Penentuan Solusi	40
III.6 Komponen Sistem CDSS <i>Hybrid</i>	42
III.7 Ketertelusuran Kebutuhan ke Persoalan dan Komponen Sistem . . .	43
IV.1 Perbandingan Alur Kerja Sistem CDSS Konvensional dan CDSS <i>Hybrid</i>	56
V.1 Cuplikan Kamus Alias Nama Obat (DRUG_ALIASES, total 130 entri)	68
VI.1 Hasil Validasi Silang 5-Fold Model NER	80
VI.2 Hasil Evaluasi NER pada Data Uji per Jenis Entitas	81
VI.3 Hasil Pengujian Kasus Tepi Model NER	81
VI.4 Penanganan Masukan Non-Medis pada Setiap Tahap <i>Pipeline</i> . . .	83
VI.5 Statistik <i>Dataset</i> DDI (ChCh-Miner)	84
VI.6 Hasil Evaluasi Model DDI (MFFGNN) pada <i>Dataset</i> ChCh-Miner .	85
VI.7 Kondisi Keandalan Prediksi DDI	86
VI.8 Hasil Pengujian Resolusi Alias Nama Obat	87
VI.9 Hasil Evaluasi Laporan RAG dengan Gemini 2.5 Flash/Flash-Lite .	89
VI.10 Perbandingan Metrik Laporan dengan RAG dan Tanpa RAG pada 83 Kasus Uji	92
VI.11 Distribusi Isu Berdasarkan Tipe (<i>strict</i> vs <i>structural</i>)	92
VI.12 Hasil Evaluasi <i>End-to-End</i> pada 10 Kasus Representatif	96
VI.13 Ringkasan Evaluasi Kebutuhan Fungsional	100
VI.14 Waktu Respon per Tahap pada 10 Kasus <i>Micro-Benchmark</i> Terkurasi	102
VI.15 Ringkasan Evaluasi Kebutuhan Non-Fungsional	103
VI.16 Hasil Tinjauan Apoteker pada Sampel Kasus <i>Out-of-Scope</i>	108
B.1 Daftar 83 Kasus Uji <i>End-to-End</i> Sistem CDSS	131

C.1	Konfigurasi Hyperparameter Pelatihan Modul NER	146
C.2	Konfigurasi Hyperparameter Pelatihan Modul DDI	147
C.3	Konfigurasi Modul RAG	148
D.1	Kamus Alias Nama Obat (130 Entri)	149
D.2	Daftar Kata Henti Pasca-Pemrosesan NER	154

DAFTAR ALGORITMA

V.1	Inisialisasi arsitektur model IndoBERT–CRF untuk NER	65
V.2	Inisialisasi arsitektur <i>encoder</i> SMILES berbasis Bi-GRU dengan mekanisme atensi	70

DAFTAR *LISTING*

V.1	<i>System prompt</i> untuk modul generasi laporan klinis	74
V.2	<i>Template prompt</i> pengguna untuk modul generasi laporan klinis . .	75

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
ADR	<i>Adverse Drug Reaction</i>	Bab I
AI	<i>Artificial Intelligence</i>	Bab I
API	<i>Application Programming Interface</i>	Bab V
AUPR	<i>Area Under Precision–Recall Curve</i>	Bab I
BERT	<i>Bidirectional Encoder Representations from Transformers</i>	Bab I
Bi-GRU	<i>Bidirectional Gated Recurrent Unit</i>	Bab II
BiLSTM	<i>Bidirectional Long Short-Term Memory</i>	Bab II
BIO	<i>Begin–Inside–Outside</i> (skema anotasi)	Bab II
BioNER	<i>Biomedical Named Entity Recognition</i>	Bab II
CDSS	<i>Clinical Decision Support System</i>	Bab I
CNN	<i>Convolutional Neural Network</i>	Bab III
CORS	<i>Cross-Origin Resource Sharing</i>	Bab V
CRF	<i>Conditional Random Field</i>	Bab II
DDI	<i>Drug–Drug Interaction</i>	Bab I
DL	<i>Deep Learning</i>	Bab III
DNN	<i>Deep Neural Network</i>	Bab III
DSR	<i>Design Science Research</i>	Bab I
EHR	<i>Electronic Health Record</i>	Bab I
ERD	<i>Entity Relationship Diagram</i>	Bab II
FAISS	<i>Facebook AI Similarity Search</i>	Bab II
F1	<i>F1-score</i> (rata-rata harmonik <i>precision</i> dan <i>recall</i>)	Bab I
GCN	<i>Graph Convolutional Network</i>	Bab I
GIN	<i>Graph Isomorphism Network</i>	Bab II
GNN	<i>Graph Neural Network</i>	Bab I
GRU	<i>Gated Recurrent Unit</i>	Bab I
HKG	<i>Heterogeneous Knowledge Graph</i>	Bab III

Singkatan	Deskripsi	Pemakaian pertama kali
IndoBERT	<i>Indonesian Bidirectional Encoder Representations from Transformers</i>	Bab I
INN	<i>International Nonproprietary Name</i>	Bab II
LLM	<i>Large Language Model</i>	Bab I
MFFGNN	<i>Multi-type Feature Fusion Graph Neural Network</i>	Bab I
ML	<i>Machine Learning</i>	Bab III
MLM	<i>Masked Language Model</i>	Bab II
MLP	<i>Multi-Layer Perceptron</i>	Bab IV
NER	<i>Named Entity Recognition</i>	Bab I
NLG	<i>Natural Language Generation</i>	Bab II
NLP	<i>Natural Language Processing</i>	Bab I
NLU	<i>Natural Language Understanding</i>	Bab II
NMT	<i>Neural Machine Translation</i>	Bab II
NSP	<i>Next Sentence Prediction</i>	Bab II
RAG	<i>Retrieval-Augmented Generation</i>	Bab I
REST	<i>Representational State Transfer</i>	Bab V
RNN	<i>Recurrent Neural Network</i>	Bab I
ROC-AUC	<i>Receiver Operating Characteristic – Area Under Curve</i>	Bab I
SDLC	<i>System Development Life Cycle</i>	Bab II
SMILES	<i>Simplified Molecular Input Line Entry System</i>	Bab I
SPA	<i>Single-Page Application</i>	Bab V
UML	<i>Unified Modeling Language</i>	Bab II
USAN	<i>United States Adopted Names</i>	Bab V
XML	<i>Extensible Markup Language</i>	Bab V

BAB I

PENDAHULUAN

I.1 Latar Belakang

Sistem kesehatan modern di Indonesia menghadapi tantangan kompleks yang berkaitan dengan praktik polifarmasi, yaitu penggunaan beberapa jenis obat secara bersamaan oleh seorang pasien. Praktik ini sangat umum dijumpai, terutama pada pasien lanjut usia atau mereka yang mengelola beberapa penyakit kronis sekaligus seperti diabetes, hipertensi, dan penyakit jantung. Meskipun polifarmasi seringkali bermanfaat untuk menangani berbagai kondisi medis secara bersamaan, kombinasi obat-obatan dapat memicu interaksi obat-obat (*drug-drug interaction/DDI*) yang tidak terduga, mengurangi efektivitas terapi, dan bahkan menyebabkan efek samping berbahaya yang mengancam jiwa pasien (Varghese dkk. 2024).

Le Louët dan Pitts (2023) mengidentifikasi reaksi obat yang merugikan (*adverse drug reactions/ADRs*) sebagai salah satu penyebab utama morbiditas dan mortalitas pasien secara global. Di Indonesia, masalah ini semakin diperparah oleh beberapa faktor struktural. Pertama, sistem rujukan yang belum optimal menyebabkan pasien sering kali mendapatkan resep dari berbagai dokter yang berbeda tanpa koordinasi yang memadai (Herdaningsih 2016). Kedua, keterbatasan akses terhadap sistem informasi kesehatan yang terintegrasi menyulitkan tenaga kesehatan untuk melacak riwayat pengobatan pasien secara komprehensif (Herawati dkk. 2022). Ketiga, kurangnya kesadaran masyarakat tentang pentingnya melaporkan semua obat yang dikonsumsi, termasuk obat bebas, suplemen, dan produk herbal kepada tenaga kesehatan memperburuk risiko terjadinya interaksi obat yang tidak terdeteksi (Wangge dan Akbar 2016).

Interaksi obat-obat dapat terjadi melalui berbagai mekanisme farmakologis yang kompleks. Secara farmakokinetik, suatu obat dapat mempengaruhi absorpsi, distribusi, metabolisme, atau ekskresi obat lain. Misalnya, obat yang menghambat enzim sitokrom P450 (CYP450) di hati dapat meningkatkan konsentrasi plasma obat lain yang dimetabolisme oleh enzim yang sama, yang berpotensi menyebabkan tok-

sisitas (Deodhar dkk. 2020). Secara farmakodinamik, dua obat dengan efek farmakologis yang serupa dapat menghasilkan efek aditif atau sinergis yang berbahaya. Misalnya, kombinasi warfarin dengan obat lain atau suplemen yang memodifikasi koagulasi dapat secara signifikan meningkatkan risiko perdarahan (Crader, Johns, dan Arnold 2025). Metode konvensional dalam memprediksi DDI bergantung pada eksperimen *in vivo* dan *in vitro*. Namun, karena keterbatasan lingkungan, skala yang kecil, serta proses yang kompleks dan mahal, kemampuan untuk memprediksi DDI menjadi sangat terbatas. Oleh karena itu, diperlukan metode komputasional yang lebih efisien untuk melakukan prediksi DDI (He, Liu, Li, dkk. 2022).

Sistem Pendukung Keputusan Klinis (*Clinical Decision Support System/CDSS*) berbasis teknologi informasi telah menjadi solusi yang menjanjikan untuk mengatasi tantangan ini. CDSS adalah sistem yang menyediakan informasi atau rekomendasi spesifik kepada tenaga kesehatan untuk meningkatkan kualitas perawatan dan keselamatan pasien. Implementasi CDSS yang sukses telah terbukti mampu mengurangi kesalahan pengobatan, meningkatkan kepatuhan terhadap pedoman klinis, dan memperbaiki hasil klinis pasien (Sutton dkk. 2020). Namun, sebagian besar CDSS yang ada saat ini dirancang untuk berinteraksi dengan data terstruktur dari rekam medis elektronik (*Electronic Health Record/EHR*) dan kurang memiliki kemampuan untuk memproses data naratif yang tidak terstruktur, seperti keluhan pasien yang disampaikan dalam bahasa alami.

Di era kecerdasan buatan (*Artificial Intelligence/AI*), teknologi Pemrosesan Bahasa Alami (*Natural Language Processing/NLP*) telah membuka peluang transformatif untuk mengekstraksi informasi medis berharga dari teks naratif. Teknik NLP *Named Entity Recognition* (NER) memungkinkan sistem untuk secara otomatis mengidentifikasi dan mengklasifikasikan entitas medis seperti nama obat, gejala, dan kondisi penyakit dari teks yang tidak terstruktur (Liu dkk. 2024). Arsitektur *transformer*, yang diperkenalkan oleh Vaswani dkk. (2017) dalam makalah “*Attention Is All You Need*”, menggantikan penggunaan jaringan rekurensial (RNN) atau konvolusion-al dengan mekanisme *self-attention*. Mekanisme ini memungkinkan setiap token dalam kalimat untuk memperhatikan token lainnya secara paralel, meningkatkan efisiensi dalam menangkap hubungan jangka panjang antar kata, yang membuat model seperti BERT sangat relevan untuk tugas-tugas NLP yang kompleks dan data tidak terstruktur.

BERT, yang dilatih secara *bidirectional*, memiliki kemampuan untuk memahami konteks kalimat secara menyeluruh, yang memungkinkan peningkatan kinerja

dalam pengenalan entitas medis dan pemrosesan teks medis (Gardazi 2025). Kemajuan ini berlanjut dengan pengembangan model serupa seperti IndoBERT, yang merupakan versi BERT yang dipra-latih khusus untuk bahasa Indonesia. Dengan melatih IndoBERT menggunakan sejumlah besar teks bahasa Indonesia, model ini dioptimalkan untuk memahami konteks linguistik lokal, sehingga sistem lebih efektif dalam menangani teks medis dalam bahasa Indonesia (Istiqomah dan Novika 2025).

Namun, penerapan teknologi NLP dalam bidang kesehatan Indonesia menghadapi tantangan tersendiri dibandingkan dengan negara lain. Penelitian NER untuk Bahasa Indonesia masih sangat terbatas dan terkendala oleh ketidaktersediaan korpus data yang sudah terannotasi. Penelitian sebelumnya menunjukkan bahwa performa model NER Bahasa Indonesia masih jauh tertinggal dibandingkan model untuk bahasa Inggris, terutama karena kelangkaan dataset berukuran besar dan berkualitas tinggi (Alfina, Manurung, dan Fanany 2016). Di bidang biomedis, ketiadaan korpus teks medis berbahasa Indonesia yang terannotasi semakin memperburuk situasi (Qorib dan Adriani 2018). Tanpa korpus yang memadai, model NLP sulit mencapai performa optimal, sehingga banyak peneliti dan pengembang enggan berinvestasi dalam proyek NLP kesehatan berbahasa Indonesia.

Lebih lanjut, prediksi interaksi obat (DDI) adalah tugas komputasional yang kompleks yang membutuhkan integrasi berbagai jenis data. Metode *machine learning* untuk prediksi DDI telah berkembang dari pendekatan berbasis aturan ke model *deep learning* yang lebih canggih. Model MFFGNN (*Multi-type Feature Fusion Graph Neural Network*) yang dikembangkan oleh He, Liu, Li, dkk. (2022) menunjukkan peningkatan signifikan dalam prediksi interaksi obat dengan menggabungkan tiga representasi data obat. Urutan SMILES (*Simplified Molecular Input Line Entry System*) diproses menggunakan *Bidirectional Gated Recurrent Unit* (Bi-GRU), graf molekul diproses menggunakan *Graph Isomorphism Network* (GIN) dan *Graph Wavelet Unitary* (GWU), sedangkan jaringan interaksi DDI antarobat diproses menggunakan *Graph Convolutional Network* (GCN). Ketiga representasi tersebut difusi melalui modul atensi sehingga model memperoleh konteks kimia lokal sekaligus relasi global antarobat, dan MFFGNN terbukti mengungguli model *state-of-the-art* DDI sebelumnya pada beberapa dataset *benchmark* (He, Liu, Li, dkk. 2022).

Namun, tantangan utama dalam penerapan model AI di bidang kesehatan bukan hanya akurasi teknis, tetapi juga kepercayaan dan transparansi. Model AI sering kali dianggap sebagai "kotak hitam" yang menghasilkan prediksi tanpa penjelasan yang

memadai, yang menghambat adopsi oleh profesional kesehatan (Quinn dkk. 2021). Untuk mengatasi masalah ini, dipilih pendekatan *Retrieval-Augmented Generation* (RAG) yang menggabungkan kekuatan model LLM (*Large Language Model*) dengan basis pengetahuan eksternal yang terpercaya. Pendekatan ini memungkinkan sistem untuk menghasilkan jawaban sistem yang faktual, transparan, dan dapat dipertanggungjawabkan (Ravi dan Sindhgatta 2025).

Di Indonesia, kebutuhan akan sistem penunjang keputusan klinis berbasis AI yang dapat memproses keluhan pasien berbahasa Indonesia menjadi semakin penting. Penelitian menunjukkan bahwa literasi kesehatan digital masyarakat Indonesia berada pada tingkat kecil hingga sedang, yang bisa membatasi akses dan kualitas layanan kesehatan digital (Algifari dkk. 2024). Selain itu, dalam praktik pelayanan kesehatan, keluhan pasien sering kali terekam sebagai teks bebas atau narasi informal yang memerlukan pengolahan teks lanjutan (Ratnasari, Kusumadewi, dan Rosita 2015). Dengan demikian, sistem yang mampu memahami dan menganalisis keluhan berbahasa Indonesia berpotensi memberikan dampak besar terhadap peningkatan aksesibilitas layanan kesehatan dan keselamatan pasien di seluruh Indonesia.

Berdasarkan latar belakang di atas, penelitian ini mengusulkan pengembangan sistem pendukung keputusan klinis berbasis AI yang dirancang khusus untuk menganalisis keluhan pasien berbahasa Indonesia dan memprediksi potensi interaksi obat berbahaya dengan memberikan laporan klinis yang transparan dan dapat dipahami. Sistem ini akan mengintegrasikan tiga komponen utama: (1) penggunaan *transformer* untuk ekstraksi entitas medis dari teks tidak terstruktur, (2) modul prediksi DDI multimodal yang menggabungkan fitur tekstual dan struktural, dan (3) modul RAG untuk menghasilkan laporan klinis yang naratif, transparan, dan dapat dipahami. Lebih penting lagi, penelitian ini diharapkan dapat berkontribusi pada pembentukan korpus anotasi teks biomedis berbahasa Indonesia sebagai fondasi untuk penelitian NLP kesehatan di masa depan.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, penelitian ini berupaya menjawab beberapa pertanyaan penelitian sebagai berikut:

1. Bagaimana cara membangun korpus anotasi teks biomedis berbahasa Indonesia yang berkualitas tinggi untuk tugas *Named Entity Recognition* (NER) dalam bidang kesehatan, mengingat keterbatasan sumber daya dan keahlian yang tersedia?
2. Bagaimana merancang dan mengimplementasikan model *transformer* yang

mampu mengekstraksi entitas medis dari teks keluhan pasien berbahasa Indonesia yang tidak terstruktur dengan tingkat akurasi yang memadai untuk aplikasi klinis?

3. Bagaimana mengintegrasikan fitur tekstual dari keluhan pasien dan fitur struktural molekul obat untuk membangun model prediksi interaksi obat-obat (DDI) multimodal dalam meningkatkan akurasi prediksi?
4. Bagaimana menerapkan pendekatan *Retrieval-Augmented Generation* (RAG) untuk menghasilkan laporan klinis yang naratif, faktual, transparan, dan tidak hanya menyajikan prediksi efek samping tetapi juga menjelaskan dasar klinis dari prediksi tersebut dengan merujuk pada basis pengetahuan medis yang terpercaya?

I.3 Tujuan

Penelitian ini bertujuan untuk mengembangkan sistem pendukung keputusan klinis berbasis kecerdasan buatan yang mampu menganalisis keluhan pasien berbahasa Indonesia yang tidak terstruktur untuk mendeteksi potensi interaksi obat-obat (DDI) berbahaya dan menghasilkan rekomendasi klinis yang transparan, akurat, dan dapat dipahami oleh profesional medis, yang akan diselesaikan dengan:

1. Membangun korpus anotasi teks biomedis berbahasa Indonesia untuk tugas *Named Entity Recognition* (NER).
2. Mengembangkan dan melatih model *transformer* untuk mengekstraksi entitas medis dari teks keluhan pasien.
3. Merancang model prediksi interaksi obat-obat (DDI) multimodal dengan menggabungkan fitur tekstual dan struktural.
4. Mengintegrasikan pendekatan *Retrieval-Augmented Generation* (RAG) untuk menghasilkan laporan klinis naratif yang faktual dan dapat dipertanggung-jawabkan.

I.4 Batasan Masalah

Untuk memastikan fokus dan kedalaman penelitian, beberapa batasan masalah ditetapkan sebagai berikut:

1. Penelitian ini memproses teks keluhan pasien dalam Bahasa Indonesia ragam baku maupun cakapan umum, yang terbatas pada ekstraksi entitas nama obat, gejala, dan penyakit. Sistem tidak mencakup ekstraksi entitas lain (seperti prosedur atau perangkat medis) dan tidak menangani penggunaan bahasa daerah.
2. Entitas obat yang diproses diasumsikan sebagai nama generik baku yang sesuai dengan basis data (misalnya DrugBank). Sistem tidak menangani nor-

malisasi variasi penulisan nama dagang (*brand*), singkatan obat non-standar, atau koreksi kesalahan penulisan (*typo*) dari pengguna.

3. Fokus penelitian ini hanya pada penggunaan model *transformer* untuk ekstraksi entitas medis dari teks keluhan pasien dan tidak mencakup teknik NLP lainnya.
4. Model prediksi interaksi obat-obat (DDI) yang dikembangkan hanya akan menggabungkan fitur tekstual dari keluhan pasien dan fitur struktural molekul obat, tanpa mempertimbangkan faktor eksternal lain seperti data genetika atau faktor lingkungan.
5. Sistem ini dirancang sebagai alat pendukung keputusan, bukan pengganti penilaian klinis profesional. Sistem tidak akan memberikan diagnosis medis atau rekomendasi pengobatan definitif, tetapi akan memberikan informasi dan peringatan yang dapat membantu profesional kesehatan dan pasien dalam membuat keputusan yang lebih akurat.

I.5 Metodologi

Penelitian ini mengadopsi metodologi *Design Science Research* (DSR) yang sesuai untuk pengembangan artefak teknologi informasi di bidang kesehatan, sebagaimana diuraikan oleh Peffers dkk. (2007), yang melibatkan beberapa tahap sistematis dan terstruktur dalam pengembangan artefak. Penelitian akan dilaksanakan dalam beberapa tahap yang sistematis dan terstruktur, yaitu:

1. Tahapan Identifikasi Masalah

Pada tahap ini, masalah yang perlu dipecahkan melalui pengembangan sistem akan diidentifikasi secara jelas. Hal ini melibatkan pemahaman tentang tantangan yang dihadapi dalam penerapan teknologi AI di bidang kesehatan, khususnya dalam menganalisis keluhan pasien berbahasa Indonesia dan memprediksi interaksi obat berbahaya. Langkah ini mencakup studi literatur terkait NLP untuk keluhan pasien, prediksi DDI, dan sistem pendukung keputusan klinis.

2. Tahap Pengembangan Artefak (Desain dan Pembuatan Sistem)

- a. Pengumpulan dan pembentukan korpus anotasi dengan mengumpulkan teks keluhan pasien yang disimulasikan dan mengembangkan pedoman anotasi yang jelas untuk entitas medis (nama obat, gejala, kondisi medis). Korpus ini akan menjadi dasar untuk pelatihan model NLP.
- b. Mendesain sistem AI yang akan digunakan untuk ekstraksi entitas medis, prediksi interaksi obat-obat (DDI), dan generasi laporan klinis. Desain ini mencakup pemilihan *transformer* untuk ekstraksi entitas dan penggunaan MFFGNN untuk prediksi DDI dengan menggabungkan fitur tekstu-

al dan struktural.

3. Tahap Pengembangan dan Implementasi

- a. Pengembangan Modul NER (*Named Entity Recognition*): Mengembangkan model untuk mengekstraksi entitas medis dari teks keluhan pasien berbahasa Indonesia menggunakan *transformer*.
- b. Pengembangan Modul Prediksi DDI: Implementasi model MFFGNN untuk memprediksi interaksi obat-obat menggunakan data obat dalam format SMILES dan data interaksi obat. Data keluhan pasien juga digunakan untuk mendukung prediksi interaksi ini.
- c. Pengembangan Modul *Retrieval-Augmented Generation* (RAG): Menerapkan sistem RAG untuk menghasilkan laporan klinis yang transparan dan dapat dipahami dengan mengintegrasikan informasi dari basis pengetahuan eksternal yang terpercaya.

4. Tahap Evaluasi dan Pengujian

- a. Evaluasi Model NLP: Mengukur akurasi model dalam ekstraksi entitas medis menggunakan metrik seperti *precision*, *recall*, *F1-score* untuk setiap entitas medis yang diekstraksi.
- b. Evaluasi Prediksi DDI: Menggunakan metrik ROC-AUC, AUPR, *precision@k*, dan *recall@k* untuk mengevaluasi akurasi prediksi interaksi obat.
- c. Evaluasi Modul RAG: Menilai kualitas laporan klinis yang dihasilkan oleh sistem RAG dengan mengukur transparansi dan keterbacaan laporan berdasarkan kriteria klinis yang relevan.

I.6 Sistematika Penulisan

Laporan tugas akhir ini disusun secara sistematis untuk memberikan gambaran menyeluruh mengenai proses perancangan, pengembangan, dan evaluasi sistem pendukung keputusan klinis berbasis NER, DDI, dan RAG. Sistematika penulisan ini bertujuan untuk memudahkan pembaca dalam memahami struktur dan alur pembahasan laporan. Adapun gambaran umum isi setiap bab adalah sebagai berikut.

1. **Bab I Pendahuluan** berisi latar belakang permasalahan interaksi obat dan kebutuhan akan sistem pendukung keputusan klinis berbahasa Indonesia, rumusan masalah, tujuan penelitian, batasan masalah, metodologi yang digunakan, serta sistematika penulisan laporan tugas akhir.
2. **Bab II Studi Literatur** berisi kajian pustaka yang relevan dengan topik tugas akhir, mencakup konsep interaksi obat-obat, model bahasa berbasis *transformer* (IndoBERT dan BERT), *Conditional Random Field* (CRF), arsitek-

tur *Multi-type Feature Fusion Graph Neural Network* (MFFGNN), serta pendekatan *Retrieval-Augmented Generation* (RAG) yang mendasari pengembangan sistem.

3. **Bab III Analisis Masalah** berisi analisis terhadap permasalahan yang dihadapi, kebutuhan pengguna (fungsional dan non-fungsional), serta pembahasan alternatif solusi yang dipertimbangkan dalam pengembangan sistem.
4. **Bab IV Perancangan** berisi penjelasan rancangan sistem yang diusulkan, meliputi arsitektur *pipeline* CDSS hibrida, rancangan modul NER, modul DDI, modul RAG, basis pengetahuan FAISS, serta rancangan antarmuka pengguna.
5. **Bab V Implementasi** berisi penjelasan proses implementasi sistem, mencakup pembangunan korpus anotasi NER berbahasa Indonesia, pelatihan model IndoBERT-CRF, implementasi model MFFGNN, integrasi basis pengetahuan FAISS dengan *Large Language Model* Gemini 2.5, serta pengembangan antarmuka pengguna.
6. **Bab VI Evaluasi** berisi pemaparan metodologi pengujian, persiapan kasus uji, serta hasil evaluasi tiap modul (NER, DDI, dan RAG), evaluasi *end-to-end*, perbandingan mode RAG dan tanpa RAG, evaluasi pemenuhan kebutuhan fungsional dan non-fungsional, dan analisis kesalahan.
7. **Bab VII Penutup** berisi kesimpulan dari pelaksanaan tugas akhir berdasarkan hasil evaluasi serta saran untuk pengembangan sistem pada penelitian selanjutnya.
8. **Daftar Pustaka** berisi daftar referensi yang digunakan dalam penyusunan laporan tugas akhir.
9. **Lampiran** berisi dokumen-dokumen pendukung, antara lain contoh perbandingan laporan RAG dan tanpa RAG, daftar kasus uji *end-to-end*, konfigurasi *hyperparameter* pelatihan model, serta daftar alias nama obat dan kata henti pasca-pemrosesan NER.

BAB II

STUDI LITERATUR

II.1 Polifarmasi dan Interaksi Obat-Obat (*Drug-Drug Interaction/DDI*)

II.1.1 Polifarmasi dalam Praktek Medis

Polifarmasi merujuk pada penggunaan lima atau lebih obat secara bersamaan dalam pengobatan seorang pasien. Praktik ini sering kali ditemui pada pasien lanjut usia atau individu yang menderita beberapa penyakit kronis, seperti diabetes, hipertensi, dan penyakit jantung, yang memerlukan pengobatan dengan berbagai obat. Meskipun polifarmasi dapat bermanfaat untuk menangani berbagai kondisi medis secara bersamaan, praktik ini juga membawa risiko yang signifikan terkait dengan terjadinya interaksi obat dan efek samping yang merugikan (Varghese dkk. 2024). Penelitian oleh Masnoon dkk. (2017) menunjukkan bahwa penggunaan lebih dari lima obat dapat menyebabkan dampak buruk, termasuk penurunan kesehatan, kelemahan, kecacatan, dan bahkan kematian, terutama pada pasien lanjut usia. Risiko yang ditimbulkan oleh polifarmasi semakin meningkat dengan semakin banyaknya obat yang digunakan, terutama pada pasien lanjut usia yang memiliki sistem tubuh yang lebih rentan terhadap efek negatif obat-obatan. Penurunan fungsi fisiologis terkait usia, seperti penurunan fungsi ginjal dan hati, penurunan massa tubuh tanpa lemak, serta penurunan kemampuan pendengaran, penglihatan, kognisi, dan mobilitas, membuat pasien lansia lebih rentan terhadap dampak buruk obat.

Polifarmasi sendiri dapat dibagi menjadi dua kategori, yaitu polifarmasi yang tepat dan polifarmasi yang tidak tepat. Polifarmasi yang tepat terjadi ketika semua obat yang diresepkan digunakan untuk mencapai tujuan terapeutik yang spesifik, dan terapi obat telah dioptimalkan untuk mencegah terjadinya ADR. Dalam hal ini, penggunaan lebih dari satu obat diperlukan untuk mengelola kondisi medis yang kompleks dengan cara yang lebih efektif, dengan setiap obat memberikan kontribusi pada tujuan pengobatan yang jelas. Sebaliknya, polifarmasi yang tidak tepat terjadi ketika satu atau lebih obat diberikan tidak lagi dibutuhkan karena tidak ada indikasi klinis yang jelas atau untuk alasan selain terapi medis yang dibutuhkan. Polifarmasi

yang tidak tepat ini sering kali mengarah pada penggunaan obat yang tidak perlu dan berisiko menimbulkan efek samping atau kegagalan dalam mencapai tujuan terapeutik yang diinginkan. Penelitian menunjukkan bahwa polifarmasi yang tidak tepat berhubungan dengan meningkatnya morbiditas dan mortalitas (World Health Organization 2020).

Mengingat risiko yang signifikan dari polifarmasi yang tidak tepat, beberapa studi menyarankan bahwa polifarmasi tidak dapat lagi dianggap selalu bermanfaat. Meskipun polifarmasi memiliki peran penting dalam mengelola kondisi medis yang kompleks, diperlukan penalaran klinis dalam meresepkan obat, yang tidak hanya mengandalkan jumlah obat yang diberikan, tetapi juga pada indikasi medis yang jelas (Masnoon dkk. 2017). World Health Organization (2020) juga menyarankan bahwa meskipun definisi polifarmasi berbasis angka (lima obat atau lebih), fokus utama harus tetap pada praktik berbasis bukti yang bertujuan untuk mengurangi polifarmasi yang tidak tepat, serta mengoptimalkan penggunaan obat yang ada.

II.1.2 Interaksi Obat-Obat (*Drug-Drug Interaction/DDI*)

Interaksi obat-obat (*Drug-drug Interaction/DDI*) adalah fenomena yang terjadi ketika dua atau lebih obat yang digunakan bersamaan berpengaruh satu sama lain, yang dapat mempengaruhi efektivitas obat atau menimbulkan efek samping yang berbahaya. Dalam farmakologi, DDI mengacu pada reaksi yang tidak diinginkan, efek samping toksik, atau hilangnya efektivitas klinis yang terjadi ketika beberapa obat diberikan secara bersamaan untuk mengatasi satu atau lebih penyakit (Molenaar-Kuijsten dkk. 2021). DDI biasanya dibagi menjadi dua mekanisme utama, yaitu farmakokinetik dan farmakodinamik (Nguyen dkk. 2020). Pada mekanisme farmakokinetik, interaksi terjadi ketika satu obat mempengaruhi proses absorpsi, distribusi, metabolisme, atau ekskresi obat lainnya. Sementara itu, dalam mekanisme farmakodinamik, interaksi terjadi ketika dua obat memiliki efek farmakologis yang serupa atau bertentangan, yang dapat meningkatkan atau menurunkan efek terapeutik yang diharapkan (Palleria, Di Paolo, Giofrè, dkk. 2013).

Interaksi obat yang merugikan dapat menyebabkan peningkatan atau penurunan efek farmakologis dari satu atau kedua obat yang digunakan. Bahkan, dalam beberapa kasus, DDI dapat memunculkan efek samping baru yang tidak terduga, yang dapat berakibat fatal (Pichini dkk. 2023). Hal ini menambah kompleksitas pengelolaan terapi, terutama pada pasien yang menerima beberapa obat sekaligus. Studi epidemiologi yang dilakukan di rumah sakit Semarang menunjukkan bahwa sekitar satu pertiga pasien mengalami polifarmasi, dengan 15% di antaranya mengalami in-

teraksi obat yang berbahaya. Dari jumlah tersebut, 62% mengalami satu kejadian interaksi obat, sementara 38% lainnya mengalami dua atau lebih kejadian interaksi (Furdiyanti dkk. 2017). Hal ini menunjukkan bahwa meskipun tidak semua interaksi obat pasti terjadi pada setiap pasien, identifikasi terhadap potensi interaksi obat sangat penting. Interaksi ini dapat meningkatkan risiko *adverse drug reactions* (ADRs), mengurangi efektivitas terapi, dan meningkatkan kemungkinan terjadinya toksisitas (Kurniawati dkk. 2020). Oleh karena itu, pemantauan yang ketat terhadap penggunaan obat pada pasien, khususnya pada pasien lanjut usia yang lebih rentan terhadap interaksi obat berbahaya, menjadi sangat penting.

II.2 Sistem Pendukung Keputusan Klinis (*Clinical Decision Support System/CDSS*)

II.2.1 Definisi dan Fungsi Sistem Pendukung Keputusan Klinis (CDSS)

Sistem Pendukung Keputusan Klinis (*Clinical Decision Support System/CDSS*) adalah sistem berbasis teknologi informasi yang dirancang untuk memberikan rekomendasi kepada tenaga medis dalam pengambilan keputusan klinis. CDSS bertujuan untuk meningkatkan kualitas perawatan pasien, mengurangi kesalahan medis, dan memperbaiki efisiensi dalam pengelolaan perawatan kesehatan. Dengan memberikan informasi berbasis data medis yang relevan, CDSS membantu dokter dan tenaga medis lainnya dalam memilih terapi yang tepat, serta memungkinkan deteksi dini terhadap potensi masalah kesehatan (Sutton dkk. 2020).

CDSS mencakup berbagai alat dan intervensi, baik yang berbasis komputer maupun non-komputer. Alat non-komputer, seperti pedoman klinis atau sumber daya pendukung keputusan klinis digital seperti ClinicalKey atau UpToDate, berfungsi sebagai alat manajemen informasi yang menyarankan keputusan berdasarkan data terkini dan praktik medis terbaik (Wasylewicz dan Scheepers-Hoeks 2019). Selain itu, terdapat pula kategori CDSS yang lebih sederhana, seperti *laboratory information systems* (LISs) yang menyoroti nilai-nilai kritis dalam perawatan pasien atau *pharmacy information systems* (PISs) yang memberikan peringatan terkait penggunaan obat baru dan potensi *drug-drug interactions* (DDI) yang dapat membahayakan pasien. Sistem-sistem ini lebih fokus pada peningkatan perhatian dan pencegahan kesalahan medis dengan memberikan informasi penting secara *real-time*.

Dalam beberapa dekade terakhir, fokus pengembangan CDSS beralih ke sistem yang lebih canggih, dikenal sebagai advanced CDSS. Sistem ini dirancang untuk memberikan rekomendasi yang lebih spesifik dan disesuaikan dengan kondisi pasien, seperti memeriksa interaksi obat-penyakit, memberikan dukungan dosis individual

selama gangguan ginjal, atau menyarankan tes laboratorium tertentu selama penggunaan obat-obatan tertentu. Dengan kemampuan untuk menganalisis data pasien secara lebih mendalam, *advanced* CDSS memungkinkan pengelolaan terapi obat yang lebih terarah dan aman, mengurangi potensi risiko dan meningkatkan keselamatan serta efektivitas perawatan medis (Wasylewicz dan Scheepers-Hoeks 2019).

II.2.2 Tantangan dalam Sistem Pendukung Keputusan Klinis (CDSS)

Meskipun CDSS memiliki potensi besar dalam meningkatkan kualitas perawatan, terdapat beberapa tantangan utama yang perlu diatasi. Salah satu tantangan terbesar adalah pemeliharaan sistem dan konten, seiring dengan perubahan praktik medis, sering kali sulit untuk memastikan bahwa konten dan aturan pengetahuan yang mendukung CDSS tetap terkini. Untuk mengatasi masalah ini, penting untuk memiliki Layanan Manajemen Pengetahuan (*Knowledge Management/KM*) yang fokus pada penerjemahan pengetahuan baru ke dalam sistem CDSS, serta memiliki sistem yang memungkinkan pengukuran dan analisis kinerja CDSS secara berkelanjutan. Dengan sistem yang tepat, perubahan dalam kinerja dan penggunaan CDSS dapat diidentifikasi seiring berjalannya waktu, serta memastikan bahwa data yang digunakan tidak terkontaminasi oleh data yang tidak valid atau berkualitas rendah (Wasylewicz dan Scheepers-Hoeks 2019).

Selain itu, tantangan lain yang signifikan adalah pengaruh negatif terhadap keterampilan pengguna, terutama terkait dengan ketergantungan berlebihan pada sistem yang dianggap "kotak hitam". Banyak tenaga medis yang merasa kesulitan untuk memahami bagaimana rekomendasi sistem dibuat dan mengandalkan akurasi sistem tanpa penjelasan yang memadai tentang dasar pengambilan keputusan tersebut. Masalah ini dapat diatasi dengan mendesain sistem CDSS yang tetap mengedepankan keterlibatan tenaga medis dan mempertahankan otonomi mereka dalam pengambilan keputusan, sambil menawarkan rekomendasi yang didasarkan pada bukti ilmiah yang jelas dan mudah diakses (Wasylewicz dan Scheepers-Hoeks 2019).

Di sisi lain, tantangan keuangan juga menjadi hambatan utama dalam penerapan CDSS secara luas. Biaya pengaturan awal yang tinggi, baik dalam hal modal atau sumber daya manusia, serta ketidakpastian dalam *cost-effectiveness* jangka panjang menjadi masalah yang signifikan dalam implementasi CDSS (Wasylewicz dan Scheepers-Hoeks 2019). Untuk itu, penting untuk merancang sistem yang dapat menunjukkan nilai ekonomis dari sistem CDSS dalam meningkatkan efisiensi perawatan dan mengurangi biaya jangka panjang (Sutton dkk. 2020).

II.3 Pemrosesan Bahasa Alami (NLP) dalam Kesehatan

II.3.1 Pemrosesan Bahasa Alami (*Natural Language Processing*/NLP)

Menurut Jerfy, Selden, dan Balkrishnan (2024), Pemrosesan Bahasa Alami (*Natural Language Processing*/NLP) adalah cabang dari kecerdasan buatan yang bertujuan untuk memungkinkan komputer memahami, menganalisis, dan menghasilkan bahasa manusia. NLP memanfaatkan teknik komputasi untuk menganalisis dan mewakili teks yang terjadi secara alami, sehingga memungkinkan pemrosesan bahasa dengan cara yang mirip dengan kemampuan manusia untuk memahami bahasa. Secara lebih luas, NLP melibatkan berbagai tugas, seperti analisis teks, terjemahan bahasa, analisis sentimen, dan pencarian informasi, dengan tujuan utama untuk menjembatani kesenjangan komunikasi antara manusia dan mesin, serta untuk memungkinkan interaksi yang lebih lancar dan lebih bermakna (Liddy 2001).

NLP terdiri dari dua cabang utama, yaitu *Natural Language Understanding* (NLU), yang berfokus pada pemahaman bahasa manusia, dan *Natural Language Generation* (NLG), yang bertujuan untuk menghasilkan teks yang bermakna dari representasi internal sistem. Salah satu tugas penting dalam NLP adalah *Named Entity Recognition* (NER), yang digunakan untuk mengidentifikasi entitas medis dalam teks, seperti nama obat, gejala, atau diagnosis. Hal ini sangat relevan dalam pengembangan Sistem Pendukung Keputusan Klinis (CDSS) berbasis kecerdasan buatan, dengan NLP memfasilitasi proses ekstraksi data medis yang lebih cepat dan lebih terstruktur untuk memberikan rekomendasi terapi yang tepat (Rayhan dan Rayhan 2023; Khurana dkk. 2023).

Penerapan NLP dalam dunia medis memungkinkan pengolahan keluhan pasien yang disampaikan dalam bahasa alami dan pengolahan data medis yang sebelumnya sulit diakses. Dengan menggunakan algoritma pemrosesan bahasa, sistem medis dapat secara otomatis memindai dan menganalisis data besar yang tidak terstruktur, seperti catatan medis elektronik (EHR), untuk menghasilkan wawasan yang berguna bagi pengambilan keputusan klinis, meningkatkan komunikasi dengan pasien, dan mendukung identifikasi kandidat percakapan uji klinis (Jerfy, Selden, dan Balkrishnan 2024). Ini menunjukkan betapa besar potensi NLP untuk memecahkan masalah besar dalam sistem perawatan kesehatan, dengan mengoptimalkan tugas-tugas yang memakan waktu dan meningkatkan akurasi serta kecepatan analisis data medis yang ada.

II.3.2 *Biomedical Named Entity Recognition (BioNER)*

Biomedical Named Entity Recognition (BioNER) secara teoritis didefinisikan sebagai tugas fundamental dalam penambangan teks biomedis (*biomedical text mining*) yang bertujuan untuk mengidentifikasi dan mengklasifikasikan istilah medis dalam teks tidak terstruktur ke dalam kategori yang telah ditentukan, seperti protein, gen, molekul kimia, dan penyakit. Sebagai masalah pelabelan urutan (*sequence labeling*), BioNER bekerja dengan memetakan setiap token dalam kalimat masukan ke label entitas yang sesuai. Proses ini merupakan fondasi utama dalam mengubah data naratif klinis yang kompleks menjadi format terstruktur yang dapat diolah oleh mesin untuk analisis biomedis lanjutan (Yoon, So, Lee, dkk. 2019).

Dalam perkembangannya, teknologi BioNER telah mengalami transformasi signifikan dari pendekatan statistik tradisional yang sangat bergantung pada rekayasa fitur manual (*hand-crafted features*) menuju arsitektur *deep learning*. Yoon, So, Lee, dkk. (2019) menyoroti bahwa pendekatan berbasis jaringan saraf tiruan, khususnya arsitektur *Bidirectional Long Short-Term Memory (Bi-LSTM)* yang dikombinasikan dengan *Conditional Random Fields (CRF)*, telah menjadi standar performa yang kuat karena kemampuannya mempelajari fitur secara otomatis tanpa intervensi manual yang ekstensif. Lebih jauh lagi, untuk mengatasi keterbatasan model tunggal dalam menangani ambiguitas entitas, pendekatan kolaborasi antar jaringan saraf diterapkan untuk mengurangi kesalahan klasifikasi (*false positives*) dan menghasilkan representasi yang lebih akurat dibandingkan metode fitur manual sebelumnya.

II.3.3 *Korpus DDI Extraction 2013 dan Adaptasi Lintas-Bahasa*

Korpus *DDI Extraction 2013 (DDI2013)* yang diperkenalkan oleh Herrero-Zazo dkk. (2013) merupakan salah satu sumber daya beranotasi yang banyak digunakan untuk tugas ekstraksi entitas dan relasi interaksi obat. Korpus ini berisi dokumen yang bersumber dari basis data DrugBank dan abstrak MedLine, dengan anotasi entitas obat (*BRAND, DRUG, GROUP, DRUG_N*) serta empat tipe relasi interaksi: *mechanism* (interaksi farmakokinetik atau farmakodinamik), *effect* (efek farmakologis dari kombinasi obat), *advise* (rekomendasi klinis), dan *int* (interaksi umum tanpa kategori spesifik). DDI2013 telah menjadi tolak ukur yang umum digunakan dalam evaluasi sistem NER dan ekstraksi relasi pada domain interaksi obat. Korpus ini hanya tersedia dalam bahasa Inggris, sehingga pemanfaatannya untuk tugas NLP berbahasa Indonesia memerlukan langkah translasi yang menjaga ketepatan terminologi medis.

Translasi otomatis teks biomedis menghadapi tantangan yang berbeda dengan teks domain umum. Nama obat (*International Nonproprietary Name/INN*), istilah farmakokinetik (CYP3A4, P-glikoprotein, klirens), dan ekspresi mekanisme interaksi memerlukan presisi tinggi karena kesalahan terminologi dapat berdampak pada interpretasi klinis. Pendekatan translasi yang umum digunakan terbagi menjadi dua kategori utama: pendekatan berbasis *neural machine translation* (NMT) yang menghasilkan terjemahan dengan variasi linguistik tinggi tetapi tidak memberikan jaminan eksplisit terhadap preservasi nama obat dan istilah teknis, dan pendekatan berbasis aturan (*rule-based* atau *template-based*) yang menjaga konsistensi terminologi melalui pemetaan eksplisit melalui kamus istilah yang telah diverifikasi serta mekanisme *placeholder* untuk entitas tertentu. Pendekatan berbasis aturan memiliki konsekuensi variasi linguistik yang lebih terbatas dibandingkan NMT. Pemilihan pendekatan bergantung pada prioritas antara naturalitas teks dan ketepatan terminologi medis dalam konteks penggunaan korpus.

II.4 Model Transformer

II.4.1 Konsep Model Transformer

Model *Transformer*, yang pertama kali diperkenalkan oleh Vaswani dkk. (2017) melalui makalah "*Attention Is All You Need*", menandai perubahan paradigma dalam pemrosesan bahasa alami dengan meninggalkan mekanisme rekurensi (RNN/LSTM) sepenuhnya. Inti dari arsitektur ini adalah mekanisme *self-attention* yang memungkinkan model untuk memproses seluruh urutan masukan secara paralel dan menangkap dependensi jarak jauh antar kata dengan lebih efektif. Vaswani menyatakan bahwa arsitektur ini tidak hanya mempercepat waktu pelatihan secara drastis melalui paralelisasi, tetapi juga menghasilkan representasi kontekstual yang lebih kaya dibandingkan pendahulunya.

Keunggulan utama *Transformer* terletak pada kemampuannya untuk menangani data sekuensial yang panjang tanpa mengalami masalah *vanishing gradient* yang sering terjadi pada RNN. Masalah ini merujuk pada fenomena saat nilai gradien menyusut secara eksponensial selama proses propagasi balik (*backpropagation*), yang menyebabkan model kehilangan kemampuan untuk mempelajari atau mengingat informasi dari urutan kata yang terdahulu. Dengan mengatasi kendala tersebut, *Transformer* memungkinkan transfer pengetahuan yang efektif, yaitu model dapat dilatih pada miliaran kata teks umum dan kemudian diadaptasi (*fine-tuned*) untuk tugas spesifik dengan data yang lebih sedikit. Kemampuan generalisasi inilah yang menjadikan *Transformer* sebagai fondasi bagi berbagai *Large Language Models* (LLM) modern yang ada saat ini.

Secara teknis, mekanisme *self-attention* bekerja dengan memproyeksikan setiap token masukan ke dalam tiga vektor representasi, yaitu *query* (Q), *key* (K), dan *value* (V) melalui matriks bobot yang dipelajari selama pelatihan (Vaswani dkk. 2017). Skor relevansi antar token dihitung melalui operasi *scaled dot-product attention* dengan formula $\text{Attention}(Q, K, V) = \text{softmax}(QK^T/\sqrt{d_k})V$, dengan d_k merupakan dimensi vektor *key* yang berfungsi sebagai faktor penskala untuk menjaga kestabilan gradien. Hasil perkalian QK^T menghasilkan matriks atensi yang merepresentasikan tingkat keterkaitan setiap token dengan token lainnya dalam urutan. Untuk memperkaya representasi, *Transformer* menggunakan *multi-head attention* yang menjalankan beberapa operasi atensi secara paralel pada subruang representasi yang berbeda, kemudian menggabungkan keluarannya. Pendekatan ini memungkinkan model untuk secara simultan menangkap berbagai jenis hubungan linguistik, seperti relasi sintaksis dan dependensi semantik antar kata.

II.4.2 BERT (*Bidirectional Encoder Representations from Transformers*)

BERT (*Bidirectional Encoder Representations from Transformers*) merupakan model inovatif yang dirancang untuk melatih representasi bahasa dengan mengondisikan konteks kiri dan kanan secara bersamaan di semua lapisan. Devlin dkk. (2019) menjelaskan bahwa BERT menggunakan tujuan pelatihan *Masked Language Model* (MLM), sebagian kata dalam masukan disembunyikan dan model harus memprediksi kata tersebut berdasarkan konteks sekitarnya. Pendekatan ini memungkinkan BERT menangkap nuansa semantik yang mendalam, menjadikannya model *state-of-the-art* pada berbagai tugas NLP saat dirilis.

Selain MLM, BERT juga dilatih dengan tugas *Next Sentence Prediction* (NSP) untuk mempelajari hubungan antar kalimat yang krusial pada tugas seperti tanya jawab dan inferensi bahasa alami (Devlin dkk. 2019). Pada NSP, model menerima pasangan kalimat A dan B sebagai masukan dan diminta memprediksi secara biner apakah kalimat B merupakan kelanjutan dari kalimat A pada teks asli atau bukan. Pasangan pelatihan dibentuk dengan komposisi 50% kalimat berurutan dan 50% kalimat yang dipilih secara acak dari korpus. Kombinasi tujuan pelatihan MLM dan NSP memungkinkan BERT mempelajari representasi pada level token sekaligus pada level hubungan antar kalimat secara simultan dalam satu proses pra-pelatihan.

Fleksibilitas BERT terlihat pada kemampuannya untuk diaplikasikan pada berbagai tugas hilir (*downstream tasks*) tanpa memerlukan perubahan arsitektur yang signifikan. Dengan menambahkan satu lapisan keluaran tambahan, BERT dapat di-*fine-tune* untuk tugas seperti klasifikasi teks, penandaan urutan (*sequence labeling*),

hingga tanya jawab. Penelitian menunjukkan bahwa pendekatan pra-pelatihan dan penyesuaian ini secara konsisten mengungguli arsitektur yang dilatih khusus untuk satu tugas saja.

II.4.3 IndoBERT (*Indonesian Bidirectional Encoder Representations from Transformers*)

IndoBERT adalah model bahasa berbasis BERT yang dilatih secara khusus menggunakan korpus bahasa Indonesia yang luas, mencakup teks dari media berita, media sosial, dan laman web. Wilie dkk. (2020) mengembangkan model ini untuk mengatasi keterbatasan model multilingual yang sering kali kurang optimal dalam menangkap kaidah sintaksis dan semantik bahasa Indonesia. Pra-pelatihan IndoBERT dilakukan pada korpus Indo4B yang berisi sekitar 4 miliar kata yang dikumpulkan dari berbagai sumber publik berbahasa Indonesia. Model ini tersedia dalam dua varian utama, yaitu IndoBERT-base dengan 12 lapisan *Transformer* dan sekitar 124 juta parameter serta IndoBERT-large dengan 24 lapisan dan sekitar 335 juta parameter. Hasil evaluasi pada *benchmark* IndoNLU menunjukkan bahwa IndoBERT secara konsisten mengungguli mBERT (*Multilingual BERT*) pada berbagai tugas pemahaman bahasa Indonesia, seperti analisis sentimen, klasifikasi emosi, pengenalan entitas bernama, dan inferensi bahasa.

Dalam konteks kesehatan di Indonesia, penggunaan IndoBERT sangat relevan untuk memproses rekam medis atau keluhan pasien yang ditulis dalam bahasa Indonesia. Penelitian oleh Abdillah dkk. (2023) menunjukkan bahwa adaptasi model berbasis *Transformer* lokal seperti IndoBERT mampu memberikan akurasi yang tinggi dalam mengenali entitas medis dari teks konsultasi daring, yang sering kali menggunakan struktur bahasa tidak baku atau campuran (*code-mixing*).

II.4.4 Conditional Random Fields (CRF)

Conditional Random Fields (CRF) adalah model probabilistik diskriminatif untuk pelabelan urutan (*sequence labeling*) yang diperkenalkan oleh Lafferty, McCallum, dan Pereira (2001). Berbeda dengan model generatif seperti *Hidden Markov Model* (HMM) yang memodelkan distribusi gabungan $P(x, y)$, CRF memodelkan distribusi kondisional $P(y \mid x)$ secara langsung sehingga tidak memerlukan asumsi independensi yang ketat antar fitur masukan. CRF rantai linear (*linear-chain CRF*) yang umum digunakan pada tugas NLP merepresentasikan urutan label keluaran sebagai *Markov random field* yang dikondisikan pada urutan masukan, dengan probabilitas urutan label dihitung melalui fungsi normalisasi global pada seluruh urutan, bukan secara lokal per token.

Pada tugas pengenalan entitas bernama, lapisan CRF sering ditempatkan di atas *encoder* kontekstual seperti BiLSTM atau BERT untuk menggantikan *classifier softmax* per token. Penggunaan *softmax* secara independen dapat menghasilkan urutan label yang tidak valid menurut skema penandaan, misalnya label I-DRUG yang muncul tanpa didahului B-DRUG pada skema BIO. CRF mengatasi hal ini dengan mempelajari matriks transisi antar label sehingga urutan keluaran yang dihasilkan mempertimbangkan ketergantungan antar label tetangga. Saat inferensi, algoritma Viterbi digunakan untuk mencari urutan label dengan probabilitas tertinggi secara efisien. Kombinasi *encoder* berbasis *Transformer* dengan lapisan CRF telah menjadi pendekatan standar pada NER biomedis karena terbukti meningkatkan konsistensi label (Yoon, So, Lee, dkk. 2019; Kusumawardani dan Kusumawati 2024).

II.5 Graph-Based Deep Learning Model

II.5.1 Graph Neural Network (GNN)

Graph Neural Network (GNN) adalah kerangka kerja pembelajaran mendalam yang dirancang untuk memproses data yang direpresentasikan dalam bentuk graf, seperti struktur molekul kimia atau jejaring interaksi protein. Wu dkk. (2020) dalam survei komprehensifnya menjelaskan bahwa GNN bekerja dengan prinsip *message passing*, yaitu setiap simpul (*node*) dalam graf memperbarui representasinya dengan mengagregasi informasi dari simpul tetangganya. Hal ini memungkinkan model untuk menangkap informasi struktural dan relasional yang kompleks yang tidak dapat ditangani oleh jaringan saraf konvensional.

Penerapan GNN dalam bioinformatika dan farmakologi telah merevolusi cara prediksi sifat molekuler dilakukan. Dengan merepresentasikan atom sebagai simpul dan ikatan kimia sebagai sisi (*edge*), GNN dapat mempelajari fitur molekuler secara langsung dari struktur grafnya tanpa memerlukan rekayasa fitur manual yang rumit. Pendekatan ini terbukti sangat efektif untuk tugas-tugas seperti prediksi interaksi obat, penemuan obat baru, dan prediksi afinitas pengikatan obat-target.

II.5.2 Graph Convolutional Network (GCN)

Graph Convolutional Network (GCN) merupakan varian populer dari GNN yang mengadaptasi operasi konvolusi dari pengolahan citra ke struktur graf. Kipf dan Welling (2017) memperkenalkan GCN sebagai metode yang efisien untuk pembelajaran semi-supervisi pada data terstruktur graf. GCN melakukan operasi konvolusi spektral yang disederhanakan, memungkinkan model untuk mempelajari representasi fitur simpul dengan menggabungkan fitur simpul itu sendiri dan fitur tetangganya secara lokal.

Dalam konteks interaksi obat, GCN sering digunakan untuk mengekstraksi fitur laten dari struktur molekul obat atau dari jaringan interaksi obat (*DDI network*). Representasi yang dihasilkan oleh GCN mampu menangkap topologi jaringan interaksi, sehingga model dapat memprediksi potensi interaksi baru berdasarkan pola konektivitas yang telah dipelajari. Pada penelitian lain, He, Liu, Li, dkk. (2022) memanfaatkan GCN sebagai *encoder* utama untuk menggabungkan berbagai jenis fitur obat guna meningkatkan akurasi prediksi DDI.

II.5.3 *Multi-type Feature Fusion based on Graph Neural Network (MFFGNN)*

MFFGNN (*Multi-type Feature Fusion Graph Neural Network*) adalah arsitektur hibrida yang diusulkan oleh He, Liu, Li, dkk. (2022) untuk prediksi interaksi obat-obat (DDI). Model ini dirancang untuk mengatasi keterbatasan model tunggal dengan menggabungkan tiga jenis representasi data: urutan SMILES, graf molekul, dan jaringan interaksi DDI. Penelitian ini menggunakan Bi-GRU untuk mengekstrak fitur sekuensial dari SMILES, *Graph Isomorphism Network* (GIN) untuk fitur struktural graf molekul, dan *Graph Convolutional Network* (GCN) untuk fitur jaringan interaksi.

Kekuatan utama MFFGNN terletak pada mekanisme fusi fiturnya yang mengintegrasikan informasi kimia lokal, topologi molekul global, dan relasi semantik antarbobat. Hasil eksperimen menunjukkan bahwa pendekatan fusi multi-modal ini menghasilkan kinerja *state-of-the-art* pada dataset *benchmark* DDI, membuktikan bahwa kombinasi berbagai pandangan data (*multi-view learning*) memberikan representasi obat yang jauh lebih komprehensif dan prediktif dibandingkan menggunakan satu jenis fitur saja.

II.6 **Prediksi Interaksi Obat-Obat (DDI)**

II.6.1 **Pendekatan Konvensional dalam Prediksi Interaksi Obat-Obat (DDI)**

Pendekatan konvensional dalam deteksi interaksi obat umumnya bergantung pada uji klinis *in vivo* dan *in vitro* serta pemantauan pasca-pemasaran. Meskipun merupakan standar emas untuk validasi, metode laboratorium ini memiliki keterbatasan signifikan dalam hal biaya, waktu, dan skala. Varghese dkk. (2024) mencatat bahwa jumlah kombinasi obat yang mungkin terjadi sangatlah besar, sehingga mustahil untuk menguji semua pasangan secara eksperimental. Akibatnya, banyak interaksi obat potensial yang tidak terdeteksi hingga obat beredar luas di masyarakat.

Selain metode eksperimental, sistem pendukung keputusan klinis tradisional sering menggunakan basis data berbasis aturan (*rule-based*) yang dikurasi secara manual.

Namun, seperti dicatat dalam literatur, sistem ini sering kali statis, sulit diperbarui secara *real-time*, dan gagal mendeteksi interaksi baru yang belum terdokumentasi dalam literatur. Hal ini mendorong kebutuhan akan metode komputasional yang mampu memprediksi interaksi baru secara otomatis.

II.6.2 Pendekatan *Machine Learning* dalam Prediksi Interaksi Obat-Obat (DDI)

Peralihan ke pendekatan berbasis *Machine Learning* (ML) dan *Deep Learning* (DL) telah membuka peluang baru dalam prediksi DDI secara komputasional (*in silico*). Metode ini memperlakukan prediksi DDI sebagai masalah klasifikasi tautan (*link prediction*), yaitu model dilatih untuk memprediksi keberadaan atau jenis interaksi antara dua obat berdasarkan fitur-fiturnya. Pendekatan ini memungkinkan skrining skala besar terhadap jutaan pasangan obat dengan biaya rendah dan kecepatan tinggi.

Model berbasis graf (GNN) saat ini mendominasi riset prediksi DDI karena kemampuannya memodelkan obat sebagai simpul dalam jaringan biologis yang kompleks. Dengan memanfaatkan data struktur kimia dan profil biologis, model DL dapat memprediksi interaksi potensial bahkan untuk obat baru (*cold-start problem*) yang belum memiliki riwayat interaksi sebelumnya. He, Liu, Li, dkk. (2022) menekankan bahwa akurasi model komputasional kini telah mencapai tingkat yang memadai untuk digunakan sebagai alat bantu prediksi awal sebelum validasi klinis dilakukan.

II.7 Retrieval-Augmented Generation (RAG)

II.7.1 Konsep Retrieval-Augmented Generation (RAG)

Secara fundamental, *Retrieval-Augmented Generation* (RAG) diperkenalkan sebagai kerangka kerja arsitektural yang dirancang untuk mengatasi keterbatasan memori statis pada model bahasa besar (*Large Language Models*). Merujuk pada penelitian seminal oleh Lewis dkk. (2020), RAG didefinisikan sebagai paradigma yang menggabungkan dua komponen terpisah namun saling melengkapi, yaitu memori parametrik dan memori non-parametrik. Memori parametrik merujuk pada pengetahuan yang telah terinternalisasi dalam bobot (*weights*) model selama proses pra-pelatihan, sedangkan memori non-parametrik adalah indeks vektor padat yang berasal dari korpus pengetahuan eksternal, seperti Wikipedia atau basis data dokumen organisasi.

Dalam mekanisme operasionalnya, model RAG tidak hanya mengandalkan kemampuan generatif internal saat merespons pertanyaan, melainkan melakukan proses

temu kembali (*retrieval*) terlebih dahulu untuk mencari dokumen yang relevan dari sumber eksternal. Lewis dkk. (2020) menjelaskan bahwa dokumen-dokumen yang ditemukan tersebut kemudian digabungkan dengan masukan asli sebagai konteks tambahan bagi *generator*. Pendekatan hibrida ini memungkinkan model untuk menghasilkan respons yang lebih spesifik, kaya informasi, dan terkini tanpa perlu melakukan pelatihan ulang (*re-training*) yang memakan biaya komputasi besar setiap kali terdapat pembaruan informasi.

II.7.2 Retrieval-Augmented Generation dalam Bidang Medis

Penerapan RAG dalam domain biomedis memiliki urgensi yang signifikan untuk menjawab tantangan akurasi dan kepercayaan pada sistem kecerdasan buatan klinis. Sebagaimana diuraikan oleh Neha, Bhati, dan Shukla (2025), integrasi RAG dalam sistem medis bertujuan untuk memitigasi risiko halusinasi, yaitu peristiwa saat model menghasilkan informasi yang tampak meyakinkan namun salah. Risiko ini diatasi dengan cara menambahkan (*grounding*) setiap respons generatif pada bukti klinis yang valid. Berbeda dengan model bahasa standar yang sering dianggap sebagai "kotak hitam", pendekatan RAG memungkinkan sistem untuk menyajikan jawaban yang tidak hanya akurat secara semantik, tetapi juga transparan karena disertai dengan rujukan langsung ke sumber pengetahuan yang digunakan, seperti panduan praktik klinis atau literatur medis terakreditasi.

Lebih lanjut, Neha menekankan bahwa kemampuan RAG untuk mengakses basis pengetahuan eksternal secara *real-time* menjadikan sistem ini sangat adaptif terhadap dinamika ilmu kedokteran yang terus berkembang. Dengan memisahkan kemampuan penalaran bahasa dari penyimpanan fakta, sistem berbasis RAG dapat diperbarui hanya dengan memodifikasi basis data eksternalnya tanpa mengubah struktur model inti. Hal ini menciptakan ekosistem AI medis yang lebih akuntabel, memungkinkan profesional kesehatan dapat memverifikasi validitas jawaban yang diberikan mesin, sehingga meningkatkan tingkat adopsi teknologi ini dalam pengambilan keputusan klinis yang krusial.

II.8 Metrik Pengukuran

Sistem pada penelitian ini terdiri atas tiga modul utama, yaitu modul *Named Entity Recognition* (NER), modul prediksi *Drug-Drug Interaction* (DDI), dan modul *Retrieval-Augmented Generation* (RAG). Karena setiap modul memiliki karakteristik tugas yang berbeda, pendekatan evaluasi yang digunakan juga berbeda. Bagian ini menjelaskan metrik evaluasi yang digunakan pada masing-masing modul beserta dasar teoritisnya.

A. Metrik untuk Modul NER (*Named Entity Recognition*)

Tugas NER dievaluasi sebagai permasalahan pelabelan urutan (*sequence labeling*). Oleh karena itu, evaluasi pada level token saja tidak cukup untuk menggambarkan kualitas prediksi secara menyeluruh. Penelitian ini menggunakan evaluasi pada level entitas (*entity-level evaluation*) dengan kriteria *exact match* sebagaimana digunakan pada *shared task* CoNLL-2003 oleh Tjong Kim Sang dan De Meulder (2003). Pada pendekatan ini, sebuah prediksi dianggap benar hanya apabila tipe entitas dan batas token (*span*) hasil prediksi identik dengan anotasi *ground truth*.

Pendekatan *exact match* bersifat lebih ketat dibandingkan evaluasi berbasis token karena kesalahan batas entitas tetap dianggap sebagai prediksi yang salah secara keseluruhan. Dengan demikian, evaluasi tidak hanya menilai ketepatan label entitas, tetapi juga ketepatan lokasi entitas dalam kalimat. Dalam skema ini, *true positive* (TP) terjadi ketika model menghasilkan entitas dengan tipe dan *span* yang sama persis dengan anotasi *ground truth*. *False positive* (FP) terjadi ketika model memprediksi entitas yang sebenarnya tidak ada pada *ground truth*, baik akibat kesalahan tipe, kesalahan *span*, maupun keduanya. Sebaliknya, *false negative* (FN) terjadi ketika entitas pada *ground truth* gagal dikenali oleh model.

Berdasarkan ketiga komponen tersebut, penelitian ini menggunakan tiga metrik utama, yaitu *precision*, *recall*, dan *F1-score*.

1. **Precision** mengukur proporsi entitas hasil prediksi yang benar dibandingkan seluruh entitas yang diprediksi oleh model. Nilai *precision* yang rendah menunjukkan bahwa model menghasilkan banyak prediksi yang keliru (Powers 2011).

$$\text{Precision} = \frac{TP}{TP + FP}$$

2. **Recall** mengukur kemampuan model dalam menemukan entitas yang terdapat pada *ground truth*. Nilai *recall* yang rendah menunjukkan bahwa masih banyak entitas yang gagal dikenali oleh model (Powers 2011).

$$\text{Recall} = \frac{TP}{TP + FN}$$

3. **F1-score** merupakan rata-rata harmonik antara *precision* dan *recall*. Penggunaan rata-rata harmonik bertujuan agar nilai F1 tetap rendah apabila salah satu komponen memiliki nilai yang rendah, sehingga metrik ini dapat menye-

imbangkan antara kesalahan *false positive* dan *false negative* (Powers 2011).

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Pada evaluasi multi-kelas, misalnya ketika entitas dibedakan menjadi kelas *DRUG* dan *SYMPTOM*, nilai F1 dapat dihitung menggunakan dua pendekatan agregasi, yaitu *micro-average* dan *macro-average*. *Micro-average* menghitung total TP, FP, dan FN dari seluruh kelas terlebih dahulu sebelum menghitung nilai F1, sehingga hasil evaluasi cenderung dipengaruhi oleh kelas mayoritas. Sebaliknya, *macro-average* menghitung nilai F1 untuk setiap kelas secara terpisah kemudian dirata-ratakan tanpa pembobotan, sehingga setiap kelas memiliki kontribusi yang sama terlepas dari jumlah datanya (Liu dkk. 2024).

B. Metrik untuk Modul DDI (*Drug-Drug Interaction Prediction*)

Prediksi interaksi obat pada penelitian ini diformulasikan sebagai tugas klasifikasi biner. Untuk setiap pasangan obat (d_i, d_j) , model menghasilkan probabilitas $P \in [0, 1]$ yang menunjukkan tingkat keyakinan bahwa kedua obat tersebut memiliki interaksi. Pada level pasangan obat, *true positive* (TP) didefinisikan sebagai pasangan obat yang benar-benar berinteraksi dan berhasil diprediksi berinteraksi oleh model. *False positive* (FP) adalah pasangan obat yang sebenarnya tidak berinteraksi tetapi diprediksi berinteraksi. *False negative* (FN) adalah pasangan obat yang seharusnya berinteraksi namun gagal dikenali oleh model, sedangkan *true negative* (TN) merupakan pasangan obat yang tidak berinteraksi dan diprediksi tidak berinteraksi. Penelitian ini menggunakan nilai ambang *threshold* $\tau = 0,5$ untuk mengubah probabilitas menjadi label biner, mengikuti praktik umum pada penelitian DDI berbasis *Graph Neural Network*, termasuk MFFGNN (He, Liu, Li, dkk. 2022).

Lima metrik utama yang digunakan untuk mengevaluasi modul DDI adalah sebagai berikut.

1. **Precision** mengukur proporsi prediksi positif yang benar terhadap seluruh pasangan obat yang diprediksi berinteraksi. Dalam konteks CDSS, nilai *precision* yang rendah dapat menyebabkan terlalu banyak peringatan palsu (*false alarm*) sehingga meningkatkan risiko *alert fatigue* pada tenaga medis (Powers 2011).

$$\text{Precision} = \frac{TP}{TP + FP}$$

2. **Recall** mengukur kemampuan model dalam mendeteksi pasangan obat yang benar-benar berinteraksi. Pada sistem CDSS, nilai *recall* yang rendah lebih berisiko karena dapat menyebabkan interaksi obat penting tidak terdeteksi

(Powers 2011).

$$\text{Recall} = \frac{TP}{TP + FN}$$

3. **F1-score** digunakan sebagai ukuran tunggal yang menyeimbangkan nilai *precision* dan *recall* (Powers 2011).

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

4. **ROC-AUC** (*Receiver Operating Characteristic–Area Under Curve*) mengukur luas area di bawah kurva ROC yang memetakan *True Positive Rate* (TPR) terhadap *False Positive Rate* (FPR) pada berbagai nilai *threshold*.

$$\text{TPR} = \frac{TP}{TP + FN}, \quad \text{FPR} = \frac{FP}{FP + TN}.$$

Fawcett (2006) menunjukkan bahwa ROC-AUC dapat diinterpretasikan sebagai probabilitas bahwa model memberikan skor lebih tinggi pada sampel positif dibandingkan sampel negatif yang dipilih secara acak. Nilai ROC-AUC berada pada rentang 0 hingga 1, dengan nilai mendekati 1 menunjukkan performa klasifikasi yang semakin baik. ROC-AUC cocok digunakan untuk membandingkan performa beberapa model secara menyeluruh karena metrik ini tidak bergantung pada satu nilai *threshold* tertentu.

5. **AUPR** (*Area Under Precision-Recall Curve*) mengukur luas area di bawah kurva hubungan antara *precision* dan *recall*. Davis dan Goadrich (2006) menunjukkan bahwa kurva ROC dan kurva PR memiliki hubungan matematis, namun keduanya memberikan interpretasi yang berbeda pada kondisi data tidak seimbang. Saito dan Rehmsmeier (2015) menunjukkan bahwa AUPR lebih sensitif terhadap perubahan jumlah *false positive* pada dataset dengan distribusi kelas yang tidak seimbang. Kondisi ini relevan pada prediksi DDI karena jumlah pasangan obat yang benar-benar berinteraksi jauh lebih sedikit dibandingkan seluruh kemungkinan pasangan obat yang tersedia.

Berdasarkan karakteristik tersebut, penelitian ini melaporkan ROC-AUC dan AUPR secara bersamaan. ROC-AUC digunakan untuk menggambarkan performa model secara umum, sedangkan AUPR digunakan untuk mengevaluasi kemampuan model dalam mendeteksi kelas positif yang jumlahnya relatif sedikit.

C. Metrik untuk Modul RAG dan Kebutuhan Non-Fungsional

Evaluasi sistem *Retrieval-Augmented Generation* dilakukan pada dua tahap utama, yaitu tahap *retrieval* untuk mengambil dokumen yang relevan dari basis penge-

tahuan dan tahap generation untuk menyusun jawaban berdasarkan dokumen hasil *retrieval*. Selain kualitas keluaran, penelitian ini juga mempertimbangkan aspek non-fungsional berupa waktu respon sistem karena faktor tersebut berpengaruh terhadap kelayakan penggunaan sistem dalam lingkungan klinis.

1. ***Cosine similarity*** digunakan pada tahap *retrieval* untuk mengukur tingkat kemiripan antara vektor *query* dan vektor dokumen pada indeks FAISS. Menurut Manning, Raghavan, dan Schütze (2008), *cosine similarity* dirumuskan sebagai berikut.

$$\cos(q, d) = \frac{q \cdot d}{\|q\| \cdot \|d\|}$$

q merepresentasikan vektor *query* dan d merepresentasikan vektor dokumen. Nilai yang semakin mendekati 1 menunjukkan tingkat kemiripan semantik yang semakin tinggi antara *query* dan dokumen.

2. ***Precision@k*** mengukur proporsi dokumen relevan di antara (k) dokumen teratas yang dikembalikan sistem *retrieval*. Metrik ini menunjukkan seberapa banyak dokumen yang berhasil diambil benar-benar relevan terhadap *query* (Manning, Raghavan, dan Schütze 2008).

$$\text{Precision@k} = \frac{|\text{dokumen relevan} \cap \text{dokumen teratas-}k|}{k}$$

3. ***Recall@k*** mengukur proporsi dokumen relevan yang berhasil ditemukan dibandingkan seluruh dokumen relevan yang tersedia dalam korpus. Metrik ini digunakan untuk menilai kemampuan sistem *retrieval* dalam menemukan dokumen yang dibutuhkan (Manning, Raghavan, dan Schütze 2008).

$$\text{Recall@k} = \frac{|\text{dokumen relevan} \cap \text{dokumen teratas-}k|}{|\text{dokumen relevan}|}$$

4. ***Faithfulness* dan tingkat halusinasi (*hallucination rate*)** mengevaluasi kualitas keluaran pada tahap *generation*. Es dkk. (2024) mendefinisikan *faithfulness* sebagai proporsi klaim pada jawaban yang dapat diverifikasi melalui dokumen hasil *retrieval*. Sebaliknya, *hallucination rate* merepresentasikan proporsi informasi yang tidak memiliki dukungan sumber atau bertentangan dengan dokumen *retrieval*. Dalam domain medis, pengurangan halusinasi menjadi salah satu alasan utama penggunaan arsitektur RAG karena kesalahan informasi dapat berdampak langsung terhadap keputusan klinis (Neha, Bhati, dan Shukla 2025).
5. **Kelengkapan sitasi** mengukur proporsi pernyataan dalam jawaban yang disertai rujukan eksplisit terhadap dokumen sumber. Metrik ini digunakan untuk

menilai transparansi sistem serta mempermudah pengguna dalam melakukan penelusuran terhadap sumber informasi yang digunakan (Ravi dan Sindhgatta 2025).

6. **Waktu respon** digunakan sebagai metrik non-fungsional untuk mengevaluasi kelayakan operasional sistem dalam mendukung alur kerja klinis. Miller (1968) dan Nielsen (1993) menyebutkan tiga ambang waktu penting dalam interaksi manusia-komputer, yaitu 0,1 detik sebagai respon yang terasa instan, 1 detik sebagai batas yang masih mempertahankan alur berpikir pengguna, dan 10 detik sebagai batas sebelum perhatian pengguna mulai teralihkan. Pada konteks CDSS, Khairat dkk. (2019) melaporkan bahwa keterlambatan sistem di atas 5 detik mulai memerlukan perhatian teknis, sedangkan keterlambatan di atas 10 detik berpotensi memengaruhi proses klinis pada pasien akut. Oleh karena itu, penelitian ini menggunakan ambang 10 detik sebagai target maksimum waktu respon sistem.

II.9 Penelitian Terdahulu

II.9.1 Perancangan *Clinical Decision Support System* (CDSS) untuk *Drug Drug Interaction* (DDI) pada *e-Prescription* (Perwirani dan Sari 2022)

Penelitian yang dilakukan oleh Perwirani dan Sari (2022) berfokus pada pengembangan purwarupa CDSS untuk mendeteksi interaksi obat di lingkungan Rumah Sakit Umum Daerah (RSUD) Budi Rahayu Magelang. Penelitian ini menggunakan metode *System Development Life Cycle* (SDLC) dengan model *Prototype*, perancangan sistem yang dimodelkan menggunakan *Unified Modeling Language* (UML) dan struktur data dipetakan melalui *Entity Relationship Diagram* (ERD). Mekanisme deteksi interaksi yang diterapkan bersifat *rule-based*, yaitu sistem secara otomatis memvalidasi daftar obat yang dimasukkan oleh dokter dengan mencocokkannya terhadap basis data aturan interaksi statis. Keunggulan utama dari penelitian ini adalah alur kerjanya yang terstruktur, yaitu sistem secara otomatis memvalidasi daftar obat yang dimasukkan oleh dokter terhadap basis data interaksi yang telah ditentukan sebelumnya.

Namun, penelitian ini memiliki keterbatasan mendasar pada fleksibilitas masukan dan aksesibilitas. Karena menggunakan pendekatan *rule-based*, sistem sangat bergantung pada kelengkapan *database* statis; interaksi obat baru yang belum dimasukkan secara manual ke dalam aturan tidak akan terdeteksi. Selain itu, sistem ini bersifat tertutup (*provider-centric*), artinya hanya dapat dioperasikan oleh tenaga medis profesional melalui antarmuka rekam medis elektronik. Sistem tidak memiliki kemampuan untuk memproses masukan naratif atau keluhan subjektif

dari pasien, sehingga tidak dapat digunakan untuk skenario pemantauan mandiri (*self-monitoring*) oleh pasien yang sering kali menggunakan bahasa alami untuk mendeskripsikan riwayat pengobatan mereka.

II.9.2 Pengenalan Entitas Biomedis dalam Teks Konsultasi Kesehatan *Online* Berbahasa Indonesia Berbasis Arsitektur *Transformers* (Abdillah dkk. 2023)

Abdillah dkk. (2023) meneliti penerapan model *Deep Learning* berbasis arsitektur *Transformer* untuk tugas *Named Entity Recognition* (NER) pada teks konsultasi kesehatan daring berbahasa Indonesia. Penelitian ini membandingkan kinerja model *Deep Learning* berbasis arsitektur *Transformers*, yaitu mBERT (*multilingual BERT*) dan IndoBERT, dengan menggunakan teknik *Transfer Learning* dan skema anotasi *BIO tagging* untuk mengenali entitas seperti penyakit, gejala, dan obat. Hasil penelitian menunjukkan bahwa model IndoBERT yang dilatih khusus dengan korpus Bahasa Indonesia mampu menghasilkan *F1-Score* sebesar 91,0%, jauh mengungguli model multibahasa.

Kontribusi penting dari penelitian ini adalah pembuktian bahwa teknologi NLP modern dapat diterapkan secara efektif pada data kesehatan Indonesia yang memiliki karakteristik linguistik unik. Temuan ini menjadi landasan penting bagi pengembangan modul ekstraksi entitas (*Named Entity Recognition*) dalam tugas akhir ini. Meskipun demikian, penelitian ini mencatat bahwa fokus ekstraksi masih terbatas pada entitas penyakit dan anatomi, serta belum mengintegrasikan hasil ekstraksi tersebut ke dalam sistem prediksi klinis atau deteksi interaksi obat secara otomatis.

II.9.3 *Multi-type Feature Fusion based on Graph Neural Network for Drug-Drug Interaction Prediction* (He, Liu, Li, dkk. 2022)

He, Liu, Li, dkk. (2022) memperkenalkan arsitektur model *Multi-type Feature Fusion Graph Neural Network* (MFFGNN) yang menjadi metode *state-of-the-art* untuk prediksi interaksi obat-obat (DDI). Model ini menggabungkan tiga representasi data obat, yaitu urutan SMILES yang diproses melalui *Bidirectional Gated Recurrent Unit* (Bi-GRU), graf molekul yang diproses melalui *Graph Isomorphism Network* (GIN) untuk menangkap substruktur kimia, dan jaringan interaksi DDI yang diproses melalui *Graph Convolutional Network* (GCN) untuk menangkap relasi global antarobat. Melalui eksperimen yang ekstensif pada dataset *benchmark* (seperti DrugBank dan TWOSIDES), MFFGNN terbukti mengungguli metode-metode *baseline* sebelumnya yang hanya mengandalkan satu jenis representasi.

Penelitian ini menjadi landasan penting bagi pengembangan modul prediksi dalam sistem CDSS modern. He, Liu, Li, dkk. (2022) menunjukkan bahwa penggabungan berbagai modalitas data obat tidak hanya meningkatkan metrik evaluasi seperti AUC dan F1-*score*, tetapi juga meningkatkan kestabilan model dalam memprediksi berbagai jenis efek samping interaksi. Model ini menyediakan kerangka kerja yang kuat untuk komponen komputasi dalam sistem deteksi interaksi obat berbasis AI. Meskipun begitu, walaupun MFFGNN menunjukkan performa yang sangat presisi dalam mengenali pola interaksi molekuler, model ini memiliki keterbatasan mendasar dalam aplikasinya secara langsung ke pengguna awam. Model ini bekerja murni pada data struktur kimia dan "buta" terhadap konteks klinis berupa teks bahasa alami. Oleh karena itu, tugas akhir ini bertujuan untuk mengisi kesenjangan tersebut dengan membangun *pipeline* yang mampu menerjemahkan keluhan pasien menjadi masukan struktur molekul yang dapat dipahami oleh model MFFGNN.

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Pada subbab ini, akan dilakukan analisis terhadap kondisi saat ini mengenai pengembangan *Clinical Decision Support System* (CDSS) berbasis kecerdasan buatan untuk mendeteksi Interaksi Obat-Obat melalui keluhan pasien berbahasa Indonesia. Analisis ini bertujuan mengidentifikasi kesenjangan kritis antara kebutuhan klinis dalam mendeteksi interaksi obat dan kapabilitas teknologi yang tersedia saat ini di Indonesia. Aspek yang dikaji mencakup tantangan klinis, keterbatasan arsitektur sistem yang ada, kesenjangan data dan fungsionalitas, serta tantangan implementasi di lapangan.

III.1.1 Pemrosesan Keluhan Pasien Berbahasa Indonesia

Pemrosesan keluhan pasien yang disampaikan dalam bentuk teks naratif bahasa Indonesia adalah tantangan besar dalam dunia medis Indonesia. Keluhan pasien umumnya ditulis dalam bahasa bebas, menggunakan bahasa sehari-hari, dan sering kali disertai banyak kesalahan ejaan. Teks yang tidak terstruktur ini menyulitkan sistem untuk mengubahnya menjadi data yang dapat diproses lebih lanjut dalam pengambilan keputusan klinis (Ratnasari, Kusumadewi, dan Rosita 2015; Alamudi, Fardiansyah, dan Sudiyanto 2025). Selain itu, keterbatasan *dataset* berbahasa Indonesia yang relevan dengan konteks medis menjadi hambatan utama dalam pengembangan sistem berbasis *Natural Language Processing* (NLP) di Indonesia (Kusumawardani dan Kusumawati 2024). Akibatnya, pengembangan model untuk mengekstraksi entitas medis penting sebagai dasar pengambilan keputusan klinis menjadi sulit dan terbatas.

Penelitian Abdillah dkk. (2023) mengenai pengenalan entitas biomedis dalam teks konsultasi kesehatan daring berbahasa Indonesia menyoroti sejumlah kendala mendasar dalam penerapan NLP di domain medis berbahasa Indonesia. Permasalahan utama terletak pada terbatasnya representasi data biomedis yang relevan, karena penelitian tersebut masih bergantung pada data media sosial yang tidak spesifik,

tidak terstruktur, dan sarat bias, sehingga kurang mencerminkan konteks klinis sebenarnya. Selain itu, cakupan entitas biomedis yang dikenali masih sempit, terbatas pada *disorders* (penyakit/gejala) dan *anatomy* (bagian tubuh), tanpa mencakup entitas penting seperti obat-obatan, zat kimia, maupun prosedur medis. Akibatnya, hasil ekstraksi belum sepenuhnya mampu merepresentasikan kompleksitas data medis untuk analisis klinis yang lebih luas.

Penelitian tersebut juga menghadapi keterbatasan dalam aspek inferensi klinis dan interpretabilitas hasil. Sistem *Biomedical Named Entity Recognition* (BioNER) yang dibangun hanya berhenti pada tahap ekstraksi entitas tanpa analisis hubungan antar entitas, misalnya deteksi interaksi obat atau keterkaitan gejala dengan kondisi penyakit. Selain itu, keluaran model berupa label teknis yang sulit dipahami tenaga medis karena tidak disertai penjelasan atau konteks berbasis pengetahuan klinis, sehingga menghambat penerapan hasil model dalam pengambilan keputusan medis sehari-hari.

Kusumawardani dan Kusumawati (2024) juga menyoroti sejumlah permasalahan utama dalam penerapan *Named Entity Recognition* (NER) pada teks medis berbahasa Indonesia. Permasalahan mendasar terletak pada keterbatasan dan ketidakseimbangan *dataset* medis yang relevan dengan konteks kesehatan. Sebagian besar data yang digunakan berskala kecil atau bersumber dari platform konsultasi daring yang belum sepenuhnya mencerminkan keragaman bahasa medis Indonesia. Kondisi ini menyebabkan model sulit mengenali variasi entitas dan konteks klinis secara akurat.

Meskipun pendekatan *Bidirectional Long Short-Term Memory Conditional Random Field* (BiLSTM-CRF) dan *fine-tuned* XLM-RoBERTa menunjukkan performa tinggi secara agregat, hasil model belum stabil untuk entitas dengan frekuensi rendah seperti *protein*, *species*, atau *pathogen*, yang menghasilkan nilai F1-score sangat rendah atau bahkan tidak terdeteksi. Ketidakseimbangan ini menunjukkan keterbatasan kemampuan model dalam melakukan generalisasi terhadap entitas medis langka. Lebih jauh, ruang lingkup model masih terbatas pada tahap ekstraksi entitas tanpa analisis hubungan antar entitas medis. Akibatnya, hasil yang dihasilkan masih bersifat deskriptif dan belum menyediakan konteks klinis yang diperlukan dalam pengambilan keputusan medis. Secara keseluruhan, meskipun pendekatan *deep learning* meningkatkan akurasi ekstraksi entitas medis berbahasa Indonesia, masih terdapat permasalahan terkait kualitas data, variasi bahasa, ketidakseimbangan entitas, serta keterbatasan dalam menghasilkan keluaran yang bermakna secara

klinis dan aplikatif.

III.1.2 Prediksi Interaksi Obat-Obat Menggunakan AI


Penelitian mengenai prediksi interaksi obat-obat (*Drug-Drug Interaction/DDI*) berbasis AI menunjukkan perkembangan pesat dalam beberapa tahun terakhir. Salah satu pendekatan terkini dikembangkan oleh Asada, Miwa, dan Sasaki (2023), yang mengusulkan metode ekstraksi DDI dari literatur dengan mengintegrasikan berbagai informasi terkait obat secara bersamaan. Metode ini menggunakan representasi obat yang dibangun melalui *link prediction* pada *Heterogeneous Knowledge Graph* (HKG), seperti DrugBank, MeSH, ATC, dan UniProt. Proses ini menggabungkan informasi tekstual dari kalimat dalam korpus dengan data obat dari HKG, sehingga representasi obat lebih kaya dan kontekstual.

Metode Asada, Miwa, dan Sasaki (2023) berhasil meningkatkan performa ekstraksi DDI secara signifikan dengan mencapai *F-score* sebesar 85,40% pada *dataset* DDIExtraction2013, yang diklaim sebagai salah satu hasil terbaik (*state-of-the-art*) pada saat penelitian dilakukan. Keberhasilan ini menunjukkan bahwa penggabungan informasi dari berbagai sumber pengetahuan dapat meningkatkan ketepatan dalam mendeteksi interaksi obat dalam teks ilmiah. Namun, pendekatan ini juga memiliki beberapa keterbatasan. Pertama, model yang digunakan lebih efektif dalam mengolah data literatur berbahasa Inggris, yaitu entitas obat lebih mudah dikenali dan dikaitkan dengan informasi lain dari basis pengetahuan. Dalam konteks aplikasi di Indonesia, khususnya untuk penanganan keluhan pasien yang menggunakan bahasa Indonesia, model ini belum dapat diakomodasi secara langsung.

Kedua, meskipun metode Asada, Miwa, dan Sasaki (2023) mampu menggabungkan berbagai informasi heterogen tentang obat, integrasi data naratif yang diperoleh dari hasil pemrosesan teks klinis atau keluhan pasien ke dalam prediksi DDI belum diimplementasikan. Di dalam publikasi, *drug mention linking* diposisikan sebagai pemetaan nama obat pada teks ke identitas molekuler di *knowledge graph*, tetapi belum sampai pada tahap integrasi kontekstual antara data naratif pasien dan fitur molekul secara lebih mendalam. Dengan demikian, masih terdapat jarak antara kemampuan model dalam literatur dan kebutuhan sistem CDSS yang harus menangani keluhan pasien dalam bentuk narasi bebas.

Pendekatan lain yang juga menunjukkan peningkatan dalam prediksi DDI adalah *Multi-type Feature Fusion GNN* (MFFGNN) yang dikembangkan oleh He, Liu, Li, dkk. (2022). Metode ini menggabungkan representasi struktur kimia dan urutan


SMILES (*Simplified Molecular Input Line Entry System*) pada model prediksi DDI. Sebagaimana ditunjukkan pada Gambar III.1, MFFGNN menggabungkan urutan SMILES dengan *Bidirectional Gated Recurrent Unit* (Bi-GRU), *molecular graph* dengan *Graph Isomorphism Network* (GIN), serta jaringan DDI dengan *Graph Convolutional Network* (GCN). Model ini menunjukkan hasil yang sangat baik pada berbagai *dataset* seperti ZhangDDI dan DeepDDI. Namun, seperti model lain yang berorientasi pada data molekuler, MFFGNN belum mengintegrasikan data naratif keluhan pasien dari *Electronic Health Record* (EHR) yang diekstraksi melalui NLP/NER ke dalam proses prediksi DDI.



Gambar III.1 Model Konseptual Sistem MFFGNN (He, Liu, Li, dkk. 2022)

Selain pendekatan berbasis *deep learning* dan *knowledge graph*, terdapat penelitian di Indonesia yang berfokus pada perancangan dan implementasi CDSS berbasis *rule-based*. Perwirani dan Sari (2022) memaparkan pengembangan CDSS di RSUD Budi Rahayu Magelang yang terintegrasi dengan sistem *e-prescription* rumah sakit. Sistem ini bertujuan mendeteksi dan memperingatkan dokter serta apoteker jika ditemukan potensi interaksi obat dengan mengacu pada basis data interaksi berbasis PIONas (Badan POM). Algoritma utama yang digunakan adalah *if-then rules* untuk membandingkan pasangan obat yang diresepkan dengan tabel referensi interaksi obat yang telah disusun. Model konseptual sistem ini diilustrasikan pada Gambar III.2.

Keterbatasan utama solusi yang dikembangkan dalam penelitian tersebut adalah seluruh fitur analisis interaksi obat hanya dapat digunakan oleh profesional medis (dokter, apoteker, dan unit farmasi), karena desainnya diarahkan sebagai alat bantu praktik klinis di fasilitas kesehatan. Tidak tersedia akses bagi masyarakat awam atau pasien untuk melakukan pengecekan mandiri secara langsung. Selain itu, sistem masih berbasis *rule-based*, sehingga hanya mampu mendeteksi DDI yang sudah terdokumentasi, dan belum dapat mengolah serta mengenali masukan narasi bebas atau teks keluhan dari pasien. Fitur pemrosesan data tetap mengandalkan masukan terstruktur oleh tenaga medis dan tidak mampu mengintegrasikan laporan keluhan pasien berbasis bahasa sehari-hari atau yang belum diformalkan dalam rekam medis.



Gambar III.2 Model Konseptual Sistem CDSS RSUD Budi Rahayu Magelang (Perwirani dan Sari 2022)

III.1.3 Ringkasan Permasalahan Saat Ini

Berdasarkan kajian terhadap pemrosesan keluhan pasien berbahasa Indonesia dan praktik prediksi DDI di atas, tiga permasalahan utama yang melatarbelakangi pengembangan sistem dirangkum pada Tabel III.1. Permasalahan tersebut diberi kode unik (PS-01 hingga PS-03) untuk memudahkan ketertelusuran (*traceability*) ke kebutuhan fungsional, kebutuhan nonfungsional, serta komponen sistem yang akan dirancang pada subbab berikutnya, sesuai dengan praktik rekayasa kebutuhan yang dianjurkan oleh ISO/IEC/IEEE (2018) dan Sommerville (2016).

Tabel III.1 Ringkasan Permasalahan Saat Ini

ID	Permasalahan	Sumber Referensi
PS-01	Pemrosesan teks medis berbahasa Indonesia masih sangat terbatas. <i>Dataset Named Entity Recognition (NER)</i> medis yang tersedia umumnya berskala kecil, didominasi oleh data media sosial yang bias dan tidak terstruktur, serta belum mencakup keragaman entitas medis (obat, gejala, penyakit) secara seimbang. Akibatnya, model <i>existing</i> seperti BiLSTM-CRF dan XLM-RoBERTa belum stabil dalam mengenali entitas medis berfrekuensi rendah seperti <i>protein</i> , <i>species</i> , dan <i>pathogen</i> .	Abdillah dkk. (2023), Kusumawardani dan Kusumawati (2024)

ID	Permasalahan	Sumber Referensi
PS-02	Model prediksi DDI <i>state-of-the-art</i> (mis. metode berbasis <i>Heterogeneous Knowledge Graph</i> oleh Asada dkk. dan MF-FGNN oleh He dkk.) masih bergantung pada data molekuler dan literatur biomedis berbahasa Inggris, serta belum mengintegrasikan narasi keluhan pasien sebagai input. Hal ini menciptakan kesenjangan antara performa model di laboratorium dengan kebutuhan sistem CDSS yang harus menangani teks naratif pasien dalam bahasa lokal.	Asada, Miwa, dan Sasaki (2023), He, Liu, Li, dkk. (2022)
PS-03	CDSS <i>rule-based</i> eksisting di Indonesia, seperti yang diterapkan di RSUD Budi Rahayu Magelang, hanya dapat diakses oleh tenaga medis dengan input terstruktur (resep elektronik) dan tidak menerima narasi bebas dari pasien. Selain itu, basis interaksi yang digunakan bersifat statis sehingga tidak mampu mendeteksi DDI baru yang belum terdokumentasi.	Perwirani dan Sari (2022)

III.2 Analisis Kebutuhan

III.2.1 Identifikasi Masalah Pengguna

Penelitian terkait interaksi obat menunjukkan bahwa di Indonesia tenaga medis (dokter dan farmasis) serta pasien sering kali menghadapi risiko tinggi akibat efek samping interaksi obat yang tidak terdeteksi secara dini. Pasien atau pengguna layanan kesehatan yang mengonsumsi berbagai jenis obat kerap menyampaikan keluhan dalam bentuk narasi sehari-hari, baik di fasilitas kesehatan maupun di luar lingkungan rumah sakit. Keluhan tersebut biasanya tidak terdokumentasi secara terstruktur dan jarang dianalisis secara sistematis.

Pengelolaan keluhan pasien yang dilakukan secara naratif dan tidak terstruktur, baik dalam pengobatan di fasilitas kesehatan maupun praktik mandiri, menyebabkan data mengenai gejala dan konsumsi obat sulit dianalisis secara otomatis. Permadi dkk. (2025) dalam analisis polifarmasi terhadap interaksi obat di sebuah rumah sakit umum menunjukkan bahwa derajat keparahan interaksi antarobat kategori mayor mencapai sekitar 13%, yang berpotensi mengancam nyawa atau menyebabkan efek samping serius apabila tidak segera ditangani. Temuan tersebut menegaskan bahwa risiko klinis dari interaksi obat yang tidak terdeteksi bukanlah kasus langka.

Masalah lain yang muncul adalah kurangnya kesadaran terhadap potensi interaksi obat, baik di kalangan pasien maupun sebagian tenaga kesehatan. Wangge dan Akbar (2016) menunjukkan bahwa pasien sering kali kesulitan melaporkan semua obat yang mereka konsumsi, termasuk obat bebas, obat tradisional, maupun suplemen, secara lengkap dan akurat. Kondisi ini memperbesar kemungkinan terjadinya inter-

aksi yang tidak terpantau. Di sisi lain, tenaga medis memiliki keterbatasan waktu dan sumber daya untuk melakukan pengecekan manual terhadap seluruh kombinasi obat, terutama pada kasus polifarmasi.

Hingga saat ini, belum tersedia sistem yang mampu menganalisis keluhan pasien dalam bahasa Indonesia secara efektif dan membantu mereka memahami potensi risiko interaksi obat yang sedang atau akan mereka konsumsi. CDSS yang ada umumnya berfokus pada masukan terstruktur yang dimasukkan oleh tenaga medis, bukan pada narasi keluhan pasien. Oleh karena itu, muncul kebutuhan akan sistem yang dapat mengenali dan menganalisis gejala serta obat dari keluhan naratif yang diajukan pasien, dan secara otomatis mendeteksi potensi interaksi obat berdasarkan informasi tersebut. Sistem ini diharapkan dapat mendukung tenaga kesehatan dalam pengambilan keputusan klinis dan sekaligus memberdayakan pasien untuk lebih memahami risiko pengobatan yang dijalani.

Ringkasan masalah pengguna yang menjadi dasar penurunan kebutuhan sistem disajikan pada Tabel III.2. Setiap masalah diberi kode unik (PP-01 hingga PP-03) yang akan dirujuk pada tabel kebutuhan fungsional dan nonfungsional sebagai bentuk *traceability* antara kebutuhan pengguna dan respons sistem.

Tabel III.2 Identifikasi Masalah Pengguna

ID	Aktor	Masalah
PP-01	Pasien	Pasien menyampaikan keluhan dalam bentuk narasi sehari-hari yang tidak terdokumentasi secara terstruktur dan jarang dianalisis secara sistematis, sehingga gejala yang dialami serta obat yang dikonsumsi sulit dipetakan ke risiko interaksi obat secara otomatis.
PP-02	Pasien	Pasien sering kali kesulitan melaporkan seluruh obat yang dikonsumsi (termasuk obat bebas, obat tradisional, dan suplemen) secara lengkap dan akurat. Kondisi ini diperburuk oleh rendahnya kesadaran terhadap potensi DDI, sehingga kemungkinan terjadinya interaksi yang tidak terpantau menjadi lebih besar.
PP-03	Tenaga medis (dokter dan apoteker)	Tenaga medis memiliki keterbatasan waktu dan sumber daya untuk melakukan pengecekan manual terhadap seluruh kombinasi obat, terutama pada kasus polifarmasi yang berdasarkan studi memiliki derajat keparahan interaksi mayor sekitar 13% dan berpotensi mengancam jiwa pasien.

III.2.2 Kebutuhan Fungsional

Kebutuhan fungsional berfokus pada apa yang harus dilakukan sistem, yaitu proses, fungsi, dan fitur yang perlu tersedia. Berdasarkan analisis masalah pengguna dan permasalahan saat ini, kebutuhan fungsional yang diinginkan oleh para pemangku kepentingan (pasien, tenaga kesehatan, dan pengelola sistem) dirangkum pada Tabel III.3. Setiap kebutuhan diberi kode unik (F01 hingga F04). Ketertelusuran (*traceability*) setiap kebutuhan ke kode masalah pengguna (PP), permasalahan saat ini (PS), serta komponen sistem (K) disajikan pada Subbab III.3.3.

Tabel III.3 Kebutuhan Fungsional Sistem

ID	Kebutuhan Fungsional	Deskripsi
F01	Ekstraksi Obat dan Gejala	Sistem memungkinkan ekstraksi nama obat dan gejala dari teks keluhan pasien yang tidak terstruktur menggunakan teknologi NLP. Pasien dapat memberikan keluhan dalam bentuk narasi sehari-hari, dan sistem akan mengekstrak informasi terkait obat yang dikonsumsi serta gejala yang dialami sebagai dasar analisis lebih lanjut.
F02	Prediksi Interaksi Obat–Obat (DDI)	Sistem memungkinkan prediksi interaksi antarobat yang telah diekstraksi dari keluhan pasien. Sistem akan memproses pasangan obat dan memprediksi kemungkinan terjadinya interaksi, termasuk klasifikasi jenis interaksi seperti sinergis, antagonis, atau efek samping berbahaya lainnya berdasarkan model AI dan/atau basis pengetahuan klinis.
F03	Pemeriksaan Relevansi Gejala	Sistem memungkinkan pemeriksaan relevansi antara gejala yang disebutkan pasien dengan prediksi interaksi obat yang dihasilkan. Melalui pemrosesan berbasis pengetahuan (misalnya pendekatan RAG), sistem menghubungkan gejala dengan profil interaksi obat yang relevan untuk menilai apakah keluhan pasien konsisten dengan efek samping atau mekanisme interaksi yang diprediksi.
F04	Penyusunan Laporan dan Rekomendasi	Sistem memungkinkan pembuatan laporan yang menyajikan ringkasan risiko interaksi obat, gejala yang diamati, dan tindakan yang perlu diambil. Laporan yang dihasilkan menyertakan saran seperti perlunya konsultasi dokter, penyesuaian pengobatan, penghentian obat tertentu, atau pemantauan intensif untuk mencegah risiko efek samping yang lebih berat.

III.2.3 Kebutuhan Nonfungsional

Kebutuhan nonfungsional menjabarkan atribut mutu dan batasan yang harus dipenuhi agar sistem CDSS beroperasi dengan baik dan aman dalam konteks klinis. Kebutuhan ini menjawab pertanyaan bagaimana sistem bekerja, mencakup aspek

kualitas, batasan, dan karakteristik implementasi yang relevan dengan praktik farmasi dan rekam medis terkini. Tabel III.4 menyajikan kebutuhan nonfungsional yang diberi kode unik (NF01 hingga NF05). Ketertelusuran setiap kebutuhan ke komponen sistem (K) yang bertanggung jawab atas pemenuhannya disajikan pada Subbab III.3.3.

Tabel III.4 Kebutuhan Nonfungsional Sistem

ID	Parameter	Deskripsi
NF01	Reliabilitas	Sistem harus konsisten dalam memberikan prediksi yang akurat dan stabil pada berbagai variasi input teks keluhan pasien dan kombinasi data obat yang berbeda. Perubahan kecil pada redaksi keluhan tidak boleh menyebabkan perbedaan hasil yang tidak rasional, sehingga sistem dapat diandalkan untuk penggunaan jangka panjang dalam praktik klinis maupun swamonitoring pasien.
NF02	Keamanan dan Privasi	Sistem harus memastikan bahwa data keluhan pasien, nama obat, dan gejala diproses secara aman sesuai dengan protokol privasi dan regulasi perlindungan data yang berlaku. Data sensitif harus dienkripsi saat transit dan saat tersimpan, akses dibatasi berdasarkan peran, dan penggunaan data untuk pelatihan model harus memperhatikan anonimisasi/pseudonimisasi.
NF03	Keterbacaan dan Transparansi	Laporan yang dihasilkan oleh sistem harus mudah dipahami oleh pengguna, baik pasien maupun tenaga kesehatan. Penjelasan mengenai alasan prediksi dan hubungan antara gejala dengan interaksi obat perlu disajikan secara transparan, menghindari jargon teknis yang berlebihan, sehingga pengguna dapat memahami konteks klinis dan mengambil keputusan dengan lebih percaya diri.
NF04	Waktu Respon	Sistem harus dapat beroperasi secara cepat dan responsif. Waktu proses mulai dari input keluhan hingga keluaran laporan harus mendekati <i>real-time</i> , dengan target waktu kurang dari 10 detik untuk setiap keluhan pasien yang diproses, sehingga tetap relevan untuk penggunaan di ruang praktik maupun konsultasi daring.
NF05	Bahasa Komunikasi	Sistem harus mendukung pemrosesan keluhan pasien dalam bahasa Indonesia menggunakan teknologi NLP, termasuk variasi bahasa sehari-hari, istilah nonformal, dan potensi kesalahan ejaan. Selain itu, antarmuka dan laporan sistem idealnya disajikan dalam bahasa Indonesia yang jelas dan mudah dipahami oleh pengguna awam maupun tenaga kesehatan.

III.3 Analisis Pemilihan Solusi

III.3.1 Alternatif Solusi

Tiga pendekatan utama yang dapat dipertimbangkan dalam pengembangan sistem prediksi interaksi obat (DDI) berbasis kecerdasan buatan adalah solusi berbasis aturan, solusi berbasis *deep learning* (DL), dan solusi *hybrid* yang menggabungkan NLP, DL, serta integrasi klinis dan RAG. Masing-masing solusi memiliki kelebihan dan kekurangan yang perlu dipertimbangkan berdasarkan kebutuhan spesifik pengguna dan konteks penggunaan di Indonesia.

Salah satu pendekatan utama dalam pengembangan sistem prediksi interaksi obat adalah solusi berbasis aturan atau *rule-based Clinical Decision Support System* (CDSS). Pendekatan ini dilakukan dengan menyusun basis data interaksi obat berupa tabel yang memuat nama generik obat beserta deskripsi interaksi berdasarkan acuan resmi seperti Pusat Informasi Obat Nasional (PIONas). Dalam sistem ini, potensi interaksi antarobat ditentukan dengan mencocokkan kombinasi obat yang dikonsumsi pasien dengan referensi interaksi yang ada di basis data PIONas. Proses ini melibatkan masukan dari ahli farmasi dan dokter untuk memastikan akurasi penilaian interaksi, serta mempertimbangkan kebutuhan spesifik pengguna layanan kesehatan (Perwirani dan Sari 2022).

Sistem berbasis aturan bekerja dengan cara mengolah data obat yang dimasukkan oleh dokter tanpa memperhatikan urutan masukannya. Selanjutnya, sistem melakukan *screening* kombinasi obat tersebut dengan basis data secara dua arah (*back-to-back*). Algoritma utama yang digunakan adalah *if-then rules*, yaitu pengetahuan tentang interaksi obat yang telah terdokumentasi dimasukkan ke dalam basis pengetahuan dan diakses oleh sistem sesuai dengan logika yang telah ditentukan. Sebagai contoh, jika kombinasi obat A dan B ditemukan dalam basis data interaksi, maka sistem akan memunculkan peringatan kemungkinan interaksi obat yang terjadi, beserta penjelasan mengenai jenis interaksi tersebut. Kelebihan pendekatan ini terletak pada transparansi dan kemudahan audit, namun kemampuan untuk mendeteksi interaksi baru yang belum terdokumentasi sangat terbatas.

Solusi kedua adalah pendekatan berbasis *deep learning*, yang memanfaatkan algoritma pembelajaran representasi untuk memprediksi DDI dengan menggunakan data molekuler dan fitur graf obat. Berbagai model DL seperti *Deep Neural Network* (DNN), *Convolutional Neural Network* (CNN), dan *Graph Neural Network* (GNN) telah diterapkan untuk mempelajari pola interaksi di antara pasangan obat. Data yang digunakan meliputi representasi struktur kimia dalam format SMILES, graf

molekul, vektor fitur kimia, dan informasi interaksi historis antarobat (He, Liu, Li, dkk. 2022).

Tahapan utama pada solusi ini mencakup ekstraksi fitur dari data terstruktur, pelatihan model pada *dataset* interaksi obat seperti ZhangDDI dan DeepDDI, serta prediksi kemungkinan interaksi untuk setiap pasangan obat. Setelah model dilatih, sistem dapat menghasilkan skor probabilitas yang mengindikasikan kemungkinan terjadinya DDI berdasarkan pembelajaran dari data historis atau eksperimen laboratorium. Validasi sistem dilakukan dengan menguji metrik evaluasi seperti AUC, F1-score, dan *precision* pada *dataset* validasi atau melalui teknik *cross-validation*. Meskipun model DL menunjukkan performa tinggi pada *dataset* besar, pendekatan ini umumnya tidak secara langsung menangani narasi keluhan pasien, karena bergantung pada data molekuler dan *dataset* interaksi yang terstruktur.

Solusi ketiga adalah pendekatan hibrida yang menggabungkan kemampuan *Natural Language Processing* (NLP), ML/DL, dan RAG. Dalam pendekatan ini, NLP digunakan untuk mengekstraksi nama obat dan gejala dari keluhan pasien berbahasa Indonesia yang disampaikan dalam bentuk narasi bebas dan tidak terstruktur. Model ML/DL kemudian dimanfaatkan untuk memprediksi interaksi obat berdasarkan data struktur kimia, graf obat, atau basis pengetahuan interaksi yang ada. Di atas kedua lapisan tersebut, RAG digunakan untuk menghasilkan laporan yang mudah dipahami pengguna.

Metode RAG memungkinkan sistem mengambil informasi secara *real-time* dari basis pengetahuan eksternal atau dokumen yang telah diindeks, sehingga jawaban yang diberikan lebih faktual dan berbasis bukti. Hasil NLP dan prediksi ML/DL kemudian dihubungkan dengan informasi dari sumber medis tepercaya, baik untuk menjelaskan relevansi gejala yang diekstraksi dari keluhan pasien dengan efek atau mekanisme interaksi obat yang diprediksi, maupun untuk memberikan rekomendasi tindakan yang tepat. Studi terbaru di bidang *healthcare chatbot* dan implementasi RAG pada aplikasi klinis menunjukkan bahwa teknologi ini dapat meningkatkan akurasi, relevansi, dan keterbacaan laporan kesehatan, termasuk pada data klinis berbahasa lokal (Samudra, Turmudi Zy, dan Ermanto 2025).

III.3.2 Analisis Penentuan Solusi

Untuk membandingkan ketiga alternatif pendekatan, dilakukan analisis kualitatif berdasarkan sejumlah aspek kritis, antara lain kemampuan menangani data teks naratif, kemampuan mengidentifikasi interaksi obat baru, fleksibilitas sistem, transparansi hasil, serta kesesuaian dengan kebutuhan Indonesia (bahasa dan

praktik lokal). Ringkasan hasil analisis disajikan pada Tabel III.5.

Tabel III.5 Analisis Penentuan Solusi

Aspek yang Dianalisis	Solusi 1: Berbasis Aturan	Solusi 2: <i>Deep Learning</i>	Solusi 3: Hibrida
Kemampuan menangani data teks naratif	Rendah – Sistem tidak dirancang untuk menangani teks naratif bebas secara otomatis dan hanya menerima input terstruktur (misalnya daftar obat yang dipilih dari daftar).	Rendah – Model berfokus pada data terstruktur seperti SMILES, graf molekul, dan fitur kimia; narasi pasien harus terlebih dahulu dikonversi secara manual atau melalui modul terpisah.	Tinggi – Menggunakan NLP untuk mengekstraksi obat dan gejala langsung dari teks keluhan pasien berbahasa Indonesia, sehingga cocok untuk narasi bebas di dunia nyata.
Kemampuan mengidentifikasi interaksi obat baru	Sedang – Hanya dapat mengidentifikasi interaksi yang telah terdokumentasi dalam basis data referensi; interaksi baru tidak terdeteksi sebelum dimasukkan sebagai aturan baru.	Tinggi – Dapat mempelajari pola dan memprediksi interaksi baru dari data historis maupun eksperimen, termasuk pasangan obat yang belum pernah diuji secara langsung.	Tinggi – Menggabungkan kemampuan pembelajaran dari data (DL) dengan pengetahuan eksplisit, sehingga mampu mendeteksi interaksi baru sekaligus memanfaatkan pengetahuan yang sudah terdokumentasi.
Fleksibilitas sistem	Rendah – Tidak fleksibel terhadap perubahan pola konsumsi obat atau obat baru; pembaruan memerlukan penambahan aturan secara manual ke basis pengetahuan.	Tinggi – Dapat menyesuaikan dengan data baru melalui proses pelatihan ulang atau <i>fine-tuning</i> model, sehingga sejalan dengan dinamika penggunaan obat.	Tinggi – Menggabungkan kekuatan NLP dan ML/DL untuk menyesuaikan dengan berbagai tipe data (narasi, struktur kimia, pengetahuan klinis) dan berbagai situasi penggunaan.
Transparansi hasil	Tinggi – Aturan yang digunakan eksplisit dan mudah dijelaskan serta diaudit; sumber pengetahuan (misalnya PIONas) dapat ditelusuri dengan jelas.	Rendah – Model berbasis ML/DL bersifat <i>black box</i> , sehingga sulit dijelaskan kepada pengguna awam maupun regulator tanpa lapisan penjelasan tambahan.	Tinggi – Dapat memanfaatkan RAG untuk menyajikan penjelasan berbasis dokumen klinis dan pedoman resmi, sehingga hasil prediksi lebih transparan dan mudah dipahami.

Aspek yang Dianalisis	Solusi 1: Berbasis Aturan	Solusi 2: <i>Deep Learning</i>	Solusi 3: Hibrida
Kesesuaian dengan kebutuhan Indonesia (bahasa dan praktik lokal)	Rendah – Umumnya tidak mengakomodasi keluhan dalam bahasa Indonesia secara naratif dan tidak menangani variasi praktik lokal (misalnya penggunaan obat herbal dan obat bebas) kecuali dimasukkan secara eksplisit ke basis data.	Sedang – Dapat disesuaikan dengan data lokal untuk aspek molekuler, namun tidak secara langsung menangani narasi bebas dalam bahasa Indonesia dan tidak otomatis mencakup produk nonresep dan herbal.	Tinggi – Mampu memproses keluhan berbahasa Indonesia melalui NLP dan dapat diadaptasi untuk kebutuhan lokal, termasuk integrasi produk herbal, obat bebas, serta pola konsumsi obat yang khas di Indonesia.

Berdasarkan Tabel III.5, solusi berbasis aturan memiliki keunggulan pada aspek transparansi hasil karena aturan yang digunakan mudah dijelaskan dan diaudit, namun lemah dalam menangani teks naratif bebas dan interaksi obat baru yang belum terdokumentasi. Solusi berbasis *deep learning* unggul dalam kemampuan mempelajari pola interaksi baru dari data historis, tetapi sangat bergantung pada ketersediaan *dataset* terstruktur dan cenderung tidak langsung kompatibel dengan narasi keluhan pasien berbahasa Indonesia.

Solusi hibrida muncul sebagai pendekatan yang paling seimbang dalam menjawab kebutuhan pengguna di Indonesia. Pendekatan ini tidak hanya mampu menangani masukan naratif dalam bahasa Indonesia melalui NLP, tetapi juga memadukan teknik terkini dalam ML/DL untuk prediksi DDI dan RAG untuk menghasilkan laporan yang lebih transparan dan mudah dipahami. Selain itu, solusi hibrida menawarkan fleksibilitas dan kemampuan adaptasi yang tinggi terhadap perubahan praktik penggunaan obat, termasuk obat bebas, produk herbal, maupun pola konsumsi yang bervariasi di masyarakat. Dengan pertimbangan tersebut, pendekatan hibrida dipilih sebagai dasar konseptual bagi desain sistem yang akan dikembangkan pada bab berikutnya.

III.3.3 Komponen Sistem

Komponen-komponen ini diturunkan dari identifikasi masalah pada penjelasan sebelumnya. Alur dan keterhubungan antar komponen untuk solusi persoalan secara keseluruhan dijelaskan pada Bab IV dan diuraikan implementasinya pada Bab V. Tabel III.6 menyajikan lima komponen utama sistem CDSS *hybrid* beserta deskripsi singkatnya. Setiap komponen diberi kode unik (K-01 hingga K-05) yang digu-

nakan sebagai referensi ketertelusuran (*traceability*) antara kebutuhan sistem dengan artefak desain dan implementasi, sebagaimana dianjurkan oleh Wiegers dan Beatty (2013).

Tabel III.6 Komponen Sistem CDSS *Hybrid*

ID	Komponen	Deskripsi
K-01	Modul Ekstraksi Entitas Medis (NER)	Komponen berbasis IndoBERT yang dikombinasikan dengan lapisan <i>Conditional Random Field</i> (CRF) dan dilengkapi rangkaian pasca-pemrosesan (normalisasi huruf, penghapusan dosis dan akhiran bahasa Indonesia, penyaringan kata henti, pemisahan entitas gabungan, serta deduplikasi) untuk mengekstraksi entitas DRUG, SYMPTOM, dan DISEASE dari teks keluhan pasien berbahasa Indonesia.
K-02	Modul Prediksi Interaksi Obat (MFFGNN)	Komponen berbasis arsitektur <i>Multi-type Feature Fusion Graph Neural Network</i> (MFFGNN) yang memadukan tiga cabang <i>encoder</i> , yaitu Bi-GRU untuk urutan SMILES, GIN dan GWU untuk graf molekul, serta GCN untuk graf DDI, melalui modul fusi berbasis atensi. Komponen ini menghasilkan probabilitas interaksi biner sekaligus probabilitas tipe interaksi (<i>mechanism, effect, advise, int</i>) melalui kepala prediksi ganda.
K-03	Modul Laporan dan Penjelasan (RAG)	Komponen yang melakukan pengambilan dokumen relevan (<i>retrieval</i>) dari indeks FAISS berisi 592.122 dokumen yang dihimpun dari empat sumber (DDI2013, ChCh-Miner, TWOSIDES, DrugBank) dan menghasilkan laporan klinis berbahasa Indonesia menggunakan <i>Large Language Model</i> Gemini 2.5 Flash. Komponen ini juga dilengkapi mode <i>template-based fallback</i> untuk menjamin ketersediaan laporan ketika LLM tidak dapat diakses.
K-04	<i>CDSS Pipeline Orchestrator</i> (termasuk <i>Drug Alias Resolver</i>)	Komponen yang mengoordinasikan eksekusi seluruh modul secara berurutan (NER → DDI → RAG) melalui kelas <i>CDSSPipeline</i> dengan mekanisme <i>lazy loading</i> dan penanganan kesalahan per modul. Komponen ini juga memuat <i>Drug Alias Resolver</i> berisi 130 pemetaan alias nama obat (INN, USAN, dan ejaan adaptasi bahasa Indonesia) yang dijalankan sebelum prediksi DDI guna menyelaraskan nama obat dengan basis data ChCh-Miner.

ID	Komponen	Deskripsi
K-05	Antarmuka Pengguna (REST API dan Web UI)	Komponen lapisan aplikasi berbasis FastAPI yang menyediakan REST API (<i>endpoints</i> /api/v1/predict, /api/v1/health, /api/v1/models) sekaligus melayani antarmuka web <i>single-page application</i> (SPA) berbasis HTML5 dan Tailwind CSS. Komponen ini menampilkan hasil setiap modul secara visual kepada pengguna, termasuk <i>highlight</i> entitas NER, kartu prediksi DDI, dokumen referensi RAG, serta laporan klinis terformat Markdown.

Ketertelusuran setiap kebutuhan fungsional dan nonfungsional ke kode persoalan (PP, PS) serta komponen sistem (K) yang relevan dirangkum pada Tabel III.7.

Tabel III.7 Ketertelusuran Kebutuhan ke Persoalan dan Komponen Sistem

ID	Kebutuhan/Parameter	Persoalan/Komponen Terkait
F01	Ekstraksi Obat dan Gejala	PP-01, PS-01 K-01, K-04
F02	Prediksi Interaksi Obat–Obat (DDI)	PP-02, PP-03, PS-02 K-02
F03	Pemeriksaan Relevansi Gejala	PP-02, PS-03 K-03
F04	Penyusunan Laporan dan Rekomendasi	PP-01, PP-03, PS-03 K-03, K-04, K-05
NF01	Reliabilitas	K-01, K-02, K-03
NF02	Keamanan dan Privasi	K-04, K-05
NF03	Keterbacaan dan Transparansi	K-03, K-05
NF04	Waktu Respon	K-04, K-05
NF05	Bahasa Komunikasi	K-01, K-03, K-05

BAB IV

PERANCANGAN

Bab ini bertujuan untuk menyajikan perancangan solusi yang diusulkan dalam penelitian ini, yaitu pengembangan Sistem Pendukung Keputusan Klinis (*Clinical Decision Support System/CDSS*) berbasis kecerdasan buatan yang dapat mengatasi tantangan dalam mengidentifikasi potensi interaksi obat (*Drug-Drug Interaction/DDI*). Bab ini menggambarkan komponen-komponen utama sistem yang diusulkan, termasuk ekstraksi entitas medis, prediksi DDI, dan pembuatan laporan klinis yang transparan dan dapat dipahami, serta menjelaskan bagaimana sistem ini lebih unggul dibandingkan pendekatan CDSS konvensional yang hanya mengandalkan data terstruktur.

IV.1 Komponen Perancangan Solusi

Sistem CDSS *hybrid* yang diusulkan terdiri dari tiga modul utama yang bekerja secara terintegrasi pada saat *runtime*, yaitu (1) Modul Ekstraksi Entitas Medis (NLP/NER), (2) Modul Prediksi Interaksi Obat dengan MFFGNN, dan (3) Modul Laporan dan Penjelasan berbasis RAG. Sebelum ketiga modul tersebut dapat dijalankan, diperlukan tahap persiapan data secara *offline*, khususnya untuk pembentukan korpus pelatihan model NER berbahasa Indonesia. Bagian ini diawali dengan penjelasan tahap persiapan data tersebut, kemudian dilanjutkan dengan rancangan ketiga modul.

IV.1.1 Persiapan Data: Pembentukan Korpus Keluhan Pasien Bahasa Indonesia

Pelatihan model *Named Entity Recognition* (NER) memerlukan korpus berbahasa Indonesia yang memuat anotasi entitas obat (*DRUG*) dan gejala (*SYMPTOM*) pada konteks keluhan pasien. Saat ini, korpus DDI yang tersedia secara publik, yaitu DDIExtraction2013 berbahasa Inggris dan ditulis dalam gaya formal-saintifik (seperti abstrak jurnal dan deskripsi DrugBank). Oleh karena itu, tahap ini dirancang untuk mengubah korpus tersebut menjadi korpus berbahasa Indonesia dengan gaya keluhan pasien yang siap dianotasi dengan skema BIO. Tahap persiapan data

dijalankan satu kali secara *offline*, dan hasilnya disimpan dalam bentuk berkas pelatihan, validasi, serta uji yang selanjutnya digunakan oleh Modul 1.

1. Masukan

Masukan tahap ini berupa kalimat-kalimat berbahasa Inggris dari korpus DDIEExtraction2013 (subkorpus DrugBank dan MedLine), beserta atributnya. Atribut mencakup pasangan obat yang berinteraksi, tipe interaksi DDI (*mechanism, effect, advise, int*), serta deskripsi efek interaksi. Kalimat-kalimat tersebut umumnya berupa narasi formal-saintifik mengenai mekanisme atau efek interaksi obat, bukan dalam bentuk keluhan pasien.

2. Proses

Pembentukan korpus dirancang sebagai sebuah *pipeline* yang terdiri dari lima tahap. Setiap tahap memiliki tujuan desain yang spesifik, dengan tujuan utama yaitu menjembatani perbedaan antara teks saintifik berbahasa Inggris dan keluhan pasien berbahasa Indonesia, tanpa menghilangkan keaslian anotasi entitas.

a. Translasi Inggris–Indonesia dengan preservasi entitas

Tahap ini bertujuan untuk menerjemahkan teks ke dalam bahasa Indonesia tanpa mengubah posisi entitas *DRUG*. Translasi dilakukan dengan pendekatan berbasis pemetaan istilah farmakologis ke padanan bahasa Indonesia yang baku, sementara nama obat dipertahankan dalam bentuk aslinya karena bersifat universal. Pendekatan ini dipilih untuk menjaga konsistensi terminologi nama obat dan memastikan entitas tetap akurat, meskipun variasi bahasa yang dihasilkan menjadi lebih terbatas.

b. Adaptasi gaya menjadi keluhan pasien

Tahap ini bertujuan untuk mengubah gaya bahasa dari narasi saintifik (misalnya “*Drug A increases the absorption of Drug B*”) menjadi bentuk keluhan pasien yang subjektif (misalnya “Saya pusing setelah minum Drug A bersama Drug B”). Informasi mengenai tipe interaksi dan efeknya dipetakan ke kosakata gejala yang umum digunakan oleh masyarakat. Selanjutnya, kalimat disusun ulang ke dalam beberapa variasi gaya, yaitu: (i) pernyataan orang pertama (“Saya {gejala} setelah minum {obat}.”), (ii) gaya percakapan informal (“Udah minum {obat} tapi malah {gejala}, kenapa ya?”), (iii) bentuk pertanyaan (“Apakah {obat} bisa menyebabkan {gejala}?”), dan (iv) naratif klinis (“Pasien melaporkan {gejala} sejak mulai mengonsumsi {obat}.”). Variasi ini bertujuan agar model NER mampu mengenali entitas dalam berbagai bentuk kalimat, tidak hanya bergantung pada satu pola kalimat

tertentu.

c. Augmentasi

Tahap ini bertujuan untuk meningkatkan keragaman data tanpa mengubah label entitas. Augmentasi yang dirancang mencakup: (i) penggunaan sinonim gejala dalam bahasa awam, (ii) penambahan informasi waktu yang umum muncul dalam keluhan pasien, dan (iii) parafrase berbasis *large language model* (LLM) dengan tetap mempertahankan entitas. Seluruh variasi hanya memodifikasi konteks di sekitar entitas, sehingga posisi dan label *DRUG* serta *SYMPTOM* tetap konsisten.

d. Anotasi BIO untuk pelatihan NER

Pada tahap ini, entitas yang telah diproses sepanjang proses diubah menjadi label per token menggunakan skema BIO (*Begin-Inside-Outside*). Skema BIO dipilih karena merupakan format standar dalam pelatihan NER dan mampu menangani entitas yang terdiri dari lebih dari satu token.

e. Pengendalian mutu dan pemisahan *train/validation/test*

Tahap ini bertujuan untuk memastikan kualitas korpus sebelum digunakan. Pengendalian mutu meliputi pemeriksaan kesesuaian rentang entitas, penghapusan data duplikat, serta evaluasi distribusi gaya kalimat dan tipe interaksi. Selanjutnya, data korpus dibagi menjadi himpunan pelatihan, validasi, dan pengujian dilakukan secara stratifikasi berdasarkan tipe interaksi DDI, sehingga setiap subset memiliki distribusi yang seimbang.

3. Keluaran

Keluaran tahap ini adalah korpus berbahasa Indonesia dengan gaya keluhan pasien dalam format JSONL. Setiap entri memuat teks kalimat, daftar entitas beserta rentangnya, token, label BIO, serta atribut metadata seperti gaya kalimat dan tipe interaksi DDI. Contoh entri ditunjukkan pada Gambar IV.1.

Korpus ini selanjutnya digunakan untuk melatih model NER pada Modul 1, sehingga model dapat mengenali entitas obat dan gejala dari teks keluhan pasien informal berbahasa Indonesia, bukan dari teks saintifik berbahasa Inggris.

IV.1.2 Modul 1: Ekstraksi Entitas Medis (NLP/NER)

Pada tahap awal, pasien memberikan masukan berupa keluhan atau gejala dalam bentuk kalimat naratif bebas. Sebagai contoh, pasien dapat melaporkan: “Saya sering pusing dan mimisan setelah minum warfarin dan simvastatin.”

1. Masukan

```

1 {
2   "text": "Sejak kemarin, kok saya mimisan ya setelah
3           Argatroban dan thrombolytics?",
4   "entities": [
5     {"text": "mimisan",      "label": "SYMPTOM",
6      "start": 24, "end": 31},
7     {"text": "Argatroban",   "label": "DRUG",
8      "start": 49, "end": 59},
9     {"text": "thrombolytics", "label": "DRUG",
10      "start": 64, "end": 77}
11  ],
12  "bio_tags": ["O", "O", "O", "O", "B-SYMPTOM", "O", "O", "O",
13              "B-DRUG", "O", "B-DRUG"],
14  "ddi_type": "effect",
15  "style": "informal"
16 }
17

```

Gambar IV.1 Contoh Entri Korpus Keluhan Pasien Bahasa Indonesia Hasil Persiapan Data

Masukan dalam modul ini berupa kalimat naratif yang mencakup gejala dan obat yang digunakan pasien. Narasi tersebut dapat bervariasi bentuknya, namun umumnya memuat kombinasi informasi mengenai kondisi yang dirasakan dan obat yang dikonsumsi.

2. Proses

Modul ini menggunakan *Natural Language Processing* (NLP) dengan teknik *Named Entity Recognition* (NER) untuk mengidentifikasi dan mengekstraksi entitas medis yang relevan dari teks naratif. Proses ini bertujuan untuk mengenali dan mengklasifikasikan entitas seperti:

- a. nama obat, misalnya *warfarin* dan *simvastatin*; dan
- b. gejala yang dialami pasien, misalnya pusing dan mimisan.

Hasil ekstraksi ini mengubah teks tidak terstruktur menjadi representasi data terstruktur yang dapat diproses oleh modul-modul berikutnya.

3. Keluaran

Hasil ekstraksi berupa entitas medis yang terstruktur, misalnya:

Keluaran terstruktur pada Gambar IV.2 selanjutnya digunakan sebagai masukan untuk Modul 2, di mana obat yang disebutkan akan diproses lebih lanjut untuk prediksi interaksi.

```

1 {
2   "drugs":    ["warfarin", "simvastatin"],
3   "symptoms": ["pusing", "mimisan"]
4 }
5

```

Gambar IV.2 Contoh Keluaran Terstruktur dari Modul Ekstraksi Entitas Medis (NLP/NER)

IV.1.3 Modul 2: Prediksi Interaksi Obat dengan MFFGNN

Modul ini merupakan komponen inti dalam sistem deteksi interaksi obat, yang secara langsung mengimplementasikan arsitektur *Multi-type Feature Fusion Graph Neural Network* (MFFGNN). Arsitektur ini dirancang untuk memanfaatkan berbagai jenis data yang berbeda, termasuk representasi kimia obat, graf molekul, dan informasi interaksi antarobat (DDI), guna memprediksi kemungkinan interaksi obat yang dapat berisiko bagi pasien.

1. Masukan

Pada tahap ini, sistem menerima nama-nama obat yang telah diekstraksi pada Modul 1. Nama-nama obat tersebut kemudian diproses lebih lanjut untuk mendapatkan representasi yang lebih komprehensif dalam format yang dapat dipahami oleh model prediksi:

a. Pemetaan ke Format SMILES

Setiap obat dipetakan ke dalam format SMILES (*Simplified Molecular Input Line Entry System*), yang menyatakan struktur kimia obat dalam bentuk urutan karakter linear sehingga memudahkan representasi struktur kimia untuk analisis lanjutan.

b. Pemetaan ke Graf Molekul

Selain SMILES, obat-obatan juga dipetakan menjadi graf molekul di mana setiap atom dalam molekul menjadi simpul (*node*) dan setiap ikatan antar atom menjadi sisi (*edge*). Representasi graf ini memungkinkan model untuk memahami hubungan struktural antara atom-atom dalam molekul obat.

c. Data Jaringan Interaksi DDI

Sistem juga mengakses informasi dari jaringan interaksi DDI yang dikumpulkan dari *open knowledge base* seperti DrugBank dan berbagai korpus DDI. Dataset ini berisi pasangan-pasangan obat beserta hubungan interaksi yang telah diketahui sehingga memberikan informasi tambahan mengenai bagaimana obat-obat tersebut saling berinteraksi

dalam konteks medis.

2. Proses

Proses deteksi interaksi obat pada modul ini melibatkan beberapa tahap utama yang mencakup ekstraksi dan fusi fitur dari berbagai sumber data obat:

a. Fitur Lokal SMILES

Setiap obat diproses menggunakan *Bidirectional Gated Recurrent Unit* (Bi-GRU), yakni jenis *Recurrent Neural Network* yang memproses urutan data secara dua arah. Mekanisme ini memungkinkan model untuk memahami konteks kimia lokal dengan lebih baik dan menghasilkan *embedding* yang menggambarkan urutan atom dan ikatan dalam struktur molekul obat.

b. Fitur Graf Molekul

Obat yang telah dipetakan menjadi graf molekul dianalisis dengan *Graph Isomorphism Network* (GIN) dan *Graph Wavelet Unitary* (GWU). GIN bertujuan menangkap hubungan antar atom dan subgraf penting, sementara GWU meningkatkan pemahaman model terhadap struktur global molekul. Tahap ini menghasilkan *embedding* yang kaya informasi tentang topologi dan hubungan atomik.

c. Fitur Graf DDI

Semua obat yang dianalisis dipetakan menjadi sebuah graf DDI, di mana setiap obat direpresentasikan sebagai *node* dan interaksi antarobat sebagai *edge*. Jaringan ini berisi riwayat interaksi obat yang dikumpulkan dari berbagai sumber seperti DrugBank dan TWOSIDES. Untuk mengoptimalkan pemahaman hubungan antarobat dalam jaringan ini, digunakan *Graph Convolutional Network* (GCN) berlapis. *Gating mechanism* kemudian digunakan untuk menggabungkan vektor informasi yang diperoleh dari SMILES, graf molekul, dan graf DDI.

d. Fusi Multi-Fitur

Setelah setiap jenis fitur diekstraksi, langkah berikutnya adalah fusi multi-fitur yang menggabungkan *embedding* dari ketiga sumber menjadi satu vektor representasi akhir untuk masing-masing obat. Representasi ini bersifat komprehensif karena menggabungkan informasi kimia lokal, struktur molekul, dan interaksi antarobat.

e. Prediksi Interaksi Obat

Representasi akhir obat-obatan yang telah digabungkan kemudian dimasukkan ke dalam *Multi-Layer Perceptron* (MLP) yang menghasilkan prediksi interaksi antara pasangan obat. Fungsi aktivasi sigmoid

digunakan pada *output layer* untuk menghasilkan prediksi biner atau *multi-label* terkait keberadaan interaksi beserta tipe efek samping atau risiko yang terkait, misalnya peningkatan risiko perdarahan atau gangguan pencernaan.

3. Keluaran

Keluaran dari modul ini adalah hasil prediksi interaksi obat yang mencakup informasi mengenai pasangan obat beserta probabilitas interaksi biner dalam rentang 0 hingga 1, *flag* keberadaan interaksi (*has_interaction*), status keandalan prediksi (*reliable/unreliable* berdasarkan ketersediaan obat dalam basis data pelatihan), serta probabilitas tipe interaksi yang terdiri atas empat kategori, yaitu *mechanism*, *effect*, *advise*, dan *int*. Contoh format keluaran ditunjukkan pada Gambar IV.3.

```
1 {  
2   "drug1": "warfarin",  
3   "drug2": "simvastatin",  
4   "ddi_probability": 0.8688,  
5   "has_interaction": true,  
6   "type_probabilities": [0.72, 0.15, 0.08, 0.05],  
7   "drug1_known": true,  
8   "drug2_known": true,  
9   "reliable": true  
10 }  
11
```

Gambar IV.3 Contoh Keluaran Terstruktur dari Modul Prediksi Interaksi Obat dengan MFFGNN

IV.1.4 Modul 3: Laporan & Penjelasan (RAG)

Modul terakhir bertugas untuk memberikan laporan dan penjelasan yang komprehensif terkait hasil prediksi interaksi obat (DDI) dan gejala yang dilaporkan oleh pasien. Pendekatan yang digunakan adalah *Retrieval-Augmented Generation* (RAG), yang memungkinkan sistem mengambil informasi relevan dari berbagai *knowledge base* medis terbuka seperti DrugBank dan TWOSIDES, untuk menghasilkan laporan yang sesuai dengan kebutuhan klinis.

1. Masukan

Pada tahap ini, sistem menerima 2 masukan, yaitu sebagai berikut.

a. Hasil Prediksi DDI dari MFFGNN

Modul ini menerima keluaran dari Modul 2 (Prediksi Interaksi Obat dengan MFFGNN), yang mencakup:

- i. pasangan obat yang terlibat (misalnya: warfarin dan simvastatin);

- ii. probabilitas prediksi interaksi (misalnya, 0.97 untuk kemungkinan interaksi); dan
- iii. tipe interaksi yang diprediksi (misalnya, “meningkatkan risiko perdarahan”).

b. Daftar Gejala yang Diekstraksi

Gejala yang dilaporkan pasien dan telah diekstraksi oleh Modul 1, misalnya mimisan, pusing, atau keluhan lain yang relevan dengan interaksi obat.

2. Proses

Proses penyusunan laporan melibatkan beberapa langkah:

a. Pencarian Penjelasan Mekanisme Interaksi Obat

Sistem melakukan *query* ke DrugBank untuk mencari penjelasan mekanisme interaksi, seperti efek farmakodinamik atau farmakokinetik ketika dua obat diberikan secara bersamaan.

b. Pencarian *Real-World Evidence*

Sistem kemudian melakukan pencarian ke TWOSIDES untuk menemukan bukti klinis yang menghubungkan interaksi obat yang diprediksi dengan gejala yang dilaporkan pasien. Data ini membantu memvalidasi apakah keluhan pasien konsisten dengan profil efek samping yang tercatat.

c. Penyusunan Laporan Berbasis *Knowledge Base*

Jika terdapat kecocokan antara prediksi dan gejala, sistem menggabungkan informasi dari DrugBank dan TWOSIDES untuk menyusun narasi penjelasan yang ilmiah namun mudah dipahami. Narasi mencakup mekanisme interaksi, penjelasan gejala, dan langkah yang perlu diambil, seperti pemantauan lebih lanjut atau konsultasi dokter.

3. Keluaran

Keluaran modul ini berupa laporan terstruktur dan mudah dipahami yang menjelaskan interaksi obat serta kaitannya dengan gejala pasien. Contoh narasi yang dapat dihasilkan sistem ditunjukkan pada Gambar IV.4.

IV.2 Perbandingan Sistem yang Ada dan Sistem yang Diusulkan

Bagian ini membahas secara rinci perbandingan antara CDSS berbasis aturan yang umum digunakan dalam layanan kesehatan dengan CDSS *hybrid* berbasis kecerdasan buatan yang diusulkan. Perbandingan mencakup alur masukan, proses deteksi interaksi obat, hingga keluaran edukasi dan rekomendasi yang dihasilkan, dengan fokus pada peningkatan kapabilitas deteksi, interpretasi, dan literasi medis.

1. Ringkasan Temuan Pasien mengonsumsi <i>mefenamic acid</i> dan <i>ranitidine</i> untuk mengatasi keluhan perih lambung. Berdasarkan data yang tersedia, tidak terdeteksi interaksi obat yang signifikan secara klinis antara <i>mefenamic acid</i> dan <i>ranitidine</i>. 2. Analisis Interaksi Obat Tidak ada interaksi obat yang signifikan yang terdeteksi antara <i>mefenamic acid</i> dan <i>ranitidine</i> berdasarkan sumber yang tersedia. 3. Korelasi Gejala dengan Interaksi Obat Gejala perih lambung yang dilaporkan pasien kemungkinan besar disebabkan oleh kondisi medis yang mendasarinya, bukan akibat interaksi antara <i>mefenamic acid</i> dan <i>ranitidine</i>. <i>Mefenamic acid</i> adalah obat antiinflamasi nonsteroid (OAINS) yang dapat menyebabkan iritasi lambung sebagai efek samping, sementara <i>ranitidine</i> adalah antagonis reseptor H2 yang digunakan untuk mengurangi produksi asam lambung dan meredakan gejala seperti perih lambung. Kombinasi ini seringkali digunakan untuk mengatasi nyeri dan gejala terkait asam lambung. 4. Rekomendasi Tindakan • Pemantauan: Pantau efektivitas pengobatan terhadap gejala perih lambung. Perhatikan potensi efek samping dari masing-masing obat, terutama iritasi lambung yang dapat disebabkan oleh <i>mefenamic acid</i>. • Penyesuaian Dosis: Jika gejala tidak membaik atau memburuk, atau jika muncul efek samping yang mengkhawatirkan, pertimbangkan untuk berkonsultasi dengan dokter mengenai penyesuaian dosis atau penggantian obat. • Alternatif Obat: Jika diperlukan, dokter dapat mempertimbangkan alternatif pengobatan untuk perih lambung atau nyeri yang mungkin memiliki profil efek samping yang berbeda. 5. Sumber Referensi [1] DrugBank. (n.d.). <i>Mefenamic acid ↔ Ranitidine Interaction</i>. Diambil dari drugbank/interaction. [6] TWOSIDES. (n.d.). <i>mefenamic acid + ranitidine</i>. Diambil dari two-sides/side_effects. Disclaimer Informasi ini dihasilkan oleh sistem AI untuk mendukung keputusan klinis. Informasi ini bersifat pendukung keputusan dan tidak menggantikan penilaian klinis profesional. Konsultasikan dengan dokter Anda untuk evaluasi dan tindakan lebih lanjut.

Gambar IV.4 Contoh Keluaran Narasi Laporan dan Penjelasan Berbasis RAG

IV.2.1 Sistem Pendukung Keputusan Klinis Konvensional (*Rule-Based*)

Sistem CDSS berbasis aturan (*rule-based*) merupakan pendekatan yang telah lama digunakan di berbagai fasilitas kesehatan. Sistem ini bekerja dengan menggunakan aturan yang ditetapkan sebelumnya untuk mendeteksi interaksi antarobat berdasarkan pasangan obat yang sudah terdokumentasi dalam basis data. Sebagian besar sistem CDSS tradisional hanya mengandalkan data terstruktur yang diperoleh dari resep dokter atau *order* farmasi. Berikut merupakan proses deteksi pada sistem konvensional.

1. Masukan

Data masukan berupa resep terstruktur yang mencakup nama obat dan dosis. Data ini biasanya berasal dari sistem informasi rumah sakit tanpa mempertimbangkan keluhan atau gejala pasien.

2. Proses

Proses deteksi interaksi dilakukan dengan mesin aturan berbasis logika *if-then* yang membandingkan kombinasi obat pada resep dengan pasangan obat berisiko dalam basis data. Jika ditemukan kecocokan, sistem akan memicu peringatan interaksi.

3. Keluaran

Keluaran berupa peringatan interaksi obat yang ditampilkan pada layar resep digital dan hanya dapat diakses oleh tenaga medis. Peringatan biasanya bersifat singkat, misalnya: “Interaksi warfarin dengan simvastatin, risiko perdarahan,” tanpa penjelasan mekanisme atau rekomendasi tindakan lanjutan.

Sistem CDSS konvensional memiliki beberapa kelemahan utama sebagai berikut:

1. Sistem tidak dapat memproses keluhan berbasis narasi bebas yang disampaikan oleh pasien. Sistem hanya bergantung pada data terstruktur, seperti nama obat dan dosis, yang terbatas pada masukan yang disediakan oleh dokter atau apoteker.
2. Peringatan yang diberikan oleh sistem bersifat generik dan tidak dipersonalisasi sesuai dengan kondisi pasien. Peringatan ini tidak menghubungkan interaksi obat dengan gejala spesifik yang dialami pasien, sehingga kurang membantu dalam konteks medis yang lebih kompleks.
3. Sistem menggunakan basis data statis yang jarang diperbarui, sehingga informasi yang diberikan bisa saja usang dan tidak mencakup interaksi obat terbaru yang belum tercatat.
4. Sistem hanya dapat diakses oleh tenaga medis seperti dokter atau apoteker, sehingga pasien tidak mendapatkan edukasi langsung mengenai risiko interaksi obat atau informasi terkait kondisi medis mereka.

IV.2.2 Sistem CDSS *Hybrid* Usulan Berbasis Kecerdasan Buatan

Sistem CDSS *hybrid* yang diusulkan mengintegrasikan beberapa teknologi canggih, termasuk NLP untuk pemrosesan keluhan naratif pasien, MFFGNN untuk prediksi interaksi obat, dan RAG untuk memberikan penjelasan serta rekomendasi berbasis *knowledge base* medis terbuka seperti DrugBank dan TWOSIDES. Alur rinci komponen sistem telah dijelaskan pada Subbab IV bagian sebelumnya.

Sistem CDSS *hybrid* memiliki beberapa kelebihan jika dibandingkan dengan sistem CDSS konvensional, yaitu:

1. Sistem *hybrid* dapat memproses keluhan pasien berbasis narasi bebas, yang memungkinkan deteksi interaksi obat berdasarkan gejala yang dialami oleh pasien, bukan hanya berdasarkan resep dokter. Hal ini memberikan konteks

yang lebih komprehensif dalam menganalisis potensi interaksi obat

2. Menggunakan model MFFGNN, sistem dapat memprediksi interaksi obat yang lebih akurat dan adaptif, memanfaatkan data kimia global, graf molekul, dan relasi DDI yang terus diperbarui, tanpa bergantung pada basis data lokal yang terbatas.
3. Laporan yang dihasilkan oleh sistem tidak hanya mencakup prediksi interaksi obat, tetapi juga memberikan penjelasan mendalam tentang mekanisme interaksi, efek samping yang relevan, serta rekomendasi langkah yang harus diambil.
4. Sistem ini memungkinkan pemberian edukasi berbasis bukti kepada pasien dan tenaga medis, serta memberikan rekomendasi yang lebih relevan dan diperbarui berdasarkan sumber medis terpercaya, seperti DrugBank dan TWOSIDES.

IV.2.3 Perbandingan Alur Kerja Sistem Konvensional dengan Sistem Usulan

Perbandingan antara sistem CDSS berbasis aturan (*rule-based*) yang ada dengan sistem CDSS *hybrid* berbasis kecerdasan buatan yang diusulkan ditunjukkan pada Tabel IV.1.

IV.3 Diagram Sistem dan Alur Kerja

Bagian ini menguraikan diagram sistem dan alur kerja dari CDSS *hybrid* yang diusulkan. Setiap diagram memberikan gambaran mengenai aliran data, interaksi antar komponen, serta proses dari masukan hingga keluaran sistem.

IV.3.1 Diagram Konteks

Diagram konteks pada Gambar IV.5 memberikan gambaran besar mengenai alur data dalam CDSS *hybrid*. Aliran data dimulai dari entitas eksternal, yaitu pasien yang memasukkan gejala dalam bentuk narasi bebas, misalnya: “Saya rutin minum warfarin dan simvastatin, belakangan sering mimisan dan pusing.” Narasi ini diproses oleh modul NLP/NER untuk mengekstraksi entitas medis, yang kemudian diteruskan ke modul MFFGNN guna memprediksi interaksi obat berbasis dataset DDI. Hasil prediksi dan bukti pendukung dari *knowledge base* medis eksternal selanjutnya digunakan oleh modul RAG untuk menghasilkan laporan rekomendasi medis yang komprehensif dan dikembalikan kepada pasien.

IV.3.2 Diagram Alur Proses Sistem

Diagram alur proses pada Gambar IV.6 menunjukkan tahapan operasional CDSS *hybrid* secara berurutan. Proses dimulai dari titik *Start* ketika sistem menerima masukan keluhan naratif dan daftar obat dari pasien. Modul NLP/NER mengekstraksi

Tabel IV.1 Perbandingan Alur Kerja Sistem CDSS Konvensional dan CDSS *Hybrid*

Aspek	Sistem CDSS Lama	Sistem CDSS <i>Hybrid</i>
Masukan	Data terstruktur dari resep (nama obat dan dosis)	Keluhan gejala naratif pasien (misalnya: “mimisan setelah warfarin”) dan daftar obat yang dikonsumsi
Proses deteksi	Mesin aturan berbasis logika <i>if-then</i> dengan basis data interaksi statis	NLP untuk ekstraksi entitas medis, pemetaan SMILES/graf molekul, dan prediksi interaksi dengan MFFGNN
Keluaran	Peringatan interaksi obat singkat untuk tenaga medis	Laporan terperinci yang mencakup prediksi interaksi, penjelasan mekanisme, dan rekomendasi medis berbasis bukti
Personalisasi	Peringatan bersifat generik, tidak mempertimbangkan gejala aktual pasien	Laporan dan rekomendasi dipersonalisasi sesuai kondisi dan gejala yang dilaporkan pasien
Edukasi	Tidak menyediakan edukasi langsung bagi pasien	Menyediakan edukasi medis berbasis bukti untuk pasien dan tenaga medis


entitas obat dan gejala, kemudian nama-nama obat yang dikenali dipetakan ke format SMILES dan graf molekul. Informasi ini bersama jaringan DDI digunakan oleh model MFFGNN untuk memprediksi interaksi. Hasil prediksi diteruskan ke modul RAG yang melakukan *query* ke *knowledge base* medis, menyusun penjelasan dan rekomendasi klinis, dan akhirnya menghasilkan laporan kembali ke pasien sebagai titik *End* alur proses.

IV.3.3 Diagram Konseptual Arsitektur Sistem

Diagram konseptual arsitektur sistem pada Gambar IV.7 menggambarkan suatu *pipeline* otomatis yang dimulai dari masukan naratif pasien hingga produk akhir berupa laporan edukasi berbasis bukti mengenai deteksi interaksi obat, efek samping potensial, dan tindak lanjut yang direkomendasikan.

1. Modul 1: *Natural Language Processing & Named Entity Recognition Layer*

Modul ini menangani proses awal yang menerima masukan teks bebas dari pasien, kemudian mengidentifikasi dan mengekstraksi entitas medis utama yaitu nama obat dan gejala. Tahapan utama modul ini meliputi:




Gambar IV.5 Diagram Konteks Sistem CDSS *Hybrid*

- a. **Post-processing Entitas** yang menerapkan serangkaian tahapan pemberian dan normalisasi terhadap entitas hasil ekstraksi, meliputi normalisasi *lowercase*, penghapusan informasi dosis, penghapusan akhiran bahasa Indonesia (*-nya, -mu, -ku*), penyaringan kata henti medis, pemisahan entitas gabungan, resolusi alias nama obat Indonesia ke nama internasional, serta deduplikasi entitas.
- b. **NER Model for Drug Extraction** yang memanfaatkan model seperti BERT atau IndoBERT untuk mengenali nama obat dan gejala.
- c. **Drug Mapping & SMILES Conversion** yang mengonversi nama obat hasil ekstraksi menjadi format SMILES dan representasi graf molekul agar dapat diproses oleh model berbasis graf.

2. Modul 2: MFFGNN *Prediction Layer*

Modul ini berfokus pada prediksi interaksi obat menggunakan model berbasis *graph neural network*. Masukan yang digunakan adalah struktur SMILES,



Gambar IV.6 Diagram Alur Proses Sistem CDSS *Hybrid*

graf molekuler, dan jaringan interaksi DDI. Komponen utama MFFGNN meliputi:


- SSFEM Bi-GRU + *Attention*** untuk menghasilkan *embedding* urutan kimia dari SMILES.
- MGFEM GIN + GWU** sebagai ekstraktor fitur dari graf molekul yang menangkap informasi hubungan atom dan substruktur.
- Fusion GCN Encoder*** yang menggabungkan fitur dari berbagai representasi dan menghasilkan prediksi akhir mengenai label interaksi, probabilitas, tingkat keparahan, dan tipe efek interaksi.

3. Modul 3: RAG *Explanation Layer*

Modul ini bertujuan untuk memberikan penjelasan yang dapat dipahami mengenai hasil prediksi. Tahapannya meliputi:

- a. **Knowledge Retrieval** melalui basis data vektor yang terhubung ke Drug-Bank dan TWOSIDES untuk mengambil informasi mekanisme dan bukti klinis;
- b. **LLM Generated Result** yang memanfaatkan *Large Language Model* untuk menghasilkan penjelasan naratif yang koheren; dan
- c. **Output Result** berupa laporan berisi mekanisme, korelasi antara interaksi dan gejala, rekomendasi tindakan, serta referensi ilmiah.

Sistem juga terhubung dengan *database* eksternal secara *retrieval* sehingga informasi obat dan interaksi dapat terus diperbarui. Dengan demikian, arsitektur CDSS *hybrid* ini memungkinkan pendeteksian interaksi obat yang lebih cepat dan akurat, memberikan penjelasan yang mudah dipahami, serta mempercepat pengambilan keputusan medis yang tepat sehingga meningkatkan keselamatan pasien dalam praktik klinis.




Gambar IV.7 Diagram Konseptual Arsitektur Sistem CDSS *Hybrid*

BAB V

IMPLEMENTASI

Bab ini menjelaskan implementasi sistem *Clinical Decision Support System* (CDSS) berbasis *hybrid* yang telah dirancang pada Bab IV. Pembahasan mencakup lingkungan pengembangan, implementasi setiap modul, yaitu NER, DDI, dan RAG, mekanisme resolusi alias nama obat, antarmuka pemrograman aplikasi (API), serta antarmuka web yang disediakan.

Sistem terdiri atas tiga modul utama yang saling terhubung dalam satu *pipeline* sekuensial, yaitu NER, DDI, dan RAG. Ketiga modul tersebut diintegrasikan oleh kelas CDSSPipeline pada `main_pipeline.py`. Setiap modul dimuat secara *lazy* (*on-demand*) untuk mengoptimalkan penggunaan memori. Alur eksekusi *pipeline* ditunjukkan pada Gambar V.1.



Gambar V.1 Alur Eksekusi *Pipeline* Implementasi Sistem CDSS Hybrid

Proses eksekusi diawali dari masukan berupa teks keluhan pasien yang dinormalisasi terlebih dahulu. Modul NER kemudian memproses teks tersebut untuk mengekstraksi entitas berupa daftar obat dan gejala. Daftar obat selanjutnya melewati tahap resolusi alias agar nama obat sesuai dengan basis data yang digunakan pada modul DDI.

Apabila terdapat dua atau lebih obat yang valid, modul DDI menjalankan prediksi interaksi untuk seluruh pasangan obat yang mungkin. Sebaliknya, jika jumlah obat kurang dari dua, tahap ini dilewati dan daftar prediksi dikosongkan. Hasil ekstraksi dari modul NER, prediksi dari modul DDI, serta dokumen referensi dari modul RAG kemudian dikonsolidasikan menjadi laporan klinis sebagai keluaran akhir.

Mekanisme penanganan kesalahan diterapkan pada setiap tahap dengan blok `try/except`, sehingga kegagalan pada satu modul tidak menghentikan keseluruhan *pipeline*. Apabila modul NER gagal, daftar entitas kosong tetap diteruskan ke tahap berikutnya. Apabila modul DDI gagal, daftar prediksi interaksi dikosongkan. Apabila modul RAG gagal, sistem akan menghasilkan laporan kesalahan terstruktur sebagai pengganti laporan klinis.

V.1 Lingkungan Pengembangan

Sistem diimplementasikan menggunakan bahasa pemrograman Python versi 3.12 dengan beberapa pustaka utama sebagai berikut.

- **PyTorch (versi 2.0 ke atas)** digunakan sebagai *framework deep learning* utama untuk pelatihan dan inferensi model NER dan DDI.
- **Hugging Face Transformers (versi 4.35 ke atas)** digunakan untuk memuat dan melakukan *fine-tuning* model IndoBERT.
- **Pustaka pytorch-crf (versi 0.7.2 ke atas)** digunakan untuk mengimplementasi lapisan *Conditional Random Field* (CRF) pada model NER.
- **PyTorch Geometric (PyG) (versi 2.4 ke atas)** digunakan dalam pengolahan *graph neural network* pada model MFFGNN.
- **RDKit (versi 2023.9 ke atas)** digunakan untuk mengonversi SMILES menjadi graf molekul serta ekstraksi fitur atom dan ikatan.
- **LangChain (versi 0.1 ke atas)** dan **FAISS (versi 1.7 ke atas)** digunakan untuk penyimpanan dan pencarian dokumen berbasis vektor pada modul *Retrieval-Augmented Generation* (RAG).
- **Google GenAI (Gemini 2.5 Flash/Flash-Lite)** digunakan sebagai *Large Language Model* (LLM) untuk generasi laporan klinis.
- **FastAPI (versi 0.104 ke atas)** digunakan untuk menyediakan layanan REST API serta mendukung antarmuka web.

Proses pelatihan dan inferensi dilakukan pada CPU (*Intel Core*). Konfigurasi sistem disimpan dalam berkas YAML tunggal (`configs/default.yaml`) yang mengatur *hyperparameter*, jalur data, serta pengaturan masing-masing modul.

V.2 Implementasi Modul NER

V.2.1 Persiapan Data NER

Data pelatihan untuk tugas *Named Entity Recognition* (NER) dibangun secara sintetis melalui beberapa tahapan dalam *pipeline* sebagai berikut.

1. Parsing Korpus DDI2013

Tahap awal dilakukan dengan mengekstraksi kalimat, entitas, dan relasi dari korpus XML DDI2013 (Herrero-Zazo dkk. 2013), termasuk informasi tipe relasi (*mechanism*, *effect*, *advise*, *int*) dan rentang teks entitas obat.

2. Generasi Kalimat Indonesia berbasis *template*

Kalimat dalam bahasa Indonesia dihasilkan menggunakan pendekatan berbasis *template* yang dipandu oleh metadata terstruktur dari DDI2013, bukan melalui penerjemahan kata-per-kata dari kalimat sumber bahasa Inggris (diimplementasikan pada modul `data_pipeline/translator.py`). Proses ini terdiri dari tiga komponen, yaitu sebagai berikut.

- a. Untuk pasangan dengan tipe relasi tertentu (*mechanism*, *effect*, *advise*, *int*), kalimat dibentuk menggunakan beberapa *template* yang divariasikan secara acak (misalnya *mechanism* $\rightarrow$ {drug1} memengaruhi metabolisme {drug2}). Nama obat ({drug1}, {drug2}) dimasukkan langsung dari entitas asli sehingga tetap mempertahankan bentuk generik (INN).
- b. Klausa tambahan (*effect text*) diterjemahkan secara sederhana menggunakan kamus yang mencakup sekitar 140 pemetaan istilah medis (efek farmakologi, gejala, organ, terminologi farmakokinetik), kemudian digabungkan ke dalam kalimat hasil *template*.
- c. Untuk kasus tanpa tipe relasi spesifik, digunakan pendekatan (jalur *fallback*) berupa translasi langsung dengan mekanisme *placeholder*. Perubahan setiap nama obat diganti sementara dengan token khusus (misalnya `__DRUG0__`) sebelum proses translasi dan dikembalikan setelah proses selesai.

Pendekatan ini dipilih untuk menjaga konsistensi istilah medis, meskipun variasi linguistik yang lebih terbatas dibandingkan *neural machine translation*.

3. Adaptasi Gaya Bahasa

Kalimat yang dihasilkan kemudian disesuaikan dengan gaya bahasa yang lebih menyerupai keluhan pasien, seperti penggunaan sudut pandang orang pertama, bentuk informal, pertanyaan, dan naratif.

4. Augmentasi Data

Ukuran *dataset* diperbesar sebanyak empat kali lipat melalui variasi berbasis aturan serta bantuan LLM (Gemini).

5. Anotasi BIO

Span entitas diekstraksi secara otomatis untuk menghasilkan label dalam format BIO (*Begin-Inside-Outside*).

6. Kontrol Kualitas

Dataset selanjutnya melalui proses validasi yang meliputi jumlah minimum entitas, batas panjang teks maksimum (512 karakter), serta deduplikasi dua-tahap. Tahap pertama dilakukan melalui pencocokan teks secara eksak setelah normalisasi spasi/kapitalisasi. Tahap kedua menggunakan pendekatan kemiripan berbasis himpunan kata untuk mendeteksi sampel dengan komposisi kata yang identik sebagai *near-duplicate detection*.

Dataset akhir kemudian dibagi ke dalam data latih, validasi, dan uji dengan rasio 80:10:10.

V.2.2 Arsitektur Model IndoBERT-CRF

Model NER pada penelitian ini menggunakan arsitektur IndoBERT *Base* (indobenchmark/indobert-base-p1) yang dikombinasikan dengan lapisan *Conditional Random Field* (CRF) seperti yang telah diuraikan pada Bagian II.4.4. Implementasi arsitektur model ditunjukkan pada Algoritma V.1.

Arsitektur model terdiri dari beberapa komponen utama, yaitu lapisan *encoder* BERT, lapisan *dropout*, lapisan klasifikasi berbasis linear, serta lapisan CRF untuk pemodelan dependensi antar label. Lapisan *dropout* digunakan untuk mengurangi risiko *overfitting*, sedangkan lapisan CRF berfungsi untuk meningkatkan konsistensi prediksi label pada urutan token.

Sistem pelabelan menggunakan skema BIO (*Begin-Inside-Outside*) dengan tujuh kelas, yaitu B-DRUG, I-DRUG, B-SYMPTOM, I-SYMPTOM, B-DISEASE, I-DISEASE, dan O. Untuk meningkatkan efisiensi komputasi, sebagian besar parameter pada model BERT dibekukan. Sebanyak sebelas dari dua belas lapisan *encoder* BERT beserta lapisan *embedding* tidak diperbarui selama proses pelatihan. Hanya lapisan *encoder* terakhir BERT, lapisan klasifikasi linear, dan lapisan CRF yang dilatih.

V.2.3 Pelatihan Model NER

Proses pelatihan model dilakukan menggunakan metode validasi silang (*cross-validation*) *K-Fold* dengan nilai ($K = 5$). Setiap *fold* digunakan secara bergantian sebagai data validasi, sementara sisanya digunakan sebagai data pelatihan. Konfigurasi *hyperparameter* pelatihan lengkap, termasuk strategi pembekuan lapisan

Algoritma V.1 Inisialisasi arsitektur model IndoBERT–CRF untuk NER

Require: $model_name, num_labels, freeze_layers \leftarrow 11$

Ensure: Komponen $\langle bert, dropout, classifier, crf \rangle$

```
1: procedure BUILD-INDOBERTCRF( $model\_name, num\_labels,$   
    $freeze\_layers$ )  
2:                                     ▷ Inisialisasi komponen arsitektur  
3:    $bert \leftarrow \text{LOADPRETRAINED}(model\_name)$  ▷ IndoBERT,  $hidden = 768$ , 12  
   lapisan encoder  
4:    $dropout \leftarrow \text{DROPOUT}(p = 0.1)$   
5:    $classifier \leftarrow \text{LINEAR}(768, num\_labels)$   
6:    $crf \leftarrow \text{CRF}(num\_labels)$   
7:                                     ▷ Bekukan parameter agar tidak diperbarui saat pelatihan  
8:   for all  $param \in bert.embeddings$  do  
9:      $param.requires\_grad \leftarrow \text{false}$   
10:  end for  
11:  for  $i \leftarrow 0$  to  $freeze\_layers - 1$  do  
12:    for all  $param \in bert.encoder.layer[i]$  do  
13:       $param.requires\_grad \leftarrow \text{false}$   
14:    end for  
15:  end for  
16:                                     ▷ Encoder layer terakhir, classifier, dan crf tetap dilatih  
17:  return  $\langle bert, dropout, classifier, crf \rangle$   
18: end procedure
```

BERT, disajikan pada Lampiran C.1.

Jumlah *epoch* ditetapkan sebanyak satu kali karena model telah mencapai konvergensi dengan cepat, ditunjukkan oleh nilai F1 yang melebihi 0,99 pada *epoch* pertama.

Untuk setiap *fold*, model terbaik dipilih berdasarkan nilai F1 tertinggi pada data validasi. Untuk menjaga efisiensi penggunaan memori, dilakukan penghapusan tensor secara eksplisit setelah setiap *batch*, serta proses pengumpulan sampah (*garbage collection*) secara berkala setiap 20 *batch*.

V.2.4 Inferensi NER dan Pasca-Pemrosesan

Sebelum proses inferensi dilakukan, teks masukan terlebih dahulu dinormalisasi menjadi huruf kecil *lowercase*. Tahap ini penting karena model IndoBERT lebih optimal pada teks *lowercase*. Dengan demikian, masukan yang ditulis seluruhnya dalam huruf kapital, seperti “SAYA MINUM WARFARIN DAN ASPIRIN” tetap dapat diproses dan diekstraksi entitasnya dengan benar.

Proses inferensi NER dilakukan melalui beberapa tahapan sebagai berikut.

1. Teks masukan ditokenisasi menggunakan *tokenizer* IndoBERT dengan parameter `is_split_into_words=True`.
2. Pemetaan kembali dilakukan dari token hasil *subword tokenization* ke kata asli menggunakan `word_ids`.
3. Lapisan CRF melakukan proses dekoding menggunakan algoritma Viterbi untuk menghasilkan urutan label BIO yang konsisten.
4. Ekstraksi entitas berdasarkan urutan label BIO yang dihasilkan.

Hasil ekstraksi NER selanjutnya diproses melalui tahap pasca-pemrosesan pada tingkat *pipeline* untuk meningkatkan akurasi entitas. Tahapan tersebut meliputi:

1. **Pemisahan entitas gabungan**

Entitas yang mengandung lebih dari satu item dan dipisahkan dengan koma, dipecah menjadi beberapa entitas terpisah. Sebagai contoh, “simvastatin, metformin” dipisahkan menjadi dua entitas terpisah.

2. **Penghapusan informasi dosis**

Informasi dosis dihilangkan menggunakan *regular expression*, misalnya “warfarin 5mg” menjadi “warfarin”.

3. **Penghapusan akhiran bahasa Indonesia**

Akhiran seperti *-nya*, *-mu*, *-ku*, *-lah*, dan *-kah* yang menempel pada nama obat dihapus, misalnya “warfarinnya” menjadi “warfarin”.

4. **Penyaringan kata henti obat**

Kata-kata umum yang bukan merupakan nama obat disaring menggunakan daftar `DRUG_STOPWORDS`, seperti “obat”, “tablet”, “vitamin”, “sayur”, “makanan”, dan “minuman”.

5. **Penyaringan kata henti gejala**

Kata-kata umum yang bukan merupakan gejala medis disaring menggunakan daftar `SYMPTOM_STOPWORDS`. Daftar ini mencakup kata keterangan waktu (misalnya “pagi”, “malam”, “siang”), kata kerja atau sifat umum (misalnya “mau”, “ingin”, “bisa”, “tidak”, “sudah”), serta aktivitas sehari-hari (“tidur”, “makan”, “jalan”, “kerja”, “duduk”, “bicara”). Daftar dapat diperbarui secara bertahap berdasarkan hasil pengujian terhadap keluhan pasien nyata. Rincian lengkap kedua daftar kata henti tersebut disajikan pada Lampiran D.2 (Tabel D.2).

6. **Penyaringan token numerik dan pendek**

Token yang hanya berisi angka atau memiliki panjang kurang dari 3 karakter dihapus.

7. **Resolusi alias nama obat**

Nama obat dalam berbagai variasi penulisan dipetakan ke nama yang sesuai dalam basis data ChCh-Miner melalui kamus DRUG_ALIASES. Detail mekanisme ini dijelaskan pada Bagian V.3.

8. Deduplikasi entitas

Entitas yang duplikat dihapus dengan pendekatan *case-insensitive* dengan mempertahankan urutan kemunculan pertama.

V.3 Resolusi Alias Nama Obat

Sebelum hasil ekstraksi NER diteruskan ke modul DDI, nama obat perlu dinormalisasi terlebih dahulu agar dapat dicocokkan dengan basis data interaksi obat. Bagian ini menjelaskan mekanisme resolusi alias yang menjembatani perbedaan penamaan obat antara keluaran NER (Bahasa Indonesia) dengan basis data DDI (ChCh-Miner).

Basis data DDI yang digunakan, yaitu ChCh-Miner, menerapkan standar penamaan obat berdasarkan USAN (*United States Adopted Names*). Sementara itu, dalam praktik sehari-hari, pasien Indonesia cenderung menggunakan nama obat berdasarkan standar INN (*International Nonproprietary Names*) atau bentuk ejaan yang telah diadaptasi ke bahasa Indonesia. Perbedaan standar penamaan ini menyebabkan nama obat yang diekstraksi oleh NER tidak selalu dapat langsung ditemukan dalam basis data. Oleh karena itu, diperlukan mekanisme resolusi alias untuk menyelaraskan perbedaan sebelum prediksi DDI dijalankan.

V.3.1 Implementasi Kamus Alias

Kamus alias diimplementasikan sebagai konstanta DRUG_ALIASES pada dokumen `main_pipeline.py`, yang memetakan 130 variasi nama obat ke bentuk nama yang digunakan dalam basis data ChCh-Miner. Cuplikan kamus alias ditunjukkan pada Tabel V.1.

Secara umum, alias yang digunakan dapat dikelompokkan ke dalam tiga kategori:

1. Perbedaan INN dan USAN

Mencakup nama obat yang berbeda antara standar internasional dan standar Amerika Serikat, misalnya paracetamol dipetakan ke acetaminophen, pethidine ke meperidine, lignocaine ke lidocaine, serta adrenaline ke epinephrine.

2. Adaptasi ejaan bahasa Indonesia

Mencakup nama obat yang mengalami penyesuaian ejaan, seperti amoksisilin menjadi amoxicillin, siprofloksasin menjadi ciprofloxacin, dan deksametason menjadi dexamethasone.

3. Nama komposit

Mencakup nama obat yang mengandung bentuk garam atau informasi tamba-

Tabel V.1 Cuplikan Kamus Alias Nama Obat (DRUG_ALIASES, total 130 entri)

Alias masukan	Bentuk kanonik
<i>Perbedaan INN dan USAN</i>	
paracetamol	acetaminophen
parasetamol	acetaminophen
pethidine	meperidine
lignocaine	lidocaine
adrenaline	epinephrine
albuterol	salbutamol
ciclosporin	cyclosporin a
<i>Adaptasi ejaan bahasa Indonesia</i>	
amoksisilin	amoxicillin
siprofloksasin	ciprofloxacin
diklofenak	diclofenac
karbamazepin	carbamazepine
deksametason	dexamethasone
lansoprazol	lansoprazole
... (total 130 alias)	

han, misalnya natrium diklofenak dipetakan ke diclofenac, asam mefenamat ke *mefenamic acid*, dan asam valproat ke *valproic acid*.

V.3.2 Mekanisme Resolusi dan Keterbatasan

A. Proses Resolusi dalam *Pipeline*

Proses resolusi alias dilakukan pada metode `_filter_entities()` setelah tahap pembersihan awal yang meliputi penghapusan dosis, akhiran, dan kata henti. Nama obat yang telah dinormalisasi ke huruf kecil kemudian dicocokkan dengan entri dalam kamus DRUG_ALIASES. Apabila ditemukan kecocokan, nama obat akan digantikan dengan bentuk yang sesuai dalam basis data DDI. Proses ini dilakukan sebelum tahap validasi keberadaan obat dalam basis data SMILES, sehingga obat yang awalnya tidak dikenal dapat diselesaikan terlebih dahulu sebelum diproses lebih lanjut pada modul DDI.

B. Obat yang Tidak Tersedia dalam Basis Data

Meskipun mekanisme resolusi alias telah diterapkan, masih terdapat lima obat yang sering muncul dalam resep di Indonesia namun tidak ditemukan sama sekali dalam basis data ChCh-Miner, yaitu *doxycycline*, *glimepiride*, *clindamycin*, *omeprazole*, dan *ranitidine*. Untuk kasus tersebut, sistem tidak melakukan prediksi interaksi obat

dan menandai hasil sebagai `reliable=False`. Informasi mengenai keterbatasan ini juga disampaikan secara eksplisit dalam laporan klinis yang dihasilkan.

V.4 Implementasi Modul DDI

V.4.1 Persiapan Data DDI

Data untuk modul *Drug-Drug Interaction* (DDI) diperoleh dari *dataset* ChCh-Miner (BioSNAP) yang berisi pasangan interaksi obat dari DrugBank. Tahapan persiapan data dilakukan sebagai berikut.

1. **Parsing data**

Data awal berupa dokumen TSV yang berisi pasangan ID DrugBank, dengan jumlah sekitar 48.514 pasangan dan mencakup kurang lebih 1.514 obat unik.

2. **Pemetaan identitas obat**

Setiap ID DrugBank dipetakan ke nama obat dan representasi SMILES menggunakan API PubChem.

3. **Pembentukan sampel negatif**

Pasangan obat yang tidak memiliki interaksi dibangkitkan secara acak dengan rasio 1:1 terhadap pasangan positif.

4. **Pembagian data**

Dataset dibagi menjadi data latih, validasi, dan pengujian dengan rasio 80:10:10.

Setelah proses tersebut, diperoleh 1.332 obat unik, dengan total 66.678 pasangan data latih, 8.506 pasangan validasi, dan 8.508 pasangan pengujian. Graf DDI yang terbentuk memiliki 83.348 sisi.

V.4.2 Arsitektur MFFGNN

Model prediksi DDI mengimplementasikan arsitektur MFFGNN (*Multi-type Feature Fusion Graph Neural Network*) yang terdiri dari tiga cabang *encoder* dan satu modul fusi, sebagaimana dirancang pada Bab IV.

A. Cabang *Encoder* SMILES (Bi-GRU)

Representasi SMILES dikodekan pada tingkat karakter menggunakan skema ASCII (`vocab_size=128`, `embed_dim=64`). Representasi ini kemudian diproses menggunakan jaringan Bi-GRU dua lapis. Rincian inisialisasi komponen arsitektur *encoder* SMILES ditunjukkan pada Algoritma V.2.

Untuk memperoleh representasi global, digunakan mekanisme *attention pooling* yang mengagregasi keluaran GRU menjadi vektor berdimensi 128 (`h_smiles`).

Algoritma V.2 Inisialisasi arsitektur *encoder* SMILES berbasis Bi-GRU dengan mekanisme atensi

Ensure: Komponen $\langle embedding, gru, attention, output_proj \rangle$

```
1: procedure BUILD-SMILESENCODER()  
2:                                     ▷ Hyperparameter tetap  
3:    $vocab\_size \leftarrow 128$                                      ▷ jumlah karakter ASCII  
4:    $embed\_dim \leftarrow 64$   
5:    $hidden\_dim \leftarrow 128$   
6:    $num\_layers \leftarrow 2$   
7:                                     ▷ Komponen arsitektur  
8:    $embedding \leftarrow \text{EMBEDDING}(vocab\_size, embed\_dim, padding\_idx = 0)$   
9:    $gru \leftarrow \text{BIDIRECTIONALGRU}(embed\_dim, hidden\_dim, num\_layers)$   
10:   $attention \leftarrow \text{LINEAR}(2 \cdot hidden\_dim, 1)$   
11:   $output\_proj \leftarrow \text{LINEAR}(2 \cdot hidden\_dim, hidden\_dim)$   
12:  return  $\langle embedding, gru, attention, output\_proj \rangle$   
13: end procedure
```

B. Cabang *Encoder* Graf Molekul (GIN + GWU)

Setiap SMILES dikonversi menjadi graf molekul menggunakan RDKit dengan fitur atom berdimensi 143 dan fitur ikatan berdimensi 8. Fitur atom terdiri dari:

- Nomor atom: 118 dimensi (*one-hot*)
- Derajat ikatan: 6 dimensi
- Muatan formal: 5 dimensi
- Jumlah hidrogen: 5 dimensi
- Hibridisasi: 5 dimensi (SP, SP2, SP3, SP3D, SP3D2)
- Aromatisitas: 2 dimensi
- Keberadaan dalam cincin: 2 dimensi

Graf molekul kemudian diproses oleh tiga lapisan GIN (*Graph Isomorphism Network*) yang dilengkapi dengan koneksi residual, *batch normalization*, dan *dropout*. Keluaran dari GIN selanjutnya diproses oleh lapisan GWU (*Graph Wavelet Unitary*) yang menerapkan mekanisme *gating* untuk menggabungkan dua representasi fitur.

$$\text{gate} = \sigma(W_g[h_1 || h_2] + b_g), \quad \text{output} = \text{gate} \cdot h_1 + (1 - \text{gate}) \cdot h_2$$

Tahap *graph-level pooling* menggunakan kombinasi operasi *sum* dan *mean* untuk menghasilkan vektor representasi berdimensi 128 (h_{mol}).

C. Cabang *Encoder* Graf DDI (GCN)

Seluruh obat dalam basis data direpresentasikan sebagai graf DDI di mana setiap simpul merepresentasikan sebuah obat dan setiap sisi menunjukkan interaksi yang diketahui. Fitur awal simpul berupa *embedding* berdimensi 128 yang diinisialisasi secara acak dari distribusi normal. Representasi ini diproses menggunakan dua lapisan GCN (*Graph Convolutional Network*) dengan koneksi residual dan *batch normalization*. Representasi akhir untuk setiap obat diperoleh melalui proses *lookup* berdasarkan indeks obat, menghasilkan vektor berdimensi 128 (h_{ddi}).

D. Modul Fusi Berbasis Atensi

Ketiga representasi (h_{smiles} , h_{mol} , h_{ddi}) digabungkan menggunakan mekanisme *attention-gated fusion*:

1. Setiap representasi diproyeksikan ke dimensi yang sama (128) melalui lapisan linear.
2. Bobot atensi dihitung oleh MLP: $384 \rightarrow 128 \rightarrow 3$, diikuti *softmax*.
3. Penjumlahan berbobot menghasilkan vektor gabungan.
4. Mekanisme *gating* ($\sigma(W \cdot h + b) \odot h$) dan *layer normalization* diterapkan.

E. Kepala Prediksi

Untuk setiap pasangan obat, vektor gabungan kedua obat dikonkatenasi ($[h_{drug1} || h_{drug2}]$, dimensi 256) dan diproses oleh MLP dengan dua kepala prediksi:

- Kepala biner: Linear($128 \rightarrow 1$) dengan *sigmoid*, menghasilkan probabilitas interaksi.
- Kepala tipe: Linear($128 \rightarrow 4$) dengan *sigmoid*, menghasilkan probabilitas untuk setiap tipe interaksi (*mechanism*, *effect*, *advise*, *int*).

V.4.3 Pelatihan Model DDI

Konfigurasi *hyperparameter* pelatihan model DDI, mencakup rincian arsitektur lengkap MFFGNN beserta dimensi setiap *encoder* (SMILES Bi-GRU, GIN+GWU pada graf molekul, GCN pada graf DDI) dan konfigurasi modul *fusion* serta *predictor*, disajikan pada Lampiran C.2. Konfigurasi modul RAG, termasuk model *embedding* dan parameter *retrieval*, dipaparkan pada Lampiran C.3.

Model terbaik dipilih berdasarkan ROC-AUC tertinggi pada data validasi. *Checkpoint* disimpan mencakup bobot model, *optimizer state*, fitur simpul DDI yang telah dipelajari, serta sisi graf DDI. Proses inferensi DDI untuk setiap pasangan obat dilakukan melalui beberapa tahap berikut.

1. Validasi keberadaan obat

Sistem memeriksa apakah kedua obat terdapat dalam basis data SMILES. Jika

salah satu atau kedua obat tidak ditemukan, proses prediksi tidak dilakukan dan pasangan ditandai sebagai `reliable=False`.

2. Validasi graf molekul

SMILES dari masing-masing obat diverifikasi apakah dapat dikonversi menjadi graf molekul yang valid menggunakan RDKit. Jika proses ini gagal, prediksi dilewati.

3. Prediksi

Jika kedua obat valid, model menjalankan *forward pass* untuk menghasilkan probabilitas interaksi biner dan probabilitas tipe interaksi.

Keputusan untuk tidak menggunakan graf molekul buatan (*dummy graph*) bagi obat yang tidak dikenal diambil untuk menghindari prediksi yang tidak akurat. Dengan demikian, prediksi hanya dilakukan ketika data yang tersedia dianggap memadai dan representatif.

V.5 Implementasi Modul RAG

V.5.1 Basis Pengetahuan dan Indeks FAISS

Basis pengetahuan pada modul *Retrieval-Augmented Generation* (RAG) dibangun dari empat sumber utama sebagai berikut.

1. Korpus DDI2013

Korpus ini berisi kalimat yang memuat konteks interaksi obat dan informasi obat terkait dari *DrugBank* dan *MedLine*, menghasilkan sebanyak 10.981 dokumen.

2. Data ChCh-Miner yang telah diproses

Dataset ini berisi pasangan interaksi obat yang telah terverifikasi dari basis data BioSNAP, dengan total 2.085 dokumen.

3. TWOSIDES

TWOSIDES merupakan basis data efek samping *polypharmacy* yang diperoleh dari proyek Decagon (Stanford SNAP). *Dataset* ini berisi sekitar 4,6 juta baris catatan efek samping yang melibatkan 63.473 pasangan obat dan 1.317 jenis efek samping. Identifikasi nama obat dilakukan melalui pemetaan STITCH ID ke nama umum menggunakan API PubChem. Dari 654 STITCH ID yang ditelusuri, sebanyak 489 obat berhasil dipetakan, sementara sisanya berupa nama IUPAC yang kemudian disaring. Setiap pasangan obat dirangkum menjadi satu dokumen yang memuat hingga 15 efek samping yang paling sering dilaporkan, menghasilkan 39.049 dokumen.

4. DrugBank XML (lisensi akademik)

DrugBank merupakan basis data komprehensif berukuran 1,9GB yang men-

cakup 19.842 obat (15.485 *small molecule* dan 4.357 *biotech*) beserta informasi deskripsi, mekanisme aksi, farmakodinamik, indikasi, toksisitas, dan 2.911.156 deskripsi interaksi obat. Proses ekstraksi dilakukan menggunakan *streaming XML parser* (iterparse), kemudian data diindeks secara bertahap dalam *batch* berukuran 2.000 dokumen dengan penyimpanan *checkpoint* setiap 10 *batch*. Untuk mengendalikan ukuran indeks, hanya interaksi yang melibatkan obat dalam basis data ChCh-Miner (1.332 obat) yang diindeks, menghasilkan 540.007 dokumen.

Secara keseluruhan, terdapat 592.122 dokumen diindeks menggunakan FAISS (*Facebook AI Similarity Search*) dengan model *embedding sentence-transformers/all-MiniLM-L6-v2* (dimensi 384). Dokumen dipotong menjadi segmen berukuran 500 karakter dengan (*overlap*) 50 karakter untuk menjaga kontinuitas konteks. Penambahan sumber data ke indeks yang telah ada dilakukan secara inkremental menggunakan metode `add_texts()` dari FAISS tanpa perlu membangun ulang seluruh indeks.

V.5.2 Mekanisme Retrieval

Proses pencarian dokumen relevan dilakukan oleh kelas `ClinicalRetriever` melalui dua jenis *query* utama yaitu:

1. *Query* berbasis mekanisme interaksi
Query dibangun untuk setiap pasangan obat, misalnya: “*Interaction mechanism between warfarin and simvastatin, pharmacological effect*”.
2. *Query* berbasis konteks obat dan gejala
Query dibangun dengan mempertimbangkan daftar obat dan gejala pasien, misalnya: “*Drug interaction between warfarin and simvastatin. Side effects: pusing, mimisan*”.

Hasil pencarian kemudian disaring berdasarkan ambang batas skor kemiripan (*score_threshold* = 0,3) dan dibatasi pada *top_k* = 5 dokumen untuk setiap *query*. Untuk menghindari duplikasi, dilakukan penyaringan berdasarkan *hash* konten. Apabila tidak terdapat entitas obat yang teridentifikasi dari hasil NER, proses *retrieval* tidak dijalankan seluruhnya dan daftar dokumen kosong langsung diteruskan ke modul generasi.

V.5.3 Generasi Laporan Klinis

Modul generasi laporan klinis dirancang dengan dua mode operasi, yaitu berbasis model bahasa dan berbasis *template*.

A. Mode LLM (Gemini)

Apabila API key tersedia, laporan dihasilkan menggunakan model Gemini 2.5 Flash atau Flash-Lite dengan konfigurasi *temperature* sebesar 0,3 dan *max_output_tokens* sebanyak 4.096 token. Pada tahap generasi, model diberikan *system prompt* yang mendefinisikan peran AI sebagai sistem pendukung keputusan klinis. Salah satu batasan utama yang diterapkan pada model generasi adalah model hanya diperbolehkan membahas obat yang secara eksplisit disebutkan oleh pasien. Model tidak diperkenankan menambah obat lain yang muncul pada dokumen referensi hasil *retrieval*. Pembatasan ini diterapkan untuk menjaga relevansi keluaran sistem dan mengurangi kemungkinan munculnya informasi yang dapat membingungkan pengguna.

Selain itu, apabila sistem tidak menemukan obat yang berhasil diidentifikasi pada masukan pengguna, model diarahkan untuk menyampaikan bahwa analisis interaksi obat tidak dapat dilakukan. Mekanisme ini bertujuan untuk mencegah model menghasilkan analisis yang tidak memiliki dasar informasi yang memadai. Isi lengkap *system prompt* yang digunakan pada modul generasi ditunjukkan pada *Listing V.1*.

```
1  Anda adalah sistem pendukung keputusan klinis (CDSS) yang membantu
   tenaga medis dalam mengevaluasi potensi interaksi obat. Anda
   harus:
2
3  1. Memberikan penjelasan yang akurat berdasarkan sumber yang
   tersedia
4  2. Menggunakan bahasa Indonesia yang jelas dan profesional
5  3. Selalu menyertakan referensi sumber informasi
6  4. Memberikan rekomendasi tindakan yang sesuai
7  5. Menyertakan disclaimer bahwa informasi ini bersifat pendukung
   keputusan, bukan pengganti penilaian klinis
8
9  PENTING:
10 - Informasi yang dihasilkan adalah untuk PENDUKUNG KEPUTUSAN
   KLINIS saja, BUKAN untuk diagnosis atau penggantian konsultasi
   dokter.
11 - HANYA bahas obat-obat yang SECARA EKSPLISIT disebutkan oleh
   pasien. JANGAN menyebutkan atau membahas obat lain yang muncul
   di referensi tetapi TIDAK dikonsumsi pasien.
12 - Jika tidak ada obat yang teridentifikasi dari keluhan pasien,
   sampaikan bahwa tidak ada analisis interaksi obat yang dapat
   dilakukan dan sarankan pasien untuk memberikan informasi obat
   yang dikonsumsi.
```

Listing V.1 System prompt untuk modul generasi laporan klinis

Prompt pengguna disusun secara dinamis untuk setiap permintaan dengan mengisi lima *placeholder*, yaitu {complaint} (keluhan pasien), {drugs} (daftar obat hasil NER), {symptoms} (daftar gejala hasil NER), {ddi_predictions} (hasil prediksi modul DDI dalam format poin), dan {context} (kumpulan dokumen relevan hasil *retrieval* FAISS). *Template prompt* pengguna ditunjukkan pada *Listing V.2*. Laporan yang dihasilkan mengikuti struktur yang berisi: (1) Ringkasan Temuan, (2) Analisis Interaksi Obat, (3) Korelasi Gejala, (4) Rekomendasi Tindakan, (5) Sumber Referensi, dan (6) *Disclaimer*.

```

1 Berdasarkan data berikut, buatlah laporan klinis dalam bahasa
  Indonesia:
2
3 ## Data Pasien
4 - Keluhan: {complaint}
5 - Obat yang dikonsumsi: {drugs}
6 - Gejala yang dilaporkan: {symptoms}
7
8 ## Hasil Prediksi Interaksi Obat
9 {ddi_predictions}
10
11 ## Informasi Referensi
12 {context}
13
14 ---
15
16 Buatlah laporan klinis dengan format berikut:
17
18 ### 1. Ringkasan Temuan
19 [Ringkasan singkat tentang obat yang dikonsumsi dan potensi
  interaksi]
20
21 ### 2. Analisis Interaksi Obat
22 [Untuk setiap pasangan obat yang berinteraksi, jelaskan:
23 - Mekanisme interaksi
24 - Tingkat keparahan
25 - Efek yang mungkin terjadi]
26
27 ### 3. Korelasi Gejala dengan Interaksi Obat
28 [Hubungkan gejala yang dilaporkan pasien dengan interaksi obat
  yang terdeteksi]
29
30 ### 4. Rekomendasi Tindakan
31 [Saran tindakan untuk tenaga medis:
32 - Pemantauan yang diperlukan

```

```

33 - Penyesuaian dosis jika perlu
34 - Alternatif obat jika diperlukan]
35
36 ### 5. Sumber Referensi
37 [Cantumkan sumber informasi yang digunakan]
38
39 ### Disclaimer
40 Informasi ini dihasilkan oleh sistem AI untuk mendukung keputusan
    klinis. Konsultasikan dengan dokter Anda untuk evaluasi dan
    tindakan lebih lanjut.

```

Listing V.2 Template prompt pengguna untuk modul generasi laporan klinis

B. Mode Template (Fallback)

Apabila LLM tidak tersedia atau terjadi kegagalan, laporan dihasilkan secara terstruktur menggunakan pendekatan berbasis *template*. Pada mode ini, informasi dari modul NER, DDI, dan hasil *retrieval* disusun secara terstruktur ke dalam enam bagian yang sama seperti mode LLM. Probabilitas interaksi yang dihasilkan oleh modul DDI dicantumkan secara eksplisit untuk setiap pasangan obat sebagai indikator kepercayaan prediksi model. Selain itu, digunakan peta korelasi gejala-obat yang telah ditentukan sebelumnya untuk menghubungkan gejala pasien dengan interaksi obat yang terdeteksi. Rekomendasi tambahan juga disertakan berdasarkan jenis obat, seperti pemantauan INR untuk warfarin dan pemantauan enzim CK untuk simvastatin.

V.6 Antarmuka API dan Web

A. REST API

Sistem menyediakan REST API menggunakan FastAPI dengan *endpoint* utama:

1. **POST /api/v1/predict:** Menerima teks keluhan pasien dan mengembalikan hasil lengkap *pipeline* (NER, DDI, dan laporan klinis) dalam format JSON.
2. **GET /api/v1/health:** Memeriksa status kesehatan sistem.
3. **GET /api/v1/models:** Mengembalikan status pemuatan model.
4. **GET /app:** Menyajikan antarmuka web kepada pengguna.

CORS (*Cross-Origin Resource Sharing*) diaktifkan untuk memungkinkan akses dari aplikasi *front-end*. Objek *CDSSPipeline* diinisialisasi saat *startup* aplikasi dan digunakan secara bersama oleh seluruh *request*. Berkas-berkas statis (*frontend*) disajikan melalui *mount* *StaticFiles* pada jalur */static*.


B. Antarmuka Web

Antarmuka web dibangun sebagai *single-page application* (SPA) menggunakan HTML5 dan *framework* Tailwind CSS, lalu disajikan langsung oleh FastAPI pada *endpoint* /app. Komunikasi dengan *backend* dilakukan melalui panggilan *fetch* ke *endpoint* /api/v1/predict, sementara pustaka *marked.js* digunakan untuk mengonversi laporan klinis dari format Markdown menjadi HTML.


Tata letak antarmuka terbagi menjadi dua bagian. *Sidebar* di sisi kiri menampilkan informasi tiga modul *pipeline* (NER, DDI, RAG) beserta beberapa contoh keluhan siap pakai. Panel utama di sisi kanan terdiri dari *header bar* dengan indikator status kesehatan sistem, area hasil yang menampilkan keluaran tiap modul secara bertahap, serta *form* masukan keluhan pasien di bagian bawah.

Hasil analisis disajikan mengikuti urutan eksekusi *pipeline*. Entitas yang terdeteksi modul NER ditampilkan sebagai *badge* berwarna pada teks keluhan asli (hijau untuk *DRUG* dan merah untuk *SYMPTOM*). Prediksi modul DDI ditampilkan dalam bentuk kartu pasangan obat yang memuat *progress bar* probabilitas interaksi serta *badge* reliabilitas. Keluaran modul RAG terdiri atas laporan klinis dalam format Markdown terformat yang mencakup ringkasan temuan, analisis interaksi, korelasi gejala, rekomendasi, dan *disclaimer*, disertai daftar dokumen referensi yang dapat dilipat.


Tampilan awal antarmuka saat halaman pertama dibuka ditunjukkan pada Gambar V.2. Gambar V.3 memperlihatkan area hasil setelah keluhan diproses, mencakup keluaran modul NER dan DDI. Gambar V.4 menampilkan laporan klinis dari modul RAG beserta dokumen referensi yang dipakai.



Gambar V.2 Tampilan awal antarmuka web sistem CDSS



Gambar V.3 Hasil ekstraksi entitas (NER) dan prediksi interaksi obat (DDI)



Gambar V.4 Laporan klinis modul RAG beserta dokumen referensi

BAB VI

EVALUASI

Bab ini menyajikan hasil evaluasi terhadap sistem CDSS *hybrid* yang telah diimplementasikan. Evaluasi dilakukan pada empat tingkat, yaitu: (1) evaluasi modul NER secara terpisah, (2) evaluasi modul DDI secara terpisah, (3) evaluasi modul RAG, serta (4) evaluasi *end-to-end* untuk menguji integrasi keseluruhan *pipeline*. Selain itu, dibahas pula evaluasi perbandingan penggunaan RAG dan tanpa RAG, pengukuran waktu respons sistem, evaluasi fitur resolusi alias nama obat, pengujian penanganan masukan non-medis, serta evaluasi pemenuhan kebutuhan fungsional dan non-fungsional sistem.

VI.1 Evaluasi Modul NER

Modul NER bertugas mengekstraksi entitas medis (*DRUG*, *SYMPTOM*, dan *DISEASE*) dari teks keluhan pasien berbahasa Indonesia menggunakan arsitektur IndoBERT-CRF. Evaluasi modul ini mencakup empat aspek utama, yaitu penetapan metrik evaluasi pada level entitas, validasi silang *5-fold* untuk mengukur stabilitas model, evaluasi pada data uji terpisah untuk mengukur kemampuan generalisasi model, serta analisis kasus tepi (*edge case*) untuk menguji ketahanan model terhadap variasi penulisan dan istilah klinis informal yang umum ditemukan pada keluhan pasien.

VI.1.1 Metrik Evaluasi

Evaluasi NER dilakukan menggunakan metrik pada level entitas (*entity-level*) dari pustaka *seqeval*, yaitu *precision*, *recall*, dan *F1-score*. Sebuah entitas dianggap benar hanya jika label dan rentang token (*span*) yang diprediksi sesuai dengan *ground truth*. Pendekatan ini lebih ketat dibandingkan evaluasi pada level token, karena kesalahan pada satu token dalam entitas multi-kata tetap dihitung sebagai kegagalan penuh. Sebagai contoh, prediksi “jantung” dari entitas “jantung berdebar” dianggap tidak tepat karena entitas tidak dikenali secara utuh. Pendekatan ini dipilih karena lebih sesuai dengan kebutuhan modul berikutnya dalam *pipeline* sistem. Modul DDI memerlukan nama obat secara lengkap untuk proses pencocokan ke basis

data ChCh-Miner, sedangkan modul RAG memerlukan gejala yang lengkap agar mekanisme interaksi dapat dijelaskan secara tepat.

Definisi formal serta formulasi *precision*, *recall*, dan *F1-score* pada level entitas telah dipaparkan pada Subbab II.8. Pada konteks NER untuk sistem CDSS ini, *F1-score* dipilih sebagai indikator utama karena kedua jenis kesalahan sama-sama berdampak pada modul lanjutan, *false positive* (misalnya kata “mau” terdeteksi sebagai *SYMPTOM*) menyebabkan prediksi DDI atau laporan RAG menjadi tidak relevan, sedangkan *false negative* (nama obat tidak dikenali) menyebabkan prediksi interaksi tidak dapat dijalankan sama sekali.

Selain metrik agregat, evaluasi juga menampilkan metrik untuk setiap kelas entitas (*DRUG*, *SYMPTOM*, *DISEASE*) untuk mengidentifikasi kelas yang mungkin terdampak oleh ketidakseimbangan distribusi data pelatihan. *Classification report* juga ditampilkan untuk memberikan gambaran distribusi kesalahan secara lebih rinci.

VI.1.2 Hasil Validasi Silang *K-Fold*

Pelatihan model NER menggunakan validasi silang *5-fold*. Hasil evaluasi pada masing-masing *fold* ditunjukkan pada Tabel VI.1.

Tabel VI.1 Hasil Validasi Silang 5-Fold Model NER

Fold	Precision	Recall	F1-Score
0	0,9993	0,9998	0,9996
1	0,9959	0,9984	0,9971
2	0,9914	0,9968	0,9941
3	0,9919	0,9972	0,9945
4	0,9928	0,9973	0,9950
Rata-rata	0,9942	0,9979	0,9961

Rata-rata *F1-score* sebesar 0,9961 menunjukkan bahwa model mampu mengekstraksi entitas medis dari teks berbahasa Indonesia dengan akurasi yang sangat tinggi. Perbedaan performa antar-*fold* juga relatif kecil dengan standar deviasi F1 sebesar 0,0023. Hasil ini menunjukkan bahwa model cukup stabil terhadap pembagian data pelatihan dan validasi yang berbeda.

VI.1.3 Hasil Evaluasi pada Data Uji

Model terbaik dari *fold* 0 kemudian diuji menggunakan pada himpunan data uji terpisah yang terdiri atas 6.385 sampel dengan total 22.976 entitas. Hasil evaluasi untuk masing-masing jenis entitas ditunjukkan pada Tabel VI.2.

Secara keseluruhan, model mencapai *F1-score* 0,9941 pada data uji. Entitas *DRUG*

Tabel VI.2 Hasil Evaluasi NER pada Data Uji per Jenis Entitas

Entitas	Precision	Recall	F1-Score	Support
DRUG	0,9960	0,9976	0,9968	14.906
SYMPTOM	0,9880	0,9905	0,9892	8.070
Keseluruhan	0,9932	0,9951	0,9941	22.976

memiliki performa tertinggi dengan *F1-score* sebesar 0,9968, sedangkan entitas *SYMPTOM* *F1-score* sebesar 0,9892. Selisih antara hasil validasi silang (0,9961) dan hasil data uji (0,9941) yang relatif kecil menunjukkan tidak terdapat indikasi *overfitting* yang berarti. Hasil ini menunjukkan bahwa arsitektur IndoBERT-CRF mampu melakukan ekstraksi entitas medis berbahasa Indonesia secara konsisten pada data yang belum pernah dilihat selama pelatihan.

VI.1.4 Analisis Kasus Tepi NER

Pengujian kasus tepi *edge case* dilakukan untuk mengidentifikasi keterbatasan model NER dalam menangani masukan yang tidak umum atau memiliki variasi penulisan tertentu. Hasil pengujian dirangkum pada Tabel VI.3.

Tabel VI.3 Hasil Pengujian Kasus Tepi Model NER

Kasus	masukan	Hasil
Huruf kapital semua	“SAYA MUAL DAN PUSING...”	Berhasil setelah normalisasi <i>lowercase</i>
Akhiran Indonesia	“warfarinnya”, “simvastatinnya”	Berhasil setelah <i>suffix stripping</i>
Entitas gabungan	“simvastatin, metformin”	Berhasil dipisahkan oleh pasca-pemrosesan
Informasi dosis	“warfarin 5mg”	Dosis dihilangkan, nama obat diekstraksi
Token numerik	“12345”	Disaring, tidak dianggap entitas
Kata makanan	“sayur”, “buah”	Disaring oleh daftar kata henti
Tanpa obat	“Saya pusing sejak pagi”	Tidak ada obat diekstraksi (benar)
Gejala multi-kata	“jantung berdebar”, “kaki bengkak”	Berhasil diekstraksi sebagai satu entitas

Secara umum, mekanisme pasca-pemrosesan yang diimplementasikan pada Subbab V.2.4 mampu menangani sebagian besar kesalahan yang muncul pada kasus tepi yang diidentifikasi. Proses normalisasi teks, penghapusan *suffix*, pemisahan entitas gabungan, serta penyaringan token tertentu membantu meningkatkan konsistensi hasil ekstraksi entitas.

Meskipun demikian, terdapat beberapa keterbatasan yang masih melekat pada modul NER. Pertama, data pelatihan berasal dari korpus DDI2013 berbahasa Inggris yang diadaptasi menggunakan pendekatan *template-based* (Subbab II.3.3) untuk menjaga konsistensi terminologi medis, sehingga variasi linguistiknya masih terbatas dibandingkan bahasa alami pasien sehari-hari, meskipun telah ditangani secara parsial melalui adaptasi gaya dan augmentasi berbasis LLM. Kedua, modul saat ini dirancang khusus untuk teks bahasa Indonesia dan belum mendukung bahasa daerah maupun campuran bahasa (*code-mixing*).

VI.1.5 Evaluasi Penanganan Masukan Non-Medis

Sistem CDSS harus mampu menangani masukan yang tidak mengandung informasi medis secara tepat tanpa menghasilkan laporan yang menyesatkan. Evaluasi ini dilakukan untuk menguji mekanisme penanganan masukan non-medis yang telah diimplementasikan, terutama pada tahap pasca-pemrosesan NER (Subbab VI.1) dan pengaturan alur *retrieval* RAG.

Masukan “saya mau tidur” digunakan sebagai kasus uji masukan non-medis. Kalimat ini dipilih karena mengandung kata “mau” dan “tidur” yang berpotensi dikenali secara keliru sebagai entitas medis oleh model NER. Kata “mau” dapat menyerupai pola gejala dalam bahasa Indonesia informal, sedangkan “tidur” memiliki kemiripan kontekstual dengan keluhan tidur (*insomnia*) yang terdapat pada data pelatihan. Kasus ini merepresentasikan situasi ketika pengguna yang memasukkan kalimat sehari-hari yang tidak berkaitan dengan obat maupun keluhan medis.

Tabel VI.4 merangkum penanganan masukan non-medis pada setiap tahap *pipeline* beserta hasil yang dicapai.

Hasil tersebut menunjukkan bahwa keluaran akhir sistem dapat terpengaruh apabila kesalahan pada tahap awal *pipeline* tidak ditangani secara khusus. Dengan mekanisme penanganan yang diimplementasikan pada keempat tahap tersebut, sistem tidak menghasilkan laporan medis yang tidak relevan untuk masukan non-medis.

Terdapat tiga mekanisme utama yang diimplementasikan untuk menangani masukan non-medis, yaitu sebagai berikut.

- 1. Penyaringan kata henti (*stopword*)**

Kata-kata umum seperti “mau”, “tidur”, “makan”, dan “sayur” disaring dari hasil NER sehingga tidak dianggap sebagai entitas medis.

- 2. Pelewatan *retrieval* RAG**

Tabel VI.4 Penanganan Masukan Non-Medis pada Setiap Tahap *Pipeline*

Komponen	Penanganan	Hasil
NER	Penyaringan kata henti (<i>stopwords</i>) pada pasca-pemrosesan untuk istilah umum non-medis seperti “mau” dan “tidur”	Tidak ada entitas obat maupun gejala yang terekstraksi
DDI	Modul dilewati ketika jumlah obat hasil NER kurang dari dua	Daftar prediksi interaksi kosong, $P_{\text{bernilai}0}$
RAG <i>retrieval</i>	Proses pencarian FAISS dilewati ketika tidak ada entitas obat	Tidak ada dokumen referensi yang diambil
RAG <i>generation</i>	<i>Prompt</i> sistem mewajibkan LLM hanya membahas obat yang disebutkan pasien serta menyatakan analisis tidak dapat dilakukan apabila tidak ada obat	Laporan menyatakan bahwa tidak ada obat yang teridentifikasi dari keluhan pasien

Jika tidak ada entitas obat yang diekstraksi, proses *retrieval* pada FAISS dilewati untuk menghindari pengambilan dokumen yang tidak relevan.

3. Penguatan instruksi *prompt*

Prompt LLM diperkuat dengan instruksi agar model hanya membahas obat yang benar-benar disebutkan pasien, sehingga keluaran tetap sesuai konteks meskipun informasi obat tidak tersedia.

Kombinasi ketiga mekanisme tersebut memastikan bahwa sistem tidak menghasilkan informasi medis yang menyesatkan ketika menerima masukan yang tidak mengandung konteks medis.

VI.2 Evaluasi Modul DDI

Modul DDI digunakan untuk memprediksi probabilitas interaksi antarpasangan obat menggunakan arsitektur *Multi-type Feature Fusion Graph Neural Network* (MF-FGNN). Model ini menggabungkan tiga representasi, yaitu representasi SMILES melalui Bi-GRU, graf molekul melalui GIN, dan graf interaksi global melalui *Fusion* GCN. Evaluasi modul dilakukan pada empat aspek, yaitu: (1) penetapan metrik evaluasi untuk klasifikasi biner yang sesuai untuk data interaksi yang tidak seimbang, (2) hasil pelatihan dan pengujian pada *dataset* ChCh-Miner, (3) statistik distribusi *dataset*, dan (4) analisis keandalan prediksi pada pengujian *end-to-end*.

VI.2.1 Metrik Evaluasi

Prediksi DDI merupakan tugas klasifikasi biner, yaitu menentukan apakah sepasang obat berinteraksi atau tidak. Pada *dataset* DDI, distribusi kelas umumnya tidak seimbang karena jumlah pasangan obat yang tidak diketahui berinteraksi jauh lebih banyak dibanding pasangan yang telah terkonfirmasi berinteraksi. Definisi formal serta formulasi *precision*, *recall*, *F1-score*, ROC-AUC, dan AUPR telah dipaparkan pada Subbab II.8.

Pada penelitian ini, kelima metrik tersebut dilaporkan sebagai satu kesatuan dengan pembagian peran sebagai berikut. ROC-AUC dan AUPR digunakan untuk menggambarkan performa diskriminatif model secara bebas *threshold*, di mana AUPR menjadi pelengkap penting ROC-AUC pada kondisi data tidak seimbang. *Precision*, *recall*, dan *F1-score* dihitung pada *threshold* probabilitas τ sebesar 0,5 sesuai praktik umum pada evaluasi model DDI berbasis MFFGNN. Pada konteks CDSS, *recall* memperoleh bobot perhatian lebih besar karena *false negative* (interaksi terlewat) berisiko langsung terhadap keselamatan pasien, sedangkan *false positive* masih dapat ditinjau ulang oleh klinisi melalui penjelasan dan referensi yang disajikan modul RAG.

VI.2.2 Statistik Dataset

Dataset yang digunakan untuk pelatihan dan evaluasi modul DDI adalah ChCh-Miner dari koleksi BioSNAP (*Stanford Network Analysis Project*). *Dataset* ini berisi pasangan obat yang terkonfirmasi berinteraksi berdasarkan literatur medis. Ringkasan statistik *dataset* ditunjukkan pada Tabel VI.5.

Tabel VI.5 Statistik *Dataset* DDI (ChCh-Miner)

Parameter	Nilai
Jumlah obat unik	1.332
Pasangan pelatihan	68.056
Pasangan validasi	8.506
Pasangan pengujian	8.508
Sisi graf DDI	83.348
Sumber data	ChCh-Miner (BioSNAP)

Pembagian data pelatihan, validasi, dan pengujian dilakukan dengan rasio 80:10:10 pada level pasangan obat menggunakan *stratified split*, sehingga distribusi kelas positif dan negatif pada masing-masing subset tetap terjaga. Pasangan negatif (*non-interacting*) diperoleh dari pasangan obat yang tidak terdapat pada daftar interaksi ChCh-Miner, kemudian di-*sampling* secara acak rasio 1:1 terhadap pasangan positif. Jumlah obat unik sebanyak 1.332 juga menjadi batas cakupan modul DDI. Obat yang

tidak terdaftar pada basis data akan dikategorikan sebagai *out-of-scope* dan ditangani secara konservatif oleh sistem pada Subbab VI.2.5.

VI.2.3 Hasil Pelatihan dan Pengujian

Tabel VI.6 menunjukkan perbandingan performa model pada data validasi terbaik selama pelatihan dan pada data uji.

Tabel VI.6 Hasil Evaluasi Model DDI (MFFGNN) pada *Dataset* ChCh-Miner

Metrik	Validasi (Terbaik)	Data Uji
ROC-AUC	0,9708	0,9539
AUPR	0,9641	0,9487
Precision	—	0,8599
Recall	—	0,9290
F1-Score	0,9214	0,8931

Model mencapai nilai ROC-AUC sebesar 0,9539 dan AUPR sebesar 0,9487 pada data uji yang terdiri atas 8.508 pasangan. Penurunan performa dari data validasi ke data uji relatif kecil, dengan selisih ROC-AUC sebesar 0,017, AUPR sebesar 0,015, dan *F1-score* sebesar 0,028. Hal ini menunjukkan bahwa model tidak mengalami *overfitting* yang signifikan dan masih mampu melakukan generalisasi pada pasangan obat yang tidak muncul selama proses pelatihan.

Nilai ROC-AUC (0,9539) dan AUPR (0,9487) dengan selisih kurang dari 0,01 juga menunjukkan bahwa model bekerja baik pada kelas positif maupun negatif. Kondisi ini sejalan dengan strategi *negative sampling* 1:1 yang diterapkan pada pembentukan *dataset*, sehingga distribusi kelas menjadi lebih seimbang dibandingkan kondisi asli pada data DDI.

Perbedaan antara *precision* (0,8599) dan *recall* (0,9290) pada data uji menunjukkan bahwa model cenderung lebih sensitif dalam mendeteksi interaksi obat, meskipun menghasilkan sejumlah *false positive*. Dalam konteks CDSS klinis, karakteristik tersebut masih dapat diterima karena *false negative* memiliki risiko yang lebih besar dibandingkan *false positive*. Interaksi yang terlewat dapat berdampak langsung pada keselamatan pasien, sedangkan prediksi yang keliru masih dapat diverifikasi lebih lanjut oleh tenaga medis melalui penjelasan dan referensi dari modul RAG. Nilai *F1-score* sebesar 0,8931 menunjukkan bahwa keseimbangan model baik secara keseluruhan pada kedua aspek tersebut.

Perlu dicatat bahwa keputusan biner “terdapat interaksi” pada modul DDI menggunakan ambang probabilitas standar *binary classification* ($P \geq 0,5$) yang mengikuti

praktik umum pada *machine learning* dan belum dikalibrasi berdasarkan tingkat urgensi klinis. Oleh karena itu, angka probabilitas yang dilaporkan merefleksikan keyakinan model, bukan urgensi klinis, dan diperlukan interpretasi hati-hati oleh pengguna pada saat membaca skor prediksi.

VI.2.4 Analisis Keandalan Prediksi

Sistem menerapkan mekanisme keandalan (*reliability flag*) pada setiap prediksi DDI. Mekanisme ini digunakan untuk membedakan prediksi yang benar-benar dihasilkan model dari kondisi ketika prediksi tidak dapat dilakukan karena keterbatasan data. Tabel VI.7 menunjukkan kondisi yang memengaruhi keandalan prediksi.

Tabel VI.7 Kondisi Keandalan Prediksi DDI

Kondisi	Reliable	Penanganan
Kedua obat dikenal, SMILES valid	Ya	Prediksi model dijalankan
Salah satu obat tidak dikenal	Tidak	Prediksi dilewati, <i>Pbernilai0</i>
Kedua obat tidak dikenal	Tidak	Prediksi dilewati, <i>Pbernilai0</i>
Konversi graf molekul gagal	Tidak	Prediksi dilewati, <i>Pbernilai0</i>

Pada pengujian *end-to-end* terhadap 83 kasus uji (Subbab VI.5), modul DDI menjalankan prediksi pada 96 pasangan obat dari 70 kasus yang memiliki dua atau lebih obat. Dari 96 pasangan tersebut, 78 pasangan (81,2%) memperoleh status *reliable* karena kedua obat dikenali dan memiliki representasi SMILES serta graf molekul yang valid. Sedangkan 18 pasangan sisanya tergolong *out-of-scope* karena salah satu atau kedua obat tidak terdapat dalam basis data ChCh-Miner. Cakupan prediksi yang diperoleh juga dipengaruhi oleh sistem resolusi alias nama obat yang dibahas pada (Subbab VI.2.5). Bagian ini membantu meningkatkan jumlah obat yang dapat dikenali oleh modul DDI.

VI.2.5 Evaluasi Resolusi Alias Nama Obat

Sistem resolusi alias nama obat diimplementasikan untuk mengatasi ketidaksesuaian antara nama obat yang umum digunakan di Indonesia dengan nama obat yang tersedia dalam basis data ChCh-Miner. Sistem ini memuat 130 alias yang mencakup nama obat dalam bahasa Indonesia, nama dagang umum, dan variasi nama *International Nonproprietary Name* (INN). Daftar lengkap seluruh 130 alias, dikelompokkan berdasarkan kelas farmakologis, dapat dilihat pada Lampiran D.1 (Tabel D.1). Evaluasi bagian ini dilakukan untuk melihat pengaruh sistem alias terhadap cakupan prediksi DDI pada masukan berbahasa Indonesia.

Tabel VI.8 menunjukkan hasil pengujian resolusi alias pada kasus representatif.

Tabel VI.8 Hasil Pengujian Resolusi Alias Nama Obat

masukan NER	Resolusi Alias	DDI (P)	Status
paracetamol	acetaminophen	0,5550	RELIABLE
paracetamol (tanpa alias)	–	0,0000	UNRELIABLE

Kasus uji “paracetamol dan warfarin” menunjukkan bahwa sistem alias mampu meningkatkan cakupan prediksi DDI. Nama “paracetamol” yang umum digunakan di Indonesia berhasil dipetakan menjadi “acetaminophen” yang terdapat dalam basis data ChCh-Miner. Dengan resolusi tersebut, prediksi DDI dapat dijalankan dan memperoleh hasil probabilitas interaksi P sebesar 0,5550 dengan status RELIABLE. Sebaliknya, tanpa resolusi alias, “paracetamol” tidak dikenali sehingga prediksi tidak dapat dilakukan.

Implementasi 130 alias nama obat meningkatkan jumlah prediksi yang dapat dijalankan secara andal pada evaluasi *end-to-end*. Alias yang digunakan mencakup beberapa jenis pemetaan berikut.

1. Nama Indonesia ke nama internasional, seperti *paracetamol* menjadi *acetaminophen*, *parasetamol* menjadi *acetaminophen*, *levotiroksin* menjadi *thyroxine*, *siklosporin* menjadi *cyclosporin a*.
2. Variasi ejaan, seperti *amlodipin* menjadi *amlodipine*.
3. Nama alternatif, seperti *vitamin B12* menjadi *cyanocobalamin*, asam folat menjadi *folic acid*, dan alkohol menjadi *ethanol*.

Penanganan terhadap kasus nama obat Indonesia dan variasi ejaan yang tidak terdapat pada basis data ChCh-Miner dilakukan dengan menambahkan 13 entri alias yang mencakup *lithium*, alkohol, *levothyroxine*, *cyclosporine*, kalium klorida, dan beberapa variasi ejaan lainnya. Implementasi ini memungkinkan 7 pasangan DDI yang melibatkan obat-obat tersebut diprediksi dengan status RELIABLE. Meskipun demikian, masih terdapat beberapa obat umum yang belum tersedia pada basis data ChCh-Miner, seperti *doxycycline*, *glimepiride*, *clindamycin*, *omeprazole*, insulin, *ketoconazole*, *colchicine*, dan *ranitidine*. Pada kasus tersebut, sistem alias yang ada saat ini belum dapat membantu karena obat memang tidak termasuk dalam cakupan *dataset* DDI yang digunakan.

Selain itu, ketidaksesuaian format nama pada ChCh-Miner, seperti “ibuprofen, (+-)-” untuk ibuprofen dan “candesartan cilexetil” untuk candesartan, telah ditangani melalui penambahan entri alias khusus dengan referensi silang ke berkas *drug_smiles.json* ChCh-Miner. Meskipun demikian, masih terdapat satu keter-

batasan teknis yang melekat pada mekanisme resolusi nama obat. Resolusi alias dilakukan melalui pencarian *exact match* pada kamus DRUG_ALIASES (130 entri), sehingga variasi ejaan yang tidak tercakup dalam kamus, seperti *typo*, singkatan tidak lazim, atau nama dagang regional tidak dapat diresolusi dan akan menghasilkan prediksi tidak andal. Mekanisme *fuzzy matching* belum diimplementasikan pada penelitian ini dan menjadi salah satu arah pengembangan lanjutan.

VI.3 Evaluasi Modul RAG

Modul RAG menghasilkan laporan klinis terstruktur yang menggabungkan keluaran modul NER dan DDI dengan dokumen literatur farmakologi melalui mekanisme *Retrieval-Augmented Generation*. Komponen utama pada modul ini terdiri atas indeks FAISS yang berisi 592.122 dokumen dari DrugBank, DDI2013, dan TWO-SIDES, serta LLM Gemini 2.5 Flash/Flash-Lite sebagai menghasilkan laporan klinis. Evaluasi modul RAG meliputi: (1) penetapan metrik evaluasi untuk menilai kualitas laporan, (2) analisis basis pengetahuan FAISS, (3) evaluasi keluaran LLM secara kuantitatif terhadap 83 kasus uji, serta (4) analisis kualitatif terhadap karakteristik laporan yang dihasilkan.

VI.3.1 Metrik Evaluasi

Tidak seperti modul NER dan DDI yang memiliki *ground truth* eksplisit, evaluasi pada modul RAG tidak dapat diukur hanya dengan satu metrik tunggal. Kualitas laporan dipengaruhi oleh beberapa aspek, seperti kelengkapan informasi, struktur laporan, keterkaitan dengan kondisi pasien, serta kedalaman pembahasan klinis. Oleh karena itu, evaluasi modul RAG menggunakan kombinasi metrik heuristik berbasis aturan yang dapat dihitung secara otomatis pada seluruh kasus uji.

1. Cakupan obat

Mengukur proporsi nama obat dari hasil ekstraksi NER yang disebutkan kembali dalam laporan. Metrik ini digunakan untuk menilai apakah laporan membahas seluruh obat yang relevan.

2. Cakupan gejala

Mengukur proporsi gejala dari hasil NER yang dibahas dalam laporan. Metrik ini menunjukkan sejauh mana laporan mempertahankan konteks keluhan pasien.

3. Skor struktur

Mengukur keberadaan enam bagian laporan yang diharapkan, yaitu Ringkasan Temuan, Analisis Interaksi Obat, Korelasi Gejala, Rekomendasi Tindakan, Sumber Referensi, dan *Disclaimer*. Metrik ini digunakan untuk menilai konsistensi format keluaran.

4. Cakupan interaksi

Mengukur proporsi pasangan obat yang diprediksi berinteraksi berdasarkan prediksi modul DDI yang turut dibahas dalam laporan.

5. Kehadiran *disclaimer*

Memeriksa apakah laporan menyertakan peringatan bahwa informasi yang diberikan bukan pengganti diagnosis medis atau konsultasi medis profesional.

6. Kekayaan klinis

Mengukur jumlah istilah klinis yang muncul dalam laporan, seperti interaksi, dosis, efek samping, metabolisme, risiko, dan pemantauan. Metrik ini digunakan untuk menilai kedalaman pembahasan klinis.

Selain metrik di atas, dilakukan pula analisis halusinasi konten (*strict*) pada Subbab VI.4 untuk mengidentifikasi kesalahan yang bersifat kritis terhadap keselamatan klinis, seperti mekanisme interaksi yang salah atau interaksi yang tidak terdeteksi.

VI.3.2 Evaluasi Laporan LLM

Seluruh 83 kasus uji *end-to-end* diproses menggunakan mode LLM dengan Gemini 2.5 Flash/Flash-Lite sebagai penghasil laporan klinis. Selama pengujian, seluruh kasus berhasil diproses dan tidak ada kasus yang jatuh ke mode *template fallback*. Meskipun demikian, mekanisme *template fallback* tetap dipertahankan sebagai jaminan *graceful degradation* apabila layanan LLM tidak tersedia. Contoh keluaran lengkap dapat dilihat pada Lampiran A.4. Tabel VI.9 menunjukkan ringkasan hasil evaluasi laporan terhadap seluruh kasus uji.

Tabel VI.9 Hasil Evaluasi Laporan RAG dengan Gemini 2.5 Flash/Flash-Lite

Metrik	Nilai
Cakupan obat (157/161 token obat tersebut)	0,9752
Cakupan gejala (85/87 token gejala tersebut)	0,9770
Cakupan interaksi (91/96 pasangan interaksi)	0,9479
Kehadiran <i>disclaimer</i>	100% (83/83)
Kecukupan panjang (>1.000 karakter)	100% (83/83)
Rentang panjang laporan (karakter)	1.583 – 7.914
Rata-rata panjang (karakter)	3.716

Secara keseluruhan, laporan yang dihasilkan mencapai cakupan obat sebesar 97,52%, cakupan gejala sebesar 97,70%, dan cakupan interaksi sebesar 94,79%. Hasil tersebut menunjukkan bahwa sebagian besar informasi penting dari *pipeline* berhasil dipertahankan pada laporan akhir. Panjang laporan berkisar antara 1.583 karakter pada kasus pendek tanpa interaksi hingga 7.914 karakter pada kasus polifarmasi kompleks. Variasi ini menunjukkan bahwa LLM mampu menyesuaikan kedalaman penjelasan berdasarkan kompleksitas kasus. Selisih kecil antara nilai

cakupan dengan kondisi ideal disebabkan oleh penggunaan sinonim atau parafrasa. Pada beberapa kasus, nama obat atau gejala tidak ditulis ulang secara persis, tetapi tetap dirujuk dalam bentuk kalimat yang setara secara makna.

VI.3.3 Analisis Kualitatif Laporan LLM

Evaluasi kuantitatif pada subbab sebelumnya menunjukkan bahwa laporan memiliki cakupan dan struktur yang baik. Namun, metrik tersebut belum sepenuhnya menggambarkan kualitas naratif laporan, kedalaman pembahasan klinis, maupun kemampuan model dalam menyesuaikan pembahasan terhadap kasus tertentu. Oleh karena itu, dilakukan analisis kualitatif terhadap keluaran Gemini 2.5 Flash/Flash-Lite pada keseluruhan 83 kasus uji.

Secara umum, laporan yang dihasilkan menunjukkan beberapa karakteristik berikut.

1. Kontekstualisasi referensi

Dokumen yang ditemukan melalui *retrieval* tidak hanya ditampilkan sebagai kutipan, tetapi diintegrasikan ke dalam penjelasan naratif. Informasi dari TWOSIDES maupun DrugBank dapat digunakan untuk memperkuat penjelasan mengenai efek samping dan mekanisme interaksi.

2. Korelasi antara gejala dan interaksi

LLM mampu menghubungkan gejala pasien dengan mekanisme interaksi obat yang relevan. Sebagai contoh, gejala mimisan dikaitkan dengan peningkatan efek antikoagulan warfarin akibat interaksi obat tertentu.

3. Rekomendasi spesifik

Laporan tidak hanya menyebutkan adanya interaksi, tetapi juga memberikan tindak lanjut yang lebih rinci, seperti pemantauan INR, observasi tanda perdarahan, atau pertimbangan penggunaan alternatif terapi.

4. Penanganan kasus tanpa interaksi

Pada kasus dengan prediksi DDI yang tidak andal atau tidak tersedia dalam basis data, LLM tetap dapat memberikan informasi umum mengenai masing-masing obat berdasarkan dokumen *retrieval*, disertai penjelasan bahwa data interaksi tidak ditemukan.

Karakteristik di atas tidak muncul secara konsisten pada mode tanpa RAG. Tanpa dokumen *retrieval*, LLM cenderung menghasilkan pembahasan yang lebih generik dan kurang terkait dengan gejala spesifik pasien. Perbedaan ini dianalisis lebih lanjut pada Subbab VI.4.

VI.4 Evaluasi Perbandingan RAG dan Tanpa RAG

Evaluasi ini dilakukan untuk mengukur kontribusi komponen RAG terhadap kualitas laporan klinis yang dihasilkan LLM. Perbandingan dilakukan antara mode dengan RAG dan tanpa RAG menggunakan 83 kasus uji *end-to-end* yang mencakup berbagai jenis skenario, seperti interaksi obat umum, mekanisme farmakologi spesifik, kasus polifarmasi, kasus obat di luar cakupan basis data DDI, hingga masukan non-medis. Pada mode RAG, LLM menerima dokumen hasil *retrieval* dari indeks FAISS sebagai konteks tambahan. Sebaliknya, pada mode tanpa RAG, LLM hanya menerima masukan pengguna tanpa dokumen *retrieval*. Contoh keluaran lengkap dari kedua mode untuk tiga kasus representatif dapat dilihat pada Lampiran A.

VI.4.1 Metodologi Pengecekan Halusinasi

Setiap laporan yang dihasilkan diperiksa terhadap enam kategori isu, yang dikelompokkan menjadi dua kelas, yaitu halusinasi konten (*strict*) dan isu struktural.

1. WRONG_MECHANISM

Laporan tidak menyebutkan mekanisme interaksi yang benar berdasarkan *ground truth* farmakologi.

2. MISSED_INTERACTION

Laporan tidak mendeteksi adanya interaksi padahal *ground truth* mengkonfirmasi interaksi tersebut.

3. FALSE_INTERACTION

Laporan mengklaim adanya interaksi padahal *ground truth* menunjukkan bahwa kombinasi obat tersebut aman.

4. FABRICATED_REF

Laporan mengutip studi atau tanggal publikasi yang kemungkinan difabrikasi oleh LLM.

5. UNGROUNDED_CLAIM

Laporan membuat klaim yang konfiden tanpa didukung oleh sumber referensi.

6. MISSING_SECTIONS

Laporan tidak mengandung bagian yang diharapkan, yaitu Ringkasan Temuan, Analisis Interaksi Obat, Korelasi Gejala, Rekomendasi Tindakan, Sumber Referensi, dan *Disclaimer*.

Pemisahan antara isu konten dan isu struktural dilakukan agar kesalahan format tidak memengaruhi pengukuran halusinasi medis. Pemeriksaan dilakukan secara heuristik menggunakan pencocokan kata kunci terhadap *ground truth* mekanisme interaksi dari DrugBank.

VI.4.2 Hasil Perbandingan

Hasil perbandingan antara mode RAG dan tanpa RAG ditunjukkan pada Tabel VI.10.

Tabel VI.10 Perbandingan Metrik Laporan dengan RAG dan Tanpa RAG pada 83 Kasus Uji

Metrik	Dengan RAG	Tanpa RAG
Total kasus uji	83	83
Halusinasi konten (<i>strict</i>)	8	14
Tingkat halusinasi konten	9,6%	16,9%
Isu struktural (<i>MISSING_SECTIONS</i>)	0	0
Total kasus dengan isu (gabungan)	8/83	14/83
Tingkat kasus bermasalah (gabungan)	9,6%	16,9%
Rata-rata panjang laporan (karakter)	3.716	3.018
Kasus dengan sitasi sumber [n]	78/83	0/83
Total sitasi sumber	365	0

Tabel VI.11 merinci distribusi isu halusinasi berdasarkan tipe.

Tabel VI.11 Distribusi Isu Berdasarkan Tipe (*strict* vs *structural*)

Tipe Isu	Dengan RAG	Tanpa RAG
<i>Halusinasi konten (strict)</i>		
WRONG_MECHANISM	5	10
MISSED_INTERACTION	2	3
FALSE_INTERACTION	1	1
FABRICATED_REF	0	0
UNGROUNDED_CLAIM	0	0
Subtotal halusinasi konten	8	14
<i>Isu struktural</i>		
MISSING_SECTIONS	0	0
Total isu (gabungan)	8	14

Secara umum, mode dengan RAG menghasilkan jumlah halusinasi yang lebih rendah dibandingkan mode tanpa RAG. Hasil evaluasi menunjukkan beberapa temuan penting.

1. Penurunan halusinasi konten

Mode tanpa RAG menghasilkan 14 isu halusinasi konten (*strict*) dari 83 kasus (16,9%), sedangkan mode dengan RAG hanya menghasilkan 8 isu (9,6%), menurunkan tingkat halusinasi sebesar 42,9%. Penurunan terbesar terjadi pada kategori *WRONG_MECHANISM*, yang menunjukkan bahwa dokumen hasil *retrieval* membantu LLM mengidentifikasi mekanisme interaksi secara lebih tepat.

2. Struktur laporan tetap konsisten

Tidak ditemukan kasus MISSING_SECTIONS pada kedua mode. Hasil ini menunjukkan bahwa keluaran model konsisten pada keenam bagian standar laporan, didukung oleh pengaturan *max_output_tokens* sebanyak 4.096 yang menyediakan kapasitas memadai untuk *prompt* polifarmasi kompleks, serta jalur *template fallback* yang menjamin kelengkapan struktur laporan apabila terjadi kegagalan API Gemini. Pemisahan kelas *strict* dan *structural* memastikan bahwa metrik halusinasi konten tidak terpengaruh oleh isu pemformatan.

3. Traceability melalui sitasi

Mode dengan RAG menghasilkan 365 sitasi sumber pada 78 kasus dari 83 kasus (94,0%), sedangkan mode tanpa RAG tidak menghasilkan sitasi sama sekali. Dari 5 kasus tanpa sitasi bernomor, seluruhnya merupakan kasus tanpa obat yang teridentifikasi oleh NER. Pada kasus-kasus ini, laporan secara eksplisit menyatakan ketiadaan informasi referensi karena tidak ada obat yang dikonsumsi pasien. Tidak ditemukan kasus dengan *template fallback* ataupun *Mode Offline* pada keseluruhan 166 laporan (83 laporan dengan RAG dan 83 laporan tanpa RAG). Kehadiran sitasi memungkinkan tenaga medis menelusuri kembali sumber informasi yang digunakan dalam laporan.

4. Kasus kompleks

Pada beberapa kasus dengan mekanisme interaksi spesifik atau obat tidak terdapat dalam basis data DDI, mode RAG mampu memberikan penjelasan yang lebih tepat dibandingkan mode tanpa RAG.

- **Kasus 5** (omeprazole–clopidogrel): Mode dengan RAG berhasil mengidentifikasi mekanisme inhibisi enzim CYP2C19 yang mengurangi efektivitas clopidogrel, sedangkan mode tanpa RAG menyatakan “tidak ada interaksi” — kesalahan berpotensi berbahaya secara klinis karena dapat mengurangi efek antiplatelet dan meningkatkan risiko trombosis.
- **Kasus 65** (omeprazole–phenytoin, DDI *unreliable*): Modul DDI tidak dapat memprediksi karena omeprazole tidak terdapat di ChCh-Miner. Mode dengan RAG, dengan dukungan 9 dokumen *retrieval*, berhasil mengidentifikasi inhibisi CYP2C9/CYP2C19 oleh omeprazole yang menyebabkan toksisitas phenytoin (nystagmus, ataksia, kebingungan — gejala yang dilaporkan pasien). Mode tanpa RAG menyatakan “tidak terdeteksi interaksi yang signifikan” dan menyangkal hubungan gejala dengan interaksi — contoh *striking* bagaimana RAG mengompensasi kegagalan modul DDI.
- **Kasus 73** (cholestyramine–warfarin, DDI *unreliable*): Cholestyramine

tidak terdapat di ChCh-Miner. Mode dengan RAG mengidentifikasi mekanisme *binding* cholestyramine yang mengurangi absorpsi warfarin sehingga menurunkan INR dan meningkatkan risiko trombosis. Mode tanpa RAG memberikan analisis generik tanpa mekanisme spesifik.

- **Kasus 13** (methotrexate–ibuprofen): Mode dengan RAG secara benar menyebutkan risiko toksisitas renal akibat penurunan klirens methotrexate oleh ibuprofen, sedangkan mode tanpa RAG tidak menyebutkan mekanisme ini.
- **Kasus 22** (propranolol–salbutamol): Mode dengan RAG secara benar mengidentifikasi antagonisme reseptor beta-adrenergik yang dapat mengurangi efektivitas salbutamol pada pasien asma, sedangkan mode tanpa RAG gagal menyebutkan mekanisme antagonisme ini.

5. Pembahasan lebih mendalam

Laporan dengan RAG rata-rata 23,1% lebih panjang (3.716 dengan 3.018 karakter), yang mengindikasikan bahwa dokumen yang ditemukan memungkinkan LLM memberikan pembahasan yang lebih mendalam mengenai mekanisme interaksi dan rekomendasi klinis.

Pada kasus interaksi obat yang umum dan telah banyak diketahui oleh LLM, perbedaan antara mode RAG dan tanpa RAG tidak terlalu besar. Kedua mode masih dapat menghasilkan laporan dengan struktur yang baik dan ringkasan klinis yang cukup relevan. Namun, RAG memberikan kontribusi yang penting pada kasus dengan mekanisme interaksi yang spesifik, ambigu, atau berada di luar cakupan basis data DDI. Pada kondisi tersebut, mode tanpa RAG lebih rentan menghasilkan halusinasi atau mengabaikan interaksi yang sebenarnya penting secara klinis. Reduksi halusinasi konten dari 16,9% menjadi 9,6% (42,9%) mengkuantifikasi dampak ini secara langsung.

Selain itu, RAG juga meningkatkan transparansi laporan melalui penyediaan sitasi sumber. Dalam konteks CDSS klinis, kemampuan untuk menelusuri sumber informasi menjadi aspek penting karena keputusan terapi perlu dapat diverifikasi oleh tenaga medis. Dengan demikian, integrasi RAG tidak hanya berfungsi sebagai penambah konteks, tetapi juga menjadi komponen penting untuk meningkatkan keandalan dan keamanan sistem pendukung keputusan klinis.

VI.5 Evaluasi *End-to-End*

Evaluasi *end-to-end* dilakukan untuk menguji integrasi keseluruhan *pipeline* CDSS, mulai dari ekstraksi entitas oleh modul NER, prediksi interaksi obat oleh modul DDI, hingga penyusunan laporan klinis oleh modul RAG. Berbeda dengan evaluasi per-

modul yang mengukur performa setiap komponen, evaluasi ini menilai bagaimana modul-modul tersebut bekerja secara terintegrasi, termasuk propagasi kesalahan antarmodul dan kualitas keluaran akhir yang diterima pengguna. Bagian ini memaparkan skenario pengujian pada 83 kasus uji, hasil keluaran *pipeline* pada 10 kasus representatif, serta analisis kualitatif terhadap kontribusi masing-masing modul dalam sistem terintegrasi.

VI.5.1 Skenario Pengujian

Evaluasi dilakukan pada 83 kasus uji yang dirancang untuk merepresentasikan kondisi penggunaan nyata. Kasus-kasus tersebut mencakup beberapa kategori, yaitu sebagai berikut.

1. Interaksi obat dengan tingkat keparahan tinggi yang telah terdokumentasi secara luas, seperti *warfarin-simvastatin* dan *fluoxetine-tramadol*;
2. Interaksi obat sedang hingga rendah pada terapi umum, seperti *amlodipine-lisinopril*;
3. Pasangan obat di luar cakupan basis data ChCh-Miner (*out-of-scope*), seperti *omeprazole-clopidogrel* dan *warfarin-cholestyramine*;
4. Kasus polifarmasi dengan tiga obat atau lebih;
5. Masukan yang mengandung nama dagang atau ejaan bahasa Indonesia; serta
6. Masukan non-medis sebagai *negative test*.

Komposisi 83 kasus dibagi menjadi dua kelompok, yaitu 57 kasus yang mencakup skenario interaksi umum dan 26 kasus yang secara khusus dirancang sebagai *stress test* terhadap mekanisme *abstain*, resolusi alias, dan kompensasi RAG pada pasangan *drug-not-in-DB*. Dengan komposisi tersebut, evaluasi tidak hanya mengukur performa pada kasus umum, tetapi juga pada (*edge case*) yang menguji keandalan sistem. Daftar lengkap ke-83 kasus uji beserta keluhan pasien, obat hasil ekstraksi NER, dan probabilitas prediksi DDI dapat dilihat pada Lampiran B (Tabel B.1).

Setiap kasus dievaluasi berdasarkan empat dimensi utama, yaitu: (1) kemampuan ekstraksi entitas obat dan gejala oleh modul NER, (2) prediksi probabilitas interaksi serta status *reliability* oleh modul DDI, (3) kualitas dan struktur laporan klinis yang dihasilkan oleh modul RAGI serta (4) waktu respon keseluruhan *pipeline*. Pengujian dilakukan pada dua mode operasi, yaitu mode dengan RAG aktif (Gemini 2.5 Flash dan FAISS *retrieval*) dan mode tanpa RAG (Gemini tanpa konteks dokumen), untuk mengisolasi kontribusi komponen RAG terhadap kualitas keluaran.

VI.5.2 Hasil *End-to-End* untuk Kasus Representatif

Tabel VI.12 menampilkan hasil pengujian *end-to-end* untuk 10 kasus representatif yang dipilih untuk menggambarkan variasi keluaran sistem.

Tabel VI.12 Hasil Evaluasi *End-to-End* pada 10 Kasus Representatif

No	Masukan	NER: Obat	NER: Gejala	DDI	RAG (Gemini)
1	Saya pusing dan mimisan setelah minum warfarin dan simvastatin	warfarin, simvastatin	pusing, mimisan	P bernilai 0,8688 RE-LIABLE	4.648 kar.
2	Saya mual dan lemas setelah minum metformin dan aspirin	metformin, aspirin	mual, lemas	P bernilai 0,8241 RE-LIABLE	4.949 kar.
3	Saya nyeri lambung setelah minum ibuprofen dan aspirin	ibuprofen, aspirin	nyeri lambung	P bernilai 0,0000 UN-RELIABLE	6.290 kar.
4	Dok, saya jantung berdebar setelah minum amlodipin dan atenolol	amlodipin, atenolol	jantung berdebar	P bernilai 0,0000 UN-RELIABLE	6.604 kar.
5	Saya mual setelah minum omeprazole dan clopidogrel	omeprazole, clopidogrel	mual	P bernilai 0,0000 UN-RELIABLE	4.765 kar.
6	Saya gelisah dan gemetar setelah minum fluoxetine dan tramadol	fluoxetine, tramadol	gelisah, gemetar	P bernilai 0,9972 RE-LIABLE	3.549 kar.
7	Saya mual setelah minum amoxicillin dan methotrexate	amoxicillin, methotrexate	mual	P bernilai 0,9605 RE-LIABLE	4.999 kar.

No	masukan	NER: Obat	NER: Gejala	DDI	RAG (Gemini)
8	Saya nyeri sendi setelah minum prednisone dan ciprofloxacin	prednisone, ciprofloxacin	nyeri sendi	P bernilai 0,4356 RE-LIABLE	6.472 kar.
9	Saya pusing setelah minum amlodipine dan lisinopril	amlodipine, lisinopril	pusing	P bernilai 0,0447 RE-LIABLE	5.431 kar.
10	Saya mual dan pusing setelah minum carbamazepine dan erythromycin	carbamazepine, erythromycin	mual, pusing	P bernilai 0,9643 RE-LIABLE	4.584 kar.

Berdasarkan 10 kasus representatif di atas, diperoleh beberapa temuan terkait performa masing-masing modul dalam *pipeline*. Analisis kuantitatif terhadap keseluruhan 83 kasus dipaparkan pada Subbab VI.7.

A. Modul NER

Modul NER berhasil mengekstraksi entitas obat dan gejala pada seluruh kasus representatif tanpa kegagalan ekstraksi. Beberapa temuan penting meliputi:

- Entitas multi-kata seperti “jantung berdebar”, “nyeri lambung”, dan “nyeri sendi” berhasil dikenali sebagai satu entitas utuh.
- Proses normalisasi dan pasca-pemrosesan, seperti *lowercase*, penghapusan akhiran, dan penyaringan kata henti, berfungsi dengan baik pada seluruh kasus.
- Nama obat internasional seperti *fluoxetine*, *methotrexate*, dan *carbamazepine* berhasil dikenali meskipun bukan merupakan istilah bahasa Indonesia.

B. Modul DDI

Dari 10 kasus representatif tersebut, sebanyak 7 pasangan obat menghasilkan prediksi yang andal (*reliable*) dengan probabilitas interaksi seperti yang tertera pada Tabel VI.12.

Prediksi dengan probabilitas tinggi umumnya konsisten dengan literatur medis

yang tersedia. Sebagai contoh, interaksi *fluoxetine* dan *tramadol* berpotensi menyebabkan sindrom serotonin, sedangkan *carbamazepine* dan *erythromycin* berinteraksi melalui penghambatan CYP3A4. Sebanyak tiga pasangan ditandai sebagai UNRELIABLE karena salah satu obat tidak terdapat dalam basis data ChCh-Miner. Kondisi ini terjadi akibat perbedaan format nama obat, penggunaan ejaan Indonesia, atau keterbatasan cakupan basis data.

C. Modul RAG

Modul RAG berhasil menghasilkan laporan klinis pada seluruh 10 kasus representatif menggunakan Gemini 2.5 Flash dan Flash-Lite. Panjang laporan berkisar antara 3.549 hingga 6.604 karakter. Pencarian dokumen (*retrieval*) dari indeks FAISS yang memuat 592.122 dokumen berhasil menyediakan konteks yang relevan untuk setiap kasus, termasuk data efek samping dari TWOSIDES yang memperkaya informasi dalam laporan.

Bahkan pada kasus dengan prediksi DDI tidak andal (Kasus 3, 4, 5), modul RAG tetap mampu menghasilkan laporan yang informatif dengan memanfaatkan literatur farmakologi yang ditemukan melalui *retrieval*.

VI.6 Evaluasi Kebutuhan Fungsional dan Non-Fungsional

Bagian ini mengevaluasi pemenuhan kebutuhan fungsional (F01–F04) dan non-fungsional (NF01–NF05) yang telah didefinisikan pada tahap perancangan sistem. Evaluasi dilakukan dengan menggabungkan bukti kuantitatif dari pengukuran teknis (mis. waktu respon dan *F1-score*) dengan bukti kualitatif dari pemeriksaan implementasi (mis. ketersediaan mekanisme *template fallback*, penyajian sitasi, serta keterbacaan keluaran). Untuk setiap kebutuhan, dipaparkan deskripsi singkat, bukti pemenuhan, serta status akhir (TERPENUHI, SEBAGIAN TERPENUHI, atau TIDAK TERPENUHI).

VI.6.1 Evaluasi Kebutuhan Fungsional

A. F01: Ekstraksi Obat dan Gejala

Sistem berhasil melakukan ekstraksi nama obat dan gejala dari teks keluhan pasien menggunakan model IndoBERT-CRF. Bukti utamanya adalah *F1-score* NER sebesar 0,9961 pada validasi silang 5-fold dan 0,9941 pada himpunan uji terpisah (Subbab VI.1), serta keberhasilan ekstraksi entitas DRUG dan SYMPTOM pada seluruh 83 kasus uji *end-to-end* (Subbab VI.5) yang juga mencakup variasi penulisan informal seperti huruf kapital, akhiran bahasa Indonesia, informasi dosis, dan entitas multi-kata.

B. F02: Prediksi Interaksi Obat-Obat (DDI)

Sistem berhasil melakukan prediksi interaksi obat yang telah diekstraksi dari keluhan pasien. Bukti utamanya adalah model MFFGNN yang mencapai ROC-AUC 0,9539, AUPR 0,9487, dan F1-score 0,8931 pada data uji (Subbab VI.2), serta keberhasilan prediksi DDI pada 81,2% pasangan obat dari 83 kasus uji *end-to-end* dengan dukungan mekanisme *reliability flag* yang membedakan prediksi andal dan tidak andal (Subbab VI.5).

C. F03: Pemeriksaan Relevansi Gejala

Sistem berhasil melakukan pemeriksaan relevansi antara gejala yang disebutkan pasien dengan prediksi interaksi obat melalui modul RAG. Dari 62 kasus yang mengandung gejala pasien, sebanyak 60 kasus (~96,8%) menyebutkan gejala secara eksplisit dalam laporan, sedangkan 59 kasus (~95,2%) berhasil menghubungkan gejala dengan interaksi obat secara relevan.

Berikut merupakan contoh korelasi gejala yang berhasil diidentifikasi.

1. **Kasus 1:** *warfarin–simvastatin* dengan gejala mimisan
RAG menjelaskan bahwa mimisan berkaitan dengan peningkatan efek anti-tikoagulan akibat interaksi kedua obat.
2. **Kasus 22:** *propranolol–salbutamol* dengan gejala sesak napas
RAG menjelaskan antagonisme *beta-blocker* terhadap bronkodilator sebagai mekanisme yang mendasari gejala sesak napas.
3. **Kasus 4:** *amlodipine – lisinopril* dengan gejala kaki bengkak
Pada kasus tanpa interaksi signifikan, RAG tetap menjelaskan bahwa bengkak kemungkinan merupakan efek samping individual *amlodipine*, bukan akibat interaksi antarobat.

D. F04: Penyusunan Laporan dan Rekomendasi

Sistem berhasil menyusun laporan klinis yang memuat ringkasan risiko interaksi obat, gejala yang diamati, dan rekomendasi tindak lanjut. Seluruh 83 kasus uji menghasilkan laporan dengan enam bagian standar (Ringkasan Temuan, Analisis Interaksi Obat, Korelasi Gejala, Rekomendasi Tindakan, Sumber Referensi, dan *Disclaimer*), didukung 365 sitasi pada 78 dari 83 kasus pada mode RAG (Subbab VI.4) serta mekanisme *template fallback* ketika Gemini API tidak tersedia (Subbab VI.3).

Tabel VI.13 merangkum hasil evaluasi pemenuhan kebutuhan fungsional sistem secara menyeluruh.

Tabel VI.13 Ringkasan Evaluasi Kebutuhan Fungsional

Kode	Kebutuhan	Status	Bukti Utama
F01	Ekstraksi obat dan gejala dari teks keluhan pasien	Terpenuhi	NER F1 bernilai 0,9961 (CV), 0,9941 (uji); 83 kasus <i>e2e</i> berhasil
F02	Prediksi interaksi obat-obat (DDI)	Terpenuhi	ROC-AUC bernilai 0,9539; F1 bernilai 0,8931; <i>reliability flag</i> tersedia
F03	Pemeriksaan relevansi gejala dengan interaksi obat	Terpenuhi	83 kasus <i>e2e</i> : korelasi gejala-interaksi teridentifikasi (59/62 atau sebesar 95,2%)
F04	Penyusunan laporan dan rekomendasi klinis	Terpenuhi	6 bagian standar lengkap pada 83/83 kasus; 365 sitasi pada 78/83 kasus (94,0%); 100% <i>disclaimer</i>

Seluruh kebutuhan fungsional (F01–F04) berhasil dipenuhi oleh sistem. Pemenuhan ini didukung oleh bukti kuantitatif dari evaluasi model secara individu maupun pengujian *end-to-end* pada 83 kasus uji.

VI.6.2 Evaluasi Kebutuhan Non-Fungsional

A. NF01: Reliabilitas

Sistem menunjukkan reliabilitas tinggi berdasarkan beberapa indikator sebagai berikut.

1. Model NER mencapai F1-*score* rata-rata 0,9961 dengan standar deviasi antar-*fold* yang sangat rendah (0,0023), menunjukkan konsistensi prediksi terhadap variasi pembagian data.
2. Model DDI mencapai ROC-AUC 0,9539 pada data uji dengan penurunan dari validasi (Δ bernilai 0,017) yang mengindikasikan *overfitting* minimal.
3. Pengujian pada 83 kasus *end-to-end* menunjukkan konsistensi keluaran pada seluruh modul tanpa kegagalan sistem.
4. Mekanisme pasca-pemrosesan berhasil menangani variasi masukan termasuk huruf kapital semua (*ALL CAPS*), akhiran bahasa Indonesia, informasi dosis, dan format penulisan yang beragam.
5. Mekanisme *template fallback* pada modul RAG tervalidasi menghasilkan laporan klinis terstruktur lengkap (5 bagian standar dan *disclaimer*) tanpa dependensi LLM, sehingga sistem tetap beroperasi sekalipun Gemini API tidak tersedia (contoh keluaran pada Lampiran A.4).

B. NF02: Keamanan dan Privasi

Sistem telah memenuhi beberapa aspek keamanan dasar, yaitu:

1. Sistem berjalan secara lokal (*localhost*) dan data pasien tidak dipersistensikan di *server* manapun.
2. Mode *template fallback* tersedia sehingga sistem dapat beroperasi tanpa koneksi ke API eksternal, menjaga privasi data secara penuh.

Namun, beberapa aspek masih belum tersedia, seperti:

1. Komunikasi belum menggunakan HTTPS.
2. Belum terdapat mekanisme *role-based access control*, enkripsi data, atau anonimisasi data pasien.
3. Pada mode LLM, teks keluhan pasien dikirim ke Gemini API milik Google, yang berpotensi menimbulkan isu privasi data medis.

C. NF03: Keterbacaan dan Transparansi

Sistem memenuhi aspek keterbacaan dan transparansi melalui:

1. Mode RAG menghasilkan 365 sitasi sumber pada 78 dari 83 kasus uji ($\sim 94,0\%$, dengan rata-rata $\sim 4,7$ sitasi per kasus yang mengandung sitasi), dibandingkan dengan 0 sitasi pada mode tanpa RAG (Tabel VI.10).
2. Terdapat *Disclaimer* pada seluruh laporan yang dihasilkan (83/83 pada mode RAG dan 83/83 pada mode tanpa RAG), menyatakan bahwa informasi bukan pengganti diagnosis medis profesional.
3. Struktur laporan konsisten dengan enam bagian standar (Ringkasan Temuan, Analisis Interaksi Obat, Korelasi Gejala, Rekomendasi Tindakan, Sumber Referensi, dan *Disclaimer*).
4. Antarmuka web menampilkan keluaran setiap modul secara transparan, sehingga pengguna dapat menelusuri proses pengambilan keputusan.

D. NF04: Waktu Respon

Evaluasi pemenuhan NF04 dilakukan untuk memverifikasi bahwa waktu respon total sistem berada di bawah 10.000 milidetik. Pengukuran dilakukan dengan pendekatan *micro-benchmark* terkontrol pada 10 kasus terkurasi yang dirancang untuk merepresentasikan variasi alur *pipeline*, seperti masukan dengan 0 hingga 3 obat, kasus dengan dan tanpa gejala, kasus dengan resolusi alias, serta kasus polifarmasi multi-pasangan. Pengujian ini tidak dilakukan pada keseluruhan 83 kasus uji, melainkan pada sampel representatif agar waktu eksekusi tiap tahap dapat diukur secara konsisten. Pengukuran dijalankan dengan kondisi seluruh model telah dimuat ke memori (*warm start*).

Tabel VI.14 menunjukkan rata-rata, nilai minimum, dan nilai maksimum waktu ek-

sekusi setiap tahap *pipeline*.

Tabel VI.14 Waktu Respon per Tahap pada 10 Kasus *Micro-Benchmark* Terkurasi

Tahap	Rata-rata (ms)	Min (ms)	Maks (ms)
NER (IndoBERT+CRF)	374	188	1.229
DDI (MFFGNN)	192	0	665
RAG Retrieval	292	0	1.091
RAG Generate (template)	317	76	769
Total (tanpa Gemini)	1.175	264	3.515
Estimasi Gemini API	~5.000	—	—
Total (dengan Gemini)	~6.175	—	—

Total waktu respon *pipeline* lengkap, termasuk panggilan Gemini API, diestimasi sebesar ~6.175 milidetik (~6,2 detik), sehingga memenuhi target NF04 yang mengharuskan waktu respon di bawah 10.000 milidetik. Beberapa temuan penting dari pengujian ini adalah sebagai berikut.

1. **Bottleneck utama sistem.** Latensi terbesar berasal dari pemanggilan Gemini API yang menyumbang ~81% dari total waktu respon, yaitu sekitar ~5.000 milidetik dari total ~6.175 milidetik. Sementara itu, seluruh *pipeline* lokal (NER, DDI, RAG retrieval, dan *template generation*) hanya memerlukan rata-rata 1.175 milidetik (~1,2 detik).
2. **Variabilitas waktu eksekusi.** Tahap NER menunjukkan variasi waktu eksekusi yang paling tinggi, yaitu antara 188–1.229 milidetik. Variasi ini dipengaruhi oleh panjang masukan dan jumlah token yang diproses oleh model IndoBERT.
3. **Kasus tanpa interaksi obat.** Pada kasus yang tidak memiliki pasangan obat, misalnya hanya satu obat atau tidak ada obat sama sekali, tahap DDI dan RAG dapat dilewati sehingga waktu eksekusinya bernilai 0 milidetik.
4. **Waktu pemuatan model (*cold start*).** Waktu pemuatan model bersifat *one-time* dan hanya terjadi sekali saat server dijalankan. Proses ini memerlukan waktu sekitar 19 detik untuk model NER, 1,4 detik untuk model DDI, dan 20 detik untuk indeks RAG, dengan total sekitar 41 detik. Karena hanya dilakukan pada saat inisialisasi sistem, waktu tersebut tidak dihitung sebagai bagian dari waktu respon inferensi.

Ringkasan bukti utama disajikan pada Tabel VI.15.

E. NF05: Bahasa Komunikasi

Sistem mendukung komunikasi dalam bahasa Indonesia melalui:

1. Model NER berbasis IndoBERT-CRF mencapai *F1-score* 0,9961 untuk ekstraksi entitas medis dari teks bahasa Indonesia.
2. Sistem resolusi alias memuat 130 pemetaan nama obat Indonesia ke nama internasional (misalnya parasetamol menjadi *acetaminophen*, asam folat menjadi *folic acid*).
3. Mekanisme pasca-pemrosesan menangani variasi penulisan informal dalam bahasa Indonesia, termasuk akhiran “-nya” dan “-an”.
4. Seluruh laporan keluaran dihasilkan dalam bahasa Indonesia, baik pada mode LLM maupun mode *template*.

Tabel VI.15 merangkum hasil evaluasi pemenuhan kebutuhan non-fungsional sistem secara menyeluruh.

Tabel VI.15 Ringkasan Evaluasi Kebutuhan Non-Fungsional

Kode	Kebutuhan	Status	Bukti Utama
NF01	Reliabilitas	Terpenuhi	NER memperoleh F1 sebesar 0,9961 pada evaluasi <i>cross-validation</i> dengan standar deviasi 0,0023. Modul DDI mencapai ROC-AUC sebesar 0,9539 dengan selisih validasi dan pengujian sebesar 0,017. Seluruh 83 kasus <i>end-to-end</i> berhasil diproses tanpa kegagalan, dan sistem menyediakan mekanisme <i>template fallback</i> .
NF02	Keamanan dan privasi	Sebagian terpenuhi	Sistem dijalankan secara <i>localhost</i> dan data pengguna tidak dipersistensikan. Mode berbasis <i>template</i> juga dapat digunakan tanpa LLM eksternal. Namun, HTTPS, RBAC, enkripsi, dan anonimisasi data belum diimplementasikan. Pada mode RAG, data masih dikirimkan ke Gemini API.

Kode	Kebutuhan	Status	Bukti Utama
NF03	Keterbacaan dan transparansi	Terpenuhi	Sebanyak 365 sitasi dihasilkan pada 78 dari 83 kasus uji (94,0%). Seluruh keluaran menyertakan <i>disclaimer</i> medis (83/83). Laporan disusun dalam enam bagian standar dan antarmuka menampilkan keluaran setiap modul secara terpisah.
NF04	Waktu respon < 10.000 milidetik	Terpenuhi	Rata-rata waktu respon sistem sekitar 6.175 milidetik (~6,2 detik). <i>Pipeline</i> lokal membutuhkan sekitar 1.175 milidetik, sedangkan <i>bottleneck</i> utama berasal dari proses generasi menggunakan Gemini API yang memerlukan sekitar 5.000 milidetik.
NF05	Komunikasi dalam bahasa Indonesia	Terpenuhi	Modul NER berbasis IndoBERT-CRF mencapai F1 sebesar 0,9961. Sistem juga dilengkapi 130 pasangan alias nama obat Indonesia ke nama internasional, mekanisme pasca-pemrosesan bahasa informal Indonesia, dan keluaran laporan dalam bahasa Indonesia.

Dari lima kebutuhan non-fungsional, empat di antaranya (NF01, NF03, NF04, NF05) telah **terpenuhi sepenuhnya**, sedangkan NF02 (Keamanan dan Privasi) hanya **sebagian terpenuhi**. Aspek yang belum terpenuhi pada NF02 merupakan komponen yang membutuhkan infrastruktur keamanan tambahan dan kebijakan organisasi, sehingga termasuk dalam rekomendasi pengembangan untuk fase *deployment klinis*.

VI.7 Analisis Kesalahan per Modul

Untuk memahami sumber keterbatasan sistem secara lebih menyeluruh, dilakukan analisis kesalahan pada setiap modul berdasarkan 83 kasus uji *end-to-end*. Berbeda dengan evaluasi berbasis metrik agregat yang menilai performa secara umum, analisis ini berfokus pada pola kesalahan spesifik pada tiap modul, sumber penyebabnya, serta penanganan yang diimplementasikan. Evaluasi dilakukan mengikuti alur *pipeline* sistem, yaitu dimulai dari modul NER, dilanjutkan ke modul DDI, dan diakhiri pada modul RAG. Dengan pendekatan ini, dampak kesalahan pada modul awal terhadap modul akhir dapat diamati secara lebih jelas. Sebagai pelengkap, dilakukan pula tinjauan kualitatif oleh apoteker pada sebagian kasus *out-of-scope* untuk menilai kelayakan klinis keluaran sistem ketika prediksi MFFGNN tidak tersedia.

A. Modul NER

Model NER berhasil mengekstraksi entitas obat dan gejala pada seluruh 83 kasus tanpa kegagalan total ekstraksi total. Hasil ini konsisten dengan nilai *F1-score* 0,9941 yang dilaporkan pada data uji (Tabel VI.2). Meskipun demikian, analisis pada kasus uji *end-to-end* menunjukkan beberapa keterbatasan yang tidak sepenuhnya tercermin pada metrik agregat.

1. *False positive* dari istilah laboratorium dan parameter klinis

Istilah laboratorium dan parameter klinis seperti “INR”, “leukosit”, “hormon”, dan “gula darah” berpotensi diidentifikasi modul NER sebagai entitas *DRUG* karena polanya menyerupai nama obat. Penanganan dilakukan melalui daftar kata henti pasca-pemrosesan yang memuat 25 istilah laboratorium dan kondisi tubuh, sehingga istilah-istilah tersebut disaring dari hasil ekstraksi entitas dan tidak diteruskan ke modul DDI.

2. Variasi penulisan informal nama obat

Beberapa nama obat dengan ejaan Indonesia, seperti parasetamol, amlodipin, dan levotiroksin, tidak dapat langsung dipetakan ke basis data ChCh-Miner meskipun token berhasil diekstraksi oleh modul NER. Permasalahan ini bukan berasal dari kegagalan ekstraksi, melainkan keterbatasan resolusi alias pada tahap berikutnya. Penanganan dilakukan melalui 130 pemetaan alias sebagaimana dijelaskan pada Subbab VI.2.5.

Secara umum, modul NER bukan merupakan *bottleneck* utama sistem. Kontribusi kesalahan modul ini terhadap kegagalan *end-to-end* relatif kecil.

B. Modul DDI

Dari total 83 kasus uji, sebanyak 13 kasus tidak diproses oleh modul DDI karena jumlah obat yang terdeteksi kurang dari dua, terdiri atas 8 kasus dengan satu obat dan 5 kasus tanpa obat sama sekali, misalnya pada masukan nonmedis atau keluhan yang hanya berisi gejala. Pada 70 kasus yang memiliki minimal dua obat, dihasilkan 96 pasangan obat dengan rincian sebagai berikut.

- **Pasangan dalam cakupan DDI (*in-scope*)**

Terdapat 78 pasangan obat dengan kedua obat terdapat dalam basis data ChCh-Miner dan memiliki data SMILES serta graf molekul yang valid, sehingga modul DDI menjalankan prediksi MFFGNN. Seluruh pasangan ini menghasilkan prediksi probabilitas interaksi dengan status *reliable*.

- **Pasangan di luar cakupan DDI (*out-of-scope*)**

Terdapat 18 pasangan obat dengan salah satu atau kedua obat tidak terdapat dalam basis data ChCh-Miner, sehingga modul DDI tidak menjalankan prediksi. Sistem secara konservatif memberikan status *unreliable* dengan probabilitas 0, sedangkan modul RAG memberikan informasi umum berbasis literatur tanpa membuat klaim interaksi yang tidak didukung data. Pasangan *out-of-scope* tidak diperhitungkan dalam evaluasi akurasi DDI karena prediksi memang tidak dilakukan.

Dua sumber utama pasangan *out-of-scope* pada kasus uji adalah: (1) nama obat Indonesia atau *brand name* yang tidak dikenali basis data, seperti “lithium”, “alkohol”, “levotiroksin”, “siklosporin”, “kalium”, dan (2) *false positive* dari modul NER berupa istilah laboratorium atau kondisi tubuh, seperti “INR”, “leukosit”, “hormon”, “gula darah”. Penanganan dilakukan melalui dua implementasi tambahan, yaitu kamus alias yang mencapai 130 entri dan daftar kata henti NER yang mencakup 25 istilah laboratorium serta kondisi tubuh. Dengan implementasi ini, proporsi pasangan *in-scope* pada 57 kasus umum mencapai 85,5% (47 dari 55 pasangan).

Pada 26 kasus *stress test* (kasus 59–83), pengujian sengaja dirancang dengan memasukkan obat-obat yang memang tidak tersedia di ChCh-Miner, seperti *omeprazole*, *insulin*, *metformin*, *ranitidine*, *cholestyramine*, *sucralfate*. Akibatnya, terdapat 18 pasangan *out-of-scope* pada keseluruhan 83 kasus. Kondisi ini tidak menunjukkan kegagalan model maupun sistem alias, melainkan keterbatasan cakupan basis data ChCh-Miner. Dengan demikian, cakupan basis data menjadi keterbatasan utama pada kasus-kasus tertentu, sementara sistem telah menangani kondisi tersebut secara konservatif dengan tidak memberikan prediksi yang tidak didukung data.

Pada pasangan *out-of-scope*, modul RAG yang didukung basis pengetahuan sebanyak 592.122 dokumen berperan penting dalam mengompensasi kekosongan

prediksi DDI dengan memberikan penjelasan berbasis literatur mengenai mekanisme interaksi, seperti yang ditunjukkan pada Kasus 65 dan 73 pada Subbab VI.4.

Untuk menilai kelayakan klinis keluaran sistem pada kasus *out-of-scope*, dilakukan tinjauan oleh seorang apoteker terhadap empat kasus representatif. Pada kasus-kasus ini, prediksi DDI dari MFFGNN tidak tersedia sehingga laporan klinis sepenuhnya dihasilkan oleh modul RAG berdasarkan basis pengetahuan literatur. Keempat kasus dipilih karena telah mencakup beberapa mekanisme interaksi farmakokinetik, seperti penghambatan CYP2C19, gangguan absorpsi gastrointestinal, serta variasi keluhan klinis, seperti gejala gastrointestinal, neurologis, dan hematologi, sehingga dianggap mewakili keluhan-keluhan serupa yang muncul pada kasus *out-of-scope* lainnya.

Tabel VI.16 merangkum hasil tinjauan apoteker terhadap keempat kasus tersebut.

Seluruh kasus dinyatakan benar tanpa koreksi oleh apoteker. Catatan yang diberikan bersifat konfirmatif terhadap mekanisme interaksi yang dihasilkan sistem, termasuk penghambatan CYP2C19 oleh *omeprazole* pada metabolisme *clopidogrel* dan *phenytoin*, penggunaan *ranitidine* untuk mengurangi iritasi lambung akibat asam mefenamat, serta penurunan absorpsi warfarin oleh *cholestyramine* yang dapat meningkatkan risiko trombosis.

Selain itu, rekomendasi klinis yang diberikan sistem, seperti penggantian PPI, pemantauan kadar obat, evaluasi DVT, dinilai sesuai dengan praktik klinis. Hasil ini menunjukkan bahwa pada kasus *out-of-scope*, modul RAG yang didukung basis pengetahuan literatur farmakologi (DrugBank, DDI2013, TWOSIDES) mampu menghasilkan analisis interaksi yang akurat secara klinis meskipun prediksi DDI tidak tersedia.

Dapat disimpulkan bahwa keberadaan modul RAG justru membuat keluaran sistem semakin benar pada kasus *out-of-scope*. Ketika prediksi DDI dari MFFGNN tidak tersedia akibat keterbatasan cakupan basis data ChCh-Miner, RAG tidak sekadar berperan sebagai pengganti, tetapi mengisi kekosongan tersebut dengan analisis berbasis literatur yang seluruhnya dinilai benar oleh apoteker. Dengan demikian, integrasi RAG terbukti meningkatkan ketepatan klinis sistem CDSS secara keseluruhan dan memperluas cakupan kasus yang dapat ditangani.

Namun, tinjauan ini masih bersifat awal karena hanya melibatkan satu apoteker dan sebagian kecil kasus. Oleh karena itu, evaluasi klinis yang lebih luas dengan meli-

Tabel VI.16 Hasil Tinjauan Apoteker pada Sampel Kasus *Out-of-Scope*

No	Keluhan Pasien (Ringkas)	Pasangan Obat	Hasil Validasi	Catatan Apoteker
5	Nyeri perut setelah omeprazole dan clopidogrel	omeprazole, clopidogrel	Benar	Penjelasan sistem detail dan tepat; saran penggantian omeprazole dengan pantoprazole atau lansoprazole sesuai praktik klinis.
54	Perih lambung hilang dengan asam mefenamat dan ranitidine	mefenamic acid, ranitidine	Benar	Kombinasi tepat: ranitidine umum diberikan untuk meredam efek asam dari asam mefenamat; penjelasan sistem konsisten dengan praktik.
65	Phenytoin dan omeprazole, gejala neurologis (pusing, jalan limbung, mata berkedut, bingung)	phenytoin, omeprazole	Benar	Jawaban sistem sesuai literatur ilmiah (toksisitas phenytoin akibat penghambatan CYP2C19); mekanisme yang dijelaskan benar.
73	Warfarin dan cholestyramine, INR turun drastis (2,5→1,1), kaki bengkak nyeri	warfarin, cholestyramine	Benar	Penjelasan sangat detail; identifikasi penurunan absorpsi warfarin oleh cholestyramine dan kewaspadaan terhadap kemungkinan DVT sudah sesuai.

batkan beberapa tenaga medis tetap diperlukan pada penelitian lanjutan, yang termasuk dalam rekomendasi pengembangan.

C. Modul RAG

Seluruh 83 kasus berhasil menghasilkan laporan klinis tanpa kegagalan (*offline rate* sebesar 0% dan *template fallback rate* sebesar 0%). Hal ini menunjukkan bahwa modul RAG memiliki keandalan operasional yang tinggi. Analisis kesalahan pada dilakukan dengan membandingkan keluaran mode dengan RAG dan tanpa RAG pada keseluruhan kasus uji.

Pada mode RAG ditemukan 8 isu halusinasi konten (9,6%), sedangkan pada mode tanpa RAG ditemukan 14 isu (16,9%), yang menunjukkan penurunan sebesar 42,9%. Jenis kesalahan dominan adalah `WRONG_MECHANISM`, yaitu mekanisme inter-

aksi yang tidak tepat atau tidak lengkap (10 kasus tanpa RAG dibandingkan 5 kasus dengan RAG), dan MISSED_INTERACTION, yaitu interaksi yang seharusnya disebutkan tetapi terlewat (3 kasus tanpa RAG dibandingkan 2 kasus dengan RAG). Kesalahan FALSE_INTERACTION relatif jarang ditemukan dan tidak meningkat pada mode RAG. Temuan ini menunjukkan bahwa integrasi basis pengetahuan lebih banyak membantu memperbaiki akurasi mekanisme dibandingkan memunculkan klaim interaksi yang tidak valid.

Tidak ditemukan kasus MISSING_SECTIONS baik pada mode RAG maupun tanpa RAG. Konsistensi format keluaran ini didukung oleh pengaturan *token budget* yang memadai, penguatan struktur pada *prompt* sistem, dan mekanisme *retry* pada jalur *template fallback*. Selain itu, pada pasangan obat *out-of-scope* dengan DDI *unreliable*, mode RAG tetap mampu menjelaskan mekanisme interaksi yang relevan berdasarkan literatur, seperti penghambatan CYP2C19 dan gangguan absorpsi gastrointestinal. Sebaliknya, mode tanpa RAG cenderung memberikan respons umum atau menyatakan tidak terdapat interaksi. Hasil ini menunjukkan bahwa modul RAG berperan penting sebagai kompensasi ketika prediksi DDI tidak tersedia.

Lima kasus WRONG_MECHANISM yang masih muncul pada mode RAG umumnya disebabkan oleh kualitas dokumen retri yang kurang optimal. Dalam beberapa kasus, FAISS hanya mengembalikan dokumen yang relevan untuk salah satu obat sehingga model bahasa harus melakukan inferensi dengan konteks yang tidak lengkap. Pengembangan selanjutnya dapat difokuskan pada mekanisme *re-ranking* berbasis pasangan obat dan perluasan basis pengetahuan untuk obat dengan cakupan literatur yang masih terbatas.

BAB VII

PENUTUP

VII.1 Kesimpulan

Tugas akhir ini bertujuan untuk merancang, membangun, dan mengevaluasi sebuah sistem *Clinical Decision Support System* (CDSS) hibrida yang memadukan modul *Named Entity Recognition* (NER), prediksi interaksi obat (DDI), dan *Retrieval-Augmented Generation* (RAG) sebagai sarana bantu bagi tenaga kesehatan untuk mengidentifikasi potensi interaksi obat dari keluhan pasien berbahasa Indonesia. Berdasarkan hasil perancangan, implementasi, dan evaluasi yang telah dilakukan, sistem ini berhasil dibangun dan mampu memproses keluhan pasien mulai dari tahap ekstraksi entitas hingga penyusunan laporan klinis pendukung secara utuh dalam satu *pipeline*.

Pada modul NER, arsitektur IndoBERT yang dikombinasikan dengan lapisan *Conditional Random Field* (CRF) berhasil mengekstraksi entitas DRUG, SYMPTOM, dan DISEASE dengan rata-rata *F1-score* sebesar 0,9961 pada validasi silang 5-fold. Modul prediksi DDI dengan arsitektur MFFGNN memperoleh nilai ROC-AUC sebesar 0,9539 pada dataset ChCh-Miner, yang menunjukkan keandalan model dalam memprediksi pasangan obat yang berpotensi berinteraksi. Sementara itu, modul RAG yang dibangun di atas basis pengetahuan berisi 592.122 dokumen pada indeks FAISS serta diperkuat oleh *Large Language Model* Gemini 2.5 Flash/Flash-Lite mampu menurunkan tingkat halusinasi konten dari 16,9% pada mode tanpa RAG menjadi 9,6% pada mode dengan RAG, atau berkurang sekitar 42,9%. Modul tersebut juga menyisipkan 365 sitasi sumber pada 78 dari 83 kasus uji (94,0%), sedangkan mode tanpa RAG tidak menghasilkan sitasi sama sekali, sehingga laporan klinis yang dihasilkan menjadi lebih dapat ditelusuri.

Dari sisi pemenuhan kebutuhan, seluruh kebutuhan fungsional telah terpenuhi, mencakup ekstraksi nama obat dan gejala dari teks keluhan pasien (F01), prediksi interaksi antarobat menggunakan MFFGNN (F02), pemeriksaan relevansi gejala terhadap interaksi yang diprediksi (F03), serta penyusunan laporan klinis yang memu-

at ringkasan risiko dan rekomendasi tindak lanjut (F04). Sebagian besar kebutuhan nonfungsional juga telah dipenuhi, yaitu empat dari lima aspek yang ditetapkan. Reliabilitas (NF01) tercermin dari capaian metrik NER dan DDI di atas serta dukungan 130 alias obat yang memungkinkan prediksi DDI berhasil dijalankan pada 81,2% dari 96 pasangan obat di 83 kasus uji. Keterbacaan dan transparansi (NF03) ditunjukkan oleh penyisipan sitasi pada mayoritas kasus uji serta penyertaan *disclaimer* medis pada seluruh laporan, sementara waktu respons rata-rata sebesar 6,2 detik (NF04) masih berada di bawah ambang target sebesar 10 detik. Bahasa komunikasi sistem (NF05) sepenuhnya menggunakan bahasa Indonesia, baik pada masukan keluhan maupun pada keluaran laporan. Adapun aspek keamanan dan privasi (NF02) baru terpenuhi sebagian, mengingat sistem dijalankan secara lokal tanpa persistensi data pasien, namun mekanisme HTTPS, *role-based access control*, enkripsi, dan anonimisasi belum diimplementasikan, sehingga aspek ini menjadi rekomendasi untuk fase *deployment* klinis selanjutnya.

VII.2 Saran

Beberapa hal berikut dapat dipertimbangkan untuk pengembangan sistem ke depan.

1. Sistem perlu diuji coba bersama dokter dan apoteker pada konteks praktik klinis nyata melalui evaluasi klinis formal agar kegunaan dan keakuratan rekomendasinya dapat dinilai langsung oleh pengguna sasaran.
2. LLM berbasis *cloud* (Gemini) sebaiknya diganti dengan model bahasa yang dijalankan secara lokal (*on-premise*) untuk menjaga privasi data pasien dan mengurangi ketergantungan pada layanan eksternal, terutama mengingat regulasi perlindungan data kesehatan di Indonesia.
3. Modul DDI saat ini hanya mengeluarkan probabilitas interaksi tanpa keterangan tingkat keparahan, sehingga penambahan klasifikasi ringan, sedang, dan berat (*severity-aware*) akan membuat keluaran sistem lebih berguna bagi tenaga kesehatan saat mengambil keputusan.
4. Ketika interaksi terdeteksi, sistem belum memberikan saran obat alternatif, padahal fitur rekomendasi substitusi obat akan sangat membantu tenaga kesehatan untuk langsung mempertimbangkan opsi pengganti tanpa harus membuka referensi terpisah.
5. Variasi penulisan dan kesalahan ejaan nama obat masih sering terjadi pada keluhan pasien, sehingga penambahan algoritma *fuzzy matching* dapat membantu menangani kasus tersebut tanpa harus menambah alias secara manual.
6. Data sintesis NER saat ini dihasilkan dari empat *template* per tipe DDI dikalikan empat gaya keluhan, sehingga terminologi medis tetap konsisten tetapi variasi kalimatnya terbatas. Pengembangan selanjutnya dapat memakai

neural machine translation (misalnya NLLB atau M2M-100) atau memanfaatkan LLM untuk menerjemahkan langsung kalimat sumber DDI2013, dengan mekanisme *placeholder* agar nama obat tidak ikut diterjemahkan, sehingga ragam kalimat menjadi lebih kaya tanpa kehilangan informasi klinis seperti mekanisme, dosis, dan kontraindikasi, dan model NER diharapkan lebih siap menghadapi keluhan pasien dengan bentuk yang lebih bervariasi.

DAFTAR PUSTAKA

- Abdillah, Abid, Diana Purwitasari, Safitri Juanita, dan Mauridhi Hery Purnomo. 2023. “Pengenalan Entitas Biomedis dalam Teks Konsultasi Kesehatan Online Berbahasa Indonesia Berbasis Arsitektur Transformers”. *Jurnal Teknologi Informasi dan Ilmu Komputer* 10:131. <https://doi.org/10.25126/jtiik.20231016337>.
- Alamudi, Mohammad Yusuf, Arief Fardiansyah, dan Henry Sudiyanto. 2025. *Peran Kecerdasan Buatan pada Kesehatan Masyarakat Global*. Jakarta: Universitas Bakrie Press. ISBN: 978-602-7989-72-6.
- Alfina, Ika, Ruli Manurung, dan Mohamad Ivan Fanany. 2016. “DBpedia Entities Expansion in Automatically Building Dataset for Indonesian NER”. *International Conference on Advanced Computer Science and Information Systems (ICACISIS)*, 335–340. <https://doi.org/10.1109/ICACISIS.2016.7872784>.
- Algifari, Muhammad Hafiz, Leonardo Zachary, Rizka Prita Yuliani, Hardika Aditama, dan Susi Ari Kristina. 2024. “Digital Health Literacy and Its Associated Factors in General Population in Indonesia”. *Indonesian Journal of Pharmacy* 35 (2): 355–362.
- Asada, Masaki, Makoto Miwa, dan Yutaka Sasaki. 2023. “Integrating Heterogeneous Knowledge Graphs into Drug–Drug Interaction Extraction from the Literature”. *Bioinformatics* 39 (1): btac754. <https://doi.org/10.1093/bioinformatics/btac754>.
- Crader, M. F., T. Johns, dan J. K. Arnold. 2025. “Warfarin Drug Interactions”. Dalam *StatPearls [Internet]*. Treasure Island (FL): StatPearls Publishing.
- Davis, Jesse, dan Mark Goadrich. 2006. “The Relationship Between Precision-Recall and ROC Curves”. Dalam *Proceedings of the 23rd International Conference on Machine Learning (ICML)*, 233–240. <https://doi.org/10.1145/1143844.1143874>.

- Deodhar, M., S. B. Al Rihani, M. J. Arwood, L. Darakjian, P. Dow, J. Turgeon, dan V. Michaud. 2020. "Mechanisms of CYP450 Inhibition: Understanding Drug-Drug Interactions Due to Mechanism-Based Inhibition in Clinical Practice". *Pharmaceutics* 12 (9): 846. <https://doi.org/10.3390/pharmaceutics12090846>.
- Devlin, Jacob, Ming-Wei Chang, Kenton Lee, dan Kristina Toutanova. 2019. "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding". Dalam *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)*.
- Es, Shahul, Jithin James, Luis Espinosa-Anke, dan Steven Schockaert. 2024. "RAGAs: Automated Evaluation of Retrieval Augmented Generation". Dalam *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations (EACL)*, 150–158.
- Fawcett, Tom. 2006. "An Introduction to ROC Analysis". *Pattern Recognition Letters* 27 (8): 861–874. <https://doi.org/10.1016/j.patrec.2005.10.010>.
- Furdiyanti, Nova Hasani, Fania Putri Luhurningtyas, Ratna Sari, dan Yulianti. 2017. "Evaluasi Dosis dan Interaksi Obat Antidiabetika Oral pada Pasien Diabetes Mellitus Tipe II". *Jurnal Farmasi Indonesia* 7 (4): 191. ISSN: 2088-8139.
- Gardazi, N. M. 2025. "BERT applications in natural language processing: a review". *Artificial Intelligence Review*, <https://doi.org/10.1007/s10462-025-11162-5>.
- He, C., Y. Liu, H. Li, dkk. 2022. "Multi-type feature fusion based on graph neural network for drug-drug interaction prediction". *BMC Bioinformatics* 23:224. <https://doi.org/10.1186/s12859-022-04763-2>.
- Herawati, M., dkk. 2022. "Health information system concept in health services in the national health insurance (JKN) era in Indonesia: An environment and one health approach". *Frontiers in Public Health*, <https://doi.org/10.3389/fpubh.2022.952415>.
- Herdaningsih, R. 2016. "Potensi Interaksi Obat-Obat pada Resep Polifarmasi di Rawat Jalan". *Indonesian Journal of Clinical Pharmacy*.
- Herrero-Zazo, María, Isabel Segura-Bedmar, Paloma Martínez, dan Thierry Declerck. 2013. "The DDI corpus: An annotated corpus with pharmacological substances and drug-drug interactions". *Journal of Biomedical Informatics* 46 (5): 914–920. <https://doi.org/10.1016/j.jbi.2013.07.011>.

- ISO/IEC/IEEE. 2018. *ISO/IEC/IEEE 29148:2018 Systems and Software Engineering — Life Cycle Processes — Requirements Engineering*. International Standard. Geneva, Switzerland.
- Istiqomah, N., dan F. Novika. 2025. “Comparative Performance of IndoBERT and IndoLEM in Extracting Health Impacts from Indonesian-Language Online News Articles”. *COSIE (Journal of Indonesian Computational Science & Engineering)*.
- Jerfy, A., O. Selden, dan R. Balkrishnan. 2024. “The Growing Impact of Natural Language Processing in Healthcare and Public Health”. *Inquiry* 61:469580241290095. <https://doi.org/10.1177/00469580241290095>.
- Khairat, Saif, Ryan Sandefer, David Marc, dan Lee Pyles. 2019. “Importance of Clinical Decision Support System Response Time Monitoring: A Case Report”. *JAMIA Open* 2 (3): 273–277. <https://doi.org/10.1093/jamiaopen/ooz022>.
- Khurana, D., A. Koli, K. Khatter, dan S. Singh. 2023. “Natural Language Processing: State of the Art, Current Trends and Challenges”. *Multimedia Tools and Applications* 82 (3): 3713–3744. <https://doi.org/10.1007/s11042-022-13428-4>.
- Kipf, Thomas N., dan Max Welling. 2017. “Semi-Supervised Classification with Graph Convolutional Networks”. *arXiv preprint arXiv:1609.02907*.
- Kurniawati, Fivy, Nanang Munif Yasin, Amila Dina, Sanses Atana, dan Sarah Nabila Hakim. 2020. “Kajian Adverse Drug Reactions Terkait Interaksi Obat di Bangsal Rawat Inap Rumah Sakit Akademik UGM”. *Jurnal Farmasi Indonesia* 30 (4): 191–200.
- Kusumawardani, Renny Pradina, dan Katarina Nimas Kusumawati. 2024. “Named Entity Recognition in the Medical Domain for Indonesian Language Health Consultation Services Using Bidirectional-LSTM-CRF Algorithm”. *Procedia Computer Science* 245:1146–1156. ISSN: 1877-0509. <https://doi.org/10.1016/j.procs.2024.10.344>.
- Lafferty, John, Andrew McCallum, dan Fernando C. N. Pereira. 2001. “Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data”. Dalam *Proceedings of the Eighteenth International Conference on Machine Learning (ICML 2001)*, 282–289. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc.

- Le Louët, H., dan P. J. Pitts. 2023. “Twenty-First Century Global ADR Management: A Need for Clarification, Redesign, and Coordinated Action”. *Therapeutic Innovation & Regulatory Science* 57 (1): 100–103. <https://doi.org/10.1007/s43441-022-00443-8>.
- Lewis, Patrick, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, H. Kućek, dkk. 2020. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. *Advances in Neural Information Processing Systems (NeurIPS)* 33:9459–9474.
- Liddy, Elizabeth D. 2001. *Natural Language Processing*. Syracuse, NY: Syracuse University, School of Information Studies.
- Liu, S., A. Wang, X. Xiu, M. Zhong, dan S. Wu. 2024. “Evaluating Medical Entity Recognition in Health Care: Entity Model Quantitative Study”. *JMIR Medical Informatics* 12:e59782. <https://doi.org/10.2196/59782>.
- Manning, Christopher D., Prabhakar Raghavan, dan Hinrich Schütze. 2008. *Introduction to Information Retrieval*. Cambridge, UK: Cambridge University Press. ISBN: 978-0-521-86571-5.
- Masnoon, Niba, Sepehr Shakib, Lisa Kalisch-Ellett, dan Geoffrey E. Caughey. 2017. “What is polypharmacy? A systematic review of definitions”. *BMC Geriatrics* 17 (1): 230. <https://doi.org/10.1186/s12877-017-0621-2>.
- Miller, Robert B. 1968. “Response Time in Man-Computer Conversational Transactions”. Dalam *Proceedings of the December 9–11, 1968, Fall Joint Computer Conference, Part I*, 267–277. ACM. <https://doi.org/10.1145/1476589.1476628>.
- Molenaar-Kuijsten, L., D. E. M. Van Balen, J. H. Beijnen, N. Steeghs, dan A. D. R. Huitema. 2021. “A review of CYP3A drug-drug interaction studies: Practical guidelines for patients using targeted oral anticancer drugs”. *Frontiers in Pharmacology* 12:670862. <https://doi.org/10.3389/fphar.2021.670862>.
- Neha, F., D. Bhati, dan D. K. Shukla. 2025. “Retrieval-Augmented Generation (RAG) in Healthcare: A Comprehensive Review”. *AI* 6 (1): 226. <https://doi.org/10.3390/ai6090226>.

- Nguyen, T., X. Liu, W. Abuhashem, R. Bussing, dan A. G. Winterstein. 2020. "Quality of evidence supporting major psychotropic drug-drug interaction warnings: A systematic literature review". *Pharmacotherapy* 40:455–468. <https://doi.org/10.1002/phar.2382>.
- Nielsen, Jakob. 1993. *Usability Engineering*. Boston, MA: Academic Press. ISBN: 978-0-12-518406-9.
- Palleria, C., A. Di Paolo, C. Giofrè, dkk. 2013. "Pharmacokinetic drug-drug interaction and their implication in clinical management". *Journal of Research in Medical Sciences* 18 (7): 601–610.
- Permadi, Yulian Wahyu, Akrom, Imam Riadi, dan St Rahmatullah. 2025. "Analisis Polifarmasi Terhadap Interaksi Obat Di Rumah Sakit Umum Kota Pekalongan". *Lambda: Jurnal Ilmiah Pendidikan MIPA dan Aplikasinya* 5 (1): 69–82. <https://doi.org/10.58218/lambda.v5i1.1200>.
- Perwirani, Resia, dan Ika Puspita Sari. 2022. "Perancangan Clinical Decision Support System (CDSS) untuk Drug Drug Interaction (DDI) pada e-Prescription". *Jurnal Manajemen dan Pelayanan Farmasi UGM (Yogyakarta)*.
- Pichini, S., A. Di Trana, O. García-Algar, dan F. P. Busardò. 2023. "Editorial: Drug-drug interactions in pharmacology". *Frontiers in Pharmacology* 14:1155738. <https://doi.org/10.3389/fphar.2023.1155738>.
- Powers, David M. W. 2011. "Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness and Correlation". *Journal of Machine Learning Technologies* 2 (1): 37–63.
- Qorib, M. R., dan M. Adriani. 2018. "Building MEDISCO: Indonesian Speech Corpus for Medical Domain". *International Conference on Asian Language Processing (IALP)*, 133–138. <https://doi.org/10.1109/IALP.2018.8629259>.
- Quinn, T. P., M. Senadeera, S. Jacobs, S. Coghlan, dan V. Le. 2021. "Trust and Medical AI: The Challenges We Face and the Expertise Needed to Overcome Them". *Journal of the American Medical Informatics Association* 28 (4): 890–894. <https://doi.org/10.1093/jamia/ocaa268>.
- Ratnasari, Chanifah, Sri Kusumadewi, dan Linda Rosita. 2015. "Natural Language Parsing of Patient Complaints in Indonesian Language". *Proceedings of the 2015 Technology Innovation in ICT Conference (TICST)*, <https://doi.org/10.1109/TICST.2015.7369373>.

- Ravi, Divya, dan Renuka Sindhgatta. 2025. "Exploring Trust and Transparency in Retrieval-Augmented Generation for Domain Experts". *Proceedings of the ACM Conference on Human Factors in Computing Systems Extended Abstracts (CHI EA)* (New York, NY, USA), 254. <https://doi.org/10.1145/3706599.3719985>.
- Rayhan, A., dan R. Rayhan. 2023. *Natural Language Processing: Transforming How Machines Understand Human Language*. <https://doi.org/10.13140/RG.2.2.34900.99200>.
- Saito, Takaya, dan Marc Rehmsmeier. 2015. "The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets". *PLOS ONE* 10 (3): e0118432. <https://doi.org/10.1371/journal.pone.0118432>.
- Samudra, Gufranaka, Ahmad Turmudi Zy, dan Ermanto. 2025. "Implementasi Retrieval Augmented Generation (RAG) dalam Perancangan Chatbot Kesehatan Pencernaan". *JSAI (Journal Scientific and Applied Informatics)* 8 (1): 181–188. <https://doi.org/10.36085/jsai.v8i1.7678>.
- Sommerville, Ian. 2016. *Software Engineering*. 10th edisi. Boston, MA: Pearson Education. ISBN: 978-0-13-394303-0.
- Sutton, R. T., D. Pincock, D. C. Baumgart, D. C. Sadowski, R. N. Fedorak, dan K. I. Kroeker. 2020. "An Overview of Clinical Decision Support Systems: Benefits, Risks, and Strategies for Success". *Nature Medicine* 26 (2): 143–147.
- Tjong Kim Sang, Erik F., dan Fien De Meulder. 2003. "Introduction to the CoNLL-2003 Shared Task: Language-Independent Named Entity Recognition". Dalam *Proceedings of the Seventh Conference on Natural Language Learning at HLT-NAACL 2003*, 142–147. <https://doi.org/10.3115/1119176.1119195>.
- Varghese, D., C. Ishida, P. Patel, dan H. H. Koya. 2024. "Polypharmacy". Dalam *StatPearls*. Treasure Island (FL): StatPearls Publishing.
- Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, dan Illia Polosukhin. 2017. "Attention Is All You Need". *arXiv preprint arXiv:1706.03762*.
- Wangge, G., dan W. Akbar. 2016. *Knowledge, attitudes and practice of pharmacovigilance among health care professionals in Indonesia*. Neliti.

- Wasylewicz, A. T. M., dan A. M. J. W. Scheepers-Hoeks. 2019. "Clinical Decision Support Systems". Chapter 11 dalam *Fundamentals of Clinical Data Science*, disunting oleh Peter Kubben, Michel Dumontier, dan Andre Dekker. Cham, Switzerland: Springer. https://doi.org/10.1007/978-3-319-99713-1_11.
- Wiegers, Karl, dan Joy Beatty. 2013. *Software Requirements*. 3rd edisi. Redmond, WA: Microsoft Press. ISBN: 978-0-7356-7966-5.
- Wilie, Bryan, Karissa Vincentio, Genta Indra Winata, Samuel Cahyawijaya, Zhi Yuan Lim, Rida Soleman, Rahmad Mahendra, Pascale Fung, Syafri Bahar, dan Ayu Purwarianti. 2020. "IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding". *arXiv preprint arXiv:2009.05387*.
- World Health Organization. 2020. *Polypharmacy: A Challenge for Global Health*. Technical report. World Health Organization.
- Wu, Zonghan, Shirui Pan, Fengwen Chen, Guodong Long, Chengqi Zhang, dan Philip S. Yu. 2020. "A Comprehensive Survey on Graph Neural Networks". *IEEE Transactions on Neural Networks and Learning Systems* 32 (1): 4–24. <https://doi.org/10.1109/TNNLS.2020.2978386>.
- Yoon, Woosung, Changhee So, Jinhyuk Lee, dkk. 2019. "CollaboNet: collaboration of deep neural networks for biomedical named entity recognition". *BMC Bioinformatics* 20 (Suppl 10): 249. <https://doi.org/10.1186/s12859-019-2813-6>.

LAMPIRAN A

Contoh Perbandingan Laporan RAG dan Tanpa RAG

Lampiran ini menyajikan contoh lengkap perbandingan laporan klinis yang dihasilkan oleh mode RAG (dengan dokumen referensi dari basis pengetahuan) dan mode tanpa RAG (hanya menggunakan pengetahuan internal LLM) untuk tiga kasus representatif.

A.1 Kasus 1: Interaksi Tinggi (Warfarin + Simvastatin)

Input: “Saya pusing dan mimisan setelah minum warfarin dan simvastatin”

NER: Obat = [warfarin, simvastatin], Gejala = [pusing, mimisan]

DDI: warfarin $\leftrightarrow$ simvastatin: $P = 0,8688$ (RELIABLE)

A.1.1 Laporan dengan RAG

Panjang laporan: 3.305 karakter. **Dokumen retrieval:** 5.

```
1  ### Laporan Klinis Interaksi Obat
2
3  **Data Pasien:**
4  *   Keluhan: Pusing dan mimisan setelah minum warfarin dan simvastatin.
5  *   Obat yang dikonsumsi: Warfarin, Simvastatin.
6  *   Gejala yang dilaporkan: Pusing, mimisan.
7
8  ---
9
10 ### 1. Ringkasan Temuan
11
12 Pasien mengonsumsi warfarin dan simvastatin. Berdasarkan analisis, terdeteksi
    potensi interaksi antara warfarin dan simvastatin dengan probabilitas 86.9%.
    Interaksi ini berpotensi meningkatkan aktivitas antikoagulan warfarin.
13
14 ### 2. Analisis Interaksi Obat
15
16 **Pasangan Obat:** Warfarin  $\leftrightarrow$  Simvastatin
17
18 *   **Mekanisme Interaksi:** Simvastatin dapat meningkatkan aktivitas antikoagulan
    dari warfarin. Mekanisme spesifiknya dapat bervariasi, namun secara umum,
    simvastatin dapat memengaruhi metabolisme atau ikatan protein warfarin,
    sehingga meningkatkan kadar warfarin bebas dalam sirkulasi atau memperpanjang
    waktu paruhnya. Hal ini dapat menyebabkan efek pengenceran darah yang
```

```

berlebihan.
19 * **Tingkat Keparahan:** Interaksi terdeteksi dengan probabilitas tinggi (86.9%)
.
20 * **Efek yang Mungkin Terjadi:** Peningkatan risiko perdarahan akibat efek
antikoagulan warfarin yang berlebihan.
21
22 ### 3. Korelasi Gejala dengan Interaksi Obat
23
24 Gejala pusing dan mimisan yang dilaporkan oleh pasien sangat mungkin berkaitan
dengan interaksi antara warfarin dan simvastatin. Peningkatan aktivitas
antikoagulan warfarin dapat menyebabkan gangguan pembekuan darah, yang
berujung pada gejala seperti mimisan (perdarahan dari hidung) dan potensi
perdarahan lain yang dapat bermanifestasi sebagai pusing (misalnya, akibat
kehilangan darah).
25
26 ### 4. Rekomendasi Tindakan
27
28 Tenaga medis disarankan untuk:
29
30 * **Pemantauan Ketat:** Lakukan pemantauan ketat terhadap parameter koagulasi
pasien, terutama International Normalized Ratio (INR), secara lebih sering
dari biasanya.
31 * **Evaluasi Gejala:** Segera evaluasi gejala pusing dan mimisan yang dilaporkan
. Lakukan pemeriksaan fisik untuk menilai tanda-tanda perdarahan.
32 * **Penyesuaian Dosis:** Pertimbangkan penyesuaian dosis warfarin. Jika INR
meningkat secara signifikan atau terdapat tanda-tanda perdarahan, dosis
warfarin mungkin perlu dikurangi.
33 * **Pertimbangkan Alternatif:** Jika memungkinkan dan sesuai dengan kondisi
klinis pasien, pertimbangkan untuk mengganti simvastatin dengan obat penurun
lipid lain yang memiliki potensi interaksi lebih rendah dengan warfarin, atau
sebaliknya. Konsultasi dengan dokter spesialis farmakologi klinis atau
spesialis terkait dapat dipertimbangkan.
34
35 ### 5. Sumber Referensi
36
37 1. DrugBank. (n.d.). *Drug Interaction: Simvastatin <-> Warfarin*. Diakses dari [
drugbank/interaction]
38 2. DrugBank. (n.d.). *Drug Interaction: Warfarin <-> Simvastatin*. Diakses dari [
drugbank/interaction]
39 3. DrugBank. (n.d.). *Drug Interaction: Simvastatin <-> (S)-Warfarin*. Diakses
dari [drugbank/interaction]
40 4. DrugBank. (n.d.). *Drug Interaction: Simvastatin <-> (R)-warfarin*. Diakses
dari [drugbank/interaction]
41 5. DrugBank. (n.d.). *Drug Interaction: Warfarin <-> Mevastatin*. Diakses dari [
drugbank/interaction]
42
43 ---
44
45 **Disclaimer:**
46 Informasi ini dihasilkan oleh sistem AI untuk mendukung keputusan klinis.
Informasi ini bersifat pendukung keputusan dan tidak menggantikan penilaian
klinis profesional. Konsultasikan dengan dokter Anda untuk evaluasi dan
tindakan lebih lanjut.

```

A.1.2 Laporan tanpa RAG

Panjang laporan: 2.739 karakter. **Dokumen *retrieval*:** 0 (jalur RAG dinonaktifkan).

```
1 Tentu, berikut adalah laporan klinis berdasarkan data yang Anda berikan:
2
3 ### 1. Ringkasan Temuan
4 Pasien melaporkan keluhan pusing dan mimisan setelah mengonsumsi warfarin dan
   simvastatin. Berdasarkan analisis, terdeteksi potensi interaksi antara
   warfarin dan simvastatin dengan probabilitas 86.9%.
5
6 ### 2. Analisis Interaksi Obat
7 * **Warfarin <-> Simvastatin**
8 * **Mekanisme Interaksi:** Simvastatin dapat menghambat enzim sitokrom P450
   (CYP) 3A4, yang merupakan jalur metabolisme utama untuk warfarin. Penghambatan
   ini dapat meningkatkan kadar warfarin dalam darah.
9 * **Tingkat Keparahan:** Interaksi terdeteksi.
10 * **Efek yang Mungkin Terjadi:** Peningkatan kadar warfarin dalam darah
   dapat meningkatkan risiko perdarahan, yang dapat bermanifestasi sebagai gejala
   seperti mimisan dan pusing.
11
12 ### 3. Korelasi Gejala dengan Interaksi Obat
13 Gejala pusing dan mimisan yang dilaporkan oleh pasien sangat mungkin berkaitan
   dengan potensi interaksi antara warfarin dan simvastatin. Peningkatan kadar
   warfarin akibat interaksi ini dapat menyebabkan efek antikoagulan yang
   berlebihan, sehingga meningkatkan risiko perdarahan (mimisan) dan gejala
   terkait seperti pusing.
14
15 ### 4. Rekomendasi Tindakan
16 * **Pemantauan yang Diperlukan:**
17 * Pantau nilai International Normalized Ratio (INR) secara ketat pada pasien
   yang mengonsumsi warfarin dan simvastatin bersamaan.
18 * Amati tanda-tanda perdarahan, termasuk mimisan, memar yang tidak biasa,
   perdarahan gusi, atau darah dalam urin/feses.
19 * Evaluasi gejala pusing secara klinis untuk menyingkirkan penyebab lain
   atau tanda perdarahan intrakranial.
20 * **Penyesuaian Dosis Jika Perlu:**
21 * Jika INR meningkat secara signifikan atau muncul tanda-tanda perdarahan,
   pertimbangkan untuk mengurangi dosis warfarin.
22 * Penyesuaian dosis simvastatin mungkin juga perlu dipertimbangkan, namun
   prioritas utama adalah manajemen INR dan risiko perdarahan.
23 * **Alternatif Obat Jika Diperlukan:**
24 * Jika interaksi tidak dapat dikelola dengan penyesuaian dosis,
   pertimbangkan untuk mengganti simvastatin dengan statin lain yang memiliki
   interaksi minimal dengan warfarin (misalnya, pravastatin atau rosuvastatin,
   tergantung pada profil pasien dan ketersediaan).
25 * Evaluasi kembali kebutuhan terapi warfarin dan simvastatin secara
   keseluruhan.
26
27 ### 5. Sumber Referensi
28 Tidak ada informasi referensi spesifik yang tersedia dalam data yang diberikan.
29
30 ### Disclaimer
31 Informasi ini dihasilkan oleh sistem AI untuk mendukung keputusan klinis.
   Informasi ini bersifat pendukung keputusan dan tidak menggantikan penilaian
   klinis profesional. Konsultasikan dengan dokter atau tenaga medis yang
```

Adapun perbedaan utama antara mode RAG–LLM dengan mode tanpa RAG yaitu sebagai berikut.

1. Dari segi sitasi, RAG menyertakan 5 referensi; tanpa RAG menyertakan 0 referensi.
2. Dari segi mekanisme, kedua mode berhasil menyebutkan mekanisme yang benar.
3. Dari segi rekomendasi, kedua mode memberikan rekomendasi pemantauan INR.

A.2 Kasus 5: Obat Tidak Dikenal di Basis Data (Omeprazole + Clopidogrel)

Input: “Perut saya nyeri setelah minum omeprazole dan clopidogrel”

NER: Obat = [omeprazole, clopidogrel], Gejala = [perut]

DDI: omeprazole $\leftrightarrow$ clopidogrel: $P = 0,0000$ (UNRELIABLE — omeprazole tidak terdapat dalam basis data ChCh-Miner)

A.2.1 Laporan dengan RAG

Meskipun model DDI tidak dapat memprediksi interaksi (karena omeprazole tidak ada dalam basis data), modul RAG berhasil menemukan dokumen relevan dari DrugBank dan DDI2013 yang menjelaskan bahwa omeprazole menghambat enzim CYP2C19, yang berperan penting dalam metabolisme clopidogrel menjadi bentuk aktifnya. Laporan menyebutkan bahwa interaksi ini dapat menurunkan paparan (AUC) terhadap metabolit aktif clopidogrel hingga 50%, serta merekomendasikan penggantian omeprazole dengan pantoprazole yang memiliki profil interaksi lebih aman. Total 7 sitasi sumber disertakan. Panjang laporan: ~ 3.500 karakter.

A.2.2 Laporan tanpa RAG

Laporan tanpa RAG menyatakan bahwa “tidak terdeteksi interaksi obat yang signifikan antara omeprazole dan clopidogrel.” Laporan tidak menyebutkan mekanisme CYP2C19, tidak memperingatkan tentang penurunan efektivitas clopidogrel, dan tidak merekomendasikan alternatif obat. Panjang laporan: ~ 1.700 karakter. Adapun perbedaan utama antara mode RAG–LLM dengan mode tanpa RAG yaitu sebagai berikut.

1. Dari segi sitasi, RAG menyertakan 7 referensi; tanpa RAG menyertakan 0 referensi.
2. Dari segi mekanisme, RAG benar mengidentifikasi CYP2C19; tanpa RAG

gagal total — menyatakan tidak ada interaksi.

3. Dari segi implikasi klinis, kegagalan tanpa RAG pada kasus ini berpotensi **berbahaya secara klinis**, karena interaksi omeprazole-clopidogrel telah terdokumentasi oleh FDA sebagai interaksi yang harus dihindari.

A.3 Kasus 8: Input Non-Medis

Input: “Saya mau tidur karena capek kerja”

NER: Obat = [], Gejala = [capek]

DDI: Dilewati (tidak ada obat)

A.3.1 Laporan dengan RAG

Sistem berhasil mengenali bahwa input tidak mengandung informasi obat. RAG *retrieval* dilewati (tidak ada pencarian dokumen) dan Gemini menghasilkan laporan yang menyatakan bahwa tidak ada obat yang teridentifikasi sehingga analisis interaksi tidak dapat dilakukan. Laporan menyarankan pasien untuk memberikan informasi obat yang dikonsumsi jika memerlukan evaluasi interaksi. Panjang laporan: ~1.600 karakter.

A.3.2 Laporan tanpa RAG

Laporan tanpa RAG memberikan respons yang serupa, menyatakan tidak ada obat yang terdeteksi. Kedua mode berperilaku konsisten pada kasus non-medis. Adapun perbedaan utama antara mode RAG–LLM dengan mode tanpa RAG yaitu sebagai berikut.

1. Kedua mode berperilaku **identik** pada kasus non-medis — tidak menghasilkan informasi medis yang menyesatkan.
2. Perbaikan *stopwords* (“mau”, “tidur” disaring) dan pelewatan RAG *retrieval* pada kasus tanpa obat berfungsi dengan baik.

A.4 Contoh Keluaran Mode *Template Fallback*

Pada evaluasi 83 kasus uji *end-to-end*, seluruh kasus berhasil diproses oleh mode LLM (Gemini 2.5 Flash/Flash-Lite) tanpa kegagalan, sehingga tidak ada kasus yang memicu jalur *template fallback* secara aktual. Untuk memvalidasi mekanisme *graceful degradation* ketika layanan LLM tidak tersedia (mis. kuota API habis, kegagalan jaringan, atau *deployment* sepenuhnya *offline*), berikut disajikan keluaran mode *template fallback* yang dihasilkan langsung oleh `ClinicalReportGenerator.generate_structured_fallback` pada Kasus 1 (warfarin + simvastatin) dengan masukan NER, prediksi DDI, dan dokumen

retrieval yang identik dengan jalur RAG normal.

Input: “Saya pusing dan mimisan setelah minum warfarin dan simvastatin”

NER: Obat = [warfarin, simvastatin], Gejala = [pusing, mimisan]

DDI: warfarin ↔ simvastatin: $P = 0,8688$ (RELIABLE)

Panjang laporan: 2.515 karakter (vs ~3.300 karakter pada mode RAG-LLM, lihat Bagian A Kasus 1).

```
1 # LAPORAN PENDUKUNG KEPUTUSAN KLINIS
2 *Dihasilkan oleh Sistem CDSS Hybrid*
3
4 ## 1. Ringkasan Temuan
5
6 **Keluhan pasien:** Saya pusing dan mimisan setelah minum warfarin dan simvastatin
7
8 **Obat yang teridentifikasi:** warfarin, simvastatin
9 **Gejala yang dilaporkan:** pusing, mimisan
10
11 Sistem mendeteksi **1 potensi interaksi obat** dari 1 pasangan yang dianalisis:
12     warfarin dan simvastatin (86.9%).
13
14 ## 2. Analisis Interaksi Obat
15
16 ### warfarin + simvastatin
17 - **Status:** INTERAKSI TERDETEKSI
18 - **Probabilitas:** 86.9%
19 - **Tingkat kepercayaan prediksi:** Tinggi (Kemungkinan besar terjadi interaksi)
20 - **Informasi terkait:**
21     - Drug Interaction: Simvastatin <-> Warfarin Description: Simvastatin may
22       increase the anticoagulant activities of Warfarin.
23     - Drug Interaction: Warfarin <-> Simvastatin Description: Simvastatin may
24       increase the anticoagulant activities of Warfarin.
25     - Drug Interaction: Simvastatin <-> (S)-Warfarin Description: Simvastatin may
26       increase the anticoagulant activities of (S)-Warfarin.
27
28 ## 3. Korelasi Gejala dengan Interaksi Obat
29
30 Gejala yang dilaporkan pasien mungkin berkaitan dengan interaksi obat yang
31 terdeteksi:
32
33 - **Pusing:** Pusing dapat merupakan efek samping dari perubahan metabolisme obat
34 akibat interaksi.
35 - **Mimisan:** Mimisan (epistaksis) dapat mengindikasikan peningkatan efek
36 antikoagulan, terutama jika terkait warfarin.
37
38 ## 4. Rekomendasi Tindakan
39
40 Berdasarkan analisis di atas, berikut rekomendasi untuk tenaga medis:
41
42 **Pemantauan:**
43 - Pantau efek samping dari kombinasi warfarin dan simvastatin
44 - Periksa nilai INR (International Normalized Ratio) secara berkala
```

```

38 - Pantau tanda-tanda perdarahan (mimisan, gusi berdarah, memar)
39 - Pantau fungsi hati dan kadar enzim CK (Creatine Kinase)
40
41 **Penyesuaian terapi:**
42 - Pertimbangkan penyesuaian dosis berdasarkan respons klinis pasien
43 - Evaluasi apakah kombinasi obat masih diperlukan
44 - Pertimbangkan alternatif obat dengan risiko interaksi lebih rendah jika tersedia
45
46 ## 5. Sumber Referensi
47
48 - DrugBank (database interaksi obat)
49 - Model prediksi MFFGNN (Multi-type Feature Fusion Graph Neural Network)
50 - Model NER IndoBERT untuk ekstraksi entitas medis
51
52 ---
53
54 ## Disclaimer
55 Laporan ini dihasilkan secara otomatis oleh sistem pendukung keputusan klinis (
    CDSS) berbasis kecerdasan buatan. Informasi yang disajikan **bukan merupakan
    diagnosis medis** dan tidak menggantikan penilaian klinis oleh tenaga
    kesehatan profesional. Selalu konsultasikan dengan dokter atau apoteker Anda
    sebelum mengambil keputusan terkait pengobatan.

```

Adapun beberapa perbedaan antara mode *template fallback* dengan mode RAG-LLM yaitu sebagai berikut.

1. Mekanisme interaksi

Mode *template* mengutip cuplikan deskripsi dari DrugBank (*verbatim* hingga 200 karakter); mode RAG-LLM mensintesis penjelasan mekanisme dalam bahasa Indonesia yang lebih mengalir dengan mengaitkan beberapa dokumen.

2. Sitasi

Mode *template* hanya mencantumkan nama sumber dataset (DrugBank, TWOSIDES, DDI2013) tanpa nomor sitasi; mode RAG-LLM menyisipkan sitasi inline bernomor [N] pada klaim spesifik (5 sitasi pada Kasus 1).

3. Korelasi gejala

Mode *template* menggunakan kamus statis pemetaan gejala → kalimat penjelasan (8 entri); mode RAG-LLM menghasilkan korelasi yang lebih kontekstual berdasarkan dokumen yang ditemukan.

4. Rekomendasi

Kedua mode menghasilkan rekomendasi pemantauan INR dan enzim CK; mode *template* menggunakan aturan *if-then* berbasis nama obat (mis. “jika ada warfarin, tambahkan pemantauan INR”), sedangkan mode RAG-LLM dapat menyesuaikan rekomendasi berdasarkan kombinasi gejala.

5. Panjang laporan

2.515 karakter (*template*) vs ~ 3.300 karakter (RAG-LLM); selisih sekitar

24% mencerminkan kepadatan informasi tambahan dari LLM.

6. **Ketersediaan**

Mode *template* berjalan sepenuhnya *offline* tanpa dependensi API eksternal, sehingga menjamin reliabilitas sistem (NF01) sekalipun layanan Gemini tidak dapat diakses.

LAMPIRAN B

Daftar Kasus Uji *End-to-End*

Lampiran ini menyajikan daftar lengkap 83 kasus uji yang digunakan pada evaluasi *end-to-end* sistem CDSS sebagaimana dibahas pada Subbab VI.5. Setiap baris memuat nomor kasus, keluhan pasien apa adanya, daftar obat yang berhasil diekstraksi oleh modul NER setelah resolusi alias, dan ringkasan prediksi probabilitas interaksi yang dihasilkan modul DDI. Tanda “–” menunjukkan bahwa modul tidak menghasilkan keluaran karena tidak ada obat yang terekstraksi atau jumlah obat kurang dari dua.

Kasus 1–57 merepresentasikan skenario umum dengan beragam mekanisme interaksi (farmakokinetik, farmakodinamik, polifarmasi, sinergisme), sedangkan Kasus 58–83 merupakan *stress test* yang sengaja mencakup obat-obat di luar cakupan basis data ChCh-Miner serta keluhan dengan narasi panjang dan kompleks.

Tabel B.1 Daftar 83 Kasus Uji *End-to-End* Sistem CDSS

No	Keluhan Pasien	Obat Terekstraksi	Probabilitas DDI
1	Saya pusing dan mimisan setelah minum warfarin dan simvastatin	warfarin, simvastatin	warfarin–simvastatin: 0,869
2	Saya minum paracetamol dan warfarin, sekarang pusing dan mual	acetaminophen, warfarin	acetaminophen–warfarin: 0,555
3	Saya jantung berdebar setelah minum fluoxetine dan tramadol	fluoxetine, tramadol	fluoxetine–tramadol: 0,997
4	Saya minum amlodipine dan lisinopril, kaki saya bengkak	amlodipine, lisinopril	amlodipine–lisinopril: 0,045
5	Perut saya nyeri setelah minum omeprazole dan clopidogrel	omeprazole, clopidogrel	omeprazole–clopidogrel: 0,000

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

No	Keluhan Pasien	Obat Terekstraksi	Probabilitas DDI
6	Saya mual setelah minum metformin	metformin	—
7	Saya pusing dan mual sejak pagi, badan lemas	—	—
8	Saya mau tidur karena capek kerja	—	—
9	Saya minum warfarin, aspirin, dan paracetamol, sekarang mimisan dan pusing	warfarin, aspirin, acetaminophen	warfarin–aspirin: 0,942; warfarin–acetaminophen: 0,573; aspirin–acetaminophen: 0,906
10	Saya penderita diabetes, kaki saya kesemutan dan lemas	—	—
11	Saya gusi berdarah setelah minum aspirin dan warfarin bersamaan	aspirin, warfarin	aspirin–warfarin: 0,988
12	Saya tremor dan berkeringat setelah minum sertralin dan tramadol	sertraline, tramadol	sertraline–tramadol: 0,997
13	Saya mual dan lemas setelah minum methotrexate dan ibuprofen	methotrexate, ibuprofen	methotrexate–ibuprofen: 0,997
14	Sesak napas saya makin parah setelah minum ciprofloxacin dan teofilin	ciprofloxacin, theophylline	ciprofloxacin–theophylline: 0,776
15	Saya minum carbamazepine dan pil KB, mens saya tidak teratur	carbamazepine	—
16	Otot saya nyeri setelah minum simvastatin dan gemfibrozil	simvastatin, gemfibrozil	simvastatin–gemfibrozil: 0,715
17	Kaki saya bengkak setelah minum diklofenak dan captopril	diclofenac, captopril	diclofenac–captopril: 0,599
18	Saya ngantuk berat setelah minum olanzapin dan amitriptilin	olanzapine, amitriptyline	olanzapine–amitriptyline: 0,987

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

No	Keluhan Pasien	Obat Terekstraksi	Probabilitas DDI
19	Saya memar-memar setelah minum warfarin dan aspirin dan clopidogrel	warfarin, aspirin, clopidogrel	warfarin–aspirin: 0,942; warfarin–clopidogrel: 0,926; aspirin–clopidogrel: 0,896
20	Saya minum amoxicillin dan paracetamol untuk demam, tidak ada keluhan	amoxicillin, acetaminophen	amoxicillin–acetaminophen: 0,000
21	Saya minum rifampisin dan warfarin, INR saya turun drastis	rifampicin, warfarin, inr	rifampicin–warfarin: 0,958; rifampicin–inr: 0,000; warfarin–inr: 0,000
22	Dok saya sesak napas setelah minum propranolol dan salbutamol	propranolol, salbutamol	propranolol–salbutamol: 0,308
23	Saya mengonsumsi lithium dan ibuprofen, tangan saya tremor	lithium ion, ibuprofen	lithium ion–ibuprofen: 0,994
24	Saya minum phenytoin dan carbamazepine, saya pusing berat	phenytoin, carbamazepine	phenytoin–carbamazepine: 0,990
25	Saya mual muntah setelah minum digoxin dan amiodarone	digoxin, amiodarone	digoxin–amiodarone: 0,794
26	Saya konsumsi metformin dan alkohol, perut kram dan mual	metformin, ethanol	metformin–ethanol: 0,881
27	Saya minum clopidogrel dan aspirin, gusi saya berdarah terus	clopidogrel, aspirin	clopidogrel–aspirin: 0,887
28	Saya minum simvastatin dan amlodipine, otot saya nyeri	simvastatin, amlodipine	simvastatin–amlodipine: 0,378
29	Saya konsumsi prednisone dan ibuprofen, perut saya perih	prednisone, ibuprofen	prednisone–ibuprofen: 0,000
30	Saya minum amoxicillin untuk batuk, tidak ada keluhan lain	amoxicillin	–
31	Saya minum methotrexate dan trimethoprim, badan lemas sekali	methotrexate, trimethoprim	methotrexate–trimethoprim: 0,757

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

No	Keluhan Pasien	Obat Terekstraksi	Probabilitas DDI
32	Saya mengonsumsi fluconazole dan simvastatin, otot kaki sakit	fluconazole, simvastatin	fluconazole–simvastatin: 0,984
33	Saya minum atenolol dan verapamil, detak jantung saya lambat	atenolol, verapamil	atenolol–verapamil: 0,674
34	Saya konsumsi ciprofloxacin dan antasida, infeksi tidak sembuh	ciprofloxacin, aluminum hydroxide	ciprofloxacin–aluminum hydroxide: 0,768
35	Saya pakai insulin dan metformin, gula darah saya drop	insulin, metformin	insulin–metformin: 0,000
36	Saya minum sertraline saja, kadang mual di pagi hari	sertraline	–
37	Badan saya demam dan pusing tapi tidak minum obat apapun	–	–
38	Saya minum teh hijau dan vitamin setiap hari, sehat saja	–	–
39	Saya minum warfarin dan erythromycin, mimisan dan memar	warfarin, erythromycin	warfarin–erythromycin: 0,872
40	Saya minum diltiazem dan simvastatin, otot saya sakit semua	diltiazem, simvastatin	diltiazem–simvastatin: 0,790
41	Dok saya konsumsi levothyroxine dan antasida, hormon tidak turun	thyroxine, aluminum hydroxide	thyroxine–aluminum hydroxide: 0,823
42	Saya minum amitriptylin dan tramadol, kepala saya sangat berat	amitriptyline, tramadol	amitriptyline–tramadol: 1,000
43	Saya konsumsi allopurinol dan azathioprine, leukosit saya drop	allopurinol, azathioprine, leukosit	allopurinol–azathioprine: 0,558; allopurinol–leukosit: 0,000; azathioprine–leukosit: 0,000

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

No	Keluhan Pasien	Obat Terekstraksi	Probabilitas DDI
44	Saya minum CTM dan alprazolam untuk alergi, sangat mengantuk	chlorpheniramine, alprazolam	chlorpheniramine–alprazolam: 0,011
45	Saya minum antalgin dan parasetamol, tidak ada keluhan	metamizole, acetaminophen	metamizole–acetaminophen: 0,294
46	Saya minum linezolid dan fluoxetine, jantung berdebar dan tremor	linezolid, fluoxetine	linezolid–fluoxetine: 0,998
47	Dok saya konsumsi tamoxifen dan paroxetine, kambuh kanker	tamoxifen, paroxetine	tamoxifen–paroxetine: 0,943
48	Saya minum cyclosporine dan ketoconazole, fungsi ginjal turun	cyclosporin a, ketoconazole	cyclosporin a–ketoconazole: 0,000
49	Saya rutin minum digoxin untuk gagal jantung. Minggu lalu dokter meresepkan clarithromycin untuk infeksi sinus. Sekarang mual, lemas, jantung berdebar pelan dan tidak teratur.	digoxin, clarithromycin	digoxin–clarithromycin: 0,962
50	Saya minum vitamin C saja setiap pagi, badan segar	vitamin c	–
51	Saya minum enalapril dan kalium klorida, lemas dan mual	enalapril, potassium chloride	enalapril–potassium chloride: 0,123
52	Dok saya minum fluoxetine dan warfarin, timbul memar di kulit	fluoxetine, warfarin	fluoxetine–warfarin: 0,875
53	Saya konsumsi nitroglycerin dan sildenafil, tekanan darah saya drop	nitroglycerin, sildenafil	nitroglycerin–sildenafil: 0,551
54	Saya minum asam mefenamat dan ranitidine, perih lambung hilang	mefenamic acid, ranitidine	mefenamic acid–ranitidine: 0,000

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

No	Keluhan Pasien	Obat Terekstraksi	Probabilitas DDI
55	Dok saya minum levofloxacin dan amiodarone, jantung berdebar	levofloxacin, amiodarone	levofloxacin–amiodarone: 0,031
56	Saya konsumsi gemfibrozil dan simvastatin, otot paha nyeri hebat	gemfibrozil, simvastatin	gemfibrozil–simvastatin: 0,786
57	Saya minum haloperidol dan olanzapine, kaku otot dan demam	haloperidol, olanzapine	haloperidol–olanzapine: 0,992
58	Saya minum paracetamol saja untuk sakit kepala ringan	acetaminophen	–
59	Saya konsumsi lisinopril dan spironolactone, kalium darah saya tinggi	lisinopril, spironolactone, potassium chloride	lisinopril–spironolactone: 0,218; lisinopril–potassium chloride: 0,114; spironolactone–potassium chloride: 0,853
60	Saya minum ciprofloxacin dan theophylline, mual dan jantung berdebar	ciprofloxacin, theophylline	ciprofloxacin–theophylline: 0,776
61	Dok saya minum metoprolol dan verapamil, denyut jantung jadi sangat lambat	metoprolol, verapamil	metoprolol–verapamil: 0,720
62	Saya minum digoxin dan amiodarone, mual dan penglihatan kabur	digoxin, amiodarone	digoxin–amiodarone: 0,794
63	Saya konsumsi rifampicin dan warfarin, INR saya turun drastis	rifampicin, warfarin	rifampicin–warfarin: 0,958
64	Saya minum methotrexate dan ibuprofen, lemas dan mual hebat	methotrexate, ibuprofen	methotrexate–ibuprofen: 0,997

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

No	Keluhan Pasien	Obat Terekstraksi	Probabilitas DDI
65	Saya rutin minum phenytoin untuk epilepsi. Saya mulai konsumsi omeprazole untuk maag, sekarang saya pusing, jalan limbung, mata berkedut, dan terasa bingung.	phenytoin, omeprazole	phenytoin–omeprazole: 0,000
66	Saya minum amlodipin saja untuk hipertensi ringan	amlodipine	—
67	Saya minum paracetamol dan amoksisilin dan deksametason untuk batuk pilek	acetaminophen, amoxicillin, dexamethasone	acetaminophen–amoxicillin: 0,000; acetaminophen–dexamethasone: 0,481; amoxicillin–dexamethasone: 0,000
68	Saya konsumsi kalsium dan vitamin D untuk osteoporosis	kalsium, vitamin d3	kalsium–vitamin d3: 0,000
69	Dok saya minum erythromycin dan warfarin, gusi mudah berdarah	erythromycin, warfarin	erythromycin–warfarin: 0,926
70	Saya konsumsi tramadol dan sertraline, gemetar dan berkeringat	tramadol, sertraline	tramadol–sertraline: 0,998
71	Saya minum carbamazepine dan warfarin, INR drop drastis	carbamazepine, warfarin, inr drop	carbamazepine–warfarin: 0,934; carbamazepine–inr drop: 0,000; warfarin–inr drop: 0,000
72	Dok saya konsumsi diazepam dan lorazepam, ngantuk berat sepanjang hari	diazepam, lorazepam	diazepam–lorazepam: 0,995

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

No	Keluhan Pasien	Obat Terekstraksi	Probabilitas DDI
73	Saya rutin minum warfarin untuk fibrilasi atrium. Dokter baru saja menambahkan cholestyramine untuk kolesterol. INR turun drastis dari 2.5 ke 1.1 dan kaki kanan saya bengkak nyeri.	warfarin, cholestyramine	warfarin–cholestyramine: 0,000
74	Saya minum antalgin saja untuk sakit kepala	metamizole	–
75	Saya konsumsi furosemide dan digoxin dan spironolactone, badan lemas	furosemide, digoxin, spironolactone	furosemide–digoxin: 0,967; furosemide–spironolactone: 0,816; digoxin–spironolactone: 0,837
76	Saya minum vitamin C dan zinc dan vitamin B12 untuk daya tahan tubuh	l-ascorbic acid, zinc, vitamin b12	l-ascorbic acid–zinc: 0,000; l-ascorbic acid–vitamin b12: 0,000; zinc–vitamin b12: 0,000
77	Dok saya minum amitriptyline dan clonidine, tekanan darah tetap tinggi	amitriptyline, clonidine	amitriptyline–clonidine: 0,531
78	Saya konsumsi antalgin dan ranitidine, perih lambung hilang	metamizole, ranitidine	metamizole–ranitidine: 0,000

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

No	Keluhan Pasien	Obat Terekstraksi	Probabilitas DDI
79	Dok, ibu saya umur 72 tahun. Sejak setahun lalu beliau didiagnosis atrial fibrilasi dan hipertensi, jadi rutin minum warfarin 5 mg dan amlodipine 10 mg setiap hari. Tiga bulan lalu dokter spesialis menambahkan amiodarone 200 mg karena denyut jantungnya tidak terkontrol. Karena ada keluhan nyeri sendi, beliau juga mulai minum aspirin tiap pagi sejak dua minggu lalu. Sekarang saya khawatir karena gusinya sering berdarah saat sikat gigi, ada memar di lengan padahal tidak terbentur, dan tadi pagi mimisan cukup banyak. Apakah ini berbahaya, dok?	warfarin, amlodipine, amiodarone	warfarin–amlodipine: 0,685; warfarin–amiodarone: 0,817; amlodipine–amiodarone: 0,805

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

No	Keluhan Pasien	Obat Terekstraksi	Probabilitas DDI
80	Dok, saya sudah konsultasi ke psikiater sejak 6 bulan lalu untuk depresi berat, dan diresepkan sertraline 100 mg setiap pagi. Selama ini cukup membantu mengontrol mood saya. Bulan lalu saya juga didiagnosis migrain kronis, dan dokter saraf meresepkan tramadol 50 mg untuk diminum saat kepala terasa sangat sakit. Beberapa hari terakhir saya merasa sangat gelisah, jantung berdebar kencang, tangan gemetar, dan keluar keringat dingin terutama setelah minum tramadol. Tadi malam saya bahkan sempat halusinasi dan suhu tubuh saya terasa naik. Saya bingung dok, apakah ini efek samping biasa atau ada masalah dengan kombinasi obat saya?	psikiater, sertraline, tramadol	psikiater–sertraline: 0,000; psikiater–tramadol: 0,000; sertraline–tramadol: 0,997

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

No	Keluhan Pasien	Obat Terekstraksi	Probabilitas DDI
81	Dokter, saya pasien transplantasi ginjal sejak 3 tahun lalu dan rutin minum cyclosporin 100 mg dua kali sehari serta mycophenolate 500 mg. Selama ini fungsi ginjal saya stabil dengan kreatinin sekitar 1,2. Dua minggu lalu saya kena bronkitis berat, lalu dokter umum meresepkan clarithromycin 500 mg dua kali sehari selama 10 hari. Setelah hari ke-7 saya merasa badan sangat lemas, tangan gemetar, kepala sangat pusing, kaki bengkak, dan kemarin hasil lab menunjukkan kreatinin saya naik menjadi 2,4. Saya khawatir dok, apakah ada masalah dengan kombinasi obat-obat yang saya konsumsi sekarang?	cyclosporin a, mycophenolate mofetil, clarithromycin	cyclosporin a–mycophenolate mofetil: 0,798; cyclosporin a–clarithromycin: 0,990; mycophenolate mofetil–clarithromycin: 0,353

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

No	Keluhan Pasien	Obat Terekstraksi	Probabilitas DDI
82	Dok, saya umur 68 tahun, hipertensi sejak 10 tahun lalu dan sudah lama minum lisinopril 20 mg dan hydrochlorothiazide 25 mg setiap pagi. Tekanan darah saya biasanya terkontrol di sekitar 130/80. Sebulan terakhir nyeri lutut karena osteoarthritis kambuh berat, jadi saya beli ibuprofen 400 mg di apotek dan minum tiga kali sehari secara rutin. Tiga hari ini saya merasa jauh lebih lemas dari biasanya, frekuensi kencing berkurang drastis, kaki bengkak, dan tekanan darah malah naik menjadi 160/95. Saya juga merasa mual. Apakah ini berkaitan dengan kombinasi obat-obat saya?	lisinopril, hydrochlorothiazide	lisinopril–hydrochlorothiazide: 0,088

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

No	Keluhan Pasien	Obat Terekstraksi	Probabilitas DDI
83	Selamat siang dokter. Saya pria 65 tahun dengan riwayat infark miokard dua tahun lalu. Sejak itu saya rutin minum simvastatin 40 mg setiap malam, aspirin 80 mg setiap pagi, metoprolol 50 mg dua kali sehari, dan warfarin 3 mg karena saya juga punya atrial fibrilasi. Bulan lalu kontrol jantung saya kurang stabil, jadi dokter spesialis menambahkan amiodarone 200 mg sehari. Sejak dua minggu lalu, betis dan paha saya terasa sangat nyeri seperti habis olahraga berat padahal saya tidak banyak aktivitas, otot terasa lemah saat naik tangga, dan kemarin urin saya warnanya gelap seperti teh. Apakah ada hubungannya dengan obat-obat yang saya konsumsi?	simvastatin, metoprolol, warfarin	simvastatin–metoprolol: 0,028; simvastatin–warfarin: 0,876; metoprolol–warfarin: 0,206

LAMPIRAN C

Konfigurasi *Hyperparameter* Pelatihan Model

Lampiran ini memuat rincian konfigurasi hyperparameter yang digunakan pada pelatihan modul NER (IndoBERT-CRF) dan modul DDI (MFFGNN), termasuk konfigurasi modul RAG. Seluruh nilai diambil langsung dari berkas konfigurasi sistem (`configs/default.yaml`) untuk memastikan reproducibilitas hasil eksperimen yang dilaporkan pada Bab V dan Bab VI.

C.1 Modul NER (IndoBERT-CRF)

Tabel C.1 memuat konfigurasi pelatihan model NER berbasis IndoBERT-CRF. Strategi pembekuan 11 dari 12 *layer* BERT serta lapisan *embedding* dipilih untuk membatasi kebutuhan memori pada pelatihan berbasis CPU.

Tabel C.1 Konfigurasi Hyperparameter Pelatihan Modul NER

Parameter	Nilai
Model dasar (<i>backbone</i>)	indobenchmark/indobert-base-p1
Jumlah label	7 (O, B-DRUG, I-DRUG, B-SYMPTOM, I-SYMPTOM, B-DISEASE, I-DISEASE)
Panjang <i>sequence</i> maksimum	64 <i>token subword</i>
Jumlah <i>epoch</i>	1
<i>Batch size</i>	4
<i>Effective batch size</i> (dengan akumulasi gradien)	4
<i>Learning rate</i>	$2,0 \times 10^{-5}$
<i>Optimizer</i>	AdamW
<i>Weight decay</i>	0,01
<i>Warmup ratio</i>	0,1
<i>Dropout</i>	0,1
<i>Max gradient norm (clipping)</i>	1,0
<i>Scheduler</i>	<i>Linear schedule with warmup</i>
Layer BERT yang dibekukan	11 dari 12 <i>layer</i>
<i>Embedding layer</i>	Dibekukan
Strategi validasi	Validasi silang 5-fold
<i>Random seed</i>	42

C.2 Modul DDI (MFFGNN)

Tabel C.2 memuat konfigurasi tiga komponen *encoder* pada MFFGNN, yaitu SMILES *encoder*, *molecular graph encoder*, dan DDI *graph encoder*, serta mekanisme *fusion* dan *predictor*. Nilai *learning rate* dan *scheduler decay* merujuk pada pengaturan asli MFFGNN (He, Liu, Li, dkk. 2022).

Tabel C.2 Konfigurasi Hyperparameter Pelatihan Modul DDI

Parameter	Nilai
SMILES encoder (Bi-GRU)	
<i>Vocab size</i>	128 (ASCII)
Dimensi <i>embedding</i>	64
Dimensi <i>hidden</i>	128
Jumlah <i>layer</i>	2
<i>Dropout</i>	0,2
<i>Bidirectional</i>	Ya
<i>Attention</i>	Ya
Molecular graph encoder (GIN + GWU)	
Dimensi fitur atom	143
Dimensi <i>hidden</i>	128
Jumlah <i>layer</i> GIN	3
<i>Dropout</i>	0,2
<i>Graph Wavelet Unitary</i> (GWU)	Aktif
DDI graph encoder (GCN)	
Dimensi masukan	128
Dimensi <i>hidden</i>	128
Jumlah <i>layer</i>	2
<i>Dropout</i>	0,2
Fusion & Predictor	
Dimensi masukan <i>fusion</i>	[128, 128, 128]
Dimensi setelah <i>fusion</i>	128
<i>Gate type</i>	Atensi (<i>attention</i>)
Dimensi <i>hidden predictor</i>	256
<i>Dropout predictor</i>	0,3
Pelatihan	
Jumlah <i>epoch</i>	10
<i>Batch size</i>	32
<i>Learning rate</i>	$1,0 \times 10^{-3}$
<i>Optimizer</i>	Adam
<i>Weight decay</i>	$1,0 \times 10^{-5}$
<i>Scheduler</i>	<i>Exponential decay</i>
<i>Scheduler gamma</i>	0,96
Rasio <i>negative sampling</i> (neg:pos)	1:1
Pembagian data (<i>train:val:test</i>)	80:10:10 (<i>stratified</i>)

C.3 Modul RAG

Tabel C.3 memuat konfigurasi modul RAG yang mencakup model *embedding*, parameter *retrieval* pada indeks FAISS, dan parameter pemanggilan LLM Gemini.

Tabel C.3 Konfigurasi Modul RAG

Parameter	Nilai
Model <i>embedding</i>	sentence-transformers/ all-MiniLM-L6-v2
Ukuran <i>chunk</i> dokumen	500 karakter
<i>Chunk overlap</i>	50 karakter
<i>Top-k retrieval</i>	5 dokumen
<i>Score threshold</i>	0,3
Model LLM	gemini-2.5-flash
<i>Temperature</i>	0,3
<i>Max output tokens</i>	8.192
Bahasa keluaran	Bahasa Indonesia
Total dokumen pada indeks FAISS	592.122

LAMPIRAN D

Daftar Alias Nama Obat dan Kata Henti Pasca-Pemrosesan NER

Lampiran ini memuat daftar lengkap kamus alias nama obat dan kata henti (*stop-words*) pasca-pemrosesan NER yang digunakan oleh sistem. Kamus alias berperan memetakan nama obat Indonesia, *brand name*, dan bentuk penulisan non-standar ke nama yang terdaftar pada basis data ChCh-Miner sebagaimana dibahas pada Subbab VI.2.5. Adapun daftar kata henti digunakan untuk menyaring istilah laboratorium, kondisi tubuh, kelas obat generik, peran tenaga kesehatan, serta kata sehari-hari yang berpotensi terdeteksi sebagai entitas medis oleh modul NER, sebagaimana dibahas pada Subbab VI.7.

D.1 Kamus Alias Nama Obat

Kamus alias berisi 130 pemetaan yang dikelompokkan berdasarkan kelas farmakologis. Format setiap baris adalah *nama_masukan* → *nama_target* pada basis data ChCh-Miner.

Tabel D.1 Kamus Alias Nama Obat (130 Entri)

Nama Masukan	Nama Target (ChCh-Miner)
Analgesik / Anti-inflamasi	
paracetamol	acetaminophen
parasetamol	acetaminophen
pethidine	meperidine
lignocaine	lidocaine
lignocain	lidocaine
diklofenak	diclofenac
natrium diklofenak	diclofenac
piroksikam	piroxicam
meloksikam	meloxicam
asam mefenamat	mefenamic acid
kodein	codeine

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

Nama Masukan	Nama Target (ChCh-Miner)
morfin	morphine
fentanil	fentanyl
Kardiovaskular	
adrenalin	epinephrine
adrenaline	epinephrine
noradrenalin	norepinephrine
noradrenaline	norepinephrine
glyceryl trinitrate	nitroglycerin
amlodipin	amlodipine
nifedipin	nifedipine
kaptopril	captopril
kandesartan	candesartan cilexetil
klopidogrel	clopidogrel
rivaroksaban	rivaroxaban
digoksin	digoxin
amiodaron	amiodarone
spironolakton	spironolactone
hidroklorotiazid	hydrochlorothiazide
furosemid	furosemide
frusemide	furosemide
Bronkodilator dan Diuretik	
albuterol	salbutamol
teofilin	theophylline
bendrofluazide	bendroflumethiazide
Antibiotik dan Anti-TB	
amoksisilin	amoxicillin
siprofloksasin	ciprofloxacin
levofloksasin	levofloxacin
eritromisin	erythromycin
azitromisin	azithromycin
klaritromisin	clarithromycin
gentamisin	gentamicin
amikasin	amikacin

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

Nama Masukan	Nama Target (ChCh-Miner)
sefadroksil	cefadroxil
sefaleksin	cephalexin
seftriakson	ceftriaxone
kotrimoksazol	trimethoprim
sulfametoksazol	sulfamethoxazole
metronidazol	metronidazole
rifampisin	rifampicin
rifampin	rifampicin
etambutol	ethambutol
pirazinamid	pyrazinamide
Antifungal dan Antiviral	
flukonazol	fluconazole
itrakonazol	itraconazole
asiklovir	acyclovir
tribavirin	ribavirin
Antidiabetik dan Penurun Lipid	
glibenklamid	glibenclamide
glyburide	glibenclamide
pioglitazon	pioglitazone
kanagliflozin	canagliflozin
fenofibrat	fenofibrate
Antikonvulsan / Neuropsikiatri	
karbamazepin	carbamazepine
fenitoin	phenytoin
fenobarbital	phenobarbital
asam valproat	valproic acid
valproat	valproic acid
klonazepam	clonazepam
Antipsikotik dan Antidepresan	
klorpromazin	chlorpromazine
risperidon	risperidone
olanzapin	olanzapine
quetiapin	quetiapine

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

Nama Masukan	Nama Target (ChCh-Miner)
klozapin	clozapine
fluoksetin	fluoxetine
sertralin	sertraline
paroksetin	paroxetine
amitriptilin	amitriptyline
duloksetin	duloxetine
venlafaksin	venlafaxine
litium	lithium ion
lithium	lithium ion
Kortikosteroid dan Obat Gastrointestinal	
deksametason	dexamethasone
prednison	prednisone
prednisolon	prednisolone
hidrokortison	cortisol
lansoprazol	lansoprazole
domperidon	domperidone
metoklopramid	metoclopramide
sukralfat	sucralfate (usan:usp:inn:ban:jan)
antasida	aluminum hydroxide
Imunosupresan dan Kemoterapi	
ciclosporin	cyclosporin a
cyclosporine	cyclosporin a
cyclosporin	cyclosporin a
siklosporin	cyclosporin a
mycophenolate	mycophenolate mofetil
mikofenolat	mycophenolate mofetil
metotreksat	methotrexate
siklofosfamid	cyclophosphamide
tamoksifen	tamoxifen
mitozantrone	mitoxantrone
Antihistamin	
setirizin	cetirizine
klorfeniramin	(+)-chlorpheniramine

Bersambung ke halaman berikutnya

Lanjutan dari halaman sebelumnya

Nama Masukan	Nama Target (ChCh-Miner)
chlorpheniramine	(+)-chlorpheniramine
ctm	(+)-chlorpheniramine
Penyesuaian Format ChCh-Miner	
ibuprofen	ibuprofen, (+)-
candesartan	candesartan cilexetil
galantamine	(-)-galantamine
galantamin	(-)-galantamine
doxepin	(z)-doxepin
doksepin	(z)-doxepin
vincristine	(+)-vincristine
tetrahydrozoline	(+)-tetrahydrozoline
quinacrine	(+)-quinacrine
carnitine	(-)-carnitine
karnitin	(-)-carnitine
Tambahan dari Analisis Kesalahan	
alkohol	ethanol
alcohol	ethanol
levothyroxine	thyroxine
levotiroksin	thyroxine
kalium klorida	potassium chloride
kalium	potassium chloride
kcl	potassium chloride
antalgin	metamizole
dipyrone	metamizole
metampiron	metamizole
Vitamin dan Suplemen	
vitamin c	l-ascorbic acid
asam askorbat	l-ascorbic acid
ascorbic acid	l-ascorbic acid
vitamin d	vitamin d3
vitamin d3	vitamin d3
kolekalsiferol	vitamin d3
cholecalciferol	vitamin d3

D.2 Kata Henti Pasca-Pemrosesan NER

Kata henti dipisahkan menjadi dua kategori: kata henti yang menyaring *false positive* entitas *DRUG* dan kata henti yang menyaring *false positive* entitas *SYMPTOM*. Penyaringan dilakukan setelah *decoding* CRF dan resolusi alias, sehingga istilah yang masuk pada salah satu kategori akan langsung dibuang dari hasil ekstraksi entitas.

Tabel D.2 Daftar Kata Henti Pasca-Pemrosesan NER

Kategori	Kata Henti
Kata henti entitas DRUG	
Bentuk sediaan umum	obat, obat-obatan, obatan, tablet, kapsul, pil, sirup, vitamin, suplemen, jamu, herbal, minum, dosis, resep
Makanan dan minuman	sayur, buah, nasi, air, makanan, minuman
Parameter laboratorium	inr, inr drop, hb, hemoglobin, leukosit, eritrosit, trombosit, gula, glukosa, gula darah, tekanan darah, kolesterol, trigliserida, hormon, elektrolit, kreatinin, urea, asam urat
Cairan tubuh dan spesimen	darah, urin, feses, dahak, sputum
Kelas obat generik	antiplatelet, antikoagulan, antibiotik, antibiotika, analgesik, antasid, nsaid, statin, diuretik, ace inhibitor, arb, ssri
Penyakit / kondisi (<i>false positive</i>)	atrial fibrilasi, atrial, fibrilasi, osteoarthritis, osteoarthritis, hipertensi, diabetes, asma, ppok, stroke, infark
Peran tenaga kesehatan	psikiater, dokter, apoteker, perawat
Kata henti entitas SYMPTOM	
Keterangan waktu dan intensitas	cuaca, hari, pagi, malam, siang, waktu, kali, sangat, sekali
Kata kerja dan keterangan umum	mau, ingin, bisa, tidak, sudah, belum, akan, harus, sering, jarang, baru, lama, cepat, lambat
Aktivitas sehari-hari	tidur, makan, jalan, kerja, duduk, berdiri, bicara, napas, pikir, rasa

Selain penyaringan kata henti, modul pasca-pemrosesan juga membuang *token* dengan panjang kurang dari 3 karakter, *token* numerik murni (mis. “500”, “20”), dan informasi dosis (mis. “5mg”, “200 mcg”) melalui ekspresi reguler. Akhiran bahasa Indonesia yang melekat pada entitas (*-nya*, *-mu*, *-ku*, *-lah*, *-kah*) juga dihapus sebelum proses resolusi alias.